UNIVERSITAS GADJAH MADA
PUSAT STUDI PENGELOLAAN
SUMBER DAYA LAHAN

MODUL

PELATIHAN PEMANFAATAN REMOTE SENSING DAN DIGITAL SOIL MAPPING

Untuk Pertanian Presisi pada Perkebunan Kelapa Sawit

2026



DAFTAR ISI

1. Pengantar Remote Sensing dan Digital Soil Mapping....7

1.1. Pengenalan Remote Sensing....7

1.2. Pemetaan Tanah Konvensional dan Pemetaan Tanah Digital....12

1.3. Peran Remote Sensing dan Digital Soil Mapping dalam Pertanian Presisi....14

2. Multi-source Data Fusion....16

2.1. Data untuk Multi-Source Data Fusion....16

2.2. Konsep Multi-source Data Fusion....17

3. Remote Sensing untuk Delineasi Soil Mapping Units (SMU)....19

3.1. Pemetaan Tanah....19

3.2. Soil Mapping Unit (SMU)....20

3.3. Prinsip Delineasi dengan Pendekatan Bentanglahan....23

3.4. Batas Delineasi Luasan Minimum....24

4. Remote Sensing untuk Estimasi Soil Properties....27

4.1. Indikator Remote Sensing untuk Estimasi Soil Properties....27

4.2. Faktor yang Memengaruhi Estimasi Soil Properties....36

5. Bare Soil Detection & Information Extraction....42

5.1. Permukaan Tanah, Vegetasi, dan Pantulan Spektral....42

5.2. Indeks yang Digunakan dalam Bare Soil Detection....46

5.3. Metode Bare Soil Detection....48

6. Interpretasi Pedologis dari Data Remote Sensing....52

6.1. Kunci Interpretasi Citra Penginderaan Jauh....52

6.2. Interpretasi Pola Citra Menjadi Informasi Pedologis....61

7. Proximal Soil Sensing....67

7.1. Konsep Proximal Soil Sensing....67

7.2. Perbedaan Remote Sensing dan Proximal Soil Sensing....71

7.3. Interpretasi Pantulan Spektral Proximal Soil Sensing....74
8. Pemodelan Digital Soil Mapping....78
8.1. SCORPAN Sebagai Variabel Lingkungan....78
8.2. Algoritma Digital Soil Mapping....82
8.3. Data Splitting....84
8.4. Pembuatan Model dan Validasi....86
8.5. Residual dan Uncertainty....89
DAFTAR PUSTAKA....93

DAFTAR GAMBAR

Gambar 1.1 Diagram alur proses penginderaan jauh....8
Gambar 1.2 Energi yang dipantulkan dan dipancarkan oleh sensor penginderaan jauh....9
Gambar 1.3 Spektrum gelombang elektromagnetik yang umum digunakan....9
Gambar 1.4 Pola respons spektral beberapa objek....10
Gambar 1.5 Diagram konsep SCORPAN....13
Gambar 1.6 Citra Landsat menunjukkan serangan hama serangga pada tanaman (kiri) dan peta estimasi hasil panen gandum (kanan)....15
Gambar 2.1 Ilustrasi tingkat fusi....17
Gambar 3.1 Distribusi material pada catena....23
Gambar 3.2 Visualisasi perbandingan hasil *overlay* bentuklahan, kemiringan lereng, dan penggunaan lahan (kiri), dan hasil generalisasi *overlay* bentuklahan, kemiringan lereng, dan penggunaan lahan berdasarkan MLA di Sub-DAS Bompon (kanan)....26
Gambar 4.1 Jalur estimasi langsung dan tidak langsung sifat tanah dari data penginderaan jauh 28
Gambar 4.2 Ilustrasi skematis fitur serapan pada spektrum pantulan tanah (a) serta posisi kanal Sentinel-2 dan sensor hiperspektral (b)....29
Gambar 4.3 Faktor-faktor yang memengaruhi sinyal tanah yang direkam sensor....36
Gambar 5.1 Ilustrasi pantulan tanah terbuka, vegetasi hijau, serta serasah dan sisa tanaman kering (a) dan perubahan nilai NDVI dan NBR2 pada campuran tanah dengan penutup di dalam satu piksel (b)....43
Gambar 5.2 Garis tanah serta sebaran vegetasi hijau dan serasah pada ruang pantulan merah–inframerah dekat....45
Gambar 5.3 Ilustrasi perubahan NDVI dan BSI pada satu blok peremajaan kelapa sawit dengan kacangan penutup tanah....50
Gambar 5.4 Alur umum deteksi tanah terbuka dari deret waktu citra....51
Gambar 6.1 Pola dasar aliran dan faktor geologi yang mengendalikannya....55
Gambar 6.2 Ilustrasi tekstur citra dan simpangan baku lokal dengan dua ukuran jendela....56
Gambar 6.3 Contoh kunci interpretasi bertingkat untuk satuan tanah–lanskap....61
Gambar 6.4 Ilustrasi pembobotan batas dari analisis beberapa unsur secara terpisah....62
Gambar 6.5 Ilustrasi hasil klasifikasi per piksel, klasifikasi berbasis objek, dan interpretasi pedologis pada kebun di atas punggungan....65

Gambar 7.1 Kedudukan sensor *proximal soil sensing* pada spektrum elektromagnetik dan sensor di luar spektrum tersebut.....69
Gambar 7.2 Kedalaman tanah yang diwakili oleh beberapa teknik penginderaan jauh dan *proximal soil sensing*.....73
Gambar 7.3 Pengaruh beberapa praolah terhadap spektrum pantulan.....75
Gambar 7.4 Alur pengukuran, pemodelan, dan prediksi sifat tanah dengan spektroskopi.....76
Gambar 8.1 Ilustrasi kovariat SCORPAN sebagai lapisan raster pada sebuah kebun dan titik sampel tanah di atasnya.....80
Gambar 8.2 Ilustrasi skema pembagian data pada sampel tanah yang mengelompok.....85
Gambar 8.3 Alur pembuatan model *digital soil mapping* dari data tanah dan kovariat hingga peta prediksi dan ketidakpastiannya.....87
Gambar 8.4 Ilustrasi pemanfaatan residual dalam *regression kriging* pada transek sintetis...90
Gambar 8.5 Ilustrasi validasi interval prediksi dengan PICP (a) dan wilayah keberlakuan model (b).....92

DAFTAR TABEL

Tabel 1.1 Resolusi Citra Satelit.....11

Tabel 2.1 Sumber Data untuk Multi-Source Data Fusion.....16

Tabel 3.1 Perbedaan metode analitik dan sintetik.....19

Tabel 3.2 Kategori peta tanah berdasarkan skala pemetaan.....22

Tabel 4.1 Indikator Penginderaan Jauh untuk Beberapa Sifat Tanah.....31

Tabel 4.2 Contoh Transformasi Indeks yang Berkaitan dengan Sifat Tanah.....34

Tabel 4.3 Faktor yang Memengaruhi Estimasi Sifat Tanah dan Upaya Pengendaliannya.....40

Tabel 5.1 Indeks untuk Deteksi Tanah Terbuka.....47

Tabel 6.1 Faktor Pembentuk Tanah dan Kenampakannya pada Data Penginderaan Jauh.....58

Tabel 6.2 Perbedaan Interpretasi Pedologis dan Klasifikasi Citra Otomatis.....63

Tabel 7.1 Jenis Sensor *Proximal Soil Sensing* untuk Karakterisasi Tanah.....69

Tabel 7.2 Perbedaan Penginderaan Jauh dan *Proximal Soil Sensing*.....71

Tabel 8.1 Faktor SCORPAN, Contoh Kovariat, dan Sumber Datanya.....79

Tabel 8.2 Perbandingan Kelompok Algoritma Digital Soil Mapping.....82

Tabel 8.3 Ukuran Ketelitian untuk Validasi Peta Sifat Tanah.....88

1. Pengantar Remote Sensing dan Digital Soil Mapping

Ceramah dan diskusi:

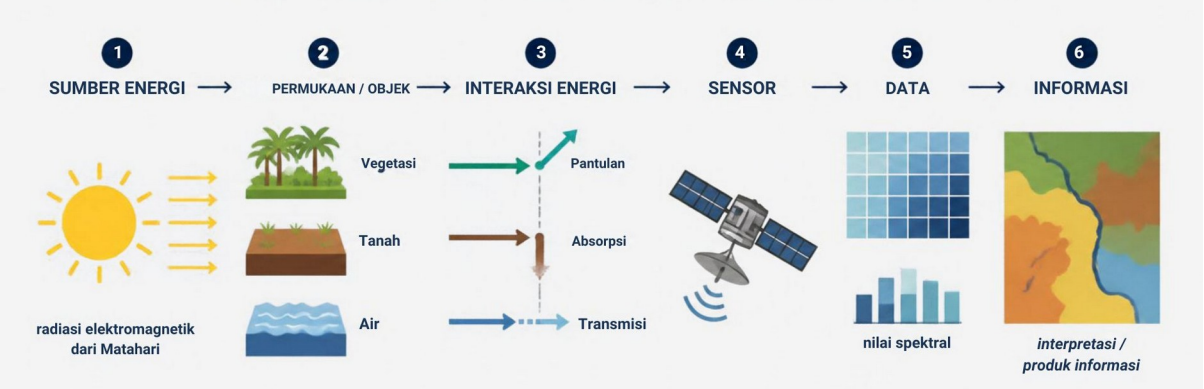
1.1. Pengenalan Remote Sensing

Remote sensing atau penginderaan jauh merupakan ilmu, seni, dan teknologi untuk memperoleh informasi mengenai suatu objek, fenomena, atau kondisi di permukaan bumi dengan menggunakan alat tanpa melakukan kontak langsung dengan objek yang diamati (Lillesand & Kiefer, 1990). Informasi tersebut diperoleh menggunakan alat pengindera atau sensor yang ditempatkan pada suatu wahana, seperti balon udara, pesawat terbang, pesawat ulang-alik, maupun satelit (Sutanto, 1994). Sutanto (1994) menjelaskan bahwa penginderaan jauh merupakan suatu teknik untuk memperoleh dan menganalisis informasi mengenai permukaan bumi berdasarkan energi elektromagnetik yang dipantulkan atau dipancarkan oleh suatu objek.

Penginderaan jauh merupakan teknologi yang memanfaatkan radiasi elektromagnetik atau spektrum energi lainnya untuk memperoleh informasi mengenai objek di permukaan bumi. Proses penginderaan jauh melibatkan empat komponen utama, yaitu sumber energi, objek, atmosfer, dan sensor dengan rincian sebagai berikut:

1. **Sumber energi**, radiasi elektromagnetik dalam penginderaan jauh berasal dari sumber alami seperti matahari atau sumber energi buatan dari sensor, yang membedakan sistem pasif dan aktif.
2. **Objek**, objek penginderaan jauh meliputi berbagai kenampakan di permukaan bumi, seperti tanah, air, vegetasi, dan objek hasil aktivitas manusia.
3. **Interaksi atmosfer**, atmosfer menjadi media perambatan energi elektromagnetik yang dapat menyebabkan penyerapan dan hamburan sehingga memengaruhi energi yang diterima sensor.
4. **Sensor**, sensor merupakan perangkat yang merekam energi elektromagnetik dari objek di permukaan bumi dan mengubahnya menjadi data yang dapat diolah menjadi informasi.

Berdasarkan komponen utama tersebut remote sensing melibatkan energi elektromagnetik yang berinteraksi dengan objek di permukaan bumi akan mengalami proses pemantulan, penyerapan, atau transmisi, kemudian energi yang diterima oleh sensor direkam sebagai data. Data tersebut selanjutnya diolah dan diinterpretasikan untuk menghasilkan informasi mengenai karakteristik objek atau fenomena di permukaan bumi. Sistem remote sensing tersebut ditunjukkan pada Gambar 1.1.



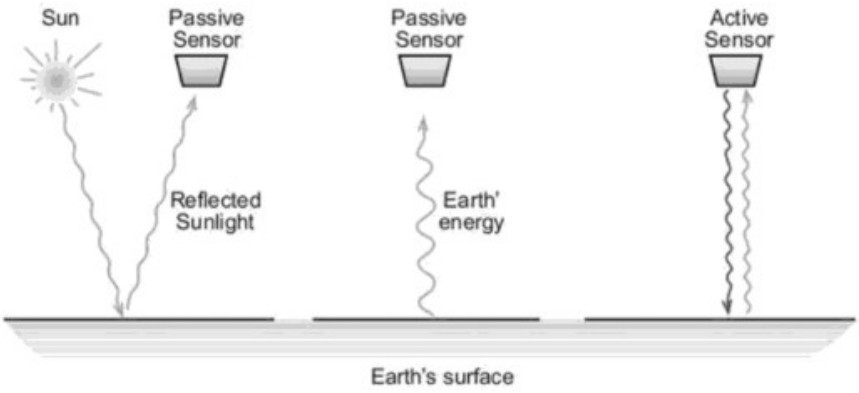
Gambar 1.1 Diagram alur proses penginderaan jauh

Sumber energi dalam penginderaan jauh terdiri dari energi aktif dan energi pasif. Energi yang berasal dari radiasi matahari disebut dengan sensor pasif, sedangkan energi yang berasal dari sinyal buatan yang dapat memancarkan sendiri oleh satelit disebut dengan sensor aktif. Contoh sensor pasif yang digunakan dalam penginderaan jauh antara lain Sentinel-2 MSI, Landsat OLI, dan MODIS, sementara itu, sensor aktif dalam penginderaan jauh antara lain RADAR (Sentinel-1 SAR), ALOS PALSAR, dan LiDAR.

Energi yang umum digunakan dalam sensor aktif maupun pasif berupa gelombang elektromagnetik, seperti gelombang radio, inframerah, dan cahaya tampak. Ketika energi elektromagnetik mengenai suatu objek di permukaan bumi, energi tersebut dapat mengalami tiga bentuk interaksi, yaitu dipantulkan, diserap, atau diteruskan (ditransmisikan) (Danoedoro, 2012). Dengan menerapkan hukum kekekalan energi, hubungan timbal balik antara tiga jenis interaksi tenaga tersebut dapat dinyatakan sebagai berikut:

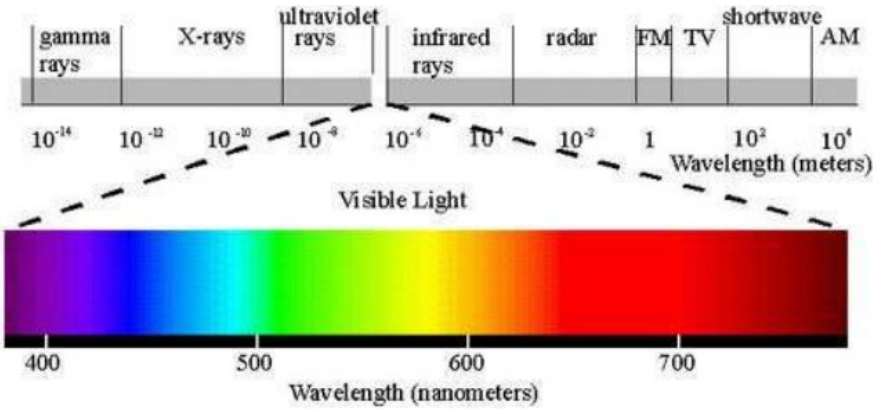
$EI(\lambda) = ER(\lambda) + EA(\lambda) + ET(\lambda)$

dimana: EI = tenaga yang mengenai benda
ER = tenaga yang dipantulkan
EA = tenaga yang diserap
ET = tenaga yang ditransmisikan



Gambar 1.2 Energi yang dipantulkan dan dipancarkan oleh sensor penginderaan jauh
Sumber: Syah, 2010

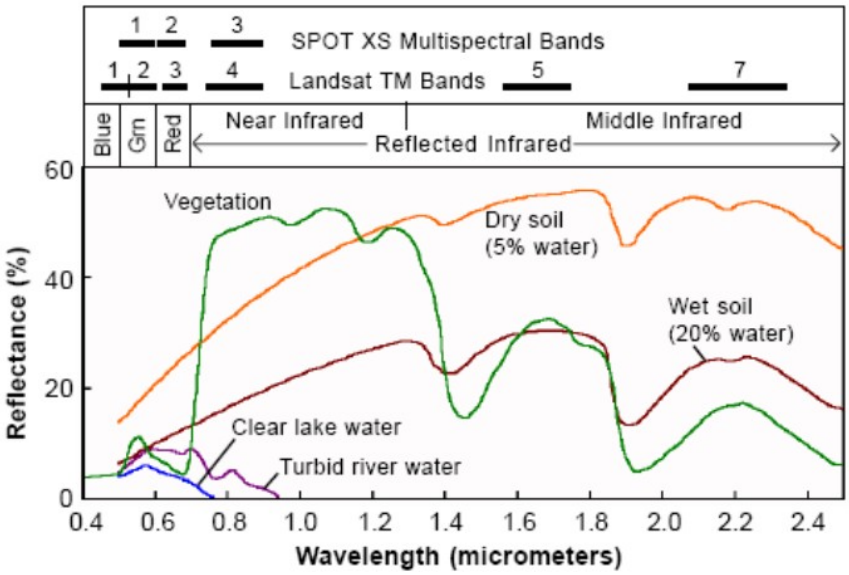
Susunan seluruh gelombang elektromagnetik berdasarkan panjang gelombangnya disebut spektrum elektromagnetik (Gambar 1.3). Gambar spektrum elektromagnetik dibawah ini disusun berdasarkan panjang gelombang mencakup kisaran energi yang sangat rendah, dengan panjang gelombang tinggi dan frekuensi rendah. Setiap objek memiliki struktur partikel yang berbeda, baik pada skala mikro maupun makro, sehingga menghasilkan pola respons elektromagnetik yang berbeda. Perbedaan respons tersebut menjadi dasar dalam membedakan objek melalui penginderaan jauh. Setiap objek memberikan respons yang berbeda terhadap gelombang elektromagnetik pada panjang gelombang tertentu.



Gambar 1.3 Spektrum gelombang elektromagnetik yang umum digunakan
Sumber: Jensen, 2004

Pola pantulan spektral setiap objek pada Gambar 1.4 menunjukkan karakteristik yang berbeda pada berbagai panjang gelombang, yang dapat dijelaskan sebagai berikut:

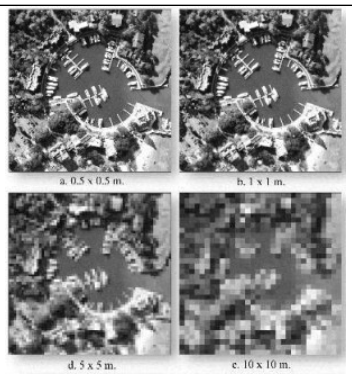
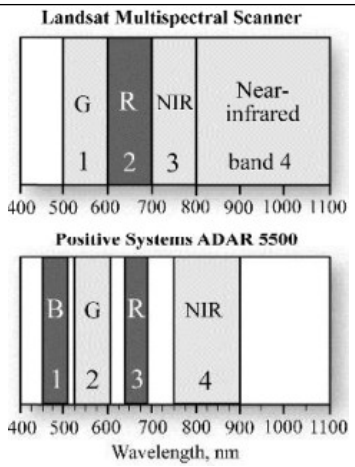
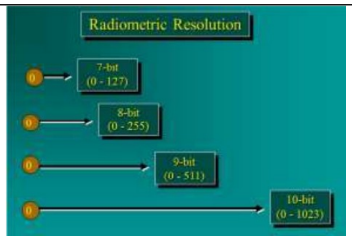
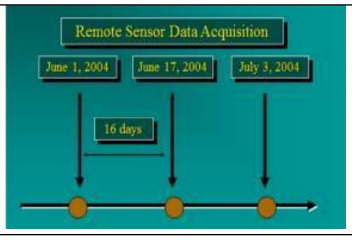
a. **Vegetasi (garis hijau)** memiliki pantulan rendah pada wilayah cahaya tampak, terutama pada kanal merah, kemudian mengalami peningkatan tajam pada inframerah dekat (NIR) sekitar 0,7 µm. Pantulan kembali menurun pada 1,4 dan 1,9 µm karena penyerapan oleh kandungan air dalam vegetasi.
b. **Tanah kering (garis oranye)** menunjukkan pantulan yang relatif tinggi dan meningkat secara bertahap dari wilayah tampak menuju inframerah dekat dan inframerah tengah. Pantulannya lebih tinggi dibandingkan tanah basah karena kandungan air yang lebih rendah.
c. **Tanah basah (garis cokelat)** memiliki pantulan lebih rendah dibandingkan tanah kering. Kandungan air menyebabkan penyerapan energi elektromagnetik sehingga nilai reflektansinya menurun.
d. **Air jernih (garis biru)** memiliki pantulan sangat rendah, terutama pada wilayah inframerah dekat dan inframerah tengah karena energi elektromagnetik pada wilayah tersebut banyak diserap oleh air.
e. **Air keruh (garis ungu)** menunjukkan pantulan sedikit lebih tinggi dibandingkan air jernih pada beberapa panjang gelombang karena adanya material tersuspensi di dalam air.



Gambar 1.4 Pola respons spektral beberapa objek
Sumber: Jensen, 2004

Kemampuan sensor penginderaan jauh dalam merekam dan membedakan informasi objek secara detail, terdiri atas resolusi spasial, spektral, radiometrik, dan temporal. Rincian jenis resolusi penginderaan jauh disajikan pada Tabel 1.1.

Tabel 1.1 Resolusi Citra Satelit

Resolusi	Keterangan	Ilustrasi
Spasial	Ukuran objek terkecil yang masih dapat dideteksi oleh sistem pencitraan	
Spektral	Kemampuan sistem optik-elektronik untuk membedakan informasi objek berdasarkan pantulan atau pancaran spektralnya.	
Radiometrik	Kemampuan sensor dalam mencatat respons spektral objek	
Temporal	Kemampuan suatu sistem satelit untuk merekam kembali wilayah yang sama dalam selang waktu tertentu	

Sumber: Jensen, 2004

1.2. Pemetaan Tanah Konvensional dan Pemetaan Tanah Digital

Pemahaman mengenai pola sifat tanah sangat penting dalam pertanian untuk meningkatkan produktivitas dan mendukung pengelolaan lahan yang berkelanjutan (Hosseinpour-Zarnaq et al., 2025). Variasi dan distribusi tanah pada suatu lanskap terbentuk melalui interaksi berbagai faktor pembentuk tanah, yaitu iklim, organisme, bahan induk, topografi, dan waktu Pola dan distribusi sifat tanah dapat dipahami secara spasial melalui peta tanah. Pemetaan tanah merupakan kegiatan untuk memperoleh informasi mengenai jenis, sifat, dan distribusi tanah pada suatu wilayah. Pemetaan tanah dapat dilakukan melalui pendekatan konvensional maupun digital, yang memiliki perbedaan pada metode pengumpulan data, analisis, dan penyajian informasi spasial.

Pemetaan tanah konvensional mengandalkan survei lapangan yang meliputi pengamatan profil tanah, pengambilan sampel, analisis laboratorium, interpretasi lanskap, dan delineasi satuan tanah. Pengamatan lapangan memberikan informasi langsung mengenai karakteristik tanah yang kemudian diinterpretasikan dalam kaitannya dengan kondisi lingkungan dan lanskap. Pemetaan tanah dengan pendekatan survei konvensional membutuhkan waktu dan biaya yang relatif besar serta memiliki keterbatasan dalam pemantauan tanah pada skala luas (Lu *et al*., 2023). *Digital Soil Mapping* (DSM) atau pemetaan tanah digital dikembangkan untuk mengatasi keterbatasan tersebut melalui pemanfaatan data lingkungan, teknologi geospasial, dan pemodelan untuk menghasilkan informasi tanah secara spasial.

Pendekatan geografis dalam pemetaan tanah berkembang melalui berbagai metode geostatistik, seperti *trend surfaces*, *kriging*, dan *co-kriging*. Selanjutnya, konsep faktor pembentuk tanah yang dikemukakan oleh Jenny dikembangkan menjadi fungsi prediksi spasial tanah melalui hubungan kuantitatif empiris antara sifat tanah dan faktor lingkungan. Pendekatan tersebut dikenal sebagai konsep SCORPAN yang mencakup tujuh faktor, yaitu *soil, climate, organisms, relief, parent material, age,* dan *spatial position* (McBratney *et al*., 2003).



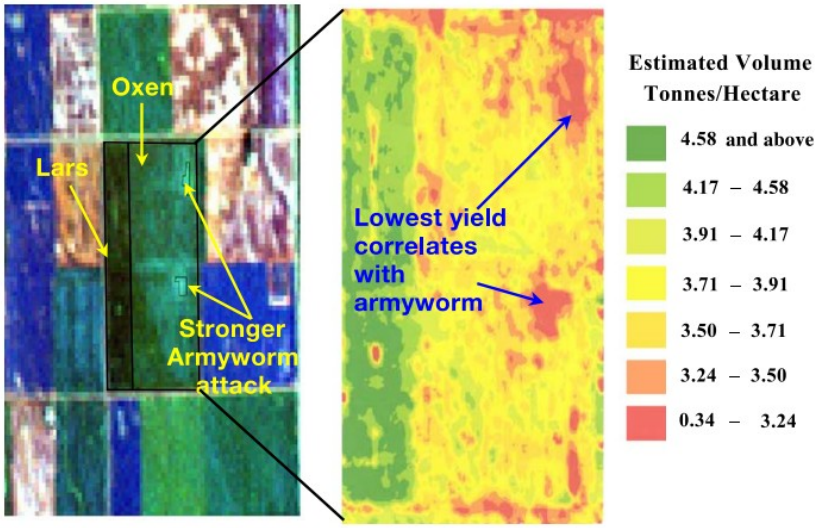
Gambar 1.5 Diagram konsep SCORPAN

1.3. Peran Remote Sensing dan Digital Soil Mapping dalam Pertanian Presisi

Pertanian presisi, yang sering disebut juga sebagai pengelolaan tanaman spesifik lokasi, merupakan penerapan teknologi dan prinsip untuk mengelola variabilitas spasial dan temporal yang berkaitan dengan berbagai aspek produksi pertanian. Pertanian presisi didefinisikan sebagai suatu sistem yang mengintegrasikan informasi dengan produksi tanaman untuk meningkatkan efisiensi, produktivitas, dan profitabilitas produksi pertanian dalam jangka panjang dan secara spesifik lokasi, serta meminimalkan dampak yang tidak diinginkan terhadap ekosistem (Elsharkawy et al., 2022; Mukhamedova et al., 2022).

Penggunaan remote sensing memiliki potensi penting dalam mendukung penerapan pertanian presisi (Briliyanti et al., 2025). Pemanfaatan penginderaan jauh yang terintegrasi dengan GPS, Sistem Informasi Geografis (SIG), serta berbagai teknologi pendukung lainnya berperan dalam memperoleh dan mengolah informasi spasial untuk mendukung pengelolaan lahan secara spesifik lokasi (Mooy & Watuwaya, 2023). Integrasi berbagai teknologi tersebut memungkinkan pengembangan beragam aplikasi, termasuk pemetaan tanah dan pemantauan pertumbuhan tanaman (Martos et al., 2021; Segarra et al., 2020). Pada perkebunan sawit iformasi tersebut dapat dimanfaatkan meningkatkan ketepatan dalam perencanaan dan mendukung efisiensi penggunaan sumber daya pertanian, termasuk air dan pupuk.

Salah satu informasi penting dalam pengelolaan lahan secara spesifik lokasi adalah informasi mengenai sifat dan variabilitas tanah. Dalam konteks tersebut, Digital Soil Mapping (DSM) dapat digunakan untuk mengestimasi dan memetakan berbagai sifat tanah secara spasial berdasarkan data tanah dan informasi lingkungan. Informasi yang dihasilkan dapat berupa sifat fisik maupun kimia tanah, seperti tekstur, kelembapan, pH, bahan organik, dan indikator kesuburan tanah. Informasi tersebut selanjutnya dapat menjadi dasar dalam pengelolaan lahan spesifik lokasi dan melengkapi berbagai aplikasi pertanian presisi lainnya, seperti deteksi tekanan biotik berupa serangan hama dan penyakit serta tekanan abiotik seperti kekeringan dan banjir hingga estimasi hasil pertanian (Pascucci et al., 2020; Weiss et al., 2020).



Gambar 1.6 Citra Landsat menunjukkan serangan hama serangga pada tanaman (kiri) dan peta estimasi hasil panen gandum (kanan)
Sumber: Seelan et al., 2003

Penerapan pertanian presisi pada perkebunan kelapa sawit didasarkan pada pemanfaatan informasi mengenai berbagai faktor yang memengaruhi produksi, seperti kondisi iklim, kondisi dan kesuburan tanah, umur tanaman, serta faktor lainnya. Penerapan pertanian presisi pada perkebunan kelapa sawit untuk mendukung estimasi produksi juga memanfaatkan informasi indeks tanaman yang diperoleh dari citra satelit. Selain informasi indeks tanaman, berbagai faktor eksternal yang memengaruhi produksi, seperti curah hujan, kesuburan tanah, dan serangan hama dan penyakit, serta faktor internal seperti jumlah tanaman, varietas, dan umur tanaman dapat diintegrasikan dengan berbagai teknologi komputerisasi untuk mendukung pengelolaan perkebunan secara spesifik lokasi (Ginting & Wiratmoko, 2021).

2. Multi-source Data Fusion

Ceramah dan diskusi:

2.1. Data untuk Multi-Source Data Fusion

Setiap sumber data memiliki karakteristik dan informasi yang berbeda. Pemahaman terhadap karakteristik tersebut menjadi dasar dalam menentukan jenis data yang dapat diintegrasikan sesuai dengan tujuan analisis. Beberapa jenis sumber data yang umum digunakan dalam Multi-Source Data Fusion disajikan pada Tabel 2.1.

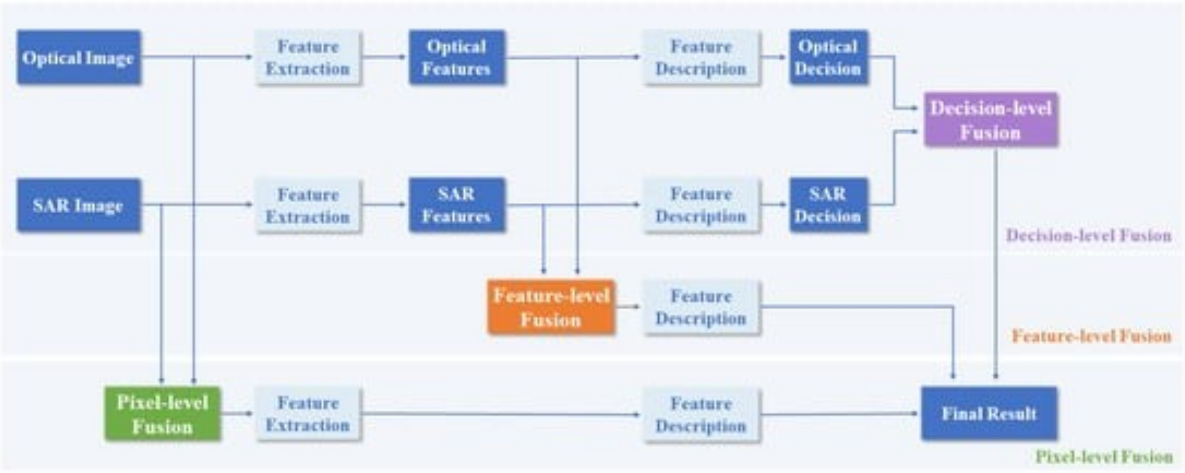
Tabel 2.1 Sumber Data untuk Multi-Source Data Fusion

Sumber Data	**Karakteristik**	**Contoh**	**Produk Turunan**
Optical remote sensing	- Menggunakan pantulan cahaya matahari (sensor pasif) - Menampilkan visual objek (seperti foto udara)	Sentinel-2, Landsat 8, SPOT, Worldview	NDVI, EVI, BSI
SAR *(Synthetic Aperture Radar)*	- Menggunakan gelombang mikro (sensor aktif) - Sensitif terhadap kekasaran permukaan, bentuk fisik objek, dan kelembapan tanah	Sentinel-1, ALOS PALSAR, TerraSAR-X	Backscatter HH, VV, HV, VH, rasio polarisasi
LiDAR (*Light Detection and Ranging*)	- Menggunakan pulsa laser (sensor aktif) - Kemampuan menembus celah vegetasi rapat untuk merekam tanah asli	Airborne LiDAR	CHM, DTM, DSM
DEM *(Digital Elevation Model)*	- Hasil pengolahan data SAR, LiDAR atau foto udara - Menampilkan nilai elevasi permukaan bumi	DEMNAS, SRTM	Slope, TWI, flow accumulation

2.2. Konsep Multi-source Data Fusion

Data fusion merupakan pendekatan multidisiplin yang menggabungkan informasi dari data *multi-source* untuk meningkatkan nilai informasi, kinerja interpretasi, serta kualitas representasi visual data. Teknik ini dapat dimanfaatkan dalam deteksi, pengenalan, identifikasi, dan klasifikasi objek, pemantauan objek, deteksi perubahan, serta pendukung pengambilan keputusan (Zhang, 2010). Integrasi data penginderaan jauh dari berbagai sumber dengan teknologi deep learning semakin berkembang dalam mendukung pertanian presisi (Ma *et al*., 2026).

Fusi data penginderaan jauh merupakan teknik yang banyak digunakan untuk mengintegrasikan informasi dari berbagai sensor yang memiliki karakteristik resolusi spasial dan spektral berbeda. Proses integrasi ini bertujuan menghasilkan dataset yang lebih informatif dan detail melalui pemanfaatan informasi yang saling melengkapi dari setiap sumber data. Secara umum, fusi data penginderaan jauh dibedakan menjadi tiga tingkatan berdasarkan tahap integrasi informasi yang dilakukan, yaitu fusi tingkat piksel atau data (*the pixel/data level*), fusi tingkat fitur (*the feature level*), dan fusi tingkat keputusan (*the decision level*) (Pohl & van Genderen, 1998), yang diilustrasikan pada Gambar 2.1.



Gambar 2.1 Ilustrasi tingkat fusi
Sumber: Ma et al., 2026

Setiap tingkat fusi memiliki tujuan dan pendekatan yang berbeda, bergantung pada jenis informasi yang digabungkan. Perbedaan tersebut dapat dilihat melalui karakteristik dan contoh penerapannya dalam pengolahan data penginderaan jauh berikut.

1. **Fusi tingkat piksel atau data (*the pixel/data level*)**

   Fusi tingkat piksel pada citra optik bertujuan untuk meningkatkan resolusi spasial dan detail tekstural (pan-sharpening). Pada citra multitemporal bertujuan untuk mengidentifikasi perubahan antar-waktu. Misalnya, menggabungkan citra pankromatik resolusi tinggi dengan citra multispektral resolusi lebih rendah untuk menghasikan citra berwarna dengan resolusi spasial lebih tinggi.

2. **Fusi tingkat fitur (*the feature level*)**

   Fusi tingkat fitur bertujuan untuk menggabungkan fitur atau parameter yang diekstrak dari beberapa sumber data. Misalnya, menggabungkan NDVI dari Sentinel-2 dengan backscatter HH dan HV dari ALOS PALSAR untuk klasifikasi tutupan lahan.

3. **Fusi tingkat keputusan (*the decision level*)**

   Fusi tingkat keputusan menggabungkan hasil klasifikasi atau prediksi dari beberapa algoritma untuk menghasilkan keputusan akhir. Misanya, menggabungkan hasil klasifikasi tutupan lahan dari Sentinel-2 dan ALOS PALSAR menggunakan *majority voting*.

3. Remote Sensing untuk Delineasi Soil Mapping Units (SMU)

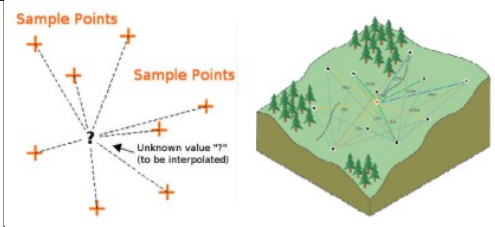
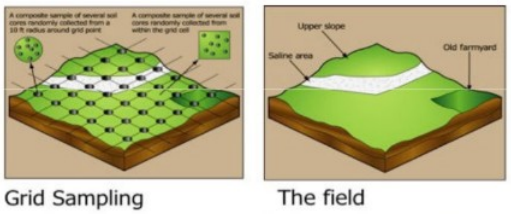
Ceramah dan diskusi:

3.1. Pemetaan Tanah

Pemetaan tanah atau survei tanah merupakan kegiatan sistematis untuk mengidentifikasi, mengklasifikasikan, dan menggambarkan persebaran satuan-satuan tanah di suatu wilayah. Hasil kegiatan ini disajikan dalam bentuk peta tanah dengan skala yang disesuaikan dengan tujuan pemetaan dan kebutuhan pengguna (Sartohadi et al., 2022). Secara umum, tahapan pemetaan tanah meliputi penentuan lokasi dan jumlah pengamatan, pengamatan/deskripsi tanah, pengambilan contoh tanah, klasifikasi tanah, penyusunan peta, serta interpretasi tanah.

Metode **penentuan lokasi pengamatan** tanah pada umumnya dikelompokkan menjadi dua, yaitu metode analitik dan sintetik. Kedua metode memiliki kelebihan dan keunggulan masing-masing. Perbedaan dari kedua metode disajikan pada Tabel 3.1.

Tabel 3.1 Perbedaan metode analitik dan sintetik

Aspek	Metode Analitik	Metode Sintetik
Prinsip	Mengidentifikasi perbedaan satuan tanah berdasarkan parameter atau karakteristik tanah tertentu	Memperkirakan persebaran satuan tanah berdasarkan konsep pola persebaran tanah dan kondisi bentanglahan
Skala pemetaan	Lebih sesuai untuk pemetaan tanah tingkat detail (skala 1:10.000 atau lebih besar)	Lebih sesuai untuk pemetaan tanah tingkat tinjau (skala 1:250.000)
Sampling tanah	Sampling tanah dilakukan menggunakan grid dan pemetaan dilakukan dengan menginterpolasi variabel tanah dari masing-masing grid	Sampling tanah dilakukan berdasarkan delineasi landscape dan pemetaan dilakukan berdasar satuan unit landscape
Ilustrasi		 Grid Sampling The field

Jumlah dan lokasi pengamatan pada metode analitik dapat ditentukan sebelum kegiatan lapangan dengan pola teratur berdasarkan jarak dan arah tertentu, sedangkan pada metode sintetik, lokasi dan jumlah pengamatan dapat disesuaikan selama survei berdasarkan keragaman medan dan bentanglahan. Pengamatan atau deskripsi tanah di lapangan dilakukan melalui pengamatan profil tanah dan pemboran. Pengamatan profil tanah memberikan informasi karakteristik tanah secara lengkap dan terperinci, sedangkan pengamatan melalui pemboran hanya mencakup sifat-sifat tanah tertentu dengan tingkat ketelitian yang lebih rendah.

Pengambilan contoh tanah untuk analisis laboratorium ditentukan berdasarkan tujuan pemetaan tanah. Contoh tanah untuk analisis laboratorium dibedakan menjadi dua jenis, yaitu contoh tanah tunggal dan contoh tanah komposit. Contoh tanah tunggal diambil dari satu horizon tanah tertentu dan umumnya digunakan untuk analisis karakteristik serta klasifikasi tanah. Sedangkan, contoh tanah komposit merupakan campuran beberapa contoh tanah yang diambil secara proporsional dari satu atau beberapa lokasi pengamatan dan umumnya digunakan untuk menganalisis potensi kesuburan tanah.

Penyusunan peta tanah merupakan proses penentuan batas persebaran satuan tanah dan penyajian informasi secara kartografis agar mudah dipahami. Penentuan batas-batas (delineasi) satuan tanah dapat dilakukan melalui pendekatan statistik dan bentanglahan. Batas satuan tanah dengan pendekatan statistik didasarkan pada analisis kecenderungan dan interpolasi antar titik pengamatan. Pendekatan bentanglahan umumnya menggunakan relief sebagai parameter utama untuk membedakan satuan tanah, tetapi dapat mempertimbangkan karakteristik lain, seperti penggunaan lahan.

Interpretasi tanah merupakan tahap akhir pemetaan tanah yang bertujuan menerjemahkan informasi hasil survei menjadi informasi yang relevan bagi pengguna. Interpretasi ini menekankan potensi, keterbatasan, risiko kerusakan, dan kesesuaian tanah untuk berbagai penggunaan lahan, sehingga lebih mudah digunakan sebagai dasar pengambilan keputusan dibandingkan sekadar mengetahui nama satuan tanah yang terasa asing.

3.2. Soil Mapping Unit (SMU)

Terdapat dua istilah yang memiliki makna berbeda dalam pemetaan tanah, yaitu satuan pemetaan lahan *(land mapping unit)*, satuan tanah *(soil unit)*. Gabungan keduanya membentuk satuan pemetaan tanah (*soil mapping unit*), yang secara praktis disingkat menjadi SEPERTI

(Satuan Peta Tanah). Setiap SPT dapat terdiri atas beberapa satuan tanah yang memiliki potensi penggunaan dan tingkat pembatas yang relatif serupa. Penamaan SPT umumnya didasarkan pada satuan tanah yang dominan, yaitu memiliki proporsi lebih dari 70%, atau relatif dominan, sekitar 50% dari keseluruhan satuan tanah penyusunnya.

Nama SPT mengandung paling tidak tiga informasi, yaitu: (1) nama satuan relief, (2) nama satuan tanah, dan (3) komposisi satuan-satuan penyusunnya. Satuan relief ditentukan berdasarkan satuan geomorfologi yang disesuaikan dengan skala pemetaan. Satuan geomorfologi mencerminkan karakteristik relief, batuan penyusun, serta jenis dan intensitas proses geomorfologi yang berlangsung. Nama satuan geomorfologis tidak dicantumkan dalam nama SPT, namun dijelaskan dalam buku deskripsi peta tanah yang menyertai publikasi peta tanah resmi. Nama satuan tanah dan komposisi satuan-satuan tanah yang terkandung di dalamnya menjadi penyusun nama SPT. Berdasarkan komposisi satuan-satuan tanah dalam satuan lahan yang digunakan sebagai satuan pemetaan tanah, SPT dibedakan menjadi empat jenis, yaitu:

- **Konsosiasi (*consociation*)**, yaitu satuan pemetaan tanah yang didominasi oleh satu satuan tanah yang sama, dengan sekurang-kurangnya 50% tanah yang sama, 25% tanah serupa, dan maksimal 25% tanah tidak serupa. Penamaan SPT didasarkan pada satuan tanah yang dominan. Tanah serupa memiliki perbedaan pada satu atau dua kriteria klasifikasi dan umumnya mempunyai potensi penggunaan yang hampir sama.
- **Asosiasi tanah (*soil association*)**, yaitu satuan pemetaan tanah yang terdiri atas dua atau lebih satuan tanah yang tidak serupa, tetapi memiliki pola persebaran geografis yang teratur. Satuan tanah penyusunnya belum dapat dipisahkan pada skala pemetaan yang digunakan, tetapi dapat dipisahkan pada skala yang lebih besar.
- **Kompleks tanah (*soil complex*)**, yaitu satuan pemetaan tanah yang terdiri atas dua atau lebih satuan tanah yang tidak serupa dengan pola persebaran yang tidak teratur. Satuan-satuan tanah penyusunnya tetap sulit dipisahkan meskipun dilakukan pemetaan pada skala yang lebih besar.
- **Kelompok tak dibedakan (*undifferentiated group*)**, yaitu satuan pemetaan tanah yang terdiri atas dua atau lebih satuan tanah yang tidak serupa, tetapi dikelompokkan dalam satu SPT karena memiliki kesamaan dalam penggunaan dan pengelolaan lahan secara umum. Persebaran satuan tanah penyusunnya tidak harus mengikuti pola geografis tertentu.

Peta tanah berdasarkan skala pemetaanya dibedakan menjadi lima kategori yang disajikan pada Tabel 3.2.

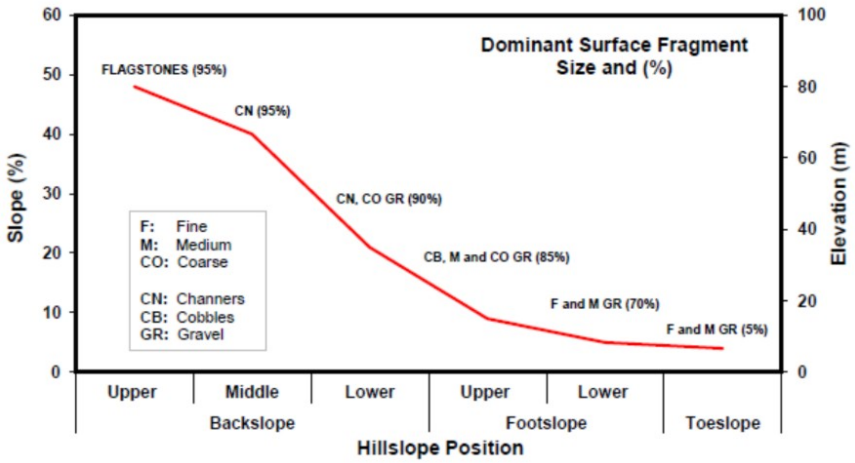
Tabel 3.2 Kategori peta tanah berdasarkan skala pemetaan

Kategori peta tanah	**Skala peta**	**Karakteristik dan kegunaan**
Peta tanah bagan *(schematic/generalized soil map)*	1:2.500.000 -1:5.000.000	Menyajikan informasi persebaran tanah secara umum pada wilayah yang sangat luas, seperti negara atau pulau. Satuan tanah yang digunakan umumnya berupa jenis tanah utama.
Peta tanah eksplorasi *(exploratory soil map)*	1:1.000.000	Menggambarkan persebaran tanah berdasarkan hasil survei pada wilayah luas. Digunakan untuk inventarisasi jenis tanah utama dan identifikasi kondisi tanah secara umum
Peta tanah tinjau *(reconnaissance soil map)*	1:250.000	Disusun berdasarkan survei lapangan, pemboran, deskripsi profil, dan analisis laboratorium. Digunakan untuk mengetahui potensi serta permasalahan tanah dalam perencanaan pembangunan pertanian tingkat regional hingga nasional.
Peta tanah semi detail *(semi-detailed soil map)*	1:50.000 -1:10.000	Disusun melalui survei tanah yang lebih intensif dengan pengamatan profil, pemboran, dan analisis laboratorium. Digunakan untuk perencanaan dan pelaksanaan kegiatan pertanian serta pengelolaan lahan pada wilayah yang tidak terlalu luas.
Peta tanah detail *(detailed soil map)*	1:10.000 atau lebih besar	Menyajikan informasi tanah secara terperinci berdasarkan survei lapangan, dengan Seri tanah sebagai satuan pemetaan. Karakteristik tanah, baik sifat fisik maupun kimia serta tingkat kesuburannya.

3.3. Prinsip Delineasi dengan Pendekatan Bentanglahan

Hubungan antara bentanglahan, bentuklahan, dan tanah digunakan untuk memahami serta memprediksi pola persebaran tanah berdasarkan karakteristik bentanglahan dan bentuklahan di suatu wilayah. Delineasi batas satuan peta tanah berdasarkan pada prinsip bahwa persebaran tanah mengikuti pola bentuk permukaan bumi, bahan induk, hidrologi, dan vegetasi (Hudson, 1992). Konsep yang mendasari hubungan tersebut adalah *catena* atau toposekuen, yaitu rangkaian tanah sepanjang lereng dari puncak hingga dasar lembah (Milne, 1935).

Tanah yang terbentuk dari bahan induk dan kondisi iklim serupa tetap dapat memiliki karakteristik berbeda di sepanjang lereng akibat variasi kemiringan dan posisi topografi, pergerakan air, serta proses erosi, transportasi, dan deposisi material (Birkeland, 1999; Schaetzl & Anderson, 2005). Puncak dan dataran antarpunggungan (*interfluve*) cenderung mengalami infiltrasi dan pencucian vertikal, lereng atas hingga tengah lebih dipengaruhi oleh limpasan permukaan dan erosi, sedangkan lereng kaki dan lembah menjadi zona akumulasi air, sedimen halus, dan kation terlarut dari bagian hulu.



Gambar 3.1 Distribusi material pada catena

Gambar 3.1 menunjukkan adanya hubungan antara posisi lereng, kemiringan lereng, dan dominasi ukuran fragmen batuan pada permukaan tanah. Secara umum, kemiringan lereng mengalami penurunan dari bagian upper backslope hingga toeslope, yaitu dari sekitar 48% hingga 4%. Pada bagian backslope yang relatif curam, fragmen permukaan didominasi oleh flagstones dan channers, dengan persentase dominasi masing-masing sebesar 95%. Selanjutnya, pada bagian lower backslope hingga upper footslope, dijumpai kombinasi fragmen berupa cobbles, material berukuran sedang (medium), dan kerikil kasar (coarse gravel), dengan persentase dominasi berkisar antara 90% dan 85%. Sementara itu, pada bagian

lower footslope hingga toeslope yang memiliki kemiringan lebih landai, fragmen permukaan yang ditunjukkan adalah kerikil halus (fine gravel) dan kerikil sedang (medium gravel), dengan persentase dominasi masing-masing 70% dan 5%.

Pola tersebut mengindikasikan adanya variasi karakteristik fragmen permukaan tanah sepanjang transek lereng yang berkaitan dengan perbedaan posisi geomorfologis. Perubahan ini dapat dipengaruhi oleh proses pelapukan, erosi, transportasi, dan deposisi material. Oleh karena itu, posisi lereng dan kemiringannya dapat menjadi informasi pendukung dalam interpretasi proses geomorfologi serta pemetaan karakteristik tanah berdasarkan distribusi material permukaan.

Bahan induk tanah merupakan material lepas hasil pelapukan batuan induk. Karakteristik dan persebaran bahan induk menjadi dasar dalam pendekatan persebaran batuan induk untuk pemetaan tanah. Sebagian besar bahan induk hasil pelapukan batuan telah mengalami proses transportasi dan sedimentasi, sehingga material dapat berpindah dari lokasi asal dan diendapkan di tempat lain. Material tersebut dapat berasal dari perombakan tanah yang telah berkembang sebelumnya, maupun dari hasil erosi dan longsoran.

Bahan induk tanah juga bervariasi berdasarkan karakteristik material penyusunnya. Material halus, seperti abu gunung api, relatif mudah mengalami pelapukan, sedangkan endapan pasir kuarsa cenderung lebih sulit lapuk. Variasi asal-usul, sifat material, dan proses perpindahan tersebut menjadi dasar pendekatan geomorfologi dalam pemetaan tanah, yang mengkaji hubungan antara pembentukan bentanglahan, proses transportasi dan sedimentasi, serta pola persebaran tanah yang dihasilkan.

Contoh pendekatan geomorfologi untuk delineasi adalah batuan beku vulkanik berupa aliran lava memiliki sifat resisten terhadap pelapukan dan relatif kedap air. Ketika mengalami denudasi, batuan ini cenderung membentuk bentanglahan dengan medan kasar, lereng terjal, serta jaringan aliran yang memanjang dan relatif rapat. Lembah yang terbentuk umumnya berbentuk V akibat proses erosi yang dominan. Pada citra penginderaan jauh, karakteristik morfologi tersebut dapat digunakan untuk mengenali bentuklahan yang tersusun atas batuan induk aliran lava, yang umumnya berupa batuan beku vulkanik masif.

3.4. Batas Delineasi Luasan Minimum

Penentuan skala peta dilakukan pada tahap awal perencanaan survei untuk menentukan tingkat kedetailan informasi yang akan disajikan, termasuk aspek yang relevan untuk ditampilkan atau tidak ditampilkan sesuai dengan cakupan pemetaan, baik pada tingkat lokal, regional, maupun global. Dalam penyusunan peta tanah, tingkat kerincian delineasi yang ditarik dari citra dan DEM dibatasi secara oleh skala peta target. Setiap skala peta memiliki

batas ukuran terkecil poligon yang masih dapat digambar dengan jelas dan dibaca oleh pengguna peta.

Ukuran terkecil di atas kertas peta atau layar tampilan ini disebut *Minimum Legible Delineation* (MLD), yang menurut konvensi survei tanah Cornell ditentukan sebesar 0,4 cm² (lingkaran berdiameter sekitar 7 mm atau bujur sangkar bersisi sekitar 6,3 mm) (Rossiter, 2000; Soil Survey Division Staff, 2017). Apabila nilai MLD tersebut dikonversikan ke ukuran sebenarnya di lapangan menggunakan bilangan skala peta (S_N, misalnya 10.000 untuk skala 1:10.000), diperoleh luas satuan peta terkecil di dalam peta, yang disebut *Minimum Legible Area* (MLA) atau sering pula disebut *Minimum Mapping Unit* (MMU) (Rossiter, 2000):

$$\text{MLA (ha)} = \frac{\text{MLD (cm}^2) \times S_N^2}{10^8} = \frac{0,4 \times S_N^2}{10^8} = \frac{(S_N / 1.000)^2}{250}$$

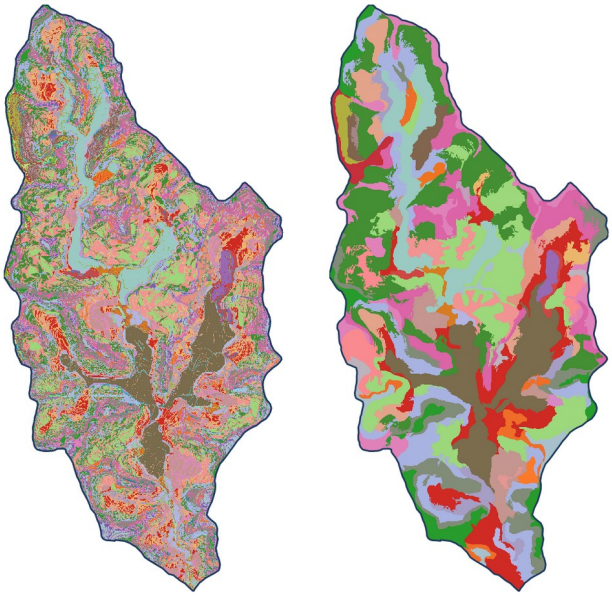
Keterangan:

MLA = *Minimum Legible Area,* luas minimum yang dapat dipetakan.

MLD = *Minimum Legible Delineation*, ditentukan sebesar 0,4 cm²

S_N = Penyebut skala peta, misalnya 10.000 untuk skala 1:10.000.

Penentuan delineasi satuan tanah melalui pendekatan bentanglahan menggunakan relief dan penggunaan lahan untuk membedakan satuan tanah. Dalam penerapannya, integrasi berbagai lapisan data tersebut dapat menghasilkan batas-batas satuan yang sangat rinci, bahkan membentuk poligon-poligon kecil akibat perbedaan kelas pada setiap lapisan. Penerapan MLA membantu menyederhanakan batas satuan lahan, mengurangi poligon serpihan (sliver polygons), serta menjaga agar satuan tanah yang dihasilkan tetap terbaca secara kartografis dan relevan secara pedologis.



Gambar 3.2 Visualisasi perbandingan hasil *overlay* bentuklahan, kemiringan lereng, dan penggunaan lahan (kiri), dan hasil generalisasi *overlay* bentuklahan, kemiringan lereng, dan penggunaan lahan berdasarkan MLA di Sub-DAS Bompon (kanan)

4. Remote Sensing untuk Estimasi Soil Properties

Ceramah dan diskusi:

4.1. Indikator Remote Sensing untuk Estimasi Soil Properties

Estimasi sifat-sifat tanah (*soil properties*) menggunakan penginderaan jauh merupakan upaya menduga nilai suatu sifat tanah, seperti kadar lempung, kelembapan, atau karbon organik, pada setiap lokasi berdasarkan besaran yang direkam oleh sensor. Sensor tidak mengukur sifat tanah secara langsung, tetapi merekam energi elektromagnetik yang dipantulkan, dipancarkan, atau dihamburkan kembali oleh permukaan, sebagaimana dibahas dalam Modul 1. Oleh karena itu, setiap estimasi memerlukan hubungan antara besaran yang terekam dan sifat tanah yang dicari. Mulder et al. (2011) mencatat bahwa hubungan tersebut dapat dibangun melalui pendekatan berbasis fisik maupun empiris, dan bahwa sifat tanah yang telah diukur dengan penginderaan jauh maupun penginderaan proksimal (*proximal sensing*) meliputi mineralogi, tekstur, besi, kelembapan, karbon organik, salinitas, dan kandungan karbonat. Dalam praktik, hubungan empiris dibangun dan diuji dengan membandingkan nilai piksel dengan hasil analisis sampel tanah yang diambil pada piksel yang sama (Chabrillat et al., 2019).

Peran penginderaan jauh dalam pemetaan tanah tidak terbatas pada pengukuran sifat tanah. Mulder et al. (2011) membedakan tiga peran, yaitu mendukung segmentasi lanskap menjadi satuan tanah–lanskap yang relatif homogen, menduga sifat tanah dari data optik dan gelombang mikro, serta menyediakan data sekunder untuk interpolasi spasial sifat tanah yang sampelnya tersebar jarang. Peran pertama telah dibahas dalam Modul 3, sedangkan modul ini berfokus pada peran kedua. Mulder et al. (2011) juga menunjukkan bahwa keberhasilan pengukuran sifat tanah dengan data optik dan gelombang mikro dilaporkan terutama di wilayah bervegetasi jarang. Di wilayah bervegetasi rapat, informasi tanah umumnya diperoleh secara tidak langsung melalui indikator seperti kelompok fungsional tumbuhan dan perubahan produktivitas. Pengamatan ini menjadi dasar untuk membedakan dua jalur estimasi sifat tanah, sebagaimana ditunjukkan pada Gambar 4.1.



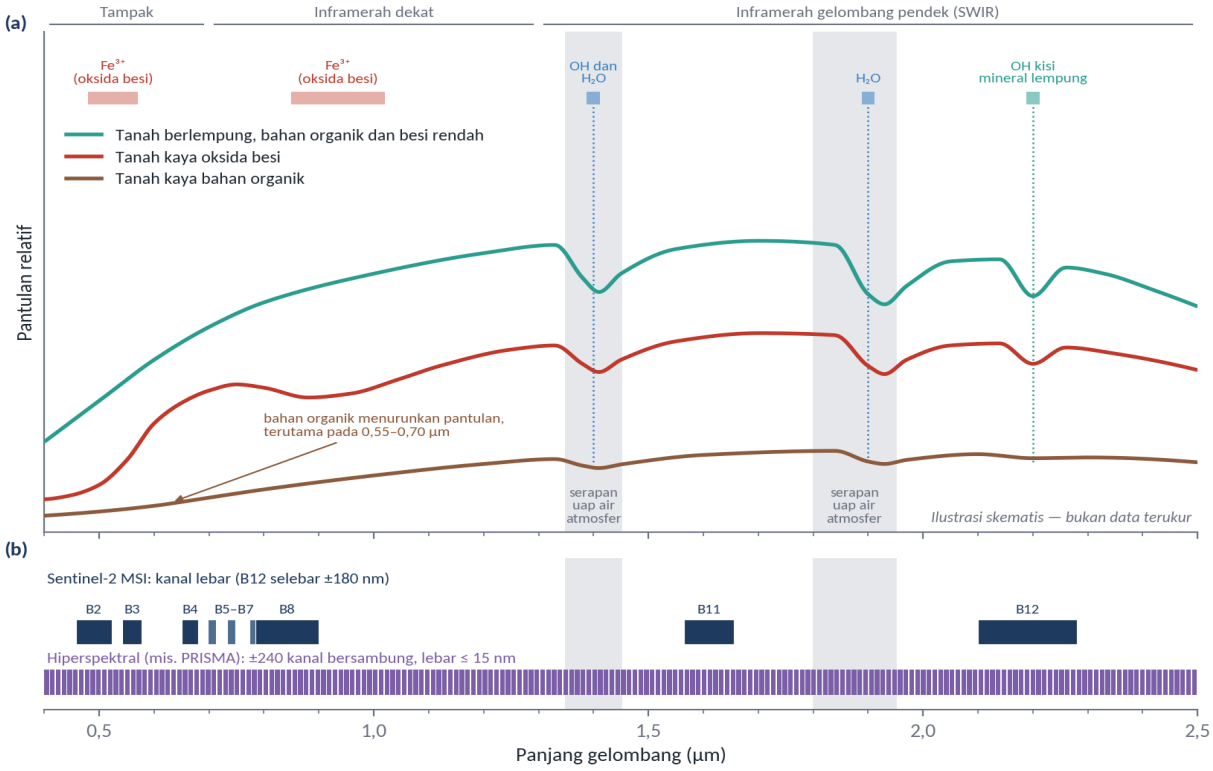
Gambar 4.1 Jalur estimasi langsung dan tidak langsung sifat tanah dari data penginderaan jauh

Sumber: Diagram konseptual disusun berdasarkan Mulder et al. (2011) dan Chabrillat et al. (2019)

Pada jalur langsung, sifat tanah yang dicari ikut membentuk sinyal yang direkam sensor. Jalur ini hanya dapat ditempuh apabila permukaan tanah terbuka dan sifat tersebut memiliki jejak spektral, sehingga hasilnya mewakili lapisan permukaan tanah. Pada jalur tidak langsung, sinyal berasal dari objek lain, seperti vegetasi atau bentuk medan, yang keadaannya berkaitan dengan tanah di tempat tersebut. Indikator semacam ini berperan sebagai variabel pengganti (*proxy*) bagi faktor-faktor SCORPAN (McBratney et al., 2003) dan dalam pemodelan DSM disebut kovariat lingkungan. Kedua jalur sama-sama memerlukan data tanah dari lapangan dan laboratorium untuk kalibrasi dan validasi. Dengan demikian, penginderaan jauh tidak menggantikan pengambilan sampel tanah, tetapi memperluas informasi dari titik-titik sampel ke seluruh wilayah kajian.

Dasar fisik jalur langsung adalah spektrum pantulan tanah. Lillesand et al. (2015) menyebutkan bahwa pantulan tanah dipengaruhi oleh kandungan air, kandungan bahan organik, tekstur, kekasaran permukaan, dan kandungan oksida besi, serta bahwa faktor-faktor tersebut saling berkaitan. Chabrillat et al. (2019) menjelaskan pengaruh tersebut melalui konsep kromofor (*chromophore*), yaitu komponen yang menentukan bentuk spektrum tanah. Kromofor kimia menghasilkan serapan pada panjang gelombang tertentu, baik melalui transisi elektronik atom di wilayah tampak dan inframerah dekat maupun melalui getaran *overtone* dan kombinasi gugus fungsi molekul di wilayah inframerah gelombang pendek (*shortwave*

infrared, SWIR). Kromofor fisik, seperti ukuran dan bentuk partikel, menghamburkan cahaya sehingga mengubah ketinggian garis dasar (albedo) dan bentuk umum spektrum. Hunt (1977) mencatat bahwa fitur serapan yang paling umum dijumpai pada material alami di wilayah tampak hingga inframerah dekat disebabkan oleh besi serta oleh air atau gugus hidroksil (OH). Posisi fitur-fitur utama tersebut diilustrasikan pada Gambar 4.2.



Gambar 4.2 Ilustrasi skematis fitur serapan pada spektrum pantulan tanah (a) serta posisi kanal Sentinel-2 dan sensor hiperspektral (b)

Sumber: Ilustrasi skematis disusun berdasarkan Hunt (1977), Scheinost et al. (1998), Galvão dan Vitorello (1998), serta Chabrillat et al. (2019); posisi kanal Sentinel-2 mengacu pada Drusch et al. (2012) dan kanal hiperspektral pada Cogliati et al. (2021)

Hubungan antara fitur spektral pada Gambar 4.2 dan komponen tanah dapat dijelaskan sebagai berikut:

- **Oksida besi**, transisi elektronik pada ion besi feri (Fe^{3+}) menghasilkan serapan di wilayah biru–hijau dan serapan lebar di sekitar 0,85–1,0 µm. Serapan di wilayah biru–hijau membuat tanah yang kaya oksida besi cenderung berwarna kemerahan, dan indeks kemerahan yang diturunkan dari spektrum tampak berkorelasi dengan kandungan hematit (Madeira et al., 1997). Scheinost et al. (1998) menunjukkan bahwa pita serapan hematit terletak pada sekitar 0,848–0,906 µm dan 0,521–0,565 µm, sedangkan pada oksida besi lain, termasuk goetit, terletak pada sekitar 0,909–1,022 µm dan 0,479–0,499 µm.

Perbedaan posisi tersebut memungkinkan hematit dibedakan dari oksida besi lain pada data beresolusi spektral tinggi.

- **Bahan organik**, bahan organik menurunkan pantulan, terutama di wilayah tampak, dan memengaruhi kemiringan spektrum dari wilayah tampak ke inframerah dekat (Chabrillat et al., 2019). Pada tanah tropis Brasil, Galvão dan Vitorello (1998) mendapati bahwa bahan organik merupakan komponen utama yang menurunkan pantulan pada 0,55–0,70 μm, dan kandungan bahan organik lebih dari 1,7% sudah mengaburkan fitur spektral besi.
- **Air dan gugus hidroksil**, molekul air higroskopis menghasilkan serapan di sekitar 1,4 dan 1,9 μm (Chabrillat et al., 2019), dan kandungan air yang lebih tinggi menurunkan pantulan di seluruh spektrum. Twomey et al. (1986) menjelaskan bahwa air yang mengisi ruang di sekitar partikel menurunkan indeks bias relatif partikel, sehingga cahaya harus dihamburkan lebih banyak kali sebelum keluar dari permukaan dan peluangnya untuk diserap meningkat. Lobell dan Asner (2002) menunjukkan bahwa penurunan pantulan akibat kelembapan bersifat tidak linear dan dapat digambarkan dengan model eksponensial, serta bahwa pantulan di wilayah tampak dan inframerah dekat mencapai kejenuhan pada kadar air yang lebih rendah daripada pantulan di wilayah SWIR.
- **Mineral lempung dan karbonat**, getaran gugus OH pada kisi mineral lempung menghasilkan serapan di sekitar 2,2 μm, sedangkan karbonat, misalnya kalsit, menghasilkan serapan di sekitar 2,3 μm (Chabrillat et al., 2019). Fitur di sekitar 2,2 μm menjadi dasar berbagai indeks untuk menduga kadar lempung yang dibahas pada Tabel 4.2. Clark et al. (1990) menunjukkan bahwa banyak mineral bergugus OH memiliki serapan diagnostik yang tajam, tetapi sebagian mineral tidak dapat dibedakan pada resolusi spektral rendah.
- **Ukuran partikel dan agregat**, sebagai kromofor fisik, ukuran partikel memengaruhi tingkat pantulan secara keseluruhan. Pada sampel tanah yang telah diganggu, pantulan meningkat ketika ukuran partikel mengecil, sedangkan agregat besar yang tidak beraturan memerangkap cahaya di antara rongga dan retakannya (Chabrillat et al., 2019). Di lapangan, pengaruh tekstur juga terkait dengan kelembapan. Lillesand et al. (2015) menjelaskan bahwa tanah berpasir yang berdrainase baik cenderung kering dan berpantulan tinggi, sedangkan tanah bertekstur halus yang berdrainase buruk cenderung lembap dan berpantulan lebih rendah; tanpa pengaruh air, kecenderungan tersebut justru berbalik.

Spektrum yang terekam merupakan gabungan pengaruh komponen-komponen tersebut, sehingga satu komponen dapat menutupi atau menggeser fitur komponen lain. Salah satu

contohnya adalah temuan Galvão dan Vitorello (1998) bahwa bahan organik mengaburkan fitur besi. Chabrillat et al. (2019) juga mencatat bahwa fitur suatu komponen, misalnya bahan organik, dapat tersembunyi atau sedikit bergeser karena kehadiran komponen lain seperti oksida besi. Oleh karena itu, satu fitur spektral jarang dapat ditafsirkan sebagai cerminan satu sifat tanah saja.

Tidak semua sifat tanah memiliki jejak spektral. Chabrillat et al. (2019) merumuskan bahwa suatu sifat tanah dapat diduga dari data spektral apabila sifat tersebut memiliki jejak spektral sendiri karena struktur kimia atau fisiknya, atau berkorelasi dengan sifat lain yang memiliki jejak spektral, dan apabila nilainya cukup bervariasi di wilayah kajian. Sifat seperti pH tidak memiliki fitur spektral, sehingga estimasinya bergantung pada korelasi dengan sifat lain, misalnya dengan besi (Chabrillat et al., 2019). Konsekuensinya, estimasi sifat kimia seperti pH, kapasitas tukar kation (KTK), dan kadar unsur hara bersifat tidak langsung dan sangat bergantung pada kondisi setempat. Penelitian dengan citra Sentinel-2 memperlihatkan keragaman hasil tersebut. Vaudour et al. (2019) memperoleh kinerja prediksi menengah untuk karbon organik, pH, kalsium karbonat, dan KTK di Dataran Versailles yang beriklim sedang, tetapi kinerja untuk lempung, besi, dan KTK di daerah tangkapan Peyne yang beriklim Mediterania hanya mendekati menengah. Gholizadeh et al. (2018) melaporkan bahwa Sentinel-2 memadai untuk memetakan karbon organik dan cukup untuk lempung, tetapi tidak dapat mendeteksi variasi kadar debu dan pasir. Ringkasan indikator penginderaan jauh untuk beberapa sifat tanah disajikan pada Tabel 4.1.

Tabel 4.1 Indikator Penginderaan Jauh untuk Beberapa Sifat Tanah

Sifat tanah	Dasar keterkaitan	Indikator dan data	Jalur estimasi
Tekstur (kadar lempung)	Serapan gugus OH kisi mineral lempung di sekitar 2,2 µm; kadar lempung memengaruhi dinamika kelembapan setelah hujan	Kanal dan rasio SWIR; kedalaman serapan 2,2 µm pada data hiperspektral; perubahan hamburan balik SAR antara kondisi basah dan kering	Langsung (mineral lempung) dan tidak langsung (dinamika kelembapan)
Kelembapan permukaan	Air menurunkan pantulan di seluruh spektrum dan memperdalam serapan 1,4 dan 1,9 µm; air mengubah sifat dielektrik tanah	Pantulan SWIR; indeks kelembapan pada data hiperspektral; hamburan balik SAR; radiometer gelombang mikro	Langsung
Bahan organik dan karbon organik	Menurunkan pantulan, terutama di wilayah tampak, dan mengubah kemiringan spektrum	Pantulan kanal tampak; indeks kecerahan dan warna; model multivariat seluruh kanal	Langsung

Sifat tanah	Dasar keterkaitan	Indikator dan data	Jalur estimasi
Oksida besi dan warna tanah	Transisi elektronik ion besi feri di wilayah biru–hijau dan sekitar 0,85–1,0 μm	Kanal tampak dan inframerah dekat; indeks kemerahan dan indeks warna	Langsung
Drainase	Sebaran tanah yang sering jenuh air berkaitan dengan posisi topografi dan akumulasi aliran	Indeks kebasahan topografi dan indeks kedalaman muka air dari DEM; kelembapan multitemporal dari SAR	Tidak langsung
pH, KTK, dan unsur hara	Tidak memiliki fitur spektral khas; berkorelasi dengan bahan organik, lempung, atau oksida besi	Model multivariat kanal dan kovariat lingkungan	Tidak langsung, berlaku lokal

Sumber: Rangkuman penulis berdasarkan Lillesand et al. (2015), Chabrillat et al. (2019), Hallikainen et al. (1985), Zribi et al. (2012), Ågren et al. (2014), dan Vaudour et al. (2019)

Selain data optik, beberapa sifat tanah dapat diduga dari data gelombang mikro. Hamburan balik radar dari tanah terbuka ditentukan terutama oleh kekasaran permukaan dan konstanta dielektrik tanah (Oh et al., 1992). Konstanta dielektrik dipengaruhi oleh kadar air volumetrik dan komposisi tekstur tanah, dan pengaruh tekstur tersebut paling nyata pada frekuensi di bawah 5 GHz (Hallikainen et al., 1985). Berdasarkan hubungan tersebut, Oh et al. (1992) menyusun model empiris hamburan balik pada beberapa polarisasi, sehingga kelembapan dan kekasaran permukaan tanah terbuka dapat diduga secara bersamaan dari citra radar multipolarisasi. Kepekaan terhadap kelembapan juga dapat dimanfaatkan untuk menduga tekstur. Zribi et al. (2012) menemukan korelasi yang kuat antara tekstur tanah dan selisih sinyal dua citra TerraSAR-X yang direkam sesaat setelah hujan dan tiga minggu kemudian dalam kondisi kering. Bousbih et al. (2019) memperoleh klasifikasi kadar lempung terbaik dengan indikator kelembapan yang diturunkan dari gabungan citra Sentinel-1 dan Sentinel-2. Pengamatan gelombang mikro pasif pada pita L, seperti misi SMOS, berkaitan dengan kelembapan pada beberapa sentimeter teratas tanah, tetapi resolusi spasial maksimumnya sekitar 50 km (Kerr et al., 2010), sehingga lebih sesuai untuk pemantauan regional daripada untuk satuan pengelolaan kebun.

Untuk sifat yang berkaitan dengan pergerakan air, seperti drainase, data elevasi menjadi indikator tidak langsung yang penting. Indeks kebasahan topografi (*Topographic Wetness Index*, TWI) dirumuskan sebagai $\mathrm{TWI} = \ln\left(a / \tan\beta\right)$, dengan a adalah luas daerah tangkapan spesifik dan β adalah kemiringan lereng (Beven & Kirkby, 1979). Nilai TWI yang tinggi menunjukkan lokasi yang menerima aliran dari daerah tangkapan yang luas tetapi berlereng

landai, sehingga cenderung lebih basah. Ågren et al. (2014) menemukan bahwa TWI dan indeks kedalaman muka air kartografis (*Depth-to-Water*, DTW) merupakan prediktor kebasahan tanah terbaik di antara beberapa indeks medan yang diuji, tetapi TWI peka terhadap resolusi DEM yang digunakan. Pada wilayah bervegetasi, respons vegetasi juga dapat menjadi indikator sifat tanah. Loiseau et al. (2019) menunjukkan bahwa komponen utama pertama dari deret waktu NDVI menjadi variabel terpenting kedua untuk menduga kadar lempung di Prancis, meskipun data satelit saja belum menghasilkan estimasi yang memuaskan. Mgohele et al. (2024), yang meninjau 70 artikel, juga menunjukkan bahwa NDVI dan SAVI merupakan indeks yang paling sering diturunkan dalam prediksi tekstur tanah dengan data penginderaan jauh. Temuan ini menegaskan besarnya peran indikator tidak langsung dalam praktik.

Informasi spektral yang berkaitan dengan sifat tanah sering diringkas melalui transformasi indeks, yaitu operasi aritmetika antarkanal seperti rasio, selisih ternormalisasi, atau kombinasi beberapa kanal. Transformasi ini bertujuan menonjolkan fitur spektral tertentu sekaligus meredam pengaruh yang tidak diinginkan. Rasio dua kanal, misalnya, meredam pengaruh perbedaan iluminasi, sehingga objek yang sama pada lereng yang terkena sinar matahari dan lereng yang terbayangi memiliki nilai rasio yang serupa (Lillesand et al., 2015). Indeks untuk tanah dapat dikelompokkan berdasarkan fitur yang dimanfaatkannya. Indeks warna tanah, seperti indeks kecerahan, saturasi, rona, pewarnaan, dan kemerahan, memanfaatkan kanal tampak. Dasar fisiknya adalah keterkaitan antara warna tanah dan pantulan pada kanal tampak, yang menjadi dasar model berbasis fisik antara warna permukaan dan data satelit (Escadafal, 1993). Madeira et al. (1997) menunjukkan bahwa indeks hematit yang disusun dari kanal tampak Landsat TM mampu memetakan kandungan hematit pada horizon permukaan tanah laterit di sekitar Brasília secara akurat. Rasio kanal SWIR memanfaatkan serapan mineral lempung di sekitar 2,2 μm yang berada di dalam rentang kanal B12 Sentinel-2, sedangkan kanal B11 berada di luar serapan tersebut. Pada data hiperspektral, fitur yang sempit dapat diukur lebih langsung, misalnya melalui indeks kelembapan NSMI yang memanfaatkan pantulan pada 1,800 dan 2,119 μm di tepi serapan air 1,9 μm (Haubrock et al., 2008; Chabrillat et al., 2019), atau melalui penghilangan kontinum (*continuum removal*), yaitu pembagian spektrum dengan garis kontinumnya untuk mengisolasi satu fitur serapan (Clark & Roush, 1984). Contoh transformasi indeks yang berkaitan dengan sifat tanah disajikan pada Tabel 4.2. Pada tabel tersebut, R, G, B, NIR, SWIR1, dan SWIR2 berturut-turut menyatakan pantulan kanal merah, hijau, biru, inframerah dekat, SWIR pertama, dan SWIR kedua, sedangkan R_{1800} dan R_{2119} menyatakan pantulan pada 1,800 dan 2,119 μm.

Tabel 4.2 Contoh Transformasi Indeks yang Berkaitan dengan Sifat Tanah

Indeks	Rumus	Padanan kanal Sentinel-2	Sifat tanah terkait
Indeks kecerahan (*Brightness Index*, BI)	$\left(\frac{R^2+G^2+B^2}{3}\right)^{0,5}$	$\left(\frac{\mathrm{B4}^2+\mathrm{B3}^2+\mathrm{B2}^2}{3}\right)^{0,5}$	Kecerahan umum permukaan, yang dipengaruhi bahan organik dan kelembapan
Indeks saturasi (*Saturation Index*, SI)	$\frac{R-B}{R+B}$	$\frac{\mathrm{B4}-\mathrm{B2}}{\mathrm{B4}+\mathrm{B2}}$	Kemiringan spektrum tampak
Indeks rona (*Hue Index*, HI)	$\frac{2R-G-B}{G-B}$	$\frac{2\mathrm{B4}-\mathrm{B3}-\mathrm{B2}}{\mathrm{B3}-\mathrm{B2}}$	Rona warna tanah
Indeks pewarnaan (*Coloration Index*, CI)	$\frac{R-G}{R+G}$	$\frac{\mathrm{B4}-\mathrm{B3}}{\mathrm{B4}+\mathrm{B3}}$	Warna tanah
Indeks kemerahan (*Redness Index*, RI)	$\frac{R^2}{B\times G^3}$	$\frac{\mathrm{B4}^2}{\mathrm{B2}\times \mathrm{B3}^3}$	Kandungan hematit
Rasio mineral lempung (*Clay Minerals Ratio*, CMR)	$\frac{\mathrm{SWIR1}}{\mathrm{SWIR2}}$	$\frac{\mathrm{B11}}{\mathrm{B12}}$	Mineral lempung
Indeks ukuran butir tanah atas (*Topsoil Grain Size Index*, TGSI)	$\frac{R-B}{R+G+B}$	$\frac{\mathrm{B4}-\mathrm{B2}}{\mathrm{B4}+\mathrm{B3}+\mathrm{B2}}$	Kadar pasir halus; dikembangkan untuk lahan kering
NDVI (*Normalized Difference Vegetation Index*)	$\frac{\mathrm{NIR}-R}{\mathrm{NIR}+R}$	$\frac{\mathrm{B8}-\mathrm{B4}}{\mathrm{B8}+\mathrm{B4}}$	Tidak langsung melalui respons vegetasi; juga ukuran tutupan vegetasi
Indeks kelembapan tanah ternormalisasi (*Normalized Soil Moisture Index*, NSMI)	$\frac{R_{1800}-R_{2119}}{R_{1800}+R_{2119}}$	Tidak tersedia; memerlukan data hiperspektral	Kelembapan permukaan
Kedalaman serapan setelah penghilangan kontinum (*band depth*)	$1-\frac{R}{R_c}$ pada pusat serapan, dengan R_c pantulan kontinum	Tidak tersedia; memerlukan data hiperspektral	Mineral lempung (sekitar 2,2 µm) dan karbonat (sekitar 2,3 µm)

Sumber: Rumus BI, SI, HI, CI, RI, dan NDVI mengikuti Forkuor et al. (2017); CMR dan TGSI mengikuti kompilasi Mgohele et al. (2024), dengan TGSI dikembangkan oleh Xiao et

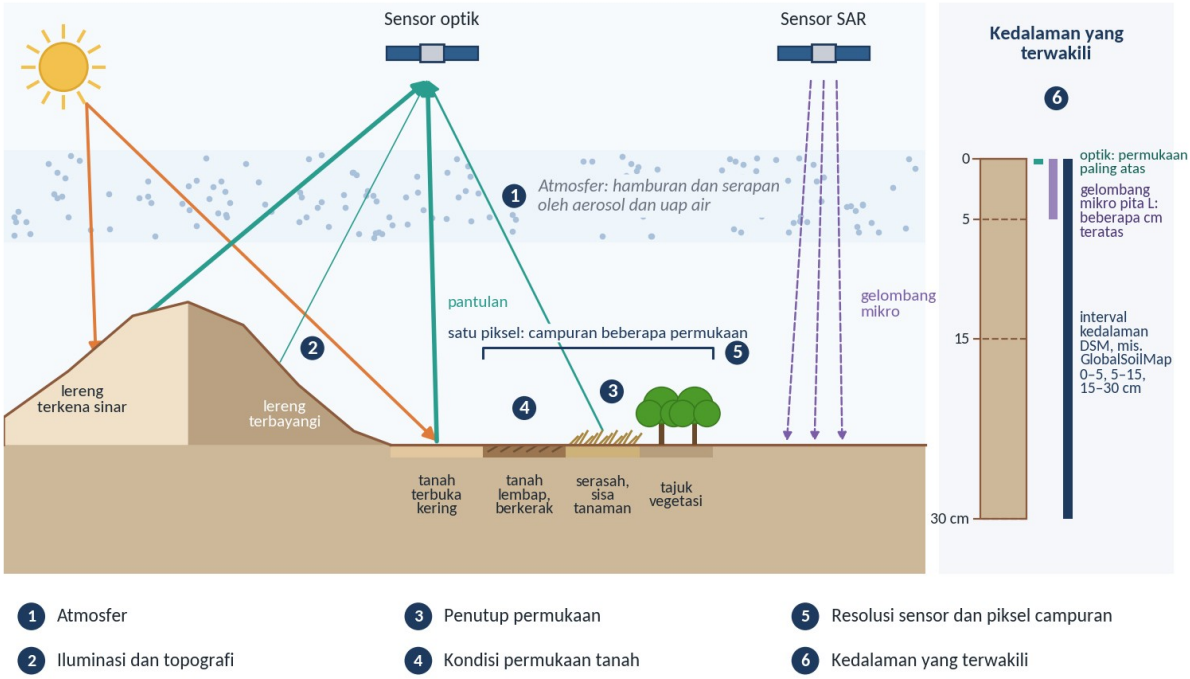
al. (2006); NSMI dari Haubrock et al. (2008); kedalaman serapan dari Clark dan Roush (1984); padanan kanal Sentinel-2 berdasarkan Drusch et al. (2012)

Indeks-indeks tersebut perlu digunakan secara hati-hati. Rumus indeks hanya menonjolkan suatu fitur spektral, tetapi tidak menjamin bahwa fitur tersebut hanya berasal dari sifat tanah yang dimaksud. Indeks warna, misalnya, dipengaruhi bersama oleh oksida besi, bahan organik, dan kelembapan, sedangkan kombinasi kanal SWIR1 dan SWIR2 dalam bentuk selisih ternormalisasi juga digunakan sebagai indeks pengolahan tanah dan sisa tanaman (Mgohele et al., 2024). Hubungan antara nilai indeks dan sifat tanah juga bersifat empiris, sehingga perlu dikalibrasi dengan data tanah setempat. Forkuor et al. (2017) menemukan bahwa kanal SWIR dan inframerah dekat Landsat 8 serta indeks kemerahan, pewarnaan, dan saturasi termasuk prediktor spektral yang menonjol dalam pemetaan sifat tanah di bagian barat daya Burkina Faso. Namun, indeks-indeks tersebut digunakan bersama variabel medan dan iklim dalam model statistik, bukan sebagai penduga tunggal.

Kemampuan suatu sensor untuk menangkap fitur-fitur spektral tanah ditentukan oleh resolusi spektralnya. Sentinel-2 memiliki kanal SWIR yang lebar, misalnya B12 dengan lebar sekitar 180 nm (Drusch et al., 2012), sehingga fitur serapan yang sempit hanya terekam sebagai penurunan rata-rata pantulan di dalam kanal. Sensor hiperspektral merekam ratusan kanal sempit yang bersambung. PRISMA, yang diluncurkan pada 22 Maret 2019, merekam rentang 0,40–2,50 µm dengan lebar kanal tidak lebih dari 15 nm dan ukuran piksel 30 m (Cogliati et al., 2021), sedangkan EnMAP dirancang dengan ukuran piksel yang sama dan kebijakan data terbuka (Chabrillat et al., 2019). Sebelumnya, Hyperion menjadi satu-satunya sensor hiperspektral satelit yang mencakup seluruh wilayah tampak hingga SWIR pada periode 2000 hingga awal 2017, dengan rasio sinyal terhadap derau yang tergolong sedang hingga rendah (Chabrillat et al., 2019). Castaldi et al. (2016) membandingkan kemampuan beberapa sensor multispektral dan hiperspektral menggunakan spektrum pustaka yang disimulasikan sesuai karakteristik setiap sensor. Tanpa derau, sensor hiperspektral umumnya lebih baik daripada sensor multispektral dalam menduga lempung, pasir, debu, dan karbon organik. Penambahan derau memperkecil perbedaan tersebut, dan kanal selebar 40 nm masih memberikan ketelitian yang hampir sama dengan kanal yang lebih sempit. Castaldi et al. (2016) menyimpulkan bahwa sensor hiperspektral generasi baru akan meningkatkan ketelitian estimasi pada citra tanah terbuka, tetapi peningkatannya belum cukup untuk estimasi kuantitatif tekstur dan karbon organik yang akurat. Dengan demikian, ketelitian estimasi tidak hanya ditentukan oleh jenis sensor, tetapi juga oleh berbagai faktor yang dibahas dalam subbab berikutnya.

4.2. Faktor yang Memengaruhi Estimasi Soil Properties

Sinyal yang direkam sensor dari suatu permukaan tanah tidak hanya ditentukan oleh sifat tanah yang ingin diduga. Chabrillat et al. (2019), merangkum beberapa penelitian, menyebutkan tiga faktor utama yang memengaruhi pantulan tanah dan ketelitian model, yaitu atmosfer, rasio sinyal terhadap derau sensor yang rendah, serta faktor pengganggu di permukaan tanah seperti tutupan vegetasi parsial, kelembapan, dan kerak tanah. Ketersediaan data tanah untuk kalibrasi menjadi tantangan tambahan. Perbedaan kondisi pengukuran juga penting. Sampel tanah di laboratorium dikeringkan, dihaluskan, dan diayak, sedangkan sensor pada pesawat atau satelit merekam permukaan alami yang suhunya tidak seragam, bercampur dengan objek lain, serta bervariasi kelembapan dan kekasarannya (Chabrillat et al., 2019). Angelopoulou et al. (2019), dalam tinjauannya mengenai estimasi karbon organik, juga menunjukkan bahwa ketelitian prediksi menurun dari wahana pesawat nirawak ke satelit. Faktor-faktor yang berkaitan dengan perekaman sinyal diilustrasikan pada Gambar 4.3, sedangkan faktor yang berkaitan dengan data kalibrasi dan model dibahas pada bagian akhir subbab ini.



Gambar 4.3 Faktor-faktor yang memengaruhi sinyal tanah yang direkam sensor
Sumber: Diagram konseptual disusun berdasarkan Chabrillat et al. (2019); kedalaman yang terwakili mengacu pada Kerr et al. (2010) dan Poggio et al. (2021)

Faktor pertama adalah atmosfer. Energi yang dipantulkan tanah dihamburkan dan diserap oleh gas dan aerosol sebelum mencapai sensor, sebagaimana dibahas dalam Modul 1. Uap air menyerap kuat di sekitar 1,4 dan 1,9 µm (Lillesand et al., 2015; Gambar 4.2), yaitu wilayah

yang sama dengan serapan air dan gugus OH di dalam tanah, sehingga fitur tanah pada wilayah tersebut sulit dimanfaatkan dari data satelit. Chabrillat et al. (2019) mencatat bahwa koreksi atmosfer yang tidak tepat dapat menghasilkan sinyal yang keliru dianggap sebagai fitur tanah dan menambah derau, serta bahwa indeks yang memakai panjang gelombang di dekat pita serapan air, seperti NSMI, sangat peka terhadap mutu koreksi atmosfer. Untuk Sentinel-2, koreksi atmosfer dilakukan oleh pengolah Sen2Cor yang mengubah produk Level-1C berupa pantulan puncak atmosfer menjadi produk Level-2A berupa pantulan permukaan, sekaligus menghasilkan peta uap air dan peta klasifikasi adegan yang memuat peluang keberadaan awan (Main-Knorn et al., 2017). Estimasi sifat tanah sebaiknya menggunakan pantulan permukaan tersebut.

Faktor kedua adalah geometri penyinaran dan topografi. Pada lahan berlereng, tanah yang sama tampak lebih cerah pada lereng yang menghadap matahari dan lebih gelap pada lereng yang membelakanginya. Teillet et al. (1982) menunjukkan bahwa koreksi kosinus sederhana berdasarkan kemiringan dan arah lereng dari DEM tidak memadai, terutama pada sudut datang yang besar, sehingga diperlukan koreksi yang juga memperhitungkan sifat pantulan permukaan yang tidak Lambertian dan pengaruh atmosfer. Rasio kanal dapat meredam pengaruh iluminasi (Lillesand et al., 2015), tetapi hanya untuk komponen yang bersifat perkalian dan tidak menghilangkan komponen tambahan seperti radiasi jalur atmosfer. Selain itu, permukaan tanah memantulkan energi secara anisotropis, sehingga nilai pantulan juga bergantung pada posisi matahari dan arah pandang sensor (Chabrillat et al., 2019).

Faktor ketiga adalah penutup permukaan. Tanah jarang benar-benar terbuka, karena vegetasi serta bahan organik dan anorganik sering menutupi sebagian atau seluruh permukaannya. Chabrillat et al. (2019), berdasarkan penelitian terdahulu, mencatat bahwa tutupan vegetasi lebih dari 20% sudah menghalangi estimasi sifat tanah yang akurat. Bahan organik mati juga memiliki ciri spektral sendiri. Daughtry (2001) menunjukkan bahwa sisa tanaman kering memiliki serapan lebar di sekitar 2,1 μm yang berkaitan dengan lignin dan selulosa, sedangkan tanah tidak memiliki serapan tersebut. Karena kanal B12 Sentinel-2 mencakup 2,10–2,28 μm, serapan sisa tanaman dan serapan mineral lempung terekam dalam kanal yang sama, sehingga nilai rasio SWIR dapat berubah karena serasah, bukan karena lempung. Penutup permukaan juga memengaruhi data radar. Dubois et al. (1995) mendapati bahwa vegetasi yang cukup rapat, dengan NDVI lebih dari 0,4, menyebabkan kelembapan tanah diduga terlalu rendah dan kekasaran permukaan diduga terlalu tinggi. Oleh karena itu, estimasi langsung memerlukan penyaringan piksel tanah terbuka, yang akan dibahas secara khusus dalam Modul 5. Waktu perekaman juga menentukan. Forkuor et al. (2017) menemukan

bahwa citra yang direkam saat pengolahan tanah atau awal pertumbuhan tanaman merupakan prediktor spektral terpenting, sedangkan Loiseau et al. (2019) menyusun mosaik tanah terbuka dari citra Sentinel-2 yang direkam pada masa tanam.

Faktor keempat adalah kondisi permukaan tanah itu sendiri, terutama kelembapan, kekasaran, dan kerak. Kelembapan merupakan kromofor yang sangat kuat. Chabrillat et al. (2019) mencatat bahwa pengaruh kelembapan terhadap pantulan dapat lebih besar daripada perbedaan pantulan antarkategori tanah. Kekasaran permukaan yang berasal dari partikel, agregat, fragmen batuan, dan relief mikro menimbulkan bayangan kecil yang menurunkan pantulan, dan pengaruhnya dapat sangat bervariasi setelah pengolahan tanah. Sebaliknya, kerak yang terbentuk akibat pembasahan dan pengeringan berulang meningkatkan pantulan dibandingkan tanah yang tidak berkerak (Chabrillat et al., 2019). Berbagai indeks dan model telah dikembangkan untuk mengurangi pengaruh kelembapan, misalnya pengelompokan spektrum tanah lembap berdasarkan NSMI sebelum memodelkan bahan organik di laboratorium (Hong et al., 2018). Namun, koreksi pengaruh kelembapan secara menyeluruh terhadap fitur serapan mineral dan bahan organik belum dapat dicapai (Chabrillat et al., 2019). Dalam praktik, pengaruh ini dikurangi dengan memilih citra yang direkam ketika permukaan tanah relatif kering dan kondisinya seragam. Chabrillat et al. (2019) mencatat bahwa pemetaan sifat tanah dengan data hiperspektral umumnya dilakukan pada lahan budi daya yang diolah secara rutin sehingga lapisan atas setebal sekitar 20–30 cm teraduk homogen, sebagian besar permukaannya terbuka tanpa kerak, dan kadar air permukaannya rendah.

Faktor kelima adalah karakteristik sensor. Resolusi spektral menentukan fitur yang dapat ditangkap. Chabrillat et al. (2019) menjelaskan bahwa sifat tanah dengan fitur spektral yang lebar dan tegas, seperti besi, hanya sedikit terpengaruh oleh penurunan resolusi spektral, sedangkan sifat tanpa fitur spektral, seperti pH, sangat terpengaruh. Rasio sinyal terhadap derau juga menentukan, karena penambahan derau menurunkan ketelitian semua model estimasi, terutama untuk data Hyperion (Castaldi et al., 2016). Resolusi spasial menentukan kemurnian suatu piksel. Piksel yang lebih besar lebih mungkin mencampur tanah terbuka dengan vegetasi, jalan, atau bayangan. Chabrillat et al. (2019) merangkum penelitian yang menunjukkan bahwa pengaruh resolusi spasial bergantung pada struktur spasial sifat tanah dan ukuran petak lahan. Pada wilayah berpetak kecil, ketelitian pemetaan lempung menurun dari R^2 0,74 pada piksel 5 m menjadi 0,66 pada piksel 30 m. Resolusi temporal menentukan peluang memperoleh citra yang bebas awan sekaligus menangkap permukaan dalam keadaan terbuka. Konstelasi Sentinel-2A dan Sentinel-2B memungkinkan perekaman ulang wilayah yang sama setiap lima

hari atau kurang (Main-Knorn et al., 2017), sehingga peluang tersebut lebih besar dibandingkan sensor dengan perekaman ulang yang lebih jarang.

Faktor keenam adalah kedalaman lapisan yang diwakili oleh sinyal. Sinyal optik hanya berasal dari bagian paling atas permukaan tanah. Clark dan Roush (1984) menjelaskan bahwa makin kuat suatu bahan menyerap, makin sedikit foton yang menembus ke dalam permukaannya. Chabrillat et al. (2019) menekankan bahwa yang terekam sensor adalah permukaan tanah paling atas dalam keadaan tidak terganggu, sedangkan pustaka spektral tanah disusun dari sampel 0–5 cm yang telah diganggu. Pengamatan gelombang mikro pita L berkaitan dengan kelembapan pada beberapa sentimeter teratas tanah (Kerr et al., 2010). Sebaliknya, DSM umumnya memerlukan nilai sifat tanah pada interval kedalaman tertentu, misalnya enam interval baku GlobalSoilMap, yaitu 0–5, 5–15, 15–30, 30–60, 60–100, dan 100 –200 cm (Poggio et al., 2021). Hasil estimasi langsung dari citra hanya dapat dianggap mewakili lapisan atas apabila lapisan tersebut cukup homogen, seperti lapisan olah pada lahan yang diolah secara rutin. Loiseau et al. (2019) melaporkan bahwa penambahan data satelit memperbaiki estimasi kadar lempung pada lapisan atas, yaitu 0–30 cm. Untuk lapisan yang lebih dalam, informasi penginderaan jauh lebih berperan sebagai kovariat lingkungan dalam pemodelan DSM. Pada tanaman tahunan yang tidak diolah secara rutin, kesesuaian antara kondisi permukaan dan lapisan yang diambil sampelnya perlu diperiksa di lapangan.

Faktor terakhir berkaitan dengan data kalibrasi dan model. Hubungan antara indikator dan sifat tanah hanya dapat dibangun apabila nilai sifat tanah cukup bervariasi di wilayah kajian (Chabrillat et al., 2019). Bartholomeus et al. (2008) menunjukkan bahwa indeks berbasis wilayah tampak dan serapan di sekitar 2,1 μm dapat menduga karbon organik pada spektrum laboratorium, tetapi model berbasis indeks tersebut memerlukan rentang karbon organik yang lebar dalam data kalibrasi, karena penerapannya di luar rentang tersebut menghasilkan galat yang besar. Ketelitian peta hasil estimasi juga dipengaruhi oleh sumber ketidakpastian lain, seperti galat posisi GPS, gangguan atmosfer, variasi kondisi permukaan, dan variasi sifat tanah di dalam satu piksel, serta oleh strategi validasi yang digunakan (Chabrillat et al., 2019). Perbedaan waktu antara pengambilan sampel dan perekaman citra perlu diperhatikan, terutama untuk sifat yang cepat berubah seperti kelembapan. Selain itu, model yang dikalibrasi di satu wilayah belum tentu berlaku di wilayah lain, sebagaimana terlihat dari perbedaan kinerja Sentinel-2 antara dua wilayah yang dikaji Vaudour et al. (2019). Pembahasan mengenai pembagian data, pembuatan dan validasi model, serta residual dan ketidakpastian disajikan dalam Modul 8. Rangkuman faktor-faktor yang memengaruhi estimasi sifat tanah beserta upaya pengendaliannya disajikan pada Tabel 4.3.

Tabel 4.3 Faktor yang Memengaruhi Estimasi Sifat Tanah dan Upaya Pengendaliannya

Kelompok faktor	Pengaruh terhadap estimasi	Upaya pengendalian
Atmosfer	Hamburan dan serapan mengubah pantulan; wilayah serapan uap air sulit dimanfaatkan	Gunakan pantulan permukaan hasil koreksi atmosfer; hindari kanal di wilayah serapan uap air
Iluminasi dan topografi	Tanah yang sama memberi pantulan berbeda pada lereng yang menghadap dan membelakangi matahari	Lakukan koreksi topografi dengan DEM; gunakan indeks rasio dengan menyadari keterbatasannya
Penutup permukaan	Vegetasi, serasah, dan sisa tanaman menutupi atau mencampur sinyal tanah	Saring piksel tanah terbuka dan pilih waktu perekaman saat permukaan terbuka (Modul 5)
Kondisi permukaan tanah	Kelembapan dan kekasaran menurunkan pantulan, sedangkan kerak meningkatkan pantulan	Pilih citra saat permukaan kering dan seragam; gunakan indeks kelembapan untuk pengelompokan atau koreksi
Karakteristik sensor	Lebar kanal, derau, ukuran piksel, dan frekuensi perekaman membatasi fitur dan wilayah yang dapat diamati	Sesuaikan sensor dengan sifat sasaran; gunakan data hiperspektral untuk fitur sempit dan citra multitemporal untuk memperbesar peluang pengamatan
Kedalaman yang terwakili	Sinyal hanya mewakili permukaan, sedangkan DSM memerlukan beberapa interval kedalaman	Sesuaikan kedalaman sampel dengan lapisan yang terwakili; gunakan kovariat lingkungan untuk lapisan yang lebih dalam
Data kalibrasi dan model	Rentang nilai yang sempit, perbedaan waktu dan posisi, serta perbedaan wilayah melemahkan model	Rancang sampel yang mencakup rentang nilai di wilayah kajian; validasi dengan data independen (Modul 8)

Sumber: Rangkuman penulis berdasarkan uraian dalam subbab ini

Bagi perkebunan kelapa sawit, faktor-faktor tersebut bekerja secara bersamaan. Pada blok yang tajuknya telah menutup, permukaan tanah sebagian besar tidak teramati oleh sensor optik, sehingga estimasi langsung dari citra optik hanya mungkin dilakukan pada areal yang terbuka, misalnya ketika lahan dibuka atau diremajakan. Kondisi tanaman yang terekam pada citra juga tidak hanya mencerminkan tanah, karena produksi kelapa sawit dipengaruhi pula oleh faktor eksternal seperti curah hujan serta serangan hama dan penyakit, dan oleh faktor internal seperti jumlah tanaman, varietas, dan umur tanaman (Ginting & Wiratmoko, 2021). Oleh karena itu, indikator vegetasi perlu ditafsirkan bersama data lain. Estimasi sifat tanah di perkebunan kelapa sawit lebih tepat dipandang sebagai gabungan berbagai indikator, yaitu pengamatan tanah terbuka pada waktu yang tepat (Modul 5), data SAR dan DEM untuk

kelembapan dan drainase, pengukuran proksimal di lapangan (Modul 7), serta pemodelan DSM yang dikalibrasi dengan data tanah setempat (Modul 8).

5. Bare Soil Detection & Information Extraction

Ceramah dan diskusi:

5.1. Permukaan Tanah, Vegetasi, dan Pantulan Spektral

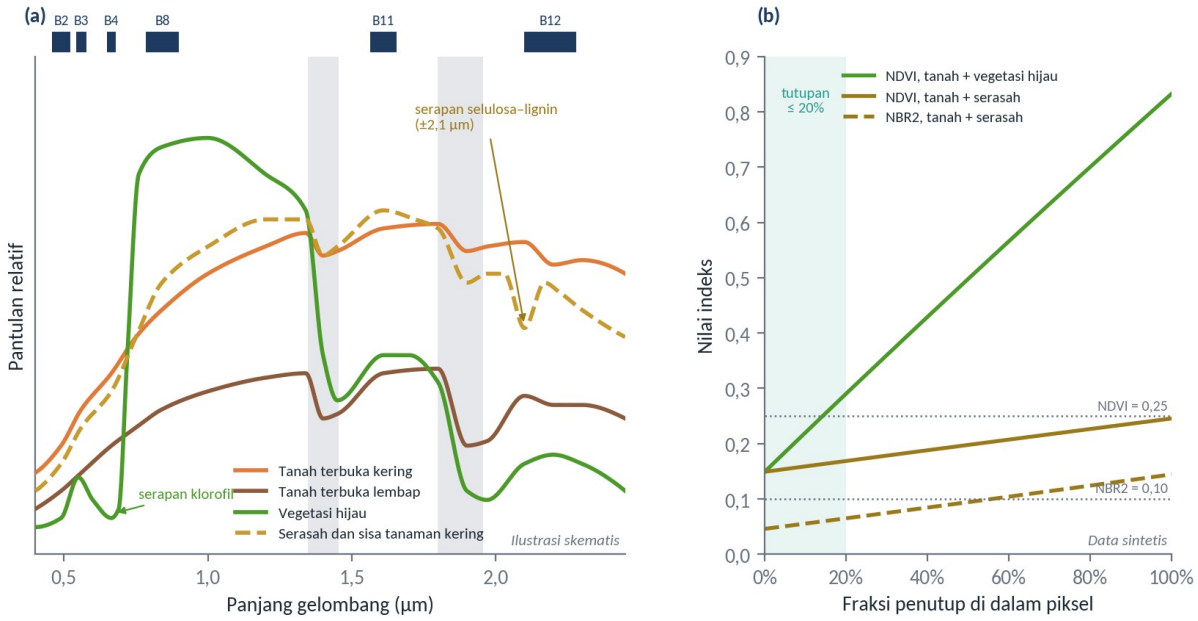
Deteksi tanah terbuka (*bare soil detection*) merupakan proses mengenali piksel citra yang permukaannya berupa tanah tanpa penutup atau hampir tanpa penutup, kemudian mengekstraksi informasi spektral dari piksel-piksel tersebut. Modul 4 menunjukkan bahwa estimasi sifat tanah secara langsung dari citra optik hanya dapat dilakukan apabila permukaan tanah terbuka, karena sinyal yang terekam berasal dari lapisan paling atas permukaan. Oleh karena itu, deteksi tanah terbuka berperan sebagai langkah penyaring sebelum estimasi sifat tanah. Demattê et al. (2020) mendefinisikan permukaan terbuka sebagai permukaan abiotik alami, seperti tanah, pasir, dan singkapan batuan, yang vegetasi alaminya tidak ada atau hampir tidak ada. Informasi dari piksel-piksel terbuka tersebut dapat dirangkum menjadi citra pantulan tanah terbuka serta frekuensi keterbukaan setiap piksel, yang selanjutnya dapat digunakan dalam pemetaan tanah digital (Demattê et al., 2020; Roberts et al., 2019). Diek et al. (2017), misalnya, menurunkan peta kadar pasir, debu, lempung, dan bahan organik tanah dari komposit tanah terbuka yang disusun dari deret waktu citra Landsat.

Deteksi tanah terbuka bertumpu pada perbedaan pantulan antara tanah, vegetasi hijau, dan bahan tumbuhan kering, seperti serasah dan sisa tanaman. Pola pantulan ketiga jenis permukaan tersebut pada Gambar 5.1(a) dapat dijelaskan sebagai berikut:

- **Tanah terbuka**, pantulan tanah terbuka meningkat secara bertahap dari kanal biru hingga SWIR pertama, karena bahan organik dan oksida besi menyerap energi di wilayah tampak, sedangkan sebagian mineral, seperti kuarsa, memantulkan kuat di wilayah inframerah dekat dan inframerah gelombang pendek (Demattê et al., 2020). Tanah yang lembap memiliki pola yang sama dengan pantulan yang lebih rendah, sebagaimana dibahas dalam Modul 4.
- **Vegetasi hijau**, vegetasi hijau menyerap kuat di kanal merah karena klorofil, memantulkan kuat di inframerah dekat, dan menyerap di wilayah SWIR karena kandungan air daun, sebagaimana dibahas dalam Modul 1. Kontras antara kanal merah dan inframerah dekat inilah yang membuat vegetasi hijau mudah dibedakan dari tanah.
- **Serasah dan sisa tanaman kering**, bahan tumbuhan kering tidak lagi memiliki kontras merah–inframerah dekat yang tajam, sehingga di wilayah tampak dan inframerah dekat pantulannya menyerupai tanah. Daughtry (2001) menunjukkan bahwa sisa tanaman kering

memiliki serapan lebar di sekitar 2,1 µm yang berkaitan dengan lignin dan selulosa, sedangkan tanah tidak memiliki serapan tersebut.

Perbedaan ketiga pola tersebut menjelaskan mengapa vegetasi hijau relatif mudah disaring, sedangkan serasah dan sisa tanaman lebih sulit. Dvorakova et al. (2020) mencatat bahwa vegetasi yang sedang tumbuh dapat dikenali dengan mudah melalui NDVI, tetapi perbedaan antara tanah terbuka dan sisa tanaman hanya tampak di wilayah SWIR, yang pada Landsat dan Sentinel-2 hanya diwakili oleh dua kanal lebar.



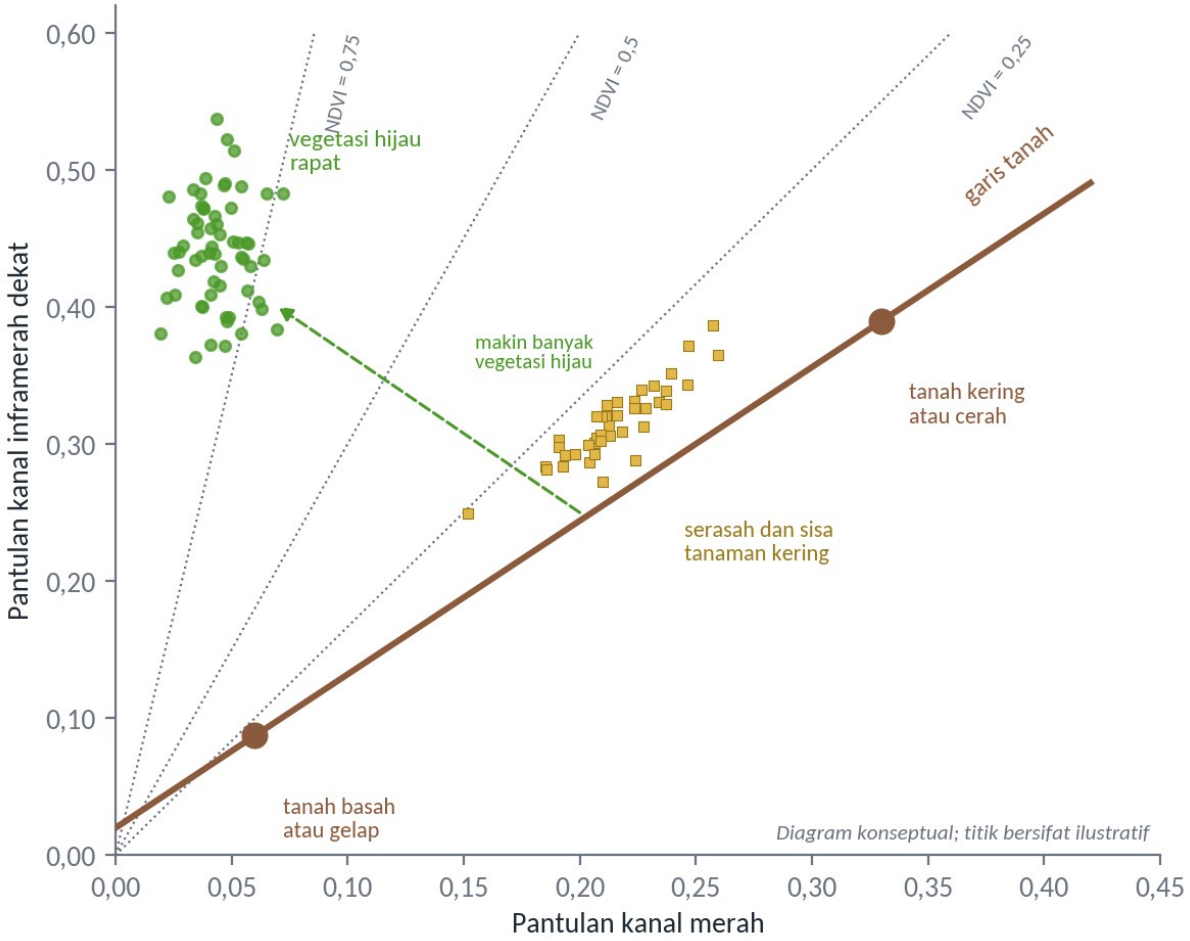
Gambar 5.1 Ilustrasi pantulan tanah terbuka, vegetasi hijau, serta serasah dan sisa tanaman kering (a) dan perubahan nilai NDVI dan NBR2 pada campuran tanah dengan penutup di dalam satu piksel (b)

Sumber: Ilustrasi skematis disusun berdasarkan Daughtry (2001) dan Demattê et al. (2020); nilai indeks pada (b) merupakan data sintetis yang dihitung dari spektrum (a) dengan model campuran linear (Adams et al., 1986); nilai ambang mengacu pada Castaldi et al. (2019) dan Demattê et al. (2020)

Satu piksel biasanya terdiri dari beberapa jenis permukaan sekaligus, sangat jarang yang hanya berisi satu jenis permukaan. Pantulan sebuah piksel dapat dipandang sebagai campuran pantulan beberapa komponen murni (*endmember*) yang dibobot menurut fraksi luasnya di dalam piksel. Konsep ini menjadi dasar model campuran spektral (*spectral mixture model*) yang dikembangkan Adams et al. (1986). Asner dan Heidebrecht (2002) menggunakan model tersebut untuk menduga fraksi vegetasi fotosintetik, vegetasi nonfotosintetik, dan tanah terbuka di lahan semak dan padang rumput kering, dan mendapati bahwa fraksi tanah terbuka cenderung diduga terlalu tinggi karena tanah memantulkan lebih kuat daripada vegetasi hijau. Campuran dalam jumlah kecil sudah cukup untuk mengubah spektrum tanah. Bartholomeus et

al. (2011) menunjukkan bahwa tutupan jagung yang hanya beberapa persen sudah menurunkan ketelitian model karbon organik secara drastis, sedangkan Castaldi et al. (2019) mencatat bahwa kehadiran vegetasi hijau atau kering lebih dari 20% dapat sangat mengubah bentuk spektrum. Gambar 5.1(b) memperlihatkan konsekuensinya dengan data sintetis. Nilai NDVI naik dengan cepat ketika fraksi vegetasi hijau bertambah, tetapi hampir tidak berubah ketika penutupnya berupa serasah, sehingga piksel yang tertutup serasah tetap lolos dari penyaringan berbasis NDVI.

Hubungan antara tanah dan vegetasi juga dapat dipahami melalui ruang pantulan kanal merah dan inframerah dekat (Gambar 5.2). Baret et al. (1993) menjelaskan konsep garis tanah (*soil line*), yaitu hubungan linear antara pantulan merah dan inframerah dekat pada tanah terbuka. Kemiringan dan titik potong garis tersebut bervariasi menurut jenis tanah dan kondisi permukaannya. Tanah yang lebih basah atau lebih gelap memiliki pantulan yang lebih rendah pada kedua kanal sehingga menempati bagian garis yang dekat dengan titik asal, sedangkan tanah yang kering atau cerah menempati bagian yang lebih jauh. Vegetasi hijau menjauh dari garis tanah ke arah pantulan inframerah dekat yang tinggi dan pantulan merah yang rendah, sedangkan serasah dan sisa tanaman kering berada dekat garis tanah. Demattê et al. (2020) memanfaatkan sifat ini untuk memeriksa mutu hasil deteksi. Piksel tanah terbuka yang benar akan berkumpul di sekitar garis tren, sedangkan vegetasi dan tutupan lain tersebar menjauh darinya.



Gambar 5.2 Garis tanah serta sebaran vegetasi hijau dan serasah pada ruang pantulan merah–inframerah dekat

Sumber: Diagram konseptual disusun berdasarkan Baret et al. (1993) dan Demattê et al. (2020)

Tantangan deteksi tanah terbuka paling besar ditemui di wilayah bervegetasi rapat. Roberts et al. (2019) mencatat bahwa di bawah hutan atau semak yang tajuknya menutup, permukaan tanah hampir tidak mungkin teramati kecuali vegetasinya dibuka, sedangkan pada vegetasi yang lebih jarang peluang memperoleh pantulan tanah dari deret waktu citra jauh lebih besar. Kondisi ini berlaku pula pada perkebunan kelapa sawit. Descals et al. (2021) hanya memetakan tegakan kelapa sawit yang tajuknya telah menutup, sehingga perkebunan muda dan jarang tidak tercakup dalam peta mereka. Danylo et al. (2021) menunjukkan bahwa fraksi tanah terbuka pada perkebunan kelapa sawit menurun seiring berkembangnya tajuk, dan perkebunan berumur sekitar dua hingga tiga tahun masih memiliki tajuk terbuka dengan nilai indeks tanah terbuka yang tinggi.

Kesempatan mengamati tanah pada blok yang telah menghasilkan terutama muncul saat peremajaan. Wibowo dan Junaedi (2017) menguraikan tahap persiapan lahan peremajaan, yaitu penumbangan, pencincangan, dan perumpukan batang kelapa sawit tua di dalam barisan

sebagai mulsa dan sumber bahan organik. Tahap ini diikuti penanaman kacangan penutup tanah untuk menutup rumpukan dan menjaga kelembapan tanah, kemudian penanaman kelapa sawit. Astuti et al. (2018) melaporkan bahwa kacangan penutup tanah ditanam sebelum kelapa sawit, dan *Pueraria javanica* dapat menutup 90–100% permukaan dalam lima hingga enam bulan setelah tanam. Dengan demikian, permukaan blok peremajaan bukan tanah terbuka yang seragam, melainkan mosaik tanah terbuka, rumpukan batang tercincang, dan kacangan penutup tanah yang tumbuh cepat. Jendela waktu pengamatan tanah terbuka pada blok tersebut hanya berlangsung beberapa bulan.

5.2. Indeks yang Digunakan dalam Bare Soil Detection

Indeks untuk deteksi tanah terbuka disusun dengan memanfaatkan kontras spektral yang telah diuraikan pada subbab sebelumnya. Secara umum, indeks tersebut dapat dikelompokkan menjadi indeks vegetasi yang bernilai rendah pada tanah, indeks tanah yang bernilai tinggi pada tanah, dan indeks yang membedakan tanah dari bahan tumbuhan kering. Kelompok pertama diwakili oleh indeks vegetasi selisih ternormalisasi (*Normalized Difference Vegetation Index*, NDVI), yaitu selisih ternormalisasi antara kanal inframerah dekat dan merah yang dikaji Tucker (1979) sebagai salah satu kombinasi kanal untuk pemantauan vegetasi. NDVI tanah terbuka umumnya rendah, sehingga nilai ambang NDVI paling sering dipakai untuk menyaring piksel tanah. Pada vegetasi yang jarang, nilai NDVI ikut dipengaruhi oleh kecerahan tanah di bawahnya. Untuk mengurangi pengaruh tersebut, Huete (1988) mengembangkan indeks vegetasi yang disesuaikan dengan tanah (*Soil-Adjusted Vegetation Index*, SAVI), yang menambahkan faktor koreksi latar tanah L ke dalam rumus NDVI (Nugraha & Citra, 2021).

Kelompok kedua diwakili oleh indeks tanah terbuka (*Bare Soil Index*, BSI), yang dikembangkan dalam model kerapatan tajuk hutan (*Forest Canopy Density*, FCD) oleh Rikimaru et al. (2002). BSI membandingkan jumlah pantulan kanal SWIR pertama dan merah dengan jumlah pantulan kanal inframerah dekat dan biru (Nugraha & Citra, 2021). Danylo et al. (2021) memanfaatkan BSI untuk mendeteksi penurunan fraksi tanah terbuka seiring berkembangnya tajuk kelapa sawit. Deret waktu BSI dari citra Landsat mereka gunakan untuk menentukan saat tajuk menutup, dan dengan cara itu memperkirakan umur perkebunan.

Kelompok ketiga memanfaatkan wilayah SWIR. Rasio pembakaran ternormalisasi kedua (*Normalized Burn Ratio 2*, NBR2) menggunakan selisih ternormalisasi kanal SWIR pertama dan kedua (Demattê et al., 2020). Karena serapan selulosa–lignin di sekitar 2,1 µm berada di dalam kanal SWIR kedua, nilai NBR2 pada serasah dan sisa tanaman lebih tinggi daripada pada tanah, sebagaimana terlihat pada Gambar 5.1(b). Pada data hiperspektral, serapan tersebut

dapat diukur lebih langsung dengan indeks serapan selulosa (*Cellulose Absorption Index*, CAI). CAI bernilai positif untuk sisa tanaman, kecuali yang jenuh air, dan negatif untuk tanah (Daughtry, 2001). Dvorakova et al. (2020) menguji pengaruh ambang CAI pada data hiperspektral wahana udara terhadap kinerja model karbon organik, dengan tujuan memisahkan tanah dari sisa tanaman. Rumus indeks-indeks tersebut beserta padanannya pada kanal Sentinel-2 disajikan pada Tabel 5.1. Pada tabel tersebut, B, G, R, NIR, SWIR1, dan SWIR2 berturut-turut menyatakan pantulan kanal biru, hijau, merah, inframerah dekat, SWIR pertama, dan SWIR kedua, sedangkan $R_{2,0}$, $R_{2,1}$, dan $R_{2,2}$ menyatakan pantulan pada kanal sempit di sekitar 2,0, 2,1, dan 2,2 μm.

Tabel 5.1 Indeks untuk Deteksi Tanah Terbuka

Indeks	Rumus	Padanan kanal Sentinel-2	Pemanfaatan
NDVI	$\frac{\text{NIR} - R}{\text{NIR} + R}$	$\frac{\text{B8} - \text{B4}}{\text{B8} + \text{B4}}$	Menyaring vegetasi hijau; tanah terbuka bernilai rendah, misalnya kurang dari 0,25 atau antara −0,25 dan 0,25
SAVI	$\frac{(1+L)(\text{NIR} - R)}{\text{NIR} + R + L}$, dengan $L = 0{,}5$	$\frac{1{,}5(\text{B8} - \text{B4})}{\text{B8} + \text{B4} + 0{,}5}$	Meredam pengaruh latar tanah pada tutupan vegetasi jarang
BSI	$\frac{(\text{SWIR1} + R) - (\text{NIR} + B)}{(\text{SWIR1} + R) + (\text{NIR} + B)}$	$\frac{(\text{B11} + \text{B4}) - (\text{B8} + \text{B2})}{(\text{B11} + \text{B4}) + (\text{B8} + \text{B2})}$	Meningkat dengan bertambahnya fraksi tanah terbuka; dalam model FCD nilainya dikalikan 100 lalu ditambah 100
NBR2	$\frac{\text{SWIR1} - \text{SWIR2}}{\text{SWIR1} + \text{SWIR2}}$	$\frac{\text{B11} - \text{B12}}{\text{B11} + \text{B12}}$	Membedakan tanah dari serasah dan sisa tanaman; tanah terbuka misalnya antara −0,30 dan 0,10
VNSIR	$1 - \left[(2R - G - B) + 3(\text{SWIR2} -$	$1 - \left[(2\text{B4} - \text{B3} - \text{B2}) + 3(\text{B12} -$	Aturan tambahan untuk permukaan terbuka; misalnya kurang dari 0,9
CAI	$100 \times \left[0{,}5(R_{2,0} + R_{2,2}) - R_{2,1}\right]$	Tidak tersedia; memerlukan data hiperspektral	Positif untuk sisa tanaman kering dan negatif untuk tanah

Sumber: Rumus dan ambang NDVI, NBR2, dan VNSIR mengikuti Demattê et al. (2020), dengan ambang NDVI kurang dari 0,25 dari Castaldi et al. (2019); SAVI dari Huete (1988) dan BSI dari Rikimaru et al. (2002), keduanya sebagaimana dituliskan Nugraha dan Citra (2021); CAI mengikuti Prajapati et al. (2019); padanan kanal Sentinel-2 berdasarkan Drusch et al. (2012)

Nilai ambang pada Tabel 5.1 tidak berlaku umum. Demattê et al. (2020) menekankan bahwa penentuan ambang untuk setiap indeks memerlukan interpretasi citra oleh tenaga ahli dan pengamatan lapangan, dan bahwa ambang yang lebar untuk pemetaan global perlu disesuaikan dengan pola spektral setempat. Mereka juga mencatat bahwa kelembapan tanah tetap dapat memengaruhi pantulan meskipun ambang telah disesuaikan dan citra telah dirata-ratakan menurut waktu. Ambang NDVI yang rendah pun tidak menjamin piksel benar-benar terbuka. Castaldi et al. (2019) menduga bahwa sebagian lahan yang tergolong tanah terbuka dengan NDVI di bawah 0,25 sudah ditumbuhi kecambah jagung, dan sebagian lain kemungkinan masih tertutup sisa tanaman dan gulma. Gambar 5.1(b) juga memperlihatkan bahwa BSI dan NDVI sulit memisahkan tanah dari serasah, sehingga penyaringan dengan indeks berbasis SWIR kedua tetap diperlukan. Selain itu, indeks tanah terbuka tidak membedakan tanah dari permukaan abiotik lain, seperti pasir, singkapan batuan, jalan, atau permukiman. Oleh karena itu, hasil penyaringan sebaiknya dipadukan dengan data penggunaan lahan. Pada perkebunan kelapa sawit, ambang juga dapat diturunkan dari data setempat. Danylo et al. (2021), misalnya, menetapkan ambang BSI dari persentil ke-95 nilai BSI pada perkebunan yang telah mapan, karena nilai tersebut bertepatan dengan perkebunan sangat muda yang tajuknya masih terbuka.

5.3. Metode Bare Soil Detection

Metode deteksi tanah terbuka berkembang dari penyaringan satu citra hingga pengolahan deret waktu citra dalam jumlah besar. Pemilihan metode bergantung pada kerapatan penutup permukaan, ketersediaan citra bebas awan, dan tujuan pemanfaatannya. Beberapa metode yang umum digunakan adalah sebagai berikut:

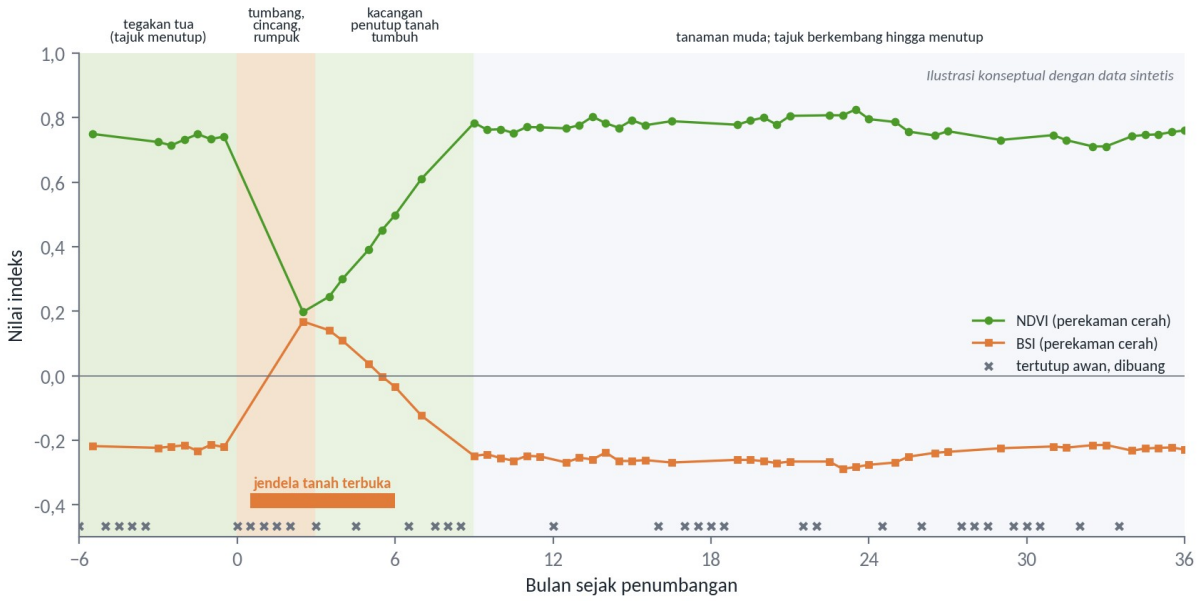
- **Ambang indeks pada citra tunggal**, metode ini memilih satu citra yang direkam ketika sebagian besar lahan terbuka, lalu menyaring piksel tanah dengan ambang indeks. Castaldi et al. (2019) menggunakan ambang NDVI kurang dari 0,25 pada citra Sentinel-2 untuk memprediksi karbon organik di lahan pertanian. Metode ini sederhana, tetapi hasilnya sangat bergantung pada waktu perekaman serta kondisi kelembapan dan penutup permukaan pada saat itu.
- **Aturan gabungan beberapa indeks**, metode ini menerapkan beberapa indeks secara bersamaan pada setiap citra. Algoritme *Geospatial Soil Sensing System* (GEOS3) yang

digunakan Demattê et al. (2020), misalnya, menandai suatu piksel sebagai permukaan terbuka apabila NDVI, NBR2, dan VNSIR berada dalam rentang tertentu, setelah awan, bayangan, dan piksel bermasalah lainnya disingkirkan dengan lapisan mutu citra. Penggabungan indeks yang memanfaatkan wilayah tampak, inframerah dekat, dan SWIR memungkinkan vegetasi hijau dan bahan tumbuhan kering disaring sekaligus.

- **Komposit multitemporal**, metode ini memanfaatkan banyak citra pada piksel yang sama untuk memperoleh kondisi paling terbuka. Diek et al. (2017) memilih pengamatan yang paling sedikit bervegetasi, yang disebut piksel terbersih (*barest pixel*), dari deret waktu Landsat 1985–2017, dan mendapati bahwa sekitar lima tahun data Landsat diperlukan untuk komposit yang mencakup 90% luas maksimum tanah terbuka. Rogge et al. (2018) mengembangkan *Soil Composite Mapping Processor* (SCMaP), yang menyusun komposit per piksel untuk mengatasi keterbatasan keterbukaan tanah, terutama di wilayah yang tanahnya jarang terbuka. Demattê et al. (2020) menggabungkan semua pengamatan yang tertandai terbuka dengan nilai median dan menghitung frekuensi keterbukaan setiap piksel, sedangkan Roberts et al. (2019) menggunakan median geometrik berbobot yang memberi bobot menurut tingkat keterbukaan, alih-alih menyaring, sehingga setiap piksel tetap memperoleh nilai. Loiseau et al. (2019) menyusun mosaik tanah terbuka dari citra Sentinel-2 yang direkam pada masa tanam.
- **Pemisahan campuran spektral**, metode ini menduga fraksi tanah, vegetasi hijau, dan bahan tumbuhan kering di dalam setiap piksel dengan model campuran spektral (Adams et al., 1986; Asner & Heidebrecht, 2002). Bartholomeus et al. (2011) mengembangkan pemisahan campuran residual (*residual spectral unmixing*), yang menghilangkan pengaruh tanaman jagung dari spektrum campuran, sehingga sisa spektrum tanahnya dapat dipakai untuk memetakan karbon organik dengan ketelitian yang setara dengan tanah terbuka. Metode ini memperluas wilayah yang dapat dianalisis ke piksel yang sebagian tertutup vegetasi. Namun, pemisahan tanah dari sisa tanaman telah terbukti pada data hiperspektral, sedangkan kemampuannya pada data multispektral Sentinel-2 masih perlu diuji (Castaldi et al., 2019).
- **Analisis deret waktu dan klasifikasi**, metode ini memantau perubahan indeks atau kelas tutupan lahan dari waktu ke waktu. Danylo et al. (2021) menghitung median BSI dalam jendela bergerak 12 bulan dari citra Landsat yang awannya telah disaring, mengabaikan periode dengan kurang dari tiga pengamatan, lalu menelusuri deret waktu tersebut ke belakang hingga BSI turun di bawah ambang. Descals et al. (2021) melatih jaringan saraf konvolusional dengan citra Sentinel-1 dan Sentinel-2 untuk memetakan tegakan kelapa

sawit bertajuk tertutup, antara lain dengan memanfaatkan respons hamburan balik tegakan dan pola jaringan jalan panen. Data radar bermanfaat dalam pemantauan semacam ini karena mampu menembus awan (Danylo et al., 2021), sehingga dapat melengkapi citra optik yang sering terhalang awan.

Kelima metode tersebut tidak saling meniadakan. Penyaringan dengan aturan indeks menjadi inti dari hampir semua metode, komposit multitemporal memperbesar luas tanah yang teramati, sedangkan pemisahan campuran spektral dan analisis deret waktu membantu menafsirkan piksel yang tidak sepenuhnya terbuka. Gambar 5.3 mengilustrasikan bagaimana NDVI dan BSI pada satu blok peremajaan kelapa sawit dapat berubah dari tegakan tua hingga tanaman muda. Penurunan NDVI dan kenaikan BSI menandai jendela tanah terbuka yang pendek setelah penumbangan. Sebagian perekaman pada jendela tersebut dapat hilang karena awan, sehingga kerapatan deret waktu sangat menentukan. Konstelasi Sentinel-2A dan Sentinel-2B, misalnya, memungkinkan perekaman ulang setiap lima hari atau kurang (Main-Knorn et al., 2017).

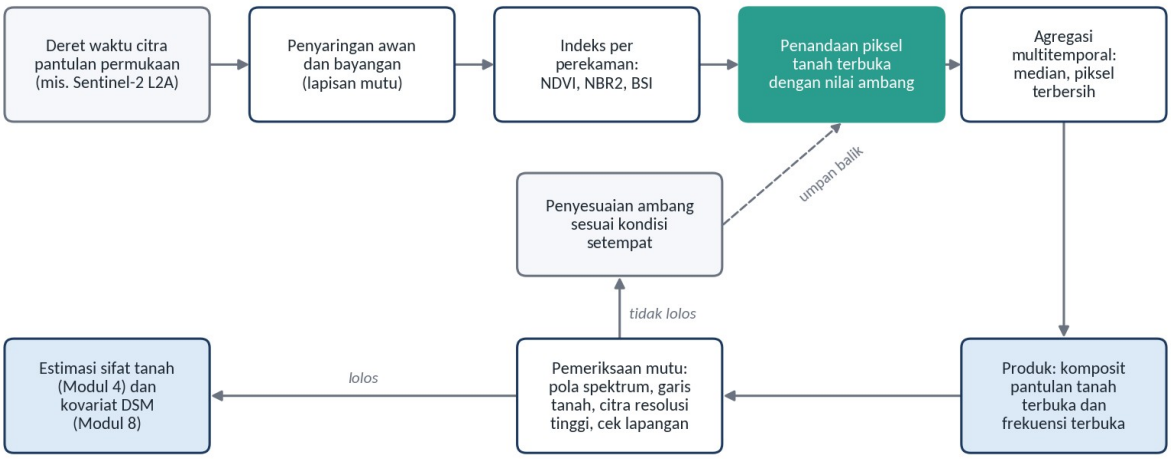


Gambar 5.3 Ilustrasi perubahan NDVI dan BSI pada satu blok peremajaan kelapa sawit dengan kacangan penutup tanah

Sumber: Ilustrasi konseptual dengan data sintetis; urutan kegiatan dan perkiraan waktunya disusun berdasarkan Wibowo dan Junaedi (2017), Astuti et al. (2018), dan Danylo et al. (2021)

Hasil deteksi tanah terbuka selalu perlu diperiksa sebelum digunakan. Dematthê et al. (2020) memeriksa mutu citra tanah terbuka melalui pola spektrumnya, yang seharusnya meningkat dari kanal biru hingga SWIR pertama, serta melalui sebaran piksel terhadap garis tanah. Danylo et al. (2021) mengonfirmasi ambang yang digunakan dengan interpretasi visual

citra resolusi tinggi, sedangkan Demattê et al. (2020) menekankan perlunya pengamatan lapangan. Apabila hasil pemeriksaan belum memadai, ambang disesuaikan dengan kondisi setempat dan proses penandaan diulang. Alur umum deteksi tanah terbuka dari deret waktu citra ditunjukkan pada Gambar 5.4.



Gambar 5.4 Alur umum deteksi tanah terbuka dari deret waktu citra
Sumber: Diagram konseptual disusun berdasarkan Demattê et al. (2020), Diek et al. (2017), dan Roberts et al. (2019)

Bagi perkebunan kelapa sawit, uraian tersebut memiliki beberapa konsekuensi praktis. Pertama, tanah terbuka terutama dapat diamati pada blok peremajaan dan pembukaan lahan, dengan jendela waktu yang hanya berlangsung beberapa bulan sebelum tertutup kacangan penutup tanah. Kedua, karena permukaan blok tersebut bercampur dengan rumpukan batang tercincang, penyaringan perlu memanfaatkan indeks berbasis SWIR kedua dan diperiksa dengan citra resolusi tinggi atau pengamatan lapangan. Ketiga, karena blok-blok diremajakan pada waktu yang berbeda, komposit dari deret waktu yang panjang memungkinkan semakin banyak blok teramati dalam keadaan terbuka, sejalan dengan temuan Diek et al. (2017) bahwa komposit yang lengkap memerlukan data beberapa tahun. Keempat, permukaan blok peremajaan telah diolah dengan alat berat, seperti ekskavator untuk penumbangan dan pencincangan (Wibowo & Junaedi, 2017), sehingga keterwakilan pantulannya terhadap lapisan tanah yang diambil sampelnya perlu diperiksa, sebagaimana dibahas dalam Modul 4. Untuk blok yang tajuknya telah menutup, informasi tanah tetap perlu diperoleh secara tidak langsung melalui kovariat lingkungan (Modul 8) atau melalui pengukuran proksimal di lapangan (Modul 7).

6. Interpretasi Pedologis dari Data Remote Sensing

Ceramah dan diskusi:

6.1. Kunci Interpretasi Citra Penginderaan Jauh

Interpretasi pedologis adalah proses menerjemahkan kenampakan pada citra penginderaan jauh menjadi informasi tentang tanah, terutama tentang sebaran dan batas satuan tanah. Proses ini berbeda dari interpretasi objek lain karena tanah sendiri jarang tampak pada citra. Buringh (1955) membedakan interpretasi objek yang tampak jelas pada foto udara, seperti vegetasi, yang ukuran, bentuk, tekstur, dan warnanya dapat dipelajari secara langsung, dari interpretasi tanah. Tanah umumnya tertutup oleh rumput, pohon, atau tanaman, sehingga tidak dapat dikenali dan diartikan secara langsung dari gambar fotonya. Interpretasi pedologis karenanya bekerja melalui kenampakan lanskap yang dapat dilihat dan berkaitan dengan pembentukan tanah. Dasar pemikiran ini dirumuskan Rossiter (2000) sebagai hipotesis survei tanah, yaitu bahwa pola sebaran tanah dapat diramalkan dan dikorelasikan dengan kenampakan luar yang lebih mudah dipetakan, seperti geomorfologi, vegetasi, penggunaan lahan saat ini, dan catatan sejarah. Kenampakan luar tersebut dibaca melalui unsur-unsur interpretasi citra, yang telah diperkenalkan secara ringkas dalam Modul 3 sebagai petunjuk batas satuan peta tanah (Tabel 3.2). Subbab ini menguraikan setiap unsur secara lebih rinci beserta makna pedologisnya, kemudian membahas keterkaitan faktor pembentuk tanah dengan kenampakan pada citra serta penyusunan kunci interpretasi untuk keperluan pedologis.

Unsur interpretasi citra adalah ciri-ciri kenampakan yang digunakan penafsir untuk mengenali objek dan membedakannya dari latar di sekitarnya. Natural Resources Canada (2025) menegaskan bahwa pengenalan objek merupakan kunci bagi interpretasi dan ekstraksi informasi, dan bahwa perbedaan antara objek dan latarnya diamati dengan membandingkan sebagian atau seluruh unsur rona, bentuk, ukuran, pola, tekstur, bayangan, dan asosiasi. Lillesand et al. (2015) dan Sutanto (1994) juga memasukkan situs, yaitu kedudukan objek di dalam lanskapnya. Unsur-unsur tersebut tidak sama tingkat kerumitannya. Rona merupakan unsur yang paling mendasar, karena variasi rona memungkinkan bentuk, tekstur, dan pola objek dikenali (Natural Resources Canada, 2025). Sebaliknya, situs dan asosiasi menuntut pemahaman tentang hubungan suatu objek dengan objek lain dan dengan lanskap di sekitarnya. Pengamatan stereoskopis juga sangat membantu. Citra dua dimensi menghilangkan kesan kedalaman, sedangkan pengamatan stereo memulihkan kesan ketinggian sehingga pengenalan objek meningkat secara nyata (Natural Resources Canada, 2025). Terdapat sembilan kunci/unsur interpretasi, yaitu:

1. Rona dan warna (tone and color)

Rona (tone) adalah tingkat kecerahan atau kegelapan relatif objek pada citra saluran tunggal, sedangkan warna (color) merupakan hasil kombinasi respons beberapa saluran spektral. Pada tanah terbuka, permukaan yang lebih gelap dapat berkaitan dengan kandungan bahan organik atau kadar air yang lebih tinggi. Rona cerah dapat dijumpai pada pasir kuarsa, permukaan tanah yang kering, material karbonatan, garam, atau horizon permukaan yang telah kehilangan bahan organik. Warna merah hingga kuning kecokelatan dapat berkaitan dengan oksida besi, tetapi hubungan ini dipengaruhi mineralogi, kelembapan, pencahayaan, dan pengolahan citra.

Pemilihan komposit kanal membantu menonjolkan objek yang berbeda:

- Komposit warna asli (true color; Sentinel-2 RGB = B04–B03–B02) mendekati persepsi mata manusia dan berguna untuk mengenali tanah terbuka, tubuh air, serta objek buatan.
- Komposit inframerah warna semu (standard false color; RGB = B08–B04–B03) menampilkan kanal NIR pada saluran merah sehingga vegetasi sehat umumnya tampak merah, dengan variasi warna menurut struktur tajuk dan kondisi vegetasi (Riebeek, 2014).
- Komposit SWIR–NIR–Red (RGB = B11–B08–B04 atau B12–B08–B04) dapat membantu membedakan variasi kelembapan, vegetasi, tanah terbuka, dan permukaan buatan. Warna yang tampil bergantung pada susunan kanal dan rentang peregangan citra.

Karena rona dan warna juga berubah akibat bayangan, atmosfer, sudut penyinaran, dan respons sensor, interpretasi pedologis sebaiknya selalu diperiksa menggunakan kunci lain serta data pendukung.

2. Tekstur citra (image texture)

Tekstur citra adalah kesan halus atau kasar yang terbentuk dari variasi rona antarpiksel yang bertetangga. Konsep ini berbeda dari tekstur tanah (soil texture), yaitu proporsi fraksi pasir, debu, dan lempung. Tekstur citra dapat membantu mengenali homogenitas permukaan, struktur tajuk, pola erosi, dan batas penggunaan lahan; tetapi tidak secara langsung memberikan persentase fraksi tanah.

Pada citra digital, tekstur lokal dapat didekati melalui simpangan baku nilai piksel dalam jendela bergerak atau melalui ukuran berbasis Gray-Level Co-occurrence Matrix (GLCM), seperti kontras dan entropi (Danoedoro, 1996; Haralick et al., 1973). Untuk simpangan baku sampel dalam jendela W yang berpusat pada lokasi (x,y), bentuk umumnya adalah:

$$\sigma lokal(x,y) = \sqrt{\frac{\sum \rho(i,j) - \rho\bar{W}^2}{Nw - 1}}$$

Di sini, ρ(i,j) adalah nilai piksel pada lokasi (i,j), ρ̄W adalah rerata nilai piksel dalam jendela, dan Nw adalah jumlah piksel pada jendela tersebut. Untuk jendela 3×3, Nw = 9. Simpangan baku rendah menunjukkan nilai piksel relatif homogen, sedangkan nilai tinggi menunjukkan variasi radiometrik lebih besar. Hasilnya tetap dipengaruhi resolusi spasial, ukuran jendela, kontras pencahayaan, dan jenis penutup lahan.

Sebagai contoh, hamparan sawah atau rumput yang seragam dapat tampak bertekstur halus; hutan atau kebun campur bertajuk berlapis dapat tampak lebih kasar karena variasi tajuk dan bayangan. Pada perkebunan, perbedaan tekstur antarblok dapat membantu menandai variasi struktur kanopi, tetapi umur tanaman atau status kesehatan tidak boleh dipastikan dari tekstur saja tanpa verifikasi.

3. Pola (pattern)

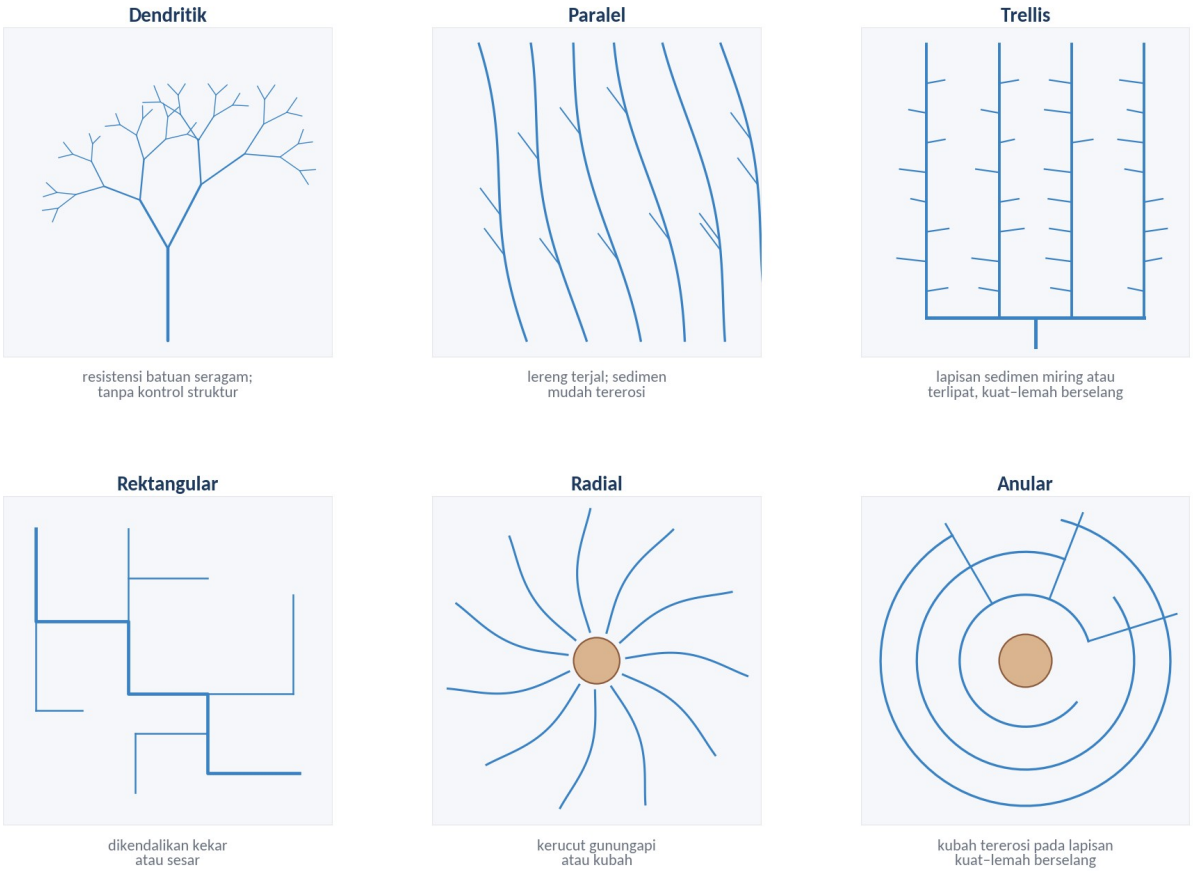
Pola adalah susunan keruangan objek yang berulang atau memiliki keteraturan tertentu. Dalam interpretasi lanskap, pola aliran sungai dan pola tata ruang lahan sering menjadi petunjuk penting. Pola dendritik dapat berkembang pada material yang relatif homogen; pola paralel dapat berhubungan dengan lereng yang memanjang dan seragam; sedangkan pola rektangular atau trelis dapat mencerminkan pengaruh struktur geologi. Pola tidak secara tunggal menentukan jenis batuan atau tanah, sehingga perlu diperiksa bersama geologi, relief, dan bukti lapangan.

Kerapatan drainase dapat dihitung sebagai rasio total panjang saluran terhadap luas daerah tangkapan (Carlston, 1963):

$$Dd = \frac{\Sigma Li}{A}$$

Di sini, ΣLi adalah jumlah panjang saluran yang dipetakan dan A adalah luas wilayah kajian. Satuan lazimnya km/km². Kerapatan drainase dipengaruhi permeabilitas, relief, iklim, litologi, tutupan lahan, dan skala pemetaan; karena itu, nilai tinggi atau rendah bukan bukti langsung tekstur tanah tertentu.

Pada perkebunan, pola jalan koleksi, kanal drainase, batas blok, dan barisan tanaman dapat membedakan tata ruang perkebunan terencana dari mosaik kebun rakyat atau vegetasi sekunder (Dadap et al., 2021). Jarak tanam dan ukuran blok harus disesuaikan dengan desain kebun yang benar-benar diamati.



Gambar 6.1 Pola dasar aliran dan faktor geologi yang mengendalikannya
Sumber: Diagram konseptual; jenis pola dan faktor pengendalinya mengacu pada Howard (1967) dan Sulaiman et al. (2021)

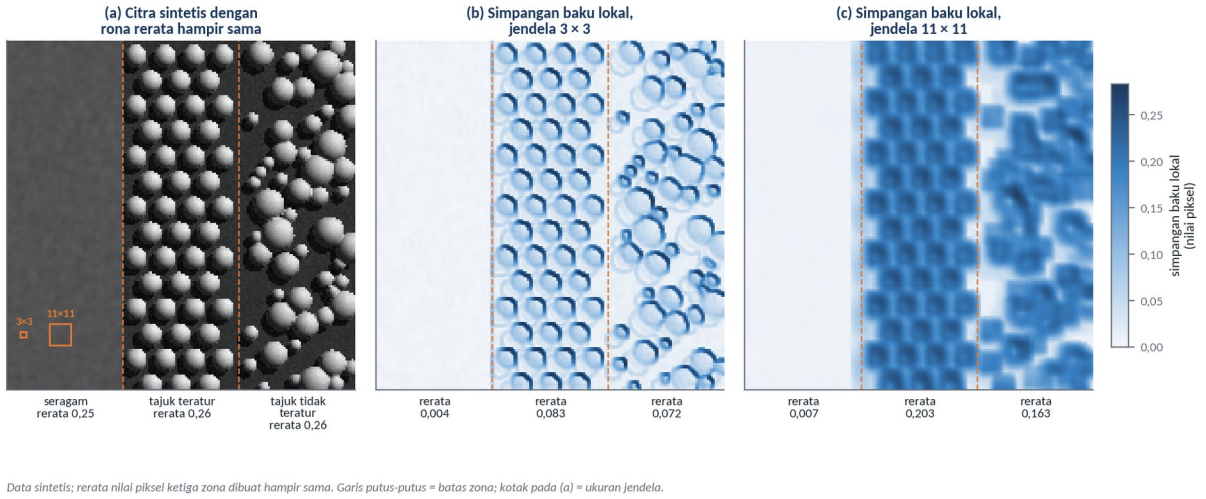
4. Bentuk (shape)

Bentuk merujuk pada konfigurasi geometris dan garis batas objek. Bentuk pita memanjang dan berkelok di dasar lembah dapat menunjukkan dataran aluvial atau koluvial; bentuk kipas di mulut lembah dapat mengindikasikan kipas aluvial; sedangkan cekungan berbentuk tapal kuda yang diikuti tubuh material memanjang di bawahnya dapat menjadi petunjuk gerakan massa. Bentuk tersebut merupakan petunjuk geomorfologi, bukan identifikasi definitif, dan perlu dikonfirmasi melalui relief, jaringan drainase, geologi, serta survei lapangan.

5. Ukuran (size)

Ukuran meliputi panjang, lebar, luas, tinggi, atau dimensi relatif suatu objek. Ukuran petak dapat membantu membedakan fragmentasi lahan dan pola pengelolaan, sedangkan luas bentuk lahan membantu menentukan skala delineasi. Petak sawah sempit di perbukitan dapat berbeda dari petak luas di dataran aluvial; blok perkebunan komersial juga dapat memiliki ukuran yang lebih seragam. Akan tetapi, ukuran objek tidak secara langsung menunjukkan nilai

sifat tanah. Batas minimum pemetaan dan ukuran objek yang dapat dikenali harus mempertimbangkan resolusi spasial citra.



Gambar 6.2 Ilustrasi tekstur citra dan simpangan baku lokal dengan dua ukuran jendela
Sumber: Ilustrasi konseptual dengan data sintetis; ukuran tekstur dan pengaruh ukuran jendela mengacu pada Hall-Beyer (2017)

6. Bayangan (shadow)

Bayangan terbentuk ketika objek menghalangi datangnya radiasi atau ketika relief mengubah iluminasi permukaan. Bayangan dapat memperjelas punggungan, lembah, tebing teras, gawir longsor, dan perbedaan tinggi tajuk (Highland & Bobrowsky, 2008). Model hillshade dari DEM juga dapat membantu memperlihatkan relief. Namun, bayangan mengurangi informasi spektral permukaan yang tertutup dan dapat disalahartikan sebagai objek gelap atau kondisi basah. Saat mengekstraksi nilai spektral, area bayangan perlu dikenali dan ditangani secara konsisten.

7. Situs (site)

Situs menunjukkan kedudukan objek dalam konteks lingkungan fisiknya, terutama posisi topografi dan hubungan dengan lereng, elevasi, serta jaringan hidrologi. Dalam analisis katena, posisi dapat dibedakan menjadi punggungan atau interfluve, bahu lereng, lereng tengah, kaki lereng, dan dasar lembah. Posisi tersebut memengaruhi redistribusi air dan sedimen: bagian atas lereng sering lebih rentan terhadap erosi, sedangkan kaki lereng dan dataran koluvial dapat menjadi lokasi akumulasi material dan rembesan air.

Dalam Digital Soil Mapping (DSM), situs dapat direpresentasikan dengan kovariat medan seperti elevasi, kemiringan, kelengkungan, Topographic Position Index (TPI), dan

Topographic Wetness Index (TWI). Variabel tersebut menjelaskan konteks topografi yang berpotensi mengontrol distribusi tanah, tetapi interpretasinya harus memperhatikan resolusi DEM, skala analisis, dan karakteristik wilayah.

8. Asosiasi (association)

Asosiasi adalah keterkaitan spasial atau fungsional antara objek yang sering dijumpai bersama. Contohnya, sawah berteras dapat berasosiasi dengan lahan relatif landai, jaringan irigasi, dan kondisi hidrologis tertentu; vegetasi riparian dapat berasosiasi dengan koridor sungai dan proses deposisi; kanal drainase di lahan rawa dapat mengindikasikan pengelolaan muka air. Asosiasi membantu membangun hipotesis tentang lingkungan tanah, tetapi bukan bukti bahwa tanah di lokasi tersebut memiliki klasifikasi atau sifat tertentu.

Hubungan antarobjek dapat dianalisis secara spasial, misalnya dengan tabulasi silang antara satuan bentuk lahan dan penggunaan lahan. Hasilnya menunjukkan pola keterkaitan dalam data, bukan dengan sendirinya membuktikan hubungan sebab-akibat.

9. Konvergensi bukti (convergence of evidence)

Konvergensi bukti adalah penggabungan beberapa kunci interpretasi dan sumber data untuk menentukan penjelasan yang paling konsisten. Tidak ada satu kunci yang selalu cukup: rona merah muda pada komposit tertentu dapat berasal dari tanah terbuka atau atap bangunan, sedangkan tekstur citra halus dapat berasal dari sawah, rumput, atau permukaan lain yang homogen. Penafsir perlu menguji interpretasi dengan menggabungkan warna, tekstur, bentuk, pola, situs, asosiasi, DEM, geologi, penggunaan lahan, dan pengamatan lapangan.

Sebagai ilustrasi, dugaan satuan lembah yang lembap dapat diperkuat apabila poligon berada pada dasar lembah, memiliki bentuk memanjang mengikuti sungai, berasosiasi dengan sawah atau vegetasi riparian, serta menunjukkan indikator kelembapan yang konsisten. Namun, simpulan tersebut tetap merupakan hipotesis pemetaan sampai dikonfirmasi dengan pengamatan tanah, kondisi hidrologis, dan data pendukung yang memadai.

Tidak ada satu unsur pun yang cukup untuk menarik kesimpulan. Rona yang sama dapat dihasilkan oleh objek yang berbeda, dan tekstur halus dapat berasal dari lahan pertanian, padang rumput, atau permukaan seragam lainnya. Karena itu, penafsir perlu menggabungkan beberapa unsur sekaligus. Natural Resources Canada (2025) mencontohkan bahwa jembatan dikenali dari bentuk, rona, dan asosiasinya dengan sungai yang dilintasinya, sedangkan bendungan dikenali dari rona yang kontras dengan sungai yang gelap, bentuknya, dan asosiasinya dengan sungai. Penggabungan beberapa unsur yang saling menguatkan ini dikenal sebagai konvergensi bukti (*convergence of evidence*). Dalam interpretasi foto udara untuk

survei tanah, prinsip yang sama mendasari pendekatan analisis unsur, yang mencari kombinasi unik unsur-unsur interpretasi (Rossiter, 2000), serta penilaian batas berdasarkan kemunculannya pada beberapa analisis unsur yang terpisah (Buringh, 1954), yang dibahas pada subbab berikutnya. Sebagai ilustrasi konseptual, dugaan adanya satuan dasar lembah yang basah menjadi lebih kuat apabila poligonnya berada pada posisi terendah dalam lanskap, berbentuk memanjang mengikuti alur, berona gelap atau tampak kebiruan pada komposit inframerah gelombang pendek saat lahan terbuka, dan berasosiasi dengan sawah atau vegetasi rawa. Dugaan tersebut tetap merupakan hipotesis pemetaan sampai dikonfirmasi dengan pengamatan tanah di lapangan.

Unsur-unsur interpretasi tersebut memperoleh makna pedologisnya melalui faktor-faktor pembentuk tanah yang telah dibahas dalam Modul 1 (McBratney et al., 2003). Tidak semua faktor sama mudahnya untuk dikenali pada citra. Rossiter (2000) menyatakan bahwa pemetaan berbasis analisis lanskap paling efektif apabila faktor yang dominan di suatu wilayah adalah bahan induk, relief, dan waktu, bukan organisme dan iklim. Buringh (1954) juga mencatat bahwa unsur-unsur interpretasi tidak sama bobotnya. Bentuklahan dan lereng umumnya menunjukkan perbedaan tanah yang besar, sedangkan perbedaan vegetasi umumnya hanya menunjukkan perbedaan yang kecil. Kenampakan setiap faktor pembentuk tanah pada data penginderaan jauh dirangkum pada Tabel 6.1.

Tabel 6.1 Faktor Pembentuk Tanah dan Kenampakannya pada Data Penginderaan Jauh

Faktor	Kenampakan pada citra dan data turunan	Petunjuk pedologis	Catatan
Relief	Bentuk dan kemiringan lereng, posisi pada lereng, bayangan medan, model elevasi	Perbedaan proses pada setiap posisi lereng, misalnya tanah berkembang di tempat pada punggungan dan tanah koluvial di kaki lereng	Unsur yang paling sering menunjukkan perbedaan tanah yang besar
Bahan induk	Bentuklahan, pola dan kerapatan aliran, rona, singkapan batuan	Jenis batuan atau endapan serta struktur geologinya	Sering memerlukan peta geologi atau pengetahuan wilayah
Waktu	Tingkat pengikisan, teras bertingkat, permukaan geomorfik yang dibatasi lereng terjal	Umur paparan permukaan yang memengaruhi tingkat perkembangan tanah	Hanya memberi urutan umur relatif
Organisme	Tipe vegetasi alami, penggunaan lahan	Vegetasi penciri kondisi basah atau kering,	Vegetasi umumnya bukan petunjuk yang

Faktor	Kenampakan pada citra dan data turunan	Petunjuk pedologis	Catatan
		payau atau asin, dan tanah dalam atau dangkal; penggunaan lahan tertentu, seperti sawah	andal karena kuatnya pengaruh manusia
Iklim	Perbedaan tipe vegetasi dan penggunaan lahan antarwilayah	Rezim kelembapan dan suhu tanah	Jarang bervariasi pada skala kebun
Kondisi air	Rona gelap atau basah, jarak terhadap alur, vegetasi rawa	Kelas drainase dan kedalaman muka air tanah	Paling jelas pada perekaman saat lahan basah dan terbuka

Sumber: Rangkuman penulis berdasarkan Buringh (1954, 1955), Rossiter (2000), Howard (1967), dan Sulaiman et al. (2021)

Relief merupakan faktor yang paling mudah dibaca, baik melalui pengamatan stereoskopis, bayangan medan, maupun model elevasi digital, dan tampil terutama melalui unsur bentuk, bayangan, dan situs. Bahan induk biasanya disimpulkan dari bentuklahan serta pola dan kerapatan aliran, sebagaimana diuraikan di atas. Meskipun demikian, Rossiter (2000) mengingatkan bahwa litologi kadang dapat dikenali dari citra saja, tetapi sering memerlukan pengetahuan sebelumnya tentang wilayah atau peta geologi.

Faktor waktu dan kondisi air juga dapat dikenali secara tidak langsung. Rossiter (2000) memberi contoh dari dataran pantai Atlantik di Carolina Utara, Amerika Serikat. Di wilayah tersebut, permukaan geomorfik yang berbeda umur paparannya dipisahkan oleh lereng terjal yang jelas, sedangkan kedalaman muka air tanah dapat diduga dari jarak vertikal dan horizontal terhadap alur drainase serta dari kebasahan permukaan pada foto yang direkam ketika lahan tidak ditanami. Faktor organisme dapat dibaca melalui vegetasi dan penggunaan lahan, tetapi dengan hati-hati. Buringh (1955) menilai vegetasi umumnya bukan unsur yang andal karena tidak berhubungan langsung dengan kondisi tanah dan telah banyak diubah oleh manusia, meskipun beberapa tipe vegetasi tertentu dapat menunjukkan kondisi basah atau kering, air tawar atau payau, dan tanah yang dalam atau dangkal. Penggunaan lahan kadang berkorelasi dengan tanah, seperti contoh sawah dan kanal drainase pada pembahasan asosiasi. Sebaliknya, pada perkebunan monokultur seperti kelapa sawit, satu jenis penggunaan lahan menutupi berbagai jenis tanah, sehingga penggunaan lahan itu sendiri hampir tidak memberi petunjuk pedologis, kecuali melalui kenampakan yang menyertainya, seperti kanal drainase di lahan gambut.

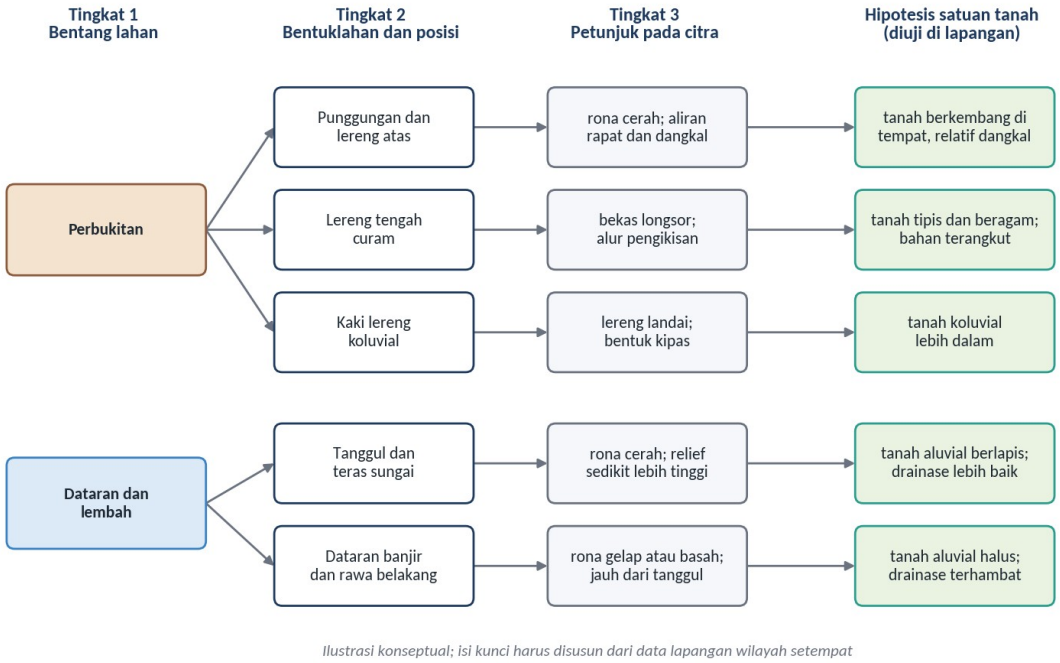
Agar petunjuk-petunjuk tersebut dapat dibaca secara konsisten, penafsir menggunakan kunci interpretasi. Sebagaimana diuraikan dalam Modul 3, kunci interpretasi adalah kumpulan contoh citra dan uraian ciri-ciri kenampakan yang membantu penafsir mengenali objek secara konsisten (Lillesand et al., 2015). Kunci tersebut disusun dari unsur-unsur interpretasi yang telah diuraikan di atas. Dalam interpretasi pedologis, kunci tidak berhenti pada pengenalan objek, tetapi menghubungkan kombinasi unsur pada citra dengan satuan lanskap dan dengan tanah yang diharapkan di dalamnya. Buringh (1955) mencatat bahwa terdapat sekitar seratus unsur yang dapat dianalisis untuk keperluan survei tanah, dan sekitar lima puluh di antaranya selalu menunjukkan perbedaan atau kesamaan kondisi tanah, meskipun pada kebanyakan tipe lahan hanya lima hingga sepuluh unsur yang perlu dianalisis. Untuk vegetasi, Buringh (1954) menyebut pentingnya kunci foto bagi tipe-tipe vegetasi penciri. Rossiter (2000) menguraikan kunci pemetaan lapangan (*field mapping key*) yang disusun dari tiga aspek berikut:

- **Posisi lanskap**, yang membatasi kemungkinan tanah menurut bentang lahan dan posisinya, misalnya teras dataran pantai tertentu atau kedudukan dalam suatu katena.
- **Kenampakan luar**, yaitu segala sesuatu yang secara konsisten mengendalikan pembentukan tanah di wilayah tersebut dan mudah dilihat di lapangan maupun pada foto udara, seperti tipe vegetasi alami dan litologi, serta segala sesuatu yang secara konsisten berkorelasi dengan jenis tanah, seperti penggunaan lahan.
- **Morfologi**, yaitu ciri profil tanah, seperti kedalaman horizon argilik, karatan, dan susunan tekstur, yang memberi identifikasi akhir tanah dan sebaiknya dapat diamati dengan pengeboran dangkal.

Dua aspek pertama dapat dibaca dari citra, sedangkan aspek ketiga hanya dapat diperoleh di lapangan. Rossiter (2000) menekankan bahwa di wilayah yang terbatas hanya diperlukan sedikit ciri diagnostik untuk membedakan tanah yang mungkin ada, sehingga kunci semacam ini juga dapat digunakan oleh tenaga yang kurang berpengalaman. Dengan demikian, kunci interpretasi pedologis selalu bersifat lokal. Kunci yang disusun di satu wilayah hanya berlaku di wilayah lain yang hubungan tanah–lanskapnya serupa.

Penyusunan kunci dimulai dari wilayah acuan yang telah diamati di lapangan. Dalam pendekatan geopedologi (Zinck, 2023), Rossiter (2000) menguraikan bahwa satuan dipisahkan secara bertingkat menurut bentang lahan, tipe relief, litologi, dan bentuklahan. Wilayah sampel berupa transek selebar 1–2 km yang mencakup sekitar 10% luas daerah kemudian dipilih untuk pengamatan tanah. Pengamatan dilakukan pada lokasi yang representatif dan dilengkapi dengan pengeboran tambahan untuk menguji keseragaman satuan serta untuk mempelajari toposekuen. Aturan interpretasi yang diperoleh dari wilayah sampel kemudian

diekstrapolasikan ke daerah lain dan diperiksa dengan pengamatan tambahan, sehingga 80–90% pengamatan berada di wilayah sampel dan 10–20% di daerah ekstrapolasi. Buringh (1954) menyebut cara serupa sebagai metode interpolasi, yaitu jalur-jalur tertentu dipetakan dengan analisis foto dan kerja lapangan, sedangkan jalur di antaranya dipetakan dengan analisis foto saja. Contoh bentuk kunci bertingkat yang dihasilkan dari proses tersebut ditunjukkan pada Gambar 6.3.



Gambar 6.3 Contoh kunci interpretasi bertingkat untuk satuan tanah–lanskap
Sumber: Ilustrasi konseptual; urutan tingkat mengikuti hierarki geopedologi dalam Rossiter (2000), sedangkan hipotesis tanah disusun berdasarkan Dalrymple et al. (1968), Buringh (1954), dan Rossiter (2000)

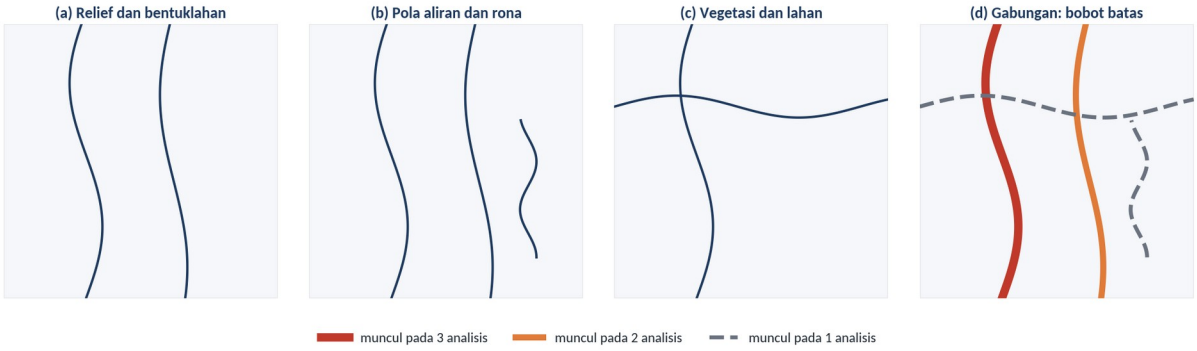
Penulisan kunci interpretasi juga merupakan cara untuk menjadikan pengetahuan penafsir dapat dipelajari orang lain. Hudson (1992) menunjukkan bahwa survei tanah bertumpu pada paradigma tanah–lanskap, dan bahwa ketergantungan yang sangat besar pada pengetahuan tasit, yaitu pengetahuan yang diperoleh dari pengalaman dan sulit diungkapkan, menimbulkan inefisiensi dalam mempelajari paradigma tersebut maupun dalam menyebarkan hasilnya. Ia menganjurkan agar hubungan geografis tanah yang ditemukan selama pemetaan diuraikan dan dipublikasikan. Kunci interpretasi yang tertulis, lengkap dengan contoh citra dan hasil pengamatan lapangannya, merupakan salah satu bentuk konkret dari anjuran tersebut.

6.2. Interpretasi Pola Citra Menjadi Informasi Pedologis

Penerjemahan pola citra menjadi informasi pedologis berlangsung dalam dua tahap yang perlu dibedakan. Buringh (1954) memisahkan analisis foto pedologis, yaitu pengenalan objek

dan pola yang mewakili satuan pemetaan tanah serta penarikan batas-batasnya secara teliti, dari klasifikasi satuan-satuan hasil analisis tersebut. Tahap pertama dapat dikerjakan dari citra, sedangkan tahap kedua memerlukan pengamatan lapangan dan analisis laboratorium karena banyak sifat tanah, seperti kandungan kapur dan warna lapisan bawah, tidak tampak pada foto. Satuan yang tampak sama pada analisis juga belum tentu merupakan satuan yang sama pada peta tanah akhir, sehingga semua satuan hasil analisis harus dipelajari di lapangan (Buringh, 1954).

Pada tahap analisis, prinsip konvergensi bukti juga berlaku pada penarikan batas. Keyakinan terhadap suatu batas meningkat apabila batas tersebut muncul dari beberapa unsur yang dianalisis secara terpisah. Buringh (1954) mencontohkan analisis yang dilakukan secara terpisah untuk beberapa unsur. Batas yang muncul berulang pada beberapa analisis menunjukkan bahwa satuan yang dipisahkannya berbeda dalam lebih dari satu sifat, sedangkan batas yang hanya muncul sekali, misalnya karena perbedaan vegetasi, bernilai meragukan. Prinsip ini diilustrasikan pada Gambar 6.4.



Gambar 6.4 Ilustrasi pembobotan batas dari analisis beberapa unsur secara terpisah
Sumber: Diagram konseptual berdasarkan prinsip analisis foto pedologis Buringh (1954)

Setelah batas-batas ditarik, setiap satuan ditafsirkan menurut faktor pembentuk tanahnya, yaitu bentuklahan dan posisi lereng, bahan induk, umur permukaan, dan kondisi airnya. Dari penafsiran tersebut disusun hipotesis tentang tanah yang diharapkan dan susunannya di dalam lanskap, misalnya urutan tanah dari punggungan hingga dasar lembah. Hipotesis inilah yang diuji di lapangan. Rossiter (2000) menggambarkan pendekatan survei bebas (*free survey*) sebagai upaya surveyor membangun model mental tentang faktor pembentuk tanah, lalu menempatkan pengamatan untuk menguji atau memperbaiki model tersebut. Pengamatan dibuat lebih sedikit di bagian yang sesuai dengan model dan lebih banyak di daerah bermasalah. Keberhasilan pendekatan ini bergantung pada ketepatan model mental penafsir dan pada konsistensi penerapannya (Rossiter, 2000).

Interpretasi juga memiliki batas yang jelas. Buringh (1955) mencatat bahwa upaya menurunkan informasi tanah yang rinci langsung dari foto udara merupakan kekeliruan, karena foto hanya memberi informasi tentang kondisi fisik permukaan bumi dan tidak pernah memuat seluruh rincian kondisi tanah. Ia juga mengutip peringatan Kellogg bahwa survei jalan pintas yang menghindari studi tanah secara cermat pasti tidak dapat dipercaya, sehingga tanah tetap harus digali. Batas ini juga terlihat dari sifat tanah yang dapat diwakili oleh satuan hasil interpretasi. Rossiter (2000) menyajikan contoh korelasi intrakelas sifat tanah terhadap satuan hasil interpretasi foto udara. Nilainya 0,61 untuk kadar lempung, tetapi hanya 0,28 untuk bahan organik, 0,33 untuk pH, dan 0,06 untuk kalium tersedia. Satuan interpretasi umumnya lebih baik dalam memisahkan sifat fisik daripada sifat kimia tanah, sehingga informasi kesuburan tanah untuk pemupukan tetap memerlukan pengambilan sampel.

Interpretasi pedologis perlu dibedakan dari klasifikasi citra otomatis. Klasifikasi berbasis piksel menetapkan kelas setiap piksel berdasarkan nilai spektralnya. Blaschke (2010) menjelaskan bahwa pendekatan per piksel menjadi pilihan ketika ukuran piksel lebih besar atau sebanding dengan objek yang dikaji. Dengan meningkatnya resolusi spasial, berkembang analisis citra berbasis objek (*Object-Based Image Analysis*, OBIA), yang membentuk objek dari kumpulan piksel melalui segmentasi dan memadukan informasi spektral dengan informasi konteks. Klasifikasi dengan pembelajaran mesin (*machine learning*), seperti *support vector machine*, pohon keputusan, *random forest*, jaringan saraf tiruan, dan *k-nearest neighbours*, mampu menangani data berdimensi tinggi dan kelas yang rumit. Namun, penerapannya memerlukan pilihan algoritme, data latih, dan parameter yang tepat (Maxwell et al., 2018). Pola yang dipelajari juga bergantung pada apa yang tampak pada citra. Descals et al. (2021), misalnya, memanfaatkan kemampuan jaringan saraf konvolusional untuk mempelajari pola spasial, seperti jaringan jalan panen, dalam membedakan perkebunan kelapa sawit perusahaan dan rakyat. Pola tersebut merupakan pola pengelolaan, bukan pola tanah. Perbedaan antara interpretasi pedologis dan klasifikasi citra otomatis dirangkum pada Tabel 6.2.

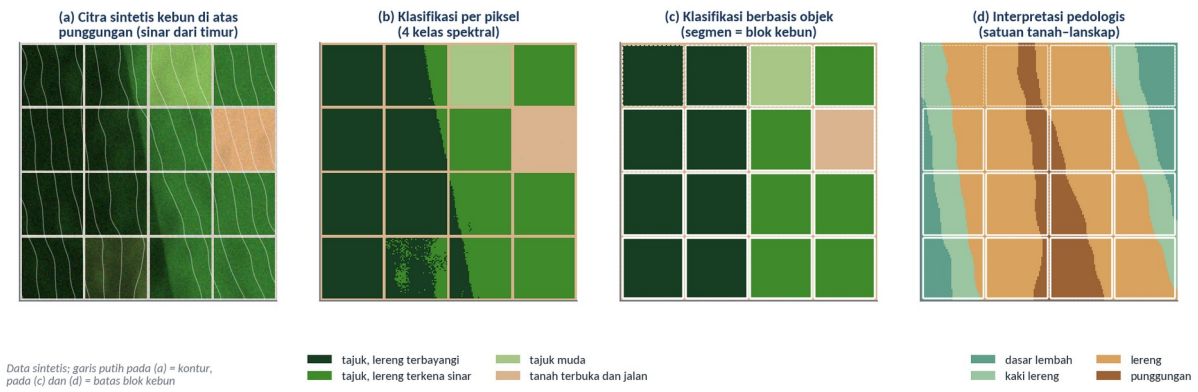
Tabel 6.2 Perbedaan Interpretasi Pedologis dan Klasifikasi Citra Otomatis

Aspek	**Interpretasi pedologis**	**Klasifikasi berbasis piksel**	**Klasifikasi berbasis objek dan pembelajaran mesin**
Satuan analisis	Satuan lanskap yang dideliniasi penafsir	Piksel	Segmen atau piksel dengan banyak fitur turunan
Informasi yang	Unsur interpretasi, konteks lanskap, peta	Nilai spektral setiap piksel	Nilai spektral, bentuk, tekstur, dan konteks

Aspek	Interpretasi pedologis	Klasifikasi berbasis piksel	Klasifikasi berbasis objek dan pembelajaran mesin
digunakan	geologi, dan pengetahuan setempat		
Dasar penalaran	Hubungan antara faktor pembentuk tanah dan tanah	Kemiripan statistik antarpiksel	Pola statistik yang dipelajari dari data latih
Keluaran	Satuan tanah–lanskap sebagai hipotesis sebaran tanah	Kelas tutupan lahan atau kelas spektral	Kelas sesuai data latih, misalnya tutupan lahan, bentuklahan, atau tanah
Kekuatan	Memanfaatkan pengetahuan pedologis dan petunjuk tidak langsung di balik penutup lahan	Cepat dan konsisten	Memanfaatkan konteks dan data berdimensi tinggi
Keterbatasan	Bergantung pada keahlian penafsir dan pengetahuan tasit; sulit diulang secara persis	Mengikuti penutup permukaan dan iluminasi, bukan tanah	Memerlukan data latih yang memadai; pola yang dipelajari belum tentu bermakna pedologis

Sumber: Rangkuman penulis berdasarkan Buringh (1954), Hudson (1992), Blaschke (2010), Maxwell et al. (2018), dan Wadoux, Samuel-Rosa, et al. (2020)

Gambar 6.5 mengilustrasikan perbedaan tersebut dengan data sintetis pada sebuah kebun di atas punggungan. Klasifikasi per piksel memisahkan tajuk yang sama menjadi dua kelas karena perbedaan iluminasi antara lereng yang terkena sinar dan lereng yang terbayangi. Blok tanaman muda di lereng yang terbayangi juga ikut tergolong keliru. Klasifikasi berbasis objek menghasilkan satuan yang lebih rapi, tetapi segmennya mengikuti batas blok kebun dan mewarisi kekeliruan akibat iluminasi. Sebaliknya, interpretasi pedologis menghasilkan satuan yang mengikuti punggungan, lereng, kaki lereng, dan dasar lembah, sehingga batasnya memotong batas-batas blok.



Gambar 6.5 Ilustrasi hasil klasifikasi per piksel, klasifikasi berbasis objek, dan interpretasi pedologis pada kebun di atas punggungan
Sumber: Ilustrasi konseptual dengan data sintetis

Perbandingan langsung antara kedua pendekatan juga telah dilakukan. Hengl dan Rossiter (2003) mencoba mengekstrapolasikan peta interpretasi foto udara bersatuan geopedologi ke wilayah yang lebih luas dengan klasifikasi terbimbing berdasarkan sembilan parameter medan dari model elevasi. Klasifikasi pertama hanya mampu mereproduksi 45,3% satuan acuan. Kesalahan terbesar terjadi pada bentuklahan dataran yang rumit, seperti kompleks gosong sungai dan tanggul alam, akibat model elevasi yang kurang rinci dan karena bentuklahan tersebut tidak dapat dijelaskan oleh parameter medan saja. Penyederhanaan legenda meningkatkan reproduksibilitas menjadi 63,4%. Wadoux, Samuel-Rosa, et al. (2020) menunjukkan masalah lain dari pembelajaran mesin. Model dapat memprediksi karbon organik tanah dengan akurat bahkan dengan kovariat semu yang tidak berhubungan dengan faktor dan proses pembentukan tanah. Mereka menegaskan bahwa pengenalan pola untuk prediksi tidak sama dengan penemuan pengetahuan, yang masih memerlukan pemilihan kovariat yang relevan secara pedologis serta penafsiran dan evaluasi pola yang ditemukan.

Kedua pendekatan tersebut lebih tepat dipandang saling melengkapi daripada saling menggantikan. Ma et al. (2019) menunjukkan bahwa pengetahuan pedologis dapat dimasukkan ke dalam pemetaan tanah digital, dan sebaliknya pemetaan tanah digital dapat menghasilkan pengetahuan baru tentang pedogenesis. Zhu et al. (2001) mengembangkan model inferensi tanah–lahan (*Soil–Land Inference Model*, SoLIM), yang menggabungkan kondisi lingkungan hasil penginderaan jauh dan SIG dengan hubungan tanah–lingkungan yang diperoleh dari pakar tanah setempat atau dari pengamatan lapangan. Bagi perkebunan kelapa sawit, interpretasi pedologis berperan menyusun satuan tanah–lanskap yang menjadi dasar delineasi satuan peta tanah (Modul 3), kerangka stratifikasi pengambilan sampel, dan kovariat kategorik dalam pemodelan DSM (Modul 8). Klasifikasi otomatis lebih tepat dimanfaatkan untuk memetakan kondisi penutup lahan, seperti status tajuk dan tanah terbuka (Modul 5). Penafsir perlu melihat

menembus pola pengelolaan kebun menuju relief, kondisi air, dan bahan induk yang benar-benar mengendalikan sebaran tanah.

.

7. Proximal Soil Sensing

Ceramah dan diskusi:

7.1. Konsep Proximal Soil Sensing

Pertanian presisi menuntut data tanah yang rapat dan dapat diperbarui, sementara cara yang selama ini dipakai, yaitu mengambil sampel di lapangan lalu menganalisisnya di laboratorium, mahal dan lambat. Di Brasil, misalnya, peta kesuburan yang andal memerlukan sedikitnya satu sampel per hektare. Namun ini sangatsulit untuk terpenuhi karena mahalnya pengambilan dan analisis sampel (Molin & Tavares, 2019). Akibatnya, rekomendasi pemupukan umumnya masih disusun dari atas ke bawah (*top-down*), yaitu dari data yang terbatas dan hubungan empiris yang berlaku umum. Viscarra Rossel dan Bouma (2016) melihat sensor tanah sebagai jalan menuju pendekatan dari bawah ke atas (*bottom-up*), yang bertolak dari pencirian kondisi tanah dan lingkungan setempat dalam ruang dan waktu. Sensor dapat mengisi kekosongan itu karena mampu mengukur dengan cepat, akurat, dan murah tanpa merusak sampel (England & Viscarra Rossel, 2018).

Istilah penginderaan tanah proksimal (*Proximal Soil Sensing*, PSS) merujuk pada penggunaan sensor di lapangan yang bekerja dalam kontak dengan tanah atau dekat dengannya, yaitu sekitar 2 m dari permukaan. Definisi ini dirumuskan Viscarra Rossel et al. (2011) dan dikutip oleh Molin dan Tavares (2019). Tekniknya sendiri tidak baru. Sebagian besar teknik PSS telah lama dipakai sebagai metode analisis laboratorium, dan yang baru adalah peralatannya. Kemajuan rekayasa membuat alat-alat tersebut lebih ringan, kecil, kokoh, dan terjangkau, sehingga dapat dibawa ke lapangan dan dipakai dengan sedikit atau tanpa penyiapan sampel (Molin & Tavares, 2019). Menurut cara pengoperasiannya, sensor PSS dapat dibedakan sebagai berikut (England & Viscarra Rossel, 2018; Molin & Tavares, 2019):

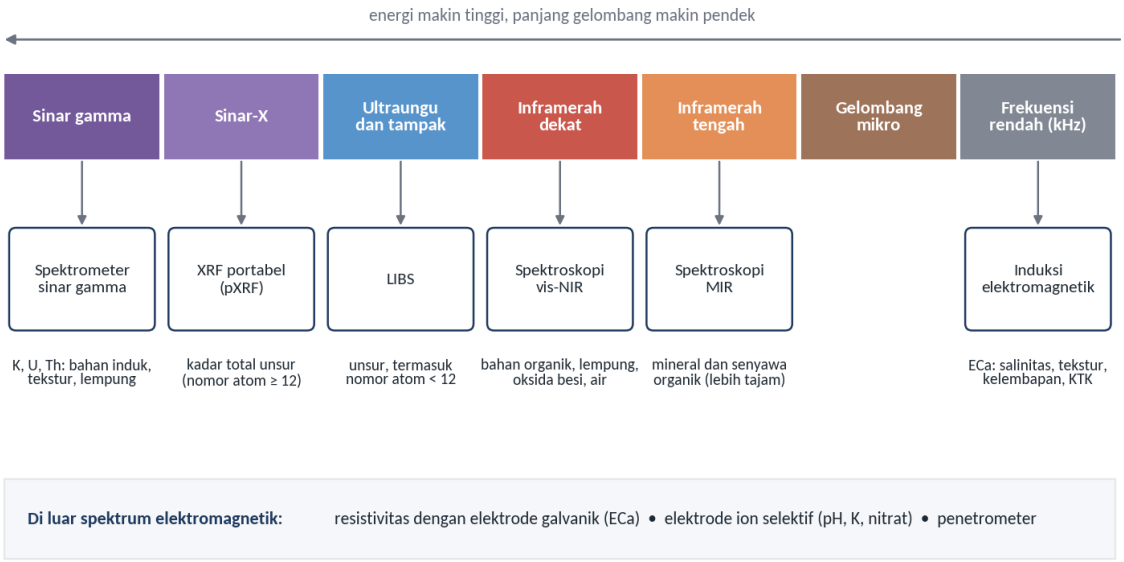
- **Alat meja (*benchtop*)**, yang dipakai di laboratorium untuk mengukur sampel yang telah dikeringkan dan dihaluskan.
- **Alat genggam**, yang dibawa ke lapangan untuk mengukur tanah secara langsung pada titik-titik pengamatan.
- **Sensor bergerak (*on-the-go*)**, yang dipasang pada kendaraan dan merekam data secara terus-menerus sepanjang lintasan.
- **Pemindai inti tanah**, yang mengukur inti tanah (*soil core*) pada interval kedalaman tertentu sehingga menghasilkan data menurut kedalaman.

Keempat cara tersebut menghasilkan data yang berbeda sifatnya. Pengukuran dengan alat meja paling terkendali karena kondisi sampelnya seragam. Sensor bergerak menghasilkan data

yang paling rapat ke arah mendatar, sedangkan pemindai inti tanah memberikan informasi ke arah vertikal, sepanjang profil tanah.

Perkembangan spektroskopi, salah satu teknik PSS yang terpenting, lebih banyak didorong oleh kemajuan pengolahan data daripada oleh alatnya. Spektroskopi reflektansi difus sudah dipakai dalam ilmu tanah sejak awal 1950-an, tetapi baru berkembang pesat dalam tiga dekade terakhir, setelah kemometrika dan statistika multivariat mapan dalam kimia analitik. Teknik lain menyusul. Daya hantar listrik tanah mulai diukur dengan induksi elektromagnetik pada akhir 1970-an, sedangkan spektrometer sinar gamma baru belakangan dipakai untuk pertanian presisi (Molin & Tavares, 2019). Tahap berikutnya adalah pustaka spektral berskala besar. Viscarra Rossel et al. (2016) menghimpun pustaka spektral tanah vis-NIR global yang terbesar dan paling beragam pada masanya, lalu memakainya untuk memprediksi karbon organik dan anorganik, kadar lempung, debu, pasir, besi, kapasitas tukar kation (KTK), dan pH. Teknologi ini juga sudah dipakai di industri kelapa sawit. Thandapani et al. (2024) melaporkan pemakaian spektrometer inframerah dekat di laboratorium sebagai alat analisis rutin untuk sampel daun, pupuk, dan tanah, yang mempercepat analisis dan mengurangi pemakaian bahan kimia.

Sebagian besar sensor PSS memanfaatkan interaksi energi elektromagnetik dengan tanah, mulai dari sinar gamma sampai medan elektromagnetik berfrekuensi rendah. Sebagian lainnya mengukur sifat listrik atau kimia tanah secara langsung. Kedudukan setiap sensor pada spektrum elektromagnetik ditunjukkan pada Gambar 7.1, sedangkan prinsip kerja dan sifat tanah yang dapat diduganya dirangkum pada Tabel 7.1.



Gambar 7.1 Kedudukan sensor *proximal soil sensing* pada spektrum elektromagnetik dan sensor di luar spektrum tersebut

Sumber: Diagram konseptual disusun berdasarkan Molin dan Tavares (2019) dan England dan Viscarra Rossel (2018)

Tabel 7.1 Jenis Sensor *Proximal Soil Sensing* untuk Karakterisasi Tanah

Sensor	Prinsip pengukuran	Sifat tanah yang dapat diduga	Catatan penggunaan
Spektroskopi vis-NIR	Pantulan difus pada 400 –2.500 nm akibat transisi elektronik serta nada atas (*overtone*) dan kombinasi getaran molekul	Karbon organik, N total, lempung, oksida besi, kelembapan; sifat lain melalui korelasi	Dapat digunakan di laboratorium maupun di lapangan; pengukuran lapangan memerlukan koreksi pengaruh air
Spektroskopi MIR	Pantulan difus pada 2.500–25.000 nm akibat getaran dasar molekul	Mineral dan senyawa organik dengan fitur yang lebih tajam; kalibrasinya umumnya lebih kokoh	Sampel perlu digiling halus; sangat peka terhadap air; penggunaan lapangan masih terbatas
Fluoresensi sinar-X portabel (pXRF)	Pancaran sinar-X khas setiap unsur setelah sampel disinari sinar-X	Kadar total unsur seperti Fe, Si, Al, K, Ca, dan P	Unsur bernomor atom < 12 tidak terdeteksi; mengukur kadar total, bukan bentuk tersedia; tidak terlalu peka terhadap kelembapan
Spektroskopi plasma terinduksi laser (LIBS)	Spektrum emisi plasma hasil penguapan permukaan sampel oleh laser	Komposisi unsur, termasuk unsur bernomor atom < 12	Sangat cepat, tetapi hasil kuantitatif di lapangan masih sulit karena memerlukan penyiapan sampel
Spektromete	Intensitas sinar gamma	Bahan induk,	Diredam oleh

Sensor	Prinsip pengukuran	Sifat tanah yang dapat diduga	Catatan penggunaan
r sinar gamma	alami (0–3 MeV) dari K, U, dan Th	pelapukan, kadar lempung, dan sifat lain yang berkaitan	kelembapan, kerapatan tanah, dan penutup tanaman
Daya hantar listrik semu (ECa)	Induksi elektromagnetik tanpa kontak atau resistivitas dengan elektrode galvanik	Salinitas, tekstur, kelembapan, kerapatan, dan KTK	Sangat dipengaruhi kelembapan; dapat mengukur beberapa kedalaman
Elektrode ion selektif (ISE)	Beda potensial yang sebanding dengan aktivitas ion tertentu	pH, K, dan nitrat	Pengukuran lapangan pada sampel lembap; pengambil sampel dapat tersumbat jerami dan akar

Sumber: Rangkuman penulis berdasarkan Molin dan Tavares (2019) dan England dan Viscarra Rossel (2018)

Di antara sensor-sensor tersebut, spektroskopi vis-NIR paling banyak dikembangkan. Alatnya praktis, biaya operasinya rendah, pengukurannya tidak merusak sampel, dan satu spektrum memuat informasi tentang banyak sifat sekaligus (Molin & Tavares, 2019). Untuk karbon organik, England dan Viscarra Rossel (2018) menilai vis-NIR sebagai metode yang paling sesuai, termasuk di lapangan, asalkan pengaruh air pada spektrum dikoreksi. Spektroskopi MIR menghasilkan fitur yang lebih kuat karena berasal dari getaran dasar molekul, tetapi kelebihan itu ada harganya. Molin dan Tavares (2019) mencatat bahwa sampel MIR perlu digiling hingga berukuran sekitar 80–100 μm, spektrumnya sangat peka terhadap air, dan alatnya selama ini terlalu mahal dan rapuh untuk dibawa ke lapangan, meskipun purwarupa portabel mulai diuji.

Molin dan Tavares (2019) juga merangkum keterbatasan sensor-sensor lain. pXRF mengukur kadar total unsur, bukan bentuk yang tersedia bagi tanaman, dan kurang peka terhadap unsur ringan. Batas deteksi P, misalnya, sekitar 5.000 mg/kg, jauh di atas U yang sekitar 5 mg/kg. Sebaliknya, pXRF tidak banyak terganggu kelembapan, karena koreksi baru diperlukan pada kadar air gravimetrik di atas 20%. Spektrometer sinar gamma menerima sekitar 95% radiasinya dari lapisan 0,5 m teratas, tetapi sinyalnya mudah teredam. Kenaikan kelembapan tanah sebesar 10% dapat menurunkan intensitasnya dengan proporsi yang sama, dan penutup tanaman setebal 2 cm dapat meredam hingga 35% radiasi. Daya hantar listrik semu (*apparent electrical conductivity*, ECa) juga bergantung pada kelembapan. Pada tanah yang kering, ECa kurang peka terhadap perbedaan tekstur, sedangkan pada tanah yang terlalu basah nilainya lebih mencerminkan daya hantar larutan tanah. Pemetaan tekstur dengan ECa

karena itu paling baik dilakukan ketika kadar air sedikit di bawah kapasitas lapang. Bagi pengguna, hal ini berarti hasil pengukuran pada kondisi kelembapan atau penutup tanah yang berbeda tidak dapat langsung dibandingkan.

Keunggulan sensor bergerak paling terasa pada kerapatan datanya. Sensor ECa umumnya merekam satu data per detik. Dengan kecepatan 4 m/s dan jarak antarlintasan 10, 20, dan 30 m, sensor tersebut menghasilkan sekitar 250, 125, dan 83 titik per hektare, padahal pengambilan sampel tanah biasanya kurang dari satu sampel per hektare (Molin & Tavares, 2019). Sistem pH bergerak menghasilkan data yang jauh lebih jarang karena harus mengambil sampel tanah terlebih dahulu. Batang pengambilnya mengambil tanah pada kedalaman sekitar 10 cm setiap kurang lebih 15 detik, sehingga pada kecepatan 4 m/s dan jarak antarlintasan 20 m hanya diperoleh sekitar delapan sampel per hektare. Pada versi yang elektrodenya diganti untuk mengukur pH, kalium tersedia, dan nitrat, R^2 antara pembacaan lapangan dan analisis laboratorium sekitar 0,93–0,96 untuk pH, tetapi hanya 0,61–0,62 untuk kalium dan 0,41–0,51 untuk nitrat (Molin & Tavares, 2019). Serapat apa pun, data sensor tetap berupa sampel. Kecepatan kendaraan dan jarak antarlintasan karena itu perlu disesuaikan dengan jangkauan keragaman spasial sifat yang dipetakan.

7.2. Perbedaan Remote Sensing dan Proximal Soil Sensing

Penginderaan jauh dan PSS tidak selalu berbeda prinsip. Spektroskopi reflektansi difus, misalnya, dapat dilakukan dari pesawat atau satelit dengan kamera multispektral atau hiperspektral, dari sensor proksimal di lapangan, atau dari alat meja di laboratorium (Molin & Tavares, 2019). Yang membedakan adalah jarak sensor ke tanah, wahananya, dan kondisi pengukurannya. Ketiganya menentukan mutu dan cakupan informasi yang diperoleh. Mulder et al. (2011) mencatat bahwa spektroskopi dari wahana antariksa masih terbatas pemanfaatannya dibandingkan spektroskopi laboratorium atau lapangan, dan tinjauan Angelopoulou et al. (2019) menunjukkan bahwa ketelitian estimasi karbon organik menurun dari pesawat nirawak ke satelit. Perbedaan kedua pendekatan dirangkum pada Tabel 7.2.

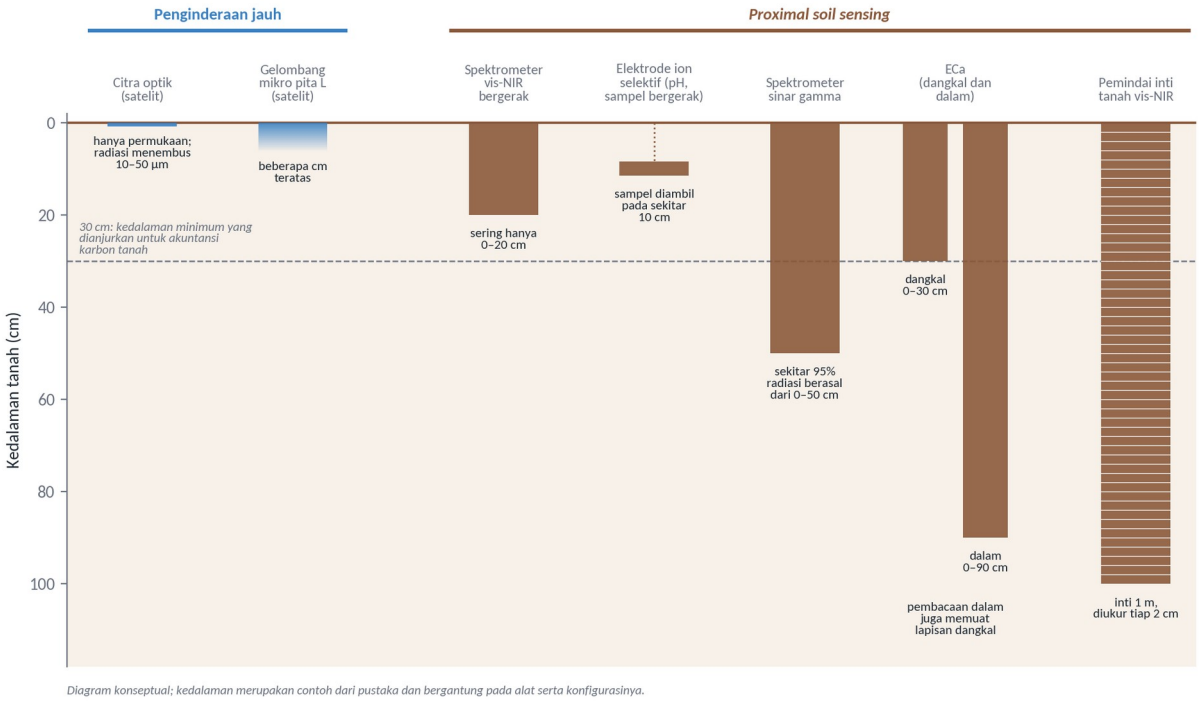
Tabel 7.2 Perbedaan Penginderaan Jauh dan *Proximal Soil Sensing*

Aspek	**Penginderaan jauh**	***Proximal soil sensing***
Jarak sensor ke tanah	Ratusan meter hingga ratusan kilometer, dari pesawat atau satelit	Kontak dengan tanah atau sekitar 2 m
Cakupan data	Menyeluruh untuk setiap piksel pada wilayah luas	Titik, lintasan, atau profil; rapat pada lintasan tetapi tidak menyeluruh
Lapisan yang	Permukaan tanah yang terbuka	Permukaan, sampel, atau inti

Aspek	Penginderaan jauh	*Proximal soil sensing*
terwakili		tanah pada berbagai kedalaman
Pengaruh atmosfer dan penutup lahan	Kuat; memerlukan koreksi atmosfer dan penyaringan tanah terbuka	Hampir tidak ada pengaruh atmosfer; dapat mengukur di bawah tajuk
Resolusi spektral	Umumnya kanal lebar pada citra multispektral	Spektrum bersambung dengan resolusi tinggi pada spektrometer
Sifat yang diukur	Sifat permukaan yang aktif secara spektral dan indikator tidak langsung	Lebih beragam, termasuk unsur, radioisotop, dan daya hantar listrik
Peran dalam DSM	Kovariat menyeluruh dan estimasi pada tanah terbuka	Data tanah yang rapat untuk kalibrasi, validasi, dan kovariat lokal

Sumber: Rangkuman penulis berdasarkan Mulder et al. (2011), Molin dan Tavares (2019), England dan Viscarra Rossel (2018), dan Chabrillat et al. (2019)

Bagi pemetaan tanah, perbedaan yang paling menentukan adalah lapisan tanah yang diwakili. Citra optik hanya merekam permukaan tanah yang terbuka, sebagaimana dibahas dalam Modul 4, karena radiasi pada spektroskopi reflektansi difus hanya menembus 10–50 µm permukaan sampel (Molin & Tavares, 2019). Gelombang mikro pita L dari satelit sedikit lebih dalam, yaitu berkaitan dengan kelembapan pada beberapa sentimeter teratas tanah (Kerr et al., 2010). Sensor proksimal tidak terikat pada permukaan, karena dapat diterapkan pada sampel, profil, atau inti tanah dari berbagai kedalaman. Sistem pemindai inti tanah, misalnya, dapat mengukur inti sepanjang 1 m pada interval 2 cm (England & Viscarra Rossel, 2018). Meskipun demikian, tidak semua sensor proksimal mengukur cukup dalam. Spektrometer vis-NIR bergerak sering hanya mengukur lapisan 0–20 cm, lebih dangkal daripada kedalaman minimum 0–30 cm yang dianjurkan untuk akuntansi karbon tanah (England & Viscarra Rossel, 2018). Sensor ECa dapat diatur untuk mengukur beberapa kedalaman dengan mengubah kuat medan magnet atau jarak antarelektrode. Namun, pembacaan yang lebih dalam, misalnya 0–90 cm, juga memuat informasi dari lapisan dangkal 0–30 cm, sehingga data dari kedua kedalaman saling berkorelasi (Molin & Tavares, 2019). Gambar 7.2 membandingkan kedalaman yang diwakili oleh teknik-teknik tersebut.



Gambar 7.2 Kedalaman tanah yang diwakili oleh beberapa teknik penginderaan jauh dan *proximal soil sensing*

Sumber: Diagram konseptual; nilai kedalaman dari Molin dan Tavares (2019), England dan Viscarra Rossel (2018), dan Kerr et al. (2010)

Kondisi pengukuran juga memengaruhi ketelitian. Di laboratorium, sampel dikeringkan, dihaluskan, dan diayak, sedangkan sensor di lapangan menghadapi tanah yang lembap, kasar, dan beragam (Chabrillat et al., 2019). Selisih ketelitiannya ternyata tidak selalu besar. Dari rangkuman berbagai penelitian, England dan Viscarra Rossel (2018) memperoleh median R^2 validasi prediksi karbon organik sebesar 0,85 untuk vis-NIR pada sampel kering yang dihaluskan dan 0,81 untuk vis-NIR pada kondisi lapangan, sedangkan MIR pada sampel kering yang digiling halus mencapai 0,93. Keunggulan lain spektrometer proksimal terletak pada spektrumnya, yang bersambung dan beresolusi tinggi, sedangkan sensor satelit multispektral hanya merekam beberapa kanal lebar. Castaldi et al. (2016) menunjukkan bahwa ketelitian prediksi tekstur dan karbon organik umumnya menurun ketika spektrum pustaka diresampel ke kanal sensor satelit.

Dalam pemetaan tanah digital, kedua pendekatan tidak perlu dipertentangkan. Penginderaan jauh unggul dalam cakupan, sedangkan PSS unggul dalam kerapatan dan kedalaman data, serta tetap dapat dipakai di bawah tajuk. Molin dan Tavares (2019) memberikan contoh dari Brasil. Di sebuah lahan seluas 50 ha, data ECa dipakai untuk menentukan lokasi pengambilan sampel tanah dan sebagai variabel bantu dalam interpolasi. Dengan hanya satu sampel per 2,5 ha, cara ini menghasilkan peta kesuburan yang lebih baik

untuk hampir semua atribut daripada pengambilan sampel rapat sebanyak empat sampel per hektare. Pola spasial ECa juga relatif stabil dari waktu ke waktu, sehingga dapat dipadukan dengan citra dan data hasil panen untuk menyusun zona pengelolaan. Bagi perkebunan kelapa sawit, peran PSS lebih penting lagi. Tajuk yang telah menutup menghalangi pengamatan tanah dari citra optik (Modul 5), sehingga pengukuran di lapangan, termasuk dengan PSS, menjadi salah satu cara utama untuk memperoleh data tanah yang rapat. Data tersebut selanjutnya dapat dipakai sebagai data kalibrasi maupun kovariat dalam pemodelan DSM (Modul 8).

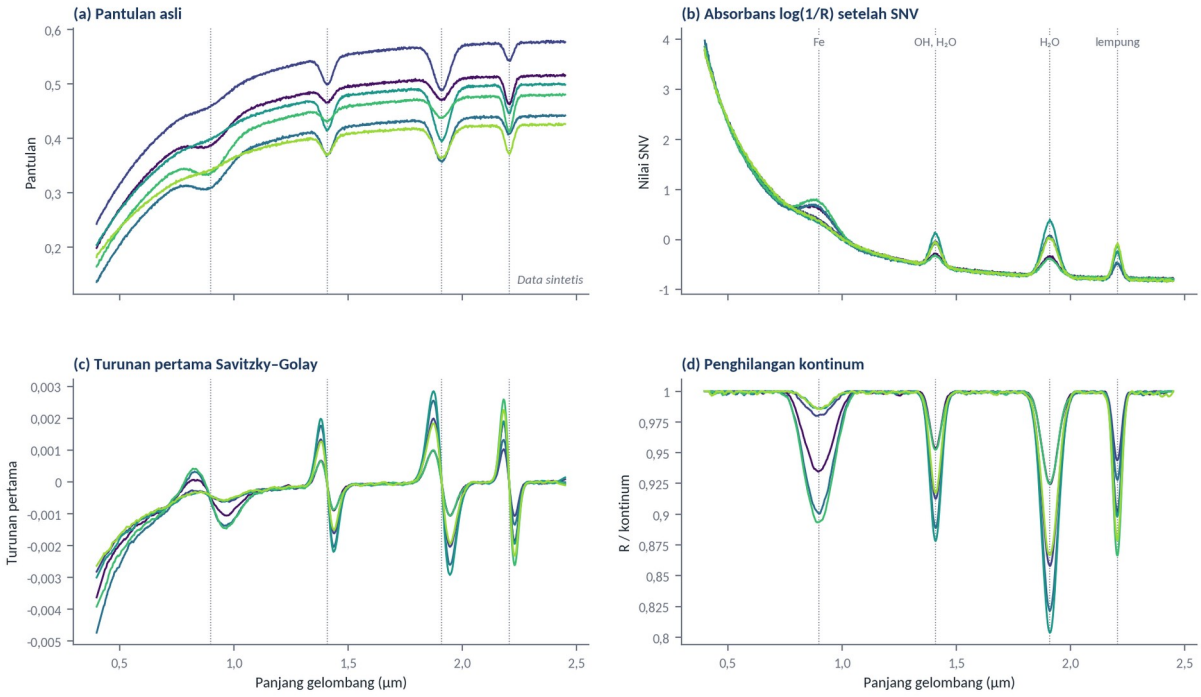
7.3. Interpretasi Pantulan Spektral Proximal Soil Sensing

Pantulan difus adalah persentase radiasi datang yang dipantulkan kembali secara tersebar oleh tanah pada setiap panjang gelombang. Nilai pantulan yang diurutkan menurut panjang gelombang membentuk spektrum. Bentuk spektrum terutama ditentukan oleh mineral, senyawa organik, dan air di dalam tanah, dan informasinya terbaca dari intensitas pantulan, bentuk kurva, serta fitur serapan pada panjang gelombang tertentu (Molin & Tavares, 2019). Setiap wilayah spektrum membawa informasi yang berbeda. Serapan di wilayah tampak (400 –700 nm), menurut England dan Viscarra Rossel (2018), berasal dari transisi elektronik dan berguna untuk mencirikan bahan organik serta oksida besi. Serapan di wilayah inframerah dekat (700–2.500 nm) merupakan nada atas dan kombinasi dari serapan dasar di wilayah inframerah tengah (2.500–25.000 nm), sehingga lebih lemah dan kurang khas. Wilayah tampak dan inframerah dekat biasanya diukur bersama sebagai vis-NIR karena informasinya saling melengkapi.

Interpretasi kualitatif dimulai dengan mengenali fitur serapan yang telah dibahas dalam Modul 4. Untuk tanah tropis, Molin dan Tavares (2019) menyebut beberapa fitur penting, yaitu serapan oksida besi seperti hematit dan goetit pada 840–940 nm, serapan air dan gugus hidroksil pada 1.400 dan 1.900 nm, serapan kaolinit pada 2.205–2.225 nm, dan serapan gibbsit pada 2.265 nm. Daftar ini dapat dijadikan titik awal untuk membaca spektrum tanah tropis di Indonesia, tetapi mineralogi setempat tetap perlu diperiksa. Tinggi rendahnya pantulan secara keseluruhan juga bermakna. Jika geometri pengukuran, kekasaran sampel, dan sumber cahayanya sama, perbedaan hamburan di seluruh spektrum berkaitan dengan ukuran butir tanah (Molin & Tavares, 2019).

Spektrum mentah jarang langsung dipakai. Barnes et al. (1989) menunjukkan bahwa sebagian besar keragaman spektrum pantulan difus disebabkan oleh ukuran partikel, sedangkan keragaman akibat komposisi kimia relatif kecil, padahal komposisi kimia itulah yang biasanya ingin diduga. Untuk memisahkannya, mereka memperkenalkan transformasi variat normal baku (*Standard Normal Variate*, SNV), yang menghilangkan gangguan perkalian akibat

hamburan dan ukuran partikel, serta *de-trending*, yang menghilangkan pergeseran dan kelengkungan garis dasar. Praolah lain yang lazim adalah mengubah pantulan menjadi absorbans, menghaluskan spektrum, dan menghitung turunannya, misalnya dengan filter Savitzky–Golay (England & Viscarra Rossel, 2018; Savitzky & Golay, 1964). Spektrum yang direkam di lapangan memerlukan satu langkah lagi, yaitu koreksi pengaruh air dengan ortogonalisasi parameter eksternal (*External Parameter Orthogonalization*, EPO) atau standardisasi langsung (*Direct Standardization*, DS) (England & Viscarra Rossel, 2018). Untuk mengukur kedalaman suatu fitur serapan, spektrum dapat dinormalisasi dengan penghilangan kontinum (Clark & Roush, 1984). Gambar 7.3 memperlihatkan pengaruh beberapa praolah tersebut pada spektrum sintetis. Praolah apa pun yang dipilih, perlakuannya harus sama untuk set latih, set validasi, dan spektrum yang akan diprediksi (England & Viscarra Rossel, 2018).

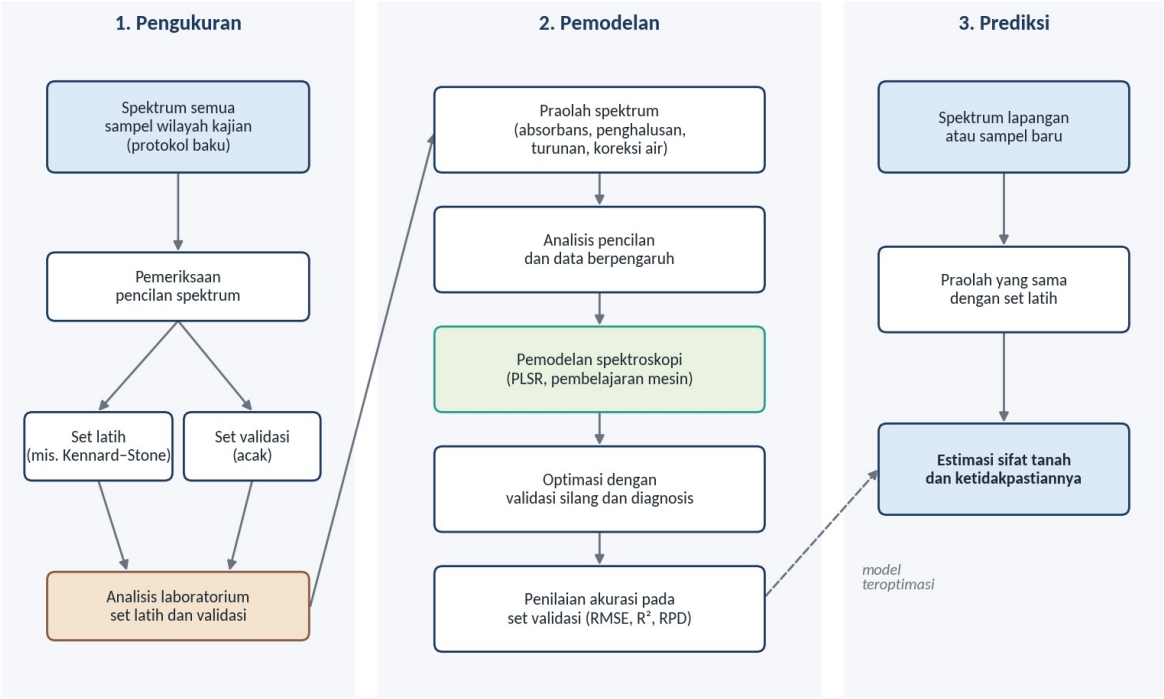


Gambar 7.3 Pengaruh beberapa praolah terhadap spektrum pantulan

Sumber: Ilustrasi konseptual dengan data sintetis; praolah mengikuti Barnes et al. (1989), Savitzky dan Golay (1964), dan Clark dan Roush (1984); posisi fitur mengacu pada Molin dan Tavares (2019)

Untuk interpretasi kuantitatif, spektrum harus dikalibrasi, yaitu dihubungkan dengan nilai sifat tanah hasil analisis laboratorium melalui model empiris. Kumpulan spektrum beserta data analisis dan metadatanya disebut pustaka spektral (England & Viscarra Rossel, 2018). Model kalibrasi umumnya dibangun dengan regresi kuadrat terkecil parsial (*Partial Least Squares Regression*, PLSR), alat dasar kemometrika (Wold et al., 2001). Pada pustaka spektral

yang besar dan beragam, pembelajaran mesin dapat menemukan hubungan lokal di dalam data dan menghasilkan prediksi yang akurat (Viscarra Rossel et al., 2016). Urutan kerjanya, dari pengukuran sampai prediksi, ditunjukkan pada Gambar 7.4.



Gambar 7.4 Alur pengukuran, pemodelan, dan prediksi sifat tanah dengan spektroskopi
Sumber: Digambar ulang dengan modifikasi dari England dan Viscarra Rossel (2018)

Pilihan pustaka spektral sangat menentukan ketelitian prediksi di tingkat kebun. England dan Viscarra Rossel (2018) membedakan dua pilihan. Pustaka besar yang sudah ada, baik regional, nasional, maupun global, dapat dipakai tanpa biaya langsung, tetapi prediksinya untuk satu kebun cenderung bias. Pustaka lokal, yang disusun dari sampel lokasi kajian, menghasilkan prediksi yang lebih akurat tetapi memerlukan biaya analisis laboratorium. Di antara keduanya terdapat beberapa jalan tengah. Metode berbasis memori memilih sampel pustaka yang spektrumnya paling mirip dengan setiap sampel yang akan diprediksi, sedangkan *spiking* menambahkan sejumlah sampel lokal ke dalam kalibrasi pustaka besar. Pendekatan rs-local menunjukkan bahwa 12–20 sampel lokal yang dipadukan dengan sampel terpilih dari pustaka besar sudah dapat meningkatkan ketelitian dan kekokohan prediksi.

Cara membagi data juga berpengaruh. England dan Viscarra Rossel (2018) menyarankan agar set latih dipilih dengan algoritme yang menjamin keterwakilan spektrum, misalnya Kennard–Stone, dan set validasi dipilih secara acak. Sebagai pegangan, dua pertiga data dipakai untuk pelatihan dan sepertiga untuk validasi. Mutu model juga tidak akan melampaui

mutu data laboratoriumnya. Mereka mengingatkan prinsip *garbage in, garbage out*, yaitu data analisis yang buruk akan menghasilkan kalibrasi yang buruk, dan menganjurkan penyertaan sampel duplikat buta, misalnya sebanyak 15%, untuk menilai ketelitian laboratorium.

Ketelitian model dinilai pada set validasi, umumnya dengan galat akar rata-rata kuadrat (RMSE), koefisien determinasi (R^2), dan rasio kinerja terhadap simpangan baku (RPD) (England & Viscarra Rossel, 2018). Sebagian peneliti, misalnya Castaldi et al. (2016), juga memakai rasio kinerja terhadap jangkauan antarkuartil (RPIQ). Angka-angka tersebut perlu dibaca bersama sifat tanah yang diduga. Karbon organik, N total, dan lempung umumnya mudah dikalibrasi karena bahan organik dan mineral lempung memiliki fitur spektral yang jelas. Hara tersedia, KTK, pH, dan kejenuhan basa tidak memiliki fitur serapan sendiri. Korelasinya dengan spektrum umumnya lemah, dan kalaupun berhasil, keberhasilannya bersifat lokal karena bergantung pada kovariasi dengan penyusun tanah yang aktif secara spektral (Molin & Tavares, 2019).

Kerangka ini membantu membaca hasil dari industri kelapa sawit. Thandapani et al. (2024) membandingkan hasil spektrometer inframerah dekat dengan analisis laboratorium konvensional pada 20 sampel tanah. R^2 yang diperoleh tinggi untuk N (0,88), P tersedia (0,88), P total (0,94), KTK (0,93), dan pH (0,88), tetapi rendah untuk Mg (0,28), Ca (0,43), B (0,29), Cu (0,33), Mn (0,003), dan Fe (0,007). Nilai yang tinggi untuk KTK dan pH tidak berarti kedua sifat itu terbaca langsung dari spektrum. Mengikuti penjelasan Molin dan Tavares (2019), nilai tersebut lebih tepat dipahami sebagai hasil kovariasi setempat, apalagi jumlah sampelnya kecil. Thandapani et al. (2024) sendiri menegaskan bahwa spektroskopi inframerah dekat adalah metode sekunder yang harus dikalibrasi secara berkala dengan data analisis laboratorium konvensional. Hasil PSS karena itu tetap merupakan estimasi yang mengandung ketidakpastian, dan perlu diperlakukan sebagai data terkalibrasi lokal ketika dipadukan dengan data penginderaan jauh dalam pemodelan DSM (Modul 8).

8. Pemodelan Digital Soil Mapping

Ceramah dan diskusi:

8.1. SCORPAN Sebagai Variabel Lingkungan

Modul 1 telah memperkenalkan SCORPAN sebagai kerangka pemetaan tanah digital. Kerangka ini berangkat dari model faktor pembentuk tanah Jenny, yang menyatakan tanah sebagai fungsi iklim, organisme, relief, bahan induk, dan waktu. McBratney et al. (2003) menambahkan dua faktor lagi, yaitu tanah itu sendiri dan posisi spasial, sehingga terbentuk model spasial yang menyatakan hubungan kuantitatif antara sifat atau kelas tanah di suatu lokasi dan kondisi lingkungannya (Wadoux, Minasny, & McBratney, 2020). Model tersebut dapat dituliskan sebagai berikut:

$$S = f(s, c, o, r, p, a, n) + e$$

dengan S adalah sifat atau kelas tanah yang dipetakan, s adalah informasi tanah yang telah diketahui, c iklim, o organisme, r relief, p bahan induk, a umur, n posisi spasial, f fungsi yang menghubungkan S dengan ketujuh faktor tersebut, dan e bagian keragaman yang tidak dijelaskan oleh faktor-faktor itu. Fungsi f tidak diturunkan dari teori, tetapi dipelajari dari data, yaitu dari pasangan nilai tanah hasil pengamatan dan nilai faktor lingkungan di lokasi yang sama. Karena itu, setiap faktor harus diwujudkan sebagai data spasial yang tersedia di seluruh wilayah yang akan dipetakan. Data inilah yang disebut kovariat atau variabel lingkungan.

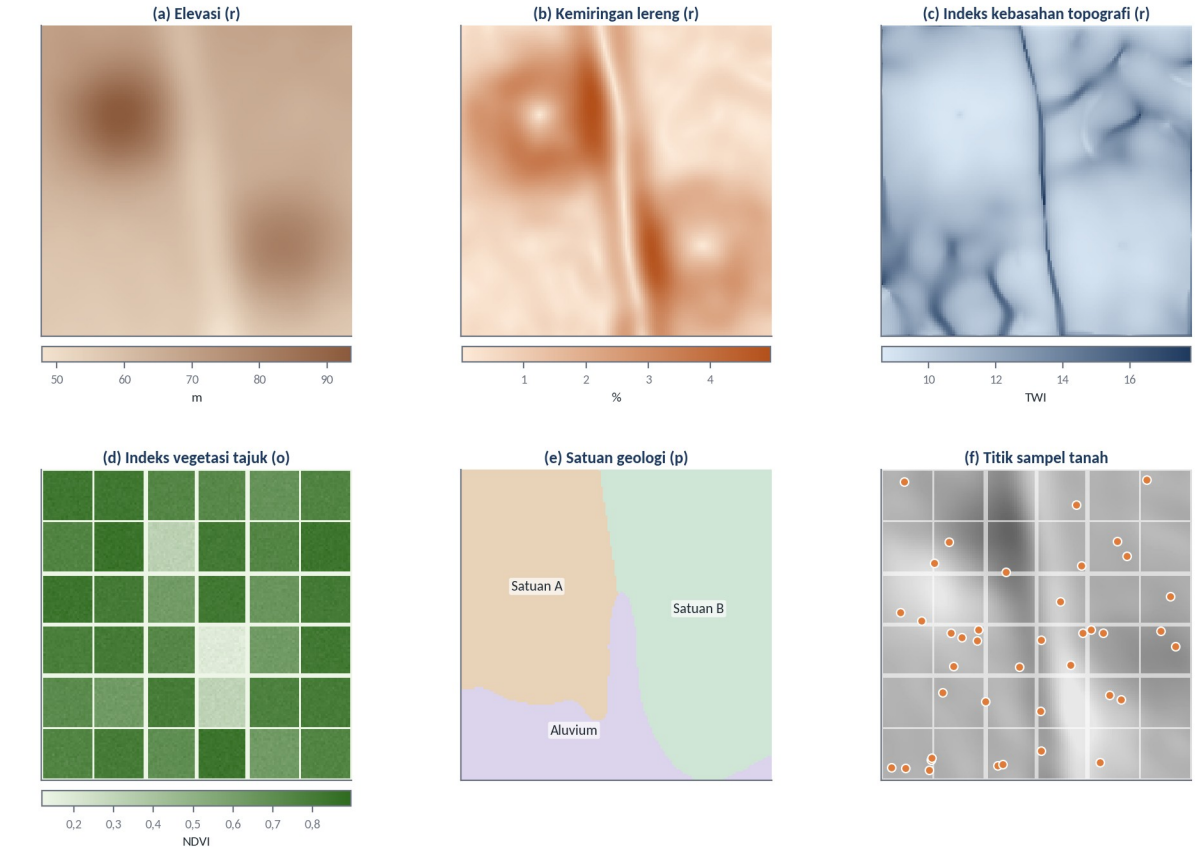
Penginderaan jauh berperan besar dalam kerangka ini karena citra dan model elevasi tersedia menyeluruh, sedangkan tanah sendiri jarang teramati secara langsung. Mulder et al. (2011) menyebut penginderaan jauh dalam pemetaan tanah terutama sebagai sumber informasi lingkungan pengganti. Jumlah kovariat yang dipakai sangat beragam. SoilGrids 2.0 memetakan sifat tanah dunia pada resolusi 250 m dengan lebih dari 400 kovariat global yang menggambarkan vegetasi, morfologi medan, iklim, geologi, dan hidrologi, ditambah data tanah dari sekitar 240.000 lokasi (Poggio et al., 2021). Penelitian pada skala yang lebih kecil umumnya memakai sekitar 20 kovariat, dan hanya sedikit yang memakai kurang dari lima atau lebih dari 100 (Wadoux, Minasny, & McBratney, 2020). Kovariat yang paling sering dipakai adalah peta sifat atau kelas tanah yang sudah ada, rerata jangka panjang curah hujan dan suhu, citra penginderaan jauh dan indeks vegetasi, elevasi beserta atribut medan seperti kemiringan, kelengkungan, dan indeks kebasahan topografi (TWI), serta peta geologi. Contoh kovariat untuk setiap faktor beserta sumber datanya dirangkum pada Tabel 8.1.

Tabel 8.1 Faktor SCORPAN, Contoh Kovariat, dan Sumber Datanya

Faktor	Contoh kovariat	Sumber data	Catatan untuk perkebunan kelapa sawit
s (tanah)	Peta tanah warisan, peta sifat tanah, data sensor proksimal	Survei terdahulu, ECa dan sinar gamma (Modul 7)	Peta tanah lama dapat dirinci dengan disagregasi; data PSS yang rapat menjadi kovariat lokal
c (iklim)	Curah hujan dan suhu rata-rata jangka panjang	Stasiun cuaca, produk iklim global	Jarang bervariasi di dalam satu kebun (Tabel 6.1)
o (organisme)	Indeks vegetasi, tutupan dan penggunaan lahan, komposit tanah terbuka	Citra optik multitemporal (Modul 4 dan 5)	Tajuk sawit lebih mencerminkan umur dan kondisi tanaman; pantulan tanah hanya terekam saat tanah terbuka
r (relief)	Elevasi, kemiringan, kelengkungan, TPI, TWI, MrVBF	Model elevasi digital dari radar satelit, LiDAR, atau peta topografi	Tetap tersedia di bawah tajuk; sering paling informatif untuk kelembapan dan drainase
p (bahan induk)	Satuan geologi, litologi, data radiometrik	Peta geologi, spektrometer sinar gamma	Skala peta geologi perlu diperiksa terhadap skala kebun
a (umur)	Umur relatif permukaan geomorfik, teras	Peta geomorfologi, interpretasi citra (Modul 6)	Umumnya hanya memberi urutan umur relatif
n (posisi)	Koordinat, peta jarak	Diturunkan dari lokasi pengamatan	Dapat menimbulkan artefak dan menyulitkan tafsiran model

Sumber: Rangkuman penulis berdasarkan McBratney et al. (2003), Wadoux, Minasny, dan McBratney (2020), Poggio et al. (2021), dan Ågren et al. (2014)

Sebagian besar kovariat berupa lapisan raster yang menutupi seluruh wilayah, seperti diilustrasikan pada Gambar 8.1. Kovariat relief diturunkan dari model elevasi, kovariat organisme dari citra, dan kovariat bahan induk dari peta geologi. Nilai setiap lapisan kemudian diambil di titik-titik sampel tanah. Perhatikan bahwa pola kovariat organisme pada contoh tersebut mengikuti blok kebun, sedangkan pola kovariat relief mengikuti bentuk lahan.



Gambar 8.1 Ilustrasi kovariat SCORPAN sebagai lapisan raster pada sebuah kebun dan titik sampel tanah di atasnya

Sumber: Ilustrasi konseptual dengan data sintetis; jenis kovariat mengacu pada Wadoux, Minasny, dan McBratney (2020)

Faktor tanah, bahan induk, umur, dan posisi lebih sulit diwujudkan sebagai kovariat daripada relief dan organisme. Peta tanah warisan dapat dipakai langsung sebagai kovariat kategorik, atau dirinci lebih dulu dengan teknik disagregasi spasial, yaitu memisahkan satuan peta tanah menjadi bagian-bagian yang lebih rinci berdasarkan hubungan tanah–lanskap. Sulaeman dan Husnain (2021) menilai teknik ini bermanfaat di Indonesia untuk merinci peta, menyelaraskan batas antarpeta, dan memetakan wilayah baru dengan memakai hubungan tanah –lanskap dari wilayah lain. Informasi bahan induk juga berharga. Cahyana et al. (2023) melaporkan bahwa informasi bahan induk memperbaiki hasil pemetaan tanah digital di Bogor. Faktor posisi biasanya diwakili oleh koordinat atau peta jarak. Kovariat semacam ini dapat mengurangi autokorelasi residual, tetapi koordinat cenderung menimbulkan artefak pada peta yang dibuat dengan algoritme berbasis pohon. Peta jarak juga tidak bermakna pedologis, sehingga menyulitkan tafsiran model (Wadoux, Minasny, & McBratney, 2020).

Kovariat tidak perlu dikumpulkan sebanyak-banyaknya. Poggio et al. (2021) menyeleksi kovariatnya untuk mengurangi kemiripan antarkovariat, memperoleh model yang lebih

sederhana dan efisien, menurunkan risiko *overfitting*, yaitu model yang terlalu menyesuaikan diri dengan data latih, serta menghindari penilaian tingkat kepentingan variabel yang bias. Untuk kebutuhan kebun, kriteria pemilihan kovariat dapat dirumuskan sebagai berikut:

- **Relevansi pedologis**, yaitu kovariat mewakili faktor yang secara masuk akal mengendalikan sifat tanah sasaran. Kadar lempung, misalnya, lebih berkaitan dengan bahan induk dan posisi lereng daripada dengan indeks vegetasi tajuk sawit.
- **Kesesuaian resolusi dan skala**, yaitu ukuran piksel kovariat sepadan dengan keragaman yang ingin dipetakan dan dengan skala peta (Modul 3). Nilai TWI peka terhadap resolusi DEM, sedangkan TPI bergantung pada skala analisisnya (Ågren et al., 2014).
- **Ketersediaan yang menyeluruh dan seragam**, yaitu kovariat tersedia untuk seluruh wilayah prediksi dengan mutu yang sama, karena model hanya dapat memprediksi di tempat nilai kovariatnya diketahui.
- **Kesesuaian waktu**, yaitu kovariat yang berubah menurut waktu, seperti citra, direkam pada periode yang sesuai dengan sifat tanah yang dipetakan dan dengan waktu pengambilan sampel.
- **Tidak berlebihan**, yaitu kovariat yang sangat mirip satu sama lain cukup diwakili oleh salah satunya.

Kriteria pertama paling sering terlewat. Model pembelajaran mesin dapat tampak akurat meskipun memakai kovariat semu yang tidak berhubungan dengan pembentukan tanah, sebagaimana dibahas dalam Modul 6 (Wadoux, Samuel-Rosa, et al., 2020). Pemilihan kovariat karena itu sebaiknya dimulai dari pengetahuan pedologis, lalu diperkuat dengan seleksi statistik. Seleksi statistik dapat memangkas kovariat secara drastis. Dalam perbandingan Nussbaum et al. (2018), lasso dan dua metode lain hanya mempertahankan 3–6% dari 300–500 kovariat yang tersedia, dan perbedaan ketelitian antarmetode umumnya kecil.

Kondisi perkebunan kelapa sawit menuntut perhatian khusus pada kovariat organisme dan relief. Tajuk sawit yang telah menutup menghalangi pantulan tanah (Modul 5), sehingga indeks vegetasi di blok yang tanamannya sudah menghasilkan lebih mencerminkan umur dan kondisi tanaman daripada tanah. Informasi spektral tanah hanya dapat diperoleh dari periode tanah terbuka, misalnya saat peremajaan, melalui komposit citra tanah terbuka. Kovariat relief sebaliknya tetap tersedia di bawah tajuk. Martinez et al. (2021) memodelkan medan sebuah perkebunan kelapa sawit seluas 5.220 ha di Llanos, Kolombia, dari DEM SRTM beresolusi 30 m. Lereng di perkebunan itu hanya 0–3%, tanahnya tergolong satu kelas, dan pengelolaannya seragam. Meskipun demikian, luas tangkapan termodifikasi (*Modified Catchment Area*, MCA), yaitu ukuran kecenderungan suatu sel untuk kehilangan atau menerima air, berkorelasi

paling kuat dengan hasil panen di antara atribut medan yang diuji. Arah korelasinya berbeda antarzona pengelolaan, yaitu positif di satu zona dan negatif di tiga zona lain. Artinya, hasil panen dapat dibatasi oleh kekurangan maupun kelebihan air, dan atribut medan dapat menangkap keduanya. Di bawah tajuk, data sensor proksimal yang rapat, seperti ECa, juga dapat menjadi kovariat atau variabel bantu (Modul 7).

8.2. Algoritma Digital Soil Mapping

Fungsi f dalam persamaan SCORPAN dapat diduga dengan berbagai algoritme. Secara garis besar, algoritme DSM dapat dikelompokkan sebagai berikut:

- **Model regresi linear**, seperti regresi linear berganda dan lasso, yang menyatakan sifat tanah sebagai kombinasi linear kovariat.
- **Model geostatistik**, seperti *ordinary kriging*, yang memprediksi dari nilai pengamatan di sekitarnya, serta *kriging* dengan *external drift* dan *regression kriging*, yang memadukan tren dari kovariat dengan *kriging* residualnya.
- **Pembelajaran mesin berbasis pohon**, seperti *random forest*, *cubist*, dan *boosted regression tree*, yang menggabungkan banyak pohon keputusan sehingga mampu menangkap hubungan tidak linear dan interaksi antarkovariat.
- **Pembelajaran mesin lainnya**, seperti *support vector machine*, jaringan saraf tiruan, dan *k-nearest neighbours*.
- **Pendekatan berbasis pengetahuan dan disagregasi**, seperti SoLIM yang memadukan pengetahuan pakar dengan kondisi lingkungan (Zhu et al., 2001) dan disagregasi spasial peta tanah warisan (Sulaeman & Husnain, 2021).

Kelompok-kelompok tersebut berbeda dalam kebutuhan data, kemampuan menangkap hubungan yang rumit, dan kemudahan tafsirannya. Perbandingannya dirangkum pada Tabel 8.2.

Tabel 8.2 Perbandingan Kelompok Algoritma Digital Soil Mapping

Kelompok	Contoh	Kekuatan	Keterbatasan
Regresi linear	Regresi linear berganda, lasso	Sederhana, cepat, dan mudah ditafsirkan	Kurang mampu menangkap hubungan tidak linear; lasso cenderung kurang pas (*underfitting*)
Geostatistik	*Ordinary kriging*, *external drift kriging*, *regression kriging*	Memanfaatkan autokorelasi spasial dan menghasilkan varians prediksi	Memerlukan sampel yang cukup rapat; *ordinary kriging* tidak memanfaatkan kovariat
Berbasis	*Random forest*, *cubist*,	Menangkap hubungan	Cenderung *overfitting*;

Kelompok	Contoh	Kekuatan	Keterbatasan
pohon	*boosted regression tree*	tidak linear dan interaksi; tahan terhadap kovariat yang saling berkorelasi	prediksi di luar rentang data latih tidak andal; sulit ditafsirkan
Pembelajaran mesin lain	*Support vector machine*, jaringan saraf tiruan, *k-nearest neighbours*	Luwes untuk pola yang rumit	Memerlukan pilihan parameter dan data latih yang tepat
Berbasis pengetahuan dan disagregasi	SoLIM, disagregasi spasial	Memanfaatkan pengetahuan pakar dan peta tanah warisan	Bergantung pada mutu pengetahuan dan peta yang tersedia

Sumber: Rangkuman penulis berdasarkan Nussbaum et al. (2018), Wadoux, Minasny, dan McBratney (2020), Maxwell et al. (2018), Meyer dan Pebesma (2021), Zhu et al. (2001), dan Sulaeman dan Husnain (2021)

Tidak ada algoritme yang selalu unggul. Nussbaum et al. (2018) membandingkan enam pendekatan untuk 48 kombinasi sifat tanah dan kedalaman di tiga wilayah di Swiss. Perbedaan ketelitiannya umumnya kecil. *Random forest* paling sering menjadi yang terbaik di antara metode tunggal, yaitu pada 28 dari 48 kasus, tetapi cenderung *overfitting*, dan pada separuh kasus tersebut kalah oleh rata-rata tertimbang beberapa model. Pada skala global, Hengl et al. (2017) mengaitkan peningkatan ketelitian SoilGrids250m dengan tiga hal, yaitu penggunaan pembelajaran mesin sebagai pengganti regresi linear, kovariat yang lebih rinci, dan tambahan data profil tanah. Faktor kedua dan ketiga menunjukkan bahwa mutu kovariat dan data tanah sama pentingnya dengan pilihan algoritme. Dalam pustaka DSM, *random forest* adalah algoritme pembelajaran mesin yang paling populer untuk memetakan sifat tanah, dan sekitar 80% penelitian pemetaan kelas tanah memakai sedikitnya satu algoritme berbasis pohon (Wadoux, Minasny, & McBratney, 2020).

Pilihan algoritme untuk perkebunan kelapa sawit sebaiknya didasarkan pada kondisi data dan kebutuhan pengguna, bukan pada popularitas algoritme. Nussbaum et al. (2018) merumuskan beberapa syarat metode DSM. Metode tersebut sebaiknya mampu membangun model secara efisien meskipun jumlah kovariat melebihi jumlah pengamatan, tahan terhadap banyak kovariat yang saling berkorelasi dan berderau, menghasilkan prediksi yang teliti tanpa *overfitting*, memodelkan hubungan yang tidak linear, memperhitungkan autokorelasi spasial, memungkinkan pemeriksaan kewajaran pedologis, dan mengukur ketidakpastian prediksi. Tidak ada satu algoritme yang memenuhi semuanya dengan sama baiknya, sehingga pilihan bergantung pada syarat mana yang paling penting. Jika sampel tanah sedikit, risiko *overfitting* pada model yang sangat luwes meningkat, sehingga model yang lebih sederhana dan mudah

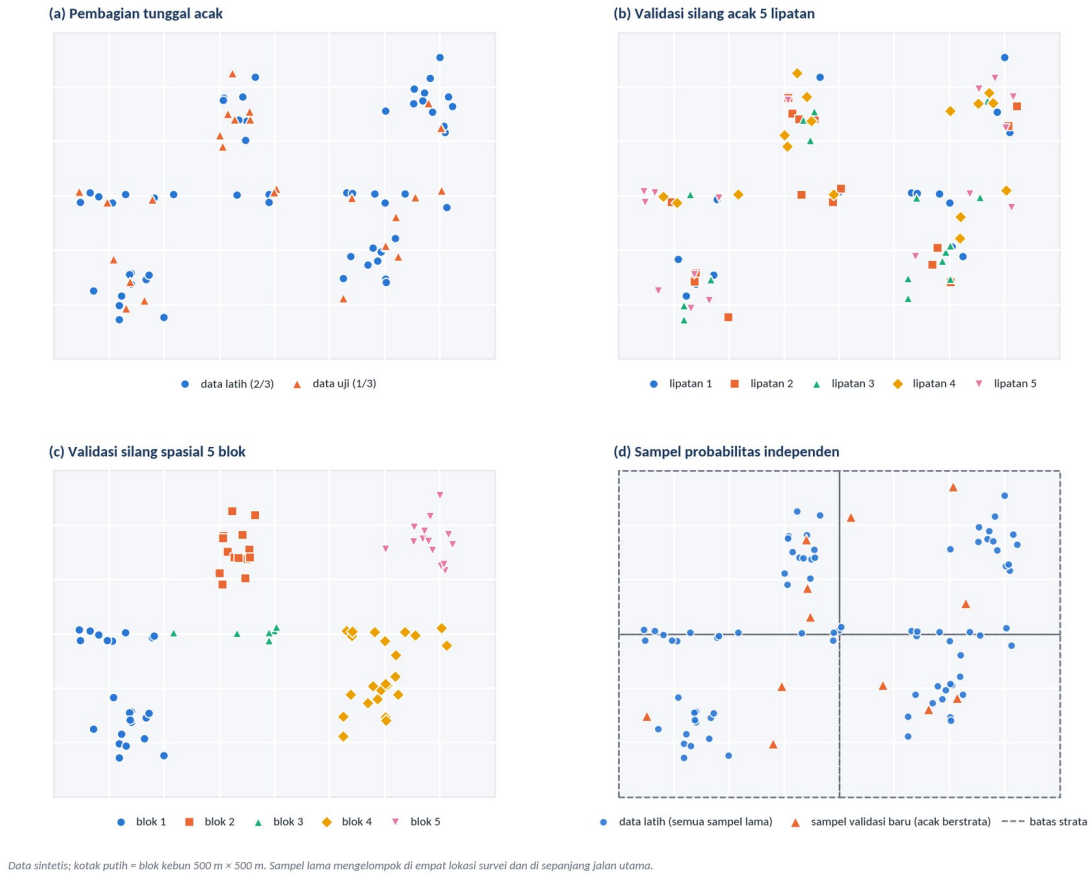
diperiksa layak dipertimbangkan. Jika sampelnya rapat dan residualnya masih berautokorelasi spasial, *kriging* residual dapat menambah ketelitian. Jika rekomendasi pemupukan memerlukan rentang nilai, algoritme yang menghasilkan interval prediksi, seperti *quantile regression forest*, lebih sesuai. Pilihan akhir sebaiknya ditentukan dengan membandingkan beberapa algoritme pada skema validasi yang sama.

8.3. Data Splitting

Model DSM harus dinilai dengan data yang tidak dipakai untuk membangunnya. Model yang dinilai dengan data latihnya sendiri hampir selalu tampak lebih baik daripada kenyataannya, terutama model yang luwes dan cenderung *overfitting* seperti *random forest* (Nussbaum et al., 2018). Karena itu, data tanah dibagi menjadi data untuk melatih model dan data untuk menilainya. Dalam pustaka DSM, sekitar 30% penelitian menilai model dengan validasi silang dan 30% lainnya dengan pembagian data tunggal, sedangkan hanya dua penelitian yang mengumpulkan sampel probabilitas tambahan khusus untuk validasi (Wadoux, Minasny, & McBratney, 2020). Skema pembagian data yang umum dipakai adalah sebagai berikut:

- **Pembagian tunggal (*holdout*)**, yaitu data dibagi sekali menjadi data latih dan data uji, misalnya dua pertiga untuk pelatihan dan sepertiga untuk validasi seperti yang dianjurkan untuk kalibrasi spektroskopi (England & Viscarra Rossel, 2018).
- **Validasi silang lipat-k (*k-fold cross-validation*)**, yaitu data dibagi menjadi k kelompok, lalu model dibangun k kali dengan satu kelompok sebagai data uji pada setiap putaran. SoilGrids, misalnya, memakai validasi silang 10 lipatan (Hengl et al., 2017; Poggio et al., 2021).
- **Validasi silang tinggalkan-satu (*leave-one-out*)**, yaitu bentuk ekstrem validasi silang dengan hanya satu pengamatan sebagai data uji pada setiap putaran.
- **Validasi silang spasial**, yaitu data dibagi menjadi blok-blok yang terpisah secara geografis, atau pengamatan di sekitar data uji dikeluarkan dari data latih (Roberts et al., 2017; Wadoux, Minasny, & McBratney, 2020).
- **Validasi dengan sampel probabilitas independen**, yaitu sampel baru yang dipilih secara acak, misalnya acak berstrata, khusus untuk menilai peta (Brus et al., 2011).

Keempat skema pertama membagi sampel yang sudah ada, sedangkan skema kelima menambah data baru. Perbedaan skema-skema tersebut diilustrasikan pada Gambar 8.2.



Gambar 8.2 Ilustrasi skema pembagian data pada sampel tanah yang mengelompok
Sumber: Ilustrasi konseptual dengan data sintetis; skema mengacu pada Brus et al. (2011), Roberts et al. (2017), dan Wadoux, Minasny, dan McBratney (2020)

Pilihan skema memengaruhi hasil penilaian. Wadoux, Minasny, dan McBratney (2020) mengingatkan bahwa pengamatan tanah yang berdekatan cenderung mirip, padahal pembelajaran mesin mengasumsikan pengamatan yang saling bebas. Jika sampel mengelompok, data uji dalam validasi silang acak hampir selalu memiliki tetangga dekat di dalam data latih. Statistik validasi yang diperoleh lebih mencerminkan kemampuan model mengulang data latihnya daripada kemampuannya memetakan wilayah yang tidak disampel, sehingga hasilnya terlalu optimistis. Ploton et al. (2020) menunjukkan akibatnya dengan jelas. Pada pemetaan biomassa hutan di Afrika Tengah dari data inventarisasi 11,8 juta pohon, validasi acak menunjukkan bahwa model *random forest* menjelaskan lebih dari separuh keragaman biomassa, sedangkan validasi spasial menunjukkan kemampuan prediksi yang hampir nol. Validasi silang spasial mengatasi masalah ini, tetapi dapat bergeser ke arah sebaliknya. Blok yang terlalu besar memaksa model mengekstrapolasi, sehingga hasilnya terlalu pesimistis (Roberts et al., 2017; Wadoux, Minasny, & McBratney, 2020).

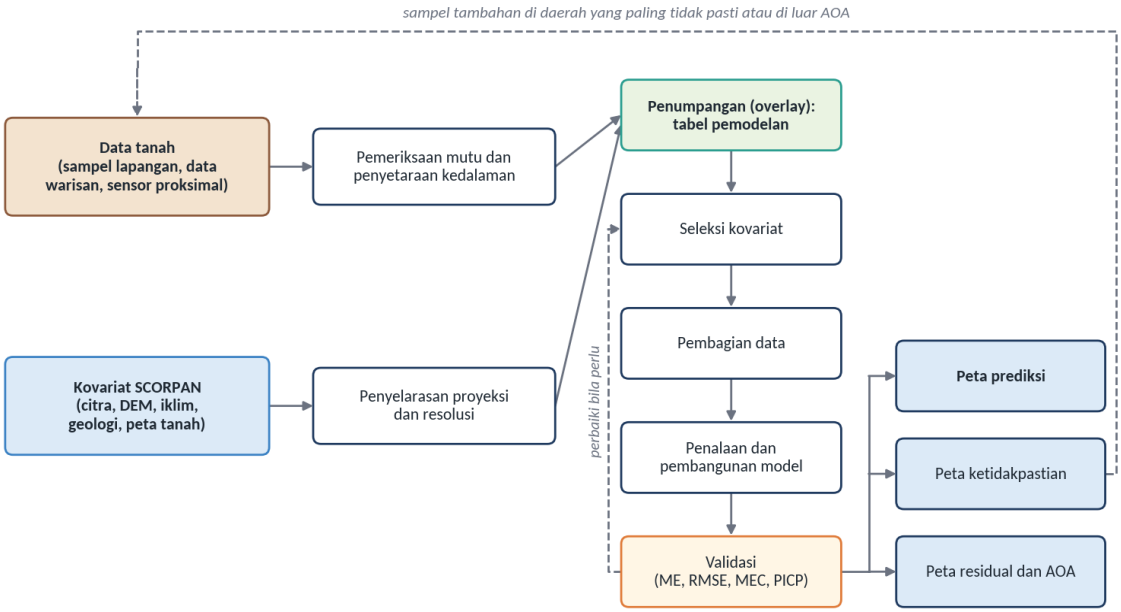
Jalan keluar yang paling kokoh adalah sampel validasi independen yang dipilih dengan desain probabilitas. Brus et al. (2011) menganjurkan pengumpulan data tambahan semacam ini

karena ukuran mutu peta beserta galat bakunya dapat diduga tanpa asumsi apa pun tentang autokorelasi spasial galat prediksi. Di antara lima desain sampling acak yang mereka evaluasi, sampling acak berstrata umumnya merupakan pilihan yang baik karena mudah diterapkan dan memberikan dugaan yang relatif teliti.

Di perkebunan, sampel tanah dapat mengelompok, misalnya menurut blok atau di sepanjang jalan kebun, atau berasal dari beberapa survei dengan desain yang berbeda. Struktur ini perlu diperhitungkan saat membagi data. Roberts et al. (2017) menyarankan agar data dibagi menurut struktur yang menimbulkan ketergantungan, seperti ruang, waktu, atau kelompok hierarkis. Dalam konteks kebun, pengamatan dari blok yang sama dapat diperlakukan sebagai satu kelompok, sehingga seluruh pengamatan satu blok selalu berada bersama di data latih atau di data uji. Agar data latih mewakili keragaman kovariat, titik sampel dapat dipilih dengan algoritme Kennard–Stone (England & Viscarra Rossel, 2018) atau dengan rancangan *conditioned Latin hypercube* (cLHS), yang bertujuan mencakup ruang yang dibentuk oleh kovariat (Wadoux, Minasny, & McBratney, 2020). Rancangan semacam ini paling baik diterapkan sejak perencanaan pengambilan sampel, bukan setelah data terkumpul.

8.4. Pembuatan Model dan Validasi

Pembuatan model DSM mengikuti urutan yang relatif baku (Gambar 8.3). Data tanah diperiksa mutunya, lalu disetarakan kedalamannya. SoilGrids 2.0, misalnya, memakai enam interval kedalaman baku menurut spesifikasi GlobalSoilMap, yaitu 0–5, 5–15, 15–30, 30–60, 60–100, dan 100–200 cm (Poggio et al., 2021). Nilai kovariat di setiap lokasi pengamatan kemudian diambil dengan penumpangan (*overlay*), sehingga terbentuk tabel pemodelan yang memuat nilai sifat tanah dan nilai semua kovariat di setiap titik. Tabel inilah yang dipakai untuk memilih kovariat, membagi data, menala parameter, dan membangun model. Model akhir lalu diterapkan pada setiap piksel untuk menghasilkan peta prediksi beserta peta ketidakpastiannya.



Gambar 8.3 Alur pembuatan model *digital soil mapping* dari data tanah dan kovariat hingga peta prediksi dan ketidakpastiannya
Sumber: Diagram konseptual disusun berdasarkan Poggio et al. (2021) dan Wadoux, Minasny, dan McBratney (2020)

Seleksi kovariat dan penalaan parameter sering dikerjakan bersamaan. Poggio et al. (2021) menyeleksi kovariat dalam dua langkah, yaitu membuang kovariat yang saling berkorelasi kuat, lalu menjalankan eliminasi fitur rekursif (*recursive feature elimination*). Parameter *random forest*, yaitu jumlah pohon (*ntree*) dan jumlah kovariat yang dicoba pada setiap percabangan (*mtry*), kemudian ditala dengan validasi silang 10 lipatan. Hasil penalaan tersebut memberi pelajaran praktis. Menambah jumlah pohon di atas 200 hanya menaikkan ketelitian kurang dari 0,1%, padahal memerlukan memori dan waktu hitung yang jauh lebih besar. Penalaan dan penilaian akhir sebaiknya tidak memakai data uji yang sama, karena hasilnya akan terlalu optimistis. Untuk data yang berautokorelasi spasial, penalaan dapat dikerjakan dengan validasi silang spasial bersarang, yaitu blok spasial dibagi sekali lagi khusus untuk mencari parameter terbaik (Wadoux, Minasny, & McBratney, 2020).

Ketelitian model dinilai dengan membandingkan nilai prediksi dan nilai pengamatan pada data validasi. Ukuran yang paling sering dipakai dirangkum pada Tabel 8.3. Setiap ukuran menjawab pertanyaan yang berbeda. Galat rata-rata (*mean error*, ME) menunjukkan bias, yaitu kecenderungan model menaksir terlalu tinggi atau terlalu rendah. MAE dan RMSE menunjukkan besarnya galat dalam satuan sifat tanah, dan RMSE lebih peka terhadap galat

yang besar. Koefisien efisiensi model (*model efficiency coefficient*, MEC) menunjukkan bagian keragaman yang dijelaskan model terhadap garis 1:1.

Tabel 8.3 Ukuran Ketelitian untuk Validasi Peta Sifat Tanah

Ukuran	Rumus	Nilai ideal	Makna
Galat rata-rata (ME)	$\frac{1}{n}\sum_{i=1}^{n}\left(\hat{y}_i - y_i\right)$	0	Bias; nilai positif berarti model rata-rata menaksir terlalu tinggi
Galat absolut rata-rata (MAE)	$\frac{1}{n}\sum_{i=1}^{n}\lvert\hat{y}_i - y_i\rvert$	0	Besar galat rata-rata dalam satuan sifat tanah
Akar galat kuadrat rata-rata (RMSE)	$\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\hat{y}_i - y_i\right)^2}$	0	Besar galat; lebih peka terhadap galat yang besar
Koefisien efisiensi model (MEC)	$1 - \frac{\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2}{\sum_{i=1}^{n}\left(y_i - \acute{y}\right)^2}$	1	Bagian keragaman yang dijelaskan terhadap garis 1:1; negatif jika prediksi lebih buruk daripada nilai rerata
Koefisien determinasi (R^2)	Kuadrat koefisien korelasi Pearson antara y dan $\hat{y}$	1	Kekuatan hubungan linear; tidak peka terhadap bias
PICP	Proporsi pengamatan yang berada di dalam interval prediksi	Sama dengan tingkat interval, misalnya 0,90	Ketepatan dugaan ketidakpastian

Sumber: Rangkuman penulis berdasarkan Nussbaum et al. (2018), Poggio et al. (2021), dan Wadoux, Minasny, dan McBratney (2020); y_i *= nilai pengamatan,* $\hat{y}_i$ *= nilai prediksi,* $\acute{y}$ *= rerata pengamatan,* n *= jumlah data validasi*

Perbedaan antara R^2 dan MEC perlu diperhatikan saat membaca laporan penelitian. Sebagian penelitian melaporkan R^2 yang identik dengan MEC, sedangkan yang lain melaporkan kuadrat koefisien korelasi Pearson. Kedua nilai itu berbeda, kecuali untuk model linear yang diduga dengan metode kuadrat terkecil biasa (Nussbaum et al., 2018). Sebagai ilustrasi, model yang prediksinya selalu 20% lebih tinggi daripada nilai sebenarnya dapat memiliki R^2 korelasi yang tinggi, tetapi MEC-nya rendah karena bias tersebut. Untuk peta kelas tanah, ukuran yang sesuai adalah kemurnian keseluruhan (*overall purity*), kemurnian setiap satuan peta (*user's accuracy*), dan keterwakilan setiap kelas tanah (*producer's accuracy*) (Brus et al., 2011).

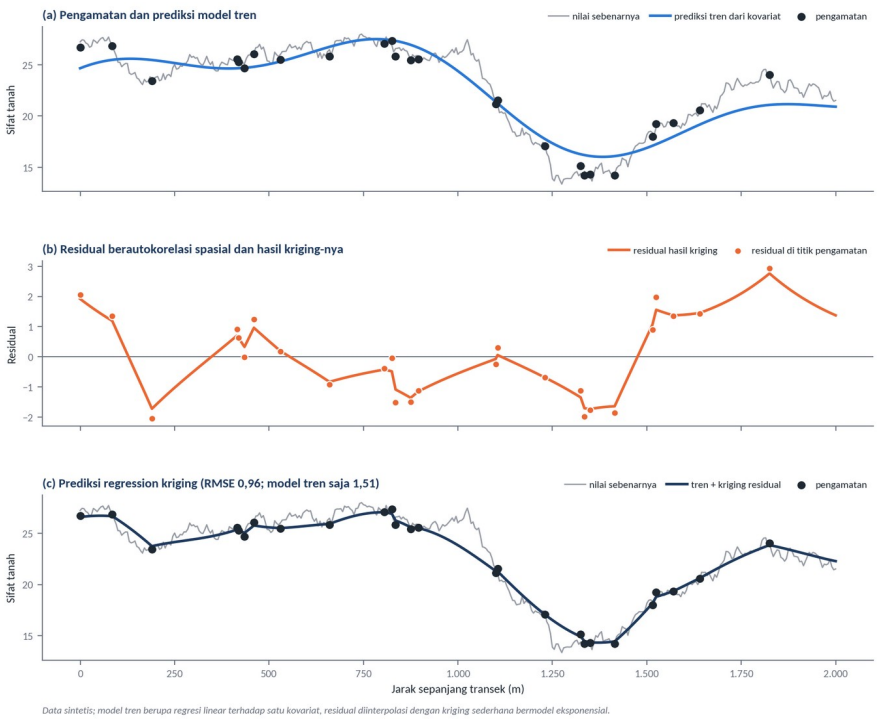
Statistik validasi sebaiknya dilengkapi dengan pemeriksaan kewajaran model. *Random forest* menyediakan ukuran tingkat kepentingan variabel dari data *out-of-bag*, yaitu data yang tidak terpilih saat setiap pohon dibangun (Breiman, 2001). Penilaian tingkat kepentingan ini

dapat bias, sehingga Poggio et al. (2021) menyeleksi kovariat terlebih dahulu, antara lain untuk menghindari bias tersebut. Tafsiran model juga berguna untuk memeriksa apakah model memprediksi karena alasan yang benar. Tafsiran model untuk memetakan nitrogen tanah lapisan atas, misalnya, dapat mengungkap bahwa model tersebut sebenarnya memprediksi kadar lempung sebagai perantaranya. Peta hasil prediksi juga perlu diperiksa secara visual, karena dua peta dengan statistik validasi yang mirip dapat memiliki pola spasial yang berbeda (Wadoux, Minasny, & McBratney, 2020).

8.5. Residual dan Uncertainty

Residual adalah selisih antara nilai pengamatan dan nilai prediksi, yaitu bagian *e* dalam persamaan SCORPAN. Residual memuat informasi yang sering terabaikan. Jika semua kovariat yang relevan telah dimasukkan, residual seharusnya tidak lagi berautokorelasi spasial. Residual yang masih berautokorelasi menandakan bahwa ada prediktor penting yang belum masuk ke dalam model (Wadoux, Minasny, & McBratney, 2020). Memetakan residual karena itu berguna untuk menemukan proses yang terlewat. Residual yang makin besar dengan makin jauhnya jarak dari sungai, misalnya, mengisyaratkan perlunya kovariat yang mewakili pengaruh sungai.

Autokorelasi residual juga dapat dimanfaatkan secara langsung. Residual di titik-titik pengamatan diinterpolasi dengan *kriging*, lalu hasilnya ditambahkan pada prediksi model tren. Prinsip ini mendasari *regression kriging* dan *kriging* dengan *external drift*, seperti yang dipakai Nussbaum et al. (2018), dan dapat pula diterapkan pada residual model pembelajaran mesin (Wadoux, Minasny, & McBratney, 2020). Manfaatnya bergantung pada kerapatan sampel. Pada SoilGrids250m, residual hampir tidak menunjukkan struktur spasial pada jarak di bawah 300 km, sehingga *kriging* residual tidak diperlukan untuk peta global. Namun, di tempat yang titik pengamatannya rapat, *kriging* residual masih dapat bermanfaat (Hengl et al., 2017). Kondisi kedua ini lebih dekat dengan perkebunan yang memiliki data tanah rapat, misalnya dari pengukuran sensor proksimal. Gambar 8.4 mengilustrasikan prinsip tersebut pada sebuah transek sintetis.



Gambar 8.4 Ilustrasi pemanfaatan residual dalam *regression kriging* pada transek sintetis
Sumber: Ilustrasi konseptual dengan data sintetis; prinsip mengacu pada Nussbaum et al. (2018) dan Hengl et al. (2017)

Setiap peta prediksi mengandung ketidakpastian. Menurut tinjauan Wadoux, Minasny, dan McBratney (2020), analisis ketidakpastian menentukan apakah peta cukup andal untuk dipakai dalam sistem produksi pertanian atau pengambilan keputusan. Mereka juga merujuk pustaka pembelajaran mesin yang membedakan dua sumber ketidakpastian. Ketidakpastian aleatorik berasal dari derau dan galat pengukuran data, sehingga sulit diduga dan lebih sulit lagi dikurangi. Ketidakpastian epistemik berasal dari keterbatasan model dan parameternya, dan dapat dikurangi, misalnya dengan menambah sampel di daerah yang jarang diamati. Galat analisis laboratorium dan galat estimasi sensor proksimal (Modul 7) termasuk sumber yang pertama, sedangkan sampel yang tidak mewakili seluruh keragaman kovariat termasuk sumber yang kedua.

Cara mengukur ketidakpastian bergantung pada algoritmenya. Model geostatistik menghasilkan varians *kriging*. Untuk pembelajaran mesin, interval dapat diperoleh dengan *bootstrap*, yaitu melatih banyak model pada sampel ulang data, atau dengan *quantile regression forest* (QRF) (Wadoux, Minasny, & McBratney, 2020). QRF adalah perluasan *random forest* yang tidak hanya menaksir rerata bersyarat, tetapi seluruh sebaran bersyarat sifat tanah, sehingga kuantil apa pun dapat diduga (Meinshausen, 2006). SoilGrids 2.0 memakai QRF untuk menghasilkan median serta kuantil 0,05 dan 0,95 di setiap piksel, yaitu batas bawah

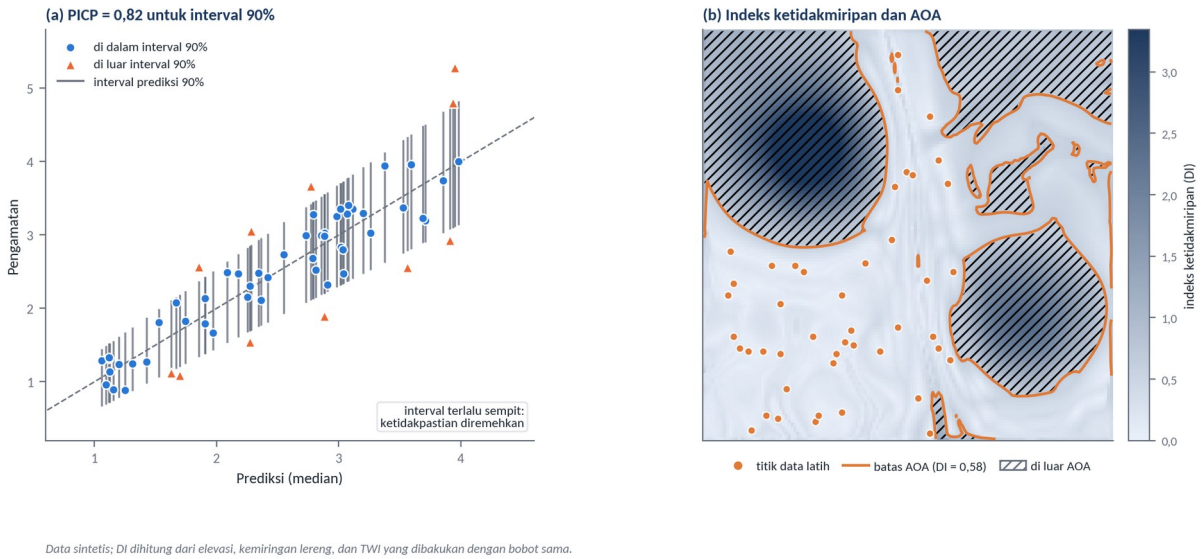
dan atas interval prediksi 90% (Poggio et al., 2021). Lebar interval tersebut dapat dipetakan sebagai peta ketidakpastian:

$$\mathrm{PI90} = q_{0,95} - q_{0,05}$$

dengan $q_{0,95}$ dan $q_{0,05}$ adalah kuantil 0,95 dan 0,05 sebaran prediksi. Poggio et al. (2021) juga memetakan rasio lebar interval tersebut terhadap median, sehingga ketidakpastian dapat dibandingkan antardaerah yang nilai prediksinya berbeda.

Interval prediksi juga perlu divalidasi. Ukurannya adalah peluang cakupan interval prediksi (*prediction interval coverage probability*, PICP), yaitu proporsi data validasi yang berada di dalam interval prediksi (Poggio et al., 2021). Untuk interval 90%, PICP idealnya mendekati 0,90. PICP yang jauh lebih kecil berarti intervalnya terlalu sempit, sehingga ketidakpastian diremehkan. Sebaliknya, PICP yang jauh lebih besar berarti intervalnya terlalu lebar. Gambar 8.5(a) mengilustrasikan perhitungan PICP dengan data sintetis.

Interval prediksi hanya bermakna di wilayah yang menyerupai data latih. Meyer dan Pebesma (2021) menunjukkan bahwa interval prediksi *random forest* tidak melebar ketika model memprediksi di luar rentang data latih, padahal prediksinya justru makin tidak andal, dan QRF pun tidak mengatasi masalah ini. Untuk itu mereka mengusulkan indeks ketidakmiripan (*dissimilarity index*, DI), yaitu jarak terdekat suatu lokasi ke data latih dalam ruang kovariat yang dibobot dengan tingkat kepentingan kovariat. Wilayah keberlakuan model (*area of applicability*, AOA) adalah wilayah yang nilai DI-nya tidak melampaui ambang yang diturunkan dari DI data latih melalui validasi silang. Di dalam AOA, ketelitian hasil validasi silang dapat dianggap berlaku. Di luar AOA, prediksi sebaiknya ditandai atau tidak dipakai, seperti pada Gambar 8.5(b).



Gambar 8.5 Ilustrasi validasi interval prediksi dengan PICP (a) dan wilayah keberlakuan model (b)

Sumber: Ilustrasi konseptual dengan data sintetis; PICP mengacu pada Poggio et al. (2021), sedangkan DI dan AOA mengacu pada Meyer dan Pebesma (2021)

Bagi perkebunan, peta ketidakpastian dan AOA memiliki kegunaan yang sangat praktis. Keduanya menunjukkan di mana peta dapat dipercaya untuk rekomendasi pemupukan dan di mana diperlukan sampel tambahan. Daerah dengan interval yang lebar atau yang berada di luar AOA, misalnya blok pada bentuk lahan yang tidak terwakili dalam data latih, menjadi sasaran utama pengambilan sampel berikutnya. Logika yang sama dipakai pada skala global. Peta ketidakpastian SoilGrids 2.0 menunjukkan perlunya lebih banyak pengamatan tanah, terutama di wilayah lintang tinggi (Poggio et al., 2021). Dengan cara ini, DSM tidak berhenti pada satu peta. Peta, ketidakpastian, sampel baru, dan model yang diperbarui membentuk siklus yang terus memperbaiki informasi tanah di kebun.

DAFTAR PUSTAKA

Adams, J. B., Smith, M. O., & Johnson, P. E. (1986). Spectral mixture modeling: A new analysis of rock and soil types at the Viking Lander 1 site. *Journal of Geophysical Research: Solid Earth*, *91*(B8), 8098–8112. https://doi.org/10.1029/JB091iB08p08098

Ågren, A. M., Lidberg, W., Strömgren, M., Ogilvie, J., & Arp, P. A. (2014). Evaluating digital terrain indices for soil wetness mapping – a Swedish case study. *Hydrology and Earth System Sciences*, *18*(9), 3623–3634. https://doi.org/10.5194/hess-18-3623-2014

Angelopoulou, T., Tziolas, N., Balafoutis, A., Zalidis, G., & Bochtis, D. (2019). Remote sensing techniques for soil organic carbon estimation: A review. *Remote Sensing*, *11*(6), 676. https://doi.org/10.3390/rs11060676

Asner, G. P., & Heidebrecht, K. B. (2002). Spectral unmixing of vegetation, soil and dry carbon cover in arid regions: Comparing multispectral and hyperspectral observations. *International Journal of Remote Sensing*, *23*(19), 3939–3958. https://doi.org/10.1080/01431160110115960

Astuti, Y. T. M., Santosa, T. N. B., & Andi. (2018). Sistem penanaman legume cover crop pada lahan replanting perkebunan kelapa sawit. *Agroista: Jurnal Agroteknologi*, *2*(1), 28–40. https://jurnal.instiperjogja.ac.id/index.php/AGI/article/view/25

Baret, F., Jacquemoud, S., & Hanocq, J. F. (1993). The soil line concept in remote sensing. *Remote Sensing Reviews*, *7*(1), 65–82. https://doi.org/10.1080/02757259309532166

Barnes, R. J., Dhanoa, M. S., & Lister, S. J. (1989). Standard normal variate transformation and de-trending of near-infrared diffuse reflectance spectra. *Applied Spectroscopy*, *43*(5), 772–777. https://doi.org/10.1366/0003702894202201

Bartholomeus, H., Kooistra, L., Stevens, A., van Leeuwen, M., van Wesemael, B., Ben-Dor, E., & Tychon, B. (2011). Soil organic carbon mapping of partially vegetated agricultural fields with imaging spectroscopy. *International Journal of Applied Earth Observation and Geoinformation*, *13*(1), 81–88. https://doi.org/10.1016/j.jag.2010.06.009

Bartholomeus, H. M., Schaepman, M. E., Kooistra, L., Stevens, A., Hoogmoed, W. B., & Spaargaren, O. S. P. (2008). Spectral reflectance based indices for soil organic carbon quantification. *Geoderma*, *145*(1–2), 28–36. https://doi.org/10.1016/j.geoderma.2008.01.010

Beven, K. J., & Kirkby, M. J. (1979). A physically based, variable contributing area model of basin hydrology. *Hydrological Sciences Bulletin*, *24*(1), 43–69. https://doi.org/10.1080/02626667909491834

Birkeland, P. W. (1999). Soils and geomorphology (Edisi ke-3). Oxford University Press.

Blaschke, T. (2010). Object based image analysis for remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing*, *65*(1), 2–16. https://doi.org/10.1016/j.isprsjprs.2009.06.004

Bousbih, S., Zribi, M., Pelletier, C., Gorrab, A., Lili-Chabaane, Z., Baghdadi, N., Ben Aissa, N., & Mougenot, B. (2019). Soil texture estimation using radar and optical data from Sentinel-1 and Sentinel-2. *Remote Sensing*, *11*(13), 1520. https://doi.org/10.3390/rs11131520

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Briliyanti, R. D., Maulana, I., Jannah, E. M., & Purboseno, S. (2025). The effectiveness of drones in improving efficiency and accuracy of oil palm plantation management in Indonesia: A literature review. *ARRUS Journal of Engineering and Technology*, *5*(1), 142–149. https://doi.org/10.35877/jetech4033

Brus, D. J., Kempen, B., & Heuvelink, G. B. M. (2011). Sampling for validation of digital soil maps. *European Journal of Soil Science*, *62*(3), 394–407. https://doi.org/10.1111/j.1365-2389.2011.01364.x

Buringh, P. (1954). The analysis and interpretation of aerial photographs in soil survey and land classification. *Netherlands Journal of Agricultural Science*, *2*(1), 16–26. https://doi.org/10.18174/njas.v2i1.17853

Buringh, P. (1955). Some problems concerning aerial photo-interpretation in soil survey. *Netherlands Journal of Agricultural Science*, *3*(2), 100–105. https://doi.org/10.18174/njas.v3i2.17817

Cahyana, D., Sulaeman, Y., Barus, B., Darmawan, & Mulyanto, B. (2023). Improving digital soil mapping in Bogor, Indonesia using parent material information. *Geoderma Regional*, *33*, e00627. https://doi.org/10.1016/j.geodrs.2023.e00627

Carlston, C. W. (1963). *Drainage density and streamflow* (Professional Paper 422-C). U.S. Geological Survey. https://doi.org/10.3133/pp422C

Castaldi, F., Hueni, A., Chabrillat, S., Ward, K., Buttafuoco, G., Bomans, B., Vreys, K., Brell, M., & van Wesemael, B. (2019). Evaluating the capability of the Sentinel 2 data for soil organic carbon prediction in croplands. *ISPRS Journal of Photogrammetry and Remote Sensing*, *147*, 267–282. https://doi.org/10.1016/j.isprsjprs.2018.11.026

Castaldi, F., Palombo, A., Santini, F., Pascucci, S., Pignatti, S., & Casa, R. (2016). Evaluation of the potential of the current and forthcoming multispectral and hyperspectral imagers to estimate soil texture and organic carbon. *Remote Sensing of Environment*, *179*, 54–65. https://doi.org/10.1016/j.rse.2016.03.025

Chabrillat, S., Ben-Dor, E., Cierniewski, J., Gomez, C., Schmid, T., & van Wesemael, B. (2019). Imaging spectroscopy for soil mapping and monitoring. *Surveys in Geophysics*, *40*(3), 361–399. https://doi.org/10.1007/s10712-019-09524-0

Clark, R. N., King, T. V. V., Klejwa, M., Swayze, G. A., & Vergo, N. (1990). High spectral resolution reflectance spectroscopy of minerals. *Journal of Geophysical*

Research: Solid Earth, *95*(B8), 12653–12680. https://doi.org/10.1029/JB095iB08p12653

Clark, R. N., & Roush, T. L. (1984). Reflectance spectroscopy: Quantitative analysis techniques for remote sensing applications. *Journal of Geophysical Research: Solid Earth*, *89*(B7), 6329–6340. https://doi.org/10.1029/JB089iB07p06329

Cogliati, S., Sarti, F., Chiarantini, L., Cosi, M., Lorusso, R., Lopinto, E., Miglietta, F., Genesio, L., Guanter, L., Damm, A., Pérez-López, S., Scheffler, D., Tagliabue, G., Panigada, C., Rascher, U., Dowling, T. P. F., Giardino, C., & Colombo, R. (2021). The PRISMA imaging spectroscopy mission: Overview and first performance analysis. *Remote Sensing of Environment*, *262*, 112499. https://doi.org/10.1016/j.rse.2021.112499

Dadap, N. C., Hoyt, A. M., Cobb, A. R., Oner, D., Kozinski, M., Fua, P. V., Rao, K., Harvey, C. F., & Konings, A. G. (2021). Drainage canals in Southeast Asian peatlands increase carbon emissions. *AGU Advances*, *2*(1), e2020AV000321. https://doi.org/10.1029/2020AV000321

Dalrymple, J. B., Blong, R. J., & Conacher, A. J. (1968). An hypothetical nine unit landsurface model. *Zeitschrift für Geomorphologie*, *12*(1), 60–76. https://doi.org/10.1127/zfg/12/1968/60

Danoedoro, P. (1996). *Pengolahan citra digital teori dan aplikasinya dalam bidang penginderaan jauh*. Fakultas Geografi Universitas Gadjah Mada.

Danoedoro, P. (2012). *Pengantar penginderaan jauh digital*. Andi.

Danylo, O., Pirker, J., Lemoine, G., Ceccherini, G., See, L., McCallum, I., Hadi, Kraxner, F., Achard, F., & Fritz, S. (2021). A map of the extent and year of detection of oil palm plantations in Indonesia, Malaysia and Thailand. *Scientific Data*, *8*(1), 96. https://doi.org/10.1038/s41597-021-00867-1

Daughtry, C. S. T. (2001). Discriminating crop residues from soil by shortwave infrared reflectance. *Agronomy Journal*, *93*(1), 125–131. https://doi.org/10.2134/agronj2001.931125x

Demattê, J. A. M., Safanelli, J. L., Poppiel, R. R., Rizzo, R., Silvero, N. E. Q., Mendes, W. de S., Bonfatti, B. R., Dotto, A. C., Salazar, D. F. U., Mello, F. A. de O., Paiva, A. F. da S., Souza, A. B., Santos, N. V. dos, Maria Nascimento, C., Mello, D. C. de, Bellinaso, H., Gonzaga Neto, L., Amorim, M. T. A., Resende, M. E. B. de, . . . Lisboa, C. J. da S. (2020). Bare Earth's surface spectra as a proxy for soil resource monitoring. *Scientific Reports*, *10*(1), 4461. https://doi.org/10.1038/s41598-020-61408-1

Descals, A., Wich, S., Meijaard, E., Gaveau, D. L. A., Peedell, S., & Szantoi, Z. (2021). High-resolution global map of smallholder and industrial closed-canopy oil palm plantations. *Earth System Science Data*, *13*(3), 1211–1231. https://doi.org/10.5194/essd-13-1211-2021

Diek, S., Fornallaz, F., Schaepman, M. E., & de Jong, R. (2017). Barest pixel composite for agricultural areas using Landsat time series. *Remote Sensing*, *9*(12), 1245. https://doi.org/10.3390/rs9121245

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., Hoersch, B., Isola, C., Laberinti, P., Martimort, P., Meygret, A., Spoto, F., Sy, O., Marchese, F., & Bargellini, P. (2012). Sentinel-2: ESA's optical high-resolution mission for GMES operational services. *Remote Sensing of Environment*, *120*, 25–36. https://doi.org/10.1016/j.rse.2011.11.026

Dubois, P. C., van Zyl, J., & Engman, T. (1995). Measuring soil moisture with imaging radars. *IEEE Transactions on Geoscience and Remote Sensing*, *33*(4), 915–926. https://doi.org/10.1109/36.406677

Dvorakova, K., Shi, P., Limbourg, Q., & van Wesemael, B. (2020). Soil organic carbon mapping from remote sensing: The effect of crop residues. *Remote Sensing*, *12*(12), 1913. https://doi.org/10.3390/rs12121913

Elsharkawy, M. M., Sheta, A. E. A. S., D'Antonio, P., Abdelwahed, M. S., & Scopa, A. (2022). Tool for the establishment of agro-management zones using GIS techniques for precision farming in Egypt. Sustainability, 14(9), 5437. https://doi.org/10.3390/su14095437

England, J. R., & Viscarra Rossel, R. A. (2018). Proximal sensing for soil carbon accounting. *SOIL*, *4*(2), 101–122. https://doi.org/10.5194/soil-4-101-2018

Escadafal, R. (1993). Remote sensing of soil color: Principles and applications. *Remote Sensing Reviews*, *7*(3–4), 261–279. https://doi.org/10.1080/02757259309532181

Forkuor, G., Hounkpatin, O. K. L., Welp, G., & Thiel, M. (2017). High resolution mapping of soil properties using remote sensing variables in south-western Burkina Faso: A comparison of machine learning and multiple linear regression models. *PLOS ONE*, *12*(1), e0170478. https://doi.org/10.1371/journal.pone.0170478

Galvão, L. S., & Vitorello, Í. (1998). Role of organic matter in obliterating the effects of iron on spectral reflectance and colour of Brazilian tropical soils. *International Journal of Remote Sensing*, *19*(10), 1969–1979. https://doi.org/10.1080/014311698215090

Gholizadeh, A., Žižala, D., Saberioon, M., & Borůvka, L. (2018). Soil organic carbon and texture retrieving and mapping using proximal, airborne and Sentinel-2 spectral imaging. *Remote Sensing of Environment*, *218*, 89–103. https://doi.org/10.1016/j.rse.2018.09.015

Ginting, E. N., & Wiratmoko, D. (2021). Potensi dan tantangan penerapan precision farming dalam upaya membangun perkebunan kelapa sawit yang berkelanjutan. *Warta Pusat Penelitian Kelapa Sawit*, *26*(2), 55–66. https://doi.org/10.22302/iopri.war.warta.v26i2.47

Hall-Beyer, M. (2017). *GLCM texture: A tutorial* (Versi 3.0). University of Calgary. https://doi.org/10.11575/PRISM/33280

Hallikainen, M. T., Ulaby, F. T., Dobson, M. C., El-Rayes, M. A., & Wu, L.-K. (1985). Microwave dielectric behavior of wet soil—Part I: Empirical models and experimental observations. *IEEE Transactions on Geoscience and Remote Sensing*, *GE-23*(1), 25–34. https://doi.org/10.1109/TGRS.1985.289497

Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, *SMC-3*(6), 610–621. https://doi.org/10.1109/TSMC.1973.4309314

Haubrock, S.-N., Chabrillat, S., Lemmnitz, C., & Kaufmann, H. (2008). Surface soil moisture quantification models from reflectance data under field conditions. *International Journal of Remote Sensing*, *29*(1), 3–29. https://doi.org/10.1080/01431160701294695

Hengl, T., Mendes de Jesus, J., Heuvelink, G. B. M., Ruiperez Gonzalez, M., Kilibarda, M., Blagotić, A., Shangguan, W., Wright, M. N., Geng, X., Bauer-Marschallinger, B., Guevara, M. A., Vargas, R., MacMillan, R. A., Batjes, N. H., Leenaars, J. G. B., Ribeiro, E., Wheeler, I., Mantel, S., & Kempen, B. (2017). SoilGrids250m: Global gridded soil information based on machine learning. *PLOS ONE*, *12*(2), e0169748. https://doi.org/10.1371/journal.pone.0169748

Hengl, T., & Rossiter, D. G. (2003). Supervised landform classification to enhance and replace photo-interpretation in semi-detailed soil survey. *Soil Science Society of America Journal*, *67*(6), 1810–1822. https://doi.org/10.2136/sssaj2003.1810

Highland, L. M., & Bobrowsky, P. (2008). *The landslide handbook—A guide to understanding landslides* (Circular 1325). U.S. Geological Survey. https://doi.org/10.3133/cir1325

Hong, Y., Yu, L., Chen, Y., Liu, Y., Liu, Y., Liu, Y., & Cheng, H. (2018). Prediction of soil organic matter by VIS–NIR spectroscopy using normalized soil moisture index as a proxy of soil moisture. *Remote Sensing*, *10*(1), 28. https://doi.org/10.3390/rs10010028

Hosseinpour-Zarnaq, M., Omid, M., Sarmadian, F., Ghasemi-Mobtaker, H., Alimardani, R., & Bohlol, P. (2025). Exploring the capabilities of hyperspectral remote sensing for soil texture evaluation. Ecological Informatics, 90, 103336. https://doi.org/10.1016/j.ecoinf.2025.103336

Howard, A. D. (1967). Drainage analysis in geologic interpretation: A summation. *AAPG Bulletin*, *51*(11), 2246–2259. https://doi.org/10.1306/5D25C26D-16C1-11D7-8645000102C1865D

Hudson, B. D. (1992). The soil survey as paradigm-based science. *Soil Science Society of America Journal*, *56*(3), 836–841. https://doi.org/10.2136/sssaj1992.03615995005600030027x

Huete, A. R. (1988). A soil-adjusted vegetation index (SAVI). *Remote Sensing of Environment*, *25*(3), 295–309. https://doi.org/10.1016/0034-4257(88)90106-X

Hunt, G. R. (1977). Spectral signatures of particulate minerals in the visible and near infrared. *Geophysics*, *42*(3), 501–513. https://doi.org/10.1190/1.1440721

Jensen, J. R. (2004). *Remote sensing and digital image processing*. Department of Geography University of South Carolina.

Kerr, Y. H., Waldteufel, P., Wigneron, J.-P., Delwart, S., Cabot, F., Boutin, J., Escorihuela, M.-J., Font, J., Reul, N., Gruhier, C., Juglea, S. E., Drinkwater, M. R., Hahne, A., Martín-Neira, M., & Mecklenburg, S. (2010). The SMOS mission: New tool for monitoring key elements of the global water cycle. *Proceedings of the IEEE*, *98*(5), 666–687. https://doi.org/10.1109/JPROC.2010.2043032

Lillesand, T. M., & Kiefer, R. W. (1990). *Penginderaan jauh dan interpretasi citra* (Dulbahri dkk., Penerj.). Gadjah Mada University Press.

Lillesand, T. M., Kiefer, R. W., & Chipman, J. W. (2015). *Remote sensing and image interpretation* (Edisi ke-7). John Wiley & Sons.

Lobell, D. B., & Asner, G. P. (2002). Moisture effects on soil reflectance. *Soil Science Society of America Journal*, *66*(3), 722–727. https://doi.org/10.2136/sssaj2002.7220

Loiseau, T., Chen, S., Mulder, V. L., Román Dobarco, M., Richer-de-Forges, A. C., Lehmann, S., Bourennane, H., Saby, N. P. A., Martin, M. P., Vaudour, E., Gomez, C., Lagacherie, P., & Arrouays, D. (2019). Satellite data integration for soil clay content modelling at a national scale. *International Journal of Applied Earth Observation and Geoinformation*, *82*, 101905. https://doi.org/10.1016/j.jag.2019.101905

Lu, Y., Liu, X., & Zhang, J. (2023). Digital soil mapping of heavy metals using multiple geospatial environmental auxiliary variables and advanced machine learning techniques. *Ecological Indicators*, 154, 110051.

Ma, Y., Minasny, B., Malone, B. P., & McBratney, A. B. (2019). Pedology and digital soil mapping (DSM). *European Journal of Soil Science*, *70*(2), 216–235. https://doi.org/10.1111/ejss.12790

Ma, Z., Chen, X., & Wang, C. (2026). Multi-source remote sensing fusion and deep learning for intelligent precision agriculture. *Sensors*, *26*(20), 6434. https://doi.org/10.3390/s26206434

Madeira, J., Bedidi, A., Cervelle, B., Pouget, M., & Flay, N. (1997). Visible spectrometric indices of hematite (Hm) and goethite (Gt) content in lateritic soils: The application of a Thematic Mapper (TM) image for soil-mapping in Brasilia, Brazil. *International Journal of Remote Sensing*, *18*(13), 2835–2852. https://doi.org/10.1080/014311697217369

Main-Knorn, M., Pflug, B., Louis, J., Debaecker, V., Müller-Wilm, U., & Gascon, F. (2017). Sen2Cor for Sentinel-2. Dalam L. Bruzzone, F. Bovolo, & J. A. Benediktsson (Ed.), *Image and signal processing for remote sensing XXIII*. SPIE. https://doi.org/10.1117/12.2278218

Martinez, A., Camberato, J. J., Owens, P., & Ashtekar, J. (2021). Using terrain algorithms on a digital elevation model to evaluate yield variability in oil palm.

Journal of Oil Palm Research, *33*(1), 84–92. https://doi.org/10.21894/jopr.2020.0092

Martos, V., Ahmad, A., Cartujo, P., & Ordoñez, J. (2021). Ensuring agricultural sustainability through remote sensing in the era of Agriculture 5.0. Applied Sciences, 11(13), 5911. https://doi.org/10.3390/app11135911

Maxwell, A. E., Warner, T. A., & Fang, F. (2018). Implementation of machine-learning classification in remote sensing: An applied review. *International Journal of Remote Sensing*, *39*(9), 2784–2817. https://doi.org/10.1080/01431161.2018.1433343

McBratney, A. B., Mendonça Santos, M. L., & Minasny, B. (2003). On digital soil mapping. *Geoderma*, *117*(1–2), 3–52. https://doi.org/10.1016/S0016-7061(03)00223-4

Meinshausen, N. (2006). Quantile regression forests. *Journal of Machine Learning Research*, *7*, 983–999. https://www.jmlr.org/papers/v7/meinshausen06a.html

Meyer, H., & Pebesma, E. (2021). Predicting into unknown space? Estimating the area of applicability of spatial prediction models. *Methods in Ecology and Evolution*, *12*(9), 1620–1633. https://doi.org/10.1111/2041-210X.13650

Mgohele, R. N., Massawe, B. H. J., Shitindi, M. J., Sanga, H. G., & Omar, M. M. (2024). Prediction of soil texture using remote sensing data. A systematic review. *Frontiers in Remote Sensing*, *5*, 1461537. https://doi.org/10.3389/frsen.2024.1461537

Milne, G. (1935). Some suggested units of classification and mapping, particularly for East African soils. Soil Research, 4(3), 183–198.

Molin, J. P., & Tavares, T. R. (2019). Sensor systems for mapping soil fertility attributes: Challenges, advances, and perspectives in Brazilian tropical soils. *Engenharia Agrícola*, *39*(spe), 126–147. https://doi.org/10.1590/1809-4430-Eng.Agric.v39nep126-147/2019

Mooy, H., & Watuwaya, B. K. (2023). Peran penginderaan jauh dan sistem informasi geografis dalam penerapan pertanian cerdas di era Industri 4.0. *Dalam Prosiding Seminar Nasional Tahun 2023* (Vol. 5, No. 1).

Mukhamedova, K. R., Cherepkova, N. P., Korotkov, A. V., Dagasheva, Z. B., & Tvaronavičienė, M. (2022). Digitalisation of agricultural production for precision farming: A case study. Sustainability, 14(22), 14802. https://doi.org/10.3390/su142214802

Mulder, V. L., de Bruin, S., Schaepman, M. E., & Mayr, T. R. (2011). The use of remote sensing in soil and terrain mapping—A review. *Geoderma*, *162*(1–2), 1–19. https://doi.org/10.1016/j.geoderma.2010.12.018

Natural Resources Canada. (2025, 8 Januari). *Elements of visual interpretation* [Tutorial Fundamentals of Remote Sensing]. Government of Canada. https://natural-resources.canada.ca/maps-tools-and-publications/satellite-imagery-elevation-data-

and-air-photos/tutorial-fundamentals-remote-sensing/image-interpretation-analysis/elements-visual-interpretation/9291

Nugraha, A. S. A., & Citra, I. P. A. (2021). Perbandingan metode Soil Adjusted Vegetation Index (SAVI) dan Forest Canopy Density (FCD) untuk identifikasi tutupan vegetasi (Kasus: Area pembuatan jalan baru Singaraja-Mengwi). *Jurnal Geografi: Media Informasi Pengembangan dan Profesi Kegeografian*, *18*(1), 1–8. https://doi.org/10.15294/jg.v18i1.25367

Nussbaum, M., Spiess, K., Baltensweiler, A., Grob, U., Keller, A., Greiner, L., Schaepman, M. E., & Papritz, A. (2018). Evaluation of digital soil mapping approaches with large sets of environmental covariates. *SOIL*, *4*(1), 1–22. https://doi.org/10.5194/soil-4-1-2018

Oh, Y., Sarabandi, K., & Ulaby, F. T. (1992). An empirical model and an inversion technique for radar scattering from bare soil surfaces. *IEEE Transactions on Geoscience and Remote Sensing*, *30*(2), 370–381. https://doi.org/10.1109/36.134086

Pascucci, S., Pignatti, S., Casa, R., Darvishzadeh, R., & Huang, W. (2020). Special issue "Hyperspectral remote sensing of agriculture and vegetation". *Remote Sensing, 12*(21), 3665. https://doi.org/10.3390/rs12213665

Ploton, P., Mortier, F., Réjou-Méchain, M., Barbier, N., Picard, N., Rossi, V., Dormann, C., Cornu, G., Viennois, G., Bayol, N., Lyapustin, A., Gourlet-Fleury, S., & Pélissier, R. (2020). Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nature Communications*, *11*(1), 4540. https://doi.org/10.1038/s41467-020-18321-y

Poggio, L., de Sousa, L. M., Batjes, N. H., Heuvelink, G. B. M., Kempen, B., Ribeiro, E., & Rossiter, D. (2021). SoilGrids 2.0: Producing soil information for the globe with quantified spatial uncertainty. *SOIL*, *7*(1), 217–240. https://doi.org/10.5194/soil-7-217-2021

Pohl, C., & van Genderen, J. L. (1998). Multisensor image fusion in remote sensing: Concepts, methods and applications. *International Journal of Remote Sensing, 19*(5), 823–854. https://doi.org/10.1080/014311698215748

Prajapati, R., Chakrborty, D., Saha, S., Gupta, V. K., & Sahoo, R. N. (2019). Remote sensing for estimation of intensity and extent of plant residue cover. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, *XLII-3/W6*, 423–427. https://doi.org/10.5194/isprs-archives-XLII-3-W6-423-2019

Riebeek, H. (2014, 14 Maret). *Why is that forest red and that cloud blue? How to interpret a false-color satellite image*. NASA Earth Observatory. https://science.nasa.gov/earth/earth-observatory/how-to-interpret-a-false-color-satellite-image

Rikimaru, A., Roy, P. S., & Miyatake, S. (2002). Tropical forest cover density mapping. *Tropical Ecology*, *43*(1), 39–47.

Roberts, D., Wilford, J., & Ghattas, O. (2019). Exposed soil and mineral map of the Australian continent revealing the land at its barest. *Nature Communications*, *10*(1), 5297. https://doi.org/10.1038/s41467-019-13276-1

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, *40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Rogge, D., Bauer, A., Zeidler, J., Mueller, A., Esch, T., & Heiden, U. (2018). Building an exposed soil composite processor (SCMaP) for mapping spatial and temporal characteristics of soils with Landsat imagery (1984–2014). *Remote Sensing of Environment*, *205*, 1–17. https://doi.org/10.1016/j.rse.2017.11.004

Rossiter, D. G. (2000). *Methodology for soil resource inventories* (Edisi revisi ke-2) [Catatan kuliah]. Soil Science Division, International Institute for Aerospace Survey & Earth Sciences (ITC). https://www.css.cornell.edu/faculty/dgr2/_static/files/pdf/SSM_LectureNotes2.pdf

Sartohadi, J., Suratman, Jamulya, & Dewi, N. I. S. (2022). *Pengantar geografi tanah* (Cetakan ke-4). Pustaka Pelajar.

Savitzky, A., & Golay, M. J. E. (1964). Smoothing and differentiation of data by simplified least squares procedures. *Analytical Chemistry*, *36*(8), 1627–1639. https://doi.org/10.1021/ac60214a047

Schaetzl, R. J., & Anderson, S. (2005). *Soils: Genesis and geomorphology*. Cambridge University Press. https://doi.org/10.1017/CBO9780511815560

Scheinost, A. C., Chavernas, A., Barrón, V., & Torrent, J. (1998). Use and limitations of second-derivative diffuse reflectance spectroscopy in the visible to near-infrared range to identify and quantify Fe oxide minerals in soils. *Clays and Clay Minerals*, *46*(5), 528–536. https://doi.org/10.1346/CCMN.1998.0460506

Seelan, S. K., Laguette, S., Casady, G. M., & Seielstad, G. A. (2003). Remote sensing applications for precision agriculture: A learning community approach. *Remote Sensing of Environment, 88*(1–2), 157–169. https://doi.org/10.1016/j.rse.2003.04.007

Segarra, J., Buchaillot, M. L., Araus, J. L., & Kefauver, S. C. (2020). Remote sensing for precision agriculture: Sentinel-2 improved features and applications. Agronomy, 10(5), 641. https://doi.org/10.3390/agronomy10050641

Soil Survey Division Staff. (2017). *Soil survey manual* (C. Ditzler, K. Scheffe, & H. C. Monger, Ed.; USDA Handbook No. 18). Government Printing Office.

Sulaeman, Y., & Husnain. (2021). Membuat peta tanah dengan teknik disagregasi spasial. *Jurnal Sumberdaya Lahan*, *15*(2), 59–73. https://doi.org/10.21082/jsdl.v15n2.2021.59-73

Sulaiman, M. S., Udin, W. S., Khan, M. A., Sulaiman, N., Ismail, R., & Bahar, A. (2021). Analysis of drainage pattern and its relationship with gold potential in Batu Melintang, Jeli, Kelantan. *IOP Conference Series: Earth and Environmental Science*, *842*(1), 012043. https://doi.org/10.1088/1755-1315/842/1/012043

Sutanto. (1994). *Penginderaan jauh* (Jilid 1 dan 2). Gadjah Mada University Press.

Syah, A. F. (2010). Penginderaan jauh dan aplikasinya di wilayah pesisir dan lautan. *Jurnal Kelautan, 3*(1), 18–28.

Teillet, P. M., Guindon, B., & Goodenough, D. G. (1982). On the slope-aspect correction of multispectral scanner data. *Canadian Journal of Remote Sensing*, *8*(2), 84–106. https://doi.org/10.1080/07038992.1982.10855028

Thandapani, P. U., Harahap, Z., & Nadaraj, S. (2024). Usage of near infrared spectrometer as an analyzing tool for nutrients in leaf, fertilizer and soil in oil palm industry. *IOP Conference Series: Earth and Environmental Science*, *1308*(1), 012036. https://doi.org/10.1088/1755-1315/1308/1/012036

Tucker, C. J. (1979). Red and photographic infrared linear combinations for monitoring vegetation. *Remote Sensing of Environment*, *8*(2), 127–150. https://doi.org/10.1016/0034-4257(79)90013-0

Twomey, S. A., Bohren, C. F., & Mergenthaler, J. L. (1986). Reflectance and albedo differences between wet and dry surfaces. *Applied Optics*, *25*(3), 431–437. https://doi.org/10.1364/AO.25.000431

Vaudour, E., Gomez, C., Fouad, Y., & Lagacherie, P. (2019). Sentinel-2 image capacities to predict common topsoil properties of temperate and Mediterranean agroecosystems. *Remote Sensing of Environment*, *223*, 21–33. https://doi.org/10.1016/j.rse.2019.01.006

Viscarra Rossel, R. A., Adamchuk, V. I., Sudduth, K. A., McKenzie, N. J., & Lobsey, C. (2011). Proximal soil sensing: An effective approach for soil measurements in space and time. *Advances in Agronomy*, *113*, 243–291. https://doi.org/10.1016/B978-0-12-386473-4.00005-1

Viscarra Rossel, R. A., Behrens, T., Ben-Dor, E., Brown, D. J., Demattê, J. A. M., Shepherd, K. D., Shi, Z., Stenberg, B., Stevens, A., Adamchuk, V., Aïchi, H., Barthès, B. G., Bartholomeus, H. M., Bayer, A. D., Bernoux, M., Böttcher, K., Brodský, L., Du, C. W., Chappell, A., . . . Ji, W. (2016). A global spectral library to characterize the world's soil. *Earth-Science Reviews*, *155*, 198–230. https://doi.org/10.1016/j.earscirev.2016.01.012

Viscarra Rossel, R. A., & Bouma, J. (2016). Soil sensing: A new paradigm for agriculture. *Agricultural Systems*, *148*, 71–74. https://doi.org/10.1016/j.agsy.2016.07.001

Wadoux, A. M. J.-C., Minasny, B., & McBratney, A. B. (2020). Machine learning for digital soil mapping: Applications, challenges and suggested solutions. *Earth-Science Reviews*, *210*, 103359. https://doi.org/10.1016/j.earscirev.2020.103359

Wadoux, A. M. J.-C., Samuel-Rosa, A., Poggio, L., & Mulder, V. L. (2020). A note on knowledge discovery and machine learning in digital soil mapping. *European Journal of Soil Science*, *71*(2), 133–136. https://doi.org/10.1111/ejss.12909

Weiss, M., Jacob, F., & Duveiller, G. (2020). Remote sensing for agricultural applications: A meta-review. *Remote Sensing of Environment, 236*, 111402. https://doi.org/10.1016/j.rse.2019.111402

Wibowo, W. H., & Junaedi, A. (2017). Peremajaan kelapa sawit (*Elaeis guineensis* Jacq.) di Seruyan Estate, Minamas Plantation Group, Seruyan, Kalimantan Tengah. *Buletin Agrohorti*, *5*(1), 107–116. https://doi.org/10.29244/agrob.5.1.107-116

Wold, S., Sjöström, M., & Eriksson, L. (2001). PLS-regression: A basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, *58*(2), 109–130. https://doi.org/10.1016/S0169-7439(01)00155-1

Xiao, J., Shen, Y., Tateishi, R., & Bayaer, W. (2006). Development of topsoil grain size index for monitoring desertification in arid land using remote sensing. *International Journal of Remote Sensing*, *27*(12), 2411–2422. https://doi.org/10.1080/01431160600554363

Zhang, J. (2010). Multi-source remote sensing data fusion: Status and trends. *International Journal of Image and Data Fusion, 1*(1), 5–24. https://doi.org/10.1080/19479830903561035

Zhu, A. X., Hudson, B., Burt, J., Lubich, K., & Simonson, D. (2001). Soil mapping using GIS, expert knowledge, and fuzzy logic. *Soil Science Society of America Journal*, *65*(5), 1463–1472. https://doi.org/10.2136/sssaj2001.6551463x

Zinck, J. A. (2023). The geopedologic approach. Dalam J. A. Zinck, G. Metternicht, H. F. del Valle, & M. Angelini (Ed.), *Geopedology: An integration of geomorphology and pedology for soil and landscape studies* (hlm. 35–67). Springer. https://doi.org/10.1007/978-3-031-20667-2_4

Zribi, M., Kotti, F., Lili-Chabaane, Z., Baghdadi, N., Ben Issa, N., Amri, R., Amri, B., & Chehbouni, A. (2012). Soil texture estimation over a semiarid area using TerraSAR-X radar data. *IEEE Geoscience and Remote Sensing Letters*, *9*(3), 353–357. https://doi.org/10.1109/LGRS.2011.2168379

