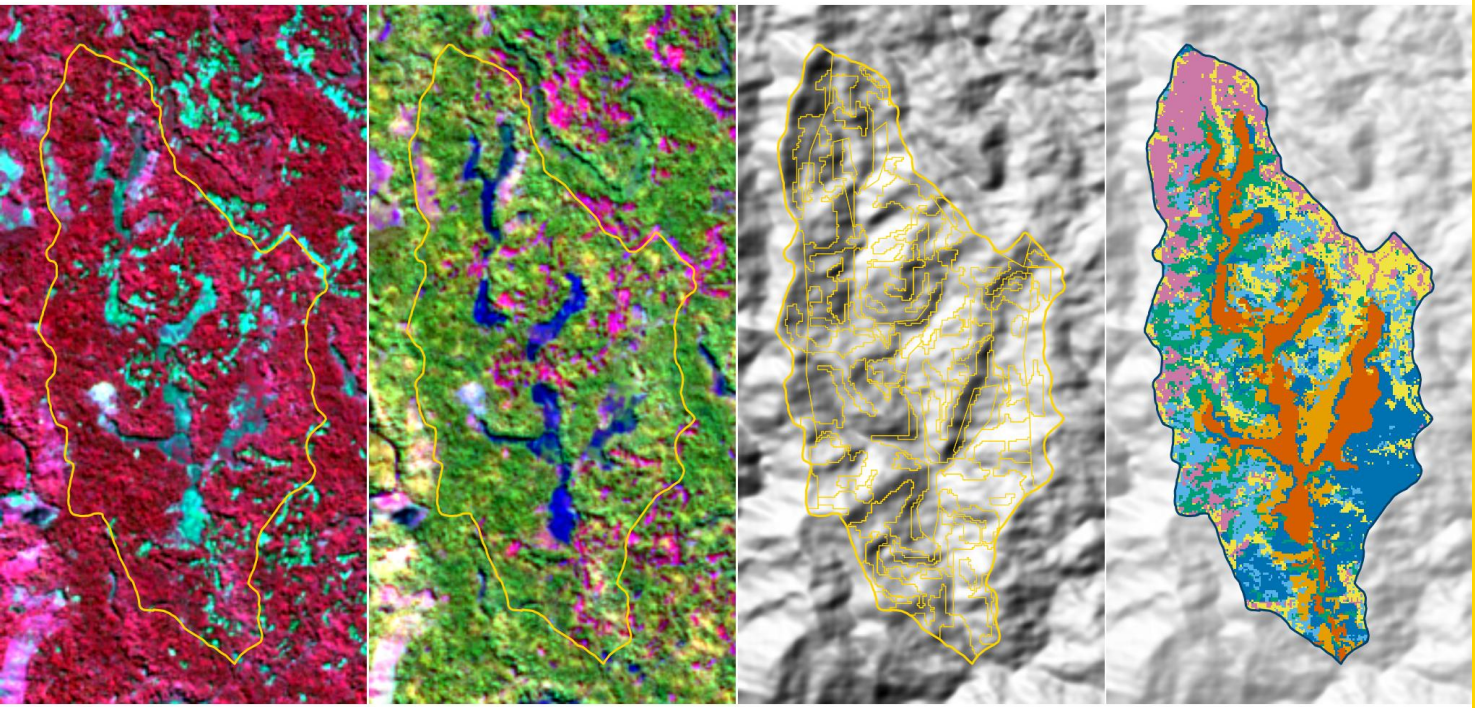
UNIVERSITAS GADJAH MADA

Modul Pembelajaran

Praktik Remote Sensing dan Digital Soil Mapping untuk Pertanian Presisi pada Perkebunan Kelapa Sawit

Wilayah latihan: Sub-DAS Bompon dan Site Gunung Madu Plantation



Sub-DAS Bompon, dari kiri: komposit inframerah dekat, komposit SWIR, batas SMU di atas bayangan medan, dan prediksi tutupan material dari model latihan. Contains modified Copernicus Sentinel data 2024–2025.

Disusun oleh:

Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Pelatihan:

3–5 November 2026

Kata Pengantar

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas rahmat-Nya modul praktik Pelatihan Pemanfaatan Remote Sensing dan Digital Soil Mapping untuk Pertanian Presisi pada Perkebunan Kelapa Sawit ini dapat diselesaikan. Modul ini kami susun sebagai pendamping modul teori, agar peserta memiliki panduan yang dapat diikuti selama pelatihan dan dapat dibuka kembali sesudahnya.

Kami mengucapkan terima kasih atas kesempatan yang telah diberikan untuk menyelenggarakan pelatihan ini. Terima kasih juga kami sampaikan kepada para narasumber, pemandu praktik, serta semua pihak yang telah membantu menyediakan data dan masukan selama penyusunan modul.

Kami menyadari bahwa modul ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran dari para pembaca sangat kami harapkan untuk penyempurnaannya. Semoga modul ini bermanfaat bagi peserta dan bagi pengelolaan lahan perkebunan.

Yogyakarta, November 2026

Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Daftar Isi

Kata Pengantar **01**
Daftar Isi **02**
Daftar Tabel **04**
Daftar Gambar **06**
Persiapan Praktik **09**
Memasang QGIS 09
Memasang Jupyter Notebook 10
Tahap 1: Mencari Data di Ina-Geoportal 12
Tahap 2: Mengunduh DEMNAS 13
Tahap 3: Mengunduh Sentinel-2 14
Tahap 4: Mengunduh Sentinel-1 16
Tahap 5: Mengambil Data dengan Python 17
Praktik 1. Multi-source Data Fusion **21**
Tahap 1: Memuat dan Mengenali Data 22
Tahap 2: Menyelaraskan ke Grid 10 m 25
Tahap 3: Menyusun dan Memotong Tumpukan Data 28
Tahap 4: Membandingkan DEMNAS dan LiDAR 30
Tahap 5: Menyiapkan Data Detail dari Foto Udara 33
Tahap 6: Pan-sharpening Sentinel-2 35
Tahap 7: Bagaimana dengan LiDAR? 38
Tahap 8: Menguji Hasilnya 39
Praktik 2. Remote Sensing untuk Delineasi Soil Mapping Unit **44**
Tahap 1: Menurunkan Lereng dari DEM 45
Tahap 2: Indeks Sifat Tanah dari Citra 48
Tahap 3: Mendigitasi Satuan Bentuklahan 50
Tahap 4: Menyusun SMU dengan Tumpang Susun 56
Tahap 5: Generalisasi Sesuai Skala 58
Tahap 6: Membandingkan dengan Peta Riset 62
Praktik 3. Proximal Soil Sensing **65**
Bagian 1: Demonstrasi Pengukuran 68
Bagian 2: Membuka Notebook 69
Bagian 3: Membaca Spektrum 69
Bagian 4: Praolah dan Data Komposisi 70
Bagian 5: Membandingkan dan Memilih Model 71
Bagian 6: Membaca Hasil 74
Bagian 7: Memakai Model untuk Sampel Tanah Baru 76
Praktik 4. Bare Soil Detection & Information Extraction **79**
Tahap 1: Melihat Kedua Citra 80
Tahap 2: Menyingkirkan Piksel Bermasalah 82
Tahap 3: Menghitung Indeks 82
Tahap 4: Mencoba Aturan Ambang 84
Tahap 5: Memeriksa dengan Peta Penggunaan Lahan 86
Tahap 6: Menyusun Masker Akhir 88
Tahap 7: Mengekstraksi Informasi Tanah 90
Tahap 8: Komposit Dua Tanggal 92

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Praktik 5. Machine Learning untuk Digital Soil Mapping 95
Tahap 1: Alur Machine Learning 97
Tahap 2: Menyiapkan Kovariat di QGIS 98
Tahap 3: Menampilkan Titik Latih dan Uji 103
Tahap 4: Menyiapkan dan Memilih Kovariat 105
Tahap 5: Membangun, Menilai, dan Memilih Kovariat Model 107
Tahap 6: Menangani Data yang Tidak Seimbang 112
Tahap 7: Peta Kelas, Peluang, dan Keberlakuan Model 115
Tahap 8: Menampilkan Hasil di QGIS 118
Tahap 9: Bahan Presentasi 122
Penutup 124
Daftar Pustaka 125

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Daftar Tabel

Tabel P0.1 Lima Praktik, Perangkat, dan Modul Teorinya 09
Tabel P0.2 Masalah yang Umum saat Memasang Jupyter 11
Tabel P0.3 Sumber Data dan Cara Mengambilnya 12
Tabel P1.1 Data Praktik 1 22
Tabel P1.2 Hasil Pemeriksaan Data pada Uji Coba 24
Tabel P1.3 Korelasi Data Detail dengan Sentinel-2 pada Grid 10 m 40
Tabel P1.4 Hasil Uji Wald pada Sentinel-2 41
Tabel P1.5 Uji Wald pada Gabungan Lain 42
Tabel P1.6 Selisih Rata-rata terhadap DEMNAS menurut Zona (m) 42
Tabel P2.1 Data Praktik 2 45
Tabel P2.2 Kelas Lereng 47
Tabel P2.3 Rumus Indeks 48
Tabel P2.4 Kunci Interpretasi Sederhana untuk Latihan 50
Tabel P2.5 Legenda SMU Contoh Hasil Uji Coba 62
Tabel P2.6 Perbandingan Luas Delineasi Uji Coba dengan Bentuklahan Riset (ha) 63
Tabel P2.7 Luas Kelas Lereng dari DEM 30 m dan dari LiDAR (ha) 64
Tabel P3.1 Berkas Praktik 3 67
Tabel P3.2 Spesifikasi ASD FieldSpec 4 68
Tabel P3.3 Hasil Lima Praolah dan Dua Algoritme 72
Tabel P3.4 Ketelitian Model Terpilih pada Data Uji 73
Tabel P3.5 R^2 dari 20 Pembagian Acak dengan Praolah SNV 74
Tabel P3.6 Prediksi Tekstur Sampel pada Berkas Contoh 77
Tabel P3.7 Ketelitian Model Lapisan 1 pada Sampel Lapisan 2 sampai 4 77
Tabel P4.1 Data Praktik 4 80
Tabel P4.2 Nomor Kanal pada Kedua Citra 80
Tabel P4.3 Rumus Indeks untuk Citra 13 Agustus 2024 82
Tabel P4.4 Tiga Aturan Tanah Terbuka untuk Citra 2024 85
Tabel P4.5 Jumlah Piksel Tanah Terbuka di Dalam Sub-DAS (Total 29.469 Piksel) 85
Tabel P4.6 Kandidat Tanah Terbuka Aturan B Menurut Penggunaan Lahan 88
Tabel P4.7 Statistik Indeks Sebelum dan Sesudah Masker 91
Tabel P4.8 Rerata Pantulan Piksel Tanah Terbuka dan Vegetasi Rapat 91
Tabel P5.1 Data Praktik 5 96
Tabel P5.2 Tujuh Kelas Tutupan Material Sub-DAS Bompon 97
Tabel P5.3 Model Pertama pada Data Latih dan Data Uji 98
Tabel P5.4 Enam Belas Kovariat dan Faktor SCORPAN-nya 103
Tabel P5.5 Pasangan Kovariat dengan Korelasi Pearson $|r| \geq 0{,}8$ 106
Tabel P5.6 Hasil Validasi Silang Klasifikasi Tutupan Material 108
Tabel P5.7 Ketelitian per Kelas pada Validasi Blok Spasial 110
Tabel P5.8 Kepentingan Kovariat dan Keputusan Pemilihan 111
Tabel P5.9 Pengaruh Pemilihan Kovariat pada Ketelitian CatBoost 112
Tabel P5.10 Pengaruh Penanganan Data Tidak Seimbang pada Validasi Blok Spasial 113
Tabel P5.11 Proporsi Luas Kelas pada Peta Prediksi (%) 114
Tabel P5.12 Ketelitian Model Akhir per Kelas pada Validasi Blok Spasial 115
Tabel P5.13 Peluang Kelas Tertinggi dan Proporsi Tebakan yang Benar 117
Tabel P5.14 Komposisi Tutupan Material Prediksi menurut Bentuklahan pada Peta SMU Contoh (%) 121

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Daftar Gambar

Gambar P0.1 Hasil pencarian katalog Ina-Geoportal dengan kata kunci DEMNAS 12
Gambar P0.2 Halaman Unduh Data di Ina-Geoportal 13
Gambar P0.3 Lembar DEMNAS 1408-23 yang mencakup Sub-DAS Bompon 14
Gambar P0.4 Formulir pencarian Copernicus Browser, dengan titik lokasi pada peta 15
Gambar P0.5 Daftar hasil pencarian Sentinel-2 15
Gambar P0.6 Memilih produk Sentinel-1 Level-1 GRD 16
Gambar P0.7 Daftar hasil pencarian Sentinel-1 16
Gambar P0.8 Desa yang bersinggungan dengan wilayah kerja 17
Gambar P0.9 Daftar adegan Sentinel-2 dari katalog STAC 18
Gambar P0.10 Membaca sepuluh kanal Sentinel-2 dan SCL pada jendela wilayah kerja 18
Gambar P0.11 Daftar adegan dan pembacaan Sentinel-1 RTC 19
Gambar P0.12 Hasil unduhan dan pencocokannya dengan data Praktik 1 19
Gambar P0.13 Pencarian produk utuh di Copernicus Data Space 20
Gambar P1.1 Data dimuat di QGIS, dengan Sentinel-2 warna asli dan batas Sub-DAS 23
Gambar P1.2 Tab Information pada DEMNAS 24
Gambar P1.3 Foto udara yang tersusun dari dua pemotretan dengan warna berbeda 25
Gambar P1.4 Dialog Warp untuk DEMNAS 26
Gambar P1.5 Dialog Warp untuk LiDAR dengan metode *Average* 26
Gambar P1.6 Mengubah hamburan balik VV ke desibel 27
Gambar P1.7 Sentinel-1 VV dalam desibel 27
Gambar P1.8 Dialog Build Virtual Raster 28
Gambar P1.9 Memotong tumpukan dengan Batas_Bompon 29
Gambar P1.10 Komposit lintas sensor dari Sentinel-2, Sentinel-1, dan LiDAR 29
Gambar P1.11 Identify Features menampilkan 14 nilai dari empat sumber 30
Gambar P1.12 Menghitung selisih DEMNAS dan LiDAR 31
Gambar P1.13 Selisih DEMNAS dan LiDAR, makin merah berarti DEMNAS makin tinggi 31
Gambar P1.14 Bayangan medan DEMNAS 32
Gambar P1.15 Bayangan medan LiDAR 1 m 32
Gambar P1.16 Membuat kanal kelabu dari foto udara 33
Gambar P1.17 Membawa pan ke grid 2,5 m 34
Gambar P1.18 Mengambil tiga kanal tampak Sentinel-2 34
Gambar P1.19 Menyetarakan pan dengan rata-rata dan simpangan baku intensitas Sentinel-2 35
Gambar P1.20 Dialog Pansharpening 36
Gambar P1.21 Sentinel-2 asli, 10 m 37
Gambar P1.22 Sentinel-2 setelah ditajamkan dengan foto udara, 2,5 m 37
Gambar P1.23 Sentinel-2 setelah ditajamkan dengan bayangan medan LiDAR 38
Gambar P1.24 Seluruh Sub-DAS setelah ditajamkan dengan foto udara 39
Gambar P1.25 Kemiripan data detail dengan kanal Sentinel-2 di notebook 40
Gambar P1.26 Hasil uji Wald di notebook 41
Gambar P1.27 Hasil fusi DEM di notebook 42
Gambar P1.28 Sentinel-2 asli, hasil dua penajaman, dan foto udara pada potongan yang sama 43
Gambar P2.1 Dialog Slope 46
Gambar P2.2 Kemiringan lereng dalam persen 46
Gambar P2.3 Dialog Reclassify by Table 47
Gambar P2.4 Lima kelas lereng 48
Gambar P2.5 Menghitung indeks kecerahan 49

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambar P2.6 Rasio mineral lempung (CMR) 49
Gambar P2.7 NDVI 50
Gambar P2.8 Tampilan acuan: komposit SWIR dengan sungai dan batas Sub-DAS 51
Gambar P2.9 Tampilan acuan: bayangan medan, kontur 10 m, dan sungai 51
Gambar P2.10 Membuat layer GeoPackage baru 52
Gambar P2.11 Form atribut setelah satu poligon selesai 52
Gambar P2.12 Digitasi poligon sedang berjalan 53
Gambar P2.13 Hasil digitasi dengan Avoid Overlap, sebelum dipotong mengikuti batas Sub-DAS 53
Gambar P2.14 Dialog Clip 54
Gambar P2.15 Menghitung luas poligon dengan Field Calculator 55
Gambar P2.16 Contoh peta satuan bentuklahan hasil digitasi uji coba 55
Gambar P2.17 Dialog Polygonize 56
Gambar P2.18 Dialog Fix Geometries 57
Gambar P2.19 Dialog Intersection 57
Gambar P2.20 Satuan peta sebelum generalisasi 58
Gambar P2.21 Poligon yang lebih kecil dari MLA terpilih 59
Gambar P2.22 Dialog Eliminate Selected Polygons 59
Gambar P2.23 Dialog Retain Fields 60
Gambar P2.24 Dialog Dissolve 60
Gambar P2.25 Peta SMU setelah generalisasi 61
Gambar P2.26 Membuat legenda SMU dengan Statistics by Categories 61
Gambar P2.27 Batas digitasi uji coba (garis hitam) di atas peta bentuklahan riset 63
Gambar P3.1 Derau antarkanal (kiri) dan spektrum 69 sampel lapisan 1 yang diwarnai menurut kadar lempung (kanan) 69
Gambar P3.2 Kedalaman serapan 2.205 nm terhadap kadar lempung 70
Gambar P3.3 Contoh spektrum lapisan 1 dengan lima praolah 71
Gambar P3.4 RMSE terhadap jumlah komponen PLSR pada praolah SNV, dari validasi silang data latih dan dari data uji 73
Gambar P3.5 Prediksi terhadap nilai laboratorium untuk setiap fraksi dan pada segitiga tekstur 74
Gambar P3.6 Sebaran R^2 data uji dari 20 pembagian acak 74
Gambar P3.7 Kenaikan MAE saat setiap jendela 20 nm diacak, untuk PLSR dan *random forest* dengan praolah SG-FD 75
Gambar P4.1 Komposit SWIR 13 Agustus 2024 81
Gambar P4.2 Komposit SWIR 21 Juli 2025 81
Gambar P4.3 Membuat masker piksel bersih dari SCL 82
Gambar P4.4 Menghitung BSI dengan Raster Calculator 83
Gambar P4.5 NDVI 13 Agustus 2024 83
Gambar P4.6 BSI 13 Agustus 2024 84
Gambar P4.7 NBR2 13 Agustus 2024 84
Gambar P4.8 Menuliskan aturan B pada Raster Calculator 85
Gambar P4.9 Kandidat tanah terbuka aturan B di atas komposit SWIR, diperbesar di bagian tengah Sub-DAS 86
Gambar P4.10 Kandidat tanah terbuka (hitam) di atas peta penggunaan lahan 87
Gambar P4.11 Dialog Zonal Histogram 87
Gambar P4.12 Menyaring poligon selain permukiman 88
Gambar P4.13 Memotong masker dengan poligon selain permukiman 89
Gambar P4.14 Masker tanah terbuka akhir di atas komposit SWIR, diperbesar di bagian tengah Sub-DAS 89
Gambar P4.15 Menerapkan masker untuk mengekstraksi indeks 90
Gambar P4.16 Rasio mineral lempung (CMR) hanya pada piksel tanah terbuka 91
Gambar P4.17 Dialog Cell Statistics 92
Gambar P4.18 Frekuensi keterbukaan dari dua tanggal 93

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambar P4.19 Komposit CMR dari tanggal dengan NDVI terendah 94
Gambar P5.1 Sebaran akurasi dari 30 pembagian acak yang berbeda 98
Gambar P5.2 Membawa DEMNAS 8 m ke grid kovariat 10 m 99
Gambar P5.3 Mengubah arah hadap menjadi kosinus 100
Gambar P5.4 Dialog Topographic Position Index 100
Gambar P5.5 Menghitung indeks kebasahan topografi dengan r.topidx 101
Gambar P5.6 Mengubah garis sungai menjadi raster 101
Gambar P5.7 Menghitung jarak ke sungai terdekat 102
Gambar P5.8 Memberi kode numerik pada kelas bentuklahan 102
Gambar P5.9 Titik latih (hitam) dan titik uji (putih) di atas peta tutupan material 104
Gambar P5.10 Dialog Sample Raster Values 104
Gambar P5.11 Tabel atribut titik latih dan uji 105
Gambar P5.12 Matriks korelasi Pearson antarkovariat 106
Gambar P5.13 Tiga skema validasi, dengan warna yang menunjukkan nomor lipatan 107
Gambar P5.14 Matriks kebingungan CatBoost pada validasi blok spasial 109
Gambar P5.15 Kepentingan permutasi kovariat, dengan garis yang menunjukkan simpangan baku antarlipatan 111
Gambar P5.16 Recall per kelas pada tiga cara penanganan data tidak seimbang 114
Gambar P5.17 Matriks kebingungan model akhir pada validasi blok spasial 115
Gambar P5.18 Peta acuan dan peta prediksi tutupan material 116
Gambar P5.19 Peluang kelas tertinggi dan entropi peluang 117
Gambar P5.20 Kesesuaian prediksi dengan peta acuan dan titik yang salah pada validasi blok spasial 118
Gambar P5.21 Prediksi tutupan material dengan batas SMU dan titik sampel 119
Gambar P5.22 Peluang kelas tertinggi dengan batas SMU dan titik sampel 119
Gambar P5.23 Kesesuaian prediksi dengan peta acuan, dengan hijau untuk piksel yang sama dan jingga untuk piksel yang berbeda 120
Gambar P5.24 Wilayah keberlakuan model, dengan merah menandai piksel di luar AOA 120
Gambar P5.25 Dialog Zonal Histogram 121
Gambar P5.26 Jumlah piksel setiap kelas material per poligon SMU pada tabel atribut 121

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Persiapan Praktik

Pelatihan ini memuat lima praktik. Empat di antaranya mengerjakan satu wilayah latihan yang sama, yaitu Sub-DAS Bompon di Kabupaten Magelang, sedangkan Praktik 3 memakai pustaka spektral dari sampel tanah Site Gunung Madu Plantation (GMP), Lampung. Hasil satu praktik menjadi masukan praktik berikutnya, sehingga pada akhirnya peserta memegang satu alur kerja yang utuh, dari data mentah sampai peta prediksi sifat tanah beserta ketidakpastiannya.

Sub-DAS Bompon bukan perkebunan kelapa sawit. Luasnya sekitar 295 ha dan penggunaan lahannya berupa agroforestri, tegalan, sawah, dan permukiman. Wilayah ini dipakai karena datanya paling lengkap untuk latihan DSM, yaitu titik sampel berstrata dengan hasil laboratorium, peta bentuklahan hasil riset, dan citra satelit. Pemandu akan menarik analogi ke kebun sawit pada setiap praktik. Agroforestri yang tajuknya rapat, misalnya, dapat dibayangkan sebagai blok tanaman menghasilkan, sedangkan tegalan dan sawah saat bera sebagai blok peremajaan.

Lima Praktik

Tabel P0.1 Lima Praktik, Perangkat, dan Modul Teorinya

Praktik	Pemandu	Perangkat	Modul teori
1. Multi-source Data Fusion	Johan	QGIS, Jupyter	Modul 2
2. Delineasi SMU	Johan, Nurarfiyah	QGIS	Modul 3, 4, 6
3. Proximal Soil Sensing	Pak Pandu, Nurarfiyah	ASD FieldSpec 4, Jupyter	Modul 4, 7
4. Bare Soil Detection	Nurarfiyah	QGIS	Modul 5
5. Machine Learning untuk DSM	Ferry	QGIS, Jupyter	Modul 2, 4, 8

Sumber: Pembagian pemandu pelatihan

Urutan pengerjaan tidak selalu sama dengan nomor bab di buku teori. Keluaran Praktik 2 dan Praktik 5 dipakai sebagai bahan presentasi pada akhir pelatihan.

Memasang QGIS

QGIS dipakai pada hampir semua praktik. Pasanglah versi rilis jangka panjang (*Long Term Release*, LTR), bukan versi terbaru. Versi LTR lebih stabil dan menjadi versi yang dipakai saat menguji modul ini, yaitu QGIS 3.44. Pada saat modul ini disusun, halaman unduhan juga menawarkan QGIS 4.2 sebagai *Latest Release*, tetapi versi itu tidak diuji, dan tampilannya dapat berbeda dari gambar pada modul.

1. Buka https://qgis.org/download/, lalu pilih sistem operasi Anda.
2. Pada bagian **Long Term Release**, klik **Download LTR 3.44**. Pada Windows, berkas yang terunduh bernama seperti `QGIS-OSGeo4W-3.44.15-2.msi`. Angka di belakang 3.44 dapat berubah, karena perbaikan terus dirilis. Jika LTR yang tertera sudah lebih baru, pilih tetap LTR tersebut.
3. Jalankan berkasnya, setujui lisensinya, lalu ikuti langkah pemasangan sampai selesai. Pemasang Windows sudah menyertakan GDAL dan GRASS, yang dipakai pada Praktik 1 dan Praktik 5. Pengguna Linux mengikuti petunjuk distribusi pada halaman yang sama.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

4. Buka QGIS. Tombol dan menu dalam modul ini mengikuti antarmuka berbahasa Inggris, sehingga sebaiknya bahasa diatur melalui **Settings > Options > General**, dengan mencentang **Override System Locale** dan memilih *American English*, lalu menutup dan membuka kembali QGIS.

Titik periksa. Help > About menampilkan versi 3.44, dan **Raster > Analysis > Slope** dapat dibuka.

Memasang Jupyter Notebook

Jupyter Notebook menjalankan kode Python di dalam browser, dan dipakai untuk akuisisi data dengan Python, evaluasi pada Praktik 1, serta Praktik 3 dan Praktik 5. Tangkapan layar pada modul memakai JupyterLab, yaitu antarmuka yang lebih baru dari proyek yang sama. Keduanya membuka berkas `.ipynb` yang sama dan terpasang sekaligus dengan langkah berikut. Ada dua cara yang sama-sama dapat dipakai.

Cara pertama adalah memasangnya di laptop, sehingga praktik tetap dapat berjalan tanpa bergantung pada layanan daring.

1. **Pasang Python 3.13.** Buka https://www.python.org/downloads/, lalu pilih rilis 3.13 terbaru pada daftar **Looking for a specific release?** Jangan langsung menekan tombol unduhan utama, karena tombol itu menawarkan Python 3.15, sedangkan sebagian pustaka praktik belum menyediakan paket siap pasang untuk versi tersebut. Pada Windows, centang **Add python.exe to PATH** di jendela pertama pemasang, lalu klik **Install Now**.
2. **Buka terminal di folder `Pelatihan`.** Pada Windows, buka folder itu di File Explorer, ketik `cmd` pada bilah alamat, lalu tekan Enter. Pada macOS dan Linux, buka Terminal, lalu masuk ke folder itu dengan perintah `cd`.
3. **Periksa Python.** Ketik `python --version`, atau `python3 --version` pada macOS dan Linux. Keluarannya harus menunjukkan 3.13.
4. **Buat lingkungan kerja dan pasang pustaka.** Jalankan perintah berikut satu per satu. Tulisan di dalam kurung tidak ikut diketik. Perintah kedua dari bawah memperbarui pemasang paket `pip`, sedangkan perintah terakhir memasang semua pustaka praktik, termasuk Jupyter. Perintah terakhir memerlukan internet dan ruang penyimpanan sekitar 800 MB, sehingga sebaiknya dikerjakan sebelum pelatihan.

```
python -m venv env_pelatihan
env_pelatihan\Scripts\activate           (Windows)
source env_pelatihan/bin/activate        (Linux atau macOS)
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

5. **Periksa hasilnya.** Jalankan perintah berikut. Keluarannya harus berbunyi `Siap dipakai`.

```
python -c "import rasterio, sklearn, catboost, imblearn; print('Siap dipakai')"
```

6. **Buka Jupyter.** Ketik `jupyter lab`, atau `python -m notebook` jika ingin tampilan yang lebih sederhana. Browser akan terbuka dan menampilkan isi folder. Masuk ke `data/`, lalu klik dua kali berkas `.ipynb`. Biarkan terminal tetap terbuka selama bekerja, dan tekan **Ctrl + C** pada terminal itu untuk menutup Jupyter.

Saat membukanya lagi di lain waktu, langkah 1 sampai 5 tidak perlu diulang. Cukup buka terminal di folder `Pelatihan`, jalankan perintah `activate` seperti langkah 4, lalu `jupyter lab`.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P0.2 Masalah yang Umum saat Memasang Jupyter

Gejala	Penyebab yang mungkin	Jalan keluar
`python` tidak dikenali	Python belum masuk PATH	Pasang ulang dengan mencentang **Add python.exe to PATH**, lalu buka terminal baru
Perintah `activate` ditolak	Terminal yang dipakai PowerShell	Pakai Command Prompt (`cmd`) seperti langkah 2
`pip` gagal memasang `rasterio` atau `scipy`	Versi Python terlalu baru atau terlalu lama	Pasang Python 3.13, hapus folder `env_pelatihan`, lalu ulangi langkah 4
`jupyter` tidak dikenali	Lingkungan kerja belum aktif	Jalankan perintah `activate` lebih dulu, atau pakai `python -m notebook`

Sumber: Disusun penyusun

Cara kedua adalah Google Colab, yang hanya memerlukan akun Google dan koneksi internet. Unggah folder `Pelatihan/data` ke Google Drive, buka notebook dengan Colab, lalu sesuaikan satu baris alamat folder pada sel pertama. Sel tersebut memasang pustaka yang diperlukan secara otomatis.

Susunan Folder

Setiap praktik memiliki foldernya sendiri dan isinya sudah mencukupi, sehingga peserta tidak perlu mencari berkas di folder lain. Berkas yang merupakan hasil praktik sebelumnya, seperti `smu_akhir.gpkg`, sudah disalin ke folder praktik yang membutuhkannya.

```
Pelatihan/
├── modul/                modul praktik ini
├── data/
│   ├── praktik-0/        notebook akuisisi data
│   ├── praktik-1/        Sentinel-1, Sentinel-2, DEMNAS, LiDAR, foto udara, dan notebook
evaluasi
│   ├── praktik-2/        citra, DEM 10 m, dan peta riset pembanding
│   ├── praktik-3/        pustaka spektral dan notebook
│   ├── praktik-4/        citra dua tanggal
│   └── praktik-5/        titik tutupan material, kovariat, dan notebook
└── screenshots/          tangkapan layar hasil uji coba
```

Di dalam setiap folder praktik terdapat `hasil-contoh/`, yang berisi semua keluaran hasil uji coba penyusun beserta proyek QGIS `Praktik_N_selesai.qgz`. Buat folder baru bernama `hasil/` untuk menyimpan pekerjaan Anda sendiri, dan biarkan `hasil-contoh/` tetap utuh. Peserta yang tertinggal pada suatu tahap dapat mengambil berkas dari `hasil-contoh/`, lalu melanjutkan tahap berikutnya bersama yang lain.

Tangkapan layar pada modul ini berasal dari uji coba langsung pada QGIS 3.44 dan JupyterLab. Tampilan pada versi lain dapat sedikit berbeda, tetapi nama alat dan parameternya sama. Alamat folder yang tampak pada gambar adalah alamat di komputer penyusun.

Akuisisi Data

Sebelum data dapat dipadukan, data itu harus diperoleh dulu. Data latihan sudah disediakan di folder `data/`, sehingga bagian ini tidak wajib dikerjakan sebelum pelatihan. Bagian ini disertakan agar peserta dapat mengulang langkah yang sama untuk kebun masing-masing.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P0.3 Sumber Data dan Cara Mengambilnya

Data	Portal	Akun	Cara dengan Python
Peta dasar dan batas wilayah	Ina-Geoportal	Diperlukan untuk unduhan portal	Layanan peta BIG, tanpa akun
DEMNAS	Ina-Geoportal	Diperlukan	Unduh manual, lalu dipotong dengan Python
Sentinel-2 L2A	Copernicus Browser	Diperlukan untuk unduhan	Earth Search, tanpa akun
Sentinel-1	Copernicus Browser	Diperlukan untuk unduhan	Planetary Computer, tanpa akun

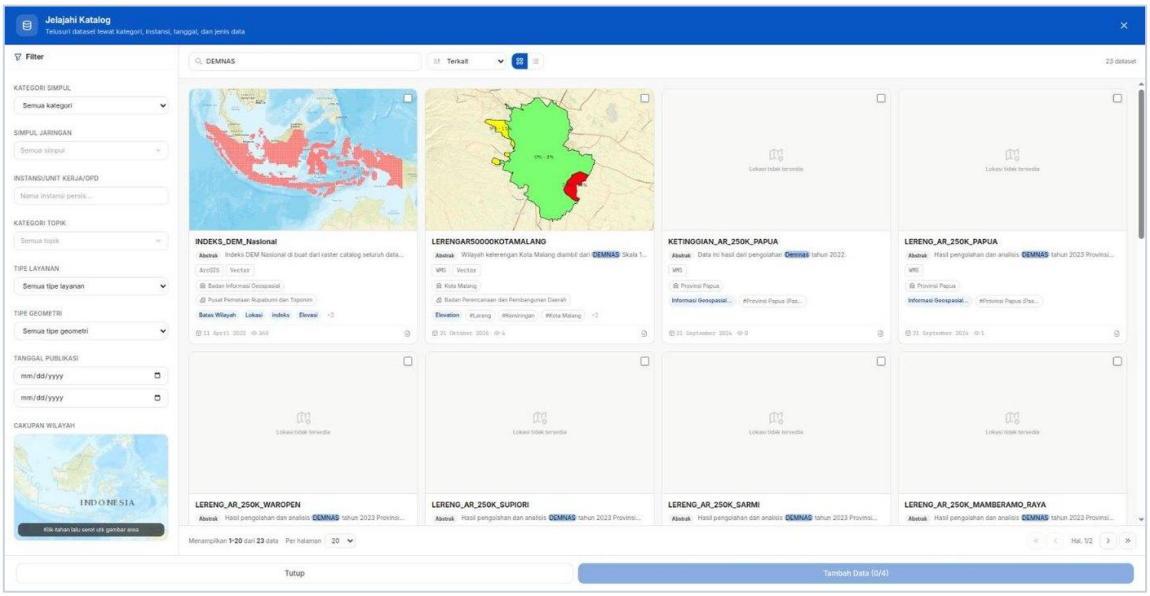
Sumber: Hasil penelusuran portal, 2 November 2026

Tampilan portal sering berubah, sehingga nama tombol dapat berbeda dari gambar. Langkah pendaftaran akun tidak diuji pada modul ini karena penyusun memakai akun yang sudah ada. Nama pengguna pada gambar telah ditutup.

Tahap 1: Mencari Data di Ina-Geoportal

Ina-Geoportal (https://tanahair.indonesia.go.id/portal-web/) adalah portal Jaringan Informasi Geospasial Nasional, yang menghimpun data dari kementerian, lembaga, dan pemerintah daerah. Ada dua pintu yang perlu dibedakan.

1. **Pencarian katalog.** Ketik nama data pada kotak pencarian di halaman utama, misalnya `DEMNAS`. Hasilnya adalah dataset dari banyak instansi, dengan abstrak, instansi pemilik, jenis layanan, dan tanggal publikasi. Periksa instansi pemiliknya, karena hasil pencarian "DEMNAS" juga memuat peta lereng buatan daerah yang hanya diturunkan dari DEMNAS.

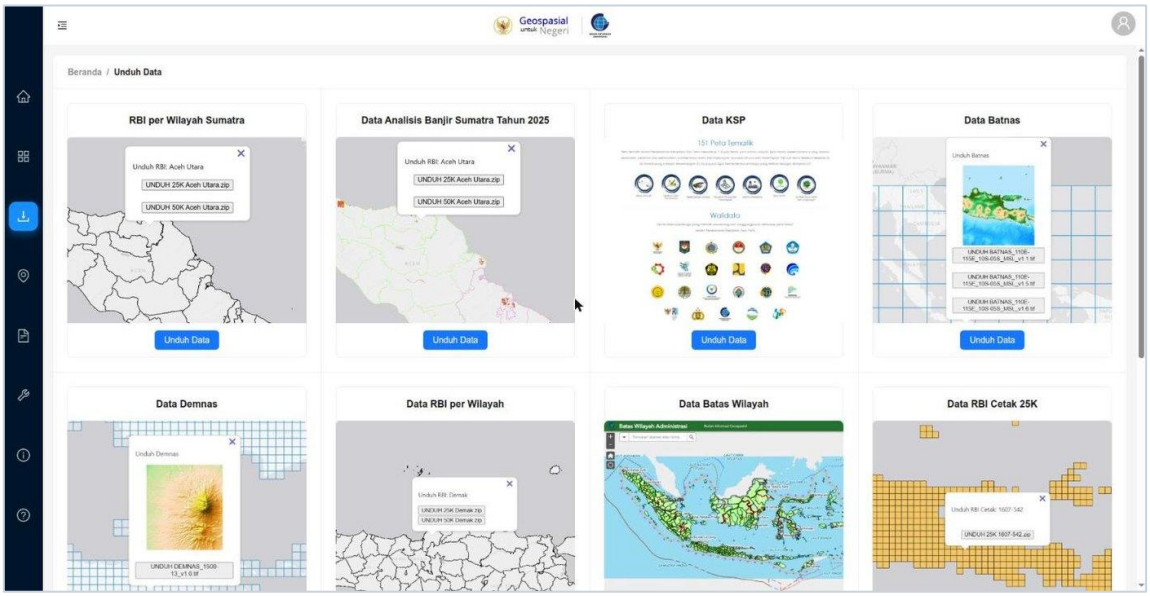


Gambar P0.1 Hasil pencarian katalog Ina-Geoportal dengan kata kunci DEMNAS

Sumber: Tangkapan layar Ina-Geoportal, Badan Informasi Geospasial

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. **Menu Unduh Data.** Klik ikon unduh pada bilah kiri. Halaman ini memuat data yang dapat diunduh langsung, antara lain DEMNAS, Batnas, Rupabumi Indonesia (RBI) per wilayah, dan batas wilayah.



Gambar P0.2 Halaman Unduh Data di Ina-Geoportal

Sumber: Tangkapan layar Ina-Geoportal, Badan Informasi Geospasial

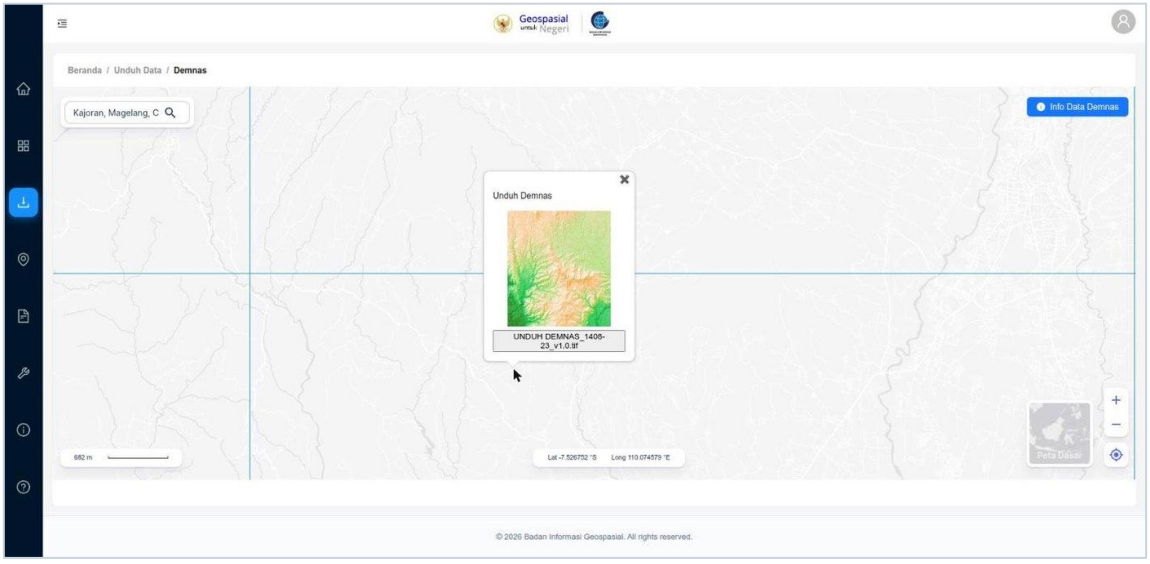
Tahap 2: Mengunduh DEMNAS

DEMNAS dibangun dari IFSAR, TerraSAR-X, dan ALOS PALSAR, dengan tambahan titik tinggi dari pembuatan peta RBI. Menurut halaman informasinya, resolusinya 0,27 detik busur, atau sekitar 8 m, dengan datum vertikal EGM2008 (Badan Informasi Geospasial, 2026).

1. Masuk dengan akun Anda, lalu buka **Unduh Data > Data Demnas > Unduh Data**. Peta menampilkan grid lembar DEMNAS.
2. Ketik nama lokasi pada **Cari Lokasi**, lalu pilih saran yang sesuai. Peta akan memperbesar terlalu jauh dan menampilkan *Map data not yet available*, jadi klik tombol **–** beberapa kali sampai garis lembar terlihat.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

3. Klik lembar yang mencakup wilayah Anda, lalu klik tombol **UNDUH DEMNAS_...tif** pada jendela yang muncul. Sub-DAS Bompon berada pada lembar `DEMNAS_1408-23_v1.0.tif`, berukuran 44 MB, yang mencakup 110,00–110,25° BT dan 7,50–7,75° LS.



Gambar P0.3 Lembar DEMNAS 1408-23 yang mencakup Sub-DAS Bompon

Sumber: Tangkapan layar Ina-Geoportal, Badan Informasi Geospasial

Perhatikan. Berkas yang diunduh pada uji coba tidak menyimpan sistem koordinat, sehingga QGIS menanyakannya atau tidak dapat menempatkannya. Koordinatnya adalah derajat geografis, jadi tetapkan `EPSG:4326` saat memuatnya. Praktik 1 tahap 1 menunjukkan caranya.

Wilayah yang melintasi dua lembar perlu digabung lebih dulu dengan **Raster > Miscellaneous > Merge**.

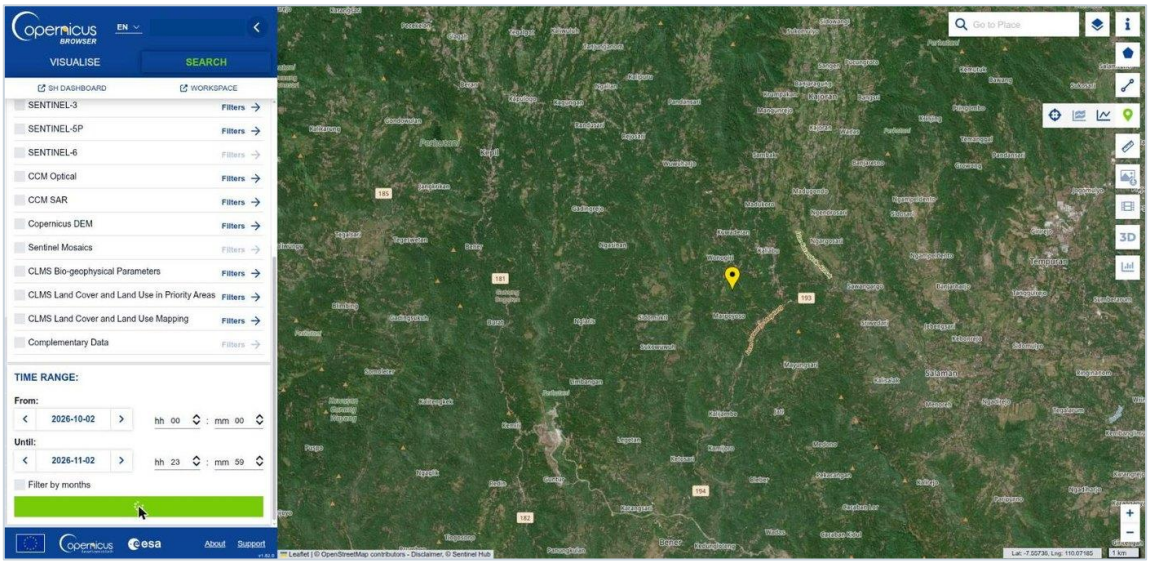
Tahap 3: Mengunduh Sentinel-2

Copernicus Browser (https://browser.dataspace.copernicus.eu) adalah pintu ke arsip Sentinel. Pencarian terbuka, tetapi unduhan memerlukan akun Copernicus Data Space Ecosystem yang gratis.

1. Masuk, geser peta ke wilayah Anda, lalu buka tab **SEARCH**.
2. Klik ikon penanda pada bilah kanan, lalu klik satu titik pada peta sebagai lokasi pencarian.
3. Pada **Data Sources**, centang **SENTINEL-2**, lalu **MSI**, lalu **L2A**, yaitu produk pantulan permukaan yang sudah terkoreksi atmosfer. Geser batas tutupan awan bila perlu. Tutupan awan itu berlaku untuk seluruh petak, bukan wilayah Anda.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

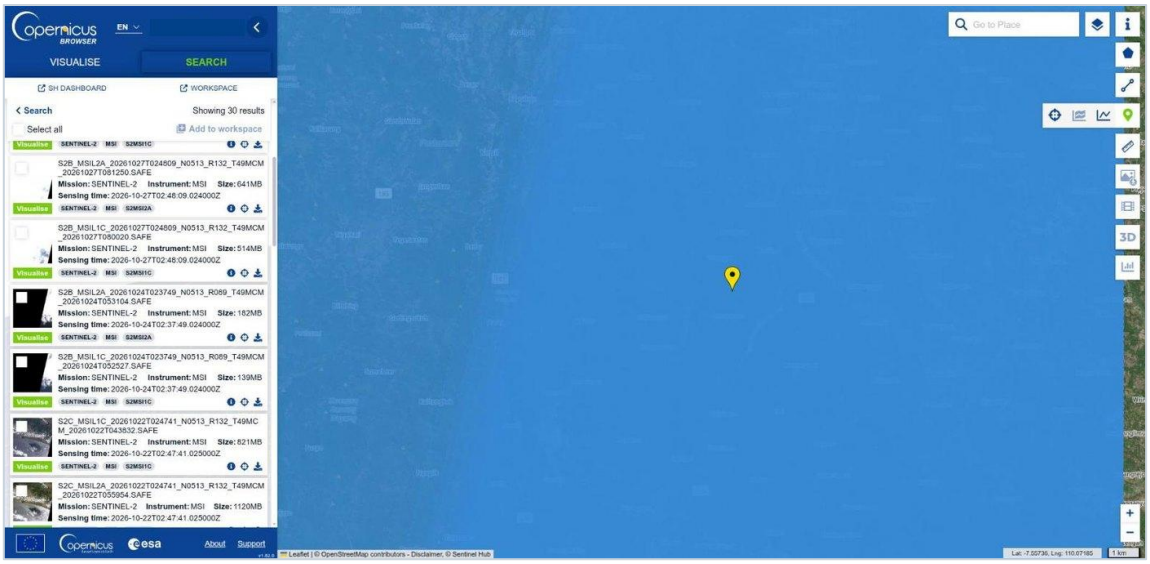
4. Isi **Time Range**, lalu klik **Search**.



Gambar P0.4 Formulir pencarian Copernicus Browser, dengan titik lokasi pada peta

Sumber: Tangkapan layar Copernicus Browser; *Contains modified Copernicus Sentinel data*

5. Daftar hasil menampilkan nama, ukuran, dan waktu perekaman. **Visualise** untuk melihat citranya lebih dulu, lalu klik ikon unduh pada produk yang dipilih. Periksa gambar kecilnya, karena sebagian petak hanya terisi sebagian dan bisa saja wilayah Anda kosong.



Gambar P0.5 Daftar hasil pencarian Sentinel-2

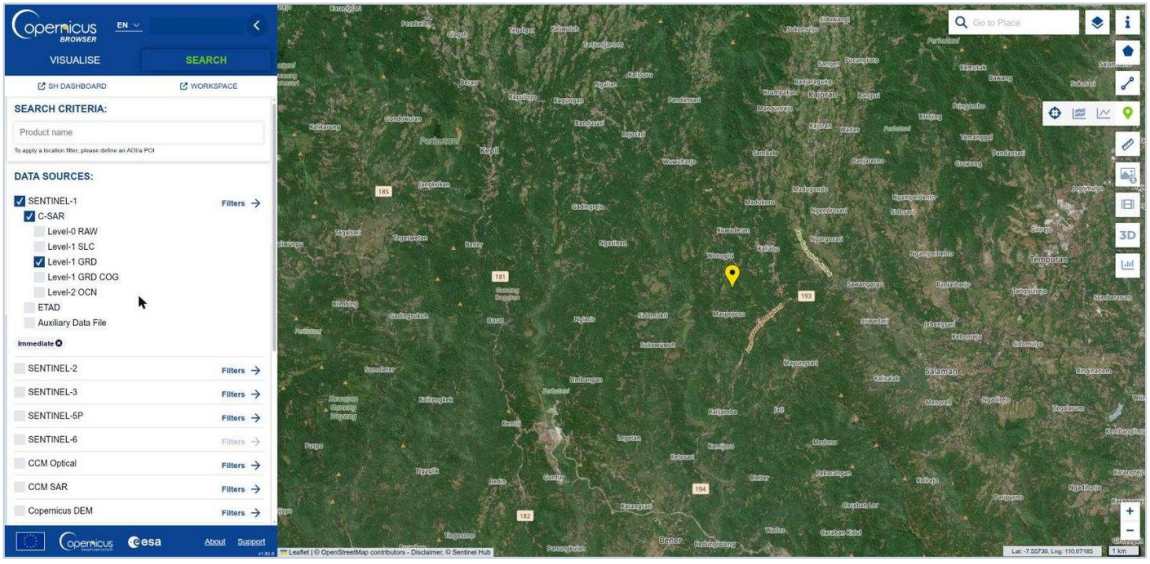
Sumber: Tangkapan layar Copernicus Browser; *Contains modified Copernicus Sentinel data*

Ukuran produk L2A pada pencarian uji coba berkisar 182–1.120 MB. Berkasnya berupa `.zip` berisi folder `.SAFE`, dengan kanal terpisah pada resolusi 10, 20, dan 60 m.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

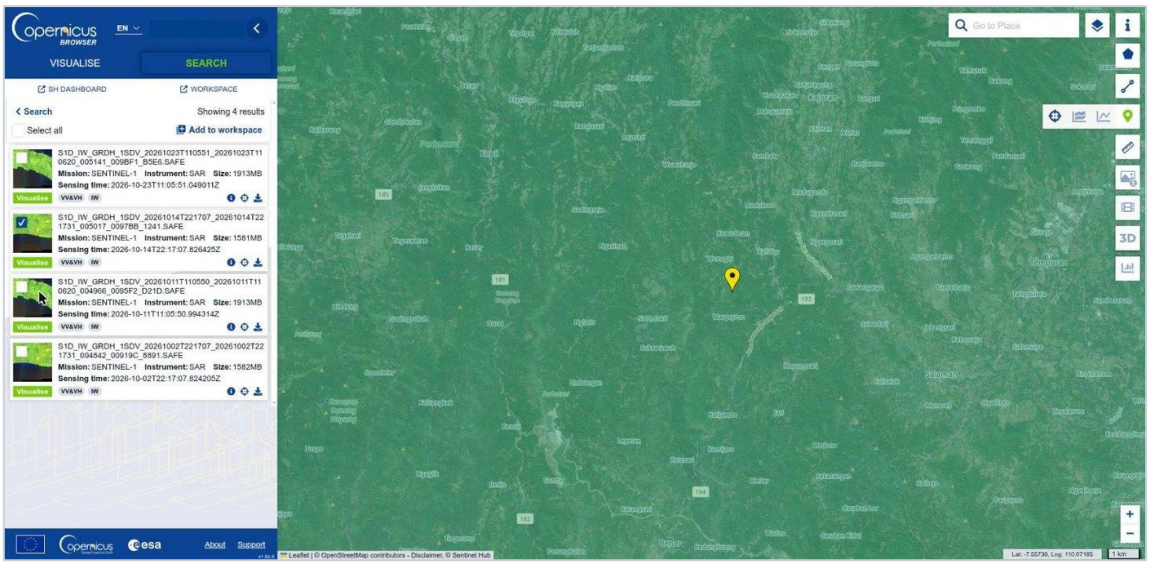
Tahap 4: Mengunduh Sentinel-1

Langkahnya sama dengan Sentinel-2, tetapi pada **Data Sources** centang **SENTINEL-1**, lalu **C-SAR**, lalu **Level-1 GRD**.



Gambar P0.6 Memilih produk Sentinel-1 Level-1 GRD

Sumber: Tangkapan layar Copernicus Browser



Gambar P0.7 Daftar hasil pencarian Sentinel-1

Sumber: Tangkapan layar Copernicus Browser; *Contains modified Copernicus Sentinel data*

Produknya berukuran 1,5–1,9 GB pada uji coba. GRD ini belum terkoreksi medan, sehingga masih perlu diolah, misalnya dengan SNAP, sebelum dipakai di wilayah berbukit. Karena itu data latihan memakai produk RTC yang sudah terkoreksi, yang lebih mudah diambil dengan Python pada tahap berikutnya.

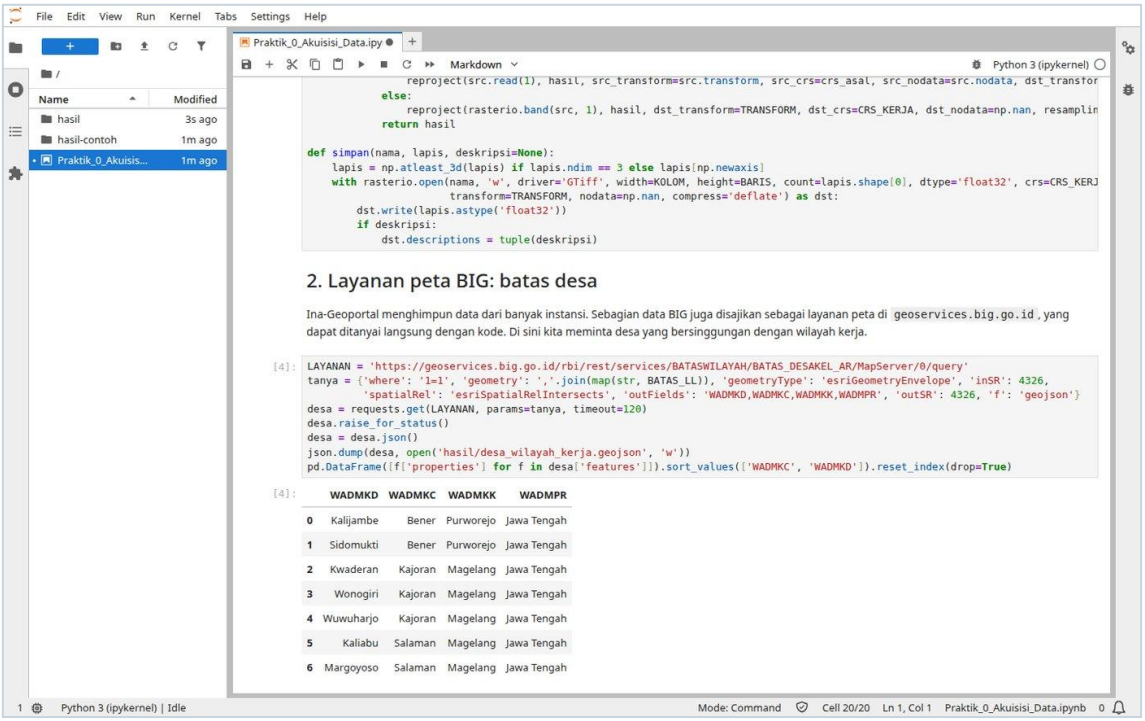
Titik periksa. Anda dapat menyebutkan nama lembar DEMNAS serta nama satu adegan Sentinel-2 dan Sentinel-1 untuk wilayah Anda. Tidak perlu mengunduhnya pada koneksi pelatihan.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tahap 5: Mengambil Data dengan Python

Portal cocok untuk sekali ambil, tetapi langkahnya sulit diulang persis. Notebook `data/praktik-0/Praktik_0_Akuisisi_Data.ipynb` mengambil data yang sama dengan kode. Hanya jendela wilayah kerja yang dibaca, sehingga Sentinel-2 dan Sentinel-1 tidak perlu diunduh utuh. Seluruh notebook selesai dalam sekitar 1 menit pada koneksi uji coba. Untuk wilayah lain, cukup ganti `BATAS` dan `TITIK` pada sel kedua.

1. Buka notebook di JupyterLab atau Colab, lalu jalankan sel berurutan.
2. **Batas desa.** Sel pertama bertanya ke layanan peta BIG, lalu menyimpan `hasil/desa_wilayah_kerja.geojson`. Pada uji coba, tujuh desa di Kabupaten Magelang dan Purworejo bersinggungan dengan wilayah kerja, karena kotak wilayah kerja lebih luas daripada Sub-DAS.



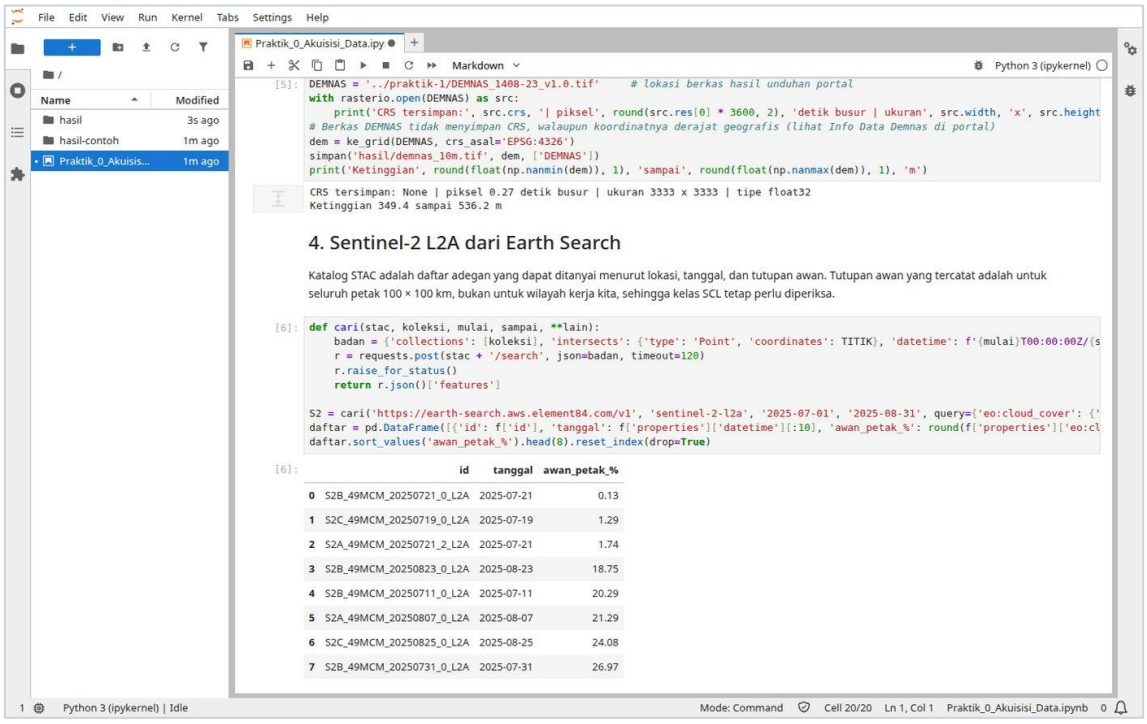
Gambar P0.8 Desa yang bersinggungan dengan wilayah kerja

Sumber: Tangkapan layar uji coba; data Badan Informasi Geospasial

3. **DEMNAS.** Bagian ini tidak mengunduh, karena unduhan portal memerlukan login, dan penyusun tidak menemukan cara unduh otomatis yang terbuka. Tuliskan lokasi berkas hasil Tahap 2 pada variabel `DEMNAS`. Notebook memberi tahu sistem koordinatnya dengan `crs_asal='EPSG:4326'`, lalu menyelaraskannya ke grid kerja.

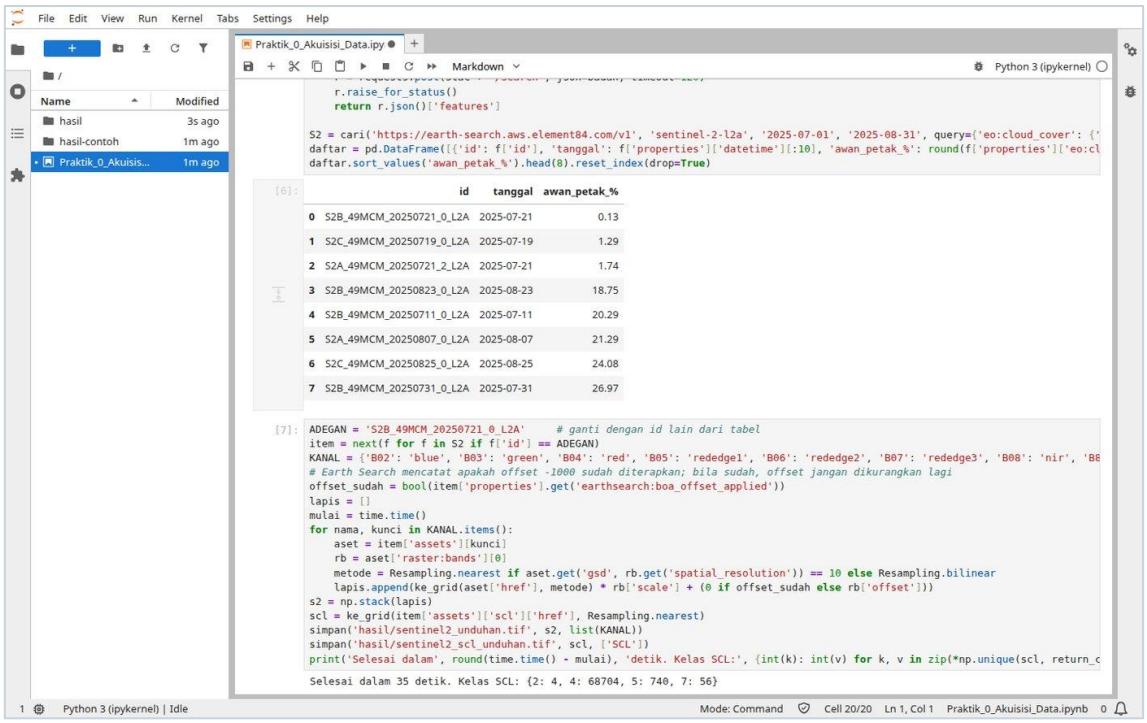
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

4. **Sentinel-2.** Notebook mencari di katalog STAC Earth Search dan menampilkan daftar adegan menurut tutupan awan. Pilih satu id pada variabel ADEGAN.



Gambar P0.9 Daftar adegan Sentinel-2 dari katalog STAC

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

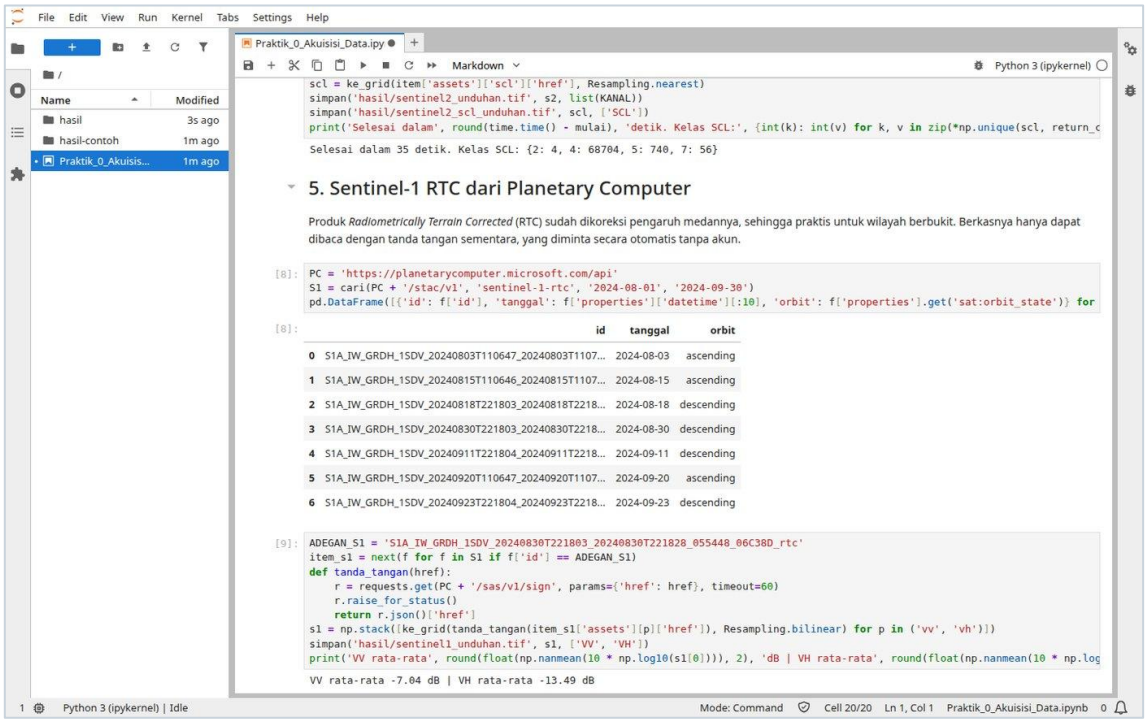


Gambar P0.10 Membaca sepuluh kanal Sentinel-2 dan SCL pada jendela wilayah kerja

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

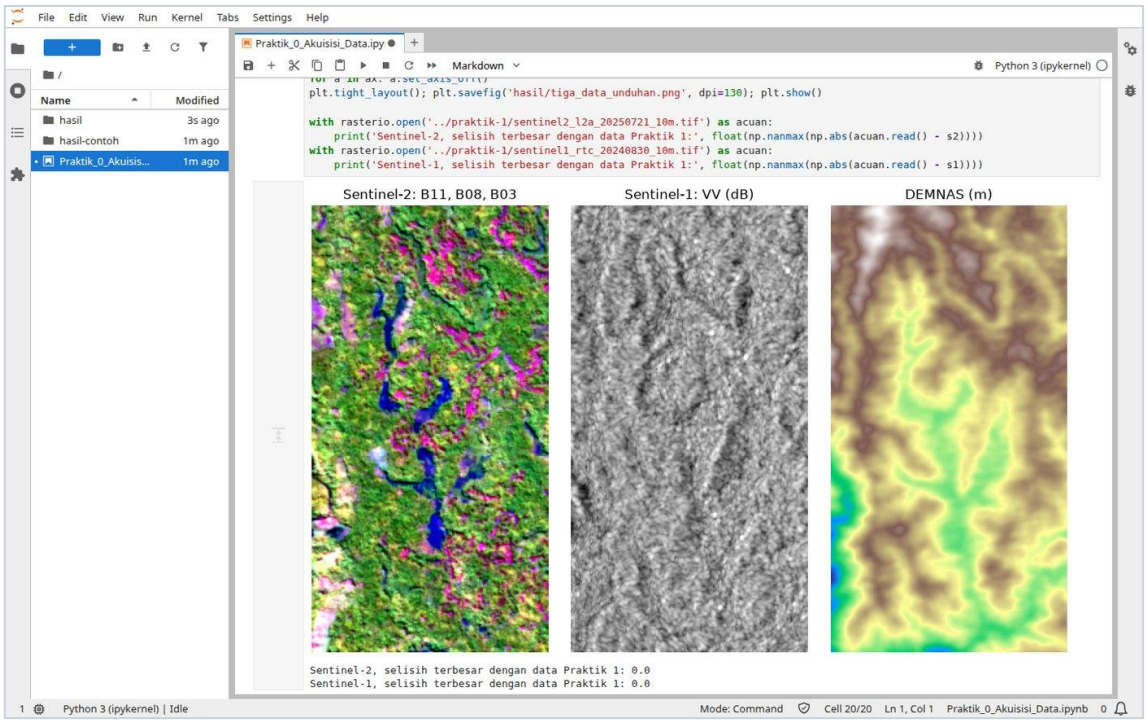
5. **Sentinel-1.** Notebook mencari produk RTC di Microsoft Planetary Computer, meminta tanda tangan sementara secara otomatis, lalu membaca VV dan VH.



Gambar P0.11 Daftar adegan dan pembacaan Sentinel-1 RTC

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

6. **Pencocokan.** Sel berikutnya menampilkan ketiga data dan mencocokkannya dengan berkas Praktik 1.

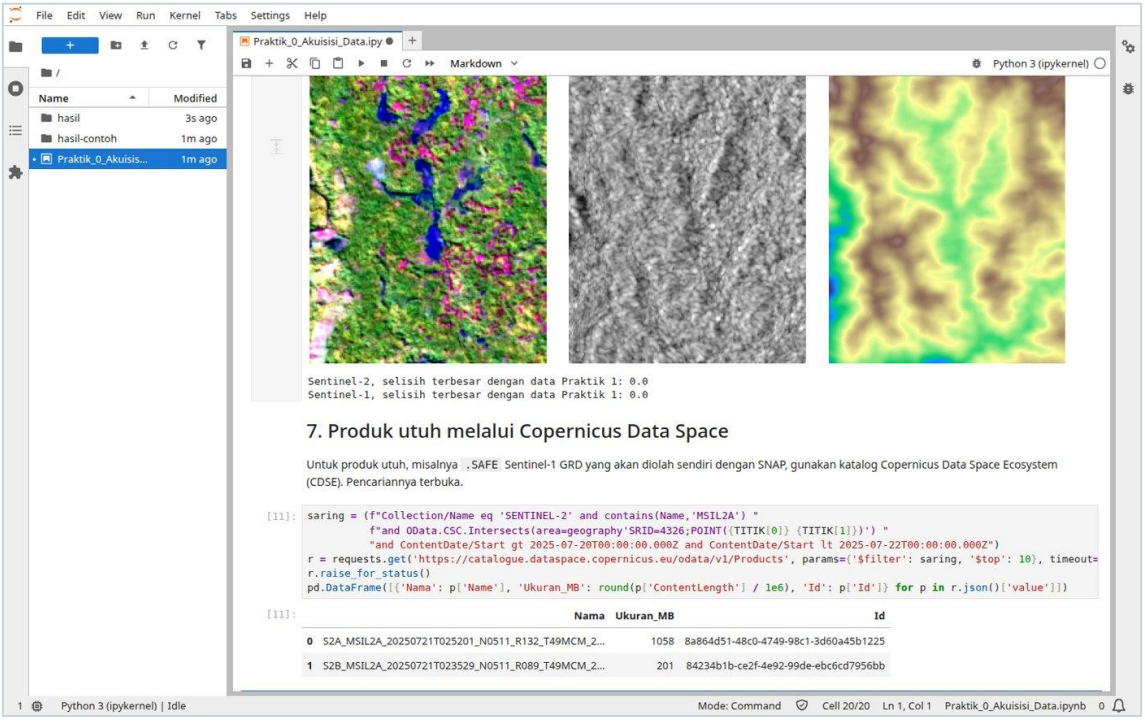


Gambar P0.12 Hasil unduhan dan pencocokannya dengan data Praktik 1

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024–2025*

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

7. **Produk utuh.** Sel terakhir mencari produk di katalog Copernicus Data Space tanpa akun. Kode untuk mengunduhnya ditulis sebagai contoh dan tidak dijalankan, karena memerlukan akun dan berukuran besar. Masukkan kata sandi hanya lewat `getpass` dan jangan menuliskannya di notebook.



Gambar P0.13 Pencarian produk utuh di Copernicus Data Space

Sumber: Tangkapan layar uji coba

Titik periksa. Sentinel-1 rata-rata VV −7,04 dB dan VH −13,49 dB, dan selisih terbesar dengan data Praktik 1 tercetak 0,0 untuk Sentinel-2 maupun Sentinel-1. Jika Anda mengganti adegan, selisih itu tentu tidak lagi nol, dan selnya perlu dilewati.

Cara Membaca Modul

Setiap modul dibuka dengan gambaran praktik dan data yang dipakai, lalu langkah kerja per tahap. Nama menu dan tombol dicetak tebal, misalnya **Raster > Analysis > Slope**. Sebagian besar alat juga dapat ditemukan dengan mengetikkan namanya pada kotak pencarian di kiri bawah QGIS atau pada **Processing Toolbox** (**Processing > Toolbox**).

Setiap tahap diakhiri titik periksa, yaitu hasil antara yang seharusnya sudah dimiliki sebelum melanjutkan. Angka pada titik periksa berasal dari uji coba, sehingga hasil Anda seharusnya sama atau sangat dekat jika langkahnya sama. Pengecualiannya adalah digitasi, karena setiap penafsir menarik batas yang berbeda. Hasil uji coba disajikan apa adanya, termasuk ketika model tidak bekerja sebaik yang diharapkan, karena membaca hasil secara jujur merupakan bagian dari kemampuan yang ingin dibangun.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Kurikulum Pembelajaran

Praktik 1. Multi-source Data Fusion

Pemandu: Johan. Perangkat: QGIS dan Jupyter Notebook. Rujukan teori: Modul 2.

Tujuan

Membekali peserta agar mampu menggabungkan Sentinel-1, Sentinel-2, DEMNAS, dan LiDAR pada satu grid, meningkatkan resolusi citra dengan pan-sharpening, dan menilai apakah hasilnya masih dapat dipercaya.

Kompetensi

Setelah mengikuti praktik ini, peserta memiliki kompetensi dalam:

1. Memeriksa watak data raster, termasuk data tanpa sistem koordinat
2. Menyelaraskan data beresolusi berbeda ke satu grid dengan metode yang sesuai
3. Menyusun dan memotong tumpukan data multisumber
4. Melakukan pan-sharpening Sentinel-2 dengan foto udara dan LiDAR
5. Menilai hasil penajaman dengan protokol Wald
6. Menggabungkan DEMNAS dan LiDAR

Ringkasan Studi

1. Deskripsi singkat
   - Peserta menyelaraskan empat sumber data dan memotongnya dengan `Batas_Bompon`
   - Peserta menajamkan Sentinel-2 dari 10 m ke 2,5 m
   - Peserta menguji hasilnya dan membandingkan DEMNAS dengan LiDAR
2. Hasil belajar
   - Peserta memahami perbedaan antara citra yang tampak tajam dan nilai yang benar
   - Peserta memiliki tumpukan 14 kanal dan citra hasil penajaman
3. Indikator hasil belajar
   - `stack_bompon_terpotong.tif` berukuran 152 × 322 piksel dengan 14 kanal
   - `s2_rgb_tajam_fu_2m5.tif` berukuran 608 × 1.288 piksel dengan piksel 2,5 m
   - Peserta dapat menjelaskan untuk apa citra hasil penajaman boleh dipakai
4. Materi pokok
   - Tingkat fusi data dan penyelarasan grid
   - Pan-sharpening: weighted Brovey dan high-pass filter
   - Protokol Wald, ERGAS, dan SAM
   - Fusi DEM berdasarkan panjang gelombang

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambaran Praktik

Praktik ini mengerjakan dua hal. Yang pertama adalah **penggabungan**: nilai dari sensor yang berbeda dibuat bertemu pada piksel yang sama. Yang kedua adalah **peningkatan resolusi**: detail dari data yang lebih rinci dipindahkan ke citra yang lebih kasar. Sentinel-2 merekam banyak kanal pada 10–20 m, sedangkan foto udara dan LiDAR Sub-DAS Bompon jauh lebih rinci tetapi hanya merekam warna dan bentuk medan. Pan-sharpening mencoba mengambil kelebihan keduanya.

Modul 2 membedakan fusi tingkat piksel, fitur, dan keputusan (Pohl & van Genderen, 1998). Hampir seluruh praktik ini berada pada tingkat piksel.

Ada satu pelajaran yang perlu dipegang sejak awal, karena ditemukan saat uji coba: **citra yang tampak paling tajam belum tentu paling benar.** Hasil penajaman yang paling memukau justru memiliki galat nilai paling besar. Karena itu, praktik ini tidak berhenti pada tampilan, tetapi juga mengujinya.

Data yang Dipakai

Semua berkas ada di folder `data/praktik-1/`. Buat folder baru `data/praktik-1/hasil/` untuk menyimpan keluaran Anda.

Tabel P1.1 Data Praktik 1

Berkas	Isi	Asal
`sentinel2_l2a_20250721_10m.tif`	Pantulan permukaan, 10 kanal, 21 Juli 2025	Sentinel-2 L2A, adegan `S2B_49MCM_20250721_0_L2A`, Earth Search
`sentinel1_rtc_20240830_10m.tif`	Hamburan balik VV dan VH, satuan linear, 30 Agustus 2024	Sentinel-1 RTC, adegan `S1A_IW_GRDH_1SDV_20240830T221803_20240830T221828_055448_06C38D_rtc`, Microsoft Planetary Computer
`DEMNAS_1408-23_v1.0.tif`	Ketinggian, 0,27 detik busur, satu lembar utuh	Ina-Geoportal, Badan Informasi Geospasial
`LiDAR_Kalijambe_Bompon_20222023.tif`	Model medan digital (DTM), 1 m	Data riset Bompon-Kalijambe, diambil 2022–2024
`foto_udara_rgb_1m.tif`	Foto udara RGB yang dirata-ratakan dari sekitar 5–8 cm ke 1 m	Data riset, menyertai data LiDAR
`Batas_Bompon.shp`	Batas Sub-DAS Bompon	Data riset

Sumber: Data proyek; *Contains modified Copernicus Sentinel data 2024–2025*

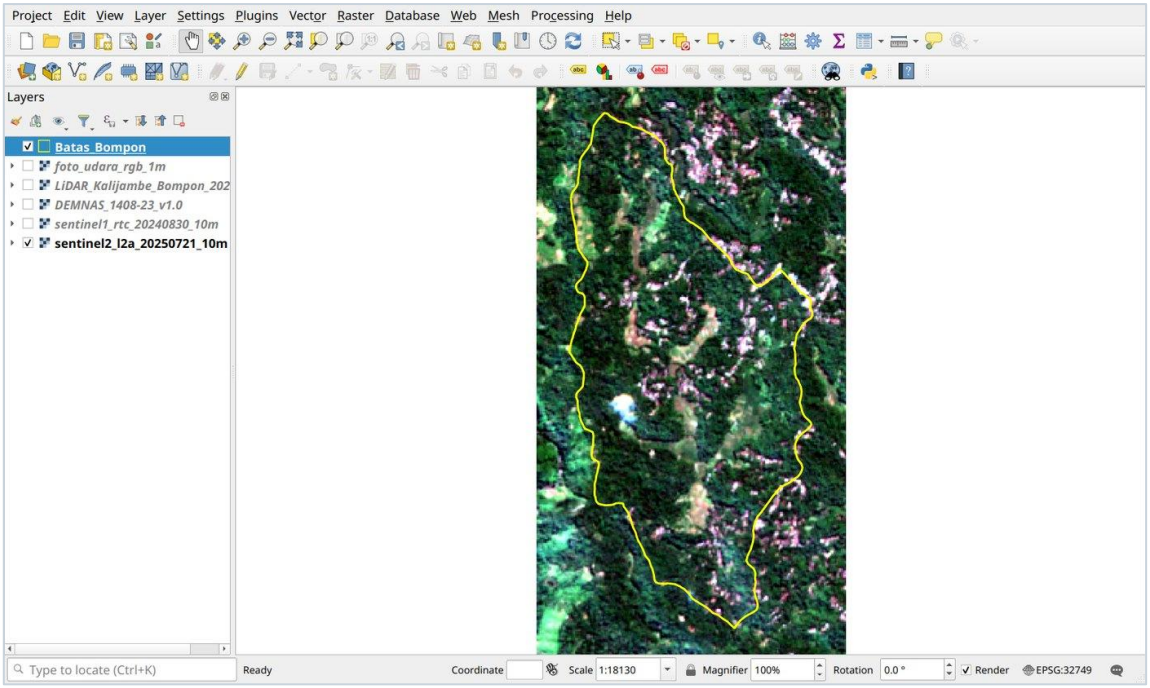
LiDAR dan foto udara diambil pada kurun 2022–2024. Tanggal pasti setiap pemotretan tidak tercantum pada data.

Tahap 1: Memuat dan Mengenali Data

1. Buka QGIS, pilih **Project > New**, lalu simpan melalui **Project > Save As** ke `hasil/praktik1.qgz`.
2. Pilih **Layer > Add Layer > Add Raster Layer**, lalu muat kelima berkas `.tif`. Muat `Batas_Bompon.shp` melalui **Layer > Add Layer > Add Vector Layer**.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

3. **DEMNAS tidak memiliki CRS.** Klik kanan layer DEMNAS, pilih **Layer CRS > Set Layer CRS**, lalu pilih `EPSG:4326`. Pengaturan ini hanya berlaku di proyek, sehingga pada tahap 2 CRS asalnya perlu disebutkan lagi.
4. Pastikan CRS proyek di pojok kanan bawah adalah `EPSG:32749`. Atur `Batas_Bompon` tanpa isian dengan garis kuning, lalu klik kanan dan pilih **Zoom to Layer**.

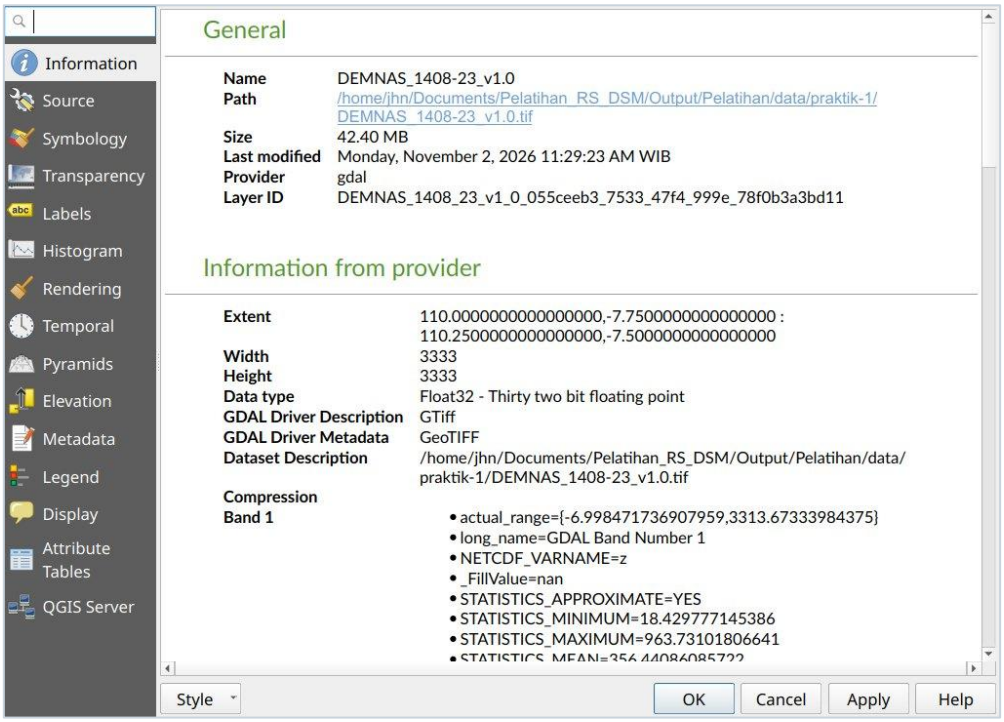


Gambar P1.1 Data dimuat di QGIS, dengan Sentinel-2 warna asli dan batas Sub-DAS

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

5. Buka tab **Information** pada setiap layer dan cocokkan dengan Tabel P1.2.



Gambar P1.2 Tab Information pada DEMNAS

Sumber: Tangkapan layar uji coba

Tabel P1.2 Hasil Pemeriksaan Data pada Uji Coba

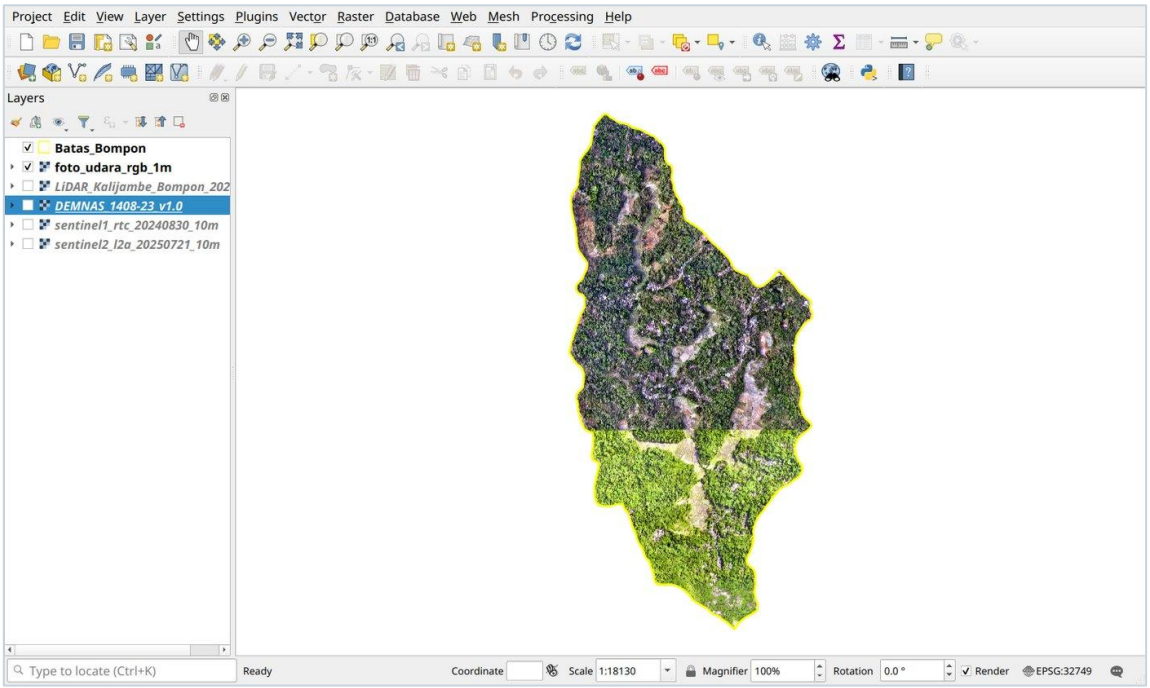
Layer	Kolom × baris	Ukuran piksel	Kanal	Satuan nilai
Sentinel-2	192 × 362	10 m	10	Pantulan, 0 sampai 1
Sentinel-1	192 × 362	10 m	2	Hamburan balik linear
DEMNAS	3.333 × 3.333	0,27 detik busur, sekitar 8 m	1	Meter, datum EGM2008
LiDAR	1.761 × 5.005	1 m	1	Meter, datum belum tercantum
Foto udara	1.520 × 3.220	1 m	3	0 sampai 255

Sumber: Hasil uji coba; datum DEMNAS dari Badan Informasi Geospasial (2026)

CRS LiDAR tampil tanpa kode EPSG karena berkasnya memakai definisi ESRI untuk UTM zona 49S. Isinya tetap benar. Urutan kanal Sentinel-2 perlu diingat: kanal 1 B02 (biru), 2 B03 (hijau), 3 B04 (merah), 4 B05, 5 B06, 6 B07, 7 B08 (inframerah dekat), 8 B8A, 9 B11, dan 10 B12. Kanal B05, B06, B07, B8A, B11, dan B12 aslinya 20 m dan sudah di-*resample* ke 10 m saat data disiapkan.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

6. Tampilkan foto udara. Perhatikan garis melintang di sekitar koordinat Y 9164437.



Gambar P1.3 Foto udara yang tersusun dari dua pemotretan dengan warna berbeda

Sumber: Tangkapan layar uji coba; foto udara data riset

Bagian utara dan selatan berasal dari dua berkas foto udara yang warnanya berbeda. Sambungan ini akan ikut terbawa ke hasil penajaman.

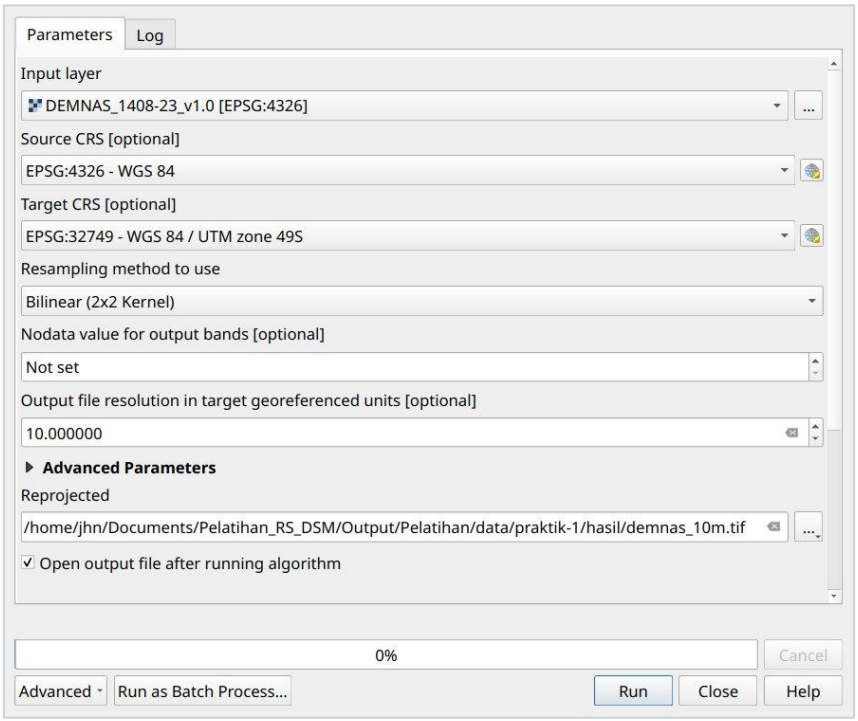
Titik periksa. Semua layer berimpit dengan batas Sub-DAS, termasuk DEMNAS setelah CRS-nya ditetapkan.

Tahap 2: Menyelaraskan ke Grid 10 m

Sentinel-2 dan Sentinel-1 sudah berada pada grid yang sama. DEMNAS dan LiDAR perlu dibawa ke grid itu, tetapi dengan metode yang berbeda, karena arah perubahan resolusinya berbeda.

1. Pilih **Raster > Projections > Warp (Reproject)**, lalu isi parameternya untuk DEMNAS:
   - **Input layer**: `DEMNAS_1408-23_v1.0`;
   - **Source CRS**: `EPSG:4326`;
   - **Target CRS**: `EPSG:32749`;
   - **Resampling method to use**: *Bilinear (2x2 Kernel)*;
   - **Output file resolution**: `10`;
   - buka **Advanced Parameters**, isi **Georeferenced extents of output file to be created** dengan `396060,397980,9162990,9166610 [EPSG:32749]`, lalu pilih **Output data type** *Float32*;
   - **Reprojected**: `hasil/demnas_10m.tif`.

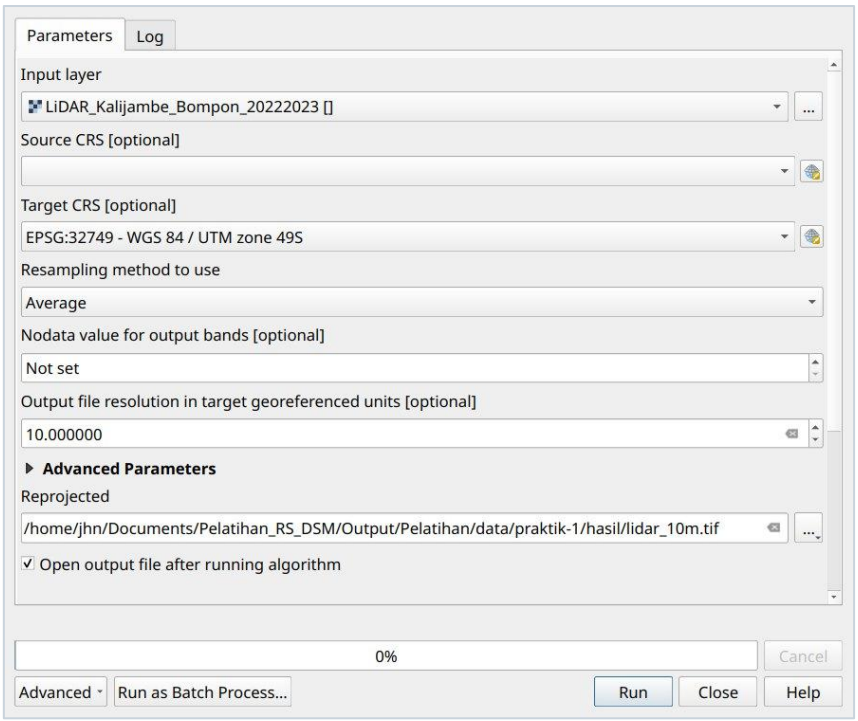
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P1.4 Dialog Warp untuk DEMNAS

Sumber: Tangkapan layar uji coba

2. Ulangi untuk LiDAR, tetapi kosongkan **Source CRS**, pilih **Resampling** *Average*, lalu simpan ke `hasil/lidar_10m.tif`.



Gambar P1.5 Dialog Warp untuk LiDAR dengan metode *Average*

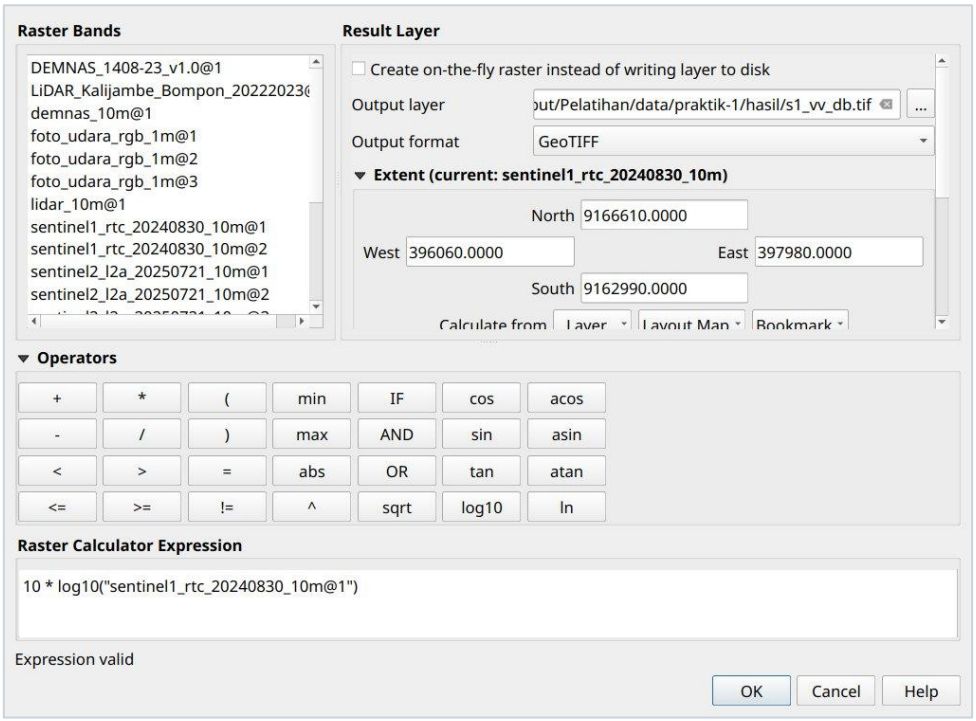
Sumber: Tangkapan layar uji coba

LiDAR 1 m dikasarkan ke 10 m, sehingga satu piksel baru mewakili 100 piksel lama, dan rata-rata adalah cara yang wajar. Metode bilinear hanya akan mengambil sedikit piksel di sekitar pusat dan mengabaikan sisanya.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

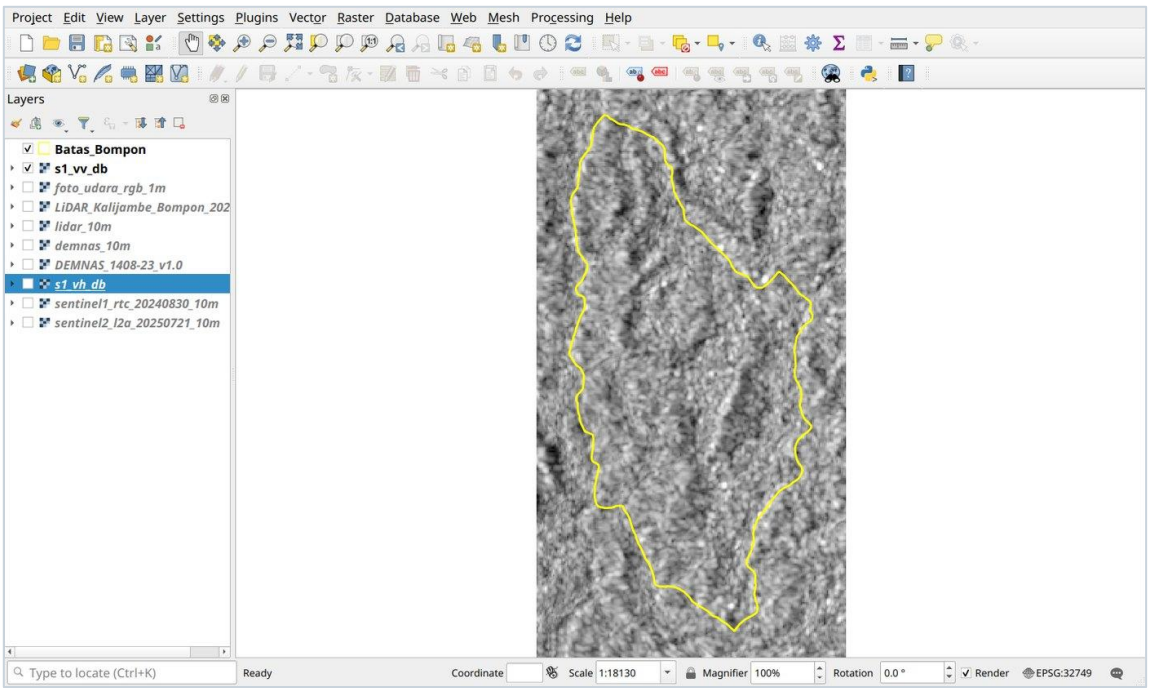
3. Pilih **Raster > Raster Calculator** untuk mengubah Sentinel-1 ke desibel. Simpan ke `hasil/s1_vv_db.tif`, lalu ulangi dengan `@2` ke `hasil/s1_vh_db.tif`.

```
10 * log10("sentinel1_rtc_20240830_10m@1")
```



Gambar P1.6 Mengubah hamburan balik VV ke desibel

Sumber: Tangkapan layar uji coba



Gambar P1.7 Sentinel-1 VV dalam desibel

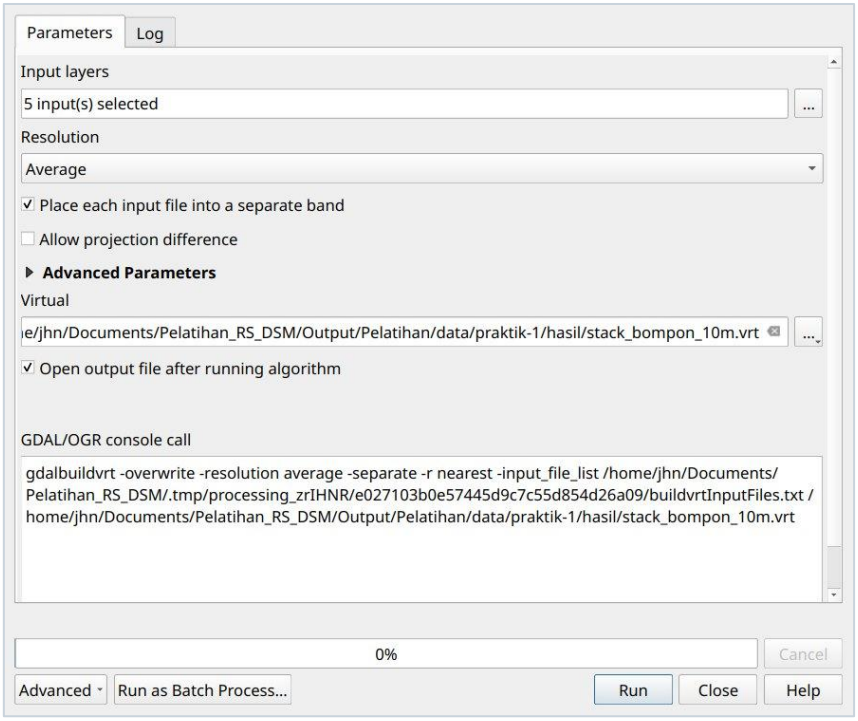
Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

Titik periksa. `demnas_10m` dan `lidar_10m` berukuran 192 × 362 piksel. VV bernilai −23,32 sampai 7,08 dB dengan rata-rata −7,04 dB, sedangkan VH −26,30 sampai −1,66 dB dengan rata-rata −13,49 dB.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tahap 3: Menyusun dan Memotong Tumpukan Data

1. Pilih **Raster > Miscellaneous > Build Virtual Raster**. Pada **Input layers**, centang dan urutkan `sentinel2_l2a_20250721_10m`, `s1_vv_db`, `s1_vh_db`, `demnas_10m`, `lidar_10m`.
2. Centang **Place each input file into a separate band**, simpan ke `hasil/stack_bompon_10m.vrt`, lalu klik **Run**.

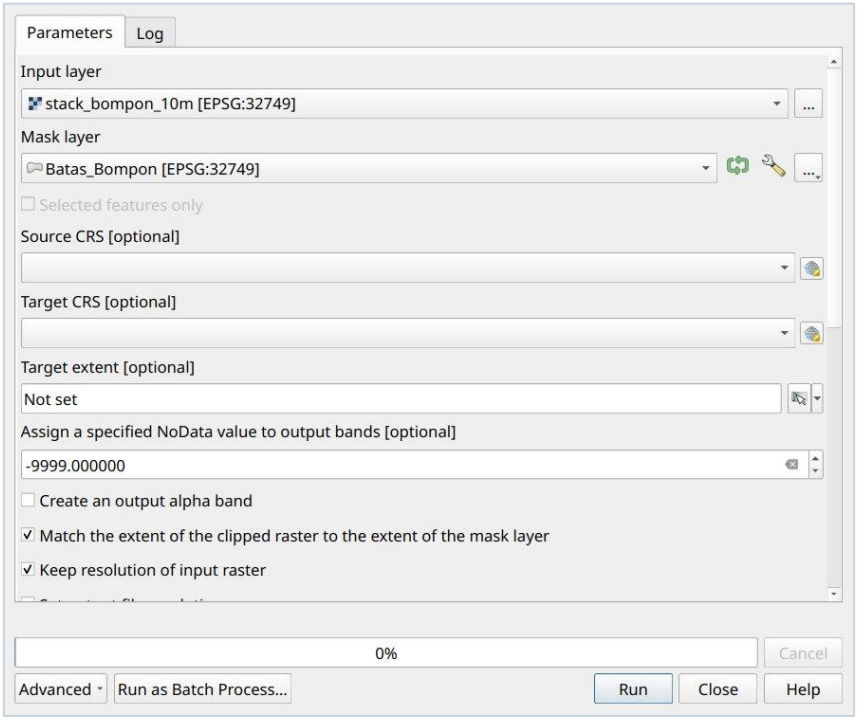


Gambar P1.8 Dialog Build Virtual Raster

Sumber: Tangkapan layar uji coba

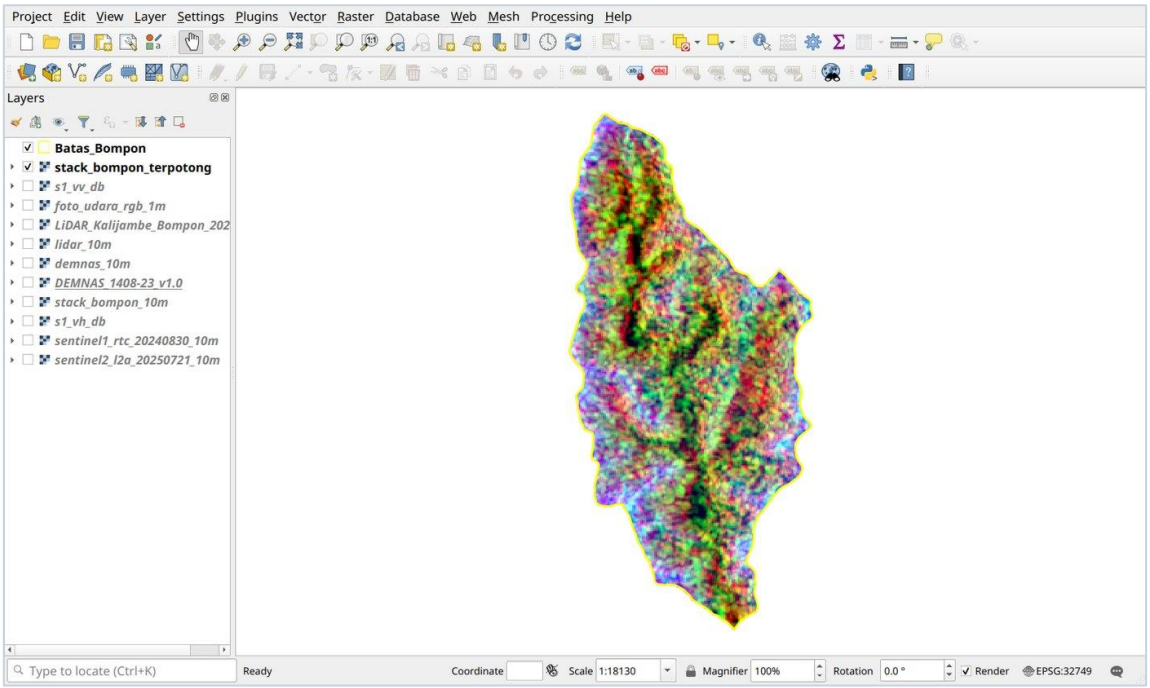
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

3. Pilih **Raster > Extraction > Clip Raster by Mask Layer**. Isi **Input layer** `stack_bompon_10m`, **Mask layer** `Batas_Bompon`, **Assign a specified NoData value** `-9999`, dan **Output data type** *Float32*. Pastikan **Match the extent** dan **Keep resolution** tercentang, lalu simpan ke `hasil/stack_bompon_terpotong.tif`.



Gambar P1.9 Memotong tumpukan dengan Batas_Bompon
Sumber: Tangkapan layar uji coba

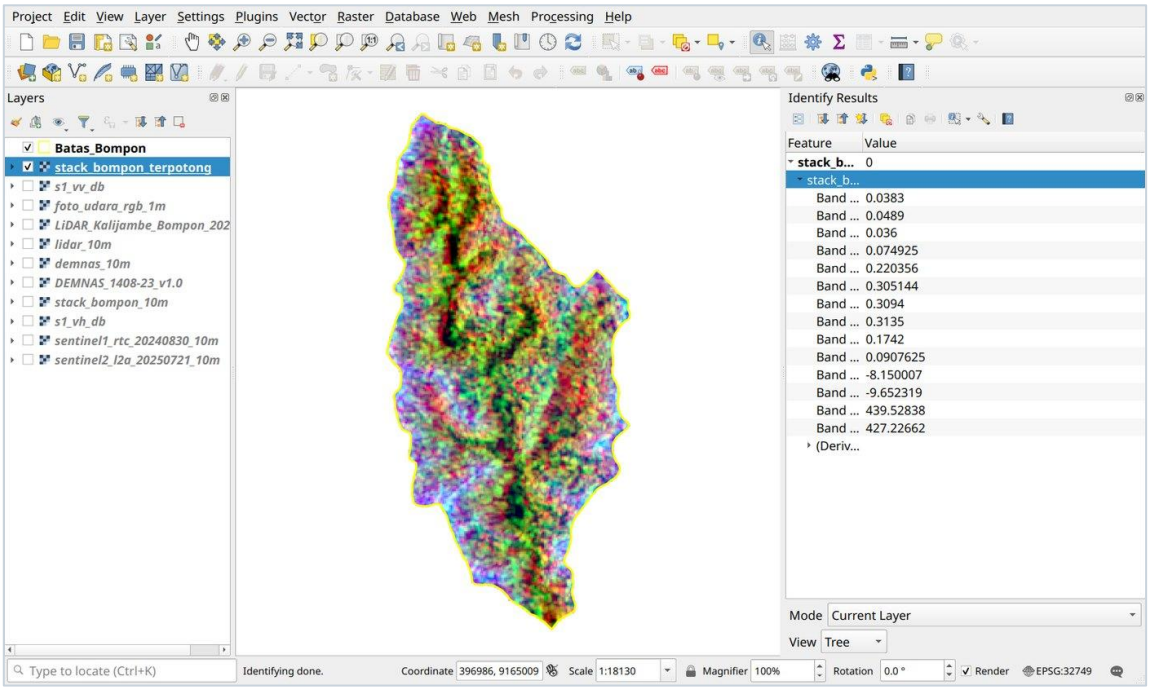
4. Tampilkan dengan **Multiband color**: merah kanal 7 (inframerah dekat), hijau kanal 12 (VH), biru kanal 14 (LiDAR).



Gambar P1.10 Komposit lintas sensor dari Sentinel-2, Sentinel-1, dan LiDAR
Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024–2025*

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

5. Klik satu piksel dengan **Identify Features**.



Gambar P1.11 Identify Features menampilkan 14 nilai dari empat sumber

Sumber: Tangkapan layar uji coba

Pada koordinat 396990, 9165005, misalnya, B04 bernilai 0,0321, B08 0,3568, VV −3,95 dB, VH −9,07 dB, DEMNAS 439,23 m, dan LiDAR 427,19 m. Satu baris angka inilah bentuk paling dasar dari data pemodelan. Perhatikan pula bahwa dua sumber ketinggian berselisih 12 m pada piksel yang sama.

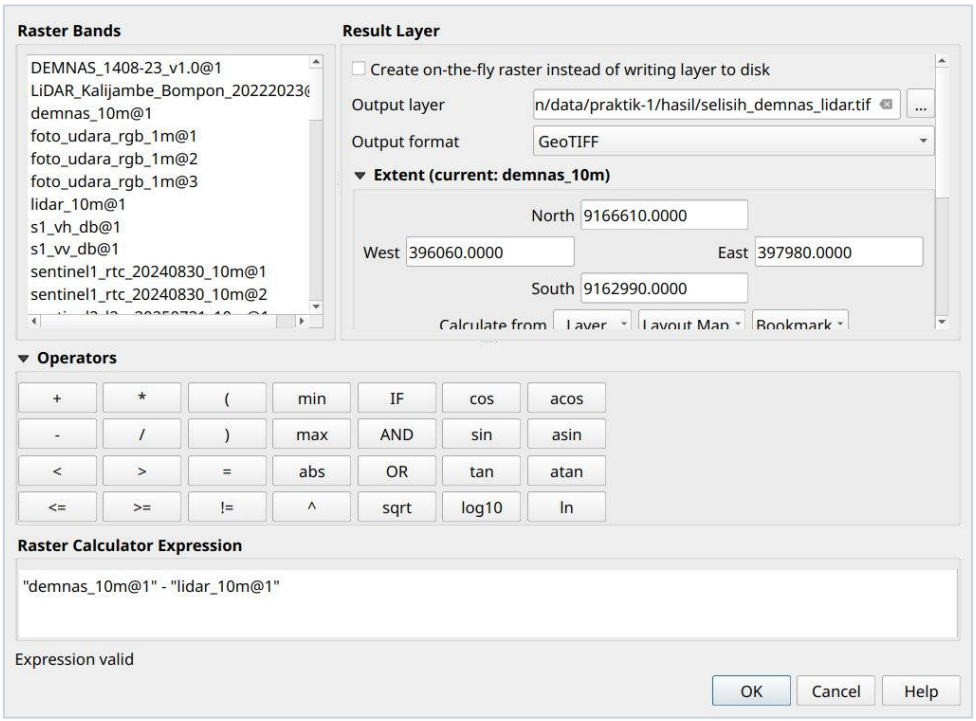
Titik periksa. `stack_bompon_terpotong.tif` berukuran 152 × 322 piksel dengan 14 kanal.

Tahap 4: Membandingkan DEMNAS dan LiDAR

1. Hitung selisihnya dengan Raster Calculator, lalu simpan ke `hasil/selisih_demnas_lidar.tif`. Potong hasilnya dengan `Batas_Bompon` seperti tahap 3.

```
"demnas_10m@1" - "lidar_10m@1"
```

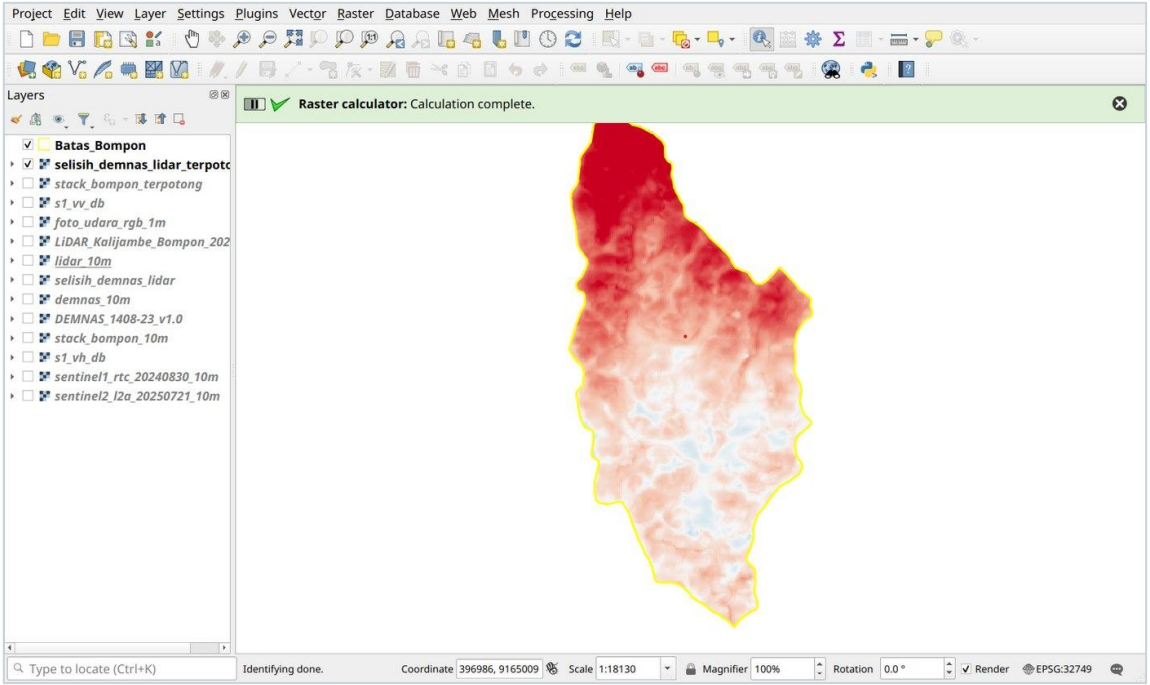

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P1.12 Menghitung selisih DEMNAS dan LiDAR

Sumber: Tangkapan layar uji coba

2. Tampilkan sebagai **Singleband pseudocolor** dengan palet merah-biru, rentang −40 sampai 40.



Gambar P1.13 Selisih DEMNAS dan LiDAR, makin merah berarti DEMNAS makin tinggi

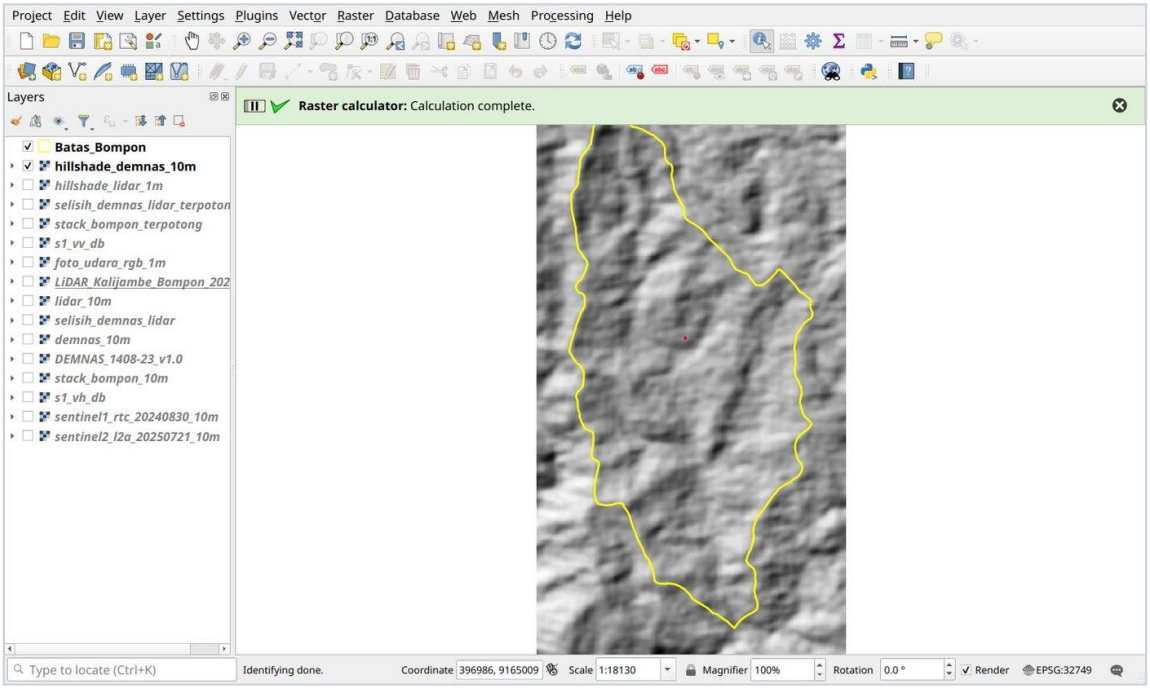
Sumber: Tangkapan layar uji coba; data Badan Informasi Geospasial dan data riset

Selisih rata-rata 15,85 m, dan polanya tidak acak. Di bagian selatan selisihnya sekitar 3–5 m, sedangkan di bagian utara naik mulus sampai sekitar 37 m. Tajuk tidak dapat menjelaskan pola seluas ini. Copernicus DEM, yang tidak dipakai pada praktik ini, berselisih rata-rata hanya 2 m dengan DEMNAS, sehingga yang paling mungkin miring adalah DTM LiDAR. Penyebabnya belum dapat dipastikan dari data ini.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

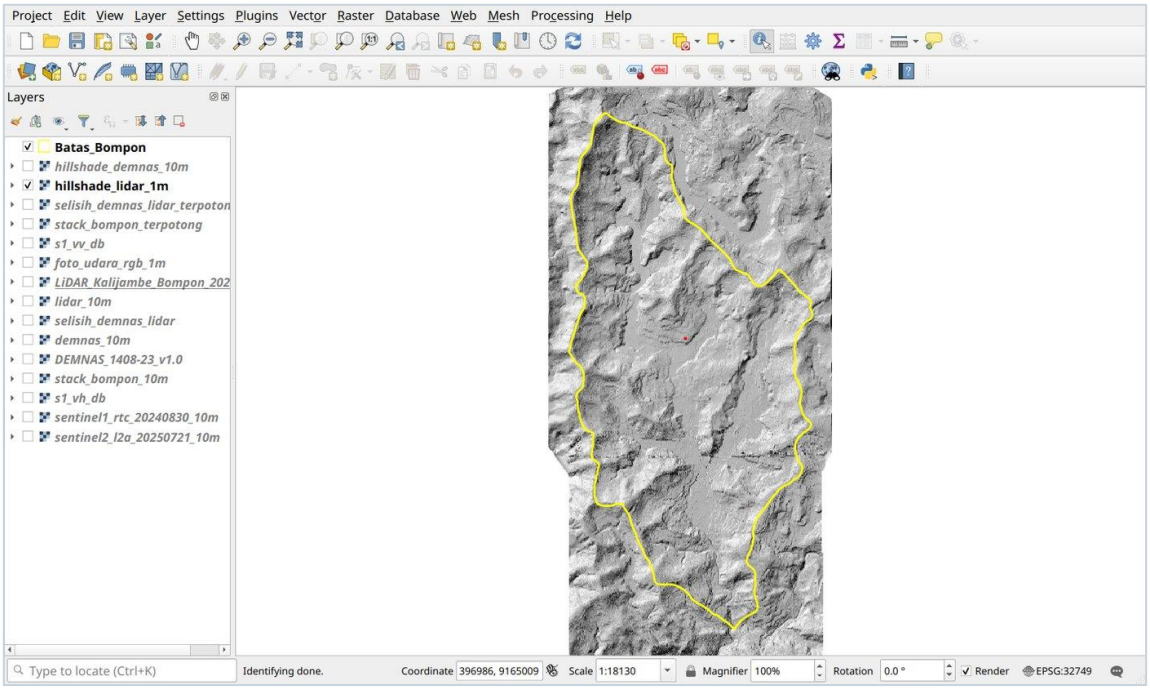
Kemiringan ini juga berpengaruh pada pengolahan lanjutan. Berkas `lidar_fill` pada data riset, yaitu hasil pengisian cekungan dari DTM ini, menaikkan bagian utara sampai 41 m dan membuat 54 ha lahan menjadi datar sempurna. Karena itu, praktik ini memakai DTM sebelum pengisian. Bagi pekerjaan yang memerlukan ketinggian mutlak atau arah aliran, jangan langsung memakai salah satunya sebelum masalah ini diperiksa.

3. Buat bayangan medan dari keduanya dengan **Raster > Analysis > Hillshade**, simpan ke `hasil/hillshade_demnas_10m.tif` dan `hasil/hillshade_lidar_1m.tif`.



Gambar P1.14 Bayangan medan DEMNAS

Sumber: Tangkapan layar uji coba; data Badan Informasi Geospasial



Gambar P1.15 Bayangan medan LiDAR 1 m

Sumber: Tangkapan layar uji coba; data riset

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

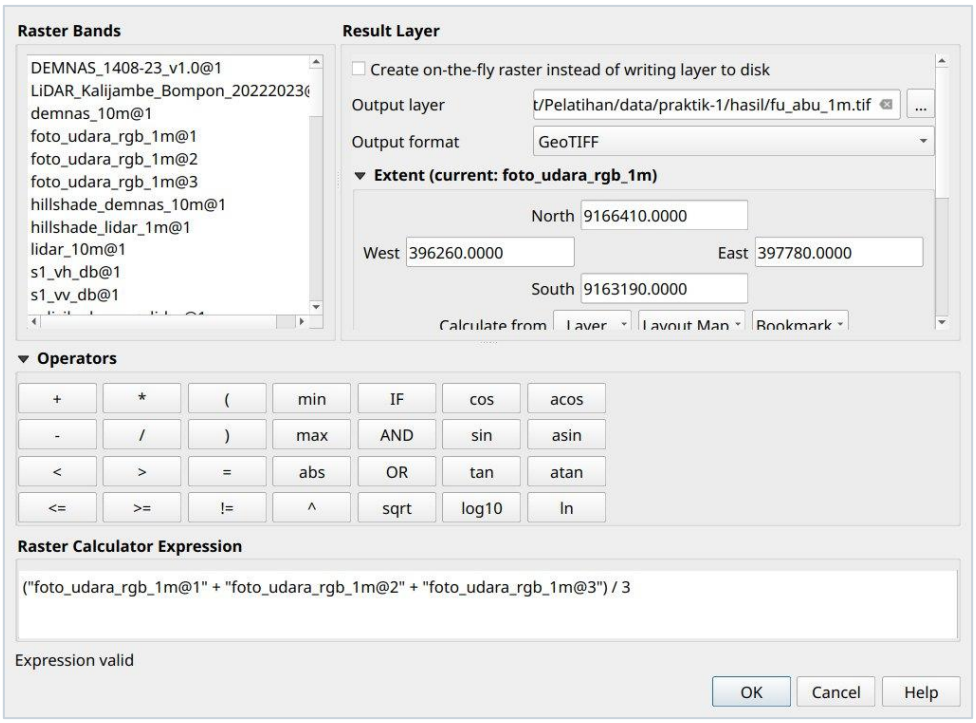
Inilah sebabnya LiDAR tetap sangat berharga: ketinggian mutlaknya bermasalah, tetapi kerincian bentuk medannya jauh melampaui DEMNAS. Teras, alur, dan tekuk lereng yang penting bagi Praktik 2 terlihat jelas.

Tahap 5: Menyiapkan Data Detail dari Foto Udara

Pan-sharpening memerlukan satu kanal rinci, yang disebut pan. Sentinel-2 tidak memiliki kanal pankromatik, sehingga pan diambil dari foto udara. Rasio resolusi yang dipakai 1:4, dari 10 m ke 2,5 m, karena pada rasio yang jauh lebih besar hasilnya hampir seluruhnya berasal dari pan.

1. Ubah foto udara menjadi kelabu dengan Raster Calculator, lalu simpan ke `hasil/fu_abu_1m.tif`.

```
("foto_udara_rgb_1m@1" + "foto_udara_rgb_1m@2" + "foto_udara_rgb_1m@3") / 3
```

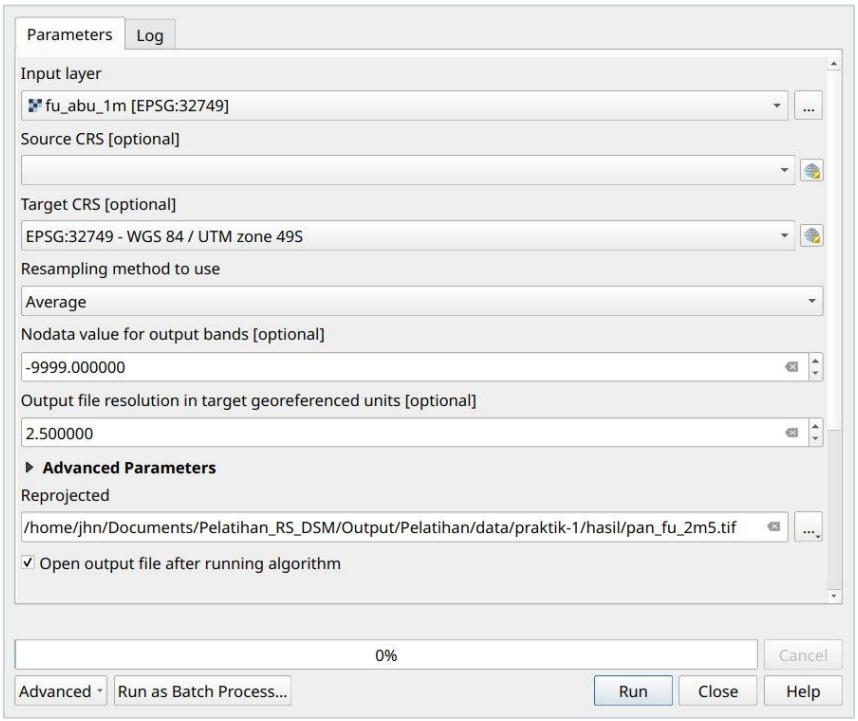


Gambar P1.16 Membuat kanal kelabu dari foto udara

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

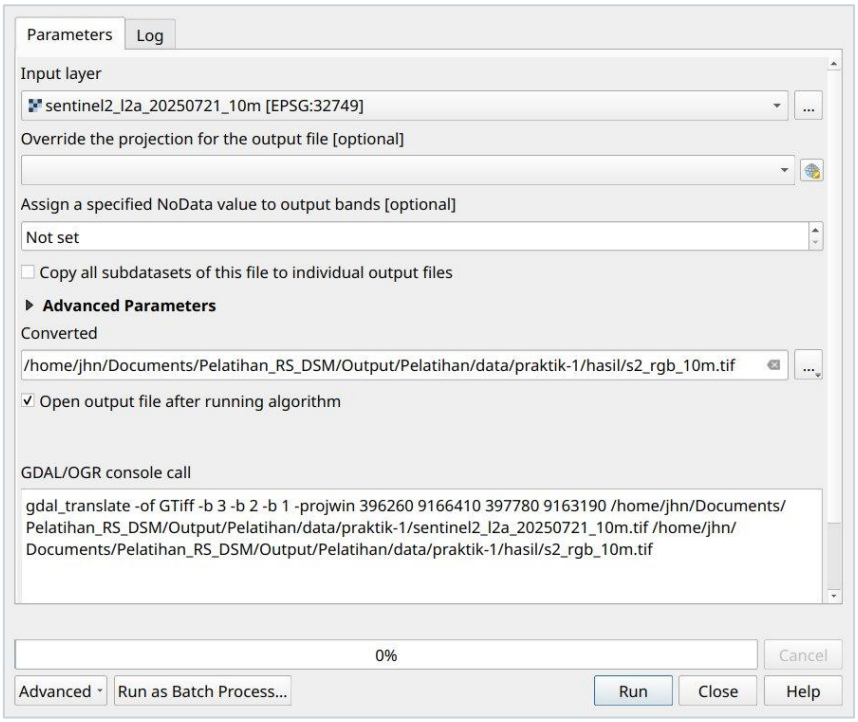
2. Bawa ke grid 2,5 m dengan Warp: **Resampling** *Average*, **Nodata** `-9999`, **Output file resolution** `2.5`, **extents** `396260,397780,9163190,9166410 [EPSG:32749]`, lalu simpan ke `hasil/pan_fu_2m5.tif`.



Gambar P1.17 Membawa pan ke grid 2,5 m

Sumber: Tangkapan layar uji coba

3. Ambil kanal merah, hijau, dan biru Sentinel-2 pada wilayah yang sama dengan **Raster > Conversion > Translate**. Pada **Additional command-line parameters** tulis `-b 3 -b 2 -b 1 -projwin 396260 9166410 397780 9163190`, lalu simpan ke `hasil/s2_rgb_10m.tif`.



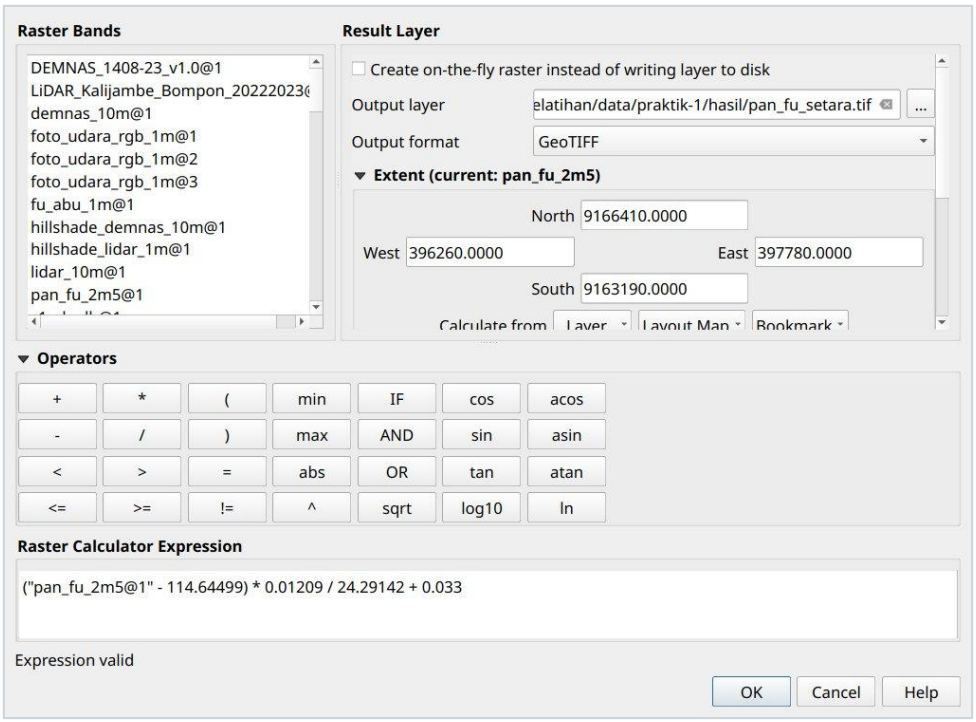
Gambar P1.18 Mengambil tiga kanal tampak Sentinel-2

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

4. **Setarakan skala pan.** Foto udara bernilai 0–255, sedangkan pantulan 0–0,2. Alat pan-sharpening tidak menyetarakannya, sehingga tanpa langkah ini nilai hasilnya ikut menjadi ratusan. Hitung rata-rata dan simpangan baku dengan **Raster layer statistics** pada dua layer berikut: pan yang dikasarkan ke 10 m di dalam batas, dan intensitas `("s2_rgb_10m@1" + "s2_rgb_10m@2" + "s2_rgb_10m@3") / 3` yang dipotong dengan `Batas_Bompon`. Lalu terapkan rumus ini dan simpan ke `hasil/pan_fu_setara.tif`.

```
("pan_fu_2m5@1" - 114.64499) * 0.01209 / 24.29142 + 0.033
```



Gambar P1.19 Menyetarakan pan dengan rata-rata dan simpangan baku intensitas Sentinel-2

Sumber: Tangkapan layar uji coba

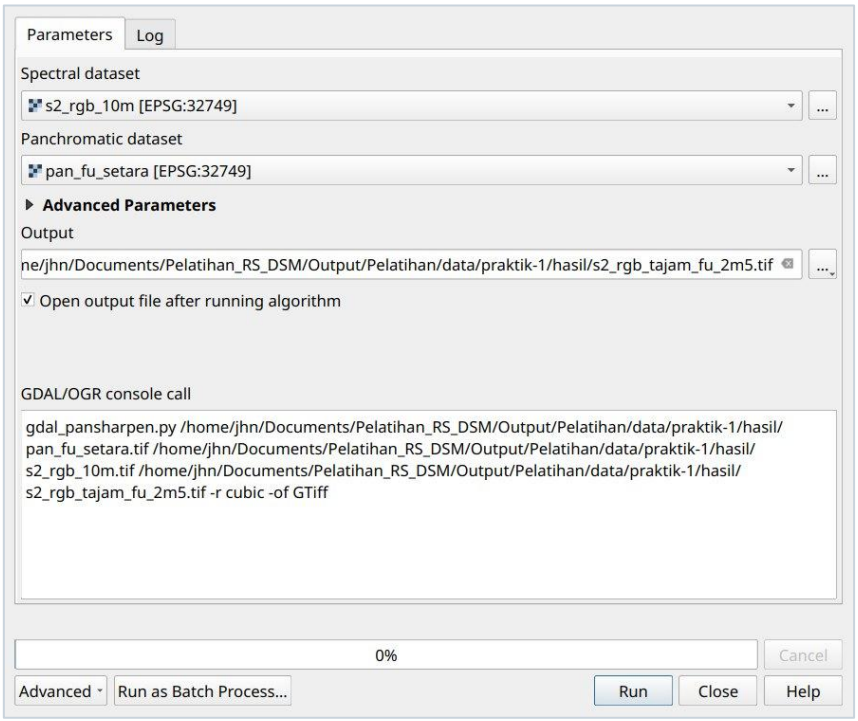
Titik periksa. Pan rata-rata 114,64 dengan simpangan baku 24,29, sedangkan intensitas rata-rata 0,033 dengan simpangan baku 0,01209.

Tahap 6: Pan-sharpening Sentinel-2

1. Buka **Processing > Toolbox**, ketik `pansharpening` pada kotak pencarian, lalu klik dua kali alat **Pansharpening** dari kelompok GDAL.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. Isi **Spectral dataset** `s2_rgb_10m` dan **Panchromatic dataset** `pan_fu_setara`, buka **Advanced Parameters**, pilih **Resampling algorithm** *Cubic*, lalu simpan ke `hasil/s2_rgb_tajam_fu_2m5.tif`.



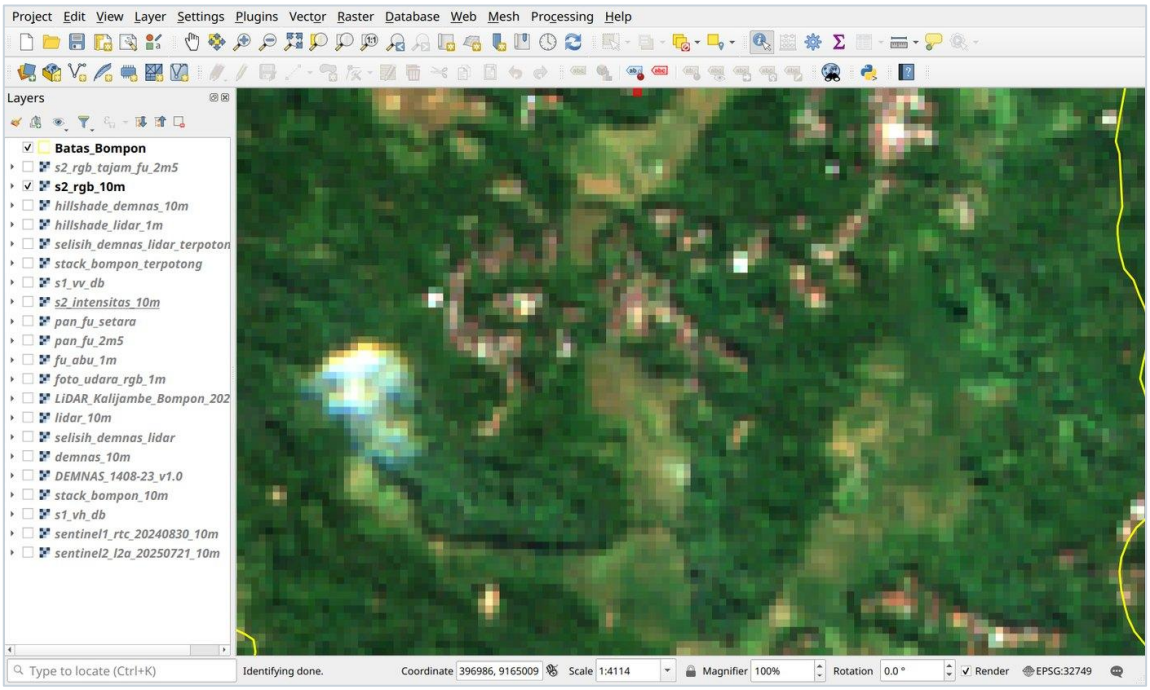
Gambar P1.20 Dialog Pansharpening

Sumber: Tangkapan layar uji coba

Alat ini memakai metode *weighted Brovey*. Setiap kanal di-*resample* ke 2,5 m, lalu dikalikan rasio pan terhadap rata-rata kanal. Jadi pan menentukan terang dan gelapnya, sedangkan Sentinel-2 menentukan perbandingan warnanya.

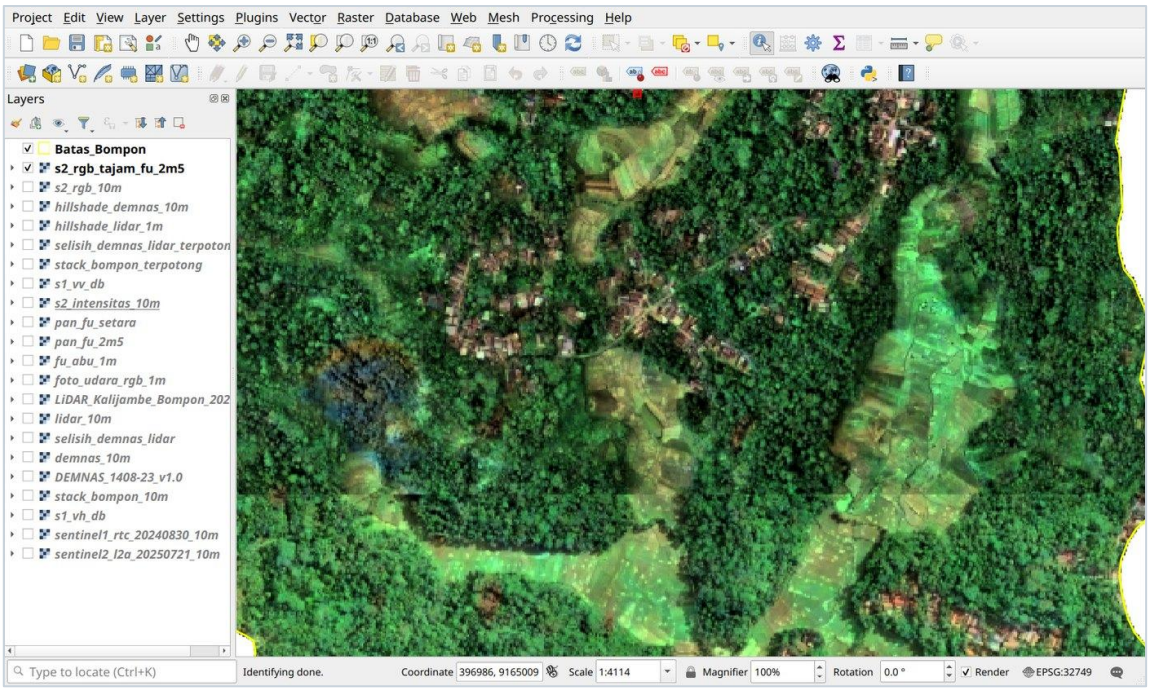
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

3. Tampilkan citra asli dan hasilnya dengan **Multiband color**, kanal 1, 2, 3, rentang 0,005–0,11 untuk semua kanal, lalu perbesar ke sekitar 396660–397460 dan 9164210–9165010.



Gambar P1.21 Sentinel-2 asli, 10 m

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*



Gambar P1.22 Sentinel-2 setelah ditajamkan dengan foto udara, 2,5 m

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

Rumah, tajuk, dan pematang sawah kini dapat dibedakan. Perubahan ini nyata bagi mata.

Titik periksa. `s2_rgb_tajam_fu_2m5.tif` berukuran 608 × 1.288 piksel dengan piksel 2,5 m dan 3 kanal.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

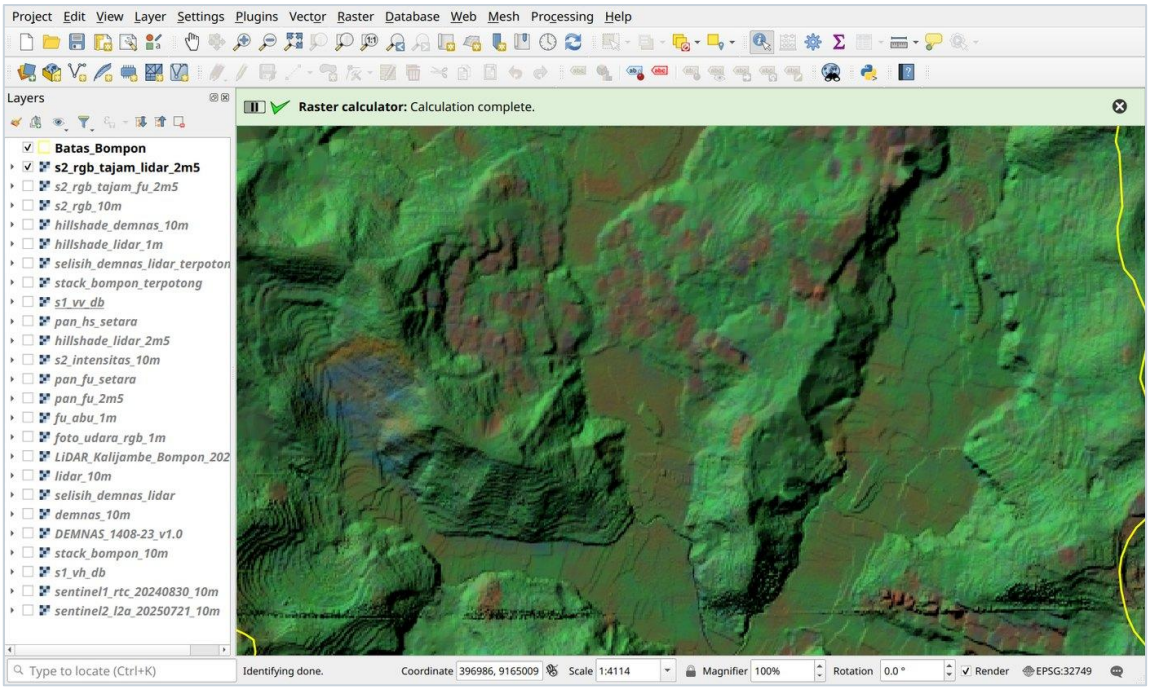
Tahap 7: Bagaimana dengan LiDAR?

DEM tidak dapat langsung dipakai sebagai pan, karena ketinggian tidak berhubungan dengan terang-gelapnya citra. Yang paling dekat adalah bayangan medannya.

1. Bawa `hillshade_lidar_1m` ke grid 2,5 m seperti langkah pan, lalu simpan ke `hasil/hillshade_lidar_2m5.tif`.
2. Setarakan seperti tahap 5 dengan statistik bayangan medan, yaitu rata-rata 169,98028 dan simpangan baku 38,5938, lalu simpan ke `hasil/pan_hs_setara.tif`.

```
("hillshade_lidar_2m5@1" - 169.98028) * 0.01209 / 38.5938 + 0.033
```

3. Jalankan Pansharpening dengan pan tersebut, lalu simpan ke `hasil/s2_rgb_tajam_lidar_2m5.tif`.

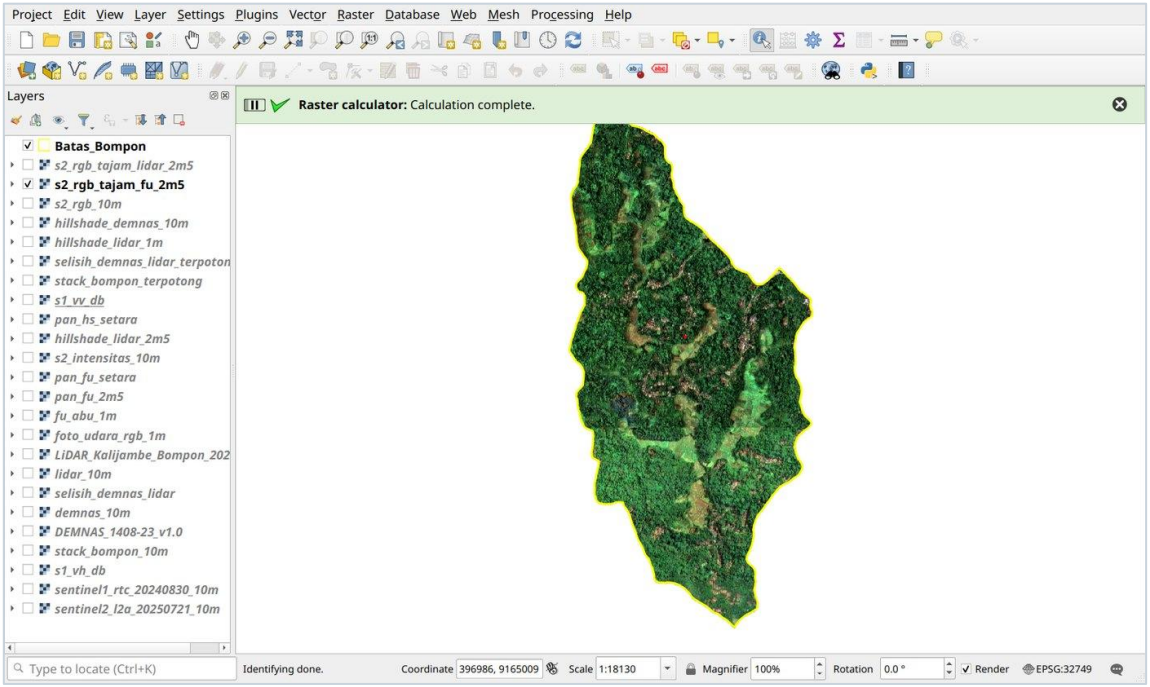


Gambar P1.23 Sentinel-2 setelah ditajamkan dengan bayangan medan LiDAR

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Medannya tampak timbul, tetapi rumah dan tajuk kehilangan bentuk. Terang pada gambar ini berasal dari matahari buatan pada azimut 315°, bukan dari pantulan permukaan. Citra ini berguna untuk membaca lanskap, tetapi nilainya tidak lagi berarti pantulan.



Gambar P1.24 Seluruh Sub-DAS setelah ditajamkan dengan foto udara

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

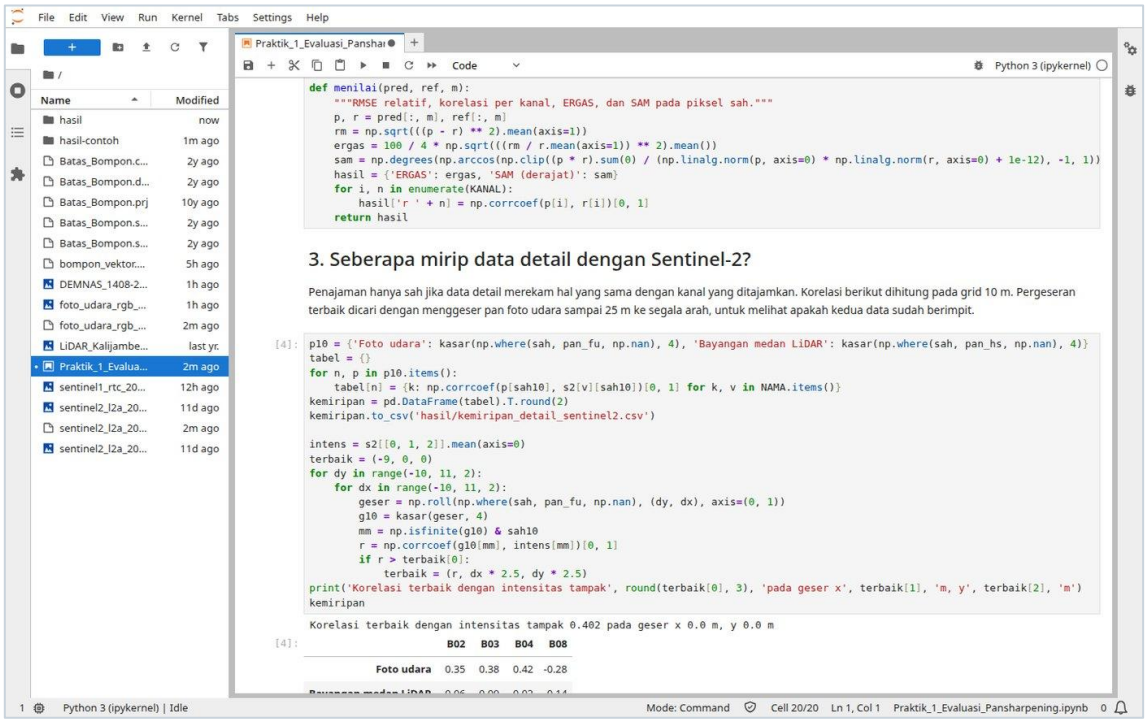
Tahap 8: Menguji Hasilnya

Buka `Praktik_1_Evaluasi_Pansharpening.ipynb`, lalu jalankan sel dari atas. Seluruhnya memerlukan sekitar 15 detik pada komputer uji coba.

Pengujian mengikuti protokol Wald et al. (1997). Kebenaran pada 2,5 m tidak kita miliki, jadi percobaan diturunkan satu tingkat. Sentinel-2 dikasarkan ke 40 m dan pan ke 10 m, lalu hasil penajaman ke 10 m dibandingkan dengan Sentinel-2 10 m yang asli. Pembandingnya adalah interpolasi bilinear, yang tidak menambah informasi apa pun. Selain Brovey, notebook mencoba *high-pass filter* (HPF), yang termasuk keluarga metode lain dalam ulasan Vivone et al. (2015). HPF hanya menambahkan detail pan, dengan bobot dari regresi kanal terhadap pan.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Bagian pertama notebook menanyakan syarat dasarnya, yaitu apakah data detail memang mirip dengan kanal yang ditajamkan.



Gambar P1.25 Kemiripan data detail dengan kanal Sentinel-2 di notebook

Sumber: Tangkapan layar uji coba

Tabel P1.3 Korelasi Data Detail dengan Sentinel-2 pada Grid 10 m

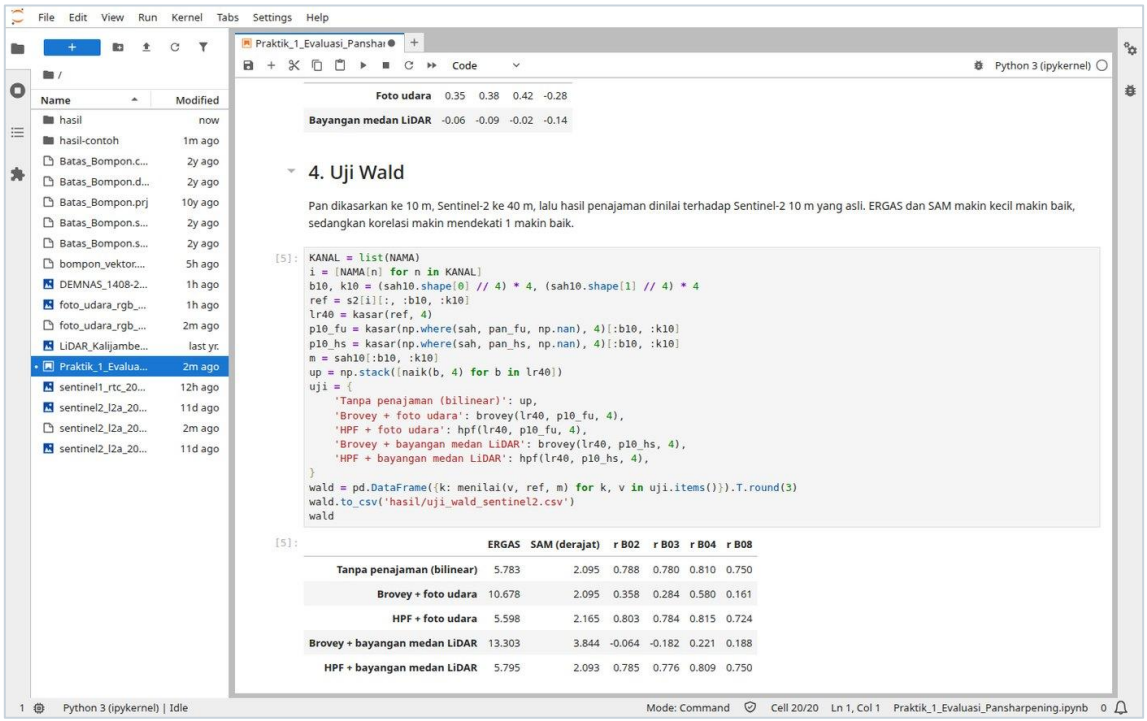
Data detail	B02	B03	B04	B08
Foto udara	0,35	0,38	0,42	−0,28
Bayangan medan LiDAR	−0,06	−0,09	−0,02	−0,14

Sumber: Hasil uji coba

Foto udara hanya sedang kemiripannya dengan kanal tampak, dan pada B08 korelasinya negatif, karena vegetasi yang gelap di foto justru terang di inframerah dekat. Bayangan medan hampir tidak berkorelasi dengan kanal apa pun. Menggeser foto udara sampai 25 m tidak memperbaiki korelasi, sehingga

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

masalahnya bukan pergeseran posisi. Perbedaan waktu perekaman, sudut pandang, dan warna antarberkas foto lebih mungkin berperan, walaupun hal itu belum diuji satu per satu.



Gambar P1.26 Hasil uji Wald di notebook

Sumber: Tangkapan layar uji coba

Tabel P1.4 Hasil Uji Wald pada Sentinel-2

Cara	ERGAS	SAM (°)	r B02	r B03	r B04	r B08
Tanpa penajaman (bilinear)	5,78	2,10	0,79	0,78	0,81	0,75
Brovey + foto udara	10,68	2,10	0,36	0,28	0,58	0,16
HPF + foto udara	5,60	2,17	0,80	0,78	0,82	0,72
Brovey + bayangan medan LiDAR	13,30	3,84	−0,06	−0,18	0,22	0,19
HPF + bayangan medan LiDAR	5,80	2,09	0,79	0,78	0,81	0,75

Sumber: Hasil uji coba; ERGAS dan SAM makin kecil makin baik

Bacalah tabel ini pelan-pelan. Brovey, metode pada alat QGIS yang menghasilkan gambar paling memukau, justru hampir melipatduakan galat dibandingkan tidak menajamkan sama sekali. HPF dengan foto udara hanya sedikit lebih baik pada kanal tampak dan lebih buruk pada B08. HPF dengan bayangan medan praktis tidak mengubah apa pun, karena bobot regresinya hampir nol. SAM Brovey sama dengan bilinear karena metode ini menjaga perbandingan antarkanal dan hanya mengubah terangnya.

Hasil ini berlaku untuk data ini, pada satu tingkat skala, dan belum tentu sama pada foto udara yang direkam berdekatan dengan citranya.

Notebook juga menguji dua gabungan lain.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

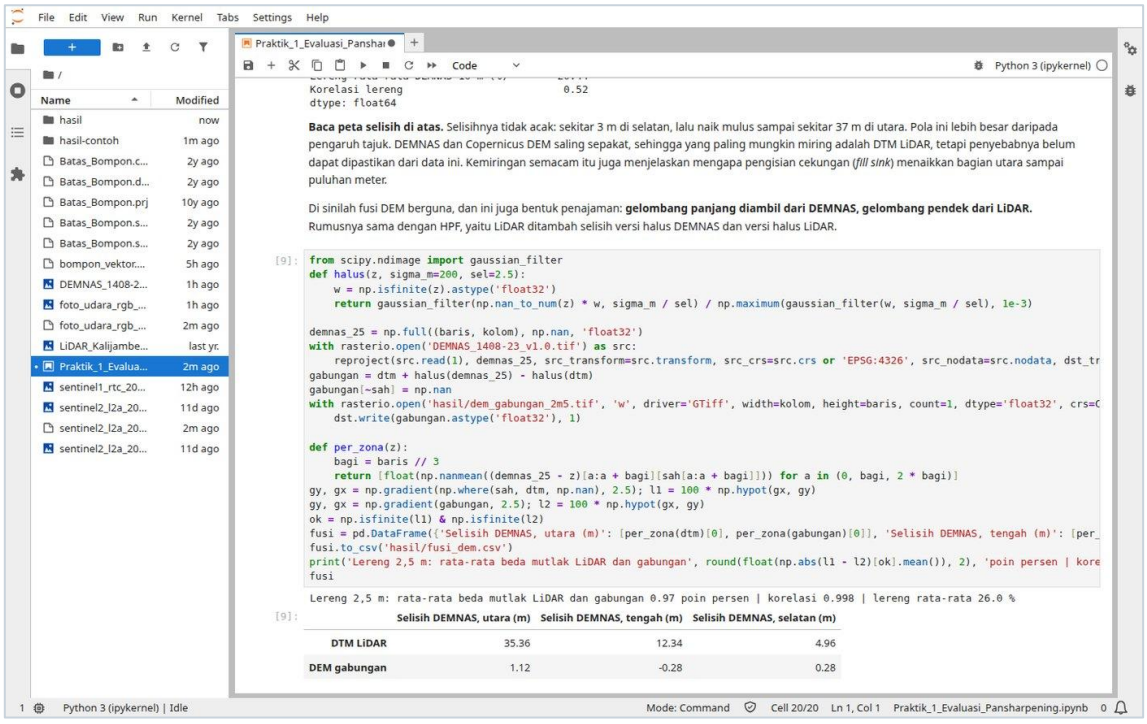
Tabel P1.5 Uji Wald pada Gabungan Lain

Data yang ditajamkan	Data detail	r bilinear	r HPF	RMSE bilinear	RMSE HPF
Sentinel-2 B11, 20 m	Sentinel-2 B08	0,946	0,948	0,0088	0,0082
Sentinel-2 B12, 20 m	Sentinel-2 B08	0,945	0,927	0,0073	0,0080
Sentinel-2 B12, 20 m	Sentinel-2 B04	0,945	0,935	0,0073	0,0073
Sentinel-1 VV	Foto udara	0,785	0,763	1,805 dB	1,849 dB
Sentinel-1 VV	Bayangan medan LiDAR	0,785	0,783	1,805 dB	1,808 dB

Sumber: Hasil uji coba

Satu-satunya perbaikan kecil yang konsisten adalah B11 dengan B08, yaitu dua kanal dari satu perekaman. Sentinel-1 tidak terbantu. Radar merekam kekasaran dan geometri permukaan dari arah miring, dan bintiknya bukan detail yang dapat diperjelas dengan foto.

Fusi DEMNAS dan LiDAR. Di sinilah penggabungan terbukti paling berguna. Tahap 4 menunjukkan bahwa kedua DEM saling melengkapi: DEMNAS lebih dapat dipercaya pada ketinggian regional, LiDAR pada detail. Notebook menghitung DEM gabungan pada 2,5 m dengan rumus LiDAR ditambah selisih versi halus DEMNAS dan versi halus LiDAR, memakai penghalusan Gaussian dengan sigma 200 m.



Gambar P1.27 Hasil fusi DEM di notebook

Sumber: Tangkapan layar uji coba

Tabel P1.6 Selisih Rata-rata terhadap DEMNAS menurut Zona (m)

DEM	Utara	Tengah	Selatan
DTM LiDAR	35,36	12,34	4,96
DEM gabungan	1,12	−0,28	0,28

Sumber: Hasil uji coba

Kemiringan regionalnya hilang, sedangkan detail lereng hampir tidak berubah: korelasi lereng 2,5 m antara LiDAR dan DEM gabungan mencapai 0,998, dengan beda rata-rata 0,97 poin persen. Ada dua batasan.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Selisih terhadap DEMNAS memang kecil karena DEMNAS dijadikan acuan, sehingga tabel ini tidak membuktikan ketinggian mutlaknya benar. DEMNAS juga dapat memuat tajuk, sehingga DEM gabungan bukan DTM murni pada skala regional.



Gambar P1.28 Sentinel-2 asli, hasil dua penajaman, dan foto udara pada potongan yang sama

Sumber: Hasil uji coba; *Contains modified Copernicus Sentinel data 2025*

Titik periksa. `hasil/uji_wald_sentinel2.csv` sama dengan Tabel P1.4, dan `hasil/dem_gabungan_2m5.tif` terbentuk.

Membaca Hasil

Citra hasil penajaman tetap berguna, tetapi untuk tujuan yang tepat. Pakailah untuk interpretasi visual, misalnya mengenali permukiman dan pematang saat menarik batas SMU. Jangan memakainya untuk menghitung indeks atau melatih model seolah-olah Sentinel-2 benar-benar memiliki piksel 2,5 m, karena nilai itu terbukti bergeser dari pantulan aslinya. Untuk pemodelan, tumpukan 10 m pada tahap 3 lebih jujur, sedangkan foto udara dan turunan LiDAR dapat masuk langsung sebagai lapisan sendiri, yaitu fusi tingkat fitur.

Keselarasan grid juga tidak berarti data itu setara. Citra optik direkam pada Juli 2025, radar pada Agustus 2024, LiDAR dan foto udara pada kurun 2022–2024, dan DEMNAS merupakan gabungan beberapa sumber. Sebelum memakai data berlapis di kebun, tanyakan selalu kapan setiap lapisan direkam dan apa yang diukurnya. Di kebun kelapa sawit, tanyakan pula pada vendor foto udara atau LiDAR: apakah ketinggiannya sudah diperiksa terhadap titik kontrol? Kemiringan seperti pada tahap 4 tidak tampak pada peta bayangan medan yang indah.

Praktik 2 memakai Copernicus DEM yang sudah disiapkan pada foldernya, sehingga hasil di atas belum memengaruhinya. Praktik 5 memakai DEMNAS yang sama dengan praktik ini, yang sudah diproyeksikan ke UTM dan dipotong, lalu dibawa ke grid 10 m dengan pengaturan seperti tahap 2.

Jika Tertinggal

Semua keluaran uji coba tersedia di `data/praktik-1/hasil-contoh/`, termasuk proyek `Praktik_1_selesai.qgz` yang dapat langsung dibuka.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Kurikulum Pembelajaran

Praktik 2. Remote Sensing untuk Delineasi Soil Mapping Unit

Pemandu: Johan dan Nurarfiyah. Perangkat: QGIS. Rujukan teori: Modul 3, Modul 4, dan Modul 6.

Tujuan

Membekali peserta agar mampu menyusun peta satuan peta tanah dari turunan DEM dan interpretasi citra, lalu menyesuaikannya dengan skala peta.

Kompetensi

Setelah mengikuti praktik ini, peserta memiliki kompetensi dalam:

1. Menurunkan kemiringan dan kelas lereng dari DEM
2. Menghitung indeks sifat tanah dan menilai keterbatasannya
3. Mendigitasi satuan bentuklahan tanpa celah dan tumpang tindih
4. Menyusun SMU melalui tumpang susun
5. Menggeneralisasi satuan sesuai luasan terkecil yang terbaca
6. Membandingkan hasil delineasi dengan peta riset

Ringkasan Studi

1. Deskripsi singkat
    - Peserta membuat peta lereng, bayangan medan, kontur, dan indeks sifat tanah
    - Peserta menarik batas tiga satuan bentuklahan dengan unsur interpretasi citra
    - Peserta menyusun dan menggeneralisasi SMU, lalu membandingkannya dengan peta riset
2. Hasil belajar
    - Peserta memahami SMU sebagai hipotesis sebaran tanah
    - Peserta memiliki peta SMU beserta legendanya
3. Indikator hasil belajar
    - Jumlah luas poligon sekitar 294,71 ha, tanpa celah dan tumpang tindih
    - Tidak ada poligon SMU yang lebih kecil dari 0,4 ha
    - Peserta dapat menjelaskan di mana batasnya berbeda dari peta riset dan mengapa
4. Materi pokok
    - Konsep SMU dan prinsip delineasi berbasis lanskap
    - Turunan DEM dan indeks sifat tanah
    - Skala peta dan MLA
    - Tumpang susun dan generalisasi

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambaran Praktik

Satuan peta tanah (*Soil Mapping Unit*, SMU) tidak ditarik dari tanah yang terlihat, karena tanah jarang terlihat. Satuan itu ditarik dari kenampakan lanskap yang berkaitan dengan pembentukan tanah, seperti bentuklahan dan lereng, sebagaimana dibahas pada Modul 3 dan Modul 4. Hasilnya berupa hipotesis tentang sebaran tanah, bukan kebenaran lapangan.

Praktik ini mengerjakan alur tersebut dari awal. Peserta menurunkan peta lereng dari DEM, melihat apa yang dapat dan tidak dapat diberikan indeks sifat tanah dari citra, menarik batas satuan bentuklahan secara manual, menumpangsusunkannya dengan kelas lereng, lalu menggeneralisasi hasilnya sesuai skala peta. Pada akhir praktik, hasil peserta dibandingkan dengan peta bentuklahan dan kelas lereng hasil riset, yang sengaja baru dibuka pada tahap terakhir.

Data yang Dipakai

Semua berkas ada di folder `data/praktik-2/`. Buat folder `data/praktik-2/hasil/` untuk menyimpan keluaran.

Tabel P2.1 Data Praktik 2

Berkas	Isi
`dem_10m.tif`	Copernicus DEM yang sudah diselaraskan ke grid 10 m
`sentinel2_l2a_20250721_10m.tif`	Sentinel-2 L2A, 21 Juli 2025, 10 kanal
`bompon_vektor.gpkg`	`batas_subdas`, `penggunaan_lahan`, `sungai`
`pembanding/peta_riset.gpkg`	`bentuklahan` dan `kelas_lereng` hasil riset; **jangan dibuka sebelum tahap 6**

Sumber: Data proyek; *Contains modified Copernicus Sentinel data 2025*

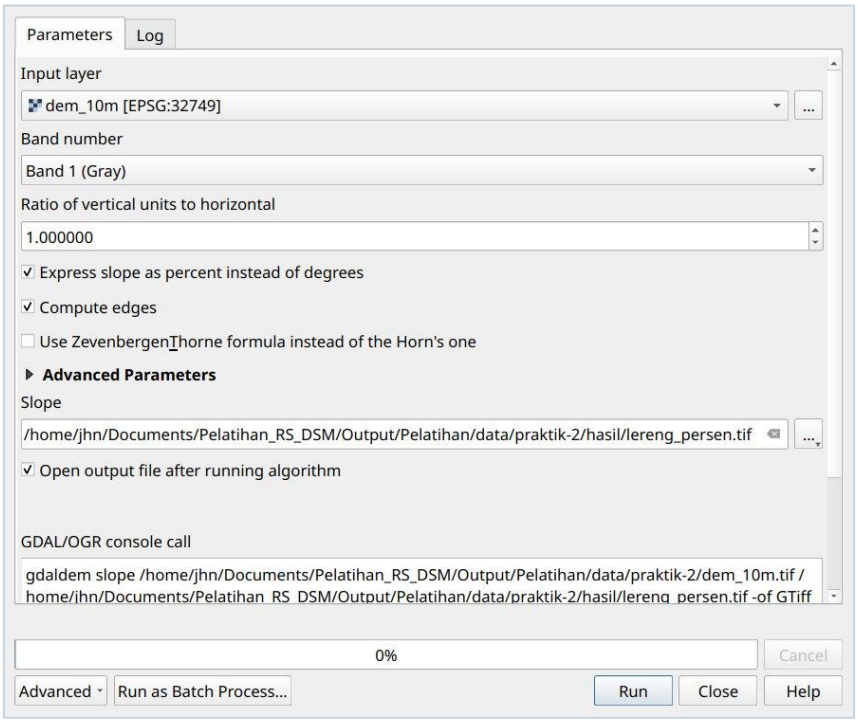
Skala sasaran pada latihan ini adalah 1:10.000, sehingga luasan terkecil yang terbaca (MLA) 0,4 ha menurut rumus pada Modul 3.

Tahap 1: Menurunkan Lereng dari DEM

1. Buat proyek baru, simpan sebagai `hasil/praktik2.qgz`, lalu muat semua data kecuali folder `pembanding`.

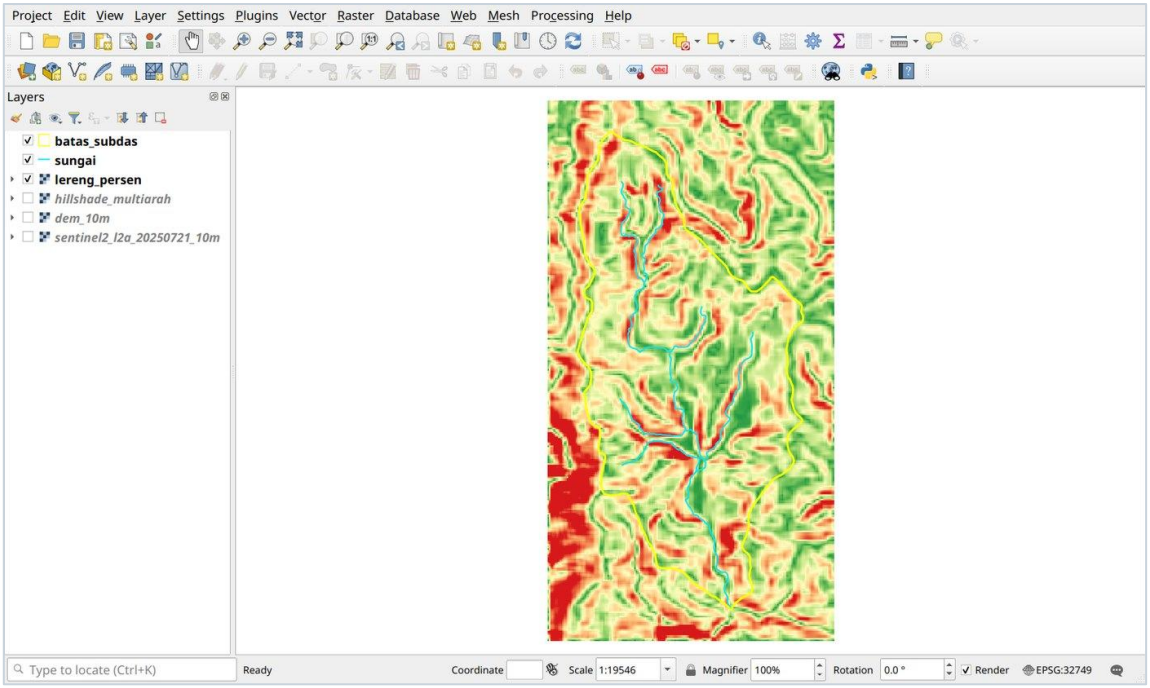
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. Pilih **Raster > Analysis > Slope**. Isi **Input layer** `dem_10m`, centang **Express slope as percent instead of degrees** dan **Compute edges**, lalu simpan ke `hasil/lereng_persen.tif`.



Gambar P2.1 Dialog Slope

Sumber: Tangkapan layar uji coba



Gambar P2.2 Kemiringan lereng dalam persen

Sumber: Tangkapan layar uji coba; data dari Copernicus DEM GLO-30

3. Cari **Reclassify by table** di Processing Toolbox. Isi **Raster layer** `lereng_persen`, lalu klik **...** pada **Reclassification table** dan isi lima baris pada Tabel P2.2.

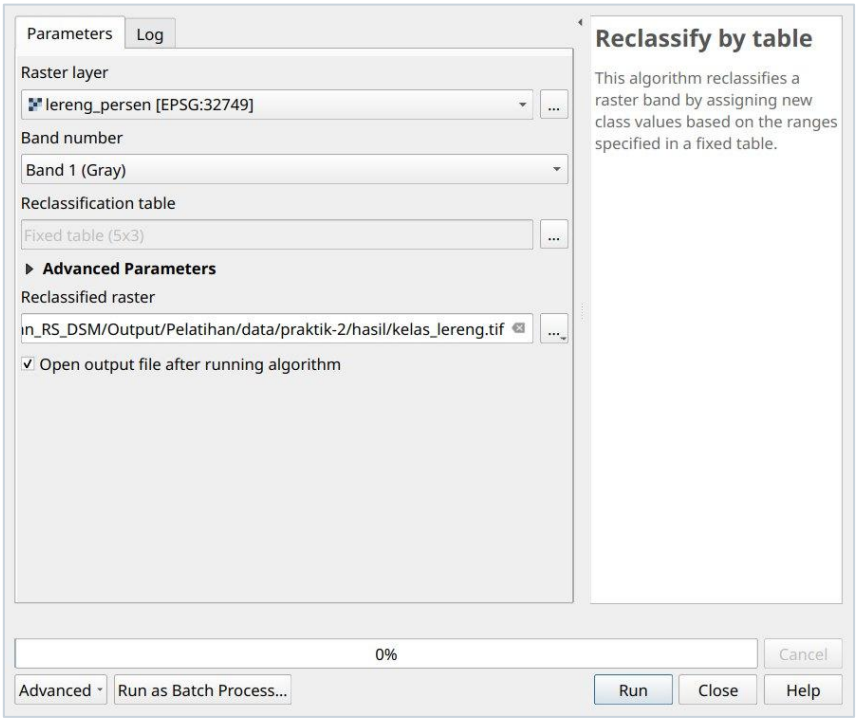
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

4. Buka **Advanced Parameters**, pilih **Range boundaries** *min <= value < max*, lalu simpan ke `hasil/kelas_lereng.tif`.

Tabel P2.2 Kelas Lereng

Minimum	Maximum	Value	Kelas
0	8	1	0–8%
8	15	2	8–15%
15	25	3	15–25%
25	45	4	25–45%
45	100000	5	>45%

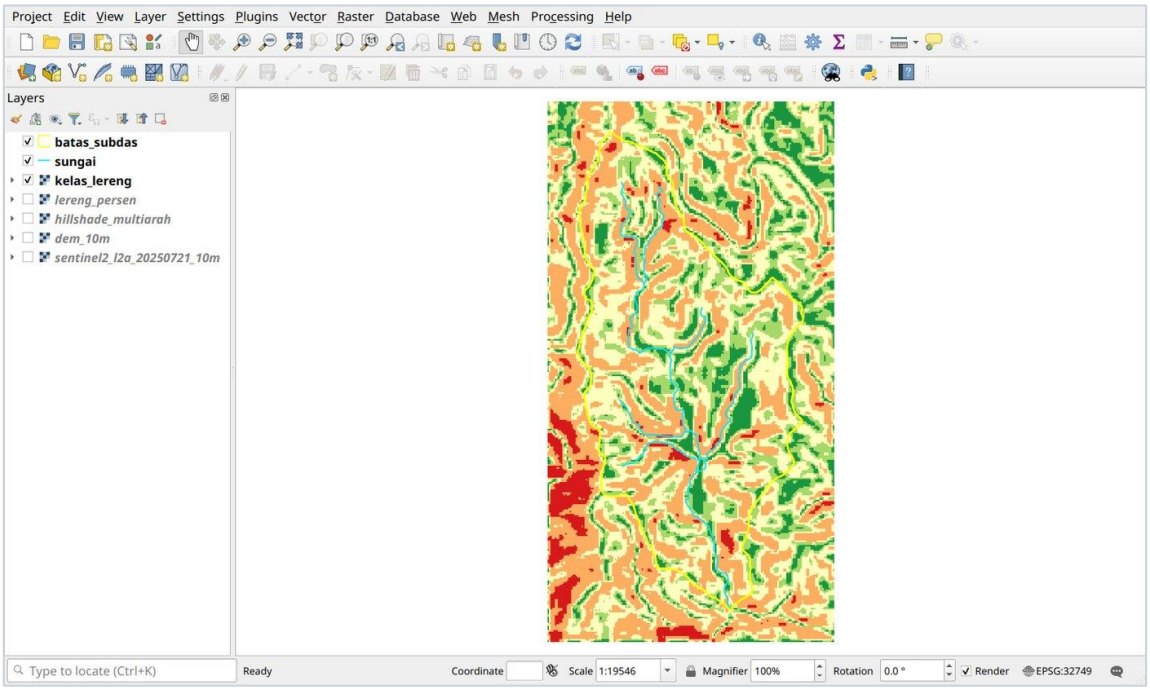
Sumber: Kelas yang dipakai pada survei Sub-DAS Bompon



Gambar P2.3 Dialog Reclassify by Table

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P2.4 Lima kelas lereng

Sumber: Tangkapan layar uji coba; data dari Copernicus DEM GLO-30

5. Pilih **Raster > Analysis > Hillshade**, centang **Multidirectional shading** dan **Compute edges**, lalu simpan ke `hasil/hillshade_multiarah.tif`.
6. Pilih **Raster > Extraction > Contour**, dengan **Interval between contour lines** `10`, lalu simpan ke `hasil/kontur_10m.gpkg`.

Titik periksa. Pada uji coba, lereng bernilai 0 sampai 87,9% dengan rata-rata 22,1%.

Tahap 2: Indeks Sifat Tanah dari Citra

Tahap ini mempraktikkan isi Modul 4. Tabel 4.2 pada modul tersebut memuat indeks yang berkaitan dengan sifat tanah. Tiga di antaranya dihitung di sini, ditambah NDVI sebagai pembanding. Indeks yang memerlukan data hiperspektral, seperti NSMI dan kedalaman serapan, hanya dapat dibahas dan tidak dapat dihitung dari Sentinel-2.

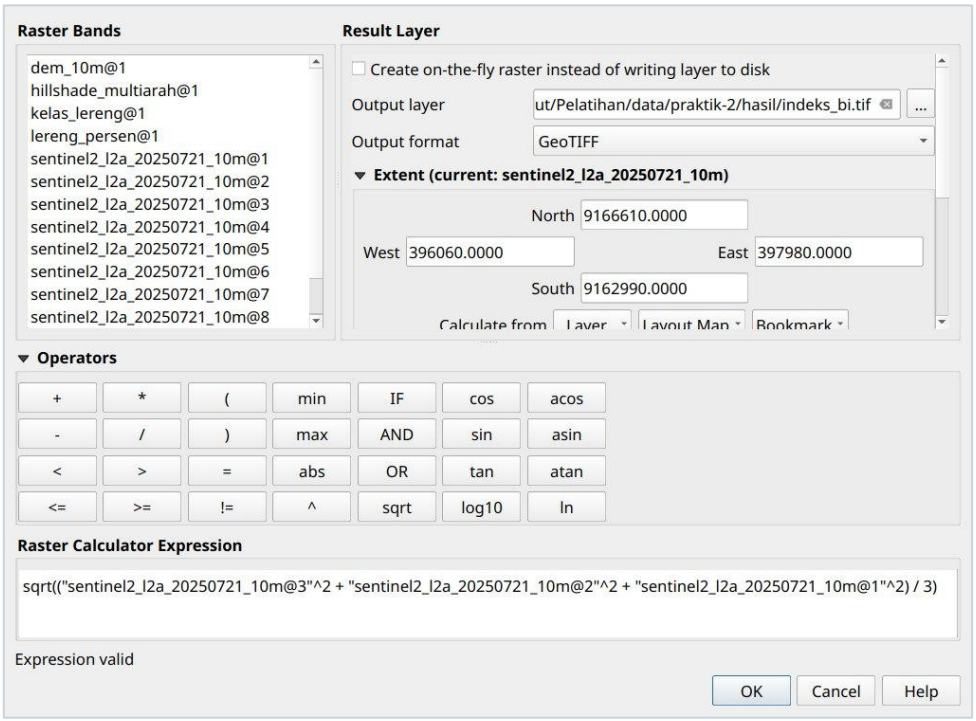
Hitung dengan **Raster > Raster Calculator**. Pada rumus di bawah, `S` mewakili `sentinel2_l2a_20250721_10m`.

Tabel P2.3 Rumus Indeks

Indeks	Ekspresi	Keluaran
Kecerahan (BI)	`sqrt(("S@3"^2 + "S@2"^2 + "S@1"^2) / 3)`	`hasil/indeks_bi.tif`
Pewarnaan (CI)	`("S@3" - "S@2") / ("S@3" + "S@2")`	`hasil/indeks_ci.tif`
Rasio mineral lempung (CMR)	`"S@9" / "S@10"`	`hasil/indeks_cmr.tif`
NDVI	`("S@7" - "S@3") / ("S@7" + "S@3")`	`hasil/indeks_ndvi.tif`

Sumber: Rumus dari Tabel 4.2 Modul 4, disesuaikan dengan urutan kanal berkas

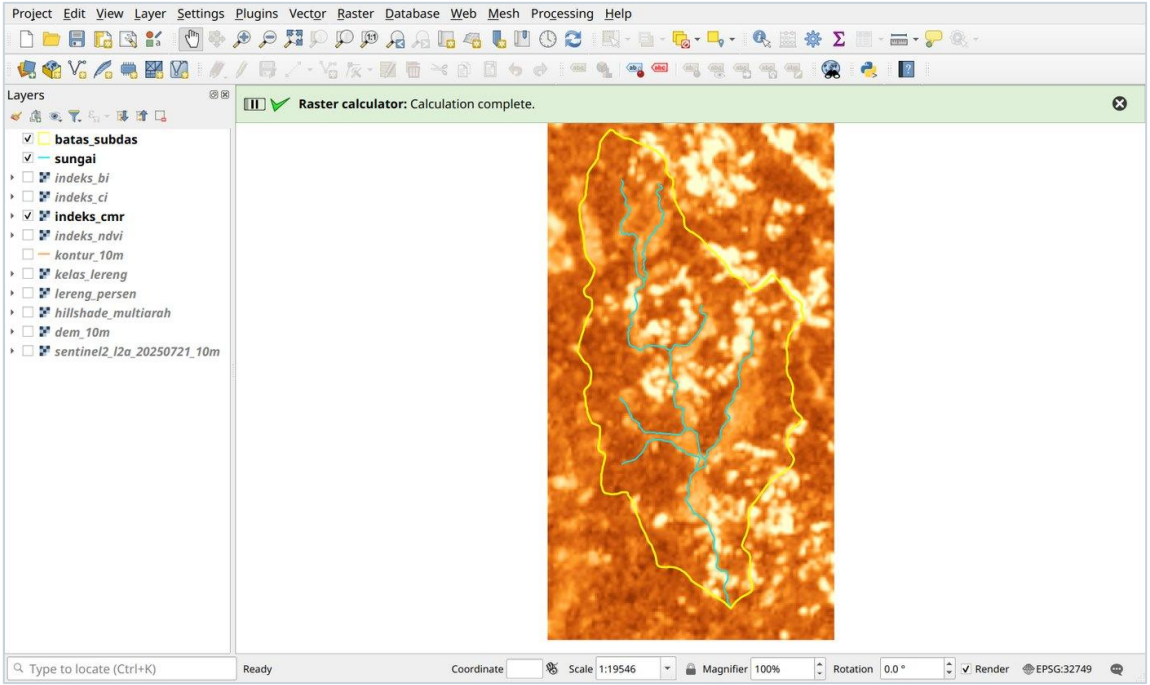
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P2.5 Menghitung indeks kecerahan

Sumber: Tangkapan layar uji coba

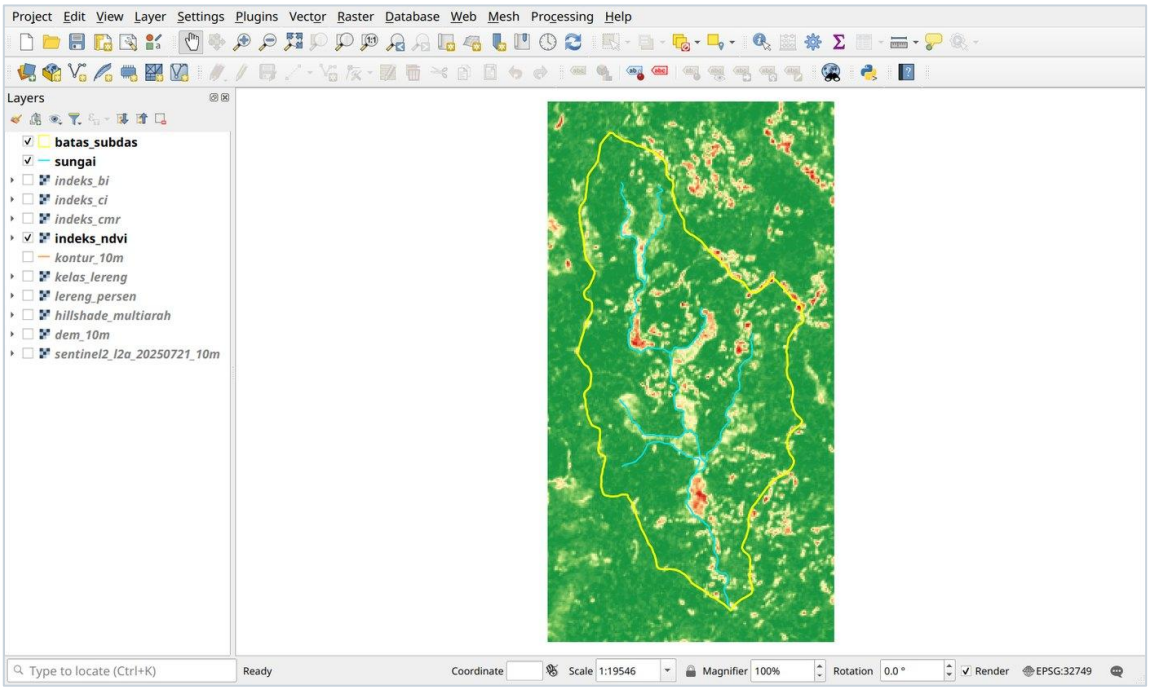
Tampilkan CMR dan NDVI berdampingan dengan mencentang layernya bergantian.



Gambar P2.6 Rasio mineral lempung (CMR)

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P2.7 NDVI

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

Kedua peta tampak sangat mirip, dan inilah pelajaran utamanya. Pada citra 2024 yang dipakai di Praktik 4, korelasi Spearman CMR dengan NDVI di dalam Sub-DAS mencapai 0,78. Sebuah indeks bernama "rasio mineral lempung" ternyata terutama menggambarkan vegetasi, karena hanya sedikit piksel yang tanahnya terbuka. Modul 4 sudah menjelaskan bahwa estimasi langsung hanya bermakna pada tanah terbuka. Karena itu, peta indeks ini tidak dipakai untuk menarik batas SMU. Praktik 4 akan membahas cara menyaring piksel tanah terbuka.

Titik periksa. BI bernilai 0,012–0,201, CI −0,547–0,319, CMR 1,111–2,660, dan NDVI 0,038–0,936.

Tahap 3: Mendigitasi Satuan Bentuklahan

Inti delineasi ada pada tahap ini. Peta lereng dari komputer tidak dapat menggantikan penafsir, karena penafsirlah yang memutuskan mana batas yang bermakna. Gunakan unsur interpretasi pada Tabel 3.2 Modul 3 dan prinsip konvergensi bukti pada Modul 6, yaitu batas yang muncul dari beberapa petunjuk lebih dapat dipercaya.

Untuk latihan ini, cukup tiga satuan. Kunci interpretasi berikut disusun penyusun modul untuk latihan.

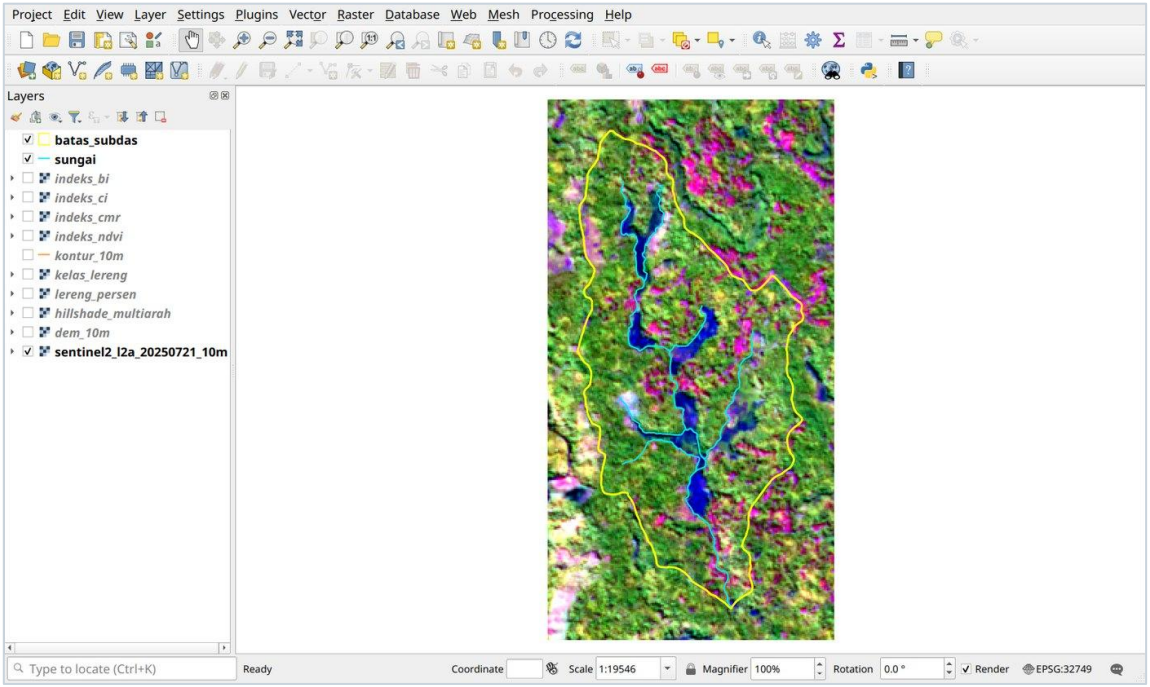
Tabel P2.4 Kunci Interpretasi Sederhana untuk Latihan

Kode	Satuan	Petunjuk pada data
K	Kaki lereng dan dataran koluvial	Situs terendah di sepanjang alur; kontur renggang; biru tua pada komposit SWIR (sawah)
P	Punggung dan interfluve	Bagian tertinggi di sepanjang batas Sub-DAS dan punggungan; relatif landai di puncak
L	Lereng perbukitan	Bagian di antara keduanya; kontur rapat dan bayangan medan kontras

Sumber: Disusun untuk latihan, memakai prinsip Tabel 3.2 Modul 3

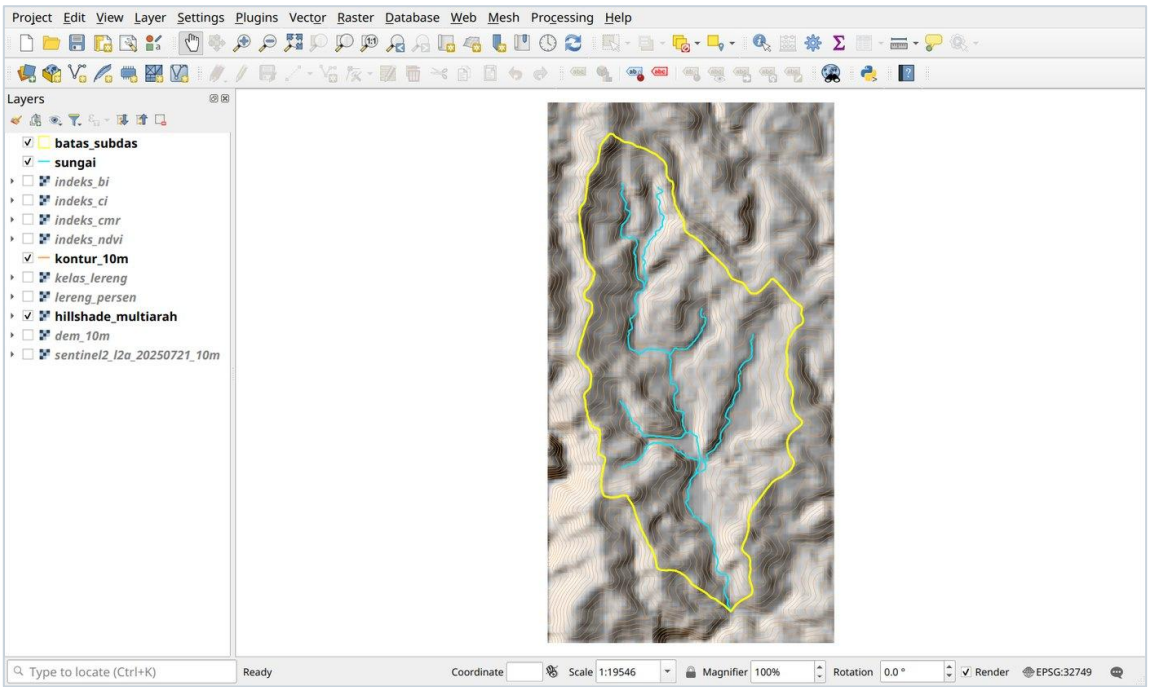
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

1. Siapkan dua tampilan acuan. Yang pertama adalah `sentinel2_l2a_20250721_10m` sebagai **Multiband color** kanal 9, 7, 2. Yang kedua adalah `hillshade_multiarah` dengan `kontur_10m` dan `sungai` di atasnya. Tampilkan bergantian saat menarik batas.



Gambar P2.8 Tampilan acuan: komposit SWIR dengan sungai dan batas Sub-DAS

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*



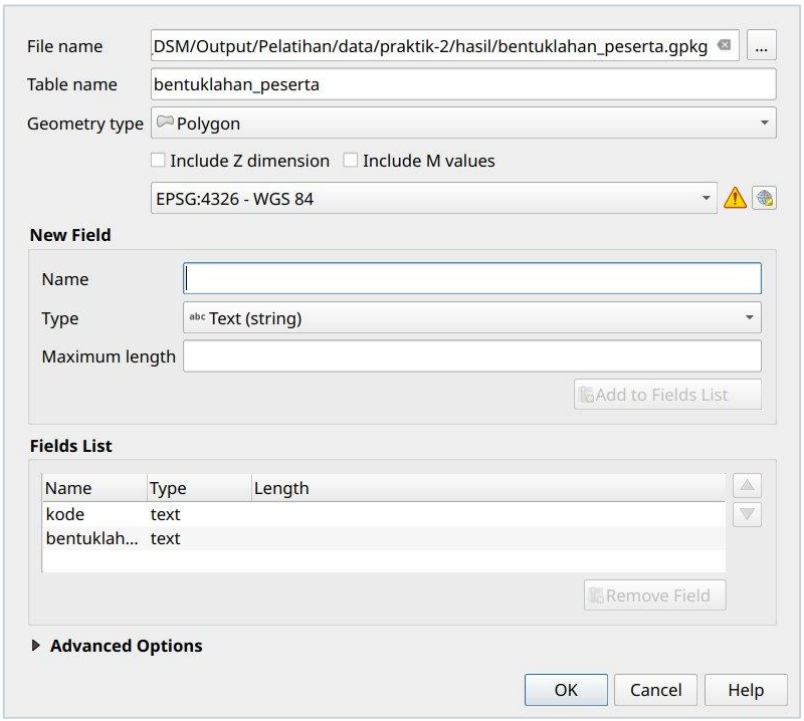
Gambar P2.9 Tampilan acuan: bayangan medan, kontur 10 m, dan sungai

Sumber: Tangkapan layar uji coba; data dari Copernicus DEM GLO-30

2. Pilih **Layer > Create Layer > New GeoPackage Layer**. Isi **File name** `hasil/bentuklahan_peserta.gpkg`, **Geometry type** *Polygon*, dan CRS `EPSG:32749`. Pada **New Field**, tambahkan dua kolom teks, yaitu `kode` dan `bentuklahan`, dengan tombol **Add to Fields List**, lalu klik **OK**. Periksa CRS-nya sebelum menutup

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

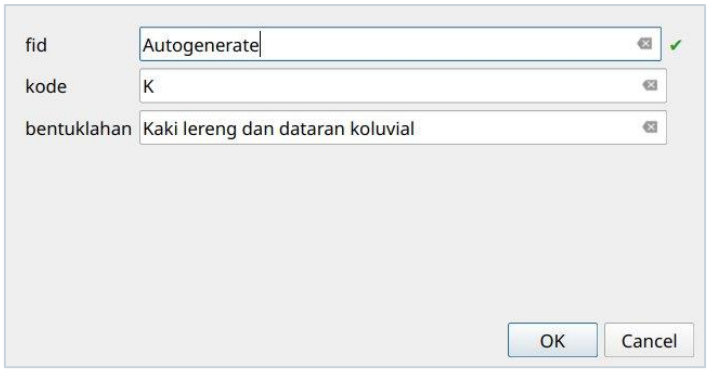
dialog. Bawaan dialog adalah `EPSG:4326`, seperti terlihat pada gambar, sehingga harus diganti lewat tombol di sebelahnya.



Gambar P2.10 Membuat layer GeoPackage baru

Sumber: Tangkapan layar uji coba

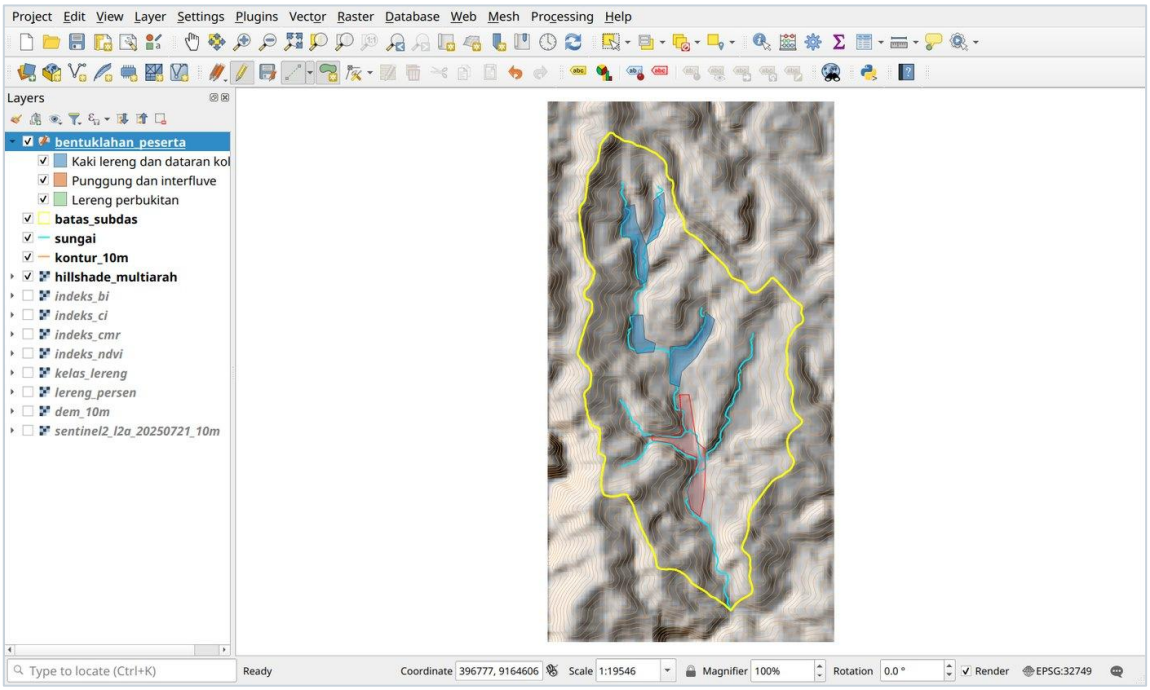
3. Aktifkan **View > Toolbars > Snapping Toolbar**. Klik ikon magnet untuk mengaktifkan *snapping*, aktifkan **Vertex** dan **Segment**, dan isi toleransi `8` piksel. Klik ikon **Enable Topological Editing**, lalu pilih **Avoid Overlap on Active Layer**.
4. Pilih layer `bentuklahan_peserta`, klik **Toggle Editing** (ikon pensil), lalu **Add Polygon Feature**.
5. Mulailah dari satuan yang paling jelas, yaitu kaki lereng dan dataran koluvial. Klik sepanjang batas yang Anda tafsirkan, lalu klik kanan untuk mengakhiri poligon. Isi `kode` dan `bentuklahan` pada form yang muncul, lalu klik **OK**.



Gambar P2.11 Form atribut setelah satu poligon selesai

Sumber: Tangkapan layar uji coba

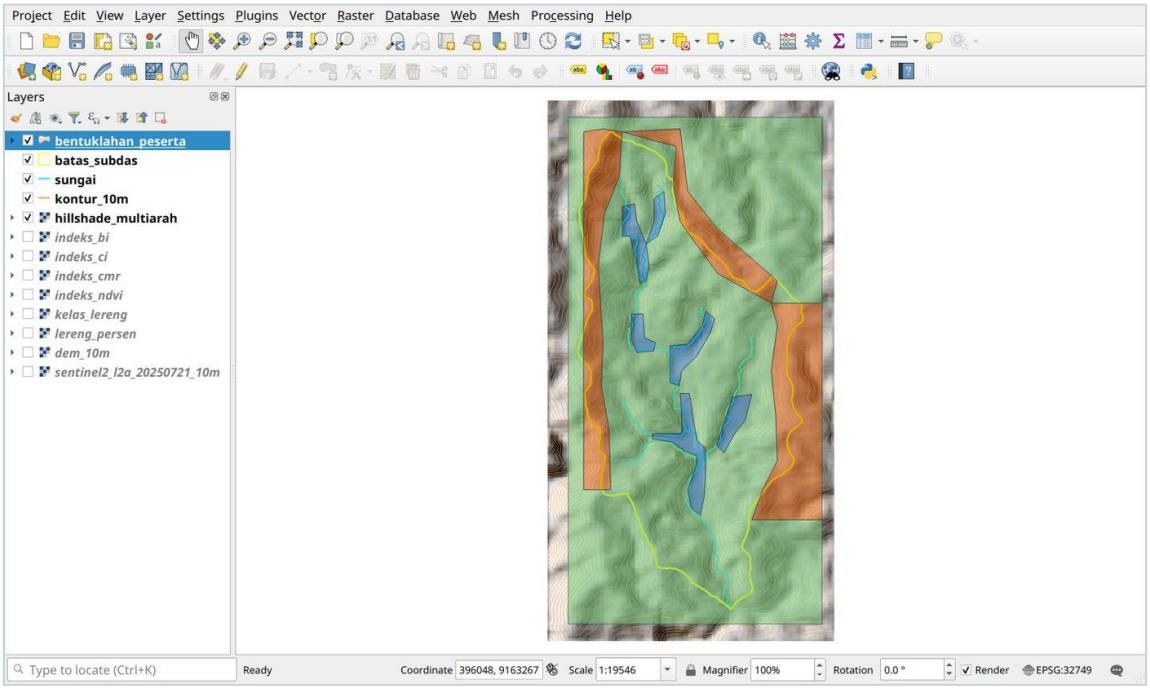
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P2.12 Digitasi poligon sedang berjalan

Sumber: Tangkapan layar uji coba

6. Lanjutkan dengan satuan punggung. Terakhir, gambar satu poligon besar untuk satuan lereng perbukitan yang melewati seluruh batas Sub-DAS. Dengan **Avoid Overlap**, QGIS memotong poligon baru mengikuti poligon yang sudah ada, sehingga tidak ada celah maupun tumpang tindih, tanpa perlu menelusuri batas yang sama dua kali.
7. Klik **Save Layer Edits**, lalu matikan **Toggle Editing**.

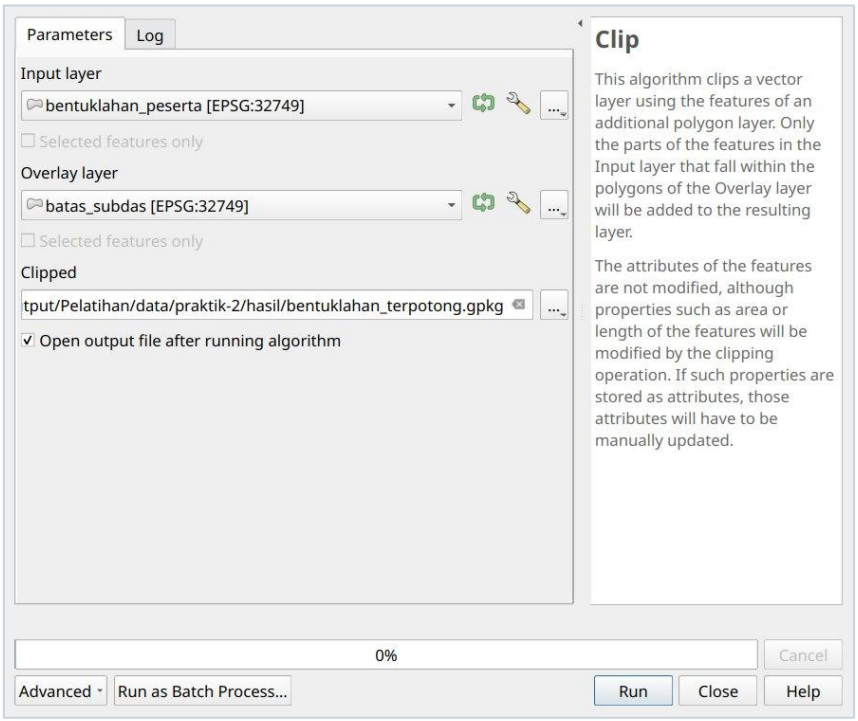


Gambar P2.13 Hasil digitasi dengan Avoid Overlap, sebelum dipotong mengikuti batas Sub-DAS

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

8. Pilih **Vector > Geoprocessing Tools > Clip**, dengan **Input layer** `bentuklahan_peserta` dan **Overlay layer** `batas_subdas`. Simpan ke `hasil/bentuklahan_terpotong.gpkg`.

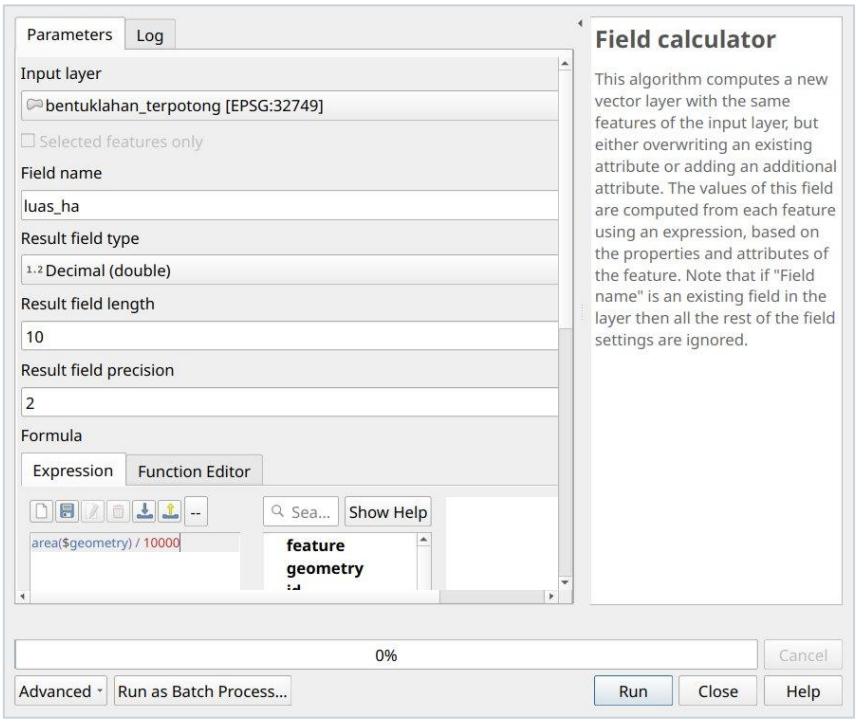


Gambar P2.14 Dialog Clip
Sumber: Tangkapan layar uji coba

9. Cari **Field calculator** di Processing Toolbox. Isi **Input layer** `bentuklahan_terpotong`, **Field name** `luas_ha`, **Result field type** *Decimal*, dan formula berikut, lalu simpan ke `hasil/bentuklahan_luas.gpkg`.

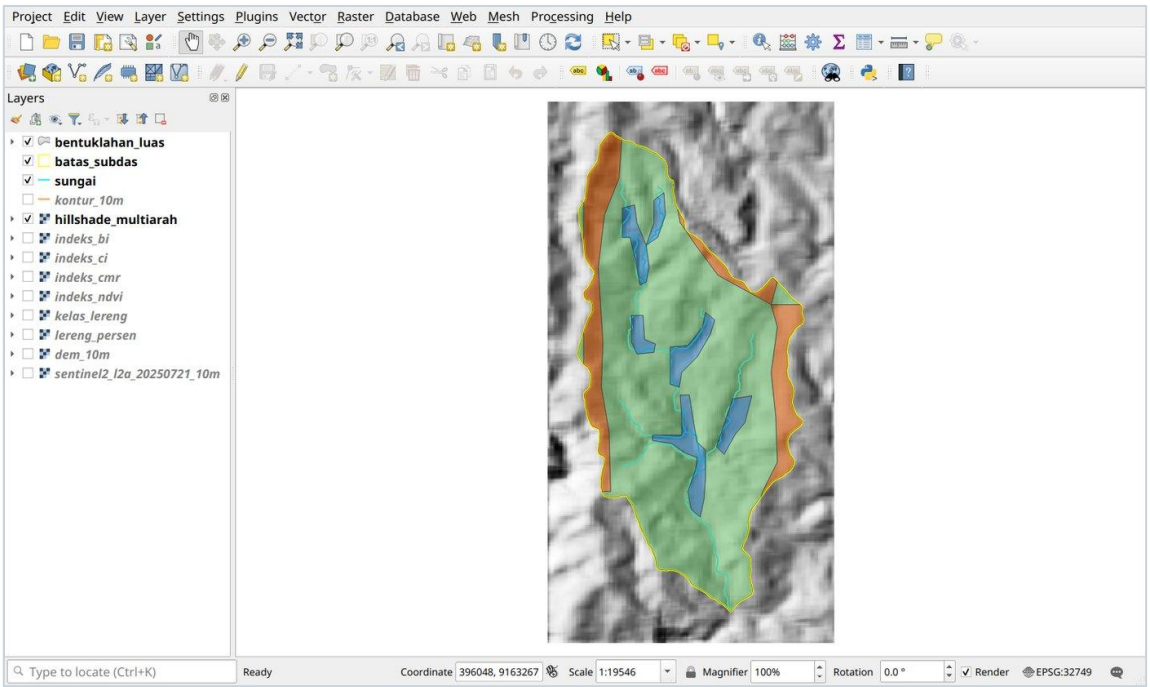
```
area($geometry) / 10000
```


© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P2.15 Menghitung luas poligon dengan Field Calculator

Sumber: Tangkapan layar uji coba



Gambar P2.16 Contoh peta satuan bentuklahan hasil digitasi uji coba

Sumber: Tangkapan layar uji coba; delineasi merupakan tafsiran penyusun untuk latihan, tanpa pengamatan lapangan

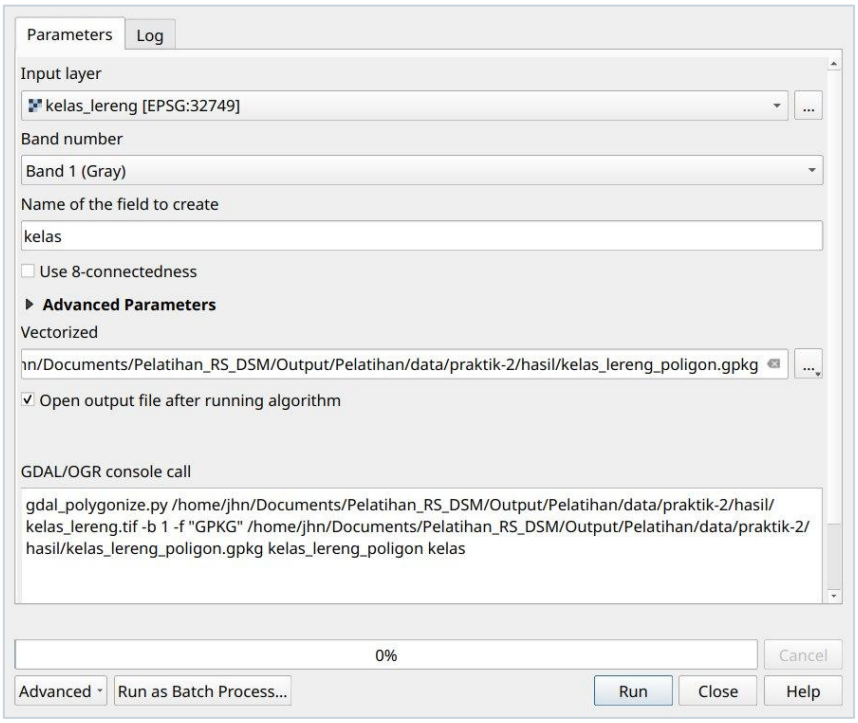
Titik periksa. Jumlah kolom `luas_ha` seluruh poligon harus sekitar 294,71 ha, sama dengan luas Sub-DAS. Pada contoh uji coba, satuan kaki lereng dan dataran koluvial seluas 26,52 ha, punggung 43,57 ha, dan lereng perbukitan 224,62 ha. Hasil Anda pasti berbeda, dan justru perbedaan itu yang didiskusikan pada tahap 6. Simpan berkas ini sebagai titik henti hari pertama.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tahap 4: Menyusun SMU dengan Tumpang Susun

Tahap ini dimulai dari berkas `bentuklahan_luas` dan `kelas_lereng`. Peserta yang belum selesai dapat memuatnya dari `hasil-contoh/`. SMU pada latihan ini adalah gabungan bentuklahan dan kelas lereng, sejalan dengan Sambodo dan Arpornthip (2021). Penggunaan lahan sengaja tidak dimasukkan, karena Modul 3 menjelaskan bahwa batasnya merupakan keputusan manusia yang tidak selalu mengikuti batas tanah.

1. Pilih **Raster > Conversion > Polygonize (Raster to Vector)**. Isi **Input layer** `kelas_lereng`, **Name of the field to create** `kelas`, lalu simpan ke `hasil/kelas_lereng_poligon.gpkg`.

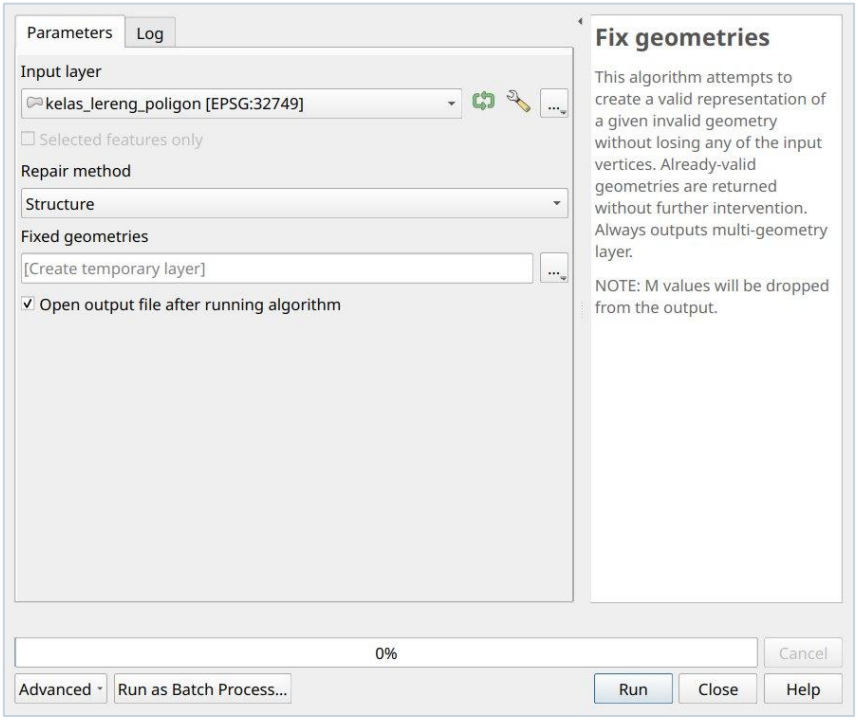


Gambar P2.17 Dialog Polygonize
Sumber: Tangkapan layar uji coba

> **Perhatian.** Jika Polygonize dijalankan dua kali ke berkas GeoPackage yang sama, fiturnya bertambah, bukan tertimpa, sehingga jumlah poligon menjadi dua kali lipat dan perhitungan berikutnya keliru. Hal ini sempat terjadi saat uji coba. Jika perlu mengulang, hapus dulu layernya dari proyek dan hapus berkasnya, atau simpan dengan nama baru.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

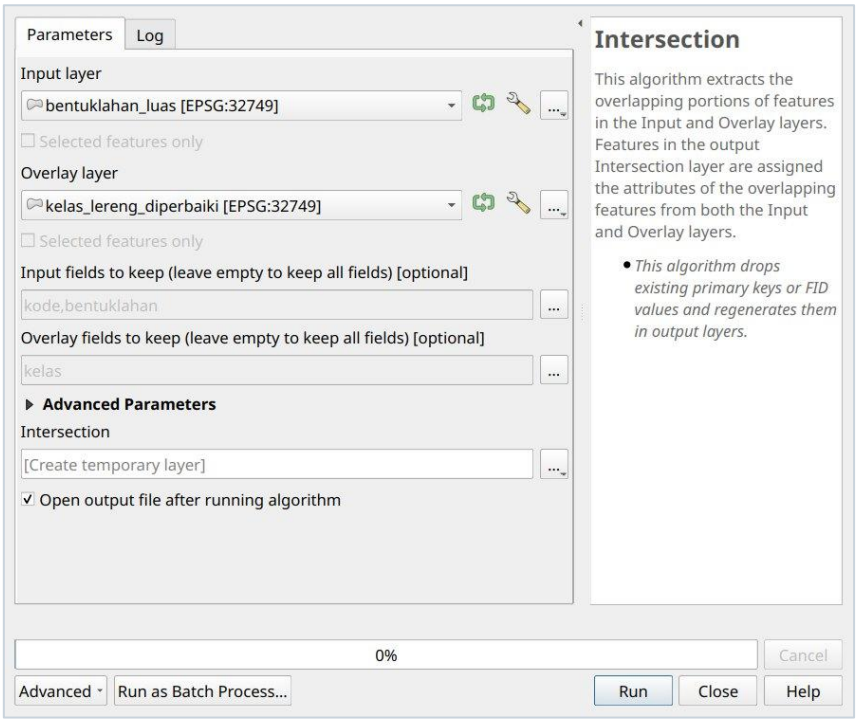
2. Jalankan **Fix geometries** dari Processing Toolbox pada `kelas_lereng_poligon`, sebagai layer sementara. Poligon hasil konversi raster sering memiliki geometri yang menyentuh dirinya sendiri, sehingga alat berikutnya dapat menolaknya.



Gambar P2.18 Dialog Fix Geometries

Sumber: Tangkapan layar uji coba

3. Pilih **Vector > Geoprocessing Tools > Intersection**. Isi **Input layer** `bentuklahan_luas`, **Overlay layer** hasil langkah 2, **Input fields to keep** `kode` dan `bentuklahan`, dan **Overlay fields to keep** `kelas`.



Gambar P2.19 Dialog Intersection

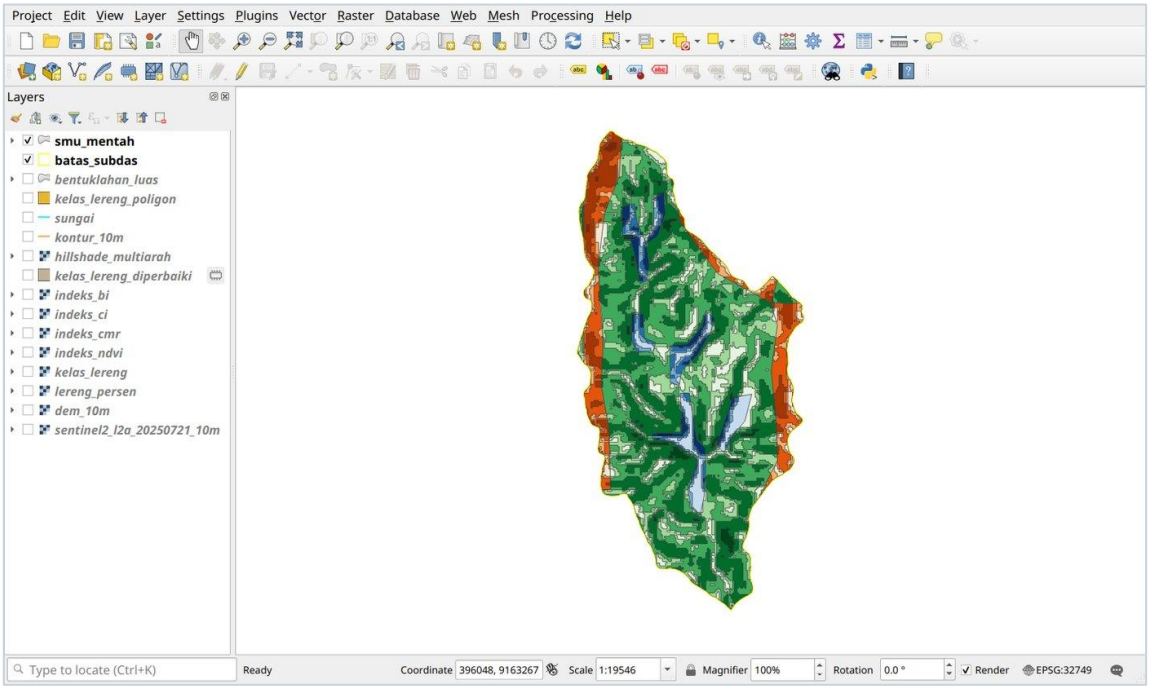
Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

4. Jalankan **Multipart to singleparts** pada hasilnya.
5. Jalankan **Field calculator** dua kali. Yang pertama membuat kolom desimal `luas_ha` dengan rumus `area($geometry) / 10000`. Yang kedua membuat kolom teks `smu` dengan rumus berikut, lalu simpan ke `hasil/smu_mentah.gpkg`.

```
"kode" || to_string(to_int("kelas"))
```

Kode `L3`, misalnya, berarti lereng perbukitan dengan kelas lereng 15–25%.



Gambar P2.20 Satuan peta sebelum generalisasi

Sumber: Tangkapan layar uji coba

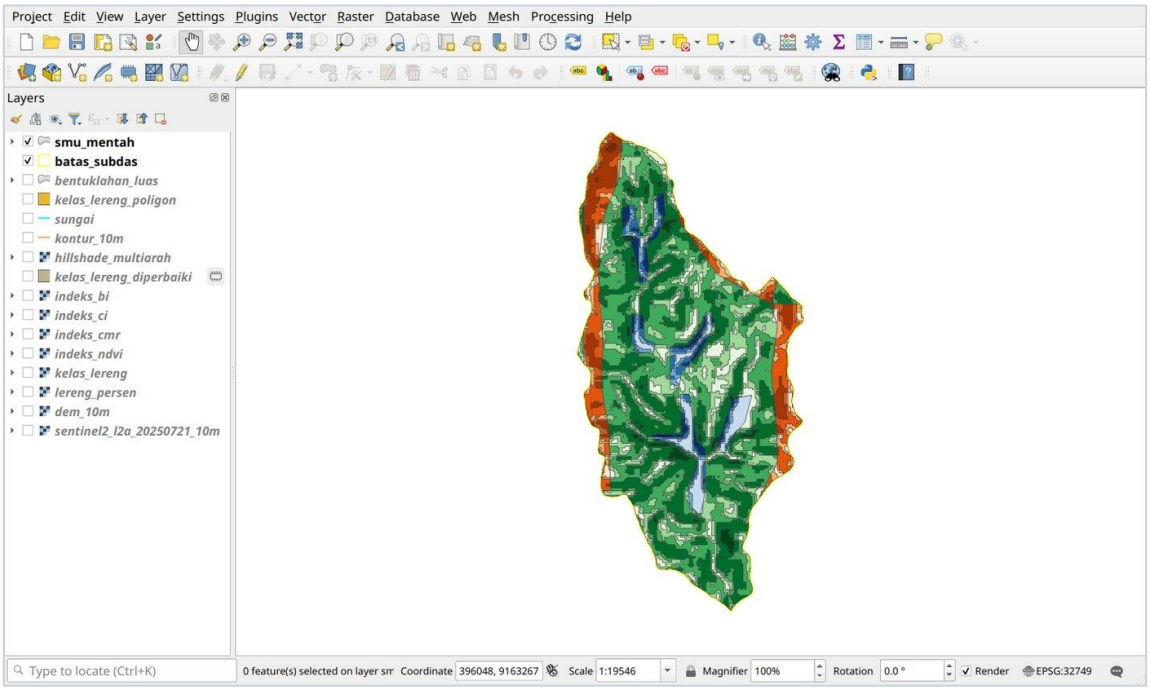
Titik periksa. Pada contoh uji coba, kelas lereng menjadi 2.707 poligon, dan tumpang susun menghasilkan 1.422 poligon, dengan 1.297 poligon, atau 91,2%, lebih kecil dari MLA 0,4 ha. Angka ini mirip dengan ilustrasi Gambar 3.5 di Modul 3, yang memperingatkan gejala yang sama. Peta seperti ini tidak terbaca pada skala 1:10.000.

Tahap 5: Generalisasi Sesuai Skala

1. Pilih layer `smu_mentah`, lalu klik **Select Features by Expression** (Ctrl+F3) dan masukkan ekspresi berikut.

```
"luas_ha" < 0.4
```

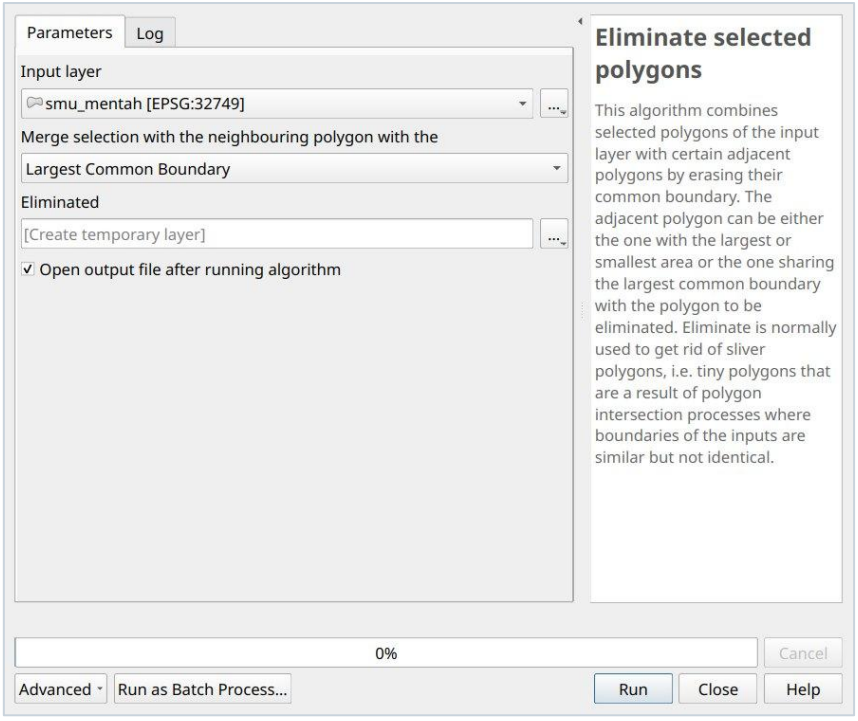

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P2.21 Poligon yang lebih kecil dari MLA terpilih

Sumber: Tangkapan layar uji coba

2. Cari **Eliminate selected polygons** di Processing Toolbox. Isi **Input layer** `smu_mentah` dan **Merge selection with the neighbouring polygon with the** *Largest Common Boundary*, lalu **Run**.



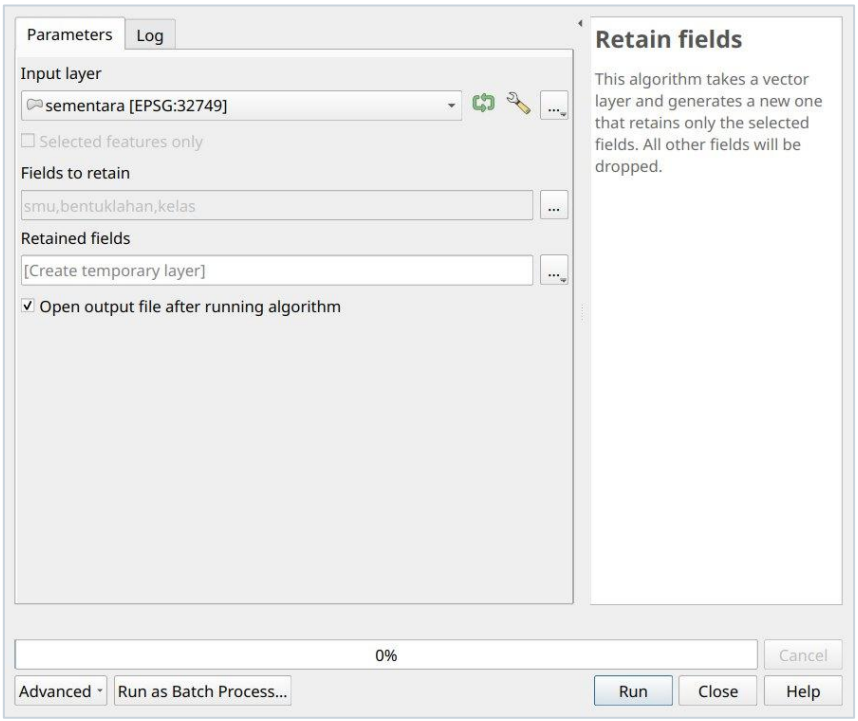
Gambar P2.22 Dialog Eliminate Selected Polygons

Sumber: Tangkapan layar uji coba

3. Hitung ulang `luas_ha` dengan **Field calculator** pada hasilnya, memakai nama kolom yang sama. Periksa dengan ekspresi yang sama bahwa tidak ada lagi poligon di bawah 0,4 ha. Jika masih ada, ulangi langkah 2.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

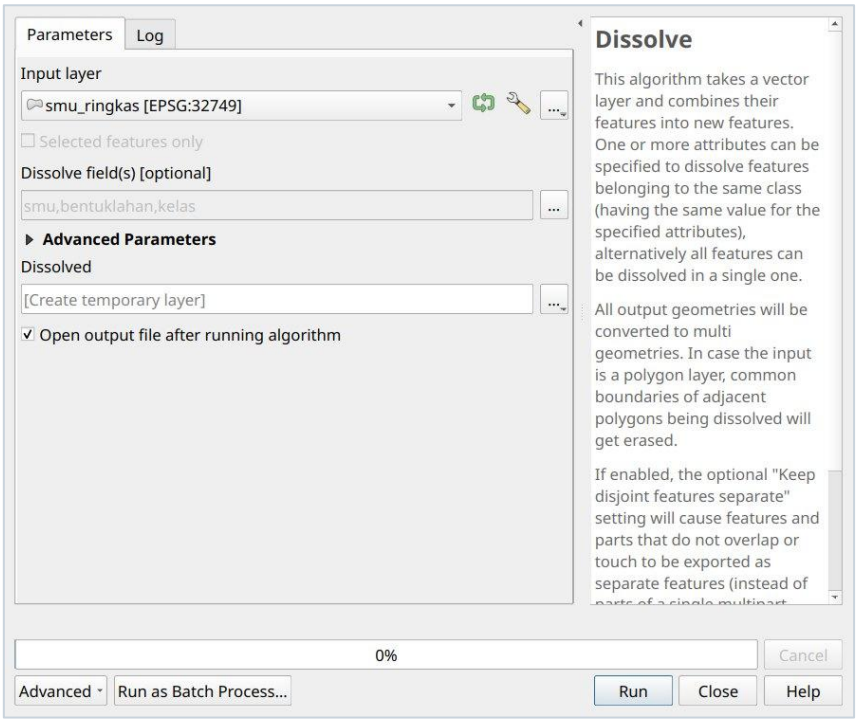
4. Jalankan **Retain fields** dan pertahankan `smu`, `bentuklahan`, dan `kelas`. Langkah ini membuang kolom `fid` lama, yang akan menimbulkan galat saat menyimpan ke GeoPackage pada langkah berikutnya.



Gambar P2.23 Dialog Retain Fields

Sumber: Tangkapan layar uji coba

5. Pilih **Vector > Geoprocessing Tools > Dissolve**. Pilih kolom `smu`, `bentuklahan`, dan `kelas` pada **Dissolve field(s)**. Di **Advanced Parameters**, centang **Keep disjoint features separate**, supaya poligon yang tidak bersentuhan tetap terpisah.

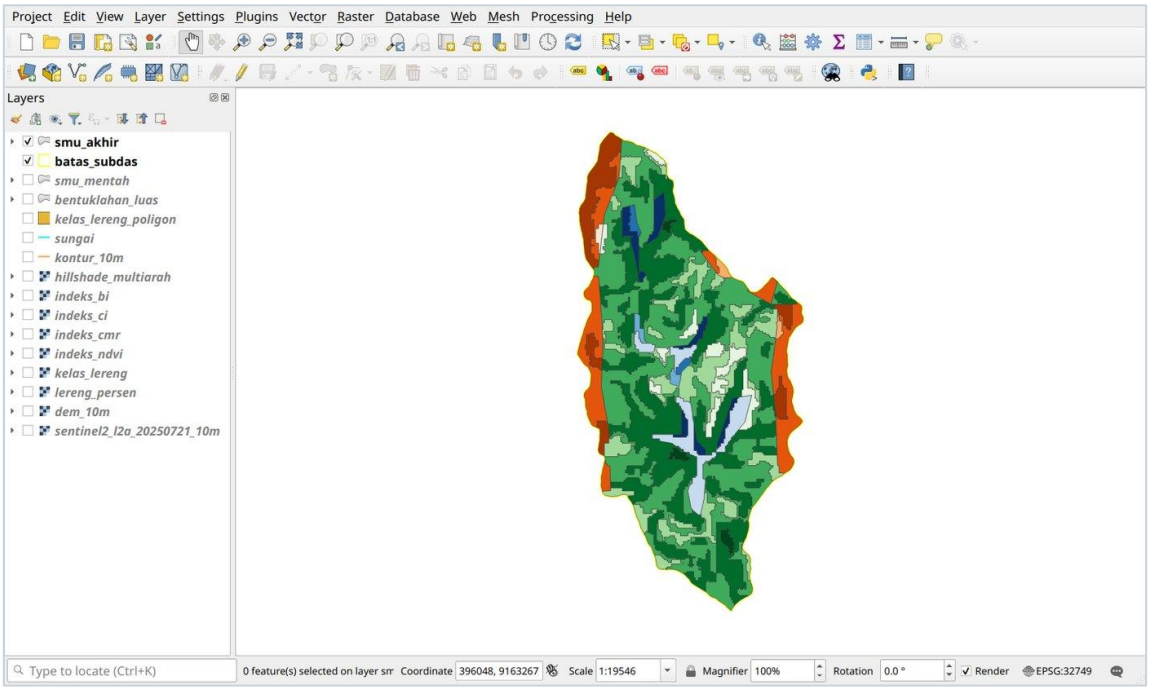


Gambar P2.24 Dialog Dissolve

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

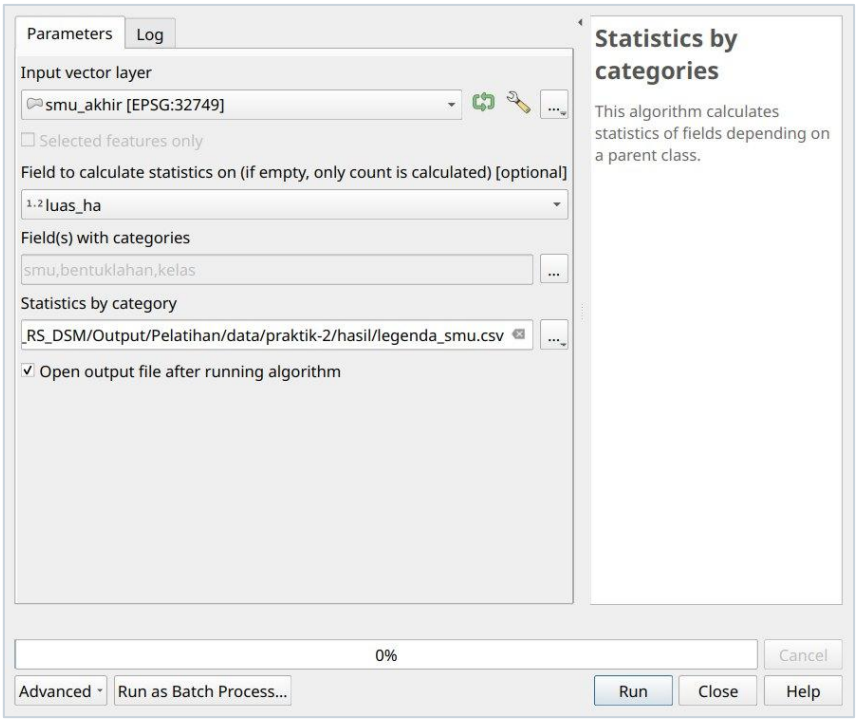
6. Hitung `luas_ha` sekali lagi, lalu simpan ke `hasil/smu_akhir.gpkg`.



Gambar P2.25 Peta SMU setelah generalisasi

Sumber: Tangkapan layar uji coba; satuan merupakan hipotesis untuk latihan

7. Cari **Statistics by categories**. Isi **Input vector layer** `smu_akhir`, **Field to calculate statistics on** `luas_ha`, dan **Field(s) with categories** `smu`, `bentuklahan`, `kelas`, lalu simpan ke `hasil/legenda_smu.csv`.



Gambar P2.26 Membuat legenda SMU dengan Statistics by Categories

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P2.5 Legenda SMU Contoh Hasil Uji Coba

SMU	Satuan bentuklahan	Kelas lereng	Poligon	Luas (ha)
K1	Kaki lereng dan dataran koluvial	0–8%	4	11,86
K2	Kaki lereng dan dataran koluvial	8–15%	2	1,46
K3	Kaki lereng dan dataran koluvial	15–25%	2	1,51
K4	Kaki lereng dan dataran koluvial	25–45%	6	7,47
L1	Lereng perbukitan	0–8%	9	9,33
L2	Lereng perbukitan	8–15%	24	34,72
L3	Lereng perbukitan	15–25%	20	98,13
L4	Lereng perbukitan	25–45%	20	86,51
L5	Lereng perbukitan	>45%	3	2,12
P1	Punggung dan interfluve	0–8%	1	0,63
P2	Punggung dan interfluve	8–15%	2	1,13
P3	Punggung dan interfluve	15–25%	7	25,11
P4	Punggung dan interfluve	25–45%	5	14,73
Jumlah			**105**	**294,71**

Sumber: Hasil uji coba; kolom `count` dan `sum` pada `legenda_smu.csv`

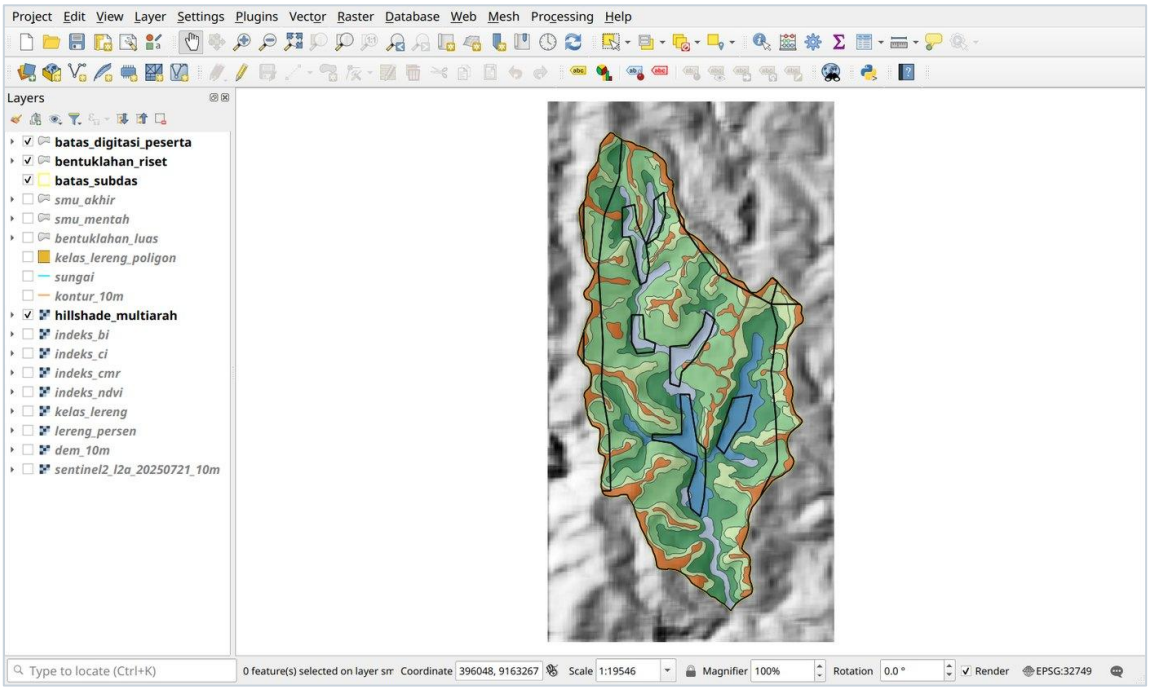
Titik periksa. Pada contoh uji coba, jumlah poligon turun dari 1.422 menjadi 105, dengan poligon terkecil 0,41 ha, dan jenis SMU turun dari 15 menjadi 13. Jumlah poligon akhir dapat berbeda sedikit setiap kali dijalankan. Pada tiga kali uji ulang dengan masukan yang sama, hasilnya 102 sampai 105 poligon, karena urutan penggabungan pada Eliminate tidak selalu sama. Dua jenis yang hilang adalah kelas lereng paling curam pada satuan kaki lereng dan satuan punggung. Modul 3 sudah memperingatkan hal ini: penggabungan menurut ukuran tidak mempertimbangkan makna pedologis, sehingga satuan kecil yang kontras dapat hilang. Dalam pekerjaan sungguhan, satuan seperti itu dapat dipertahankan sebagai simbol titik.

Tahap 6: Membandingkan dengan Peta Riset

1. Muat `pembanding/peta_riset.gpkg`, lalu pilih layer `bentuklahan`. Layer `kelas_lereng` sangat berat untuk digambar, sehingga jangan dicentang.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. Tampilkan `bentuklahan` sebagai **Categorized**, dengan batas digitasi Anda sebagai garis di atasnya.



Gambar P2.27 Batas digitasi uji coba (garis hitam) di atas peta bentuklahan riset

Sumber: Tangkapan layar uji coba; peta bentuklahan dari data riset Sub-DAS Bompon

3. Untuk mendapat angka, jalankan **Intersection** antara `bentuklahan_luas` dan `bentuklahan` riset, hitung luasnya, lalu rangkum dengan **Statistics by categories**.

Tabel P2.6 Perbandingan Luas Delineasi Uji Coba dengan Bentuklahan Riset (ha)

Delineasi uji coba	Interfluve	Lereng atas, tengah, bawah	Lereng kaki koluvial dan dataran koluvial	Jumlah
Punggung dan interfluve	12,80	30,77	0,00	43,57
Lereng perbukitan	26,59	177,51	20,51	224,61
Kaki lereng dan dataran koluvial	0,21	6,62	19,67	26,50
Jumlah	39,60	214,90	40,18	294,68

Sumber: Hasil uji coba, tiga satuan dibandingkan dengan padanannya pada enam satuan riset

Sekitar 71% luas berada pada satuan yang sepadan (12,80 + 177,51 + 19,67 = 209,98 ha), tetapi angka itu didominasi oleh lereng perbukitan yang memang luas. Satuan kaki lereng cukup baik: 74% luasnya memang koluvial menurut peta riset, walaupun separuh koluvial riset belum tertangkap. Satuan punggung paling lemah: hanya 29% luasnya yang merupakan interfluve menurut peta riset, dan sebagian besar sisanya adalah lereng. Dari DEM 30 m, puncak yang sempit sulit dipisahkan dari lereng di sebelahnya, dan koridor punggung yang digambar pada uji coba kemungkinan terlalu lebar.

Peta riset juga bukan kebenaran mutlak. Peta itu merupakan hasil survei lain dengan data yang lebih rinci. Yang diuji di lapangan adalah keduanya.

4. Lihat tabel atribut `kelas_lereng` pada peta riset, dan bandingkan kolom `luas_ha` dengan luas dari DEM 30 m. Luas dari DEM dapat dihitung dengan **Zonal histogram** pada `kelas_lereng` Anda dengan zona `batas_subdas`, lalu mengalikan jumlah piksel dengan 0,01 ha.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P2.7 Luas Kelas Lereng dari DEM 30 m dan dari LiDAR (ha)

Kelas lereng	Copernicus DEM 30 m	Peta riset, dari LiDAR
0–8%	31,14	102,99
8–15%	56,93	63,14
15–25%	109,66	74,52
25–45%	91,69	50,68
>45%	5,27	3,34

Sumber: Hasil uji coba dan layer `kelas_lereng`; kelas riset diturunkan dari DTM LiDAR

Perbedaannya mencolok. Peta riset mencatat 103 ha lahan 0–8%, sedangkan DEM global hanya 31 ha. Penjelasan yang mungkin adalah bahwa model medan LiDAR menangkap permukaan tanah termasuk teras dan dasar lembah yang datar, sedangkan Copernicus DEM adalah model permukaan yang memuat tajuk, dan pada 30 m teras seperti itu tidak terekam. Tafsiran ini belum diuji di lapangan. Yang pasti, peta lereng dari data global tidak dapat diperlakukan sebagai pengganti LiDAR, dan akibatnya pada kebun dapat besar jika kelas lereng dipakai untuk menentukan kesesuaian atau konservasi.

Bahan Diskusi

1. Di mana batas digitasi Anda paling berbeda dari peta riset, dan petunjuk apa yang Anda pakai di tempat itu?
2. Sesudah generalisasi, satuan mana yang hilang? Apakah satuan itu penting bagi pengelolaan?
3. Apa yang berubah jika skala sasaran 1:25.000, dengan MLA 2,5 ha?
4. Di kebun sawit, batas blok dan jalan sangat jelas pada citra. Bagaimana menghindari batas SMU yang hanya mengikuti batas blok?

SMU pada latihan ini tetap hipotesis, sampai diuji dengan pengamatan tanah. Praktik 5 akan menumpangkan peta prediksi tutupan material di atas peta ini, dan pada Tahap 8 praktik tersebut akan terlihat seberapa jauh satuan bentuklahan pada peta SMU benar-benar memisahkan kelas bahan induk.

Jika Tertinggal

Semua keluaran uji coba tersedia di `data/praktik-2/hasil-contoh/`, termasuk `Praktik_2_selesai.qgz`. Delineasi pada folder itu adalah tafsiran penyusun untuk latihan, tanpa pengamatan lapangan, dan klik digitasinya dijalankan secara otomatis pada alat **Add Polygon Feature** saat uji coba. Peserta yang belum selesai mendigitasi dapat memakai `bentuklahan_luas.gpkg` dari folder tersebut untuk tahap 4.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Kurikulum Pembelajaran

Praktik 3. Proximal Soil Sensing

Pemandu: Pak Pandu, didampingi Nurarfiyah. Perangkat: ASD FieldSpec 4 dan Jupyter Notebook. Rujukan teori: Modul 7 dan Modul 4.

Tujuan

Membekali peserta agar memahami bagaimana spektrum pantulan dari ASD FieldSpec 4 diubah menjadi komposisi tekstur tanah, bagaimana menilai model kalibrasinya secara jujur, dan bagaimana memakai model itu untuk sampel tanah yang belum dianalisis di laboratorium.

Kompetensi

Setelah mengikuti praktik ini, peserta memiliki kompetensi dalam:

1. Mengenali prosedur pengukuran spektrum pantulan tanah
2. Membaca spektrum dan fitur serapan
3. Menerapkan praolah SNV, MSC, penghalusan Savitzky–Golay, dan turunan pertama
4. Memodelkan komposisi tekstur dengan transformasi ILR, PLSR, dan *random forest*
5. Membaca ukuran ketelitian per fraksi dan kepentingan wilayah spektrum
6. Memakai model tersimpan untuk sampel tanah baru dan menilai batas keberlakuannya

Ringkasan Studi

1. Deskripsi singkat
   - Peserta mengikuti demonstrasi pengukuran dengan ASD FieldSpec 4
   - Peserta membaca spektrum 69 sampel lapisan atas dari pustaka spektral Site Gunung Madu Plantation
   - Peserta melatih model komposisi tekstur dan menilai hasilnya per fraksi
   - Peserta memakai model tersimpan untuk menduga tekstur sampel yang belum dianalisis di laboratorium
2. Hasil belajar
   - Peserta memahami bahwa alat merekam spektrum, sedangkan nilai tanah datang dari model
   - Peserta mampu menilai klaim akurasi model spektroskopi
3. Indikator hasil belajar
   - Notebook berjalan sampai akhir tanpa galat dalam satu sampai dua menit
   - Setiap prediksi tekstur berjumlah 100%
   - Berkas model `model_tekstur_lapisan1.joblib` dan prediksi sampel baru terbentuk di folder `hasil/`
   - Peserta dapat menjelaskan mengapa satu nilai R^2 dari 14 sampel uji belum cukup untuk menilai model
4. Materi pokok
   - Spektroskopi vis-NIR dan fitur serapan

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

- Praolah spektrum
- Data komposisi dan transformasi ILR
- PLSR, *random forest*, dan pemilihan model tanpa mengintip data uji
- Pemakaian model untuk sampel baru dan batas keberlakuannya

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambaran Praktik

Ada satu hal yang perlu dipegang sejak awal: spektroradiometer seperti ASD FieldSpec 4 merekam **spektrum pantulan** (*reflectance spectrum*), bukan nilai sifat tanah. Layar alat tidak akan menampilkan kadar lempung atau pasir. Angka-angka itu baru diperoleh setelah spektrum dihubungkan dengan hasil laboratorium melalui model kalibrasi (*calibration model*), seperti pada Gambar 7.4 di Modul 7.

Praktik ini karena itu memiliki dua bagian. Bagian pertama adalah demonstrasi pengukuran oleh Pak Pandu dengan ASD FieldSpec 4. Bagian kedua membawa peserta ke tahap sesudah pengukuran, yaitu mengubah spektrum menjadi tekstur tanah dengan notebook Jupyter. Notebook memakai pustaka spektral (*spectral library*) yang sudah tersedia, karena membuat model tidak mungkin dari beberapa sampel yang diukur saat demonstrasi. Seluruh praktik dirancang untuk satu sesi 60 menit, yaitu sekitar 20 menit demonstrasi, 30 menit notebook, dan 10 menit diskusi. Notebook sendiri hanya memerlukan satu sampai dua menit untuk dijalankan, sehingga sebagian besar waktunya dipakai untuk membaca hasil.

Sasaran notebook adalah tekstur lapisan atas (*topsoil texture*), yaitu persentase lempung (*clay*), debu (*silt*), dan pasir (*sand*). Ketiganya adalah data komposisi (*compositional data*) yang jumlahnya selalu 100%, sehingga prediksinya pun harus berjumlah 100%. Pesan terpenting dari notebook bukan tentang algoritme, melainkan tentang cara menilai. Dengan 69 sampel, perbedaan antara praolah dan antara algoritme ternyata lebih kecil daripada keragaman akibat cara data dibagi. Notebook diakhiri dengan cara memakai model yang sudah jadi untuk sampel tanah yang belum dianalisis di laboratorium, beserta batas keberlakuannya.

Data yang Dipakai

Tabel P3.1 Berkas Praktik 3

Berkas	Isi
`Praktik_3_Spektrum_ke_Sifat_Tanah.ipynb`	Notebook praktik
`spektra_visnir_gmp.csv.gz`	Pustaka spektral vis-NIR 350–2.500 nm: satu spektrum untuk setiap 274 sampel dari 71 profil, disertai hasil laboratorium seperti tekstur, pH, C-organik, N total, KTK, dan hara tersedia
`spektrum_sampel_baru.csv`	Contoh (*dummy*) berkas spektrum sampel baru, berisi 10 spektrum dari pustaka yang sama tanpa kolom laboratorium

Sumber: Disiapkan dari berkas `data spectro geo.csv`

Pustaka ini merupakan hasil pengujian sampel tanah dari Site Gunung Madu Plantation (GMP), Lampung, jadi **bukan** data Sub-DAS Bompon. Tanah lapisan atasnya jauh lebih berpasir (rata-rata pasir 51% dan lempung 37%) daripada tanah Bompon (pasir 16% dan lempung 62%). Kode `S3 L1` ditafsirkan sebagai profil S3 lapisan 1. Rentang 350–2.500 nm dan 2.151 kanalnya sama dengan spesifikasi ASD FieldSpec 4. Model pada notebook dilatih dari tanah GMP, sehingga berguna untuk latihan, tetapi untuk tanah dari tempat lain hasilnya hanya pendekatan. Modul 7 menjelaskan alasannya: prediksi dari pustaka yang bukan lokal cenderung bias untuk satu kebun.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Ada tiga catatan tentang data yang dipakai:

1. **Hanya lapisan 1**, yaitu 71 sampel lapisan atas. Lapisan dari profil yang sama saling mirip, sehingga jika semua lapisan dipakai, pembagian acak dapat menempatkan lapisan dari satu profil di data latih sekaligus data uji. Dengan satu sampel per profil, masalah itu tidak muncul.
2. **Sampel tanpa hasil laboratorium**, yaitu S73 L1 dan S45 L1. Keduanya tidak ikut melatih model, sehingga tersisa 69 sampel. Spektrum keduanya, ditambah delapan sampel lapisan 4 yang dipilih acak, disalin ke `spektrum_sampel_baru.csv` sebagai contoh sampel baru pada akhir notebook.
3. **Jumlah fraksi**, yang pada berkas sumber berkisar 100,00–100,10% karena pembulatan. Setiap sampel dinormalisasi agar jumlahnya tepat 100%, dengan perbandingan antarfraksi yang tetap. Berkas sumber tidak mencantumkan satuan, sehingga tekstur dibaca sebagai persen dari besarnya nilai.

Bagian 1: Demonstrasi Pengukuran

Bagian ini dipandu langsung oleh Pak Pandu dengan ASD FieldSpec 4, yaitu spektroradiometer portabel yang merekam seluruh rentang tampak sampai inframerah gelombang pendek.

Tabel P3.2 Spesifikasi ASD FieldSpec 4

Spesifikasi	Nilai
Rentang panjang gelombang	350–2.500 nm, 2.151 kanal
Resolusi spektral VNIR (700 nm)	3 nm
Resolusi spektral SWIR (1.400 dan 2.100 nm)	6–10 nm
Interval sampling	1,4 nm (VNIR), 1,1 nm (SWIR)
Kecepatan	Waktu pindai 100 milidetik, 2 spektrum per detik
Detektor	Silikon 512 elemen untuk VNIR (350–1.000 nm); fotodioda InGaAs untuk SWIR 1 (1.000–1.800 nm) dan SWIR 2 (1.800–2.500 nm)
Masukan	Serat optik 1,5 m dengan bidang pandang 25°
Berat	5,44 kg

Sumber: SciAps (2025)

Brosur alat mencantumkan antara lain *contact probe*, *muglight*, *turntable*, dan panel referensi putih (SciAps, 2025). Ada satu hal yang sering disalahpahami pada tabel tersebut. Jumlah 2.151 kanal berarti nilai tersedia setiap 1 nm, tetapi kemampuan alat membedakan fitur ditentukan oleh resolusi spektralnya, yaitu 3 nm di VNIR dan 6–10 nm di SWIR.

Saat mengikuti demonstrasi, perhatikan hal-hal berikut:

1. **Komponen alat**, yaitu spektrometer, serat optik, sumber cahaya, dan wadah atau pemegang sampel.
2. **Pengukuran referensi**, yaitu bagaimana panel putih dipakai sebelum mengukur sampel, dan seberapa sering langkah ini diulang.
3. **Penyiapan sampel**, yaitu apakah tanah dikeringkan, dihaluskan, dan diayak, karena Modul 7 menunjukkan bahwa kondisi sampel memengaruhi spektrum.
4. **Ulangan**, yaitu berapa kali satu sampel dipindai dan seberapa mirip hasilnya. Pustaka pada notebook hanya memuat satu spektrum untuk setiap sampel, sehingga keragaman ini hanya dapat dilihat pada demonstrasi.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Keempat hal tersebut menentukan apakah spektrum dari hari yang berbeda, atau dari kebun yang berbeda, masih dapat dibandingkan. Pada giliran mencoba alat, bandingkan spektrum dua sampel yang warnanya jelas berbeda, lalu cari perbedaannya pada bentuk kurva.

Bagian 2: Membuka Notebook

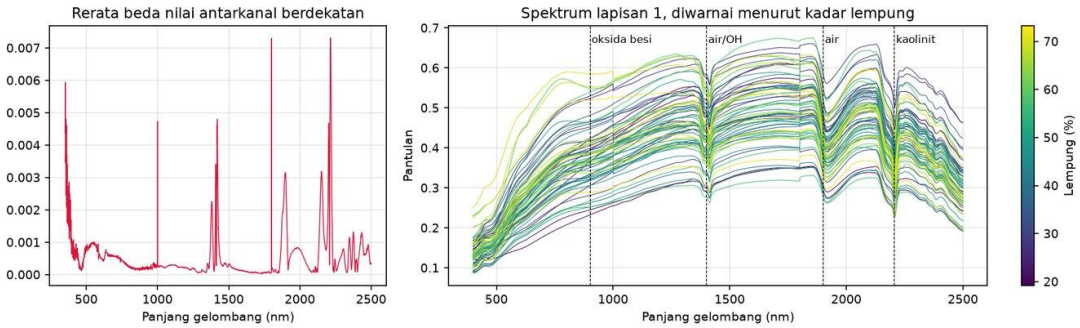
1. Buka JupyterLab atau Google Colab seperti pada Modul Persiapan.
2. Masuk ke folder `data/praktik-3/`, lalu buka `Praktik_3_Spektrum_ke_Sifat_Tanah.ipynb`.
3. Jalankan sel satu per satu dengan **Shift + Enter**, dan baca keluarannya sebelum lanjut. Pada uji coba, seluruh notebook selesai dalam 93 detik.

Notebook sudah menyimpan keluaran hasil uji coba sebagai pembanding. Menjalankan ulang sel akan menimpanya, dan gambar serta tabel Anda tersimpan di folder `hasil/`.

Bagian 3: Membaca Spektrum

Jalankan bagian 1 sampai 4 pada notebook.

Keluaran pertama menunjukkan 274 sampel dari 71 profil, dengan 71 sampel pada lapisan 1. Sebanyak 69 di antaranya memiliki hasil tekstur. Sel berikutnya memeriksa derau (*noise*). Di bawah 400 nm, beda nilai antarkanal yang berdekatan rata-rata 0,00236, atau empat kali lipat daripada 0,00054 pada 400–2.500 nm. Nilai yang melompat-lompat itu menandakan derau, sehingga pemodelan hanya memakai 400–2.500 nm. Undakan kecil di 1.000 nm dan 1.800 nm bukan sifat tanah, melainkan batas antara tiga detektor alat (SciAps, 2025).



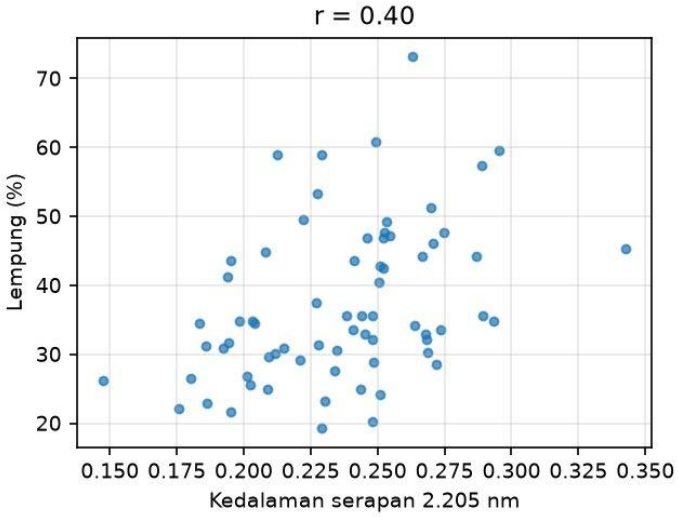
Gambar P3.1 Derau antarkanal (kiri) dan spektrum 69 sampel lapisan 1 yang diwarnai menurut kadar lempung (kanan)

Sumber: Hasil uji coba

Lembah pada spektrum disebut fitur serapan (*absorption feature*). Lembah di sekitar 1.400 dan 1.900 nm berasal dari air dan gugus hidroksil, sedangkan lembah sempit di sekitar 2.205 nm berasal dari kaolinit

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

(Molin & Tavares, 2019). Notebook kemudian mengukur kedalaman serapan (*absorption depth*) kaolinit itu terhadap garis kontinum (*continuum*) sederhana dan membandingkannya dengan kadar lempung.



Gambar P3.2 Kedalaman serapan 2.205 nm terhadap kadar lempung

Sumber: Hasil uji coba

Kedalaman serapan di 2.205 nm berkorelasi r = 0,40 dengan kadar lempung. Hubungan itu nyata, tetapi sebarannya lebar, sehingga satu fitur tidak cukup untuk menduga tekstur. Kedalaman serapan bergantung pada jenis mineral lempung, dan spektrum dipengaruhi banyak hal sekaligus. Inilah alasan model memakai seluruh spektrum, bukan satu panjang gelombang.

Bagian 4: Praolah dan Data Komposisi

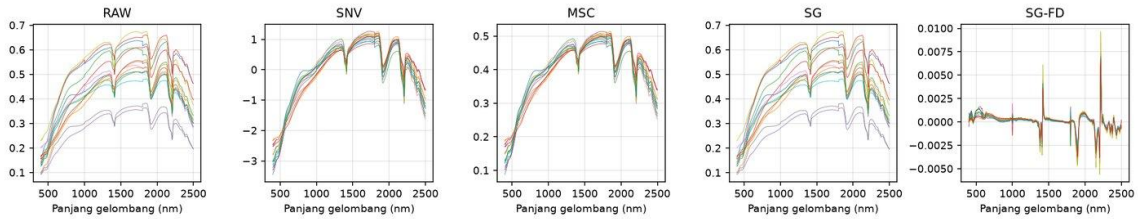
Jalankan bagian 5 sampai 7.

Data dibagi sekali secara acak (*random train-test split*) menjadi 55 sampel latih (*training set*) dan 14 sampel uji (*test set*). Pembagian yang sama dipakai untuk semua praolah dan algoritme, dan data uji tidak disentuh sampai penilaian akhir. Lima praolah (*preprocessing*) dicoba:

1. **RAW**, yaitu pantulan apa adanya.
2. **SNV** (*Standard Normal Variate*), yaitu setiap spektrum dikurangi rata-ratanya lalu dibagi simpangan bakunya, sehingga kurva yang berbeda kecerahan dirapatkan (Barnes et al., 1989).
3. **MSC** (*Multiplicative Scatter Correction*), yaitu setiap spektrum diregresikan terhadap spektrum acuan, lalu dikoreksi dengan potongan dan kemiringannya (Geladi et al., 1985). Spektrum acuan dihitung dari data latih saja, agar tidak ada informasi dari data uji yang ikut masuk.
4. **SG**, yaitu penghalusan Savitzky–Golay (*Savitzky–Golay smoothing*) dengan jendela 11 kanal (Savitzky & Golay, 1964).

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

5. **SG-FD**, yaitu turunan pertama (*first derivative*) Savitzky–Golay, yang menonjolkan posisi fitur serapan.



Gambar P3.3 Contoh spektrum lapisan 1 dengan lima praolah

Sumber: Hasil uji coba

Bagian 7 pada notebook menjelaskan mengapa tekstur perlu diperlakukan sebagai komposisi. Jika lempung, debu, dan pasir dimodelkan dengan tiga model regresi kuadrat terkecil parsial (*Partial Least Squares Regression*, PLSR) yang terpisah, jumlah prediksinya pada 14 sampel uji berkisar 98,7–101,6%. Selisih itu kecil pada data ini, tetapi tidak ada yang menjaminnya. Pada tanah dengan salah satu fraksi yang sangat kecil, prediksi terpisah dapat bernilai negatif atau berjumlah jauh dari 100%.

Transformasi log-rasio isometrik (*isometric log-ratio*, ILR) mengatasi persoalan itu (Egozcue et al., 2003). Tiga persentase diubah menjadi dua koordinat log-rasio, yaitu $ilr_1 = \sqrt{(1/2)} \cdot \ln(\text{lempung} / \text{debu})$ dan $ilr_2 = \sqrt{(2/3)} \cdot \ln(\sqrt{(\text{lempung} \cdot \text{debu})} / \text{pasir})$. Kedua koordinat itu bebas bernilai berapa saja, sehingga dapat dimodelkan seperti peubah biasa. Model memprediksi kedua koordinat, lalu hasilnya dikembalikan menjadi persentase. Hasil kebalikan ILR selalu positif dan selalu berjumlah 100%, dan notebook memeriksa bahwa transformasi bolak-balik mengembalikan data asli dengan tepat.

Bagian 5: Membandingkan dan Memilih Model

Jalankan bagian 8 dan 9.

Dua algoritme dilatih pada setiap praolah. PLSR meringkas ribuan kanal menjadi beberapa komponen laten (*latent variables*; Wold et al., 2001), dan jumlah komponennya dipilih dengan validasi silang (*cross-validation*) pada data latih. *Random forest* menggabungkan banyak pohon keputusan (*decision trees*; Breiman, 2001) dengan pengaturan yang sama untuk semua praolah. Untuk setiap kombinasi, notebook menghitung dua hal. Galat akar rata-rata kuadrat (*root mean square error*, RMSE) validasi silang dihitung hanya dari data latih, dengan 5 lipatan (*fold*) yang diulang 3 kali, dan dipakai untuk memilih kombinasi. Ukuran pada data uji dihitung terpisah untuk setiap fraksi.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P3.3 Hasil Lima Praolah dan Dua Algoritme

Praolah	Algoritme	R^2 lempung	R^2 debu	R^2 pasir	RMSE lempung	RMSE debu	RMSE pasir	Komponen PLSR	RMSE validasi silang
RAW	PLSR	0,60	−0,36	0,44	8,97	7,89	12,22	2	8,44
RAW	*Random forest*	0,21	−0,14	0,21	12,61	7,23	14,57	–	9,75
SNV	PLSR	0,54	−0,54	0,65	9,58	8,42	9,64	6	8,36
SNV	*Random forest*	0,70	0,03	0,59	7,73	6,68	10,52	–	8,63
MSC	PLSR	0,68	0,18	0,76	8,03	6,14	8,09	5	8,47
MSC	*Random forest*	0,69	0,05	0,57	7,92	6,61	10,77	–	8,53
SG	PLSR	0,60	−0,36	0,44	8,97	7,89	12,22	2	8,44
SG	*Random forest*	0,22	−0,14	0,22	12,52	7,23	14,51	–	9,72
SG-FD	PLSR	0,45	−0,17	0,29	10,55	7,34	13,85	3	8,42
SG-FD	*Random forest*	0,54	0,13	0,59	9,58	6,33	10,47	–	8,86

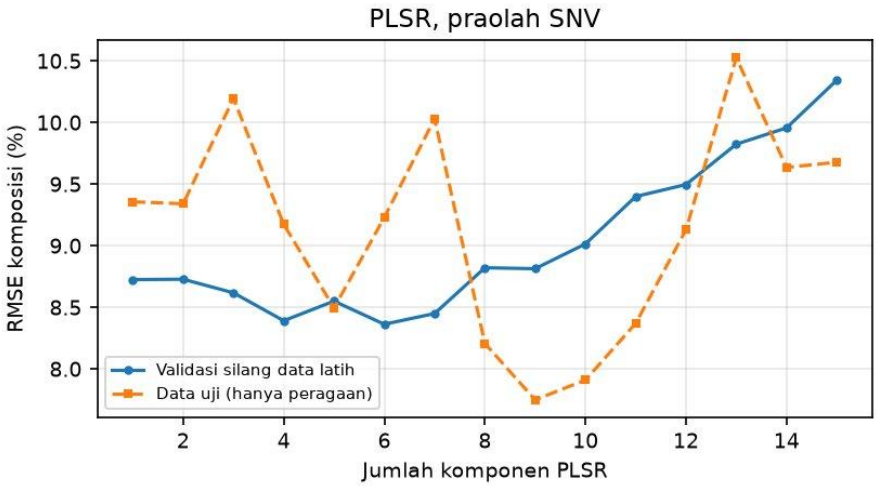
Sumber: Hasil uji coba; R^2 dan RMSE (poin persen) dari 14 sampel uji, RMSE validasi silang dari 55 sampel latih

Bacalah tabel ini per kolom. Pertama, debu hampir selalu gagal diduga, dengan R^2 di bawah atau sedikit di atas nol. Kadarnya hanya 3–24% dan keragamannya kecil, sedangkan lempung dan pasir lebih mudah diduga. Kedua, penghalusan SG memberi hasil yang hampir sama dengan pantulan mentah, karena jendela 11 kanal pada spektrum berinterval 1 nm hampir tidak mengubah bentuk kurva. Ketiga, *random forest* sangat bergantung pada praolah, sedangkan PLSR lebih stabil. Keempat, urutan menurut data uji tidak sama dengan urutan menurut validasi silang. MSC dengan PLSR tampak paling baik pada data uji, tetapi hanya berada di urutan kelima menurut validasi silang.

Godaannya adalah memilih kombinasi dengan R^2 uji tertinggi, lalu melaporkan R^2 itu. Cara itu curang, karena informasi data uji ikut bocor ke dalam pemilihan model (*data leakage*). Notebook memilih dari validasi silang data latih, dan pilihan jatuh pada SNV dengan PLSR 6 komponen. Lima kombinasi teratas

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

hanya berselisih 0,11 poin persen, yaitu 8,36–8,47, sehingga selisih sekecil itu tidak perlu dibaca sebagai keunggulan SNV atau PLSR.



Gambar P3.4 RMSE terhadap jumlah komponen PLSR pada praolah SNV, dari validasi silang data latih dan dari data uji

Sumber: Hasil uji coba; garis data uji hanya untuk peragaan

Godaan yang sama terlihat pada jumlah komponen di Gambar P3.4. Validasi silang memilih 6 komponen, dengan RMSE uji 9,23 poin persen. Garis data uji mencapai minimum pada 9 komponen dengan RMSE 7,75. Jika 9 komponen dipilih karena garis itu, angka uji akan tampak lebih baik, tetapi tidak lagi jujur, karena model sudah disesuaikan dengan 14 sampel yang seharusnya mewakili sampel baru.

Tabel P3.4 Ketelitian Model Terpilih pada Data Uji

Fraksi	R	R^2	RMSE (%)	nRMSE (%)	MAE (%)	MAPE (%)
Lempung	0,75	0,54	9,58	18,08	6,78	17,72
Debu	0,42	−0,54	8,42	45,84	7,13	70,67
Pasir	0,82	0,65	9,64	14,61	7,07	19,89

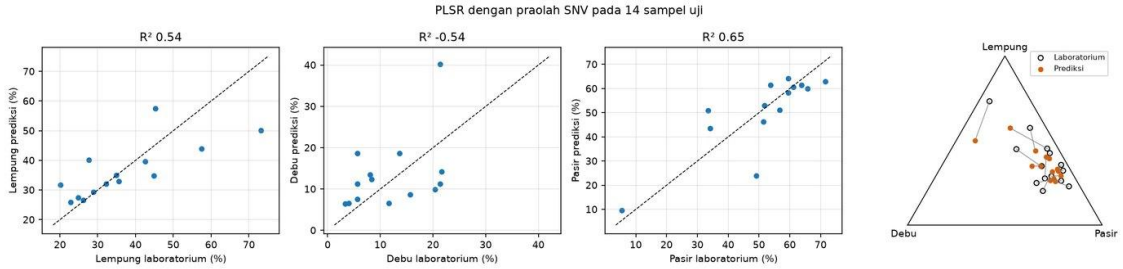
Sumber: Hasil uji coba, SNV dan PLSR 6 komponen pada 14 sampel uji

Ukuran pada Tabel P3.4 juga menunjukkan mengapa satu ukuran tidak cukup. R adalah koefisien korelasi Pearson (*Pearson correlation coefficient*), yang mengukur seberapa searah prediksi dengan nilai laboratorium. R^2 adalah koefisien determinasi (*coefficient of determination*), yang mengukur kedekatan prediksi dengan garis 1:1 dan sama dengan MEC pada Modul 8. RMSE dan galat absolut rata-rata (*mean absolute error*, MAE) menyatakan besar galat dalam poin persen, nRMSE (*normalized RMSE*) adalah RMSE yang dibagi jangkauan nilai uji, sedangkan MAPE (*mean absolute percentage error*) adalah rata-rata galat relatif. Debu memiliki korelasi positif (R = 0,42), tetapi R^2-nya negatif. Prediksi yang searah tetapi meleset jauh tetap buruk. MAPE debu yang mencapai 71% juga dibesarkan oleh kadarnya yang kecil, karena galat 7 poin persen pada kadar 10% adalah galat relatif 70%.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Bagian 6: Membaca Hasil

Jalankan bagian 10 sampai 12.

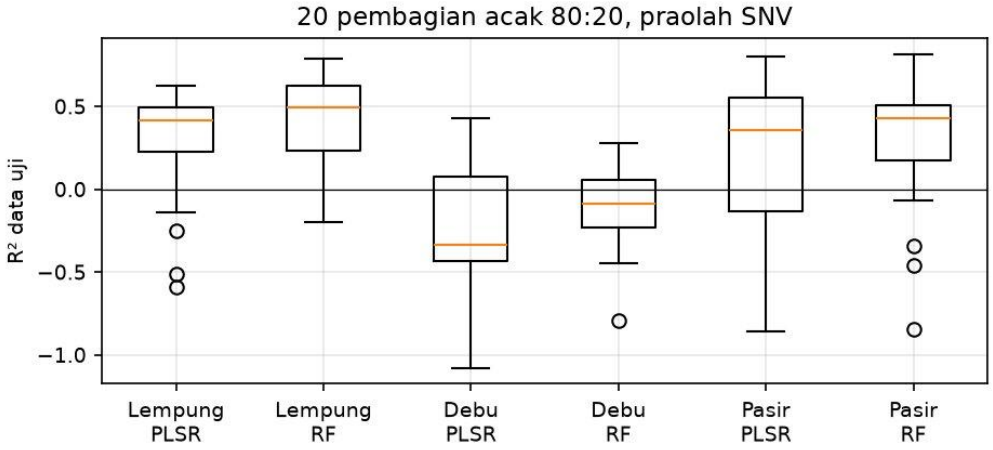


Gambar P3.5 Prediksi terhadap nilai laboratorium untuk setiap fraksi dan pada segitiga tekstur

Sumber: Hasil uji coba, SNV dan PLSR 6 komponen pada 14 sampel uji

Pada segitiga tekstur (*soil texture triangle*), titik kosong adalah nilai laboratorium, titik isi adalah prediksi, dan garis menghubungkan keduanya. Semua prediksi berada di dalam segitiga dan berjumlah tepat 100%, berkat transformasi ILR. Prediksi cenderung tertarik ke tengah sebaran, sehingga sampel yang sangat berlempung atau sangat berpasir diduga kurang ekstrem daripada aslinya.

Bagian 11 mengulang pembagian 80:20 sebanyak 20 kali dengan praolah SNV, untuk PLSR dan *random forest*.



Gambar P3.6 Sebaran R^2 data uji dari 20 pembagian acak

Sumber: Hasil uji coba

Tabel P3.5 R^2 dari 20 Pembagian Acak dengan Praolah SNV

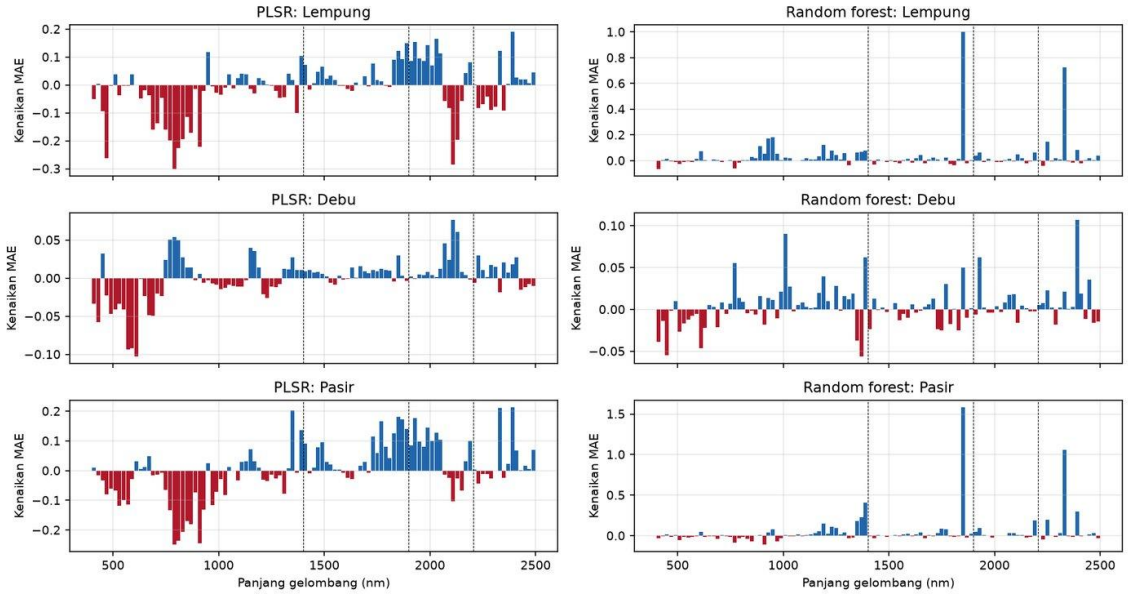
Fraksi	Algoritme	Terendah	Median	Tertinggi
Lempung	PLSR	−0,59	0,42	0,62
Lempung	*Random forest*	−0,20	0,49	0,79
Debu	PLSR	−1,08	−0,34	0,43
Debu	*Random forest*	−0,79	−0,09	0,28
Pasir	PLSR	−0,86	0,36	0,80
Pasir	*Random forest*	−0,85	0,43	0,82

Sumber: Hasil uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Untuk lempung, R^2 dari model yang sama berkisar dari −0,59 sampai 0,62 hanya karena sampel ujinya berbeda. Nilai 0,54 pada Tabel P3.4 berada di dalam rentang itu, tetapi pembagian lain dapat saja memberi kesan yang sangat berbeda. Median *random forest* bahkan sedikit lebih tinggi daripada PLSR, padahal PLSR yang terpilih pada satu pembagian tadi. Dengan 69 sampel, data ini tidak cukup untuk menyatakan bahwa salah satu algoritme lebih baik. Jika sebuah vendor melaporkan akurasi model spektroskopi dari satu pembagian dengan belasan sampel uji, tanyakan berapa sampel ujinya dan bagaimana hasilnya bila pembagian diulang.

Bagian 12 menghitung kepentingan wilayah spektrum dengan permutasi (*permutation importance*) untuk praolah SG-FD, karena turunan pertama menonjolkan posisi fitur serapan sehingga wilayah yang penting lebih mudah dikaitkan dengan fitur tertentu. Nilai satu jendela 20 nm (*spectral window*) pada data uji diacak, lalu diukur kenaikan MAE setiap fraksi. Yang diacak adalah jendela, bukan kanal tunggal, karena kanal yang bersebelahan hampir identik. Jika hanya satu kanal yang diacak, informasinya masih tersedia di kanal tetangganya, sehingga kepentingannya tampak hampir nol. Dengan 105 jendela dan 5 ulangan, perhitungan ini selesai dalam kurang dari setengah menit.



Gambar P3.7 Kenaikan MAE saat setiap jendela 20 nm diacak, untuk PLSR dan *random forest* dengan praolah SG-FD

Sumber: Hasil uji coba; garis putus-putus menandai 1.400, 1.900, dan 2.205 nm

Kedua algoritme memakai spektrum dengan cara yang berbeda. PLSR memakai wilayah yang lebar, terutama 1.850–2.050 nm di sekitar serapan air 1.900 nm dan 2.320–2.400 nm, dengan kenaikan MAE paling besar sekitar 0,2 poin persen. *Random forest* bertumpu pada dua jendela sempit, yaitu 1.840–1.860 nm dan 2.320–2.340 nm. Mengacak jendela pertama menaikkan MAE lempung sebesar 1,0 poin persen dan MAE pasir sebesar 1,6 poin persen. Jendela pertama berada di tepi serapan air 1.900 nm. Wilayah 2.320–2.400 nm tidak termasuk fitur serapan yang dibahas Modul 7, sehingga kaitannya dengan penyusun tanah tertentu perlu diperiksa lebih lanjut. Menariknya, serapan kaolinit di 2.205 nm yang berkorelasi dengan lempung tidak menonjol pada kedua model. Hasil dari 14 sampel uji ini masih kasar, sehingga yang patut diperhatikan adalah wilayah yang konsisten, bukan urutan jendela satu per satu.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Bagian 7: Memakai Model untuk Sampel Tanah Baru

Jalankan bagian 13. Inilah yang terjadi setelah demonstrasi alat. Setelah model jadi, sampel tanah baru cukup diukur spektrumnya tanpa dianalisis di laboratorium. Alurnya terdiri atas lima langkah:

1. **Latih model akhir dan simpan**, yaitu model dilatih ulang dengan seluruh 69 sampel memakai kombinasi terpilih, SNV dan PLSR 6 komponen, lalu disimpan ke `hasil/model_tekstur_lapisan1.joblib`. Berkas itu memuat semua yang diperlukan untuk memakai model, yaitu nama praolah, spektrum acuan MSC, daftar panjang gelombang, dan ringkasan sebaran spektrum pustaka.
2. **Siapkan spektrum baru**, yaitu berkas CSV dengan kolom `sampel` dan kolom pantulan `w350` sampai `w2500`, satu baris untuk setiap sampel. Pantulan dinyatakan sebagai pecahan 0–1 pada setiap 1 nm, seperti pada pustaka. Model sendiri hanya memakai kolom 400–2.500 nm.
3. **Prediksi**, yaitu spektrum baru diberi praolah yang **sama persis** dengan data latih, dimasukkan ke model, lalu hasilnya dikembalikan dari koordinat ILR menjadi persentase. Fungsi `prediksi_tekstur` pada notebook mengerjakan langkah ini dan menghentikan proses bila ada kolom panjang gelombang yang hilang.
4. **Periksa kemiripan dengan pustaka**, karena model hanya dapat dipercaya untuk spektrum yang mirip dengan spektrum yang dipakai melatihnya. Kemiripan diukur dengan jarak Mahalanobis (*Mahalanobis distance*) pada lima komponen utama (*principal component analysis*, PCA) spektrum pustaka, yang meringkas 97,7% keragamannya. Jarak itu dibagi jarak sampel pustaka yang terjauh, sehingga nilai di atas 1 berarti spektrum baru lebih asing daripada sampel pustaka mana pun.
5. **Uji sebagian sampel di laboratorium**, karena kemiripan spektrum tidak menjamin prediksi benar.

Gagasan langkah 4 sama dengan wilayah keberlakuan model pada Modul 8, yaitu prediksi hanya dapat dipercaya di wilayah yang menyerupai data latih. Bedanya, wilayah itu di sini berada dalam ruang spektrum, bukan ruang kovariat.

Berkas `spektrum_sampel_baru.csv` adalah contoh (*dummy*) berkas spektrum sampel baru. Isinya 10 spektrum asli dari pustaka yang sama tanpa kolom laboratorium, yaitu S73 L1 dan S45 L1 yang memang tidak dianalisis, ditambah delapan sampel lapisan 4 yang tidak dipakai melatih model. Untuk sampel Anda sendiri, cukup ganti nama berkas pada baris `pd.read_csv('spektrum_sampel_baru.csv')`. Model tersimpan dapat dipakai lagi di lain waktu tanpa dilatih ulang, yaitu dengan menjalankan bagian 1 notebook, sel fungsi praolah pada bagian 6, sel fungsi ILR pada bagian 7, lalu sel `prediksi_tekstur`.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P3.6 Prediksi Tekstur Sampel pada Berkas Contoh

Sampel	Lempung (%)	Debu (%)	Pasir (%)	Jarak ke pustaka	Mirip pustaka
S73 L1	23,9	11,9	64,2	0,44	ya
S45 L1	25,1	9,4	65,5	0,39	ya
S5 L4	56,0	10,9	33,1	0,69	ya
S15 L4	66,3	14,8	18,9	0,58	ya
S28 L4	60,3	7,9	31,8	0,67	ya
S33 L4	53,6	10,9	35,6	0,48	ya
S49 L4	64,0	23,0	13,0	0,92	ya
S51 L4	45,5	6,3	48,2	0,50	ya
S53 L4	40,5	4,4	55,1	0,54	ya
S61 L4	56,4	24,7	18,9	0,59	ya

Sumber: Hasil uji coba, SNV dan PLSR 6 komponen; tersimpan di `prediksi_sampel_baru.csv`

Kesepuluh sampel dinilai mirip dengan pustaka, dengan jarak 0,39–0,92. Prediksi untuk kedua sampel lapisan 1 tidak dapat diperiksa, dan galatnya kira-kira sebesar RMSE pada Tabel P3.4, yaitu sekitar 10 poin persen untuk lempung dan pasir. Delapan sampel lapisan 4 berbeda keadaannya, karena pustaka sebenarnya memiliki hasil laboratorium untuk sampel-sampel itu, demikian pula untuk semua sampel lapisan 2 sampai 4. Sel terakhir notebook memanfaatkan keadaan ini untuk menguji seberapa jauh model lapisan 1 berlaku bagi tanah lain, dengan memperlakukan semua sampel lapisan bawah sebagai sampel baru.

Tabel P3.7 Ketelitian Model Lapisan 1 pada Sampel Lapisan 2 sampai 4

Lapisan	Sampel	Mirip pustaka (%)	RMSE lempung	Bias lempung	RMSE debu	Bias debu	RMSE pasir	Bias pasir
2	69	100,0	6,0	0,2	4,3	0,4	7,6	−0,6
3	64	95,3	7,9	2,0	4,8	0,0	9,2	−2,0
4	60	80,0	13,7	6,7	5,9	2,9	17,2	−9,5

Sumber: Hasil uji coba; RMSE dan bias dalam poin persen, dengan bias positif berarti prediksi terlalu tinggi; tersimpan di `uji_lapisan_bawah.csv`

Lapisan 2 tampak cukup baik, bahkan lebih baik daripada data uji lapisan 1 pada Tabel P3.4, karena lapisan 2 berasal dari profil yang lapisan 1-nya ikut melatih model. Pada lapisan yang lebih dalam, galat dan biasnya membesar. Pada lapisan 4, lempung rata-rata diduga 6,7 poin persen terlalu tinggi dan pasir 9,5 poin persen terlalu rendah, padahal 80% spektrumnya dinilai mirip dengan pustaka. Kedelapan sampel lapisan 4 pada berkas contoh pun lolos pemeriksaan kemiripan. Jadi, pemeriksaan kemiripan membantu menyaring spektrum yang asing, tetapi tidak menjamin prediksi benar.

Karena itu, setiap kali model dipakai untuk tanah dari kebun atau kedalaman lain, kirim sebagian sampel ke laboratorium dan bandingkan hasilnya dengan prediksi. Bila prediksinya bias, tambahkan sampel setempat ke data kalibrasi, lalu latih ulang modelnya. Modul 7 menyebut cara ini *spiking*, dan pendekatan rs-local menunjukkan bahwa 12–20 sampel lokal yang dipadukan dengan sampel terpilih dari pustaka besar sudah dapat meningkatkan ketelitian dan kekokohan prediksi (England & Viscarra Rossel, 2018). Spektrum hasil demonstrasi dapat dimasukkan dengan cara yang sama, tetapi hasilnya tetap pendekatan, karena model belajar dari tanah GMP.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

> **Titik periksa.** Notebook berjalan sampai bagian 13 tanpa galat, dan folder `hasil/` berisi gambar serta berkas `metrik_per_fraksi.csv`, `kepentingan_jendela_top10.csv`, `model_tekstur_lapisan1.joblib`, `prediksi_sampel_baru.csv`, dan `uji_lapisan_bawah.csv`. Angkanya seharusnya sama dengan tabel di atas.

Jembatan ke Praktik 5

Demonstrasi tadi menghasilkan spektrum. Notebook menunjukkan bagaimana spektrum menjadi tekstur tanah. Pada Praktik 5, logika yang sama, yaitu menghubungkan pengamatan dengan data pendukung melalui model lalu menilainya secara jujur, dipakai untuk sasaran yang berbeda, yaitu kelas tutupan material. Masukannya bukan spektrum melainkan kovariat lingkungan, dan keluarannya bukan nilai satu sampel melainkan peta kelas. Data sensor proksimal yang rapat dapat masuk ke alur itu, baik sebagai data sasaran tambahan maupun sebagai kovariat lokal, sebagaimana dibahas dalam Modul 7 dan Tabel 8.1.

Jika Tertinggal

Notebook pada folder ini sudah memuat keluaran uji coba, sehingga dapat dibaca tanpa dijalankan. Gambar dan tabelnya juga tersedia di `data/praktik-3/hasil-contoh/`.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Kurikulum Pembelajaran

Praktik 4. Bare Soil Detection & Information Extraction

Pemandu: Nurarfiyah. Perangkat: QGIS. Rujukan teori: Modul 5.

Tujuan

Membekali peserta agar mampu mendeteksi tanah terbuka dari citra Sentinel-2, memeriksa hasilnya, dan mengekstraksi informasi tanah hanya dari piksel yang sesuai.

Kompetensi

Setelah mengikuti praktik ini, peserta memiliki kompetensi dalam:

1. Menyingkirkan piksel bermasalah dengan SCL
2. Menghitung NDVI, SAVI, BSI, dan NBR2
3. Menyusun dan membandingkan aturan ambang
4. Memeriksa hasil deteksi dengan peta penggunaan lahan dan bentuk spektrum
5. Mengekstraksi indeks tanah dan menyusun komposit sederhana

Ringkasan Studi

1. Deskripsi singkat
    - Peserta menghitung indeks tanah terbuka pada citra dua tanggal
    - Peserta mencoba tiga aturan ambang dan memeriksanya menurut penggunaan lahan
    - Peserta mengekstraksi indeks dari piksel tanah terbuka dan menyusun komposit dua tanggal
2. Hasil belajar
    - Peserta memahami bahwa ambang indeks tidak berlaku umum
    - Peserta memiliki masker tanah terbuka yang sudah diperiksa
3. Indikator hasil belajar
    - Rekap kandidat tanah terbuka per penggunaan lahan tersusun
    - Masker akhir berisi 75 piksel, atau 0,75 ha, jika memakai aturan yang sama
    - Peserta dapat menjelaskan mengapa sebagian besar kandidat berada di permukiman
4. Materi pokok
    - Kontras spektral tanah, vegetasi, dan serasah
    - Indeks dan ambang tanah terbuka
    - Pemeriksaan mutu hasil deteksi
    - Komposit multitemporal

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambaran Praktik

Modul 5 menjelaskan bahwa citra optik hanya dapat membaca tanah yang terbuka, dan bahwa ambang indeks tidak berlaku umum. Praktik ini menguji kedua pernyataan itu pada data sungguhan. Sub-DAS Bompon pada musim kemarau hampir seluruhnya tertutup vegetasi, mirip kondisi kebun yang tajuknya telah menutup, sehingga tanah terbuka di sini sedikit dan harus dicari dengan teliti. Tegalan dan sawah saat bera dapat dibayangkan sebagai blok peremajaan, yang tanahnya hanya terbuka sesaat.

Peserta akan menghitung indeks, mencoba beberapa aturan ambang, dan memeriksa hasilnya terhadap peta penggunaan lahan. Pada uji coba, pemeriksaan ini memberi kejutan yang menjadi pelajaran utama praktik ini: sebagian besar piksel yang lolos sebagai tanah terbuka ternyata berada di permukiman. Tanpa pemeriksaan, peta "tanah terbuka" itu sebagian besar adalah peta atap dan halaman.

Data yang Dipakai

Semua berkas ada di folder `data/praktik-4/`. Buat folder `data/praktik-4/hasil/` untuk menyimpan keluaran.

Tabel P4.1 Data Praktik 4

Berkas	Isi
`sentinel2_l2a_20240813_10m.tif`	Sentinel-2 L2A, 13 Agustus 2024, adegan `S2A_49MCM_20240813_0_L2A`, 6 kanal
`sentinel2_l2a_20240813_scl_10m.tif`	Kelas permukaan (SCL) untuk tanggal tersebut
`sentinel2_l2a_20250721_10m.tif`	Sentinel-2 L2A, 21 Juli 2025, adegan `S2B_49MCM_20250721_0_L2A`, 10 kanal
`sentinel2_l2a_20250721_scl_10m.tif`	Kelas permukaan (SCL) untuk tanggal tersebut
`bompon_vektor.gpkg`	`batas_subdas`, `penggunaan_lahan`, `jalan`

Sumber: Data proyek; *Contains modified Copernicus Sentinel data 2024–2025*

Perhatikan urutan kanalnya. Kedua citra tidak memiliki susunan kanal yang sama, sehingga rumus untuk satu tanggal tidak boleh disalin begitu saja ke tanggal yang lain.

Tabel P4.2 Nomor Kanal pada Kedua Citra

Kanal Sentinel-2	13 Agustus 2024	21 Juli 2025
B02 (biru)	1	1
B03 (hijau)	2	2
B04 (merah)	3	3
B08 (inframerah dekat)	4	7
B11 (SWIR 1)	5	9
B12 (SWIR 2)	6	10

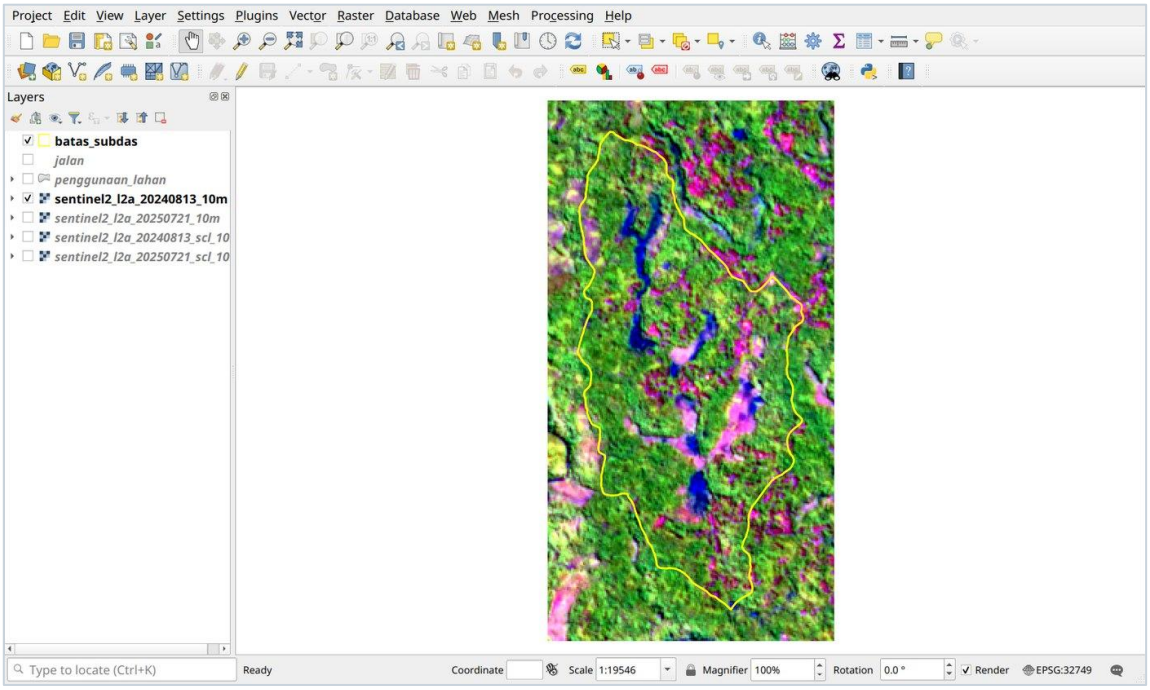
Sumber: Metadata berkas

Tahap 1: Melihat Kedua Citra

1. Muat semua berkas ke dalam proyek baru, simpan sebagai `hasil/praktik4.qgz`, dan pastikan CRS proyek `EPSG:32749`.

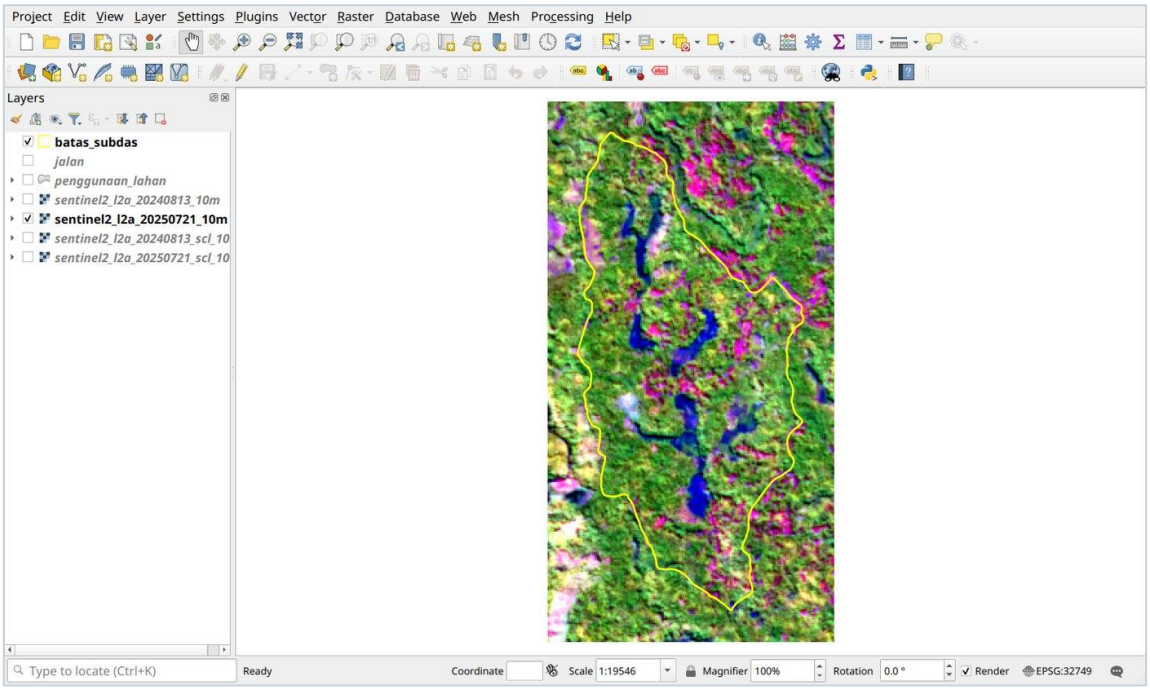
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. Tampilkan citra 2024 sebagai **Multiband color** dengan kanal 5, 4, 2 (B11, B8, B3), dan citra 2025 dengan kanal 9, 7, 2. Pilih **Cumulative count cut** 2–98%.
3. Tampilkan bergantian dengan mencentang dan menghapus centang layernya.



Gambar P4.1 Komposit SWIR 13 Agustus 2024

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*



Gambar P4.2 Komposit SWIR 21 Juli 2025

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2025*

Warna merah muda menandai permukaan yang kurang bervegetasi, dan tampak lebih luas pada 2024. Sebelum menghitung apa pun, buat dugaan di mana tanah terbuka berada, lalu bandingkan dengan hasilnya nanti.

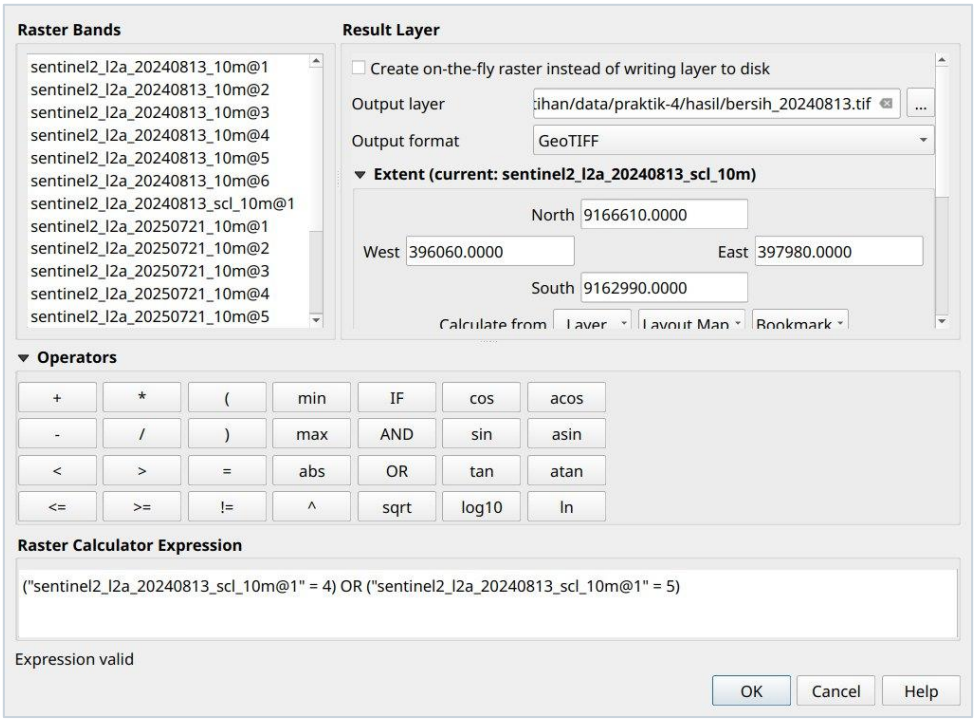
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tahap 2: Menyingkirkan Piksel Bermasalah

Modul 5 menyebut bahwa awan, bayangan, dan piksel bermasalah lain perlu disingkirkan lebih dulu. Lapisan SCL dipakai untuk itu, dengan hanya mempertahankan kelas 4 (vegetasi) dan 5 (tidak bervegetasi).

1. Pilih **Raster > Raster Calculator**.
2. Masukkan ekspresi berikut, simpan ke `hasil/bersih_20240813.tif`, lalu klik **OK**.

```
("sentinel2_l2a_20240813_scl_10m@1" = 4) OR ("sentinel2_l2a_20240813_scl_10m@1" = 5)
```



Gambar P4.3 Membuat masker piksel bersih dari SCL

Sumber: Tangkapan layar uji coba

3. Ulangi untuk tanggal 2025, dan simpan ke `hasil/bersih_20250721.tif`.

Nilai 1 berarti piksel bersih dan nilai 0 berarti piksel disingkirkan. Di dalam Sub-DAS, adegan 2024 memiliki 28.693 piksel vegetasi, 584 piksel tidak bervegetasi, dan 192 piksel kelas lain dari total 29.469 piksel.

Tahap 3: Menghitung Indeks

Hitung indeks untuk 2024 dengan Raster Calculator, satu rumus untuk satu berkas keluaran. Awalan layer `S` di bawah ini mewakili `sentinel2_l2a_20240813_10m`, jadi ketikkan nama lengkapnya atau klik dua kali namanya pada daftar **Raster Bands**.

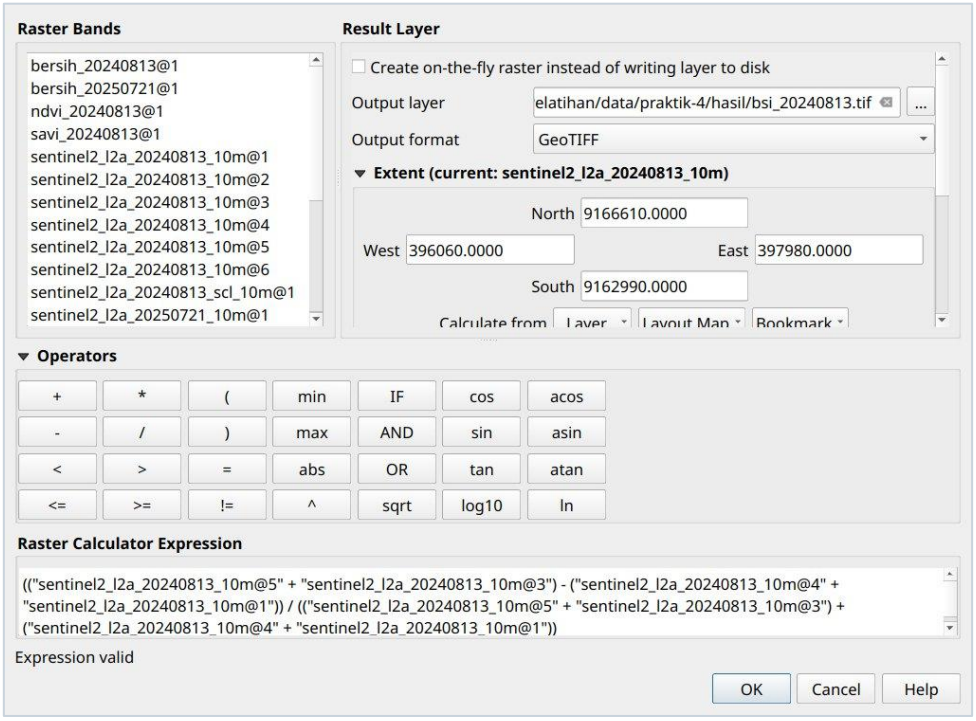
Tabel P4.3 Rumus Indeks untuk Citra 13 Agustus 2024

Indeks	Ekspresi Raster Calculator	Keluaran
NDVI	`("S@4" - "S@3") / ("S@4" + "S@3")`	`ndvi_20240813.tif`
SAVI	`1.5 * ("S@4" - "S@3") / ("S@4" + "S@3" + 0.5)`	`savi_20240813.tif`
BSI	`(("S@5" + "S@3") - ("S@4" + "S@1")) / (("S@5" + "S@3") + ("S@4" + "S@1"))`	`bsi_20240813.tif`
NBR2	`("S@5" - "S@6") / ("S@5" + "S@6")`	`nbr2_20240813.tif`

Sumber: Rumus dari Tabel 5.1 Modul 5, disesuaikan dengan urutan kanal berkas

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

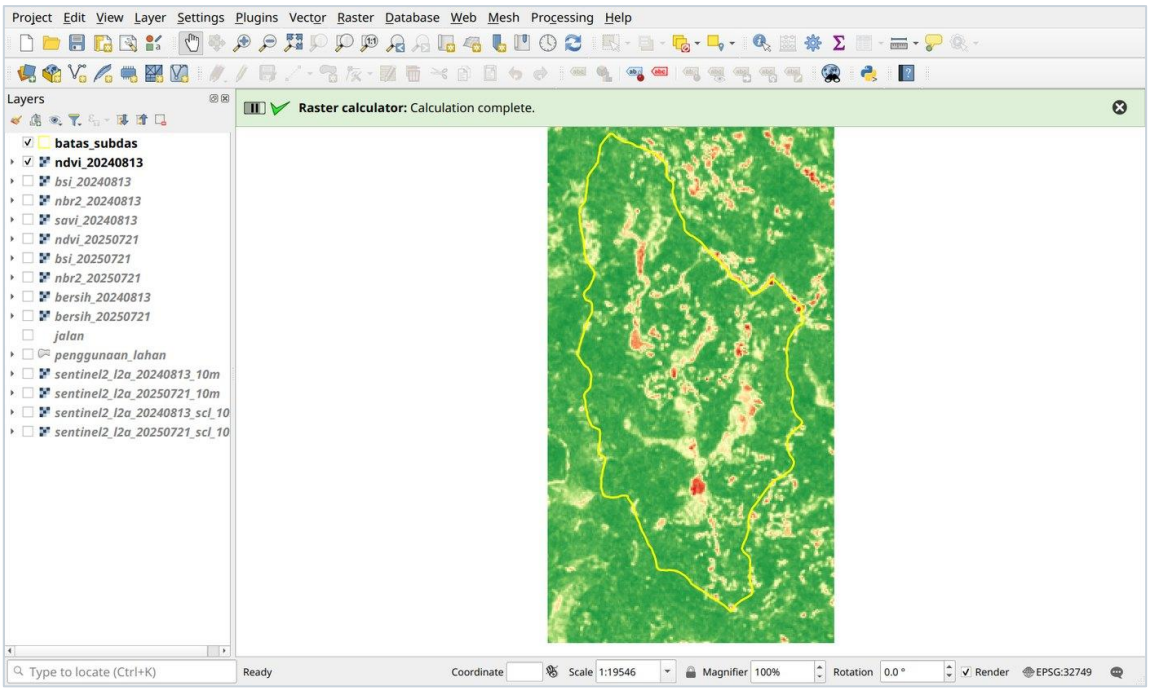
Untuk citra 2025, hitung NDVI, BSI, dan NBR2 dengan kanal 7 sebagai inframerah dekat, kanal 9 sebagai SWIR 1, dan kanal 10 sebagai SWIR 2. Simpan sebagai `ndvi_20250721.tif`, `bsi_20250721.tif`, dan `nbr2_20250721.tif`.



Gambar P4.4 Menghitung BSI dengan Raster Calculator

Sumber: Tangkapan layar uji coba

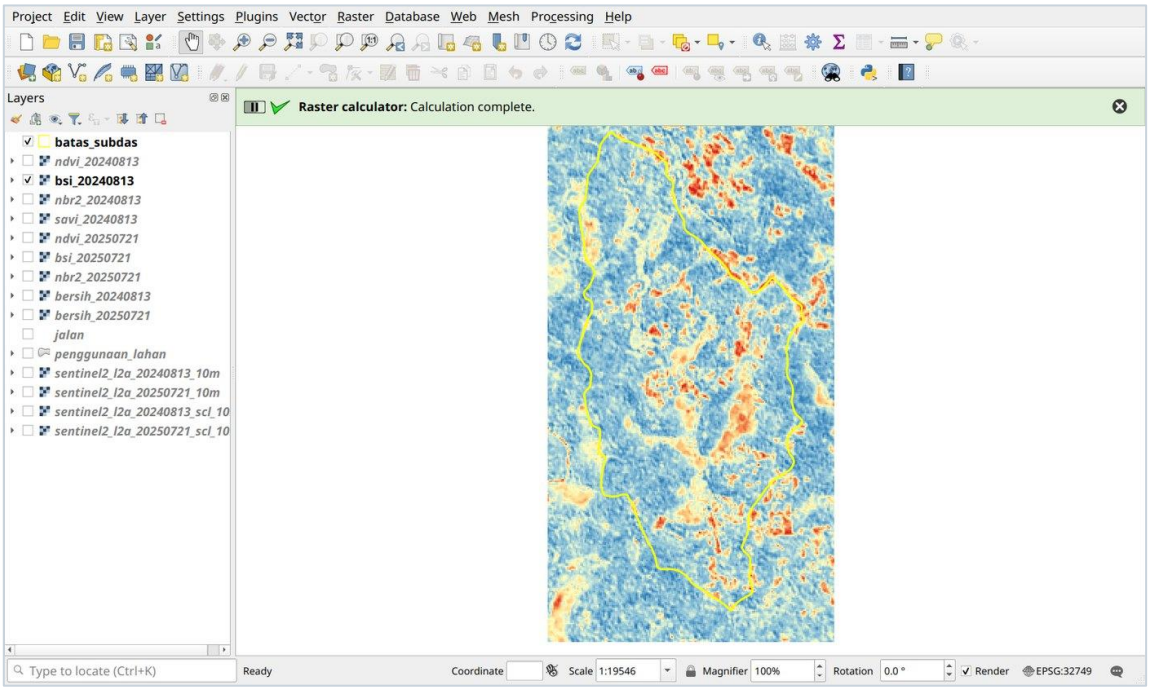
Tampilkan hasilnya sebagai **Singleband pseudocolor** dan bandingkan polanya.



Gambar P4.5 NDVI 13 Agustus 2024

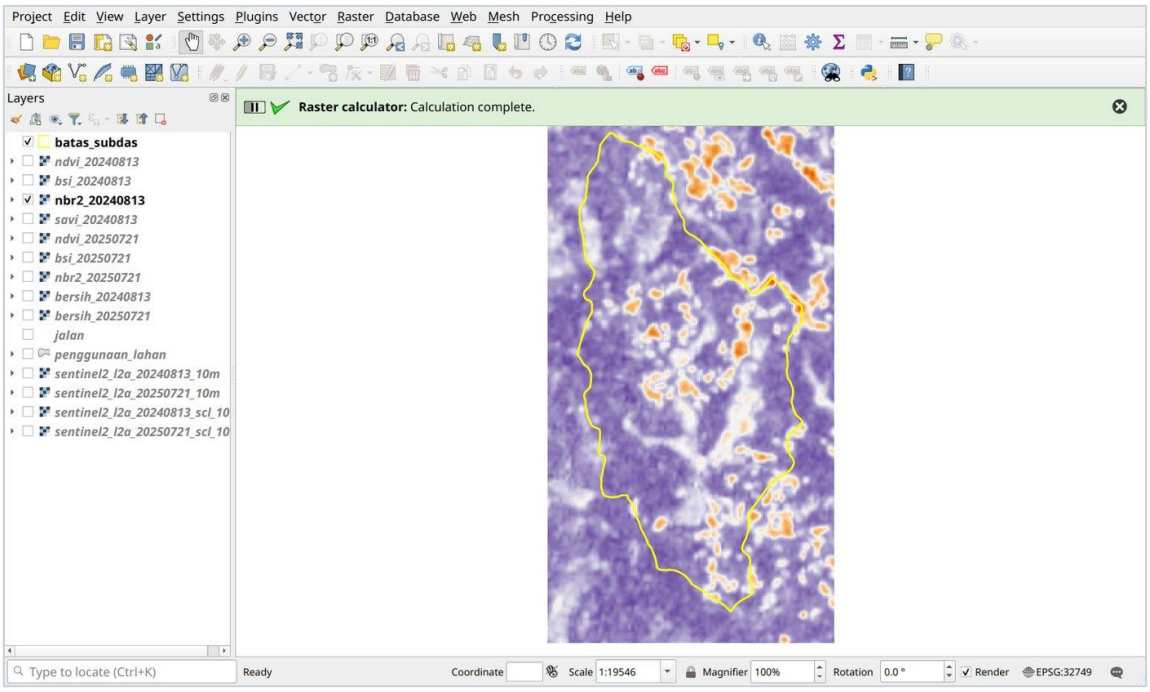
Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P4.6 BSI 13 Agustus 2024

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*



Gambar P4.7 NBR2 13 Agustus 2024

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

Di dalam Sub-DAS, median NDVI 2024 sekitar 0,82. Hanya 5% piksel yang NDVI-nya di bawah 0,46. Angka ini memberi gambaran betapa sedikitnya tanah yang terbuka.

Tahap 4: Mencoba Aturan Ambang

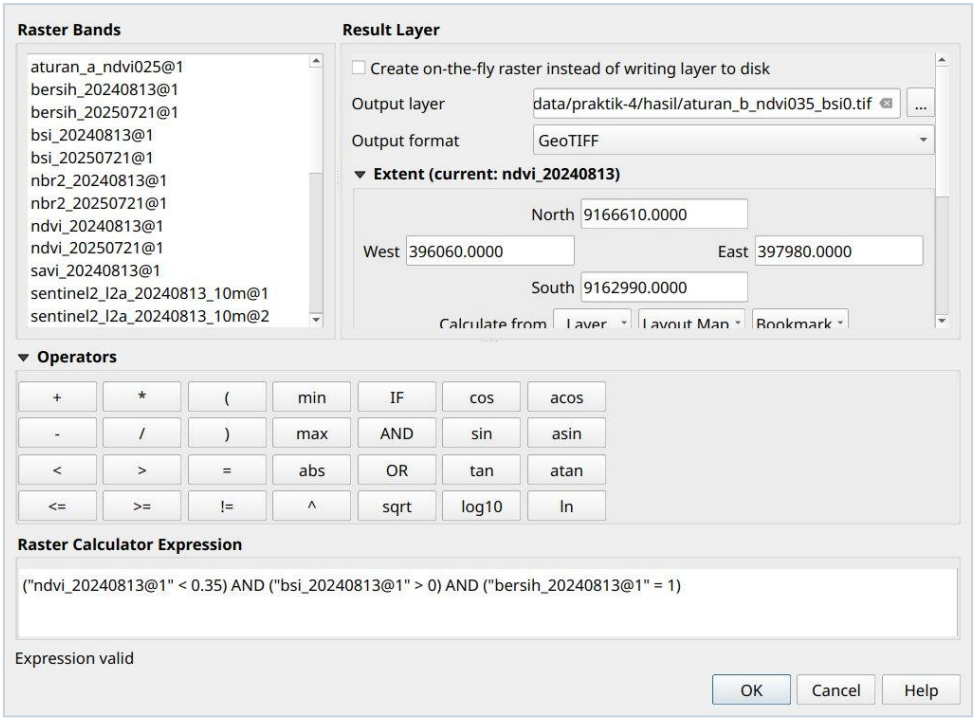
Coba tiga aturan berikut dengan Raster Calculator. Aturan A dan C memakai ambang dari pustaka yang tercantum di Tabel 5.1. Aturan B disusun penyusun modul setelah melihat citra dan nilainya, untuk latihan.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P4.4 Tiga Aturan Tanah Terbuka untuk Citra 2024

Aturan	Ekspresi	Keluaran
A	`("ndvi_20240813@1" < 0.25) AND ("bersih_20240813@1" = 1)`	`aturan_a_ndvi025.tif`
B	`("ndvi_20240813@1" < 0.35) AND ("bsi_20240813@1" > 0) AND ("bersih_20240813@1" = 1)`	`aturan_b_ndvi035_bsi0.tif`
C	`("ndvi_20240813@1" < 0.25) AND ("nbr2_20240813@1" > -0.30) AND ("nbr2_20240813@1" < 0.10) AND ("bersih_20240813@1" = 1)`	`aturan_c_ndvi025_nbr2.tif`

Sumber: Ambang A dari Castaldi et al. (2019); rentang NBR2 pada C dari Demattê et al. (2020); aturan B disusun untuk latihan



Gambar P4.8 Menuliskan aturan B pada Raster Calculator

Sumber: Tangkapan layar uji coba

Buat juga aturan B untuk 2025 dengan layer `ndvi_20250721`, `bsi_20250721`, dan `bersih_20250721`, lalu simpan ke `aturan_b_20250721.tif`. Berikutnya, hitung jumlah piksel setiap aturan di dalam Sub-DAS.

1. Buka **Processing Toolbox**, cari **Zonal histogram**.
2. Isi **Raster layer** dengan hasil aturan, **Vector layer containing zones** dengan `batas_subdas`, dan **Output column prefix** dengan `H_`.
3. Klik **Run**, lalu buka tabel atribut hasilnya. Kolom `H_1` berisi jumlah piksel bernilai 1.

Tabel P4.5 Jumlah Piksel Tanah Terbuka di Dalam Sub-DAS (Total 29.469 Piksel)

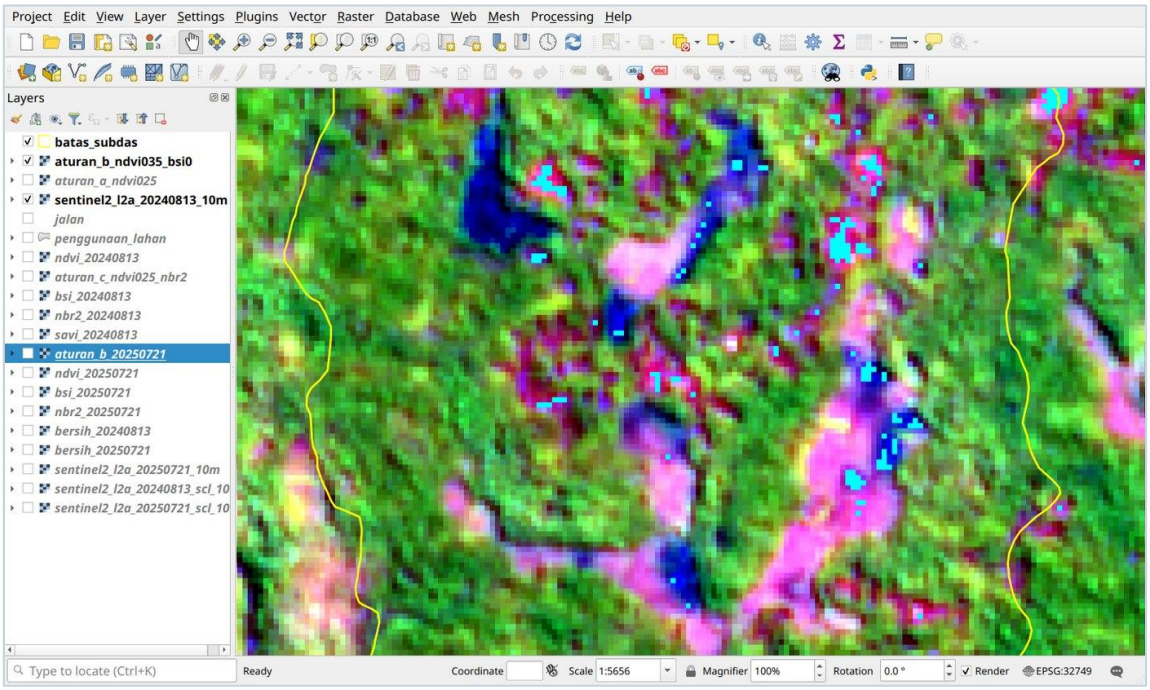
Aturan	Piksel	Luas (ha)
A, NDVI < 0,25	111	1,11
B, NDVI < 0,35 dan BSI > 0	240	2,40
C, NDVI < 0,25 dan −0,30 < NBR2 < 0,10	31	0,31
B pada citra 2025	83	0,83

Sumber: Hasil uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Perbedaan antaraturan itu sendiri sudah menjadi pelajaran. Rentang NBR2 dari pustaka menyisakan hanya 31 piksel, karena pada citra ini nilai NBR2 umumnya berada di atas 0,10, dengan median sekitar 0,37. Ambang dari wilayah lain tidak dapat dipindahkan begitu saja, seperti diingatkan Demattê et al. (2020). Aturan B dipakai pada tahap selanjutnya karena memberi jumlah piksel yang cukup untuk latihan, bukan karena terbukti benar. Pembuktiannya dimulai pada tahap berikut.

Tampilkan aturan B di atas citra dengan warna mencolok. Gunakan **Paletted/Unique values**, buat nilai 0 transparan dengan mengatur *opacity* warnanya menjadi 0, dan beri nilai 1 warna sian.



Gambar P4.9 Kandidat tanah terbuka aturan B di atas komposit SWIR, diperbesar di bagian tengah Sub-DAS

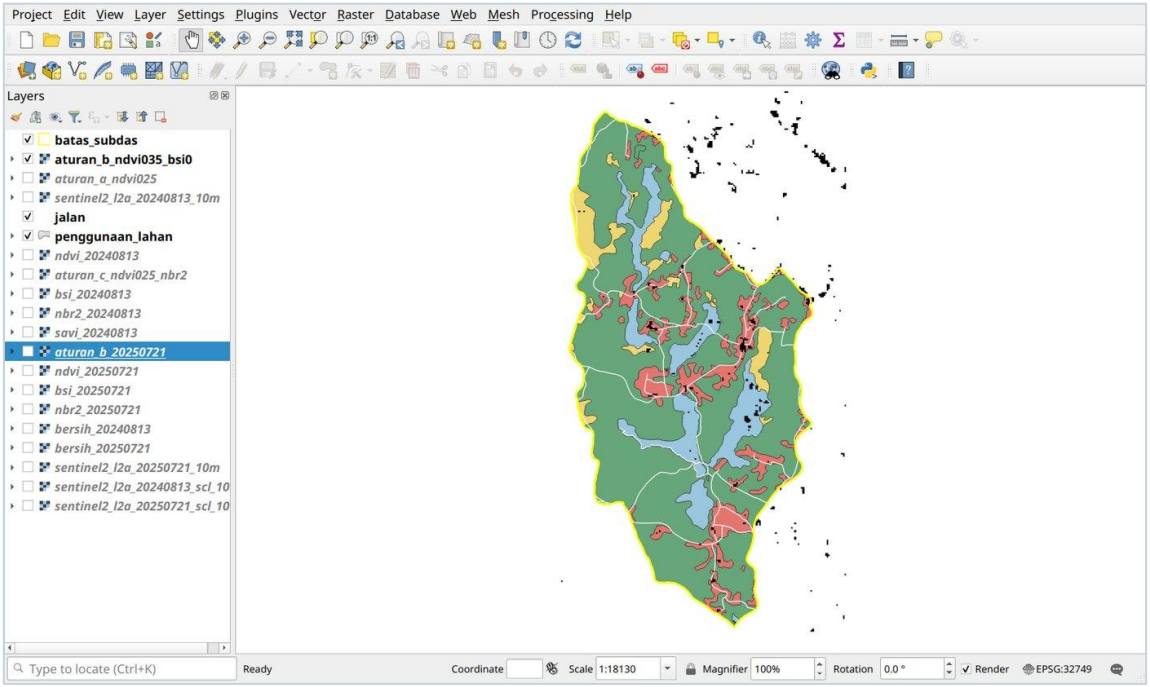
Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

Tahap 5: Memeriksa dengan Peta Penggunaan Lahan

1. Tampilkan `penggunaan_lahan` sebagai **Categorized** dan aturan B di atasnya.
2. Jalankan **Zonal histogram** lagi, kali ini dengan **Vector layer containing zones** `penggunaan_lahan`, lalu simpan ke `hasil/histogram_per_penggunaan_lahan.gpkg`.

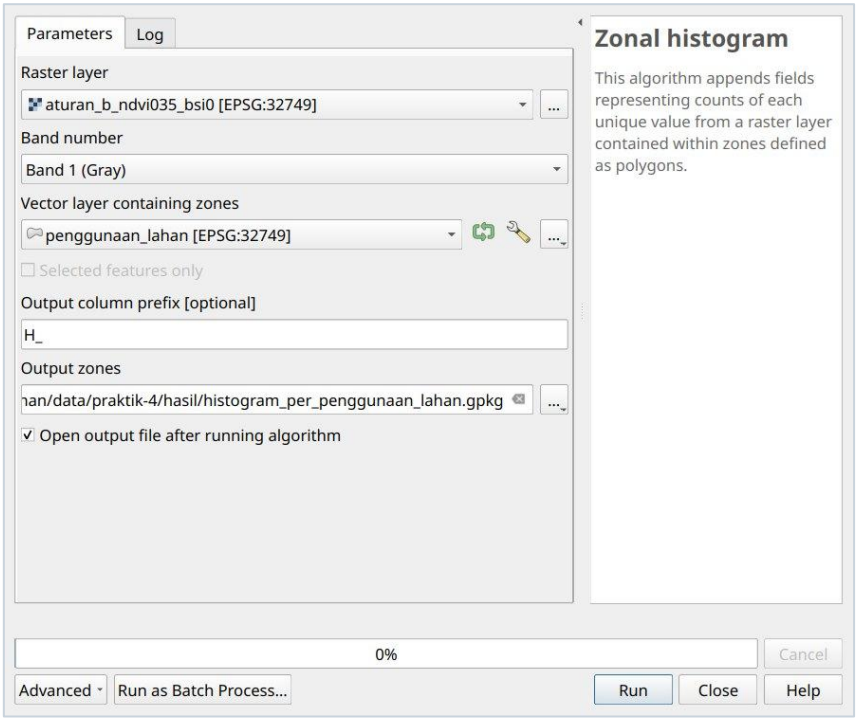
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

3. Jalankan **Statistics by categories** dengan **Input vector layer** hasil tersebut, **Field to calculate statistics on** `H_1`, dan **Field(s) with categories** `penggunaan_lahan`. Simpan ke `hasil/rekap_per_penggunaan_lahan.csv`, lalu lihat kolom `sum`.



Gambar P4.10 Kandidat tanah terbuka (hitam) di atas peta penggunaan lahan

Sumber: Tangkapan layar uji coba; data riset Sub-DAS Bompon



Gambar P4.11 Dialog Zonal Histogram

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P4.6 Kandidat Tanah Terbuka Aturan B Menurut Penggunaan Lahan

Penggunaan lahan	Piksel 2024	% dari kelasnya	Piksel 2025
Permukiman	165	4,68	80
Sawah	62	1,83	2
Tegalan	12	0,70	1
Agroforestri	1	0,00	0

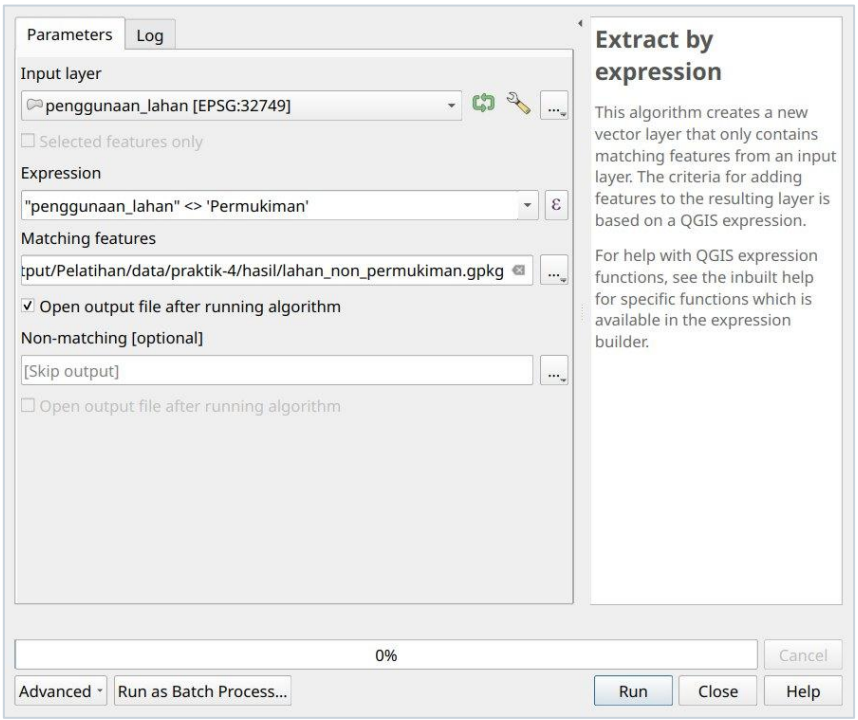
Sumber: Hasil uji coba

Inilah temuan utama. Pada citra 2024, 165 dari 240 piksel, atau 69%, berada di permukiman. Pada citra 2025, angkanya 80 dari 83 piksel, atau 96%. Indeks tanah terbuka memang tidak membedakan tanah dari atap, halaman, dan jalan, seperti diingatkan Modul 5. Yang menarik, sawah muncul pada 2024 dan hampir hilang pada 2025, sehingga kemungkinan besar sawah sedang bera atau baru diolah pada Agustus 2024. Dugaan ini perlu dikonfirmasi dengan kalender tanam atau pengamatan lapangan.

Tahap 6: Menyusun Masker Akhir

1. Jalankan **Extract by expression** dengan **Input layer** `penggunaan_lahan` dan **Expression** berikut, lalu simpan **Matching features** ke `hasil/lahan_non_permukiman.gpkg`.

```
"penggunaan_lahan" <> 'Permukiman'
```



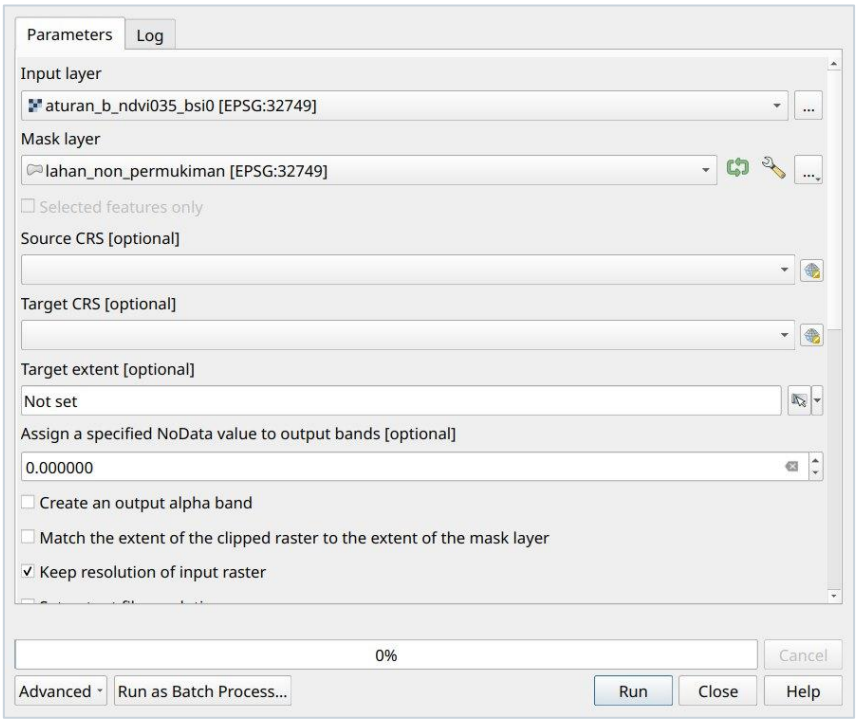
Gambar P4.12 Menyaring poligon selain permukiman

Sumber: Tangkapan layar uji coba

2. Pilih **Raster > Extraction > Clip Raster by Mask Layer**. Isi **Input layer** `aturan_b_ndvi035_bsi0`, **Mask layer** `lahan_non_permukiman`, **Assign a specified NoData value** `0`, hapus centang **Match the extent**,

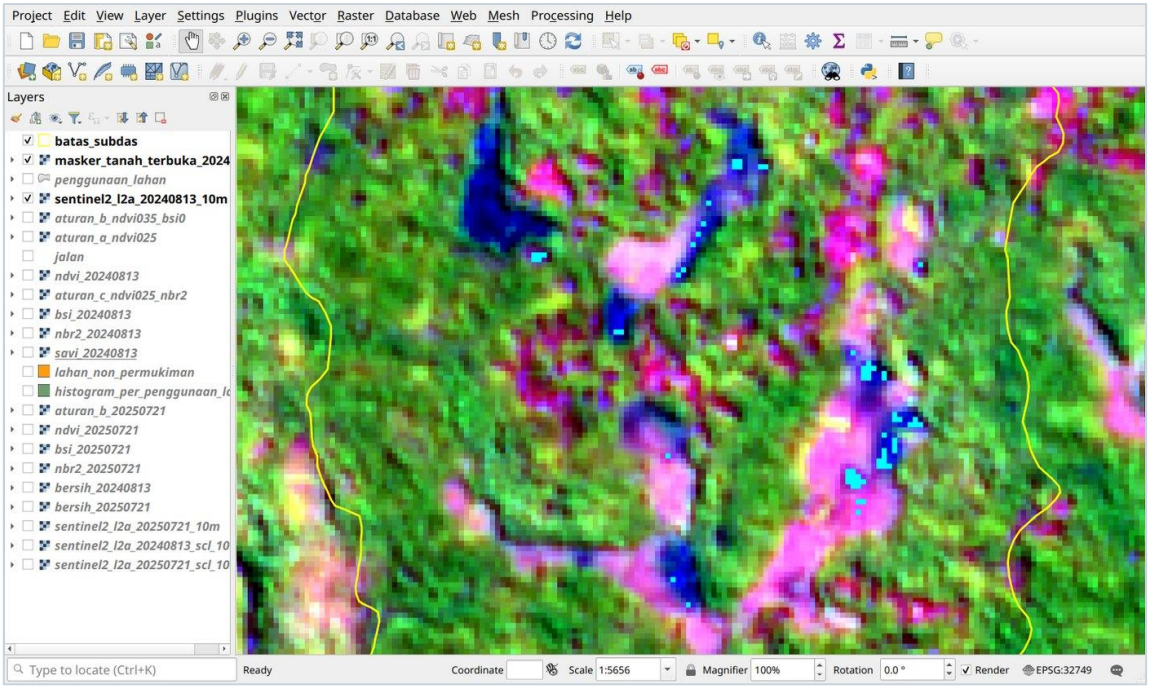
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

centang **Keep resolution**, pilih **Output data type** *Byte*, lalu simpan ke `hasil/masker_tanah_terbuka_20240813.tif`.



Gambar P4.13 Memotong masker dengan poligon selain permukiman

Sumber: Tangkapan layar uji coba



Gambar P4.14 Masker tanah terbuka akhir di atas komposit SWIR, diperbesar di bagian tengah Sub-DAS

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

Titik periksa. Masker akhir berisi 75 piksel, atau 0,75 ha. Dari luas 295 ha, tanah terbuka yang dapat dipakai hanya sekitar 0,25%. Bagi kebun bertajuk tertutup, gambaran seperti inilah yang perlu diantisipasi.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

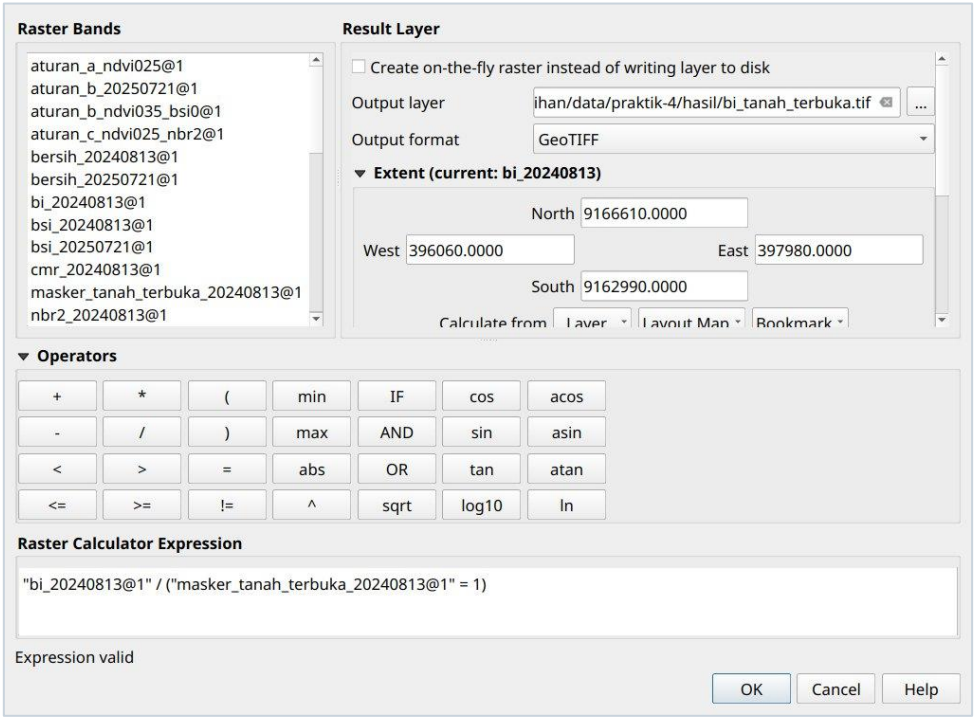
Tahap 7: Mengekstraksi Informasi Tanah

1. Hitung dua indeks sifat tanah pada citra 2024, dengan `S` seperti pada tahap 3. Simpan sebagai `bi_20240813.tif` dan `cmr_20240813.tif`.

```
sqrt(("S@3"^2 + "S@2"^2 + "S@1"^2) / 3)
"S@5" / "S@6"
```

2. Terapkan masker dengan membagi nilainya. Pembagian dengan nol menghasilkan NoData, sehingga hanya piksel tanah terbuka yang tersisa. Simpan sebagai `bi_tanah_terbuka.tif` dan `cmr_tanah_terbuka.tif`.

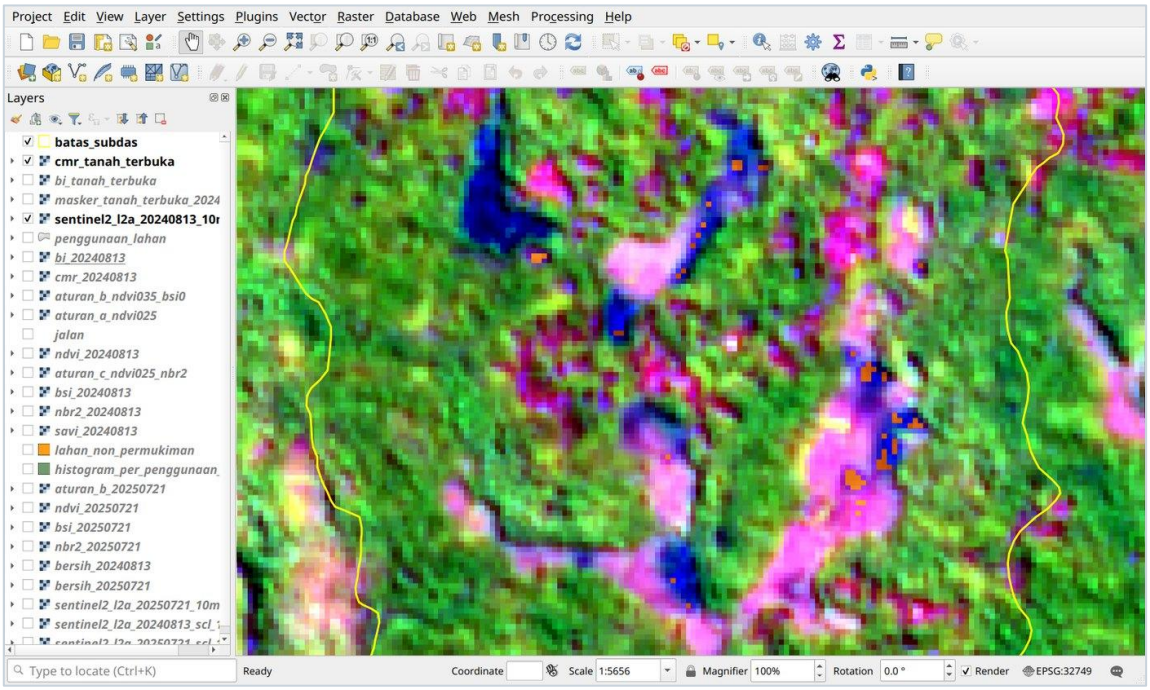
```
"cmr_20240813@1" / ("masker_tanah_terbuka_20240813@1" = 1)
```



Gambar P4.15 Menerapkan masker untuk mengekstraksi indeks

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P4.16 Rasio mineral lempung (CMR) hanya pada piksel tanah terbuka

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024*

3. Bandingkan statistik sebelum dan sesudah masker pada tab **Information**, atau dengan alat **Raster layer statistics**.

Tabel P4.7 Statistik Indeks Sebelum dan Sesudah Masker

Indeks	Cakupan	Piksel	Minimum	Rata-rata	Maksimum
BI	Seluruh grid	69.504	0,015	0,036	0,397
BI	Tanah terbuka	75	0,042	0,069	0,092
CMR	Seluruh grid	69.504	1,069	2,096	2,593
CMR	Tanah terbuka	75	1,460	1,744	2,066

Sumber: Hasil uji coba

Rata-rata CMR berubah dari 2,10 menjadi 1,74. Artinya, nilai CMR pada seluruh grid terutama dikendalikan vegetasi, bukan mineral lempung. Peta CMR tanpa masker dapat tampak seperti peta tanah, padahal yang tergambar adalah tutupan vegetasi.

Berikutnya, periksa mutu hasilnya dengan cara yang dipakai Demattê et al. (2020), yaitu melihat bentuk spektrumnya.

Tabel P4.8 Rerata Pantulan Piksel Tanah Terbuka dan Vegetasi Rapat

Kanal	Tanah terbuka (75 piksel)	Vegetasi, NDVI > 0,8 (45.405 piksel)
B02	0,046	0,022
B03	0,071	0,040
B04	0,085	0,025
B08	0,157	0,294
B11	0,145	0,154
B12	0,085	0,069

Sumber: Hasil uji coba; rerata dihitung dari seluruh piksel setiap kelompok

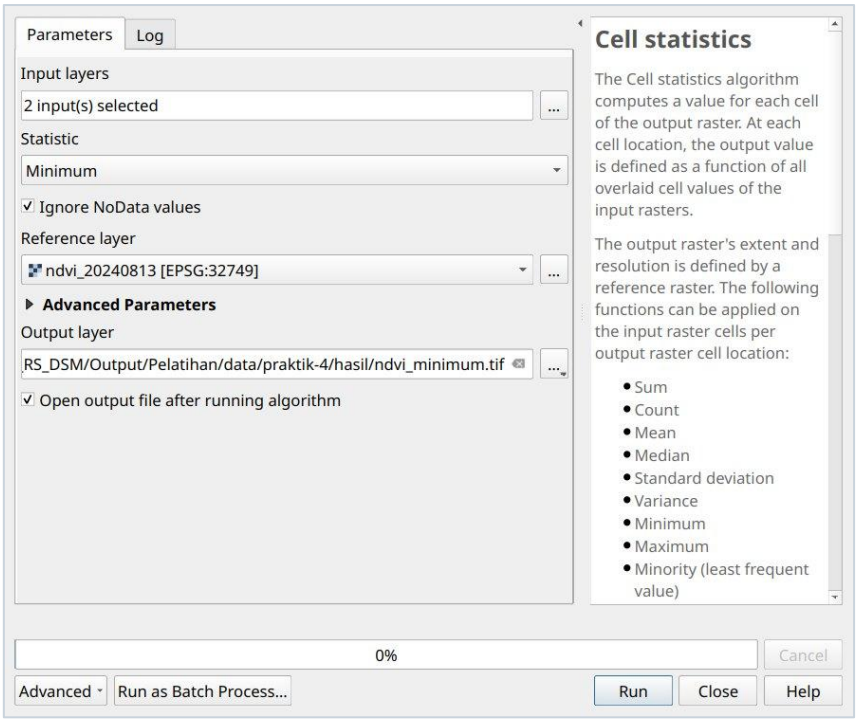
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Spektrum yang diharapkan dari tanah terbuka naik terus dari biru sampai SWIR pertama. Kumpulan piksel ini naik sampai B08, lalu sedikit turun di B11, dan NDVI dari nilai reratanya masih sekitar 0,30. Jadi, piksel-piksel ini kemungkinan bukan tanah yang benar-benar terbuka, melainkan campuran tanah dengan sisa tanaman, tumbuhan muda, atau air. Mengambil nilai CMR dari piksel ini lalu menyebutnya sifat tanah akan berlebihan tanpa pengamatan lapangan. Peserta dapat memeriksanya sendiri dengan **Identify Features** pada satu piksel masker dan satu piksel vegetasi.

Tahap 8: Komposit Dua Tanggal

Modul 5 menjelaskan bahwa komposit multitemporal mengambil kondisi paling terbuka dari banyak citra. Latihan ini hanya memakai dua tanggal sehingga sekadar memperlihatkan caranya, karena komposit yang sebenarnya memerlukan banyak citra (Diek et al., 2017).

1. Jalankan **Cell statistics** dengan **Input layers** `ndvi_20240813` dan `ndvi_20250721`, **Statistic** *Minimum*, dan **Reference layer** `ndvi_20240813`. Simpan ke `hasil/ndvi_minimum.tif`.



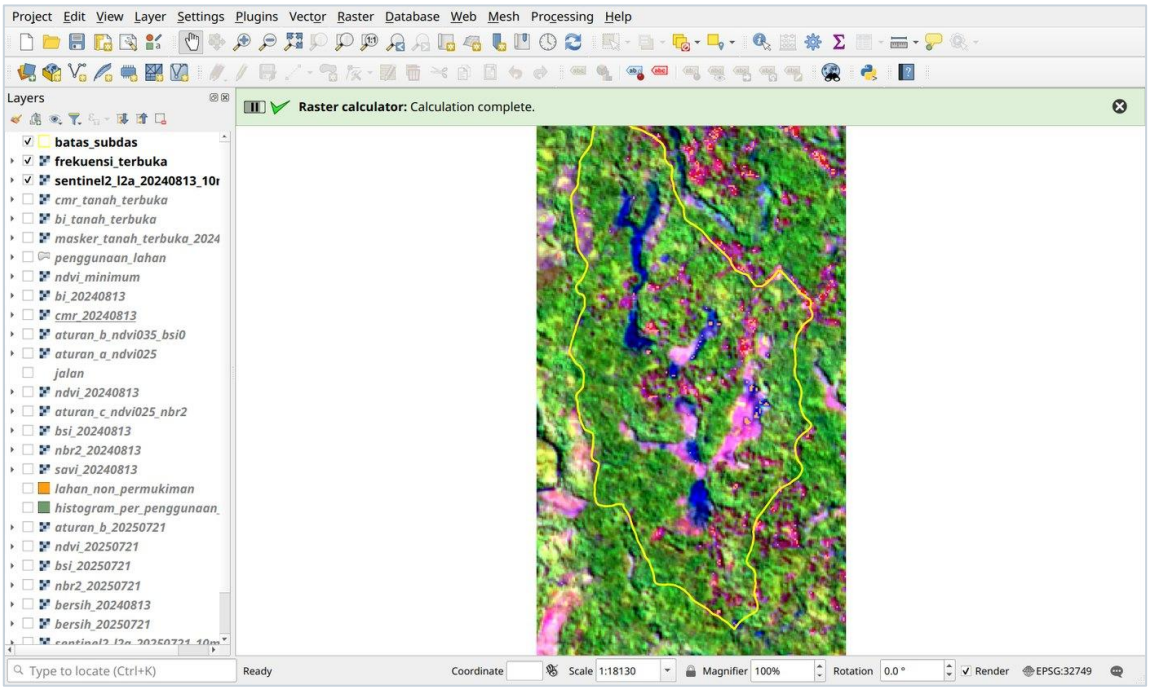
Gambar P4.17 Dialog Cell Statistics

Sumber: Tangkapan layar uji coba

2. Hitung frekuensi keterbukaan dengan menjumlahkan kedua aturan B, lalu simpan ke `hasil/frekuensi_terbuka.tif`.

```
"aturan_b_ndvi035_bsi0@1" + "aturan_b_20250721@1"
```


© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P4.18 Frekuensi keterbukaan dari dua tanggal

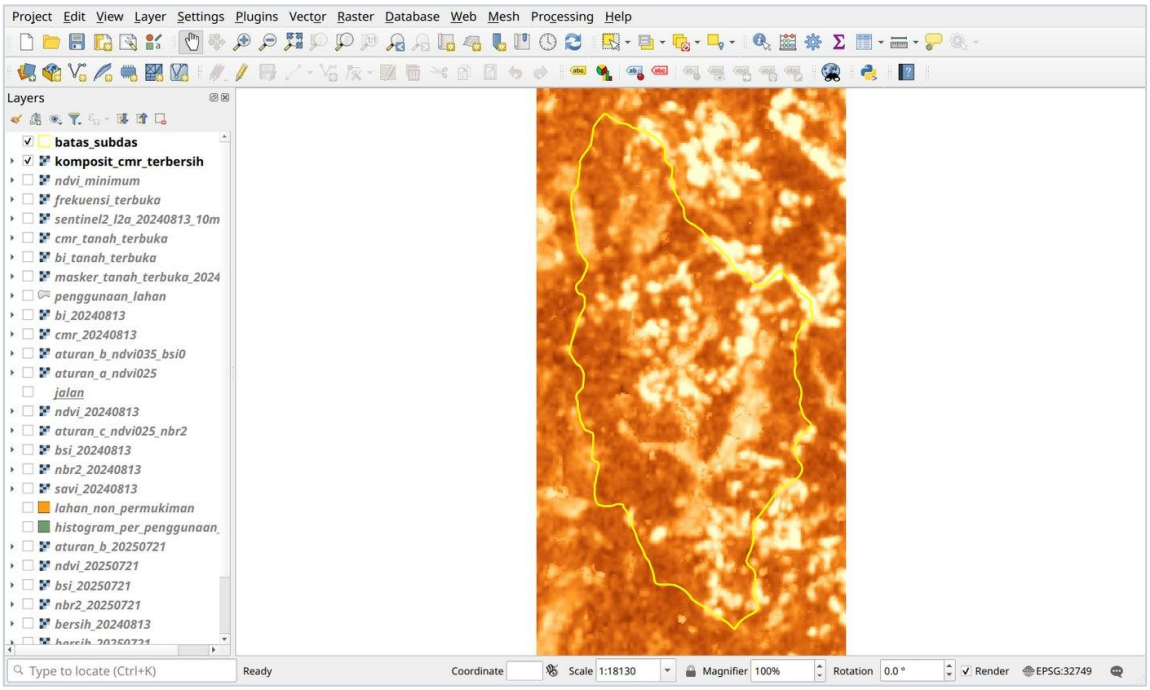
Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024–2025*

Di dalam Sub-DAS, 231 piksel terbuka satu kali dan 46 piksel terbuka dua kali. Periksa posisi piksel yang terbuka dua kali dengan peta penggunaan lahan: **seluruh 46 piksel itu berada di permukiman**. Permukaan yang terbuka di semua tanggal lebih mungkin atap atau jalan daripada tanah. Sebaliknya, permukaan pertanian muncul sesekali saja. Frekuensi keterbukaan karena itu berguna untuk memisahkan tanah garapan dari permukaan buatan, dan gagasan ini dapat dipakai di kebun.

3. Buat komposit CMR dari tanggal yang NDVI-nya lebih rendah di setiap piksel, lalu simpan ke `hasil/komposit_cmr_terbersih.tif`.

```
("ndvi_20240813@1" <= "ndvi_20250721@1") * "cmr_20240813@1" + ("ndvi_20240813@1" >
"ndvi_20250721@1") * ("sentinel2_l2a_20250721_10m@9" / "sentinel2_l2a_20250721_10m@10")
```


© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P4.19 Komposit CMR dari tanggal dengan NDVI terendah

Sumber: Tangkapan layar uji coba; *Contains modified Copernicus Sentinel data 2024–2025*

Bahan Diskusi

Sub-DAS Bompon memperlihatkan keadaan yang tidak nyaman tetapi jujur. Setelah permukiman dibuang, tanah terbuka hanya tersisa 0,75 ha, dan spektrumnya pun belum meyakinkan. Dari data ini, peta sifat tanah untuk seluruh wilayah jelas tidak dapat disusun dari pantulan langsung. Itulah alasan pemetaan pada Praktik 5 harus bersandar pada kovariat lingkungan.

Pertanyaan untuk dibawa pulang ke kebun: blok mana yang sedang atau akan diremajakan dalam dua tahun ke depan, dan apakah citra pada saat itu tersedia bebas awan? Modul 5 menunjukkan bahwa jendela waktunya hanya beberapa bulan. Peta permukiman, jalan kebun, dan area bangunan juga harus disiapkan lebih dulu, karena aturan indeks tidak dapat memisahkannya dari tanah.

Jika Tertinggal

Semua keluaran uji coba tersedia di `data/praktik-4/hasil-contoh/`, termasuk `Praktik_4_selesai.qgz`. Indeks yang dipakai pada Praktik 5 sudah tersedia di `data/praktik-5/kovariat/`.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Kurikulum Pembelajaran

Praktik 5. Machine Learning untuk Digital Soil Mapping

Pemandu: Ferry. Perangkat: QGIS dan Jupyter Notebook. Rujukan teori: Modul 8, Modul 2, dan Modul 4.

Tujuan

Membekali peserta agar mampu membangun model pemetaan tanah digital untuk sasaran kategorik, dalam praktik ini tutupan material atau bahan induk, dengan CatBoost, mulai dari penyiapan dan pemilihan kovariat sampai peta kelas beserta peluangnya, serta menilai hasilnya secara kritis.

Kompetensi

Setelah mengikuti praktik ini, peserta memiliki kompetensi dalam:

1. Menyiapkan kovariat SCORPAN dari data penginderaan jauh dan data lingkungan
2. Memilih kovariat berdasarkan korelasi Pearson dan tingkat kepentingan kovariat
3. Melatih CatBoost dengan kovariat kategorik, menilainya dengan validasi acak dan validasi spasial, serta membaca akurasi keseluruhan, kappa, presisi, recall, F1, dan matriks kebingungan
4. Menangani kelas yang jumlah sampelnya tidak seimbang dengan bobot kelas dan SMOTE-NC
5. Membuat dan membaca peta kelas, peta peluang, dan wilayah keberlakuan model

Ringkasan Studi

1. Deskripsi singkat
   - Peserta menyiapkan 16 kovariat di QGIS dan menampilkan 210 titik latih dan uji tutupan material
   - Peserta melatih CatBoost di Jupyter Notebook, memilih kovariat, dan menilainya dengan beberapa skema validasi
   - Peserta menampilkan peta tutupan material hasil prediksi di QGIS bersama peta SMU dari Praktik 2
2. Hasil belajar
   - Peserta memahami alur dari titik berkelas dan kovariat sampai peta kelas
   - Peserta mampu menyatakan seberapa jauh sebuah peta kelas hasil DSM dapat dipercaya
3. Indikator hasil belajar
   - Semua kovariat berukuran 192 × 362 piksel dengan piksel 10 m
   - Tabel metrik memuat akurasi, kappa, presisi makro, recall makro, dan F1 makro untuk CatBoost dan pembandingnya pada validasi acak, blok spasial, dan zona
   - Peta kelas, peta peluang, dan AOA tampil di QGIS bersama batas SMU
4. Materi pokok
   - Faktor SCORPAN sebagai kovariat, dengan bahan induk sebagai sasaran
   - CatBoost dan kovariat kategorik
   - Pemilihan kovariat dengan korelasi Pearson dan kepentingan permutasi
   - Ukuran ketelitian klasifikasi, validasi spasial, matriks kebingungan, dan data yang tidak seimbang
   - Peluang kelas dan wilayah keberlakuan model

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Gambaran Praktik

Praktik ini menyatukan semua hasil sebelumnya. Persamaan SCORPAN pada Modul 8 menyatakan tanah sebagai fungsi kondisi lingkungan, dan fungsi itu dipelajari dari data. Sasarannya tidak selalu berupa angka. Banyak kebutuhan pemetaan di perkebunan berupa kelas, misalnya jenis tanah, kelas drainase, atau bahan induk (*parent material*), sehingga modelnya berupa klasifikasi (*classification*), bukan regresi (*regression*). Karena itu, sasaran praktik ini adalah **tutupan material**, yaitu tujuh kelas bahan induk pada peta Malik (2017) untuk Sub-DAS Bompon. Peserta menyiapkan datanya, memilih kovariatnya, melatih dan menilai modelnya, lalu menerapkannya ke setiap piksel sehingga menghasilkan peta kelas beserta peta peluangnya (*probability map*).

Model utamanya adalah CatBoost (Prokhorenkova et al., 2018), algoritme *gradient boosting* yang dapat membaca kovariat kategorik (*categorical features*) secara langsung, sedangkan *random forest* menjadi pembanding. Dua hal perlu disampaikan sejak awal. Pertama, kelas di titik sampel diambil dari **peta**, bukan dari pengamatan lapangan, sehingga semua angka ketelitian menyatakan seberapa baik model mereproduksi peta Malik (2017). Kedua, **pada data latihan ini CatBoost tidak lebih teliti daripada* random forest*. Keduanya jelas lebih baik daripada pembanding sederhana pada validasi acak dan validasi blok spasial, tetapi hampir gagal ketika diterapkan ke zona yang belum pernah dilihatnya. Temuan ini berasal dari uji coba dan bukan kekeliruan langkah. Peserta diharapkan menemukannya sendiri dan mampu menjelaskan penyebabnya*

Data yang Dipakai

Semua berkas ada di folder `data/praktik-5/`.

Tabel P5.1 Data Praktik 5

Berkas	Isi
`Praktik_5_Machine_Learning_DSM.ipynb`	Notebook praktik
`titik_tutupan_material.gpkg`	210 titik latih dan uji, dengan kolom `id`, `kode`, `material`, `subset`, `x`, `y`, dan `jarak_tepi_m`
`titik_tutupan_material.csv`	Isi yang sama dalam bentuk tabel, dibaca oleh notebook
`material_acuan_10m.tif`	Peta tutupan material pada grid 10 m, hanya sebagai pembanding hasil
`material_acuan_10m.qml`	Gaya QGIS berisi warna dan nama ketujuh kelas, dimuat otomatis bersama petanya
`kovariat/`	16 kovariat siap pakai, satu GeoTIFF per kovariat, grid 10 m
`demnas_8m.tif`	DEMNAS yang sudah diproyeksikan ke UTM zona 49S dengan piksel 8 m dan dipotong 500 m lebih luas daripada grid kovariat, untuk atribut medan
`bompon_vektor.gpkg`	`batas_subdas`, `bentuklahan`, `penggunaan_lahan`, `sungai`
`smu_akhir.gpkg`	Peta SMU hasil Praktik 2

Sumber: Data proyek; peta tutupan material dari Malik (2017) sebagaimana dipakai Fatmawati (2026); DEMNAS dari Badan Informasi Geospasial (2026)

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P5.2 Tujuh Kelas Tutupan Material Sub-DAS Bompon

Kode	Material	Luas (ha)	Luas (%)	Titik latih	Titik uji
1	Breksi andesit sisipan diorit	9,7	3,3	21	9
2	Breksi andesit teralterasi	75,5	25,6	21	9
3	Breksi andesit teralterasi, ditumpangi lapukan batupasir Menoreh	38,2	13,0	21	9
4	Breksi vulkanik	39,8	13,5	21	9
5	Endapan material Sumbing Muda, pasir tufan, tuff pasiran, breksi andesit	67,4	22,9	21	9
6	Endapan Sumbing Muda dan endapan material longsor	35,4	12,0	21	9
7	Tuff pasiran	28,7	9,7	21	9

Sumber: Hasil uji coba; luas dihitung dari `material_acuan_10m.tif` di dalam batas Sub-DAS

Titik dibuat dari peta asal beresolusi 1 m dengan skrip `pelatihan_titik_tutupan_material.py`. Setiap titik berada di pusat satu sel grid kovariat 10 m, sekurang-kurangnya 15 m di dalam poligon kelasnya agar tidak jatuh di sel campuran pada batas kelas, dan disebar merata di setiap kelas dengan bantuan *k-means*. Kolom `subset` membagi titik menjadi data latih (*training data*) dan data uji (*test data*) secara acak berstrata (*stratified random split*). Ada tiga catatan tentang data ini:

1. **Asal kelas**, yaitu peta Malik (2017) yang merupakan hasil pemetaan geomorfologi, bukan pengamatan di setiap titik. Peta asal hanya menyimpan kode 1 sampai 7. Nama kelasnya dicocokkan dengan legenda Gambar 2.2 pada Fatmawati (2026) berdasarkan letak setiap kode di peta.
2. **Jumlah titik sama untuk setiap kelas**, padahal luas kelas terbesar hampir delapan kali luas kelas terkecil. Akibat rancangan ini dibahas pada Tahap 6 dan Tahap 7.
3. **Bahan induk sebagai sasaran.** Fatmawati (2026) memakai peta ini sebagai kovariat faktor p. Di sini perannya dibalik, sehingga peta material tidak boleh masuk ke folder `kovariat/`, karena justru itulah yang diprediksi.

Tahap 1: Alur Machine Learning

Buka `Praktik_5_Machine_Learning_DSM.ipynb` di JupyterLab atau Colab, lalu jalankan sel sampai akhir **Bagian A**. Seluruh notebook memerlukan 2–5 menit pada komputer uji coba. Waktu di laptop Anda dapat berbeda.

Bagian A memperkenalkan alur dasarnya. Titik dan kovariat dibaca, nilai kovariat diambil di setiap titik, lalu CatBoost dilatih dengan pembagian latih dan uji pada kolom `subset`. Ketelitian model klasifikasi dinyatakan dengan lima ukuran berikut:

1. **Akurasi keseluruhan** (*overall accuracy*, OA), yaitu proporsi titik yang kelasnya ditebak benar. Dengan tujuh kelas yang sama banyak, menebak sembarang menghasilkan akurasi sekitar 0,14.
2. **Kappa Cohen** (*Cohen's kappa*; Cohen, 1960), yaitu seberapa jauh akurasi melampaui kesepakatan yang dapat terjadi karena kebetulan (*chance agreement*). Nilai 0 berarti model tidak lebih baik daripada kebetulan, sedangkan nilai 1 berarti semua titik ditebak benar.
3. **Presisi makro** (*macro-averaged precision*), yaitu rata-rata presisi ketujuh kelas.
4. **Recall makro** (*macro-averaged recall*), yaitu rata-rata recall ketujuh kelas.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

5. **F1 makro** (*macro-averaged F1-score*), yaitu rata-rata F1 ketujuh kelas.

Ukuran makro memberi bobot yang sama pada setiap kelas, berapa pun jumlah titiknya, sehingga kelas yang selalu salah ditebak ikut menurunkan nilainya. Arti presisi, recall, dan F1 setiap kelas dijelaskan pada Tahap 5.

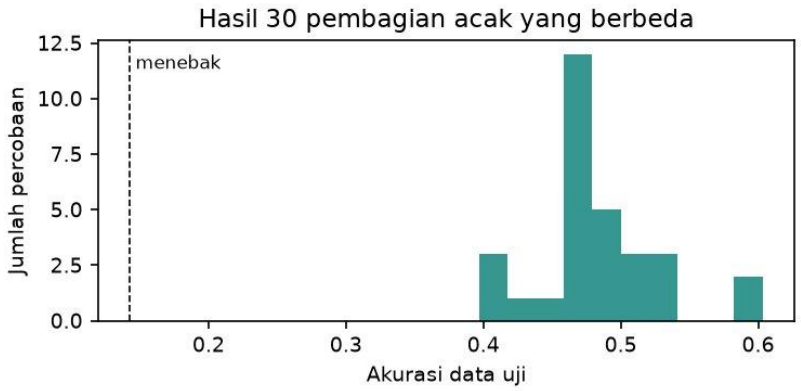
Tabel P5.3 Model Pertama pada Data Latih dan Data Uji

Data	Akurasi	Kappa	Presisi makro	Recall makro	F1 makro
Data latih (147 titik)	1,00	1,00	1,00	1,00	1,00
Data uji (63 titik)	0,54	0,46	0,51	0,54	0,51

Sumber: Hasil uji coba, CatBoost dengan 14 kovariat numerik

Pada data latih, model menebak semua titik dengan benar. Pada data yang belum pernah dilihatnya, akurasinya turun menjadi 0,54. Inilah *overfitting* yang dibahas pada Modul 8. Angka 0,54 memang jauh di atas 0,14, tetapi berarti hampir separuh titik uji masih salah kelas.

Sel berikutnya mengulang pembagian acak 70/30 sebanyak 30 kali. Akurasinya berkisar dari 0,40 sampai 0,60, dengan median 0,48. Satu pembagian yang kebetulan baik dapat memberi kesan keliru, sehingga laporan yang hanya menyebut satu pembagian tunggal (*single train-test split*) perlu dibaca dengan hati-hati.



Gambar P5.1 Sebaran akurasi dari 30 pembagian acak yang berbeda

Sumber: Hasil uji coba

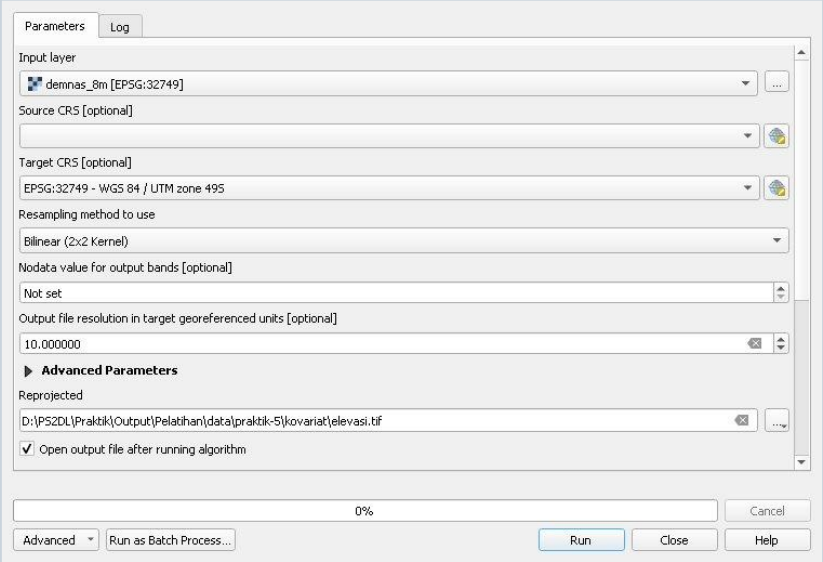
Tahap 2: Menyiapkan Kovariat di QGIS

Folder `kovariat/` sudah berisi semua kovariat siap pakai, sehingga notebook tetap berjalan walaupun tahap ini belum selesai. Tahap ini menunjukkan cara membuatnya, dan kovariat buatan Anda dapat menimpa berkas di folder itu. Tutup dulu layer yang akan ditimpa dari panel **Layers**. Kovariat optik dan radar berasal dari data Praktik 1 dan Praktik 4, sehingga tidak dibuat ulang. Atribut medan (*terrain attributes*) dihitung dari DEMNAS (Badan Informasi Geospasial, 2026), yaitu DEM yang sama dengan Praktik 1. Pada folder ini, DEMNAS sudah diproyeksikan ke UTM zona 49S dengan piksel 8 m dan dipotong 500 m lebih luas daripada grid kovariat, sehingga atribut medan di tepi Sub-DAS tidak terpotong.

1. Buat proyek baru, simpan sebagai `hasil/praktik5.qgz`, lalu muat `demnas_8m.tif` dan semua layer `bompon_vektor.gpkg`.
2. **Elevasi.** Pilih **Raster > Projections > Warp (Reproject)** dengan **Input layer** `demnas_8m`, **Target CRS** `EPSG:32749`, **Resampling method to use** *Bilinear (2x2 Kernel)*, dan **Output file resolution** `10`. Buka

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Advanced Parameters, isi **Georeferenced extents of output file to be created** dengan `396060,397980,9162990,9166610 [EPSG:32749]`, lalu pilih **Output data type** *Float32*. Simpan ke `kovariat/elevasi.tif`. Pengaturan ini sama dengan Praktik 1 tahap 2.

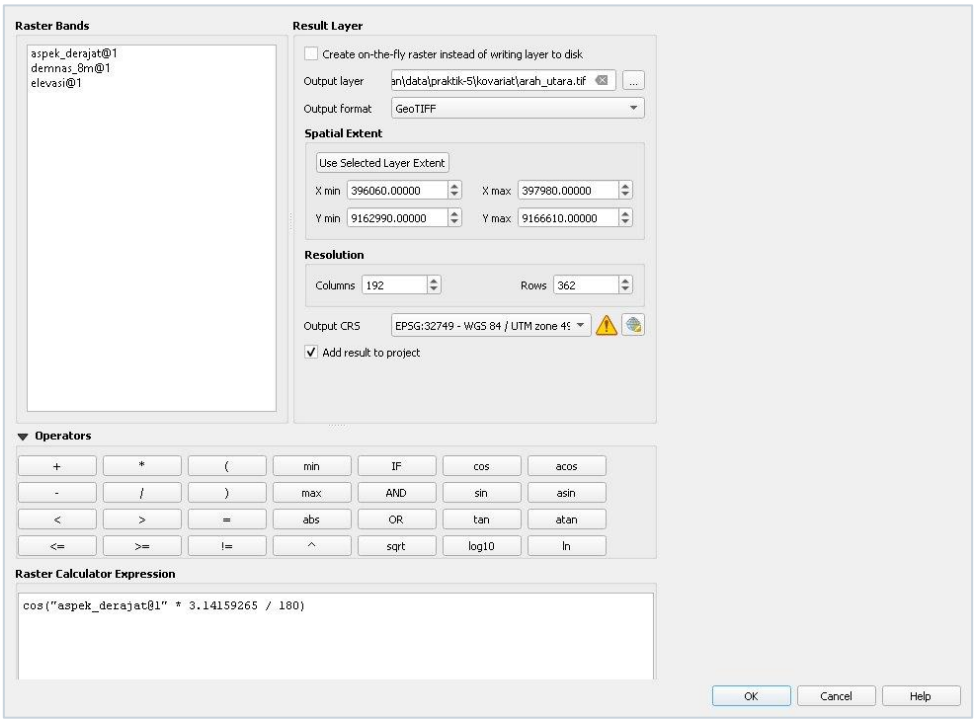


Gambar P5.2 Membawa DEMNAS 8 m ke grid kovariat 10 m
Sumber: Tangkapan layar uji coba

3. **Kemiringan lereng.** Pilih **Raster > Analysis > Slope**, dengan **Input layer** `elevasi`, centang **Express slope as percent** dan **Compute edges**, lalu simpan ke `kovariat/lereng.tif`.
4. **Arah hadap.** Pilih **Raster > Analysis > Aspect**, dengan input yang sama, centang **Return 0 for flat** dan **Compute edges**, lalu simpan ke `hasil/aspek_derajat.tif`. Nilai 359° dan 1° sebenarnya berdekatan, tetapi angkanya berjauhan. Karena itu arah diubah menjadi kosinus, yaitu ukuran seberapa menghadap ke utara (*northness*), dengan Raster Calculator berikut, lalu disimpan ke `kovariat/arah_utara.tif`.

```
cos("aspek_derajat@1" * 3.14159265 / 180)
```

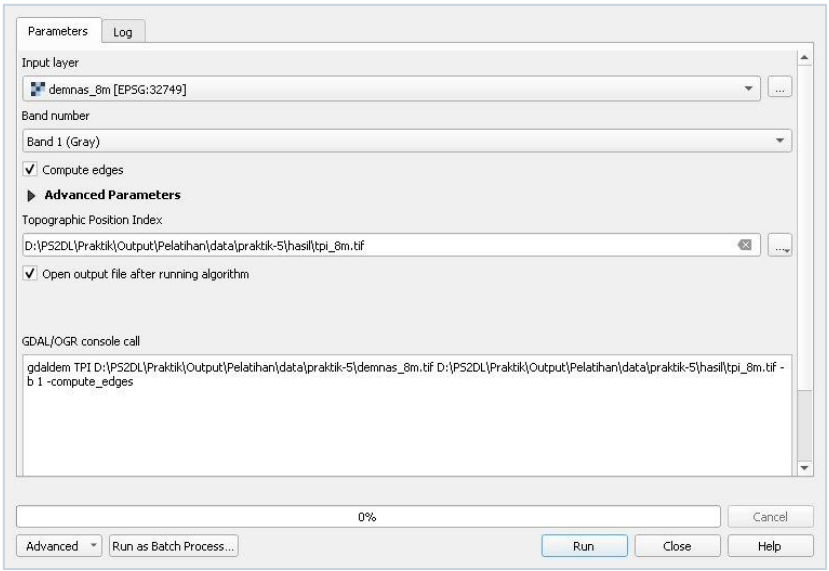

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P5.3 Mengubah arah hadap menjadi kosinus

Sumber: Tangkapan layar uji coba

5. **Posisi topografi dan kekasaran medan.** Cari **Topographic Position Index (TPI)** di Processing Toolbox. Gunakan **Input layer** `demnas_8m`, centang **Compute edges**, lalu simpan ke `hasil/tpi_8m.tif`. Lakukan hal yang sama dengan **Terrain Ruggedness Index (TRI)** ke `hasil/tri_8m.tif`. Keduanya sengaja dihitung pada piksel asli DEMNAS, sebelum diselaraskan ke 10 m, agar jendela 3 × 3 piksel mengolah ketinggian asli, bukan nilai hasil interpolasi. Jendela itu hanya mencakup sekitar 24 m × 24 m, sehingga TPI dan TRI di sini menggambarkan bentuk medan yang sangat setempat.



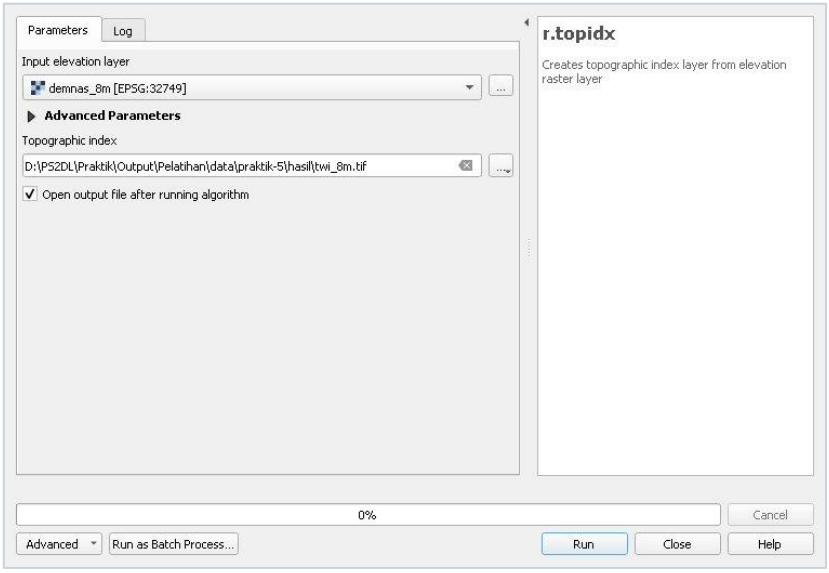
Gambar P5.4 Dialog Topographic Position Index

Sumber: Tangkapan layar uji coba

6. **Kebasahan topografi.** Indeks kebasahan topografi (*topographic wetness index*, TWI) bernilai tinggi pada tempat yang landai dan menerima aliran dari daerah tangkapan yang luas di atasnya. Cari **r.topidx**

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

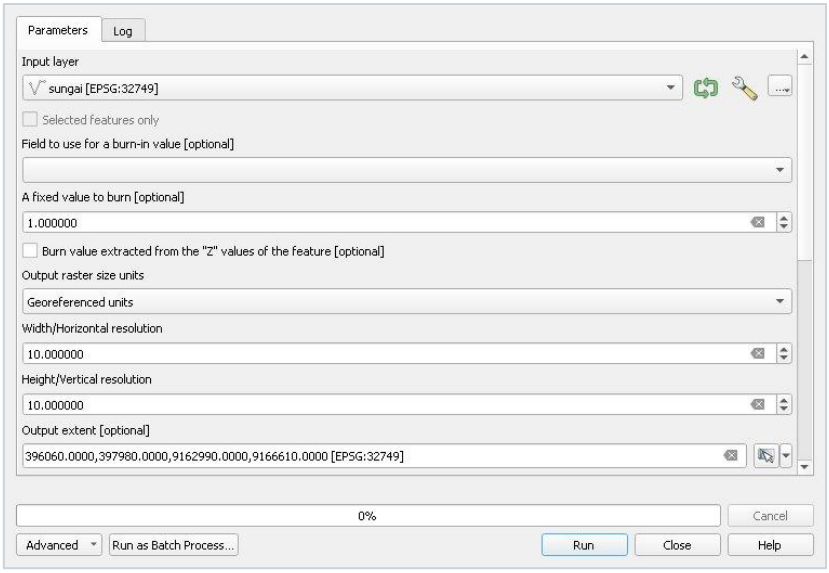
di Processing Toolbox. Isi **Input elevation layer** `demnas_8m`, lalu simpan ke `hasil/twi_8m.tif`. Alat ini memerlukan penyedia GRASS. Jika tidak tersedia di laptop Anda, lewati langkah ini dan pakai berkas yang sudah ada.



Gambar P5.5 Menghitung indeks kebasahan topografi dengan r.topidx

Sumber: Tangkapan layar uji coba

7. Selaraskan ketiganya ke grid 10 m dengan pengaturan Warp yang sama seperti langkah 2, lalu simpan sebagai `kovariat/tpi.tif`, `kovariat/tri.tif`, dan `kovariat/twi.tif`.
8. **Jarak ke sungai.** Pilih **Raster > Conversion > Rasterize (Vector to Raster)** dengan **Input layer** `sungai`, **A fixed value to burn** `1`, **Output raster size units** *Georeferenced units*, resolusi `10` dan `10`, **Output extent** `396060,397980,9162990,9166610 [EPSG:32749]`, dan **Assign a specified NoData value** `0`. Simpan ke `hasil/sungai_raster.tif`.

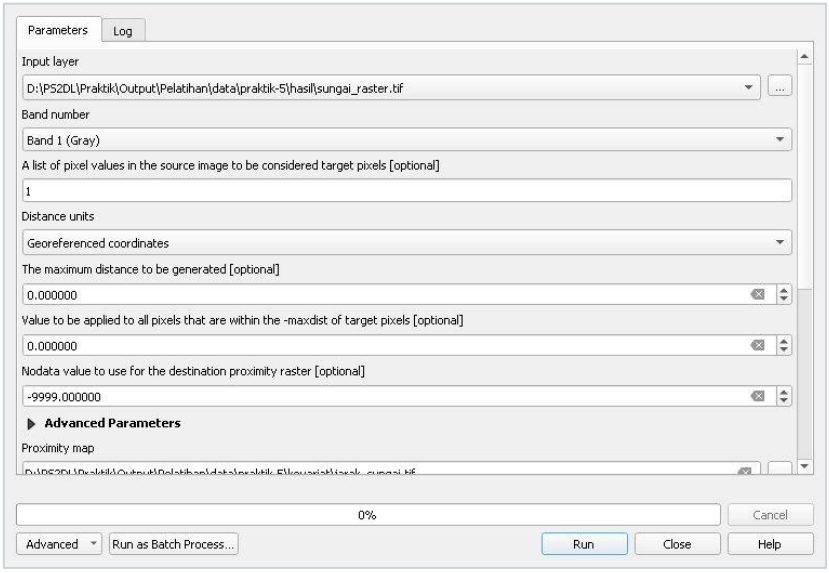


Gambar P5.6 Mengubah garis sungai menjadi raster

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

9. Pilih **Raster > Analysis > Proximity (Raster Distance)** dengan **Input layer** `sungai_raster`, **List of target pixels** `1`, **Distance units** *Georeferenced coordinates*, **Nodata value to use for the destination proximity raster** `-9999`, dan **Output data type** *Float32*. Simpan ke `kovariat/jarak_sungai.tif`.

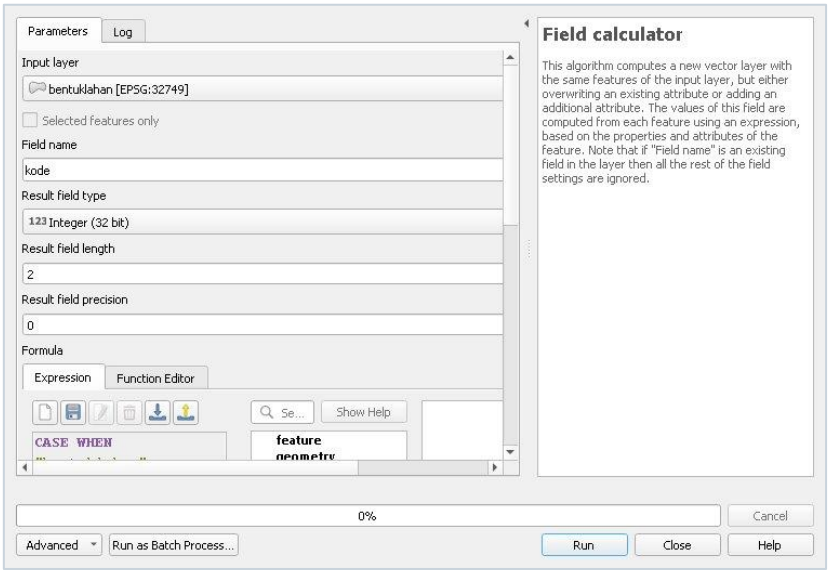


Gambar P5.7 Menghitung jarak ke sungai terdekat

Sumber: Tangkapan layar uji coba

10. **Kovariat kategorik.** Raster memerlukan angka, sehingga nama kelas diberi kode lebih dulu. Jalankan **Field calculator** dari Processing Toolbox pada layer `bentuklahan`, dengan **Field name** `kode`, **Result field type** *Integer*, dan formula berikut. Simpan ke `hasil/bentuklahan_kode.gpkg`.

```
CASE WHEN "bentuklahan"='Interfluve' THEN 1
     WHEN "bentuklahan"='Lereng Atas Perbukitan' THEN 2
     WHEN "bentuklahan"='Lereng Tengah Perbukitan' THEN 3
     WHEN "bentuklahan"='Lereng Bawah Perbukitan' THEN 4
     WHEN "bentuklahan"='Lereng Kaki Koluvial' THEN 5
     WHEN "bentuklahan"='Dataran Koluvial' THEN 6 END
```



Gambar P5.8 Memberi kode numerik pada kelas bentuklahan

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

11. Rasterize hasil tersebut seperti langkah 8, tetapi pilih **Field to use for a burn-in value** `kode`, **Assign a specified NoData value** `0`, dan **Output data type** *Int16*. Simpan ke `kovariat/kat_bentuklahan.tif`. Ulangi untuk `penggunaan_lahan` dengan kode Agroforestri 1, Tegalan 2, Sawah 3, dan Permukiman 4, lalu simpan ke `kovariat/kat_penggunaan_lahan.tif`.

Tabel P5.4 Enam Belas Kovariat dan Faktor SCORPAN-nya

Kovariat	Faktor	Asal	Minimum	Rata-rata	Maksimum
`elevasi` (m)	r	DEMNAS	349,57	458,62	536,04
`lereng` (%)	r	DEMNAS	0,05	21,51	74,10
`arah_utara`	r	DEMNAS	−1,00	−0,10	1,00
`tpi` (m)	r	DEMNAS	−0,89	0,00	0,68
`tri`	r	DEMNAS	0,21	4,36	14,25
`twi`	r	DEMNAS	3,57	5,89	15,47
`jarak_sungai` (m)	r	Peta sungai	0,00	360,19	1.287,98
`kat_bentuklahan`	r	Peta riset	1	kategori	6
`kat_penggunaan_lahan`	o	Foto udara	1	kategori	4
`ndvi_2024`	o	Sentinel-2	0,05	0,78	0,92
`ndvi_2025`	o	Sentinel-2	0,04	0,83	0,94
`bsi_2024`	o, s	Sentinel-2	−0,47	−0,22	0,25
`bi_2024`	o, s	Sentinel-2	0,02	0,04	0,40
`cmr_2024`	o, s	Sentinel-2	1,07	2,10	2,59
`sar_vv` (dB)	o, r	Sentinel-1	−23,32	−7,04	7,08
`sar_vh` (dB)	o	Sentinel-1	−26,30	−13,49	−1,66

Sumber: Hasil uji coba, seluruh grid 192 × 362 piksel; DEMNAS dari Badan Informasi Geospasial (2026); *Contains modified Copernicus Sentinel data 2024–2025*

Tidak ada faktor iklim, karena hampir tidak bervariasi di wilayah seluas ini. Faktor bahan induk (p) juga tidak ada di daftar ini, karena pada praktik ini bahan induk justru menjadi sasaran pemodelan.

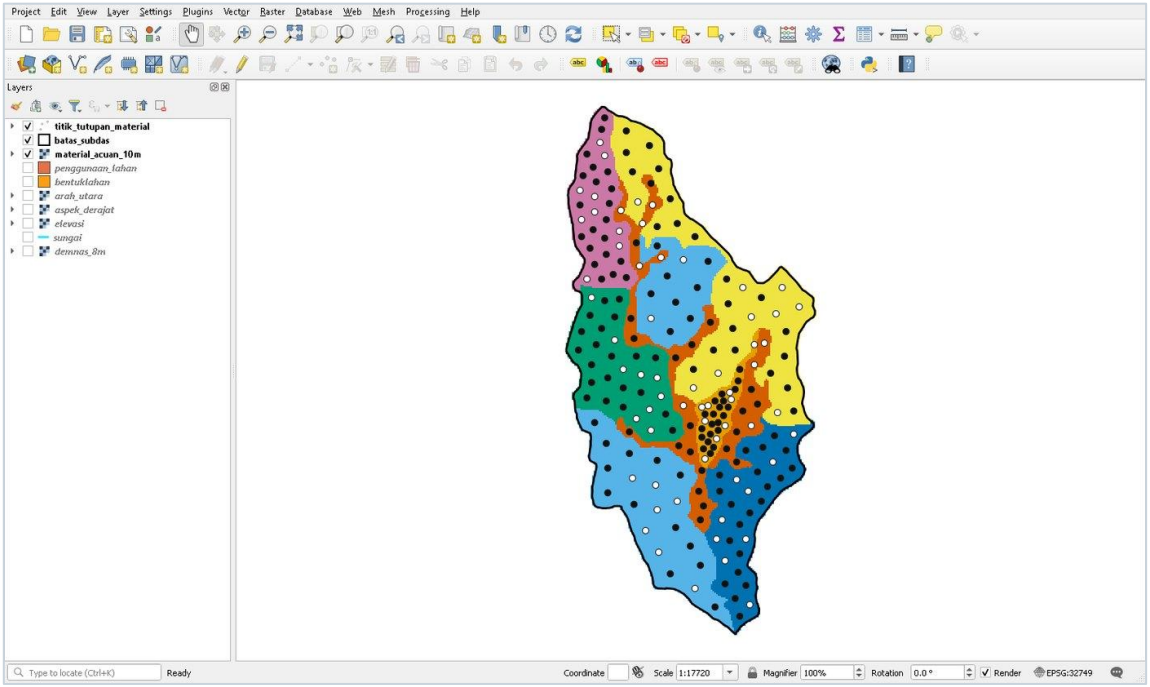
Titik periksa. Semua raster di `kovariat/` berukuran 192 × 362 piksel dengan piksel 10 m. Jika ada yang berbeda, notebook akan gagal membaca atau salah menempatkan nilainya.

Tahap 3: Menampilkan Titik Latih dan Uji

1. Muat `material_acuan_10m.tif`. Di folder yang sama ada `material_acuan_10m.qml`, yaitu berkas gaya QGIS yang namanya sama dengan rasternya. QGIS memuat gaya itu secara otomatis, sehingga peta tampil sebagai **Paletted/Unique values** lengkap dengan warna dan nama ketujuh kelas pada Tabel P5.2. Buka **Properties > Symbology** untuk melihat pengaturannya.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. Muat layer `titik_tutupan_material` dari `titik_tutupan_material.gpkg`. Buka **Properties > Symbology**, pilih **Categorized**, isi **Value** dengan `subset`, lalu klik **Classify**. Beri titik latih warna hitam dan titik uji warna putih.

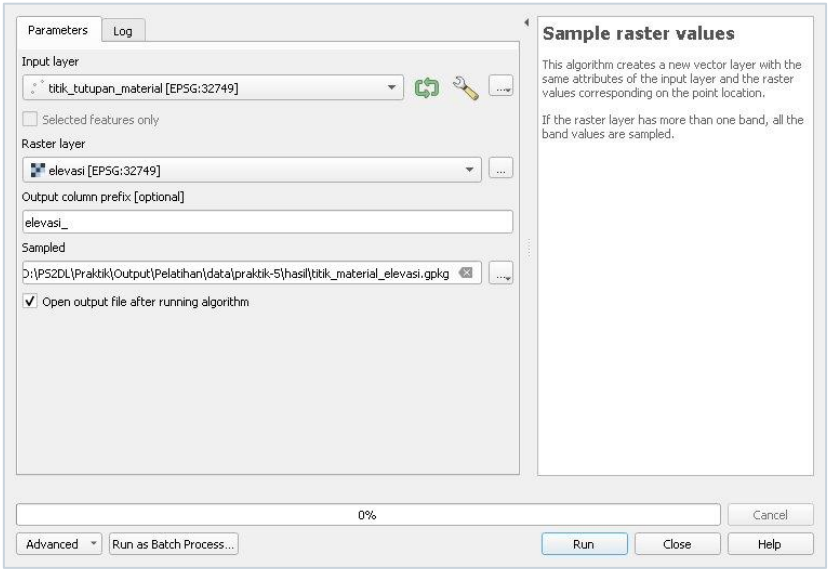


Gambar P5.9 Titik latih (hitam) dan titik uji (putih) di atas peta tutupan material

Sumber: Tangkapan layar uji coba; peta tutupan material dari Malik (2017)

Perhatikan titik-titik yang rapat di tengah Sub-DAS. Titik itu milik kelas 1, yang hanya seluas 9,7 ha tetapi tetap mendapat 30 titik.

3. Cari **Sample raster values** di Processing Toolbox. Isi **Input Layer** `titik_tutupan_material`, **Raster Layer** `elevasi`, **Output column prefix** `elevasi_`, lalu simpan ke `hasil/titik_material_elevasi.gpkg`.

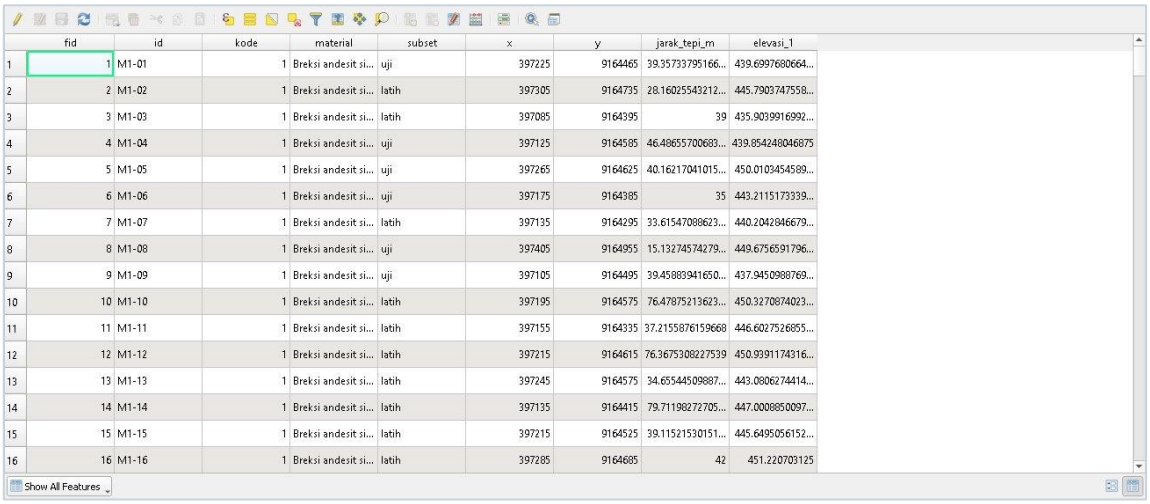


Gambar P5.10 Dialog Sample Raster Values

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

4. Buka tabel atribut hasilnya dengan tombol **F6**. Kolom `elevasi_1` berisi ketinggian di setiap titik.



	fid	id	kode	material	subset	x	y	jarak_tepi_m	elevasi_1
1	1	M1-01	1	Breksi andesit si...	uji	397225	9164465	39.35733795166...	439.6997680664...
2	2	M1-02	1	Breksi andesit si...	latih	397305	9164735	28.16025543212...	445.7903747558...
3	3	M1-03	1	Breksi andesit si...	latih	397085	9164395	39	435.9039916992...
4	4	M1-04	1	Breksi andesit si...	uji	397125	9164585	46.48655700683...	439.854248046875
5	5	M1-05	1	Breksi andesit si...	uji	397265	9164625	40.16217041015...	450.0103454589...
6	6	M1-06	1	Breksi andesit si...	uji	397175	9164385	35	443.2115173339...
7	7	M1-07	1	Breksi andesit si...	latih	397135	9164295	33.61547088623...	440.2042846679...
8	8	M1-08	1	Breksi andesit si...	uji	397405	9164955	15.13274574279...	449.6756591796...
9	9	M1-09	1	Breksi andesit si...	uji	397105	9164495	39.45883941650...	437.9450988769...
10	10	M1-10	1	Breksi andesit si...	latih	397195	9164575	76.47875213623...	450.3270874023...
11	11	M1-11	1	Breksi andesit si...	latih	397155	9164335	37.2155876159668	446.6027526855...
12	12	M1-12	1	Breksi andesit si...	latih	397215	9164615	76.3675308227539	450.9391174316...
13	13	M1-13	1	Breksi andesit si...	latih	397245	9164575	34.65544509887...	443.0806274414...
14	14	M1-14	1	Breksi andesit si...	latih	397135	9164415	79.71198272705...	447.0008850097...
15	15	M1-15	1	Breksi andesit si...	latih	397215	9164525	39.11521530151...	445.6495056152...
16	16	M1-16	1	Breksi andesit si...	latih	397285	9164685	42	451.220703125

Show All Features

Gambar P5.11 Tabel atribut titik latih dan uji

Sumber: Tangkapan layar uji coba

Langkah ini disebut penumpangan (*overlay*), dan satu baris pada tabel inilah contoh terkecil dari tabel pemodelan. Di notebook, langkah yang sama dilakukan sekaligus untuk 16 kovariat.

Titik periksa. Ada 210 titik, 30 titik untuk setiap kelas, dan semuanya berada di dalam batas Sub-DAS.

Tahap 4: Menyiapkan dan Memilih Kovariat

Kembali ke notebook, lalu jalankan **Bagian B**.

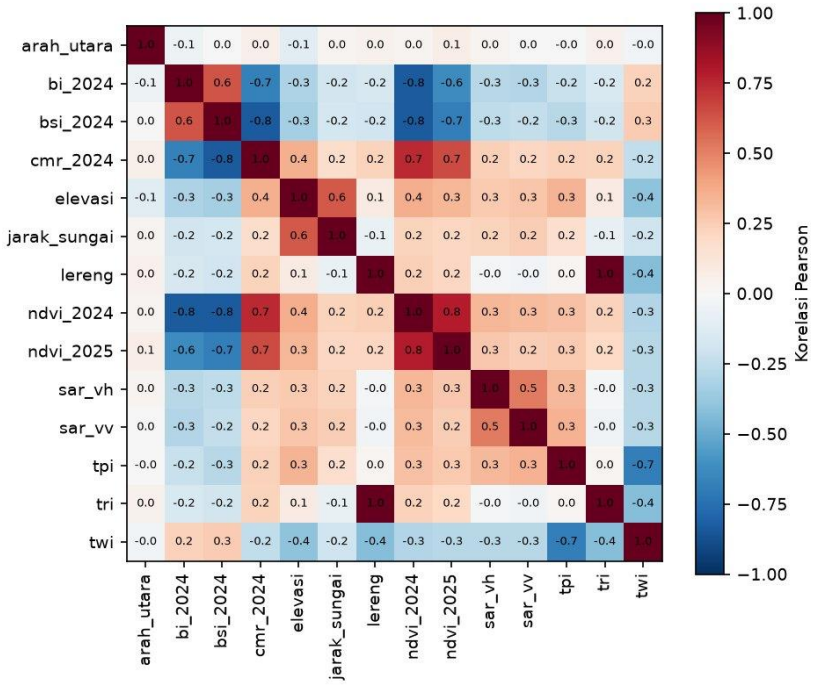
B1 memetakan kovariat ke faktor SCORPAN. Kali ini yang ditanyakan adalah seberapa jauh relief (r) dan data penginderaan jauh (o, s) mencerminkan bahan induk di bawahnya. Diskusikan alasan pada tabel itu. Rasio mineral lempung (`cmr_2024`), misalnya, masuk akal sebagai petunjuk mineral lempung hasil alterasi, tetapi Praktik 4 menunjukkan bahwa sebagian besar permukaan Sub-DAS tertutup vegetasi, sehingga citra lebih banyak merekam tajuk daripada tanah.

Tabel median per kelas pada A2 sudah memberi petunjuk awal. Kelas 6, yaitu endapan Sumbing Muda dan material longsor, sangat berbeda dari kelas lain. Median lerengnya 8,9%, sedangkan kelas lain 18,8–23,8%, dan median indeks kebasahan topografinya 7,4, sedangkan kelas lain 5,0–5,6. Enam kelas lainnya jauh lebih mirip satu sama lain.

B2 menghitung koefisien korelasi Pearson (*Pearson correlation coefficient*, r) antarkovariat dari seluruh piksel di dalam Sub-DAS. Empat pasangan memiliki $|r| \geq 0{,}8$ (Tabel P5.5). Pasangan itu baru dicatat, belum

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

dibuang. Kovariat mana yang dipertahankan diputuskan pada Tahap 5, setelah kepentingannya bagi model diketahui.



Gambar P5.12 Matriks korelasi Pearson antarkovariat

Sumber: Hasil uji coba

Tabel P5.5 Pasangan Kovariat dengan Korelasi Pearson |r| ≥ 0,8

Kovariat 1	Kovariat 2	r
bi_2024	ndvi_2024	−0,83
bsi_2024	cmr_2024	−0,83
bsi_2024	ndvi_2024	−0,83
lereng	tri	0,99

Sumber: Hasil uji coba, seluruh piksel di dalam Sub-DAS

B3 menyiapkan kovariat kategorik dalam dua bentuk. *Random forest* di scikit-learn memerlukan pengodean *one-hot* (*one-hot encoding*), yaitu satu kolom 0/1 untuk setiap kelas kategori, sehingga 16 kovariat menjadi 24 kolom. CatBoost menerima kolom berisi nama kelas apa adanya (*native categorical feature handling*). Kategori dengan sedikit nilai dikodekan *one-hot* di dalam model, sedangkan kategori dengan banyak nilai diubah menjadi statistik sasaran berurutan (*ordered target statistics*). Statistik ini pada dasarnya rata-rata sasaran per kategori, tetapi untuk setiap titik hanya dihitung dari titik-titik sebelumnya dalam suatu urutan acak, sehingga nilai sasaran titik itu tidak ikut menentukan kodenya sendiri (Prokhorenkova et al., 2018). Keunggulan ini paling terasa pada kategori yang sangat beragam, misalnya kode blok kebun atau varietas.

Tabel silang pada B3 memperlihatkan dua hal. Seluruh titik kelas 6 berada pada Dataran Koluvial dan Lereng Kaki Koluvial, dan di kedua bentuklahan itu hanya ada satu titik dari kelas lain. Selain itu, penggunaan lahan didominasi agroforestri, yaitu 149 dari 210 titik. Kecocokan bentuklahan dengan kelas 6 masuk akal secara proses, tetapi perlu diingat bahwa peta bentuklahan dan peta material sama-sama hasil kajian geomorfologi di wilayah yang sama. Sebagian kecocokan itu mungkin terjadi karena batasnya ditarik dengan cara yang serupa.

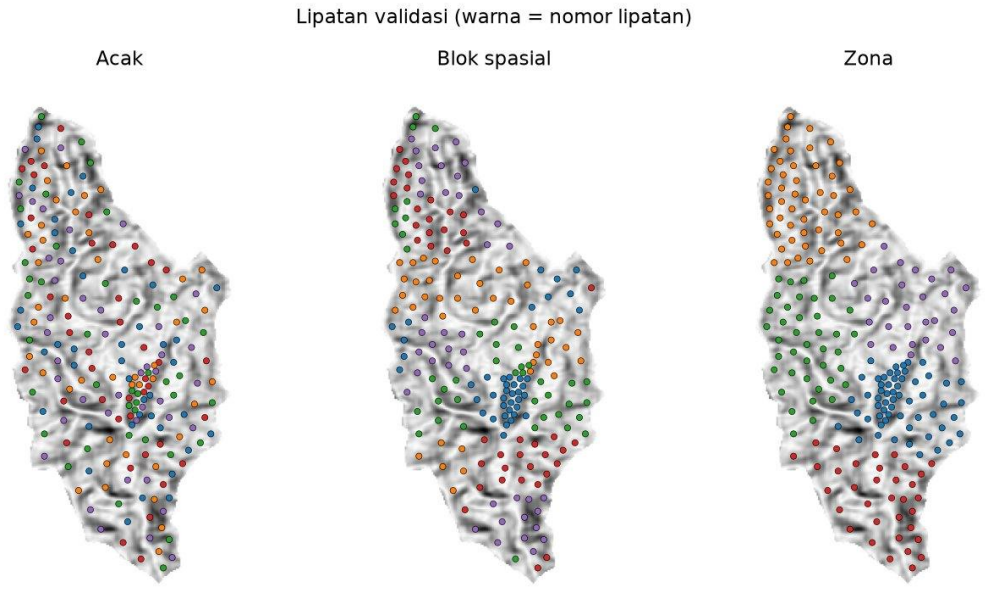
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Titik periksa. `hasil/korelasi_kovariat.png` terbentuk, dan tabel CatBoost berukuran 210 baris dan 16 kolom.

Tahap 5: Membangun, Menilai, dan Memilih Kovariat Model

Jalankan **Bagian C**, sel C1 sampai C4.

C1 membentuk tiga skema validasi silang (*cross-validation*). Skema acak (*stratified random k-fold cross-validation*) membagi titik secara acak ke dalam lima lipatan (*fold*). Skema blok spasial (*spatial block cross-validation*) membagi wilayah menjadi blok persegi 400 m, dan setiap blok utuh masuk ke satu lipatan. Skema zona (*leave-cluster-out cross-validation*) mengelompokkan titik menjadi lima zona besar dengan *k-means*, sehingga meniru penerapan model ke wilayah yang benar-benar baru. Pada skema zona, satu lipatan tidak memiliki satu pun titik latih kelas 7, sehingga kelas itu mustahil ditebak benar pada lipatan tersebut.



Gambar P5.13 Tiga skema validasi, dengan warna yang menunjukkan nomor lipatan

Sumber: Hasil uji coba

C2 membandingkan empat model. Dua di antaranya adalah pembanding sederhana (*baseline*), yaitu menebak kelas terbanyak (*majority class*) dan memberi satu kelas material untuk setiap bentuklahan. Pembanding kedua setara dengan peta konvensional, yang memberi satu label untuk setiap satuan peta.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P5.6 Hasil Validasi Silang Klasifikasi Tutupan Material

Model	Validasi	Akurasi	Kappa	Presisi makro	Recall makro	F1 makro
Kelas terbanyak	Acak	0,14	0,00	0,02	0,14	0,04
Kelas terbanyak	Blok spasial	0,02	−0,14	0,00	0,02	0,01
Kelas terbanyak	Zona	0,00	−0,17	0,00	0,00	0,00
Kelas terbanyak per bentuklahan	Acak	0,30	0,18	0,23	0,30	0,25
Kelas terbanyak per bentuklahan	Blok spasial	0,19	0,05	0,18	0,19	0,18
Kelas terbanyak per bentuklahan	Zona	0,15	0,01	0,14	0,15	0,15
Random forest (*one-hot*)	Acak	0,51	0,43	0,47	0,51	0,49
Random forest (*one-hot*)	Blok spasial	0,37	0,26	0,35	0,37	0,35
Random forest (*one-hot*)	Zona	0,19	0,05	0,18	0,19	0,18
CatBoost	Acak	0,48	0,39	0,45	0,48	0,46
CatBoost	Blok spasial	0,38	0,28	0,37	0,38	0,37
CatBoost	Zona	0,18	0,04	0,18	0,18	0,18

Sumber: Hasil uji coba dengan 16 kovariat; tersimpan di `metrik_validasi_material.csv`

Bandingkan setiap model pada ketiga skema validasi. Pada validasi acak dan blok spasial, kedua model pembelajaran mesin (*machine learning*) jelas melampaui pembanding sederhana. Akurasi blok spasial sekitar 0,1 lebih rendah daripada akurasi acak, karena pada validasi acak titik uji selalu memiliki tetangga dekat di data latih. Pada skema zona, akurasi kedua model turun menjadi 0,18–0,19 dan kappanya hanya 0,04–0,05, sedikit di atas menebak sembarang. Model yang dipelajari di satu bagian Sub-DAS hampir tidak berlaku di bagian lain. Ini peringatan penting sebelum memakai model dari satu kebun untuk kebun tetangga.

CatBoost dan *random forest* praktis sama. Sel tambahan pada C2 juga menunjukkan bahwa cara CatBoost mengodekan kategori tidak memperbaiki hasil. Dengan *one-hot* di dalam model, akurasi blok spasialnya 0,38, sedangkan dengan statistik sasaran berurutan, yaitu pengaturan bawaannya, akurasinya 0,35 dan waktunya sekitar enam kali lebih lama (37 detik dibanding 6 detik pada komputer uji coba). Hanya ada dua kovariat kategorik, masing-masing dengan 6 dan 4 kelas, sehingga keunggulan CatBoost dalam mengolah kategori belum mendapat kesempatan untuk tampak.

Kappa dan recall makro perlu dibaca dengan hati-hati pada data ini. Jumlah titik setiap kelas sama, sehingga kappa hanyalah akurasi yang diskalakan ulang, yaitu (akurasi − 1/7) / (1 − 1/7), dan recall makro persis sama dengan akurasi. Kappa negatif pada pembanding kelas terbanyak berarti tebakannya lebih buruk daripada kebetulan. Presisi makro dapat berbeda dari akurasi karena nilainya turun bila model sering memberikan suatu kelas kepada titik yang sebenarnya bukan kelas itu. Kappa tetap dilaporkan karena lazim dipakai dalam penilaian ketelitian peta, walaupun Pontius dan Millones (2011) menganjurkan agar kappa diganti dengan ukuran selisih jumlah (*quantity disagreement*) dan selisih letak kelas (*allocation disagreement*).

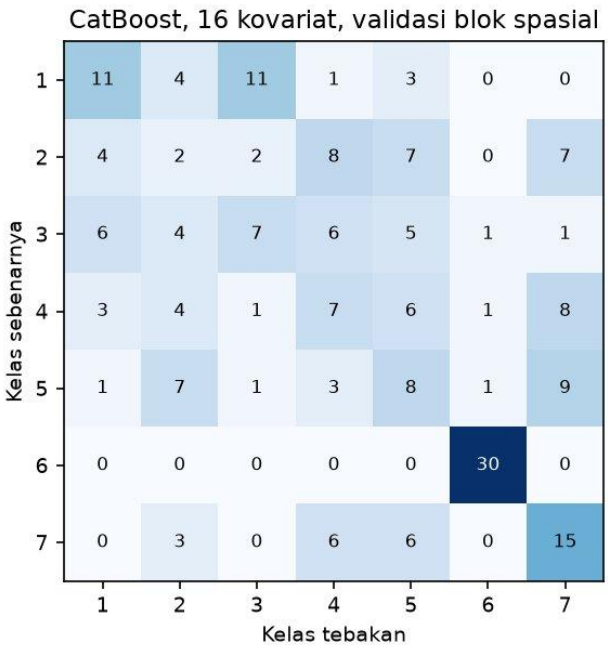
C3 menampilkan matriks kebingungan (*confusion matrix*) CatBoost pada validasi blok spasial. Dalam penginderaan jauh, matriks ini juga disebut matriks kesalahan (*error matrix*). Baris matriks adalah kelas

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

sebenarnya, sedangkan kolomnya adalah kelas tebakan model. Dari matriks itu dihitung tiga ukuran per kelas:

1. **Recall** (*recall* atau *sensitivity*), yaitu proporsi titik suatu kelas yang ditebak benar. Dalam penilaian ketelitian peta, ukuran ini disebut akurasi pembuat (*producer's accuracy*), karena menyatakan seberapa lengkap pembuat peta menangkap kelas itu (Congalton, 1991).
2. **Presisi** (*precision*), yaitu proporsi tebakan suatu kelas yang memang benar. Ukuran ini disebut akurasi pengguna (*user's accuracy*), karena menyatakan seberapa besar peluang pengguna menemukan kelas itu di lapangan bila peta menyebutkannya.
3. **F1** (*F1-score*), yaitu rata-rata harmonik (*harmonic mean*) presisi dan recall, sehingga nilainya hanya tinggi bila keduanya tinggi.

Kebalikan recall disebut kesalahan omisi (*omission error*), yaitu bagian titik suatu kelas yang terlewat. Kebalikan presisi disebut kesalahan komisi (*commission error*), yaitu bagian tebakan suatu kelas yang sebenarnya milik kelas lain. Rata-rata ketiga ukuran itu untuk ketujuh kelas adalah ukuran makro pada Tabel P5.6.



Gambar P5.14 Matriks kebingungan CatBoost pada validasi blok spasial

Sumber: Hasil uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tabel P5.7 Ketelitian per Kelas pada Validasi Blok Spasial

Kode	Material	Recall	Presisi	F1
1	Breksi andesit sisipan diorit	0,37	0,44	0,40
2	Breksi andesit teralterasi	0,07	0,08	0,07
3	Breksi andesit teralterasi, ditumpangi lapukan batupasir Menoreh	0,23	0,32	0,27
4	Breksi vulkanik	0,23	0,23	0,23
5	Endapan material Sumbing Muda, pasir tufan, tuff pasiran, breksi andesit	0,27	0,23	0,25
6	Endapan Sumbing Muda dan endapan material longsor	1,00	0,91	0,95
7	Tuff pasiran	0,50	0,38	0,43

Sumber: Hasil uji coba, CatBoost dengan 16 kovariat; recall setara dengan *producer's accuracy* dan presisi setara dengan *user's accuracy*

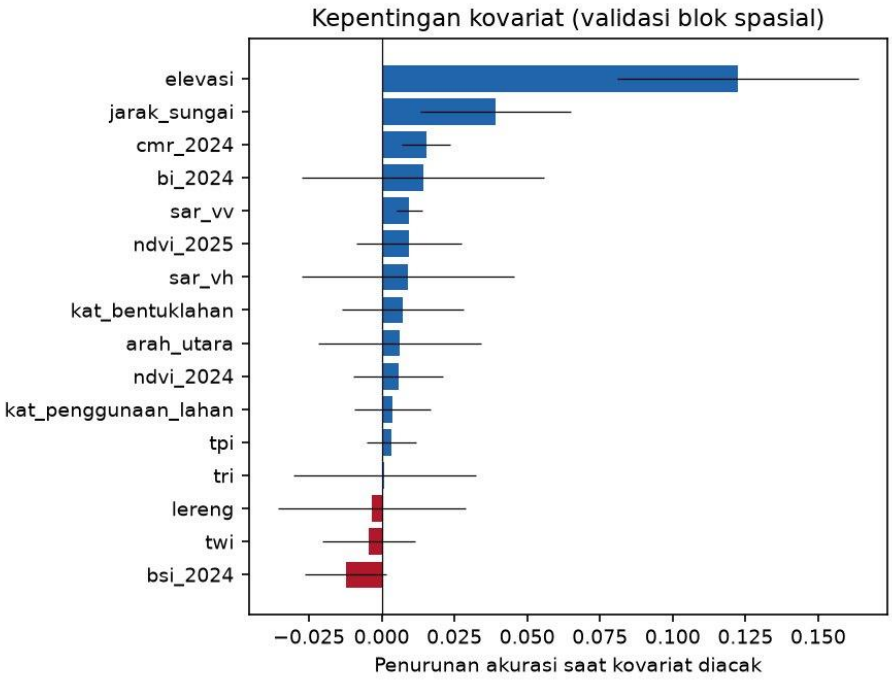
Semua titik kelas 6 ditebak benar, karena kelas ini menempati dataran dan kaki lereng koluvial yang landai dan dekat sungai. Kelas 2, yaitu breksi andesit teralterasi, paling sering tertukar dengan kelas lain (F1 0,07), disusul kelas 4, kelas 5, dan kelas 3 (F1 0,23–0,27). Kelas-kelas itu berupa batuan breksi dan endapan pada lereng perbukitan, dan kovariat yang tersedia hampir tidak membedakannya.

C4 memilih kovariat untuk model akhir dengan dua informasi. Tingkat kepentingan (*variable importance*) dihitung dengan permutasi (*permutation importance*), yaitu mengacak nilai satu kovariat pada data uji setiap lipatan blok spasial, lalu mengukur penurunan akurasinya. Kepentingan sengaja dihitung pada data yang tidak dipakai melatih model, karena kepentingan dari data latih dapat menonjolkan kovariat yang hanya membantu model menghafal (Meyer et al., 2019). Aturan pemilihannya adalah sebagai berikut:

1. **Urutan**, yaitu kovariat diurutkan dari kepentingan permutasi terbesar.
2. **Kepentingan positif**, yaitu kovariat dengan kepentingan ≤ 0 dibuang, karena mengacaknya tidak menurunkan akurasi pada data yang belum pernah dilihat model.
3. **Korelasi Pearson**, yaitu kovariat numerik yang berkorelasi $|r| \geq 0{,}8$ dengan kovariat terpilih yang lebih penting dibuang, sehingga dari setiap pasangan pada Tabel P5.5 hanya satu yang dipertahankan.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Ketiga aturan itu menggabungkan dua sudut pandang. Kepentingan menjawab kovariat mana yang benar-benar dipakai model pada data baru, sedangkan korelasi menjawab kovariat mana yang hanya mengulang informasi kovariat lain.



Gambar P5.15 Kepentingan permutasi kovariat, dengan garis yang menunjukkan simpangan baku antarlipatan

Sumber: Hasil uji coba

Tabel P5.8 Kepentingan Kovariat dan Keputusan Pemilihan

Kovariat	Kepentingan permutasi	Kepentingan bawaan CatBoost (%)	Keputusan
elevasi	0,122	22,5	Dipakai
jarak_sungai	0,039	12,5	Dipakai
cmr_2024	0,015	3,7	Dipakai
bi_2024	0,014	6,9	Dipakai
sar_vv	0,010	5,3	Dipakai
ndvi_2025	0,010	3,4	Dipakai
sar_vh	0,009	5,3	Dipakai
kat_bentuklahan	0,007	4,0	Dipakai
arah_utara	0,006	6,1	Dipakai
ndvi_2024	0,006	4,6	Dibuang, r = −0,83 dengan bi_2024
kat_penggunaan_lahan	0,004	6,1	Dipakai
tpi	0,003	5,9	Dipakai
tri	0,001	3,9	Dipakai
lereng	−0,003	4,5	Dibuang, kepentingan ≤ 0
twi	−0,004	2,6	Dibuang, kepentingan ≤ 0
bsi_2024	−0,012	2,8	Dibuang, kepentingan ≤ 0

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Sumber: Hasil uji coba; kepentingan permutasi berupa penurunan akurasi rata-rata pada lima lipatan blok spasial

Ketinggian adalah kovariat terpenting dengan selisih jauh, disusul jarak ke sungai. Kecuali untuk `elevasi`, `jarak_sungai`, `cmr_2024`, dan `sar_vv`, simpangan antarlipatan pada Gambar P5.15 lebih besar daripada nilai kepentingannya sendiri, sehingga urutan kovariat lainnya tidak stabil. Kepentingan bawaan CatBoost (*built-in feature importance*), yang dihitung dari data latih, memberi gambaran yang berbeda. `kat_penggunaan_lahan`, misalnya, memperoleh 6,1% pada kepentingan bawaan, tetapi mengacaknya hanya menurunkan akurasi sebesar 0,004 pada data uji. `lereng` dan `tri` hampir identik (r = 0,99). Dari pasangan itu `tri` yang dipertahankan, karena `lereng` sudah tersisih oleh aturan kepentingan. Hal yang sama terjadi pada pasangan `bsi_2024` dan `cmr_2024`.

Tabel P5.9 Pengaruh Pemilihan Kovariat pada Ketelitian CatBoost

Kovariat	Jumlah	Validasi	Akurasi	Kappa	Presisi makro	Recall makro	F1 makro
Semua kovariat	16	Acak	0,48	0,39	0,45	0,48	0,46
Semua kovariat	16	Blok spasial	0,38	0,28	0,37	0,38	0,37
Kovariat terpilih	12	Acak	0,53	0,46	0,50	0,53	0,51
Kovariat terpilih	12	Blok spasial	0,40	0,29	0,38	0,40	0,39
Dipilih ulang di dalam setiap lipatan (*nested*)	5–10	Blok spasial	0,37	0,27	0,35	0,37	0,36

Sumber: Hasil uji coba

Dengan 12 kovariat, akurasi blok spasial naik sedikit dari 0,38 menjadi 0,40. Angka itu optimistis, karena kovariat dipilih memakai lipatan yang sama dengan yang dipakai untuk menilainya. Jika pemilihan diulang di dalam setiap lipatan hanya dari data latihnya, yang disebut validasi silang bersarang (*nested cross-validation*), akurasinya 0,37, praktis sama dengan memakai semua kovariat. Jadi, pada data ini pemilihan kovariat tidak menaikkan ketelitian. Manfaatnya adalah model yang lebih ramping dan tersingkirnya kovariat yang hanya mengulang informasi kovariat lain. Kovariat yang terpilih juga berubah dari lipatan ke lipatan. Setiap lipatan memilih 5 sampai 10 kovariat, dan hanya tiga yang selalu terpilih, yaitu `elevasi`, `jarak_sungai`, dan `bi_2024`. Hasil pemilihan kovariat pada data sebanyak ini tidak boleh dianggap sebagai daftar baku.

Titik periksa. Folder `hasil/` berisi `metrik_validasi_material.csv`, `matriks_kebingungan.png`, dan `kepentingan_kovariat.png`, dan notebook mencetak 12 kovariat terpilih.

Tahap 6: Menangani Data yang Tidak Seimbang

Jalankan sel C5.

Data latihan ini seimbang, tetapi di kebun keadaan seperti itu jarang terjadi. Bila titik disebar acak, jumlah titik setiap kelas kira-kira sebanding dengan luasnya, sehingga datanya menjadi tidak seimbang (*imbalanced data*). Kelas yang sempit hanya memperoleh sedikit titik dan model cenderung mengabaikannya. C5 menirukan keadaan itu. Pada setiap lipatan blok spasial, titik latih dikurangi sehingga jumlahnya sebanding dengan luas kelas, lalu tiga cara dibandingkan:

1. **Tanpa penanganan**, yaitu model dilatih apa adanya.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

2. **Bobot kelas** (*class weighting*), yaitu kesalahan pada kelas yang sedikit titiknya diberi bobot lebih besar. Pada CatBoost, `auto_class_weights='Balanced'` memberi setiap kelas bobot sebesar jumlah titik kelas terbanyak dibagi jumlah titik kelas itu.
3. **SMOTE-NC** (*Synthetic Minority Over-sampling Technique–Nominal Continuous*), yaitu titik sintetis (*synthetic samples*) ditambahkan pada kelas yang sedikit dengan menginterpolasi antara sebuah titik dan tetangganya di ruang kovariat (Chawla et al., 2002), memakai pustaka imbalanced-learn (Lemaître et al., 2017). Akhiran NC menandakan bahwa kovariat kategorik ikut ditangani, yaitu titik sintetis mengambil kategori yang paling sering muncul di antara tetangganya.

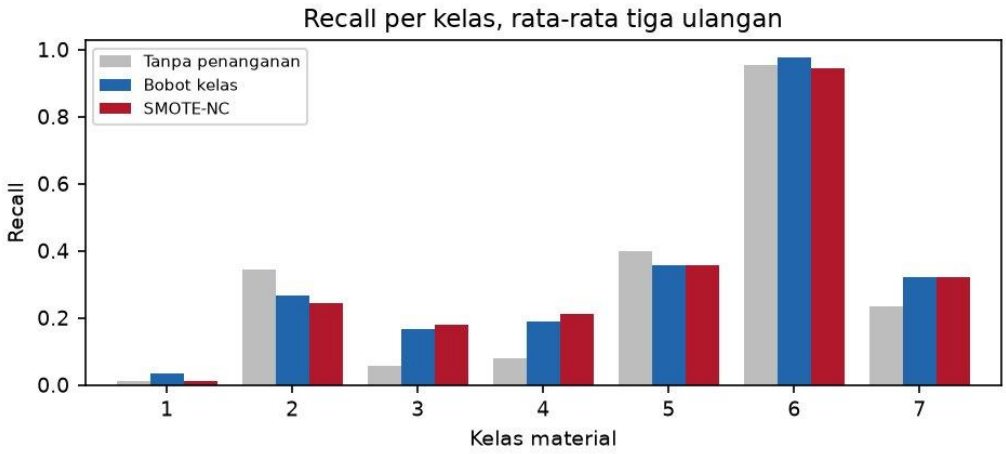
Kedua penanganan hanya diterapkan pada data latih setiap lipatan. Bila titik sintetis dibuat sebelum data dibagi, informasi dari titik uji ikut masuk ke data latih (*data leakage*) dan akurasinya menjadi semu. Metode SMOGN (*SMOTE for regression with Gaussian noise*) sering disebut dalam konteks yang sama, tetapi metode itu dirancang untuk sasaran kontinu yang nilai ekstremnya jarang, misalnya C-organik yang sangat tinggi (Branco et al., 2017). Untuk sasaran berupa kelas seperti tutupan material, padanannya adalah SMOTE.

Tabel P5.10 Pengaruh Penanganan Data Tidak Seimbang pada Validasi Blok Spasial

Ukuran	Tanpa penanganan	Bobot kelas	SMOTE-NC
Akurasi	0,30	0,33	0,32
Kappa	0,18	0,22	0,21
Presisi makro	0,31	0,33	0,31
Recall makro	0,30	0,33	0,32
F1 makro	0,27	0,31	0,31
Recall kelas 1	0,01	0,03	0,01
Recall kelas 2	0,34	0,27	0,24
Recall kelas 3	0,06	0,17	0,18
Recall kelas 4	0,08	0,19	0,21
Recall kelas 5	0,40	0,36	0,36
Recall kelas 6	0,96	0,98	0,94
Recall kelas 7	0,23	0,32	0,32

Sumber: Hasil uji coba, rata-rata tiga ulangan pengurangan titik

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P5.16 Recall per kelas pada tiga cara penanganan data tidak seimbang

Sumber: Hasil uji coba

Penanganan menaikkan kappa dari 0,18 menjadi 0,21–0,22 dan F1 makro dari 0,27 menjadi 0,31. Recall kelas yang berukuran sedang juga naik, misalnya kelas 3 dari 0,06 menjadi 0,17–0,18, kelas 4 dari 0,08 menjadi 0,19–0,21, dan kelas 7 dari 0,23 menjadi 0,32, dengan mengorbankan sebagian recall kelas yang luas. Recall kelas 2, kelas terluas, turun dari 0,34 menjadi 0,27 dengan bobot kelas dan 0,24 dengan SMOTE-NC, sedangkan recall kelas 5, kelas terluas kedua, turun dari 0,40 menjadi 0,36. Untuk kelas 1, keduanya praktis tidak membantu. Setelah dikurangi, kelas ini kadang hanya memiliki satu titik latih dalam satu lipatan. Dari satu titik, SMOTE tidak dapat menginterpolasi apa pun, dan bobot sebesar apa pun hanya memperkuat satu contoh. Penyeimbangan tidak dapat menciptakan informasi yang tidak ada di dalam data.

Penyeimbangan juga mengubah luas kelas pada peta, seperti terlihat pada Tabel P5.11.

Tabel P5.11 Proporsi Luas Kelas pada Peta Prediksi (%)

Rancangan sampel dan cara	1	2	3	4	5	6	7
Peta acuan	3,3	25,6	13,0	13,5	22,9	12,0	9,7
Sampel seimbang (30 per kelas)	10,2	13,3	18,7	14,2	15,1	14,3	14,2
Sebanding luas, tanpa penanganan	0,5	34,4	12,7	9,1	24,5	14,0	4,9
Sebanding luas, bobot kelas	2,7	24,5	16,7	11,1	21,7	15,1	8,2
Sebanding luas, SMOTE-NC	3,2	23,7	16,0	13,7	19,4	14,6	9,3

Sumber: Hasil uji coba, CatBoost dengan kovariat terpilih yang dilatih dengan seluruh titik

Model yang dilatih dari sampel sebanding luas tanpa penanganan memperluas kelas yang besar dan hampir menghilangkan kelas 1. Sebaliknya, model dari sampel seimbang memperluas kelas 1 sekitar tiga kali lipat dan menyempitkan kelas 2 menjadi sekitar separuhnya. Model menganggap setiap kelas sama umumnya dengan di data latihnya. Karena itu, rancangan sampel dan cara penanganan harus mengikuti tujuan peta. Jika yang penting adalah menemukan kelas yang jarang, misalnya bahan induk tertentu yang bermasalah, recall kelas itulah yang dikejar. Jika yang penting adalah luas setiap kelas, proporsi pada peta perlu dibandingkan dengan sumber lain. Pada uji coba ini, sampel sebanding luas yang diberi bobot kelas atau SMOTE-NC menghasilkan proporsi yang paling dekat dengan peta acuan, tetapi hasil dari satu wilayah seperti ini belum dapat dijadikan aturan umum.

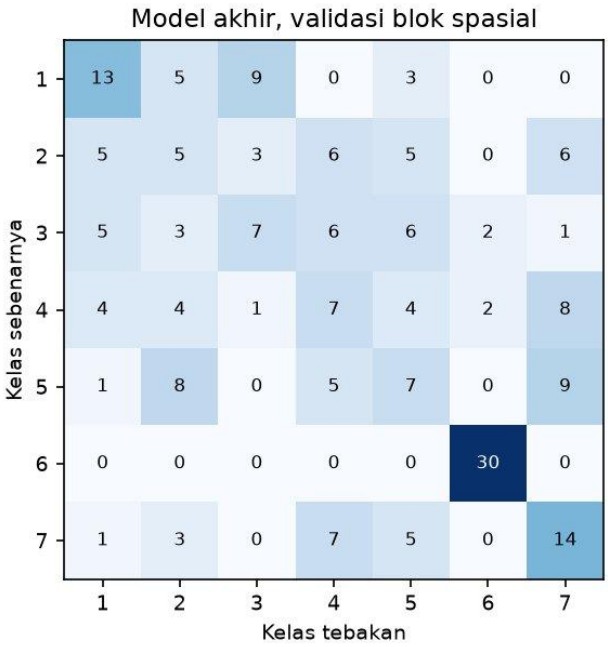
Titik periksa. Folder `hasil/` berisi `recall_data_tidak_seimbang.png`.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Tahap 7: Peta Kelas, Peluang, dan Keberlakuan Model

Jalankan sel C6 sampai C9.

C6 diawali dengan penilaian ketelitian (*accuracy assessment*) model akhir, yaitu CatBoost dengan 12 kovariat terpilih. Ketelitian sebuah peta tidak dapat dinilai dari titik yang dipakai untuk melatih modelnya, sehingga yang dilaporkan adalah hasil validasi blok spasial dengan kovariat dan pengaturan yang sama. Inilah penilaian yang lazim menyertai sebuah peta kelas, yaitu matriks kebingungan, akurasi pembuat dan akurasi pengguna setiap kelas, serta ukuran keseluruhannya (Congalton, 1991).



Gambar P5.17 Matriks kebingungan model akhir pada validasi blok spasial

Sumber: Hasil uji coba

Tabel P5.12 Ketelitian Model Akhir per Kelas pada Validasi Blok Spasial

Kode	Material	Recall	Presisi	F1
1	Breksi andesit sisipan diorit	0,43	0,45	0,44
2	Breksi andesit teralterasi	0,17	0,18	0,17
3	Breksi andesit teralterasi, ditumpangi lapukan batupasir Menoreh	0,23	0,35	0,28
4	Breksi vulkanik	0,23	0,23	0,23
5	Endapan material Sumbing Muda, pasir tufan, tuff pasiran, breksi andesit	0,23	0,23	0,23
6	Endapan Sumbing Muda dan endapan material longsor	1,00	0,88	0,94
7	Tuff pasiran	0,47	0,37	0,41
	Rata-rata makro	0,40	0,38	0,39

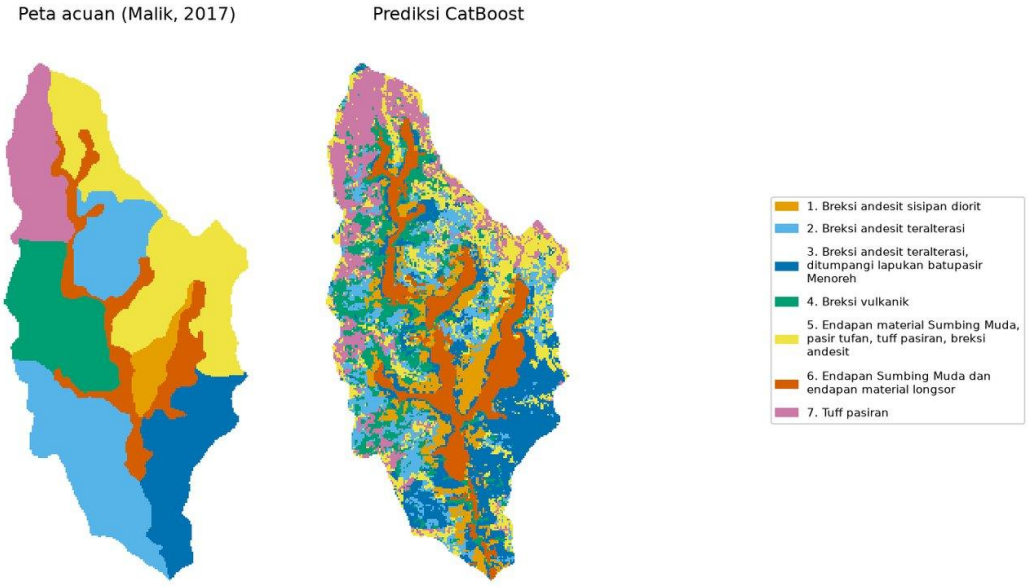
Sumber: Hasil uji coba, CatBoost dengan 12 kovariat terpilih; recall setara dengan *producer's accuracy* dan presisi setara dengan *user's accuracy*; tersimpan di `laporan_per_kelas_model_akhir.csv`

Secara keseluruhan, model akhir mencapai akurasi 0,40, kappa 0,29, presisi makro 0,38, recall makro 0,40, dan F1 makro 0,39. Angka ini sedikit optimistis karena kovariatnya dipilih dengan lipatan yang sama, sedangkan validasi silang bersarang pada Tahap 5 memberi akurasi 0,37. Matriks pada Gambar P5.17 juga memperlihatkan arah kesalahannya. Seluruh 30 titik kelas 6 ditebak benar, sehingga akurasi pembuatnya

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

1,00, tetapi 4 dari 34 titik yang ditebak sebagai kelas 6 sebenarnya kelas 3 dan kelas 4, sehingga akurasi penggunanya 0,88. Kelas 7 paling sering ditebak, yaitu 38 kali, karena 9 titik kelas 5 dan 8 titik kelas 4 ikut masuk ke kelas itu. Akibatnya, akurasi pengguna kelas 7 (0,37) lebih rendah daripada akurasi pembuatnya (0,47). Sebaliknya, kelas 3 hanya ditebak 20 kali, sehingga akurasi penggunanya (0,35) lebih tinggi daripada akurasi pembuatnya (0,23). Akurasi pengguna menjawab seberapa sering label pada peta sesuai dengan acuannya, sedangkan akurasi pembuat menjawab seberapa lengkap suatu kelas tertangkap oleh peta. Pengguna peta memerlukan keduanya.

Peta dibuat dengan melatih model yang sama pada seluruh 210 titik, lalu menerapkannya ke setiap piksel.



Gambar P5.18 Peta acuan dan peta prediksi tutupan material

Sumber: Hasil uji coba; peta acuan dari Malik (2017); prediksi model latihan, bukan peta bahan induk yang tervalidasi

Empat pemeriksaan berikut lebih penting daripada tampilan petanya:

1. **Kesesuaian dengan peta acuan**, yaitu 46,1% piksel prediksi sama dengan peta acuan. Kelas 6 paling sesuai, dengan 89,6% luasnya diprediksi benar, sedangkan kelas 2 hanya 25,9%. Angka ini bukan validasi independen, karena titik latih diambil dari peta yang sama, tetapi menunjukkan seberapa jauh model mereproduksi peta itu di antara titik-titiknya.
2. **Luas setiap kelas**, yaitu kelas 1 diprediksi seluas 30,2 ha padahal pada peta acuan hanya 9,7 ha, sedangkan kelas 2 hanya 39,2 ha dari 75,5 ha. Model akhir dilatih dengan 30 titik per kelas, sehingga inilah sisi lain dari persoalan pada Tahap 6.
3. **Tekstur peta**, yaitu peta acuan berupa poligon utuh hasil delineasi, sedangkan peta prediksi berbintik karena setiap piksel ditebak sendiri-sendiri. Bintik itu bukan informasi baru tentang batuan, melainkan tanda ketidakpastian model.
4. **Peluang** (*class probability*), yaitu rata-rata peluang kelas tertinggi di seluruh peta 0,51, dan hanya 17,3% piksel yang memiliki peluang ≥ 0,7. Kejujuran peluang itu diperiksa pada Tabel P5.13.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

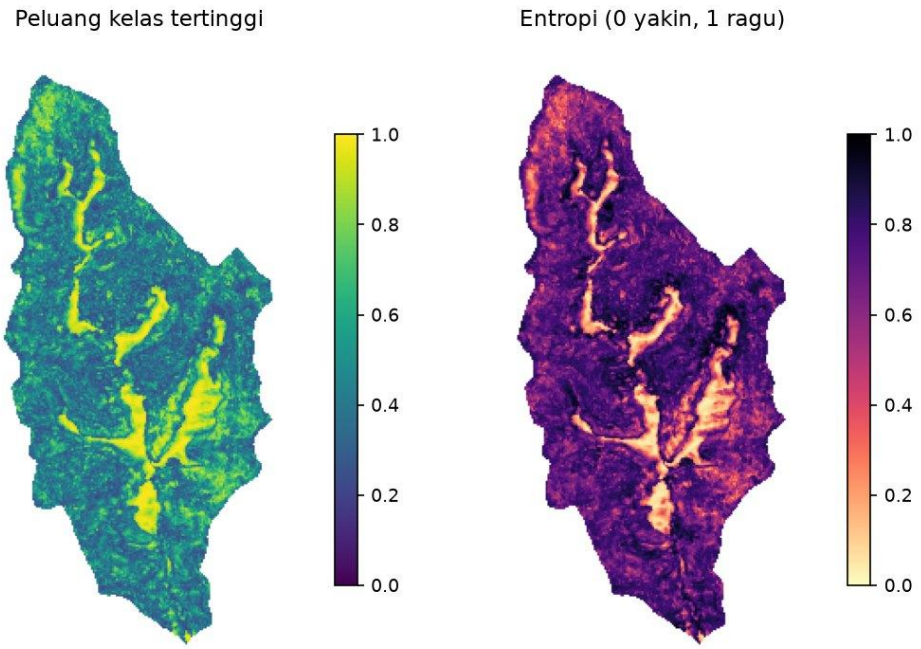
Tabel P5.13 Peluang Kelas Tertinggi dan Proporsi Tebakan yang Benar

Peluang kelas tertinggi	Jumlah titik	Proporsi benar
≤ 0,3	20	0,15
0,3–0,5	103	0,29
0,5–0,7	47	0,38
> 0,7	40	0,80

Sumber: Hasil uji coba, prediksi validasi blok spasial dengan kovariat terpilih

Titik yang diprediksi dengan peluang di atas 0,7 benar pada 80% kasus, sedangkan titik dengan peluang yang lebih rendah hanya benar pada 15–38% kasus. Jadi, peta peluang dapat dipakai untuk memisahkan bagian peta yang dapat dipegang dari bagian yang sebaiknya diperiksa di lapangan. Peluang dari model *boosting* belum tentu terkalibrasi sempurna (*well-calibrated*), sehingga pemeriksaan seperti ini perlu diulang setiap kali model berubah.

Peta pada Gambar P5.19 menampilkan peluang kelas tertinggi bersama entropi (*entropy*), yang meringkas sebaran peluang ke semua kelas. Entropi 0 berarti model yakin penuh pada satu kelas, sedangkan entropi 1 berarti ketujuh kelas sama mungkin.



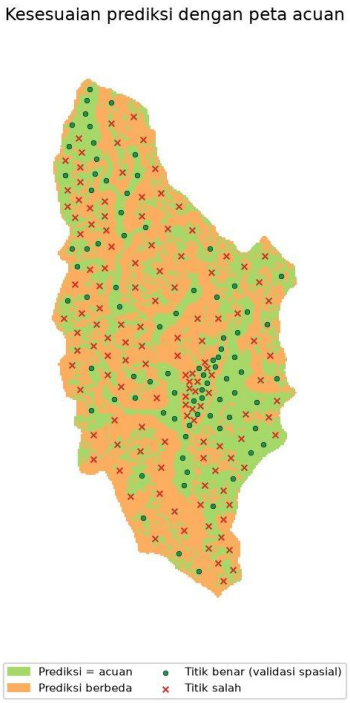
Gambar P5.19 Peluang kelas tertinggi dan entropi peluang

Sumber: Hasil uji coba

Sel C8 menghitung wilayah keberlakuan model (*area of applicability*, AOA; Meyer & Pebesma, 2021) dari indeks ketidakmiripan (*dissimilarity index*, DI), yaitu jarak setiap piksel ke titik latih terdekat dalam ruang kovariat yang dibobot menurut kepentingannya. Pada uji coba, 97,8% piksel berada di dalam AOA dengan ambang DI 0,31. Hasil ini perlu dibaca bersama Tabel P5.6. Hampir semua piksel memiliki kombinasi kovariat yang mirip dengan titik latih, tetapi validasi zona menunjukkan bahwa model hampir gagal di wilayah yang belum dilihatnya. AOA hanya memeriksa kemiripan kovariat, sehingga tidak dapat mendeteksi keadaan ketika nilai kovariat yang sama, misalnya ketinggian yang sama, ditempati material yang berbeda di bagian Sub-DAS yang berbeda.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Sel C9 memetakan kesesuaian prediksi dengan peta acuan (*agreement map*), bersama titik yang salah pada validasi blok spasial. Dari 210 titik, 127 titik salah, sama dengan jumlah titik di luar diagonal matriks pada Gambar P5.17. Kesalahan terbanyak terjadi pada kelas 2 (25 dari 30 titik), disusul kelas 3, kelas 4, dan kelas 5 yang masing-masing salah pada 23 titik, sedangkan seluruh titik kelas 6 benar.



Gambar P5.20 Kesesuaian prediksi dengan peta acuan dan titik yang salah pada validasi blok spasial

Sumber: Hasil uji coba

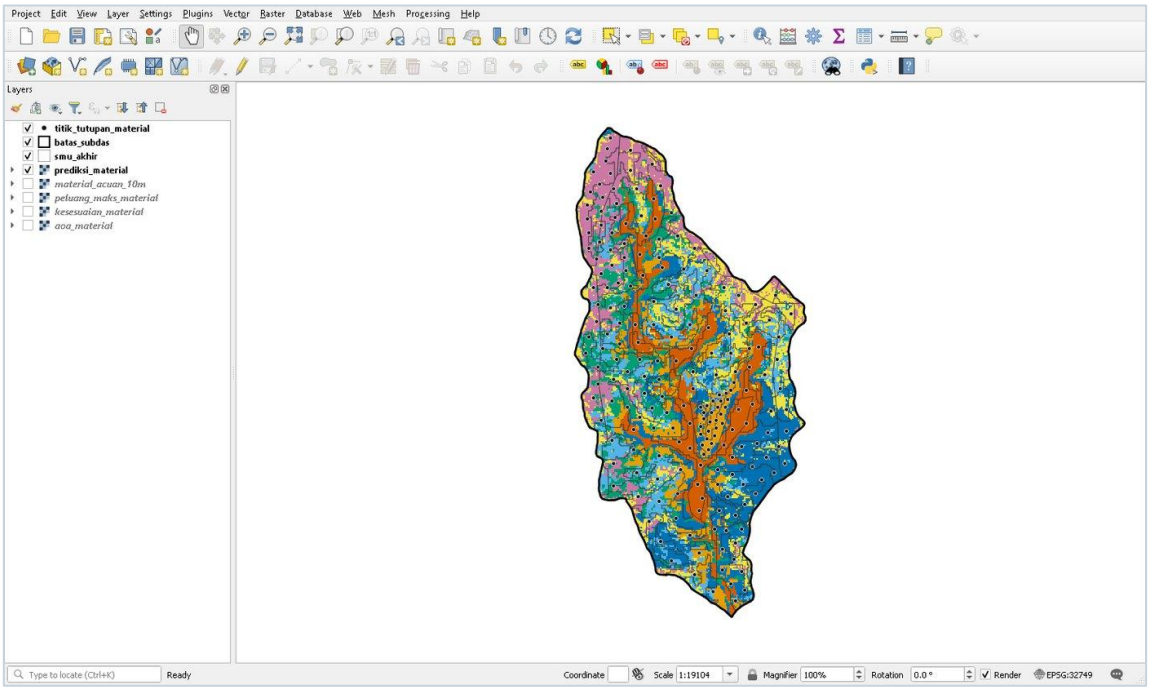
Titik periksa. Folder `hasil/` berisi `matriks_kebingungan_model_akhir.png`, `laporan_per_kelas_model_akhir.csv`, `prediksi_material.tif`, `peluang_maks_material.tif`, `entropi_material.tif`, `di_material.tif`, `aoa_material.tif`, dan `kesesuaian_material.tif`.

Tahap 8: Menampilkan Hasil di QGIS

1. Muat `hasil/prediksi_material.tif`, `hasil/peluang_maks_material.tif`, `hasil/kesesuaian_material.tif`, `hasil/aoa_material.tif`, `smu_akhir.gpkg`, dan `titik_tutupan_material.gpkg`.
2. Notebook menyalin berkas gaya peta acuan menjadi `hasil/prediksi_material.qml`, sehingga peta prediksi langsung tampil dengan warna dan nama kelas yang sama dengan peta acuan. Tampilkan `kesesuaian_material` sebagai **Paletted/Unique values**, klik **Classify**, lalu beri nilai 1 warna hijau dengan label *Sama dengan peta acuan* dan nilai 2 warna jingga dengan label *Berbeda*. Lakukan hal yang sama pada `aoa_material` untuk nilai 0 (di luar AOA) dan 1 (di dalam AOA). Tampilkan

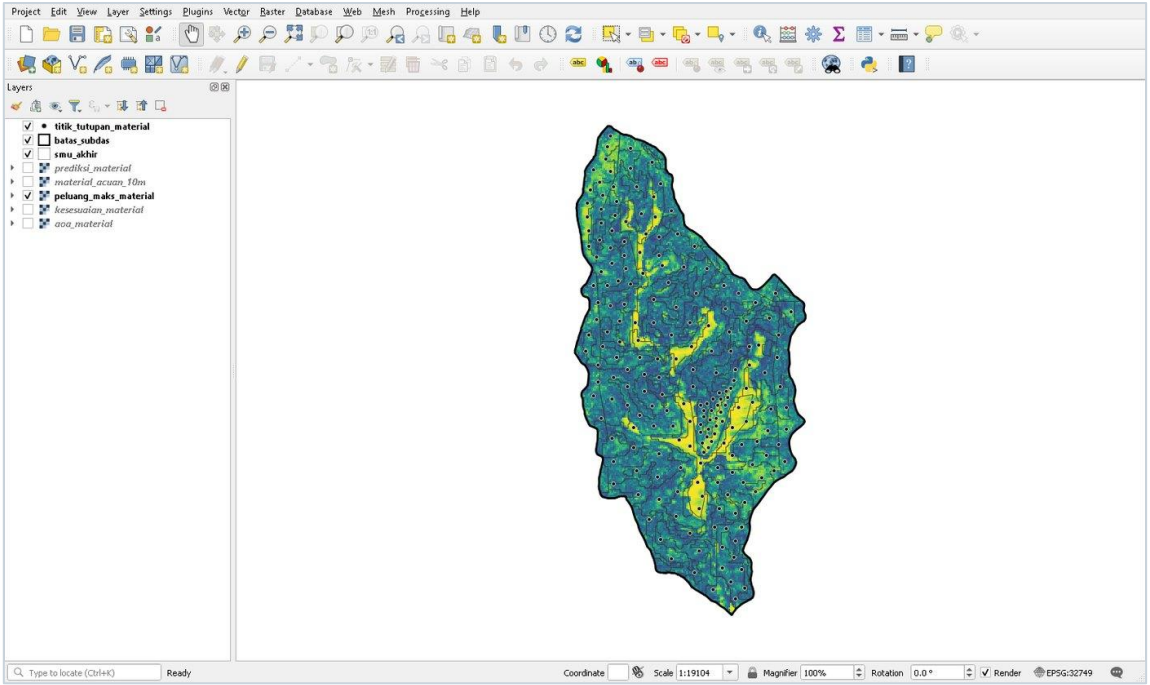
© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

`peluang_maks_material` sebagai **Singleband pseudocolor** dengan **Min** 0 dan **Max** 1, dan `smu_akhir` hanya sebagai garis batas dengan **Simple Fill**, **Fill style** *No Brush*.



Gambar P5.21 Prediksi tutupan material dengan batas SMU dan titik sampel

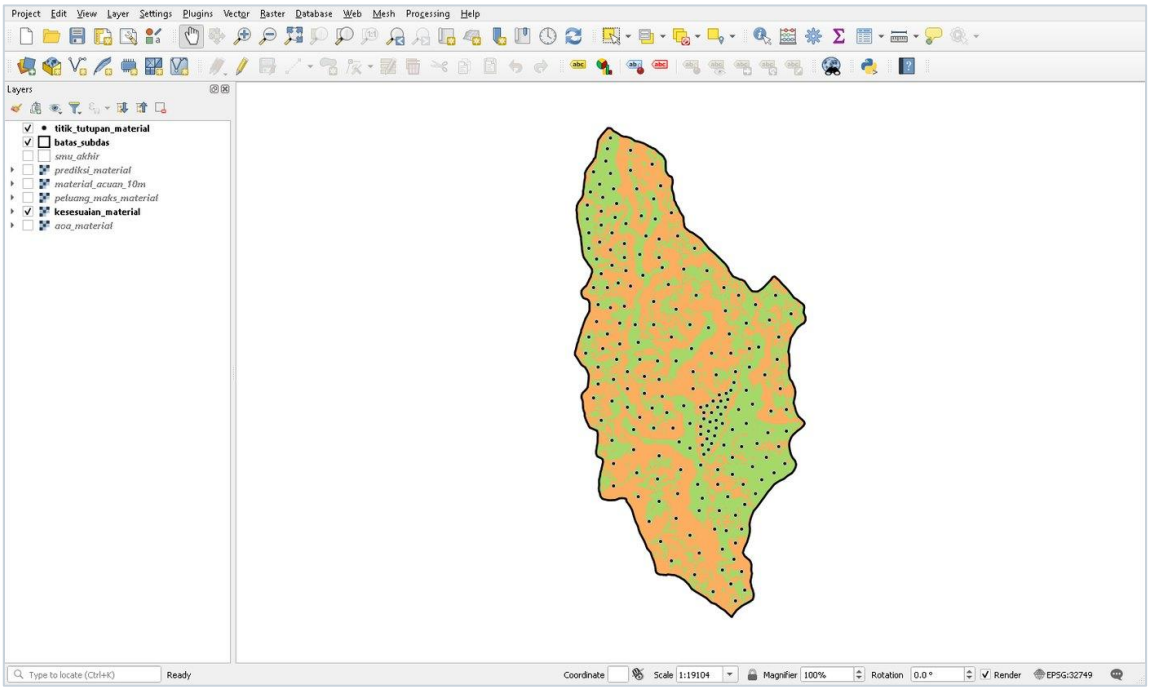
Sumber: Tangkapan layar uji coba; prediksi model latihan, bukan peta bahan induk yang tervalidasi



Gambar P5.22 Peluang kelas tertinggi dengan batas SMU dan titik sampel

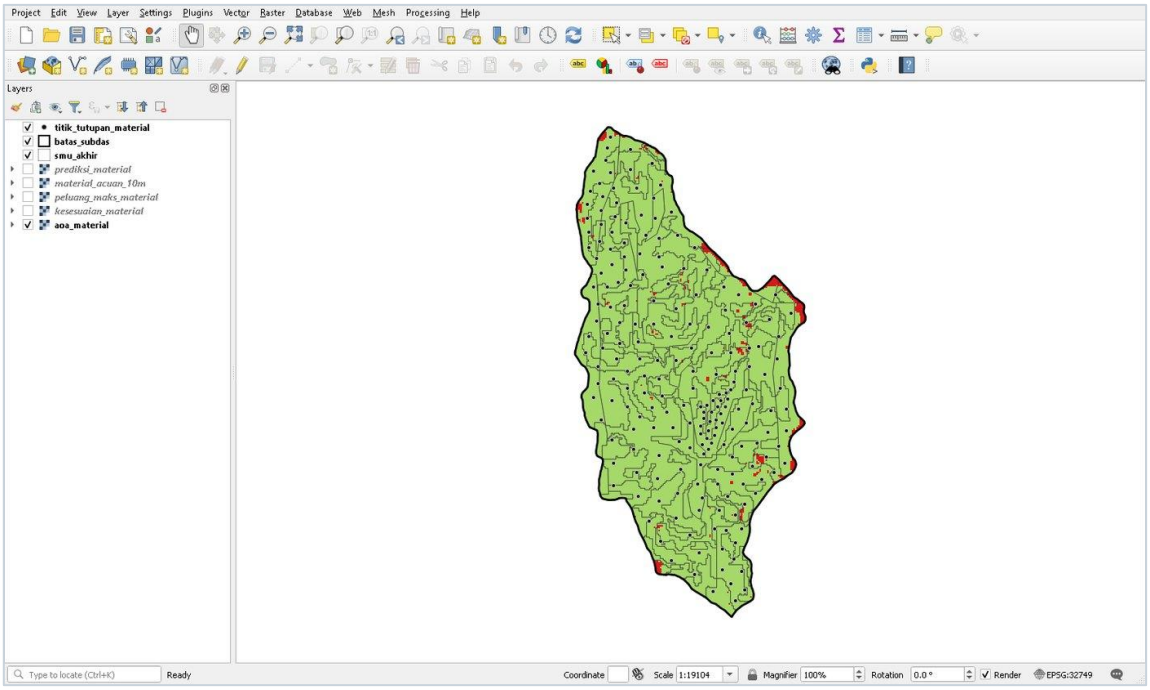
Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada



Gambar P5.23 Kesesuaian prediksi dengan peta acuan, dengan hijau untuk piksel yang sama dan jingga untuk piksel yang berbeda

Sumber: Tangkapan layar uji coba

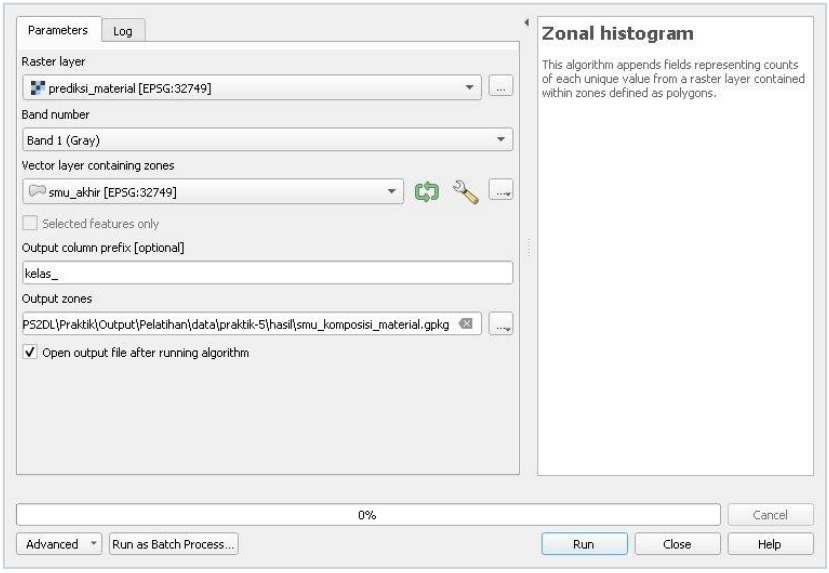


Gambar P5.24 Wilayah keberlakuan model, dengan merah menandai piksel di luar AOA

Sumber: Tangkapan layar uji coba

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

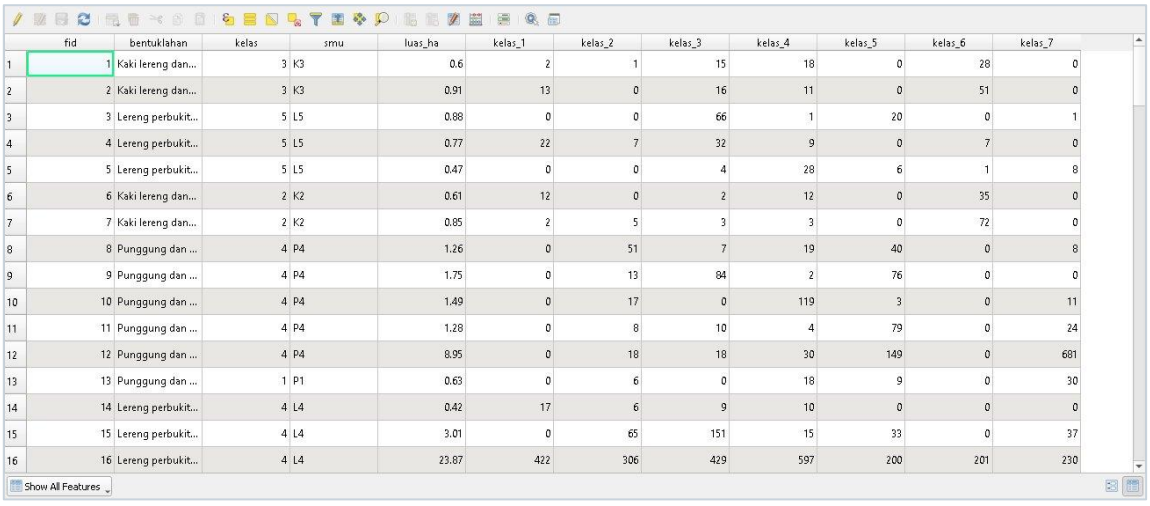
3. Cari **Zonal histogram** di Processing Toolbox. Isi **Raster layer** `prediksi_material`, **Vector layer containing zones** `smu_akhir`, **Output column prefix** `kelas_`, lalu simpan ke `hasil/smu_komposisi_material.gpkg`.



Gambar P5.25 Dialog Zonal Histogram

Sumber: Tangkapan layar uji coba

4. Buka tabel atribut hasilnya. Kolom `kelas_1` sampai `kelas_7` berisi jumlah piksel setiap kelas di dalam setiap poligon SMU. Satu piksel sama dengan 100 m², atau 0,01 ha.



	fid	bentuklahan	kelas	smu	luas_ha	kelas_1	kelas_2	kelas_3	kelas_4	kelas_5	kelas_6	kelas_7
1	1	Kaki lereng dan...	3	K3	0.6	2	1	15	18	0	28	0
2	2	Kaki lereng dan...	3	K3	0.91	13	0	16	11	0	51	0
3	3	Lereng perbukit...	5	L5	0.88	0	0	66	1	20	0	1
4	4	Lereng perbukit...	5	L5	0.77	22	7	32	9	0	7	0
5	5	Lereng perbukit...	5	L5	0.47	0	0	4	28	6	1	8
6	6	Kaki lereng dan...	2	K2	0.61	12	0	2	12	0	35	0
7	7	Kaki lereng dan...	2	K2	0.85	2	5	3	3	0	72	0
8	8	Punggung dan ...	4	P4	1.26	0	51	7	19	40	0	8
9	9	Punggung dan ...	4	P4	1.75	0	13	84	2	76	0	0
10	10	Punggung dan ...	4	P4	1.49	0	17	0	119	3	0	11
11	11	Punggung dan ...	4	P4	1.28	0	8	10	4	79	0	24
12	12	Punggung dan ...	4	P4	8.95	0	18	18	30	149	0	681
13	13	Punggung dan ...	1	P1	0.63	0	6	0	18	9	0	30
14	14	Lereng perbukit...	4	L4	0.42	17	6	9	10	0	0	0
15	15	Lereng perbukit...	4	L4	3.01	0	65	151	15	33	0	37
16	16	Lereng perbukit...	4	L4	23.87	422	306	429	597	200	201	230

Show All Features

Gambar P5.26 Jumlah piksel setiap kelas material per poligon SMU pada tabel atribut

Sumber: Tangkapan layar uji coba

Tabel P5.14 Komposisi Tutupan Material Prediksi menurut Bentuklahan pada Peta SMU Contoh (%)

Bentuklahan pada peta SMU	Luas (ha)	1	2	3	4	5	6	7
Punggung dan interfluve	41,5	0,0	12,1	12,7	10,9	26,0	0,0	38,4
Lereng perbukitan	230,7	12,4	14,8	20,8	15,7	14,5	10,6	11,2
Kaki lereng dan dataran koluvial	22,5	6,9	0,5	8,1	4,9	0,2	79,0	0,5

Sumber: Hasil uji coba, jumlah piksel prediksi CatBoost per bentuklahan; peta SMU contoh dari Praktik 2

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Satuan kaki lereng dan dataran koluvial didominasi kelas 6, yaitu endapan, sesuai dengan proses pembentukannya. Pada lereng perbukitan, tidak ada kelas yang menempati lebih dari seperempat luas, sehingga satuan itu tidak dapat diberi satu label bahan induk hanya dari peta prediksi ini. Agregasi per satuan seperti ini juga merupakan cara sederhana untuk meredam bintik pada peta kelas.

Tahap 9: Bahan Presentasi

Pada akhir pelatihan, setiap peserta atau kelompok menyajikan alur kerja dan hasilnya. Ekspor peta melalui **Project > Import/Export > Export Map to Image**. Susun penyajian untuk menjawab pertanyaan berikut:

1. Data apa yang dipakai, dan apa keterbatasan setiap sumbernya?
2. Bagaimana peta SMU disusun, dan di mana batasnya berbeda dari peta riset?
3. Kovariat mana yang dipilih, dan bagaimana kepentingan serta korelasi Pearson dipakai untuk memilihnya?
4. Seberapa baik CatBoost dibandingkan pembanding sederhananya, dan pada skema validasi yang mana?
5. Kelas mana yang paling sering tertukar, dan di mana peta ini paling tidak dapat dipercaya?
6. Jika sampel di kebun tidak seimbang, cara penanganan mana yang dipilih, dan apa akibatnya pada luas setiap kelas?
7. Jika ada anggaran untuk satu perbaikan, apa yang akan dipilih: titik pengamatan lapangan, DEM yang lebih rinci, peta geologi yang lebih rinci, atau data sensor proksimal? Mengapa?

Bahan Diskusi

Mudah sekali membuat peta kelas yang tampak meyakinkan. Peta prediksi pada praktik ini berwarna rapi dan menampilkan alur endapan yang masuk akal, tetapi hanya 46% pikselnya sama dengan peta acuan, dan sebagian besar pikselnya memiliki peluang di bawah 0,7. Kemampuan membaca matriks kebingungan, peta peluang, dan hasil validasi spasial sama pentingnya dengan kemampuan menjalankan modelnya, terutama saat menerima peta kelas dari pihak lain.

Pilihan algoritme juga perlu ditempatkan secara wajar. CatBoost tidak lebih teliti daripada *random forest* pada data ini. Keunggulannya di sini bersifat praktis, yaitu kategori dapat dimasukkan langsung tanpa penyiapan tambahan, sedangkan keunggulan pengodean kategorinya baru akan terasa pada kategori yang sangat beragam. Hal ini sejalan dengan Modul 8, bahwa mutu data dan kovariat lebih menentukan daripada pilihan algoritme.

Hasil validasi zona patut mendapat perhatian khusus. Pada validasi acak dan blok spasial, model jauh lebih baik daripada pembanding sederhana, tetapi pada zona yang belum dilihatnya akurasinya hampir sama dengan menebak. Salah satu kemungkinan penjelasannya, ketinggian sebagai kovariat terpenting lebih banyak bekerja sebagai penanda letak di dalam Sub-DAS daripada sebagai penjelas sifat batuan yang berlaku di mana saja. Meyer et al. (2019) menunjukkan bahwa kovariat seperti ini dapat membuat model tampak baik dalam mereproduksi data, tetapi buruk dalam prediksi spasial. Bagi perkebunan, artinya model yang dilatih di satu kebun belum tentu berlaku di kebun lain, dan klaim seperti itu harus dibuktikan dengan validasi pada wilayah yang terpisah.

Sebelum memakai peta kelas hasil DSM, tanyakan selalu hal-hal berikut. Dari mana label kelasnya, dari pengamatan lapangan atau dari peta lain? Apakah ketelitiannya dinilai dengan data yang terpisah secara

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

spasial? Bagaimana akurasi pembuat dan akurasi pengguna setiap kelas, bukan hanya akurasi keseluruhannya? Berapa jumlah sampel setiap kelas, dan apa akibatnya pada luas kelas di peta? Mana peta peluangnya?

Jika Tertinggal

Notebook sudah memuat keluaran uji coba. Semua keluaran tersedia di `data/praktik-5/hasil-contoh/`, termasuk proyek `Praktik_5_selesai.qgz`. Salin isinya ke `hasil/` jika perlu melanjutkan dari tahap tertentu.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Penutup

Kelima praktik pada modul ini membentuk satu alur. Data dari berbagai sensor diselaraskan, lanskap ditafsirkan menjadi satuan peta tanah, spektrum dan citra dibaca beserta keterbatasannya, lalu semuanya dipakai untuk membangun peta sifat tanah yang dinilai secara terbuka.

Kemampuan yang paling berguna untuk dibawa ke kebun mungkin bukan menjalankan alatnya, melainkan mengajukan pertanyaan yang tepat. Data apa yang sebenarnya dibaca sensor? Bagaimana data dibagi saat model dinilai? Berapa nilainya dibanding menebak rata-rata? Di mana peta ini tidak dapat dipercaya? Pertanyaan yang sama berlaku ketika menerima peta dari pihak lain.

Terima kasih.

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Daftar Pustaka

Badan Informasi Geospasial. (2026). *Info Data Demnas* [Halaman portal]. Ina-Geoportal. https://tanahair.indonesia.go.id/portal-web/unduh/demnas

Barnes, R. J., Dhanoa, M. S., & Lister, S. J. (1989). Standard normal variate transformation and de-trending of near-infrared diffuse reflectance spectra. *Applied Spectroscopy*, *43*(5), 772–777. https://doi.org/10.1366/0003702894202201

Branco, P., Torgo, L., & Ribeiro, R. P. (2017). SMOGN: A pre-processing approach for imbalanced regression. *Proceedings of Machine Learning Research*, *74*, 36–50. https://proceedings.mlr.press/v74/branco17a.html

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Castaldi, F., Hueni, A., Chabrillat, S., Ward, K., Buttafuoco, G., Bomans, B., Vreys, K., Brell, M., & van Wesemael, B. (2019). Evaluating the capability of the Sentinel 2 data for soil organic carbon prediction in croplands. *ISPRS Journal of Photogrammetry and Remote Sensing*, *147*, 267–282. https://doi.org/10.1016/j.isprsjprs.2018.11.026

Castaldi, F., Palombo, A., Santini, F., Pascucci, S., Pignatti, S., & Casa, R. (2016). Evaluation of the potential of the current and forthcoming multispectral and hyperspectral imagers to estimate soil texture and organic carbon. *Remote Sensing of Environment*, *179*, 54–65. https://doi.org/10.1016/j.rse.2016.03.025

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Congalton, R. G. (1991). A review of assessing the accuracy of classifications of remotely sensed data. *Remote Sensing of Environment*, *37*(1), 35–46. https://doi.org/10.1016/0034-4257(91)90048-B

Demattê, J. A. M., Safanelli, J. L., Poppiel, R. R., Rizzo, R., Silvero, N. E. Q., Mendes, W. de S., Bonfatti, B. R., Dotto, A. C., Salazar, D. F. U., Mello, F. A. de O., Paiva, A. F. da S., Souza, A. B., Santos, N. V. dos, Maria Nascimento, C., Mello, D. C. de, Bellinaso, H., Gonzaga Neto, L., Amorim, M. T. A., Resende, M. E. B. de, . . . Lisboa, C. J. da S. (2020). Bare Earth's surface spectra as a proxy for soil resource monitoring. *Scientific Reports*, *10*(1), 4461. https://doi.org/10.1038/s41598-020-61408-1

Diek, S., Fornallaz, F., Schaepman, M. E., & de Jong, R. (2017). Barest pixel composite for agricultural areas using Landsat time series. *Remote Sensing*, *9*(12), 1245. https://doi.org/10.3390/rs9121245

Egozcue, J. J., Pawlowsky-Glahn, V., Mateu-Figueras, G., & Barceló-Vidal, C. (2003). Isometric logratio transformations for compositional data analysis. *Mathematical Geology*, *35*(3), 279–300. https://doi.org/10.1023/A:1023818214614

England, J. R., & Viscarra Rossel, R. A. (2018). Proximal sensing for soil carbon accounting. *SOIL*, *4*(2), 101–122. https://doi.org/10.5194/soil-4-101-2018

Fatmawati, N. D. (2026). *Evaluasi pendekatan SCORPAN dalam prediksi spasial fraksi tekstur tanah pada bahan induk hasil proses alterasi di Sub-DAS Bompon* [Tesis magister, Universitas Gadjah Mada].

Geladi, P., MacDougall, D., & Martens, H. (1985). Linearization and scatter-correction for near-infrared reflectance spectra of meat. *Applied Spectroscopy*, *39*(3), 491–500. https://doi.org/10.1366/0003702854248656

Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, *18*(17), 1–5. https://jmlr.org/papers/v18/16-365.html

Malik, R. F. (2017). *Pemetaan geomorfologi detail menggunakan teknik step-wise-grid di Daerah Aliran Sungai (DAS) Bompon, Kabupaten Magelang, Jawa Tengah* [Karya akhir, Universitas Gadjah Mada].

<!-- Catatan editor: entri Malik (2017) disalin dari daftar pustaka Fatmawati (2026). Jenis karya akhirnya (skripsi atau tesis) belum diverifikasi, dan naskahnya tidak tersedia di repository. -->

Meyer, H., & Pebesma, E. (2021). Predicting into unknown space? Estimating the area of applicability of spatial prediction models. *Methods in Ecology and Evolution*, *12*(9), 1620–1633. https://doi.org/10.1111/2041-210X.13650

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada

Meyer, H., Reudenbach, C., Wöllauer, S., & Nauss, T. (2019). Importance of spatial predictor variable selection in machine learning applications – Moving from data reproduction to spatial prediction. *Ecological Modelling*, *411*, 108815. https://doi.org/10.1016/j.ecolmodel.2019.108815

Molin, J. P., & Tavares, T. R. (2019). Sensor systems for mapping soil fertility attributes: Challenges, advances, and perspectives in Brazilian tropical soils. *Engenharia Agrícola*, *39*(spe), 126–147. https://doi.org/10.1590/1809-4430-Eng.Agric.v39nep126-147/2019

Pohl, C., & van Genderen, J. L. (1998). Multisensor image fusion in remote sensing: Concepts, methods and applications. *International Journal of Remote Sensing*, *19*(5), 823–854. https://doi.org/10.1080/014311698215748

Pontius, R. G., Jr., & Millones, M. (2011). Death to Kappa: Birth of quantity disagreement and allocation disagreement for accuracy assessment. *International Journal of Remote Sensing*, *32*(15), 4407–4429. https://doi.org/10.1080/01431161.2011.552923

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, *31*, 6638–6648. https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, *40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Sambodo, A. P., & Arpornthip, T. (2021). Increasing the efficiency of detailed soil resource mapping on transitional volcanic landforms using a geomorphometric approach. *Applied and Environmental Soil Science*, *2021*, 8867647. https://doi.org/10.1155/2021/8867647

Savitzky, A., & Golay, M. J. E. (1964). Smoothing and differentiation of data by simplified least squares procedures. *Analytical Chemistry*, *36*(8), 1627–1639. https://doi.org/10.1021/ac60214a047

SciAps. (2025). *ASD FieldSpec 4: The industry-leading portable device for field spectroscopy* [Brosur].

Vivone, G., Alparone, L., Chanussot, J., Dalla Mura, M., Garzelli, A., Licciardi, G. A., Restaino, R., & Wald, L. (2015). A critical comparison among pansharpening algorithms. *IEEE Transactions on Geoscience and Remote Sensing*, *53*(5), 2565–2586. https://doi.org/10.1109/TGRS.2014.2361734

Wadoux, A. M. J.-C., Samuel-Rosa, A., Poggio, L., & Mulder, V. L. (2020). A note on knowledge discovery and machine learning in digital soil mapping. *European Journal of Soil Science*, *71*(2), 133–136. https://doi.org/10.1111/ejss.12909

Wald, L., Ranchin, T., & Mangolini, M. (1997). Fusion of satellite images of different spatial resolutions: Assessing the quality of resulting images. *Photogrammetric Engineering and Remote Sensing*, *63*(6), 691–699.

Wold, S., Sjöström, M., & Eriksson, L. (2001). PLS-regression: A basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, *58*(2), 109–130. https://doi.org/10.1016/S0169-7439(01)00155-1

© 2026 Pusat Studi Pengelolaan Sumber Daya Lahan, Universitas Gadjah Mada