Tesis

EVALUASI PENDEKATAN SCORPAN DALAM PREDIKSI SPASIAL FRAKSI TEKSTUR TANAH PADA BAHAN INDUK HASIL PROSES ALTERASI DI SUB-DAS BOMPON

diajukan oleh

Nurarfiyah Desi Fatmawati

23/527460/PPN/05167

FAKULTAS PERTANIAN

UNIVERSITAS GADJAH MADA

YOGYAKARTA

2026

Tesis

EVALUASI PENDEKATAN SCORPAN DALAM PREDIKSI SPASIAL FRAKSI TEKSTUR TANAH PADA BAHAN INDUK HASIL PROSES ALTERASI DI SUB-DAS BOMPON

Disusun oleh

Nurarfiyah Desi Fatmawati

23/527460/PPN/05167

Telah dipertahankan di depan Dewan Penguji

Pada tanggal 27 Juli 2026

	Tanda tangan	Tanggal
Pembimbing Utama:		
Prof. Dr. rer. Nat. Junun Sartohadi, M.Sc	.....	08-09-2026
Pembimbing Pendamping:		
Dr. Agr. Makruf Nurudin, S.P.,M.P	.....	08-09-'26
Penguji:		
Nur 'Ainun H. J. Pulungan, S.Si., M.Sc., PhD	.....	08-09-2026

Mengetahui

Ketua Departemen Tanah

Fakultas Pertanian

Universitas Gadjah Mada

Tanggal 08 September 2026

Dr. Agr. Makruf Nurudin, S.P.,M.P

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan dibawah ini:

Nama	: Nurarfiyah Desi Fatmawati
No. Mahasiswa	: 23/527460/PPN/05167
Tahun Terdaftar	: 2023
Program Studi	: Ilmu Tanah
Fakultas	: Pertanian

Menyatakan bahwa dokumen ilmiah Tesis ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu Lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/Lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam daftar pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah Tesis ini dikemudian hari terbukti merupakan plagiasi dan hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, 08 Juli 2026

Nurarfiyah Desi Fatmawati

23/527460/PPN/05167

PERNYATAAN

Dengan ini saya menyatakan bahwa Tesis ini bukan merupakan karya yang pernah diajukan untuk memperoleh gelar kesarjanaan di suatu perguruan tinggi, dan sepanjang pengetahuan saya juga tidak mengandung karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar Pustaka.

Yogyakarta, 08 Juli 2026

Nurarfiyah Desi Fatmawati
23/527460/PPN/05167

KATA PENGANTAR

Puji Syukur penulis panjatkan kehadirat Allah SWT, sehingga penulis dapat menyelesaikan penelitian yang berjudul "Evaluasi Pendekatan SCORPAN dalam Prediksi Spasial Fraksi Tekstur Tanah Pada Bahan Induk Hasil Proses Alterasi di Sub-DAS Bompon" untuk memenuhi sebagian persyaratan mencapai derajat master pada Program Studi Ilmu Tanah, Fakultas Pertanian, Universitas Gadjah Mada. Penyelesaian penelitian ini tidak terlepas dari bimbingan, bantuan, doa, motivasi, serta dukungan berbagai pihak. Oleh karena itu, penulis mengucapkan terima kasih kepada:

1. Prof. Dr.rer.nat. Junun Sartohadi, M.Sc. selaku dosen pembimbing utama yang telah memberikan ilmu, arahan, saran, dan masukan dalam penulisan tesis. Penulis juga berterima kasih atas kesabaran dan nasehatnya selama ini sehingga penulis dapat menyelesaikan penulisan tesis.
2. Dr. Makruf Nurudin, S.P., M.P. selaku dosen pembimbing pendamping yang telah memberikan ilmu, arahan, saran, dan masukan dalam penulisan tesis.
3. Nur Ainun Harlin J. Pulungan, S.Si., M.Sc., Ph.D. selaku dosen penguji yang telah bersedia menguji, memberikan masukan dan saran kepada penulis.
4. Kedua orang tua saya, kakak, dan adik yang telah memberikan dukungan dalam berbagai aspek untuk kelancaran perkuliahan dan penyusunan skripsi..
5. Johan Herdi Putra yang telah meluangkan waktu, menjadi teman diskusi, memberikan dukungan, dan memotivasi penulis dalam penyusunan tesis.
6. Teman-teman S2 Ilmu Tanah (Melia Ningrum P. N., Yulita Windi N., Intan Ayu P. P., Bagus Krisna S., Johnex Meison D. P., Permata Harty N. F., Azalia Caroline, Septaria Yunika) yang telah membersamai, membantu, berdiskusi, dan memotivasi penulis selama perkuliahan hingga penyelesaian tesis.
7. Serta kepada keluarga, teman, dan pihak lain yang tidak dapat penulis sebutkan satu-persatu.

Penulis berharap penelitian ini dapat terus dikembangkan dan memberikan kontribusi bagi bidang ilmu tanah, kebencanaan, dan pertanian, serta menjadi sumber informasi dan pengetahuan yang bermanfaat bagi para pembaca.

Yogyakarta, 08 Juli 2026

Penulis

DAFTAR ISI

HALAMAN JUDUL i
HALAMAN PENGESAHAN ii
PERNYATAAN BEBAS PLAGIASI iii
PERNYATAAN iv
KATA PENGANTAR v
DAFTAR ISI vi
DAFTAR TABEL viii
DAFTAR GAMBAR ix
DAFTAR LAMPIRAN xi
INTISARI xii
ABSTRACT xiii
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Permasalahan 2
1.3. Tujuan 3
1.4. Manfaat 3
1.5. Keaslian 4
BAB II TINJAUAN PUSTAKA 7
2.1. Tinjauan Pustaka 7
2.1.1. Sub-DAS Bompon 7
2.1.1.1. Karakteristik Geomorfologi dan Geologi 7
2.1.1.2. Karakteristik Meteorologi 10
2.1.1.3. Karakteristik Sosial Masyarakat 10
2.1.2. Tekstur Tanah 11
2.1.3. *Digital Soil Mapping* (DSM) 14
2.1.3.1. Konsep SCORPAN 14
2.1.3.2. Variabel Lingkungan 16
2.1.3.3. Light Detection and Ranging (LiDAR) 17
2.1.3.4. Sentinel-2A Deep Resolution 3.0 18
2.1.4. Machine Learning 19
2.1.4.1. Random Forest (RF) 19
2.1.4.2. Quantile Regression Forest (QRF) 19

2.1.4.3. CatBoost 20
2.1.4.4. Stacking 20
2.1.4.5. Resampling Data 21
2.2. Kerangka Teori 22
BAB III METODE PENELITIAN 23
3.1. Alat dan Bahan 23
3.1.1. Alat Penelitian 23
3.1.2. Bahan Penelitian 23
3.1.3. Waktu dan Tempat 23
3.2. Prosedur Penelitian 24
3.2.1. Pengamatan dan Survei Lapangan 24
3.2.2. Pengambilan Sampel 24
3.3. Pengumpulan Data 26
3.4. Analisis Data 26
3.4.1. Pengolahan Data 26
3.4.2. Uji Akurasi dan Validasi 29
3.5. Diagram Alir Penelitian 30
BAB IV HASIL DAN PEMBAHASAN 31
4.1. Statistik Deskriptif Fraksi Tekstur Tanah Berdasarkan Data Observasi 31
4.2. Sifat Fisik dan Kimia Tanah di Sub-DAS Bompon 33
4.3. Statistik Deskriptif Prediksi Fraksi Tekstur Tanah 34
4.4. Kinerja Model Prediksi Fraksi Tekstur Tanah 36
4.5. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Tekstur Tanah 38
4.6. Analisis Distribusi Spasial Prediski Fraksi Tekstur Tanah 41
4.7. Manajemen Pengelolaan Lahan Berdasarkan Distribusi Fraksi Tekstur Tanah 50
BAB V KESIMPULAN & SARAN 56
5.1. Kesimpulan 56
5.2. Saran 56
DAFTAR PUSTAKA 57
LAMPIRAN 67

DAFTAR TABEL

Tabel 1.1. Penelitian sebelumnya terkait *Digital Soil Mapping* (DSM). 4
Tabel 2. 1. Klasifikasi ukuran partikel fraksi tanah.....12
Tabel 3.1. Parameter Uji Laboratorium 26
Tabel 3.2. Kovariat lingkungan yang digunakan.....27
Tabel 3.3. Data spasial kovariat lingkungan yang digunakan.....28
Tabel 4.1. Statistik Fraksi Tanah Berdasarkan Data Observasi 31
Tabel 4. 2. Statistik Data Sifat Fisik dan Kimia Tanah.....33
Tabel 4. 3. Statistik Prediksi Fraksi Tanah 34
Tabel 4.4. Kinerja Model RF, QRF, Catboost, dan Stacking dengan Dataset Asli ...36
Tabel 4.5. Kinerja Model RF, QRF, Catboost, dan Stacking dengan Resampling SMOGN.....37
Tabel 4.6. Rekomendasi Zona Pengelolaan, Kelompok Tanaman, dan Jenis Tanaman 54

DAFTAR GAMBAR

Gambar 2.1. Zona transisi tersier-kuarter Sub-DAS Bompon 8
Gambar 2.2. Peta Tutupan Material Sub-DAS Bompon 9
Gambar 2.3. Kondisi longsor di Sub-DAS Bompon 9
Gambar 2.4. Peta Bentuklahan Sub-DAS Bompon 10
Gambar 2.5. Peta Penggunaan Lahan Sub-DAS Bompon 11
Gambar 2.6. Segitiga klasifikasi tekstur tanah USDA 13
Gambar 2.7. Aplikasi Konsep SCORPAN 16
Gambar 2. 8. Perbandingan Sentinel-2A Resoluis Spasial 10 m dan 1 m 18
Gambar 2.9. Ilustrasi Metode SMOGN 21
Gambar 2.10. Kerangka Teori 22
Gambar 3.1. Lokasi Penelitian 24
Gambar 3.2. Peta Sebaran Titik Sampel 25
Gambar 3.3. Diagram alir penelitian 30
Gambar 4.1. Distribusi Data Observasi Fraksi Tekstur Tanah Lapisan 1 (Kiri) dan Lapisan 2 (Kanan) pada Segitiga Tekstur USDA 32
Gambar 4.2. Histogram densitas distribusi fraksi pasir, debu, dan lempung pada Lapisan 1 dan Lapisan 2 35
Gambar 4.3. Distribusi Data Prediksi Fraksi Tekstur Tanah Lapisan 1 (Kiri) dan Lapisan 2 (Kanan) pada Segitiga Tekstur USDA 36
Gambar 4.4. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Pasir Lapisan 1 dan 2 39
Gambar 4.5. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Debu Lapisan 1 dan 2 40
Gambar 4. 6. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Lempung Lapisan 1 dan 2 40
Gambar 4.7. Peta Distribusi Spasial Prediksi Fraksi Pasir Lapisan 1 42
Gambar 4.8. Peta Distribusi Spasial Prediksi Fraksi Pasir Lapisan 2 43
Gambar 4.9. Peta Distribusi Spasial Prediksi Fraksi Debu Lapisan 1 44
Gambar 4.10. Peta Distribusi Spasial Prediksi Fraksi Debu Lapisan 2 45
Gambar 4.11. Peta Distribusi Spasial Prediksi Fraksi Lempung Lapisan 1 46
Gambar 4.12. Peta Distribusi Spasial Prediksi Fraksi Lempung Lapisan 2 47
Gambar 4.13. Peta distribusi spasial prediksi kandungan fraksi pasir, debu, dan lempung pada Lapisan 1 dan Lapisan 2 di Bagian Hulu Sub-DAS Bompon 48

Gambar 4.14. Peta distribusi spasial prediksi kandungan fraksi pasir, debu, dan lempung pada Lapisan 1 dan Lapisan 2 di Bagian Hilir Sub-DAS Bompon.....49
Gambar 4.15. Pengaruh Tekstur Tanah Terhadap Ketersediaan Air Bagi Tanaman 51
Gambar 4.16. Lokasi Erosi dan Longsor di Sub-DAS Bompon dengan Kandungan Lempung Tinggi.....52
Gambar 4.17. Peta Zona Manajemen Pengelolaan Lahan di Sub-DAS Bompon 53

DAFTAR LAMPIRAN

Lampiran 1. Perbandingan Peta Prediksi Fraksi Pasir, Debu, dan Lempung dengan Metode RF, QRF, CatBoost, dan Stackin Tanpa Resampling 67
Lampiran 2. Perbandingan Peta Prediksi Fraksi Pasir, Debu, dan Lempung dengan Metode RF, QRF, CatBoost, dan Stackin dengan Resampling SMOGN.....69
Lampiran 3. Statistik Deskriptif Fraksi Tanah Berdasarkan Material Tutupan.....71
Lampiran 4. Statistik Deskriptif Fraksi Tanah Berdasarkan Bentuklahan 72
Lampiran 5. Statistik Deskriptif Fraksi Tanah Berdasarkan Penggunaan Lahan 73

INTISARI

Tekstur tanah merupakan salah satu sifat dasar tanah yang memengaruhi berbagai sifat fisika dan kimia tanah. Tekstur tanah bersifat tidak mudah berubah sehingga cocok untuk dipetakan dan peta tanah dapat digunakan dalam jangka panjang. Penelitian ini bertujuan untuk (1) menganalisis karakteristik dan distribusi spasial fraksi tanah, (2) mengevaluasi kinerja pendekatan *Digital Soil Mapping* (DSM) berbasis SCORPAN dalam memprediksi fraksi tanah, dan (3) menyusun manajemen pengelolaan lahan berdasarkan distribusi fraksi tanah. Penelitian menggunakan 50 titik sampel pada kedalaman 0–20 cm dan 20–40 cm. Prediksi spasial fraksi pasir, debu, dan lempung dilakukan menggunakan kovariat lingkungan berbasis SCORPAN yang diturunkan dari data LiDAR, citra Sentinel-2, serta data lingkungan lainnya. Pemodelan dilakukan menggunakan algoritma *Random Forest*, *Quantile Regression Forest*, *CatBoost*, dan *stacking*, dengan menerapkan *Recursive Feature Elimination* (RFE) untuk menentukan skenario prediksi terbaik. Hasil penelitian menunjukkan bahwa fraksi lempung mendominasi pada kedua lapisan. Model DSM terbaik adalah stacking dengan SMOGN, namun model tersebut menunjukkan kemampuan prediksi yang relatif rendah dengan nilai R^2 tertinggi sebesar 0,249 dan cenderung lebih baik pada lapisan permukaan. Kondisi ini berkaitan dengan dominasi lempung dan rendahnya variasi tekstur pada bahan induk teralterasi, sehingga hubungan fraksi tekstur tanah dengan kovariat lingkungan sulit diidentifikasi secara optimal oleh model. Integrasi distribusi fraksi tanah, khususnya kandungan lempung, dengan zona proses geomorfologi menghasilkan enam zona pengelolaan, yaitu residual lempung sedang dan tinggi, erosional lempung sedang dan tinggi, serta deposisional lempung sedang dan tinggi. Pengelolaan lahan diarahkan pada konservasi tanah vegetatif melalui pemilihan kelompok tanaman.

Kata kunci: *Digital Soil Mapping*, SCORPAN, fraksi tanah, *machine learning*

ABSTRACT

Soil texture is one of the soil attributes that influences various physical and chemical properties of the soil. Soil texture does not change easily so it is suitable for mapping and soil maps can be used in the long term. This research aims to (1) analyze the characteristics and spatial distribution of soil fractions, (2) evaluate the performance of the SCORPAN-based *Digital Soil Mapping* (DSM) approach in predicting soil fractions, and (3) develop land management based on the distribution of soil fractions. The research used 50 sample points at depths of 0–20 cm and 20–40 cm. Spatial predictions of sand, dust and clay fractions were carried out using SCORPAN-based environmental covariates derived from LiDAR data, Sentinel-2 imagery and other environmental data. Modeling was carried out using Random Forest, Quantile Regression Forest, CatBoost, and stacking algorithms, by applying Recursive Feature Elimination (RFE) to determine the best prediction scenario. The results showed that the clay fraction dominates in both layers. At a depth of 0–20 cm, the sand content ranges from 7.05–33.67%, dust 12.23–40.39%, and clay 39.40–80.92%, while at a depth of 20–40 cm it ranges from 7.15–30.03%, 10.09–36.52%, and 44.82–81.74% respectively. The best DSM model is stacking with SMOGN, but this model shows relatively low prediction ability and tends to be better in the surface layer. The best R^2 values at a depth of 0–20 cm were 0.249 for sand, 0.195 for dust, and 0.099 for clay, while at a depth of 20–40 cm they were 0.123, 0.137, and 0.093, respectively. Integration of the distribution of soil fractions, especially clay content, with geomorphological process zones produces six management zones, namely medium and high clay residual, medium and high clay erosional, and medium and high clay depositional. Land management is directed at vegetative soil conservation through selecting plant groups.

Keywords: *Digital Soil Mapping*, SCORPAN, soil fraction, machine learning

BAB I PENDAHULUAN

1.1. Latar Belakang

Pemahaman terkait pola sifat tanah sangat penting dalam pertanian untuk meningkatkan produktivitas dan pengelolaan lahan berkelanjutan (Hosseinpour-Zarnaq et al., 2025). Pola tanah pada lanskap dipengaruhi oleh faktor pembentuk tanah yang meliputi iklim, organisme, bahan induk, topografi, dan waktu. Faktor-faktor tersebut mengakibatkan pola tanah yang kompleks dan berulang pada lanskap serta menjadi dasar dalam identifikasi, klasifikasi, dan pemetaan tanah. Klasifikasi tanah secara tradisional bersifat kualitatif dan distribusi tanah tidak memiliki batasan yang jelas (da Silva et al., 2014).

Pola sifat tanah dapat lebih dipahami secara spasial dengan adanya peta tanah. Namun, pemetaan tanah dengan pendekatan survei konvensional membutuhkan waktu yang lebih lama, biaya yang lebih mahal, dan membatasi pemantauan tanah dalam skala besar (Lu *et al*., 2023). *Digital Soil Mapping (DSM)* atau pemetaan tanah digital menjadi solusi untuk mengatasi keterbatasan waktu biaya, dan analisis laboratorium. McBratney *et al*. (2003) mengembangkan pendekatan pemetaan tanah konvensional ke digital menggunakan konsep SCORPAN. Sejak akhir tahun 1960-an, pemetaan tanah berkembang dengan pendekatan geografis atau spasial, yaitu memprediksi atribut tanah berdasarkan posisi spasial melalui interpolasi antar lokasi pengamatan tanah.Pendekatan ini memperkirakan sifat tanah pada suatu lokasi berdasarkan koordinat geografis serta informasi sifat tanah pada lokasi-lokasi tetangganya.

Pendekatan geografis berkembang melalui beberapa metode geostatistik, diantaranya *trend surfaces*, kriging, dan co-kriging. Selanjutnya, konsep faktor pembentuk tanah Jenny dikembangkan menjadi fungsi prediksi spasial tanah berdasarkan hubungan kuantitatif empiris antara tanah dan faktor-faktor yang mengacu pada ruang yaitu konsep SCORPAN yang mempertimbangkan tujuh faktor, yaitu *soil, climate, organisms, relief, parent material, age,* dan *spatial position* (McBratney *et al.,* 2003). Salah satu atau kombinasi faktor SCORPAN digunakan untuk memprediksi distribusi sifat tanah (S) menggunakan fungsi kuantitatif untuk menggambarkan hubungan tanah dan lingkungan (Heung *et al*., 2021).

Sifat tanah lebih sering diprediksi dibandingkan dengan klasifikasi tanah (McBratney et al., 2003). Sifat-sifat tanah umumnya diprediksi secara individual, meskipun antar sifat tersebut memiliki keterkaitan(Wadoux, 2019). DSM dapat

menghasilkan peta resolusi tinggi yang mengidentifikasi variabilitas sifat tanah, sehingga dapat menjadi kunci dalam membuat keputusan terkait pemilihan tanaman, penjadwalan irigasi, dan pemberian pupuk (Chattaraj et al., 2025a). Tekstur tanah merupakan satu satu contoh sifat yang berperan sebagai faktor kunci dalam penentuan akumulasi atau kehilangan karbon tanah (Hosseinpour-Zarnaq et al., 2025). Tekstur tanah cocok untuk dipetakan karena bersifat tidak mudah berubah sehingga peta tanah dapat digunakan dalam jangka panjang. Tekstur tanah ditentukan oleh bahan induk dan proses pedogenik yang terjadi (Schulz *et al*., 2023). Proses pedogenik dan laju pelapukan yang lambat mengakibatkan tekstur tanah dianggap sebagai sifat tanah yang cukup stabil dan berkembang secara perlahan (Richer-de-Forges *et al*., 2022).

Tanah yang berkembang pada bahan induk hasil proses alterasi memiliki tesktur tanah yang didominasi oleh kandungan lempung tinggi (Sambodo & Arpornthip, 2021). Kondisi tersebut berpotensi menghasilkan variasi tekstur tanah yang relatif rendah pada beberapa lokasi, sehingga diperlukan evaluasi terhadap kemampuan pendekatan SCORPAN dalam memprediksi distribusi fraksi tekstur tanah pada wilayah dengan bahan induk teralterasi.

1.2. Permasalahan

Tantangan yang muncul dalam penerapan DSM adalah keterbatasan ketersediaan data, komplesitas dan multikolinearitas data, serta risiko overfitting dalam pemodelan. Oleh karena itu, diperlukan pemilihan jenis data, model atau algoritma, dan pemilihan kovariat lingkungan untuk prediksi sifat tanah yang akurat. DSM menggabungkan data observasi lapangan, analisis laboratorium, dan variabel lingkungan yang berasal dari data penginderaan jauh untuk membuat informasi sifat tanah secara spasial (Dharumarajan *et al*., 2020). Untuk memprediksi sifat tanah DSM menerapkan berbagai model mulai dari model geostatistik, machine learning, hingga ensemble learning (Mgohele *et al*., 2024). Penggunaan data LiDAR dengan resolusi spasial yang tinggi dan peningkatan resolusi citra Sentinel-2A menggunakan *Sentinel-2 Deep Resolution 3* (S2DR3), model machine learning berupa Random Forest (RF) dan Quantile Regression Forest (QRF), serta pemilihan kovariat lingkungan yang tepat dapat meningkatkan akurasi DSM untuk prediksi tekstur tanah.

1.3. Tujuan

1. Menganalisis karakteristik dan distribusi spasial fraksi tanah di Sub-DAS Bompon.
2. Mengevaluasi kinerja pendekatan DSM berbasis SCORPAN dalam memprediksi fraksi tanah di Sub-DAS Bompon.
3. Menyusun manajemen pengelolaan lahan berdasarkan distribusi fraksi tanah di Sub-DAS Bompon.

1.4. Manfaat

1. Secara akademis, hasil penelitian dapat memberikan tambahan ilmu pengetahuan terkait penerapan *Digital Soil Mapping* (DSM) untuk prediksi distribusi fraksi tekstur tanah
2. Hasil penelitian dapat digunakan sebagai data pendukung dalam pengambilan keputusan terkait pengelolaan lahan dan konservasi untuk meningkatkan produktivitas dan keberlanjutan.

1.5. Keaslian

Tabel 1.1. Penelitian sebelumnya terkait *Digital Soil Mapping* (DSM).

No	Nama, Tahun, Judul Penelitian, dan Penerbit	Tujuan Penelitian	Metode dan Pendekatan	Hasil
1.	Pahlavan-Rad, M. R., & Akbarimoghaddam, A. 2018. Spatial variability of soil texture fractions and pH in a flood plain (case study from eastern Iran). CATENA, 160, 275–281.	Mengetahui distribusi fraksi tekstur tanah dan pH menggunakan metode *Random Forest* (RF) di daerah dataran banjir.	Pemodelan menggunakan algoritma RF dengan variabel lingkungan yang terdiri dari 20 variabel topografi, jarak dari jaringan sungai dan saluran, NDVI, dan NDSI. Variabel lingkungan memiliki resolusi spasial 30 m yang berasal dari Aster GDEM dan Indian Remote Sensing (IRS). Estimasi kesalahan variabel menggunakan data OOB *(Out-Of-Bag)*. Validasi model menggunakan ME, MAE, dan RMSE.	Hasil penelitian menunjukkan kandungan pasir lebih tinggi di dekat sungai, kandungan lempung, debu, dan nilai pH meningkat seiring jarak dari sungai, serta kandungan lempung dan pH memiliki distribusi yang sama. Nilai RMSE untuk peta prediksi fraksi pasir, debu, lempung, dan pH masing-masing adalah 21,40, 17,45, 6,06, dan 0,45. Penggunaan variabel jarak dari jaringan sungai dan saluran dalam pemetaan meningkatkan akurasi prediksi.
2.	Kaya *et al*., 2022, Digital mapping for soil texture class prediction in northwestern Türkiye by different machine	Menilai kemampuan variabel lingkungan yang berasal dari Citra Landsat 8 OLI dan DEM serta tiga model *machine learning*	Pemodelan menggunakan algoritma DT, RF, dan SVM dengan 11 variabel lingkungan. Variabel tersebut berasal dari Citra Landsat 8 OLI resolusi 28,5	Hasil penelitian menunjukkan algoritma terbaik untuk prediksi kelas tekstur tanah adalah RF dengan total akurasi 0,63 dan indeks kappa 0,14. Variabel terpenting dalam prediksi kelas tekstur tanah dengan algoritma DT dan RF

	learning algorithms, Geoderma Regional, 31.	yang terdiri dari *Decision Tree* (DT), *Random Forest* (RF), dan *Support Vector Machine* (SVM) untuk klasifikasi kelas tekstur tanah di Cekungan Danau Manyas	m dan DEM resolusi 30 m. Penilaian pentingnya variabel pada metode DT menggunakan fungsi "varImp", metode RF menggunakan OOB *(Out-Of-Bag),* dan metode SVM menggunakan batas keputusan (*hyperplane*). Validasi model menggunakan *leave-one-out cross-validation*.	adalah TWI, sedangkan untuk algoritma SVM adalah variabel GNDVI.
3.	Schulz *et al.*, 2023, Digital Soil Texture Maps of Argentina and Their Relationship to Soil-Forming Factors and Processes, In Geopedology (pp. 263–281), Springer International Publishing.	(1) Membuat peta distribusi fraksi lempung, debu, dan pasir pada kedalaman 0–15, 15–30, 30–60 dan 60–100 cm, (2) membuat peta kelas tekstur tanah untuk kedalaman tanah yang sama, (3) menggambarkan distribusi tekstur tanah dalam kaitannya dengan unit lanskap yang berbeda.	Pemodelan menggunakan algoritma *Quantile Regression Forest* (QRF) dengan 64 variabel lingkungan. Variabel lingkungan memiliki resolusi spasial 1 km yang berasal dari Data Global Lithology USGS, Citra MODIS, dan DEM MERIT. Penilaian pentingnya variabel pada metode QRF menerapkan *Recursive Feature Elimination* (RFE). Validasi model menggunakan RMSE, MEC, dan MAE.	Hasil penelitian menunjukkan prediksi fraksi lempung pada kedalaman 0-15 cm memiliki RMSE terkecil yaitu 8,766. Pemodelan menghasilkan 13 kelas tekstur tanah di Argentina. Terdapat 12 variabel lingkungan terpenting yang digunakan dalam pemodelan. Variabel terpenting adalah variabel curah hujan rata-rata tahunan dan suhu rata rata tahunan.

4.	Pelegrino *et al*., 2025, Optimizing soil texture spatial prediction in the Brazilian Cerrado: Insights from random forest and spectral data, Geoderma Regional, 40.	Mengintegrasikan Synthetic Soil Image (SySI) dengan variabel lingkungan dalam *Digital Soil Mapping* untuk memetakan distribusi fraksi tanah di Bioma Cerrado, Brazil	Pemodelan menggunakan algoritma *Random Forest* (RF) dengan 24 variabel lingkungan dengan resolusi 30 m. Variabel band spektral berasal dari SySI, variabel iklim dari WorldClim, variabel topografi dari DEM, variabel organisme dari data MODIS, dan penggunaan lahan/penutup lahan (LULC). Pemodelan terdiri dari 4 skenario berdasarkan pemilihan variabel: Model I menerapkan SySI; Model II menerapkan MODIS, LULC, WorldClim, dan turunan DEM; Model III menerapkan SySI, MODIS, dan LULC; dan Model IV menerapkan semua kovariat.	Hasil penelitian menujukkan model yang paling akurat menjelaskan sekitar 83% fraksi lempung, 86% fraksi pasir, dan 74% fraksi debu, dengan nilai RMSE lempung 0,089, pasir 0,102, dan debu 0,53. Pemodeln meunjukkan elevasi dan bioiklim memiliki kapasitas prediktif yang kuat serta ketinggian merupakan turunan DEM yang relevan untuk memprediksi tekstur tanah.

BAB II TINJAUAN PUSTAKA

2.1. Tinjauan Pustaka

2.1.1. Sub-DAS Bompon

Daerah Aliran Sungai (DAS) merupakan suatu kawasan yang dibatasi oleh pembatas-pembatas topografi punggungan bukit atau gunung. DAS menjadi kawasan yang menerima dan mengumpulkan air hujan, unsur hara, dan sedimen, serta mengalirkannya melalui anak sungai ke sungai utama menuju danau atau laut (Kironoto et al., 2020). Suatu DAS terdiri atas Sub-DAS dan Sub-Sub DAS. Sub-DAS Bompon merupakan bagian dari Sub-DAS Kodil yang berada di kawasan DAS Bogowonto. Setiap DAS mempunyai karakteristik yang menggambarkan kondisi spesifik masing-masing DAS. Berdasarkan Peraturan Direktur Jenderal Bina Pengelolaan Daerah Aliran Sungai dan Perhutanan Sosial, Nomor: P.3/V-SET/2013, karakteristik DAS meliputi karakteristik biogeofisik dan karakteristik sosial ekonomi budaya dan kelembagaan.

Tekstur tanah merupakan salah satu sifat fisik tanah yang dapat berpengaruh terhadap kejadian longsor. Sub-DAS Bompon yang berada di zona vulkanik transisional memiliki perkembangan tanah yang kompleks sehingga menghasilkan lapisan tanah yang dalam dan material terlapukkan dengan kandungan lempung yang tinggi (Sambodo & Arpornthip, 2021). Penelitian Wida et al. (2019) menunjukkan bahwa tanah residual dengan kandungan lempung yang tinggi menggambarkan risiko longsor yang tinggi di Sub-DAS Bompon. Oleh karena itu, informasi spasial terkait fraksi tekstur tanah diperlukan dalam pengelolaan lahan secara berkelanjutan karena memengaruhi struktur, kesuburan, konduktivitas hidrolik, infiltrasi, dan erosi tanah (Pahlavan-Rad & Akbarimoghaddam, 2018).

2.1.1.1. Karakteristik Geomorfologi dan Geologi

Sub-DAS Bompon berada di zona vulkanik transisional yang berada di antara zona kuarter dan zona tersier (Prayitno et al., 2019). Zona kuarter berupa zona vulkanik kuarter Sumbing dan zona tersier berupa zona struktural-vulkanik tersier Menoreh (Noviyanto et al., 2020). Pembentukan tanah pada zona bentangalam transisi tidak hanya dipengaruhi oleh proses pelapukan, namun juga dipengaruhi oleh alterasi batuan induk. Alterasi tidak hanya mengakibatkan proses pembentukan tanah dari atas ke bawah, namun juga dari bawah ke atas (Pulungan & Sartohadi, 2018).

1Pada zona vulkanik transisional Kuarter–Tersier, banyak wilayah mengalami intrusi magma yang menyebabkan alterasi batuan induk akibat panas yang

menginduksi pembentukan mineral tertentu (Carlson et al., 2009; Pulungan & Sartohadi, 2018). Di Pulau Jawa, intrusi magma umumnya berinteraksi dengan air tanah sehingga berkembang alterasi hidrotermal yang mengubah komposisi mineral batuan melalui interaksi antara fluida hidrotermal dan batuan dinding (Febriyana et al., 2014; Pancake, 1949; Pulungan & Sartohadi, 2018). Kondisi tersebut memengaruhi pembentukan tanah di bagian tengah dan bawah DAS Bogowonto, termasuk Sub-DAS Bompon, yang berkembang pada bahan induk hasil alterasi hidrotermal (Pulungan & Sartohadi, 2018).

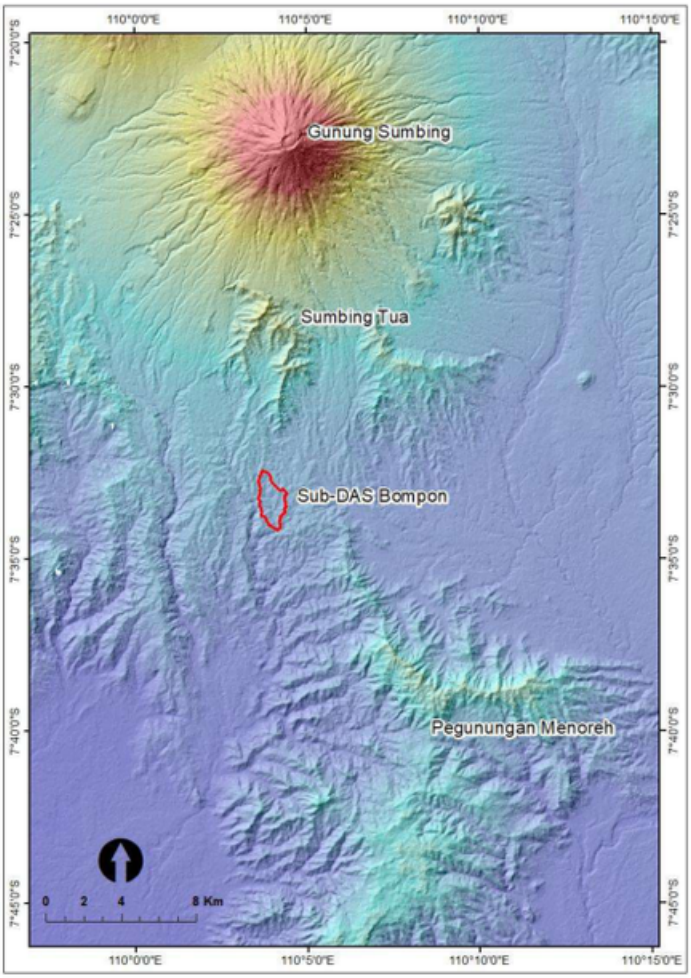

Gambar 2.1. Zona transisi tersier-kuarter Sub-DAS Bompon

Tanah di Sub-DAS Bompon berasal dari pelapukan material Gunung Sumbing Tua, Gunung Sumbing Muda, dan Pegunungan Menoreh. Gunung Sumbing yang terletak di utara Sub-DAS Bompon tersusun oleh material yang didominasi oleh tuff pasiran, sedangkan Pegunungan Menoreh yang terletak di tenggara Sub-DAS

Bompon memiliki karakteristik material yang tersusun oleh batuan breksi andesit teralterasi (Malik, 2017). Peta sebaran tutupan material disajikan pada Gambar 2.2.

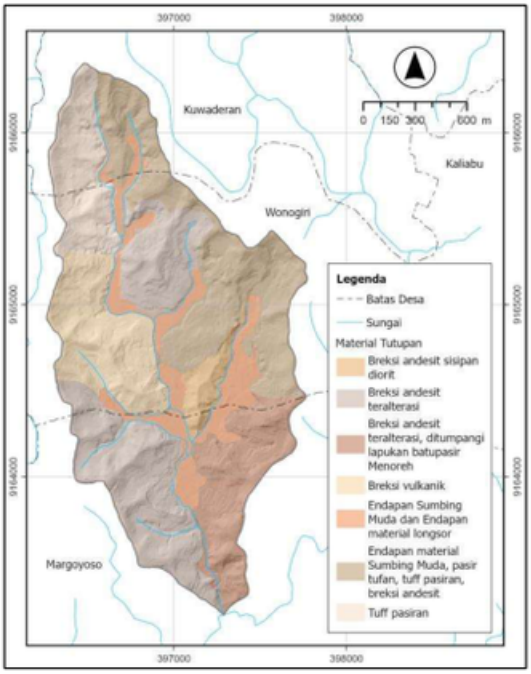

Gambar 2.2. Peta Tutupan Material Sub-DAS Bompon

Proses alterasi, proses pelapukan material, serta material abu vulkanik Sumbing mengakibatkan tanah yang tebal di Sub-DAS Bompon. Material dari endapan abu vulkanik dan alterasi breksi andesit selain membentuk tanah yang tebal, juga membentuk material lempung. Menurut Sambodo & Arpornthip (2021), Sub-DAS Bompon yang berada di zona vulkanik transisional memiliki perkembangan tanah yang kompleks sehingga menghasilkan lapisan tanah yang dalam dan material terlapukkan dengan kandungan lempung yang tinggi. Tanah yang tebal dapat diamati dari kondisi longsor di Sub-DAS Bompon yang ditunjukkan oleh Gambar 2.3.

Gambar 2.3. Kondisi longsor di Sub-DAS Bompon

Sub-DAS Bompon dibagi ke dalam 6 kelas bentuklahan, yang terdiri atas interfluve, lereng atas perbukitan, lereng tengah perbukitan, lereng bawah perbukitan,

lereng kaki koluvial, dan dataran koluvial. Adanya zona interfluve atau residual menunjukkan adanya proses struktural yang terjadi di Sub-DAS Bompon (Rahmi et al., 2019). Kondisi bentuklahan yang beragam akan menimbulkan berbagai proses geomorfologi yang berbeda seperti kejadian erosi, banjir, dan kekeringan (Malik, 2017). Lereng tengah perbukitan mendominasi kawasan Sub-DAS Bompon. Sub DAS Bompon yang memiliki topografi perbukitan rawan terhadap erosi di musim penghujan dan kekeringan di musim kemarau (Sartohadi et al., 2024).

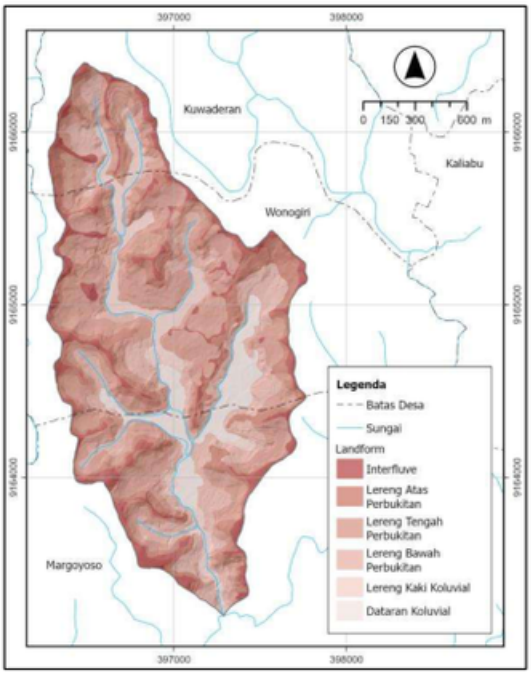

Gambar 2.4. Peta Bentuklahan Sub-DAS Bompon

2.1.1.2. Karakteristik Meteorologi

Sub-DAS Bompon memiliki dua musim yaitu musim kemarau dan musim penghujan. Musim hujan terjadi di bulan November hingga April dengan puncak curah hujan terjadi di bulan November hingga Januari (Sambodo & Arpornthip, 2021; Sartohadi et al., 2024b). Curah hujan tahunan di Sub-DAS Bompon mencapai 3.000-4.000 mm per tahun (Sartohadi et al., 2024). Terdapat perbedaan yang tegas antara musim kemarau dan penghujan di Sub-DAS Bompon. Intensitas hujan yang tinggi menyebabkan Sungai Bompon memiliki debit air yang tinggi, namun pada musim kemarau Sungai Bompon di bagian hulu tidak mengalir dan ada yang mengalir di bagian hilir dengan debit rendah.

2.1.1.3. Karakteristik Sosial Masyarakat

Mayoritas masyarakat di Sub-DAS memiliki mata pencaharian sebagai petani sehingga lahan di Sub-DAS Bompon telah dimanfaatkan untuk berbagai

bentuk pemanfaatan lahan. Penggunaan lahan di Sub-DAS Bompon didominasi oleh lahan pertanian yang mencapai >90% dari total luas areanya (Wijayanti, 2020). Bagian hulu DAS didominasi oleh pertanian campuran dengan komoditas utama tanaman sengon dan bagian dataran dekat Sungai Bompon merupakan lahan sawah sistem irigasi dan sawah tadah hujan (Sambodo & Arpornthip, 2021). Pemanfaatan lahan untuk sawah tersebar di lembah-lembah lereng kaki koluvial dan dataran koluvial. Sedangkan, permukiman warga tersebar pada wilayah hilir dan berada di lereng perbukitan. Pemanfaatan lahan oleh masyarakat, sebagian besar tidak memperhatikan kondisi fisik lereng yang berpotensi mengalami erosi dan longsor (Wida et al., 2019). Sebagian besar bangunan permukiman dibangun dengan melakukan pemotongan lereng, yang dapat meningkatkan aktivitas longsor (Malik, 2017).

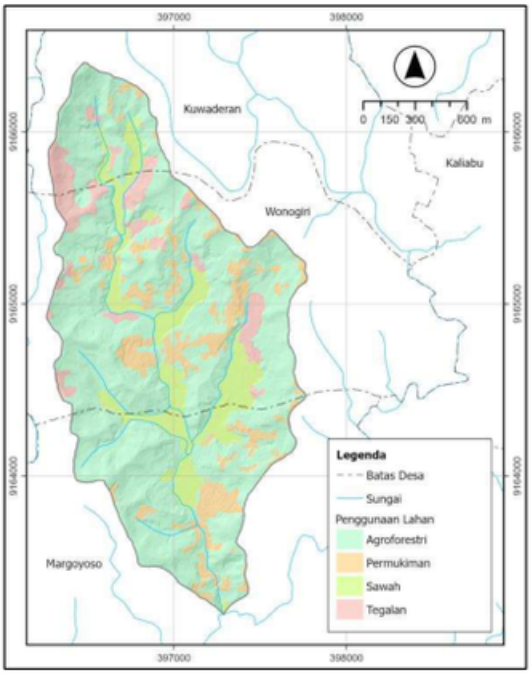

Gambar 2.5. Peta Penggunaan Lahan Sub-DAS Bompon

2.1.2. Tekstur Tanah

Tekstur tanah merupakan salah satu sifat fisik tanah yang penting. Tekstur tanah berpengaruh terhadap kapasitas tanah untuk menahan air, permeabilitas tanah, dan memengaruhi sifat fisik serta sifat kimia tanah lainnya (Ramlan & Rahman, 2023). Sifat fisik tanah lain yang dipengaruhi oleh tekstur tanah diantaranya adalah Berat Volume (BV), kelembaban tanah, total ruang pori, dan struktur tanah (Yulnafatmawita *et al.*, 2007). Sedangkan, sifat kimia tanah yang dipengaruhi oleh tekstur tanah adalah

C-organik, akumulasi C-organik dikendalikan oleh distribusi ukuran partikel (Schulz *et al*., 2023). Bahan organik dan tekstur juga berpengaruh terhadap nilai KPK tanah (Putri *et al*., 2019).

Tekstur tanah merupakan perbandingan antara fraksi pasir, debu, dan lempung dalam satu bagian tanah. Fraksi pasir adalah ukuran partikel tanah yang kasar dengan diameter 0,05-2 mm, fraksi lempung adalah ukuran partikel tanah yang halus dengan diameter kurang dari 0,002 mm, dan fraksi debu adalah ukuran partikel tanah yang berada di antara pasir dan lempung (Sartohadi et al., 2022). Kelas tekstur berpengaruh terhadap kelembaban tanah dan ketersediaan air dalam tanah, yang pada umumnya mengalami peningkatan dari pasir, lempung, dan debu (Kaya et al., 2022). Klasifikasi fraksi ukuran partikel tanah disajikan pada Tabel 2.1.

Tabel 2. 1. Klasifikasi ukuran partikel fraksi tanah

Sistem USDA		**Sistem Internasional**	
Fraksi tanah	Diameter (mm)	Fraksi tanah	Diameter (mm)
Pasir sangat kasar (*very coarse sand*)	1,0 – 2,0	Pasir kasar (*coarse sand*)	0,20 – 2,0
Pasir kasar (*coarse sand*)	0,5 – 1,0	Pasir halus (*fine sand*)	0,02 – 0,20
Pasir sedang (*medium sand*)	0,25 – 0,5	Debu (*silt*)	0,002 – 0,02
Pasir halus (*fine sand*)	0,10 – 0,25	Lempung (*clay*)	< 0,002
Pasir sangat halus (*very fine sand*)	0,05 – 0,10		
Debu kasar (*coarse silt*)	0,02 – 0,05		
Debu halus (*fine silt*)	0,002 – 0,02		
Lempung kasar (*coarse clay*)	0,002 – 0,0002		
Lempung halus (*fine clay*)	≤ 0,0002		

Sumber: (Soil Science Staff, 2017a).

Pengukuran tekstur tanah dapat dilakukan di lapangan dan di laboratorium. Perkiraan lapangan dilakukan secara kualitatif dengan metode *hand-feel soil texture* (HFST) atau metode sentuhan. Perkiraan dilakukan dengan menggosokkan tanah di antara jari-jari dan menganalisis bagaimana tanah terasa. Partikel pasir terasa kasar dan dapat dilihat dengan mata secara langsung, partikel debu terasa halus, serta partikel lempung terasa lengket di beberapa area (Soil Science Staff, 2017b). Perkiraan kelas tekstur di lapangan harus diperiksa di laboratorium untuk pengukuran secara kuantitatif, pengukuran di laboratorium dapat menggunakan metode pipet dan hidrometer. Penelitian Chandra (2016) menunjukkan bahwa analisis dengan metode hidrometer lebih efisien dibandingkan dengan metode pipet, namun metode pipet memiliki tingkat akurasi yang lebih tinggi.

Hasil analisis tekstur tanah dapat diklasifikasikan ke dalam kelas tekstur berdasarkan fraksi ukuran partikel menurut USDA dengan mempertimbangkan persentase pasir, debu, dan lempung (Kaya et al., 2022). Sistem klasifikasi USDA merupakan sistem yang digunakan di Indonesia, terutama dalam pemanfaatan lahan pertanian (Sartohadi et al., 2022). Klasifikasi tekstur tanah menurut USDA terdiri dari 12 kelas yang ditunjukkan pada Gambar 2.6..

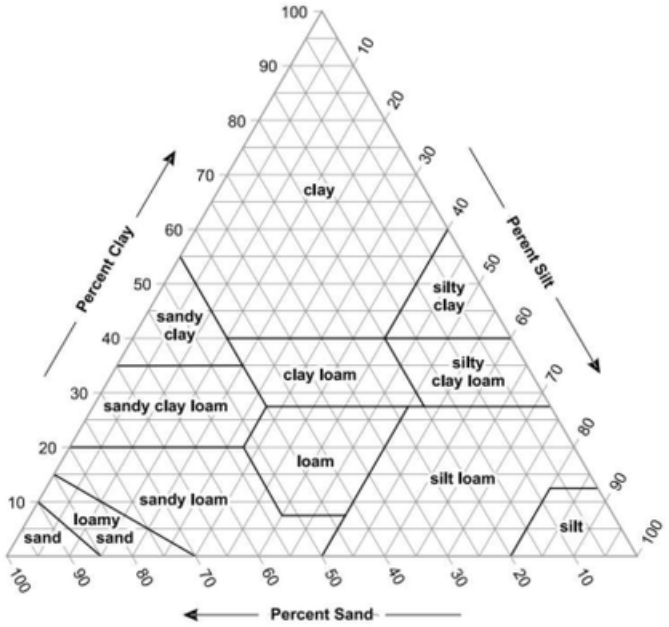

Gambar 2.6. Segitiga klasifikasi tekstur tanah USDA

Sumber: (Soil Science Staff, 2017b)

Informasi variabilitas spasial tekstur tanah dapat digunakan dalam pengambilan keputusan untuk penjadwalan irigasi, pemberian pupuk, dan pemilihan tanaman sehingga dapat memaksimalkan produktivitas (Rinaldi & He, 2014; Chattaraj et al., 2025). Tekstur tanah mengatur retensi air, ketersediaan nutrisi, dan perkembangan akar (Richer-de-Forges *et al.*, 2022). Variabilitas tekstur yang berbeda-beda pada suatu lahan dapat mengurangi efektivitas manajemen irigasi konvensional. Metode irigasi dengan mengasumsikan bahwa kondisi tanah seragam dapat menyebabkan tidak adanya penjadwalan irigasi dan kurangnya efisiensi penggunaan air yang dapat berpengaruh terhadap produktivitas tanaman (Vories et al., 2021).

Penelitian (Vories et al., 2021) menunjukkan bahwa pembagian zona pengelolaan irigasi tanpa memperhatikan tekstur tanah menyebabkan perbedaan hasil panen tanaman kapas yang tidak signifikan antar perlakukan. Setiap zona terdiri dari berbagai tekstur tanah dengan satu rekomendasi irigasi yang sama. Pemilihan

zona yang lebih homogen dengan tekstur yang sama memungkinkan sistem irigasi yang lebih efektif.

Tekstur tanah berpengaruh terhadap perkembangan akar tanaman, tekstur tanah yang lebih ringan atau kasar menghasilkan perkembangan organ bawah tanaman yang lebih baik. Penelitian (Aghhavani Shajari et al., 2020) menjelaskan bahwa penambahan pasir pada tanah disertai interval irigasi yang lebih pendek menghasilkan pertumbuhan umbi yang lebih baik dan mempercepat masa pembungaan tanaman saffron atau kuma-kuma. Peningkatan kandungan pasir dapat meningkatkan permeabilitas tanah, namun dapat mengurangi kadar air tanah selama interval irigasi yang lebih panjang sehingga diperlukan interval irigasi yang lebih pendek. Penelitian lain menunjukkan bahwa hasil umbi bunga tulip mengalami peningkatan pada tekstur tanah lempung berpasir dibandingkan dengan tekstur tanah lempung (Aghhavani Shajari et al., 2020; Khalighi et al., 2006).

2.1.3. *Digital Soil Mapping* (DSM)

Digital Soil Mapping (DSM) merupakan penerapan pendekatan statistik dan teknologi geospasial yang digunakan untuk mengestimasi sifat tanah secara spasial Zeraatpisheh et al. (2020). Keberhasilan dalam DSM membutuhkan 1) ketersediaan variabel prediktor yang cukup tercatat, 2) ketersediaan titik data tanah yang cukup agar menyesuaikan dengan variabel lingkungan, 3) fungsi prediktif cukup fleksibel untuk menyesuaikan hubungan non-linier, dan 4) hubungan tanah dan variabel lingkungan yang kuat (McBratney et al., 2003). Selain itu, dibutuhkan distribusi pengambilan titik sampel yang merata di seluruh area kajian (Viloria et al., 2016).

2.1.3.1. Konsep SCORPAN

Menurut Jenny (1941) proses pembentukan tanah dipengaruhi oleh 5 faktor yang terdiri dari iklim (Cl), organisme (O), bahan induk (P), relief (R), dan waktu (T). Kelima faktor tersebut dirumuskan sebagai berikut *S = f (Cl, O, P, R, T)*. Meskipun konsep ClOPRT banyak digunakan dan variabelnya menggambarkan variabel lingkungan, namun penerapannya dalam pemetaan digital perlu diintegrasikan dengan *Geographic Information System* (GIS) (Heung et al., 2021). McBratney et al. (2003) mengembangkan pendekatan pemetaan tanah konvensional ke digital menggunakan konsep SCORPAN. Pada konsep SCORPAN terdapat penambahan variabel pembentuk tanah berupa variabel S dan N. Sehingga diperoleh 7 faktor yang dirumuskan sebagai *S = f (S, C, O, R, P, A, N)* dengan rincian sebagai berikut:

(S) merepresentasikan sifat tanah (*soill)*. Sifat tanah dimaskukkan ke dalam konsep SCORPAN karena tanah dapat diprediksi berdasarkan sifatnya atau sifat-sifat

tanah yang lain. S berupa nilai atribut tanah tertentu pada kedalaman tanah tertentu, misalnya kandungan pasir pada kedalaman 20 cm. Sumber data faktor S dapat diperoleh melalui data penginderaan jauh, peta tanah yang sudah ada, dan pengambilan sampel lapangan dengan GPS serta analisis laboratorium.

(C) merepresentasikan iklim (*climate)* yang dapat diwakili oleh curah hujan (C), suhu (T), dan evapotrasnpirasi (E). Parameter iklim dapat diperoleh dari stasiun meterologi dan diinterpolasi untuk mengetahui sebaran spasial parameter iklim. Data penginderaan jauh juga dapat dianalisis untuk memperkirakan curah hujan, suhu, kelembapan atmosfer, dan kelembapan tanah. Suhu dapat diperkirakan melalui indeks *Normalized Difference Vegetation Index* (NDVI) dari data *Advanced Very High Resolution Radiometer* (AVHRR).

(O) merepresentasikan organisme sebagai faktor pembentuk atau pengubah tanah. Organisme utama yang berpengaruh terhadap pembentukan tanah adalah vegetasi dan manusia. Aktivitas manusia seperti alih fungsi lahan, praktik penggunaan lahan, dan perubahan tutupan vegetasi dapat berpengaruh terhadap sifat-sifat tanah. Dalam DSM faktor organisme dapat direpresentasikan oleh indeks vegetasi, peta biomassa, atau peta tutupan dan penggunaan lahan.

(R) merepresentasikan relief yang menggambarkan bentuk atau karakteristik permukaan lahan. Turunan dari data Digital Elevation Model (DEM) dapat digunakan untuk merepresentasikan atribut topografi. Atribut topografi terdiri atas atribut topografi primer dan atribut topografi sekunder. Dasar perhitungan atribut topografi primer berasal dari elevasi yang meliputi kemiringan, kelengkungan, arah hadap lereng, dan atribut lain yang berhubungan terhadap lereng. Sedangkan, atribut topografi sekunder berasal dari perhitungan atribut primer dengan menggabungkan dua atau lebih atribut primer. Atribut topografi sekunder dapat berupa *Topographic Wetness Index* (TWI), *Length-Slope Factor* (LS), atau *Topographic Position Index*(TPI).

(P) merepresentasikan bahan induk pembentuk tanah. Dalam konsep SCORPAN, data turunan DEM merupakan faktor utama yang digunakan, sedangkan bahan induk dan umur tanah kurang mendapat perhatian (Cahyana et al., 2023). Faktor bahan induk yang sering terabaikan diakibatkan oleh kompleksitas pergerakan material dari waktu ke waktu (Cahyana et al., 2023; Hosseinpour-Zarnaq et al., 2025). Informasi bahan induk dapat diperoleh melalui peta geologi, namun skala pada peta geologi lebih kasar daripada peta tanah dan data penginderaan jauh atau geofisika yang dapat merepresentasikan bahan induk membutuhkan biaya yang mahal

(Loiseau et al., 2020). Pengunaan bahan induk dapat meningkatkan kualitas dan akurasi peta tanah. Penelitian (Cahyana et al., 2023) menunjukkan bahwa penambahan faktor bahan induk sebagai kovariat dalam DSM dapat meningkatkan akurasi peta tanah secara signifikan.

(A) merepresentasikan waktu atau umur tanah. Informasi umur memberikan batasan berapa lama pedogenesis telah terjadi. Namun, umur tanah sulit untuk dikarakterisasi dengan baik. Merepresentasikan umur tanah secara digital dan spasial merupakan hal yang sulit dan menjadi tantangan sehingga faktor umur sering diabaikan.

(N) merepresentasikan posisi spasial tanah. Dalam konsep SCORPAN, faktor N bukan merupakan faktor pembentuk tanah secara langsung, namun hanya representasi koordinat untuk memastikan pola spasial yang tidak terdapat dalam variabel lingkungan yang lain. Faktor N dapat terdiri dari koordinat spasial asli dan lokasi relatif terhadap fenomena geografis yang lain seperti jarak dari sungai atau jarak terdekat dari pantai. Faktor tanah menjadi informasi yang penting dan tidal dapa diabaikan dalam DSM.

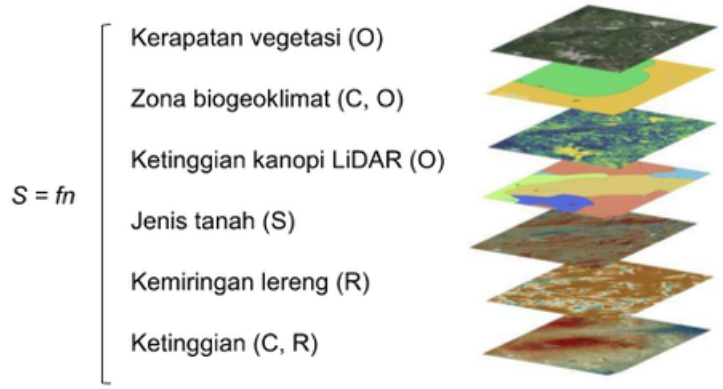

Gambar 2.7. Aplikasi Konsep SCORPAN

2.1.3.2. Variabel Lingkungan

Variabel lingkungan yang digunakan dalam membangun model prediksi sangat berpengaruh terhadap kinerja DSM (Nussbaum et al., 2018). Variabel lingkungan menghubungkan target sifat tanah dengan faktor prediktor yang merepresentasikan SCORPAN (Sulaeman & Husnain, 2021). Salah satu atau kombinasi faktor SCORPAN digunakan untuk memprediksi distribusi sifat tanah (S) menggunakan fungsi kuantitatif untuk menggambarkan hubungan tanah dan lingkungan (Heung et al., 2021). Beberapa variabel lingkungan dipilih sebagai

kovariat dalam DSM berdasarkan pada relevansi pedogenesis, ketersediaan data, dan hubungan antara variabel lingkungan dengan sifat tanah target.

Review menurut (Mgohele et al., 2024a) menunjukkan bahwa dari 70 penelitian selama 10 tahun terakhir citra satelit yang paling banyak digunakan adalah citra Sentinel 2 sebesar 42,85% dan indeks vegetasi yang paling banyak digunakan adalah NDVI sebesar 75,7%. Berdasarkan 70 penelitian dianalisis tingkat kepentingan setiap kovariat menggunakan *Accuracy-Based Importance* (ABI). Untuk prediksi kandungan lempung kovariat yang berkontribusi lebih besar adalah band NIR dan SWIR2. Sedangkan, untuk prediksi kandungan debu dan pasir, NDVI dan band NIR memiliki kontribusi yang lebih besar. Band NIR memiliki tingkat kepentingan yang tinggi karena band tersebut sangat sensitif terhadap kelembapan tanah dan kandungan bahan organik yang berkaitan dengan mineral lempung (Hong et al., 2017; Mgohele et al., 2024; Viscarra Rossel et al., 2016).

2.1.3.3. Light Detection and Ranging (LiDAR)

Variabel lingkungan dalam *Digital Soil Mapping* (DSM) diperoleh dari data penginderaan jauh berupa data raster. Data dengan resolusi spasial yang tinggi secara akurat dapat menangkap variasi lanskap skala detail untuk memprediksi sifat tanah, data tersebut dapat diperoleh melalui data LiDAR (*Light Detection and Ranging*) (Ågren et al., 2021). LiDAR menerapkan sistem penginderaan jauh sensor aktif dengan menembakkan sinar laser untuk pengukuran jarak. Prinsip LiDAR adalah memancarkan laser, dipantulkan oleh suatu objek, dan diterima kembali oleh sensor (Kroll, 2025).

Hasil perekaman LiDAR adalah *point cloud* dan tidak menghasilkan warna objek, untuk menghasilkan *point cloud* berwarna maka sensor kamera RGB (*Red-Green-Blue*) dipasang pada LiDAR. Data point cloud LiDAR menggambarkan kenampakan topografi bumi secara 3D (Yan et al., 2015). Pemindaian sensor LiDAR memiliki hasil yang lebih baik untuk memodelkan struktur vertikal vegetasi (Lu et al., 2023). Penelitian terkait LiDAR, sebagian besar berfokus pada deteksi tajuk pohon tunggal dan perkiraan tinggi tanaman (Farhadur Rahman et al., 2022).

Ketersediaan LiDAR mempermudah dalam mengidentifikasi distribusi spasial di area yang luas. Namun, integrasi LiDAR pada lanskap yang luas dapat mengakibatkan penggunaan data yang intensif (Ågren et al., 2021). Metode *machine learning* menyediakan pendekatan yang efektif untuk menganalisis kumpulan data yang heterogen.

2.1.3.4. Sentinel-2A Deep Resolution 3.0

Citra Sentinel-2A diluncurkan pada tanggal 23 Juni 2025. Citra Sentinel dapat dimanfaakan dalam pemantauan perubahan lahan, kesehatan tanaman, pengendalian bencana, kehutanan, dan lain sebagainya. Sentinel-2A memiliki resolusi temporal 5 hari, sehingga memungkinkan untuk pemantauan perubahan lahan atau kesehatan tanaman secara berkala (ESA, 2024). Sentinel-2A mempunyai 13 band spektral dengan reosluis spasial yang berbeda-beda. Empat band dengan resolusi spasial 10 m, empat band dengan resolusi spasial 20 m, dan tiga band dengan resolusi spasial 60 m (CDSE, 2016). Data Sentinel-2A tersedia secara terbuka dan dapat diakses melalui website Copernicus.

Resolusi spasial citra dapat ditingkatkan melalui *image upscaling*. Resolusi spasial yang ditingkatkan memungkinkan untuk analisis yang lebih detail dan pengambilan keputusan yang lebih baik. *Image Upscaling* pada Sentinel-2A dilakukan dengan metode *Sentinel-2 Deep Resolution 3* (S2DR3) yang dipublikasikan oleh Akhtman (2023). Penerapan S2DR3 dapat meningkatkan resolusi spasial Sentinel-2A dari 10 m, 20 m, dan 60 m hingga menjadi 1 m (Salgueiro et al., 2021). Hasil ekstraksi indeks dari citra Sentinel 2 (S2) dan S2DR3 menunjukkan kemiripan satu sama lain, hal tersebut mengonfirmasi bahwa S2DR3 dapat dimanfaatkan untuk pemetaan beresolusi tinggi. Penelitian Chanev et al. (2025) menunjukkan bahwa Normalized Difference Water Index (NDWI) dari S2 resolusi 10 m cenderung dipengaruhi oleh piksel campuran gabungan spektral tanah dan vegetasi terutama pada pertumbuhan awal tanaman, sedangkan NDWI dari S2DR3 1 m dapat mengurangi pengaruh piksel campuran.

Gambar 2. 8. Perbandingan Sentinel-2A Resoluis Spasial 10 m dan 1 m

2.1.4. Machine Learning

Salah satu model prediksi yang dapat digunakan dalam DSM adalah machine learning. Machine. Learning menggunakan algoritma dan model statistik untuk mengenali pola dalam data dan membuat model berdasarkan pola tersebut. Model machine learning dalam DSM yang paling sering digunakan adalah *Random Forest* (Mgohele et al., 2024b). Pengembangan model Random Forest dengan model regresi kuantil menghasilkan model Quantile Regression Forest (QRF)

2.1.4.1. Random Forest (RF)

Model *Random Forest* membuat sebuah pohon keputusan (*decision trees*) dan menggabungkan hasil dari setiap pohon untuk menghasilkan prediksi yang lebih akurat dan presisi (Breiman, 2001). Berbagai penelitian menunjukkan bahwa RF memiliki kemampuan prediktif yang tinggi dan dapat mengurangi *overfitting* (Sheykhmousa et al., 2020). Selain itu, Random Forest juga memberikan estimasi variabel-variabel mana yang paling berpengaruh dalam model, yang dikenal sebagai *covariate's contribution* levels atau *variable importance* sehingga mempermudah dalam memahami faktor utama yang memengaruhi variabel (Lam et al., 2023).

Estimasi kesalahan model RF dianalisis menggunakan data *Out-of-Bag* (OOB). Untuk memperkirakan tingkat kepentingan setiap variabel, nilai masing-masing variabel diubah secara acak dalam data OOB dan variabel lainnya tidak diubah. Variabel yang memiliki peningkatan kesalahan OOB relatif besar adalah variabel yang lebih penting. Pada pemodelan awal, semua variabel lingkungan digunakan dan kemudian dianalisis berdasarkan kepentingannya. Variabel dengan nilai kepentingan di bawah 7% dianggap tidak penting dan dihapuskan dari model (Pahlavan-Rad & Akbarimoghaddam, 2018). Parameter utama model RF adalah jumlah kovariat yang digunakan dalam setiap pohon regresi (*mtry*) dan jumlah pohon regresi dalam set (*ntree*) (Schulz et al., 2023).

2.1.4.2. Quantile Regression Forest (QRF)

Model Quantile Regression Forest (QRF) merupakan pengembangan dari metode Random Forest (RF). Model QRF menggabungkan model regresi kuantil dengan model RF. Random Forest merupakan salah satu algoritma yang paling populer dalam aplikasi DSM, namun QRF hasil pengembangan RF belum banyak diuji pada aplikasi DSM (Vaysse & Lagacherie, 2017). Perbedaan antara RF dan QRF terletak pada penyimpanan dan penggunaan data pengamatan untuk setiap node di setiap pohon. RF hanya menyimpan rata-rata pengamatan yang termasuk ke dalam

node dan mengabaikan informasi lainnya. Sedangkan, QRF mempertahankan semua nilai pengamatan yang termasuk ke dala node dan menilai distribusi bersyarat berdasarkan semua informasi tersebut (Meinshausen, 2006).

Estimasi kesalahan model QRF dianalisis menggunakan *Recursive Feature Elimination* (RFE) pada *package* caret untuk mengetahui variabel yang paling signifikan dalam prediksi (Schulz et al., 2023). Model QRF menunjukkan plot akurasi yang lebih baik dibandingkan dengan model Regression Kriging (RK) dalam prediksi pH tanah, bahan organik, dan kandungan *clay*. Penerapan QRF lebih direkomendasikan apabila data pengambilan sampel terbatas (Vaysse & Lagacherie, 2017). Penelitian Theres & Sakthivel (2022) menunjukkan bahwa hasil prediksi fraksi pasir, debu, dan lempung serta pH tanah memiliki akurasi yang tinggi, meskipun dengan kepadatan sampel yang rendah dan sumber data yang terbatas. Namun, aplikasi model QRF di negara-negara tropis dengan tanah dan iklim yang lebih kompleks dibandingkan dengan wilayah lain, direkomendasikan menggunakan kepadatan sampel yang lebih tinggi untuk hasil yang lebih baik (Moharana et al., 2023).

2.1.4.3. CatBoost

Categorical Boosting (CatBoost) merupakan algoritma *machine learning* berbasis *gradient boosting decision tree* yang dikembangkan untuk meningkatkan kemampuan prediksi sekaligus menangani fitur kategorikal secara efektif. CatBoost membangun sekumpulan pohon keputusan secara bertahap, dengan setiap model berikutnya diarahkan untuk memperbaiki kesalahan prediksi model sebelumnya. Salah satu karakteristik utama CatBoost adalah penerapan *ordered boosting* yang didesain untuk mengurangi *prediction shift* dan risiko *target leakage* selama proses pembelajaran. CatBoost menggunakan mekanisme khusus dalam pengolahan fitur kategorikal sehingga dapat memanfaatkan informasi kategori tanpa sepenuhnya bergantung pada proses pengkodean awal seperti *one-hot encoding*. Karakteristik tersebut memungkinkan CatBoost menangkap hubungan kompleks dan nonlinier antara variabel prediktor dan variabel target serta digunakan untuk berbagai permasalahan regresi dan klasifikasi (Prokhorenkova et al., 2018)

2.1.4.4. Stacking

Stacking atau *stacked generalization* merupakan metode *ensemble learning* yang menggabungkan prediksi dari beberapa model dasar (*base learners*) melalui model tingkat lanjut yang disebut *meta-learner*. Metode ini diperkenalkan oleh Wolpert (1992) dengan tujuan meningkatkan kemampuan generalisasi melalui

pemanfaatan keunggulan dan perbedaan pola kesalahan dari beberapa model. Pada tahap pertama, sejumlah *base learner* dilatih untuk menghasilkan prediksi, kemudian hasil prediksi tersebut digunakan sebagai masukan bagi *meta-learner* untuk menghasilkan prediksi akhir. Dalam penerapannya, prediksi *out-of-fold* atau skema validasi silang penting digunakan dalam pembentukan data pelatihan *meta-learner* untuk mengurangi risiko *overfitting* dan kebocoran informasi.

Melalui kombinasi beberapa model yang memiliki karakteristik pembelajaran berbeda, *stacking* dapat meningkatkan kemampuan prediksi terhadap hubungan yang kompleks dan nonlinier dibandingkan penggunaan satu model secara individual (Naimi & Balzer, 2018). Dalam penelitian ini, *Random Forest* dan *CatBoost* digunakan sebagai *base learners* karena memiliki mekanisme pembelajaran yang berbeda. *Random Forest* membangun sejumlah pohon keputusan melalui proses *bootstrap* dan pemilihan fitur secara acak, sedangkan *CatBoost* menggunakan pendekatan *gradient boosting* yang membangun pohon secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya. Perbedaan karakteristik tersebut memungkinkan kedua model menangkap pola hubungan yang berbeda antara kovariat lingkungan dan fraksi tanah.

2.1.4.5. Resampling Data

Ketidakseimbangan data merupakan salah satu tantangan dalam pemodelan spasial karena dapat memengaruhi kemampuan algoritma *machine learning* dalam mempelajari pola pada nilai-nilai yang kurang terwakili, sehingga berpotensi menurunkan akurasi prediksi apabila tidak ditangani dengan metode yang sesuai, seperti teknik *resampling* (Chattaraj *et al*., 2025). Resampling data dapat meningkatkan kinerja model pada kondisi data yang terbatas dan mencegah model dari overfitting. Resampling data memberikan penambahan nilai-nilai antara (*intermediate value*) ke dalam dataset dan meningkatkan representasi pada bagian data yang sebelumnya kurang terwakili dalam dataset.

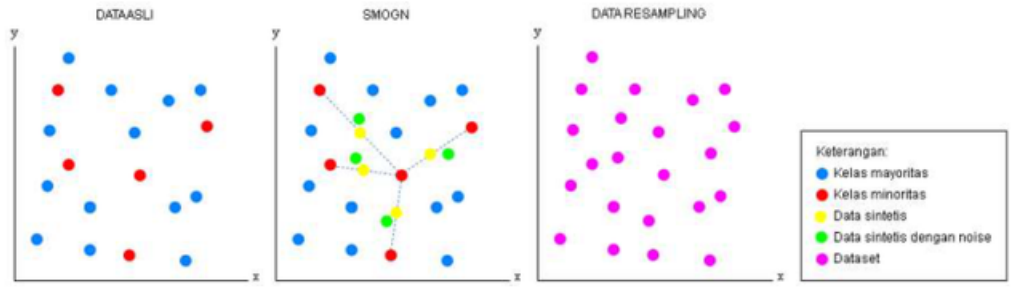

Gambar 2.9. Ilustrasi Metode SMOGN

Salah satu metode yang digunakan untuk resampling data adalah metode SMOGN. SMOGN melakukan augmentasi data dengan menghasilkan sampel baru yang berasal dari modifikasi dan variasi data yang sudah ada. Dengan menghasilkan nilai-nilai perantara untuk mengisi bagian data yang kurang terwakili, SMOGN mampu meningkatkan akurasi prediksi dalam dataset yang tidak seimbang. Untuk menghindari pembuatan data yang terlalu kaku atau duplikasi data, Noise Gaussian ditambahkan ke titik-titik sintetis (Cesmeli, 2025). Ilustrasi kinerja metode SMOGN disajikan pada Gambar 2.9.

2.2. Kerangka Teori

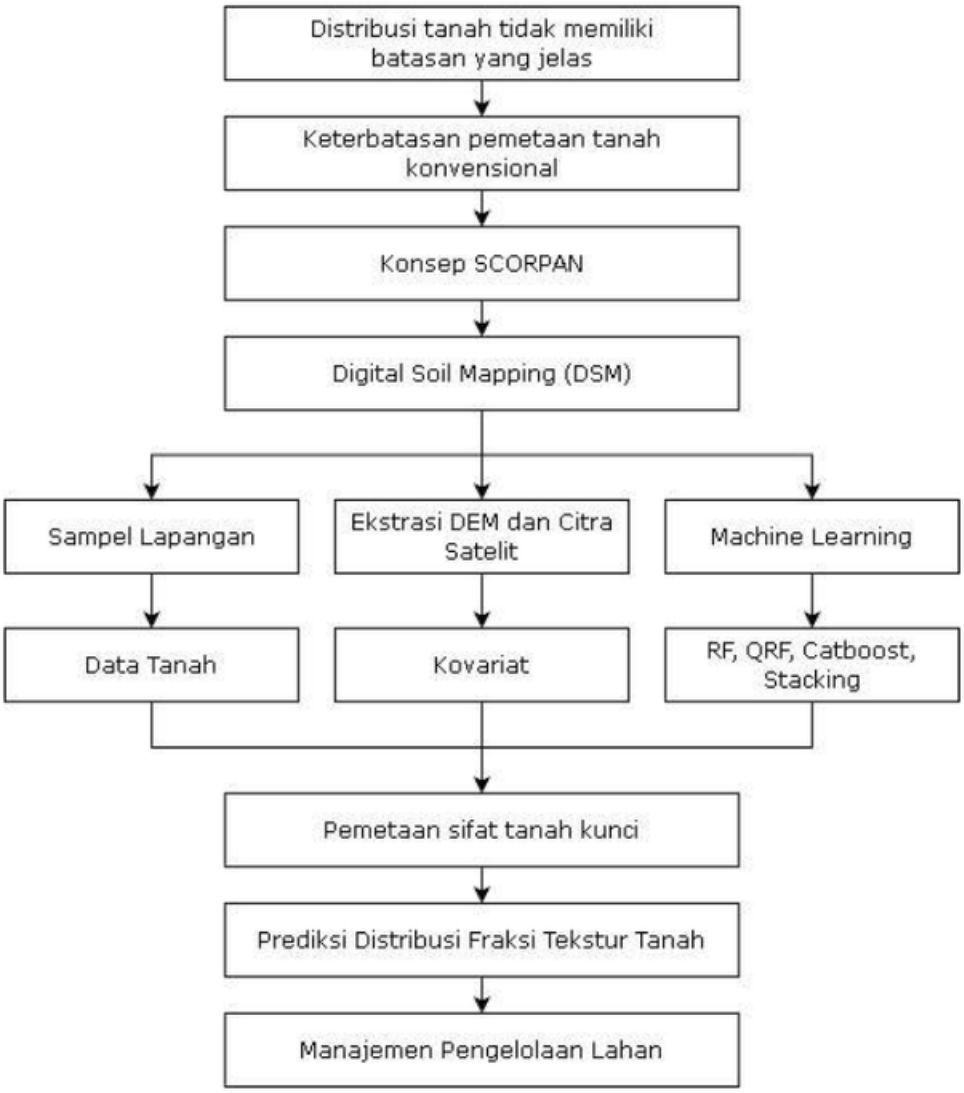

Gambar 2.10. Kerangka Teori

BAB III METODE PENELITIAN

3.1. Alat dan Bahan

3.1.1. Alat Penelitian

Alat yang diperlukan dalam penelitian terdiri dari alat pengambilan sampel dan alat uji laboratorium. Alat yang digunakan pada pengambilan sampel terdiri cangkul, bor tanah, ring BV, palu geologi, pisau, meteran, Munsell, dan plastik sampel. Alat yang digunakan dalam uji laboratorium terdiri dari pH meter, oven, ayakan 0,5 mm, ayakan 2 mm, cawan, erlenmeyer, labu ukur, dan dan peralatan laboratorium lainnya yang ada di Laboratorium Tanah Umum dan Laboratorium Fisika Tanah Fakultas Pertanian Universitas Gadjah Mada, serta Laboratorium Kimia Tanah Kuningan.

3.1.2. Bahan Penelitian

Bahan penelitian terdiri dari data sekunder untuk penentuan pengambilan titik sampel yang terdiri dari data DEM LiDAR, foto udara LiDAR, Peta Rupabumi Indonesia (RBI), dan 100 sampel tanah, aquadest, serta kemikalia untuk analisis di laboratorium.

3.1.3. Waktu dan Tempat

Penelitian dilaksanakan pada bulan Januari 2025 – selesai. Lokasi penelitian berada di Sub-DAS Bompon yang terletak di Desa Wonogiri dan Desa Kuaderan, Kecamatan Kajoran, serta Desa Margoyo, Kecamatan Salaman, Kabupaten Magelang. Koordinat Sub-DAS Bompon terletak antara 110°03′42″–110°04′08″ BT dan 7°33′13″–7°33′6″ LS. Sub-DAS Bompon memiliki luas sekitar 292,69 ha. Kegiatan preparasi sampel dan analisis laboratorium dilaksanakan di Laboratorium Tanah Umum, Laboratorium Fisika Tanah, serta di Laboratorium Kuningan, Gedung Tejuyuwono Notohadiprowiro, Departemen Tanah, Fakultas Pertanian, Universitas Gadjah Mada, Yogyakarta. Lokasi penelitian dapat dilihat pada Gambar 3.1.

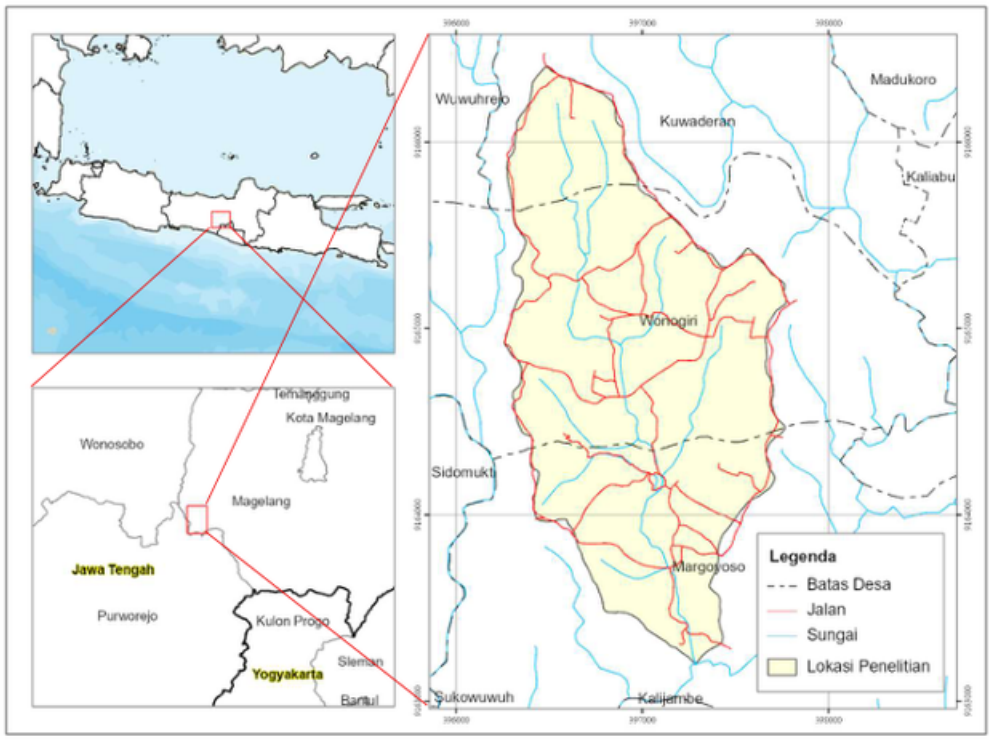

Gambar 3.1. Lokasi Penelitian

3.2. Prosedur Penelitian

Prosedur dalam penelitian ini terdiri dari pengamatan dan survei lapangan, persiapan alat dan bahan, dan pengambilan sampel

3.2.1. Pengamatan dan Survei Lapangan

Pengamatan dan survei lapangan dilakukan sebelum pengembalian sampel. Terdapat 3 kali survei yang dilakukan untuk mengetahui karakteristik area kajian dan menetukan lokasi pengambilan titik sampel. Selain itu, juga dilakukan wawancara kepada masyarakat untuk mengetahui permasalahan lahan pertanian di area kajian.

3.2.2. Pengambilan Sampel

Metode yang digunakan dalam penentuan titik sampel sampel adalah metode *stratified random sampling*. Penentuan titik berdasarkan pada unit pemetaan yang terdiri dari bentuklahan, penggunaan lahan, dan kemiringan lereng. Unit pemetaan berdasarkan ketiga parameter tersebut mampu merepresentasikan heterogenitas spasial yang melekat pada lanskap sehingga diasumsikan paling mewakili distribusi tanah suatu lanskap (Chattaraj et al., 2025a).

Data bentuklahan diperoleh dari survei kelompok riset Transbulent Tahun 2015. Berdasarkan data tersebut Sub-DAS Bompon terbagi ke dalam 6 kelas bentuklahan yang terdiri dari interfluve, lereng atas perbukitan, lereng tengah perbukitan, lereng

bawah perbukitan, lereng kaki koluvial, dan dataran koluvial. Penggunaan lahan Sub-DAS Bompon terdiri dari kelas agroforestri, permukiman, sawah, dan tegalan. Kemiringan lereng Sub-DAS Bompon dibagi menjadi 5 kelas yang terdiri dari lereng data (0-8%), lereng landai (8-15%), lereng agak curam (15-25%), lereng curam (25-45%), dan lereng sangat curam (>45%). Terdapat 50 titik pengambilan sampel dengan kedalaman 0-20 (Lapisan 1) cm dan 20-40 cm (Lapisan 2). Sebaran titk sampel dapat dilihat pada Gambar 3.2.

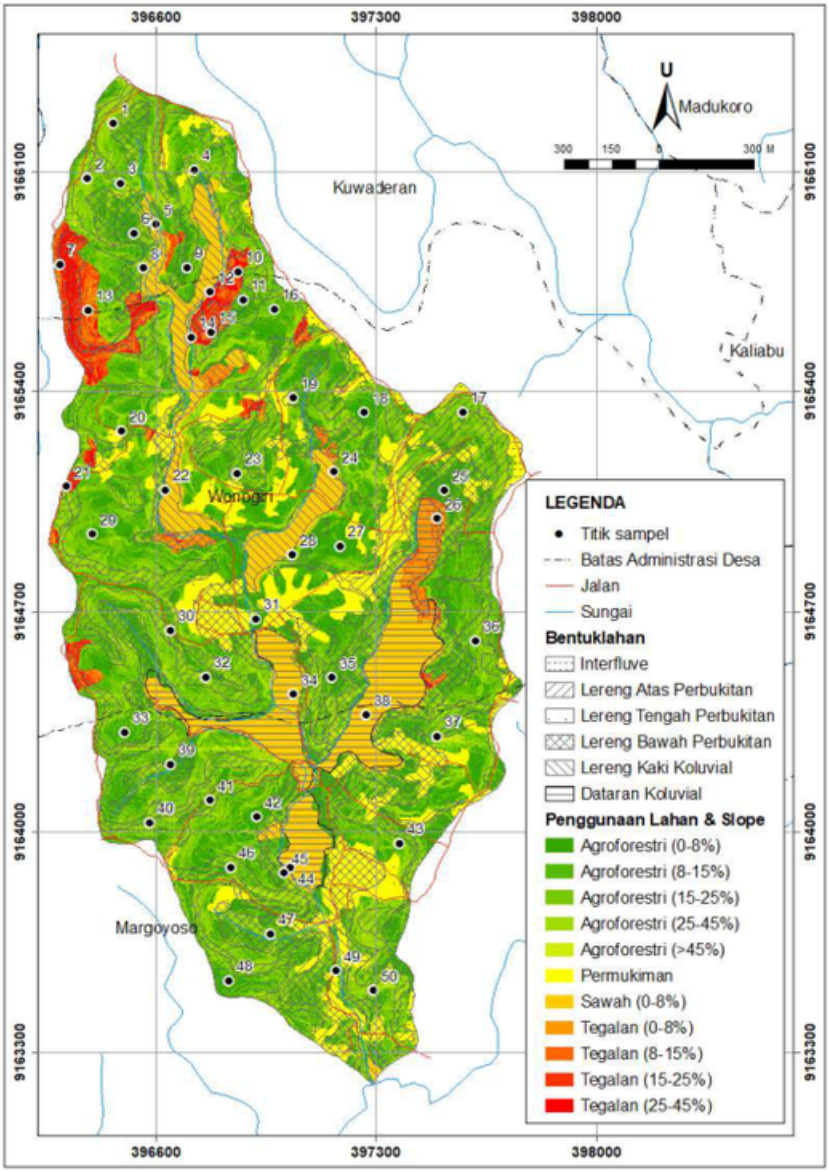

Gambar 3.2. Peta Sebaran Titik Sampel

3.3. Pengumpulan Data

Tabel 3.1. Parameter Uji Laboratorium

Parameter	Ekstrak	Alat	Referensi
pH	- H_2O - KCl 1 N	pH meter	
Kapasitas Pertukaran Kation (KPK)	- NH_4Cl 1 M	Foss	
C – organik	Walkey and Black - $K_2Cr_2O_7$ 1 N - $FeSO_4$ 0,2 N - H_2SO_4 pekat - Indikator Difenilamin (DPA)	Titrasi $FeSO_4$ 0,2 N	BPSI – Tanah dan Pupuk, 2023
Tekstur Tanah		Pemipetan	
Berat Volume		Ring BV	

3.4. Analisis Data

3.4.1. Pengolahan Data

Pemodelan dan pengolahan data dilakukan menggunakan software ArcGIS Pro dan Google Collab. Data hasil analisis laboratorium berupa sifat fisika dan kimia tanah dikonversi menjadi data spasial untuk pengolahan data. Data fraksi tekstur tanah terdiri dari fraksi lempung, fraksi debu, dan fraksi pasir untuk Lapisan 1 dan Lapisan 2. Prediksi dapat dilakukan dengan prediktor dari kovariat lingkungan yang dihasilkan dari turunan DTM LiDAR, foto udara, dan ekstraksi citra Sentinel-2A Deep Resolution 3.0. Dalam prediksi tekstur tanah di Sub-DAS Bompon terdapat 22 kovariat yang akan digunakan. Rincian kovariat dapat dilihat pada Tabel 3.2.

Tabel 3.2. Kovariat lingkungan yang digunakan

Faktor	Kovariat	Keterangan/Formula	Sumber
S (Tanah)	Clay Index	$\mathrm{CI} = \frac{\mathrm{SWIR1}}{\mathrm{SWIR2}}$	
	NDWI (Normalized Difference Water Index)	$\mathrm{NDWI} = \frac{(\mathrm{G-NIR})}{(\mathrm{G+NIR})}$	
O (Organisme)	NDVI (Normalized Difference Vegetation Index)	$\mathrm{EVI} = \frac{(\mathrm{R-NIR})}{(\mathrm{R+NIR})}$	Sentinel-2A
	SAVI (Soil Adjusted Vegetation Index)	$\mathrm{SAVI} = \frac{(\mathrm{NIR-R})}{(\mathrm{NIR+R})+0.5)*(1+0.5)}$	
	EVI (Enhanced Vegetation Index)	$\mathrm{EVI} = \frac{(\mathrm{NIR-R})}{(\mathrm{NIR+6*R-7.5*B+1})}$	
	Penggunaan Lahan		Foto Udara
	TWI (Topographic Wetness Index)	$TWI = \ln \frac{\alpha}{\tan(\beta)}$	
	Curvature		
	Elevation	Ketinggian	
	Slope	Kemiringan lereng	
	Aspect	Arah hadap lereng	
	Landform	Bentuklahan	
	CNBL (Channel Network Based Level)	Posisi akumulasi sedimen maksimum dan minimum	
R (Relief)	VD (Valley Depth)	Selisih ketinggian antara dasar lembah (valley bottom) denn\gan ketinggian tertinggi di sekitarnya	
	LSF (Slope Length & Steepness Factor)	Faktor panjang dan kemiringan lereng	DTM LiDAR
	MrVBF (Multi-resolution Valley Bottom Flatness)	Identifikasi lembah atau dataran rendah	
	MrRTF (Multi-resolution Index of the Ridge Top Flatness)	Identifikasi punggungan atau dataran tinggi	
	TPI (Topographic Position Indeks)	Posisi relatif suatu titik terhadap elevasi lain	
	Profile curvature	Perubahan kemiringan sepanjang arah aliran lereng secara vertikal	
	Plan curvature	Perubahan kemiringan sepanjang arah aliran lereng secara horizontal	
N (Posisi Relatif)	Jarak dari Sungai		
P (Bahan Induk)	Tutupan Material	Material sedimen bahan induk tanah	Malik (2017)

Keterangan: Specific Catchment Area (α), Slope (β), Slope Gradien (tan(β)), Band Merah (R), Band Hijau (G), Band Biru (B), Near-Infrared (NIR), dan SWIR (Short-Wave Infrared)

Sebaran spasial masing-masing kovariat lingkungan yang digunakan dalam pemodelan disajikan pada Tabel 3.3. Kovariat lingkungan tersebut merepresentasikan faktor tanah, organisme, relief, posisi relatif, dan bahan induk dalam konsep SCORPAN.

Tabel 3.3. Data spasial kovariat lingkungan yang digunakan

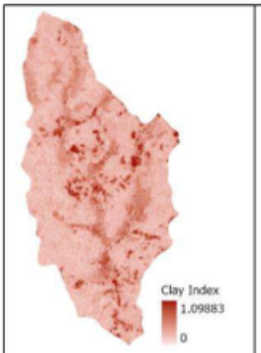	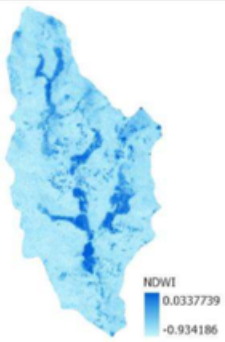	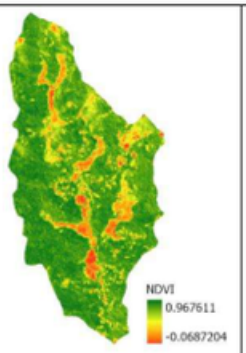	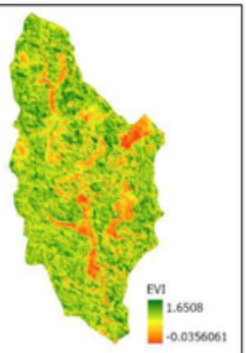
Kovariat S (Clay Index)	Kovariat O (NDWI)	Kovariat O (NDVI)	Kovariat O (EVI)
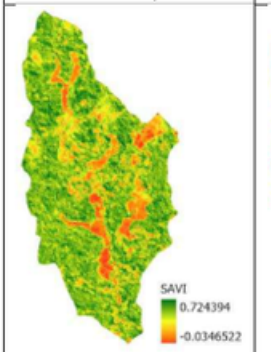		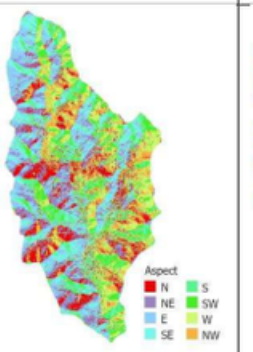	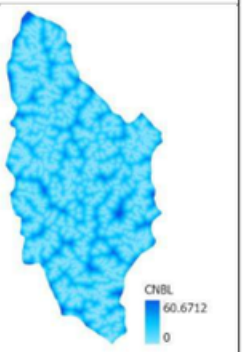
Kovariat O (SAVI)	Kovariat O (Penggunaan Lahan)	Kovariat R (Aspect)	Kovariat R (CNBL)
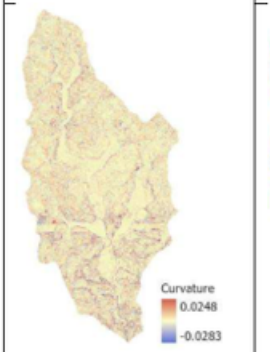	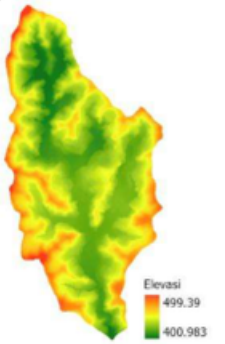	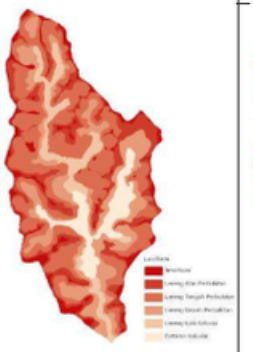	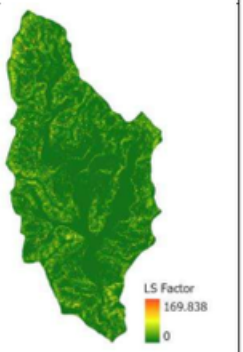
Kovariat R (Curvature)	Kovariat R (Elevasi)	Kovariat R (Landform)	Kovariat R (LS Factor)

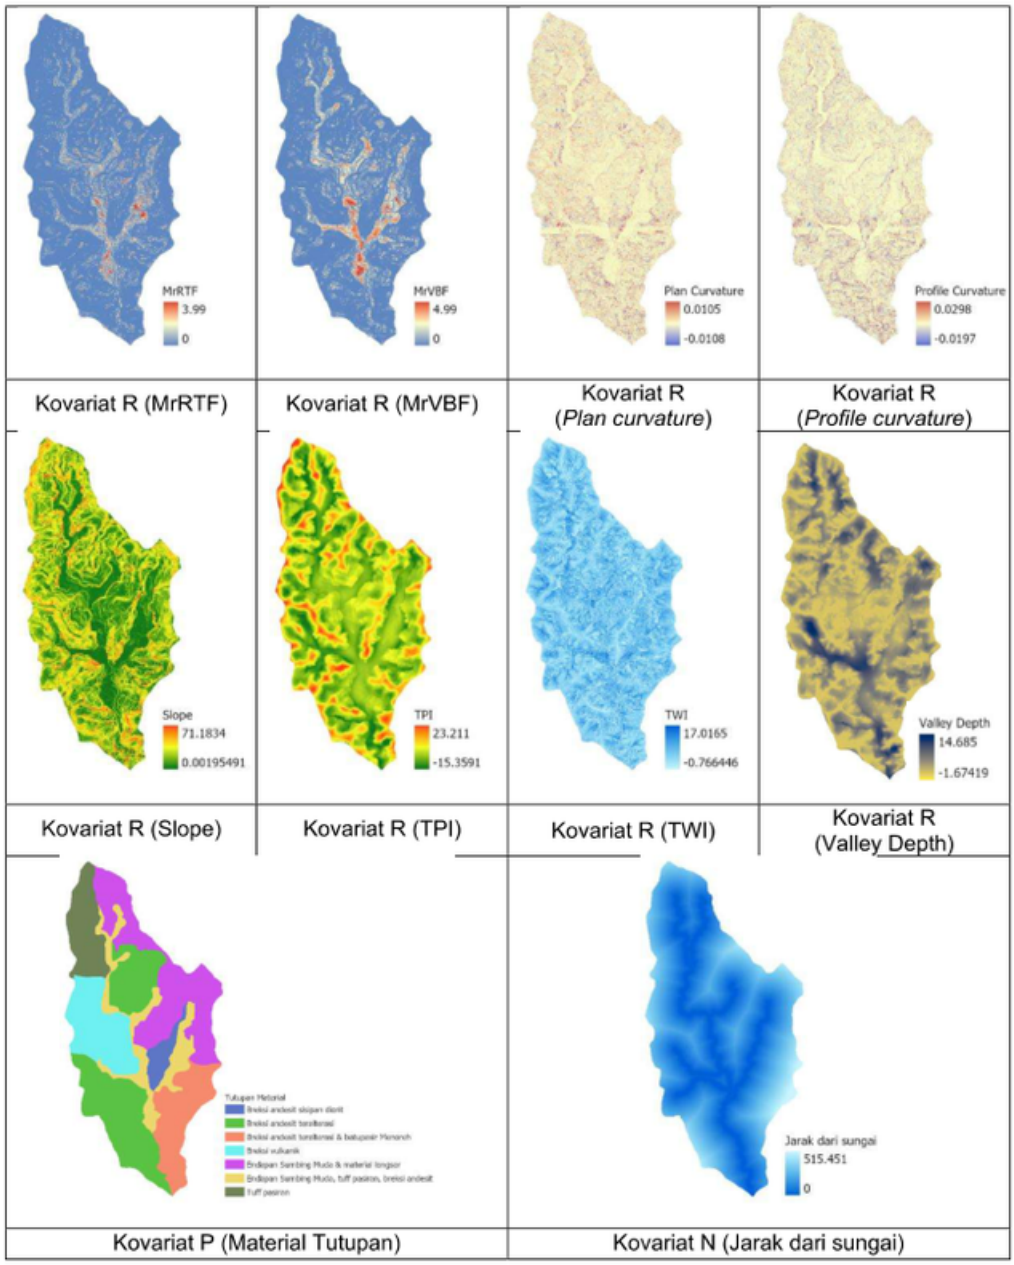

3.4.2. Uji Akurasi dan Validasi

Terdapat 6 model yang menjadi hasil akhir pengolahan, yaitu prediksi distribusi fraksi lempung, debu, dan pasir pada Lapisan 1 cm serta prediksi distribusi fraksi lempung, debu, dan pasir pada Lapisan 2. Setiap model dikalibrasi dengan *leave-one-out cross-validation* untuk mengevaluasi model *machine learning*. Akurasi pemodelan diukur menggunakan koefisien determinasi (R^2), *Root Mean Square Error* (RMSE) dan *Mean Absolute Error* (MAE).

3.5. Diagram Alir Penelitian

Gambar 3.3. Diagram alir penelitian

BAB IV HASIL DAN PEMBAHASAN

4.1. Statistik Deskriptif Fraksi Tekstur Tanah Berdasarkan Data Observasi

Hasil statistik deskriptif berdasarkan data observasi menunjukkan bahwa fraksi lempung mendominasi komposisi tanah di wilayah Sub-DAS Bompon dengan nilai rata-rata sebesar 62,48% pada Lapisan 1 dan mengalami peningkatan menjadi 64,78% pada Lapisan 2. Kandungan lempung yang tinggi sesuai dengan karakteristik Sub-DAS Bompon yang berada di zona vulkanik transisional dengan perkembangan tanah yang kompleks (Sambodo & Arpornthip, 2021). Material penyusun Sub-DAS Bompon dipengaruhi oleh abu vulkanik yang berasal dari Gunung Sumbing dan material breksi andesit teralteasi (Malik, 2017). Breksi andesit teralterasi berpengaruh terhadap pembentukan material lempung dan tanah yang tebal (Wida et al., 2019)

Fraksi pasir menunjukkan tingkat keragaman yang paling tinggi dengan nilai koefisien variasi (CV) sebesar 41,42% pada Lapisan 1 dan 46,68% pada Lapisan 2. Nilai CV yang tinggi lebih dari 35% menunjukkan bahwa distribusi pasir di Sub-DAS Bompon sangat heterogen secara spasial. Perbedaan variablitas dipengaruhi oleh proses geomorfologi dan topografi pada lanskap (Unamunzaga et al., 2014). Penelitian Karchegani et al. (2011) menjelaskan bahwa variasi tinggi distribusi fraksi tanah pada kedalaman 0-30 cm terdapat di daerah perbukitan dengan penggunaan lahan yang berbeda yaitu hutan dan lahan pertanian. Variasi tersebut dipengaruhi oleh proses redistribusi material tanah di sepanjang lereng bukit sehingga ditribusi fraksi tanah tidak merata.

Tabel 4.1. Statistik Fraksi Tanah Berdasarkan Data Observasi

Fraksi (%)	Lapisan	Min	Max	Mean	STD	CV
Pasir	1	6,49	33,67	16,43	6,81	41,42
	2	5,94	32,5	15,68	7,32	46,68
Debu	1	10,77	41,8	21,09	6,56	31,10
	2	10,02	37,81	19,54	6,14	31,44
Lempung	1	38,97	82,73	62,48	9,82	15,72
	2	44,49	82,24	64,78	10,32	15,93

Fraksi pasir pada Lapisan 1 memiliki nilai minimum 6,49% dan maksimum 33,67%, dengan nilai rata-rata 16,43%. Pada Lapisan 2, nilai minimum 5,94% dan maksimum 32,5% dengan nilai rata-rata sebesar 15,68%. Fraksi debu pada Lapisan 1 memiliki nilai minimum 10,77% dan maksimum 41,8%, dengan nilai rata-rata 21.09%. Pada Lapisan 2, nilai minimum 10,02% dan maksimum 37,81% dengan nilai rata-rata sebesar 19.54%. Fraksi lempung pada Lapisan 1 memiliki nilai minimum 38,97% dan maksimum 82,73%, dengan nilai rata-rata 62,48%. Pada Lapisan 2, nilai

minimum 44.49% dan maksimum 82,24% dengan nilai rata-rata sebesar 64,78%. Koefisien variasi fraksi pasir pada Lapisan 2 (46,68%) lebih tinggi dibandingkan dengan Lapisan 1 (41,42%).

Nilai minimum, maksimum, dan rata-rata pada fraksi pasir dan debu lebih tinggi pada Lapisan 1, sedangkan pada fraksi lempung nilai minimum, maksimum, dan rata-rata lebih tinggi pada Lapisan 2. Pola tersebut menunjukkan adanya proses pelindian partikel halus dari lapisan atas dan terjadi pengendapan pada lapisan bawah. Partikel halus yang terakumulasi pada lapisan bawah mengakibatkan peningkatan kandungan lempung (Priyono, 2012). Dominasi fraksi lempung pada sebagian besar sampel menyebabkan distribusi data tidak merata antar fraksi tekstur, sehingga berpotensi menghasilkan ketidakseimbangan data (data imbalance). Dalam proses pemodelan dapat memengaruhi performa model *machine learning* dan membutuhkan penanganan khusus sebelum pemodelan.

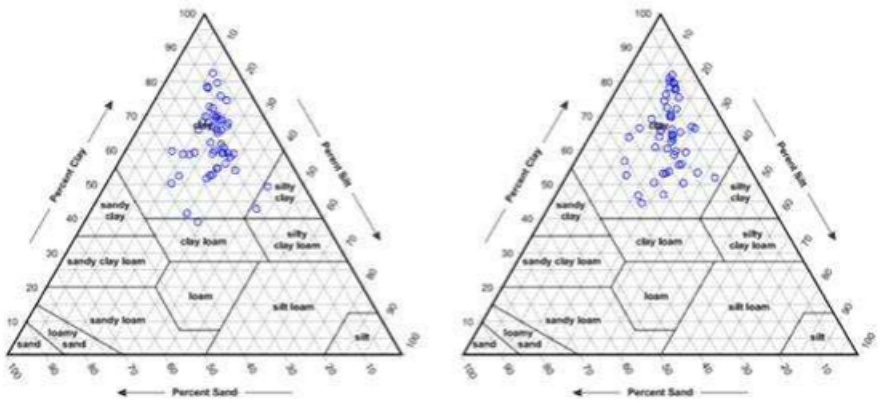

Gambar 4.1. Distribusi Data Observasi Fraksi Tekstur Tanah Lapisan 1 (Kiri) dan Lapisan 2 (Kanan) pada Segitiga Tekstur USDA

Ketidakseimbangan data teramati pada sebaran 50 titik sampel dalam segitiga tekstur USDA yang disajikan pada Gambar 4.1. Kelas tekstur tanah pada Lapisan 1 didominasi oleh kelas lempung (*clay*) dengan satu sampel pada kelas geluh lempungan (*clay* loam) dan dua sampel pada kelas lempung debuan (*silty clay*). Sedangkan, keseluruhan sampel pada Lapisan 2 memiliki kelas lempung (*clay*). Sebagian besar sampel terkonsentrasi pada kandungan lempung yang tinggi (38,97–82,73%). Kondisi tersebut berpotensi memengaruhi kinerja algoritma *machine learning* dalam mengenali pola pada kelas atau nilai minoritas, model dapat menjadi bias terhadap kelas mayoritas (Trotta, 2024).

4.2. Sifat Fisik dan Kimia Tanah di Sub-DAS Bompon

Sifat fisik dan kimia tanah merupakan indikator penting kondisi dan kualitas tanah yang dipengaruhi oleh interaksi faktor pembentuk serta proses pedogenesis. Pada Sub-DAS Bompon yang berkembang dari material vulkanik dan teralterasi, dominasi fraksi lempung diduga memengaruhi karakteristik fisik dan kimia tanah. Oleh karena itu, analisis sifat tanah diperlukan untuk memahami keterkaitannya dengan distribusi fraksi tekstur di wilayah penelitian.

Tabel 4. 2. Statistik Data Sifat Fisik dan Kimia Tanah

Sifat Tanah	Lapisan	Min	Max	Mean	STD	CV
pH	1	4,45	6,47	5,20	0,36	6,97
	2	4,49	6,11	5,23	0,35	6,71
KPK (cmol(+)/kg)	1	4,01	16,45	8,99	2,46	27,43
	2	3,81	14,85	9,22	2,42	26,21
C-Organik (%)	1	0,08	2,26	1,13	0,43	38,02
	2	0,16	1,56	0,92	0,32	34,62
BV (g/cm^3)	1	0,56	1,11	0,94	0,11	12,04
	2	0,69	1,18	0,92	0,12	12,55
Kadar Lengas (%)	1	11,73	35,4	22,90	4,81	20,99
	2	11,65	34,4	23,03	4,90	21,27

Distribusi pH tanah di Sub-DAS Bompon cenderung asam dengan nilai pH tanah berkisar antara 4,45 hingga 6,47. Tingkat keasaman tanah dipengaruhi oleh kondisi iklim dan dan kandungan mineral bahan induk. Tanah pada daerah vulkanik dengan intensitas curah hujan tinggi umumnya menunjukkan kondisi tanah yang masam (Navia et al., 2005). Sub-DAS Bompon memiliki curah hujan yang tinggi serta bahan induk berasal dari material vulkanik Gunung Sumbing yang kaya akan besi (Fe). Pelapukan mineral yang dipercepat oleh curah hujan tinggi menyebabkan terjadinya oksidasi besi dan pelepasan ion Fe^{3+} ke dalam tanah sehingga menurunkan nilai pH tanah (Sambodo & Arpornthip, 2021).

Nilai KPK berkisar antara 3,81 hingga 14.85 cmol(+)/kg yang tergolong rendah hingga sedang. Pertukaran kation dalam tanah dipengaruhi oleh bahan organik dan kandungan lempung pada tanah, penurunan kandungan fraksi lempung dapat menyebabkan rendahnya nilai KPK (Adzima et al., 2019; Capra et al., 2012). Kandungan lempung yang tinggi pada umumnya meningkatkan nilai KPK, namun pada Sub-DAS Bompon nilai KPK tergolong rendah hingga sedang. Kondisi tersebut menunjukkan bahwa nilai KPK tidak hanya ditentukan oleh kandungan fraksi lempung, tetapi juga oleh karakteristik mineralogi lempung penyusun tanah.

Mineralogi lempung di Sub-DAS Bompon dipengaruhi oleh proses alterasi dan pelapukan lanjut material vulkanik. Proses alterasi hidrotermal berperan dalam

pembentukan mineral lempung sekunder, sehingga komposisi mineral tanah didominasi oleh kaolinit (Adzima et al., 2019). Penelitian Purwaningsih et al. (2025) menunjukkan bahwa pada bentang alam transisi vulkanik Menoreh-Sumbing didominasi oleh mineral pelapukan sekunder berupa kaolinit dan kuarsa pada lapisan bawah tanah. Temuan tersebut menunjukkan bahwa proses pelapukan intensif menghasilkan mineral lempung beraktivitas rendah yang berpengaruh terhadap nilai KPK tanah.

Kandungan C-organik pada Lapisan 1 berkisar antara 0,08–2,26% dengan rata-rata 1,13%, kemudian menurun pada Lapisan 2 menjadi 0,16–1,56% dengan rata-rata 0,92%. Penurunan C-organik pada lapisan bawah menunjukkan bahwa akumulasi bahan organik lebih terkonsentrasi di permukaan akibat masukan seresah dan aktivitas vegetasi. Nilai BV relatif rendah pada kedua lapisan, dengan rata-rata 0,94 g cm^{-3} pada Lapisan 1 dan 0,92 g cm^{-3} pada Lapisan 2. Kondisi tersebut dapat dipengaruhi oleh dominasi fraksi lempung di wilayah penelitian, tanah bertekstur halus umumnya memiliki BV lebih rendah dibandingkan tanah berpasir. Kadar lengas menunjukkan rata-rata yang relatif tinggi dan hampir sama pada kedua lapisan, yaitu 22,90% pada Lapisan 1 dan 23,03% pada Lapisan 2. Tingginya kadar lengas sejalan dengan dominasi fraksi lempung, tanah bertekstur halus memiliki luas permukaan spesifik dan proporsi pori mikro yang lebih besar sehingga mampu menahan air lebih kuat dibandingkan fraksi pasir (Clark, 2020).

4.3. Statistik Deskriptif Prediksi Fraksi Tekstur Tanah

Hasil prediksi menunjukkan bahwa fraksi lempung memiliki nilai rata-rata tertinggi dibandingkan fraksi pasir dan debu pada kedua kedalaman tanah. Nilai rata-rata fraksi lempung sebesar 62,29% pada Lapisan 1 dan meningkat menjadi 65,54% pada Lapisan 2. Sedangkan, fraksi pasir memiliki nilai rata-rata sebesar 16,50% dan 15,20%, sedangkan fraksi debu memiliki nilai rata-rata sebesar 20,85% dan 19,23%. Nilai tersebut menunjukkan bahwa hasil prediksi tetap mempertahankan dominasi fraksi lempung sebagaimana ditunjukkan oleh data observasi.

Tabel 4. 3. Statistik Prediksi Fraksi Tanah

Fraksi (%)	Lapisan	Min	Max	Mean	STD	CV
Pasir	1	7,05	33,67	16,5	2,84	17,21
	2	7,15	30,03	15,2	2,46	16,18
Debu	1	12,23	40,39	20,85	1,76	8,44
	2	10,09	36,52	19,23	2,64	13,73
Lempung	1	39,4	80,92	62,29	4,89	7,85
	2	44,82	81,74	65,54	4,15	6,33

Nilai simpangan baku (STD) dan koefisien variasi (CV) hasil prediksi lebih rendah dibandingkan data observasi pada seluruh fraksi tekstur. Nilai tersebut menunjukkan bahwa distribusi data prediksi menjadi lebih homogen. Kondisi tersebut diakibatkan oleh *smoothing of distribution tails*, yaitu kecenderungan model mengurangi nilai-nilai ekstrem dengan memprediksi nilai rendah menjadi lebih tinggi dan nilai tinggi menjadi lebih rendah (Nussbaum et al., 2023). Sehingga, distribusi hasil prediksi menjadi lebih kontinu dibandingkan data observasi dengan tetap mempertahankan pola distribusi utama.

Histogram pada Gambar 4.2. menunjukkan bahwa distribusi hasil prediksi ketiga fraksi tekstur membentuk pola unimodal dengan puncak distribusi yang jelas pada masing-masing fraksi. Pada Lapisan 2, distribusi fraksi lempung bergeser ke arah nilai yang lebih tinggi, sedangkan distribusi fraksi pasir dan debu bergeser ke arah nilai yang lebih rendah dibandingkan Lapisan 1. Sebaran histogram yang relatif sempit menunjukkan bahwa sebagian besar piksel memiliki nilai prediksi yang mendekati rata-rata dan menghasilkan model distribusi prediksi yang lebih homogen. Distribusi yang terpisah antar fraksi juga menunjukkan bahwa model mampu mempertahankan proporsi setiap fraksi tekstur tanpa menghasilkan tumpang tindih yang berlebihan.

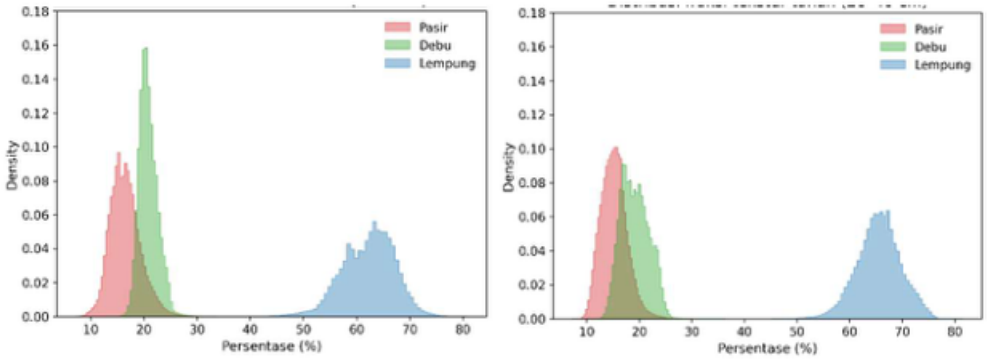

Gambar 4.2. Histogram densitas distribusi fraksi pasir, debu, dan lempung pada Lapisan 1 dan Lapisan 2

Segitiga tekstur USDA berbasis kepadatan distribusi hasil prediksi pada Gambar 4.3. menunjukkan bahwa kedua kedalaman terkonsentrasi pada kelas tekstur *clay*. Kepadatan tertinggi berada pada kisaran kandungan lempung sekitar 60–70%, pasir 12–18%, dan debu 18–24%. Kepadatan yang terkonsentrasi pada satu kelas tekstur menunjukkan bahwa sebagian besar wilayah penelitian memiliki karakteristik tekstur yang relatif seragam. Pola tersebut konsisten dengan kondisi Sub-DAS Bompon yang

berkembang dari material vulkanik teralterasi, sehingga menghasilkan tanah yang didominasi oleh kandungan lempung tinggi.

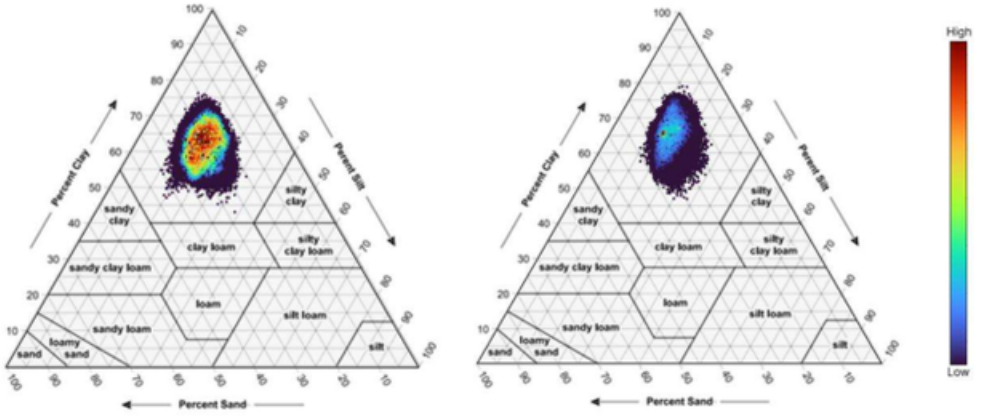

Gambar 4.3. Distribusi Data Prediksi Fraksi Tekstur Tanah Lapisan 1 (Kiri) dan Lapisan 2 (Kanan) pada Segitiga Tekstur USDA

4.4. Kinerja Model Prediksi Fraksi Tekstur Tanah

Kinerja model yang dihasilkan oleh algoritma dievaluasi menggunakan *leave-one-out cross-validation*. Tabel 4.4. membandingkan hasil uji akurasi untuk empat algoritma yang berbeda tanpa resampling data atau menggunakan dataset asli. Sedangkan, Tabel 4.5. membandingkan hasil uji akurasi untuk empat algoritma yang berbeda dengan resampling data SMOGN. Tingkat akurasi yang lebih tinggi ditunjukkan oleh nilai koefisien determinasi (R^2) yang lebih tinggi serta nilai RMSE dan MAE yang relatif rendah. Sedangkan, algoritma QRF merupakan model dengan performa terendah.

Tabel 4.4. Kinerja Model RF, QRF, Catboost, dan Stacking dengan Dataset Asli

Fraksi	Lapisan	RF			QRF			Catboost			Stacking		
		R^2	RMSE	MAE	R^2	RMSE	MAE	R^2	RMSE	MAE	R^2	RMSE	MAE
Pasir 1	1	-0,03	6,846	4,990	0,03	6,624	4,629	0,04	6,590	4,758	**0,081***	6,460	4,963
	2	-0,04	7,374	5,965	-0,13	7,699	6,029	-0,01	7,252	5,949	**0,082***	6,940	5,736
Debu	1	-0,08	6,755	5,184	-0,32	7,448	5,795	-0,15	6,956	5,202	**0,159***	5,954	4,570
	2	0,08	5,847	4,493	-0,12	6,425	4,701	0,08	5,847	4,309	**0,125***	5,690	4,548
Lempung	1	-0,03	9,856	7,746	-0,05	9,968	7,608	-0,06	10,020	7,742	**0,098***	9,238	7,246
	2	0,05	9,970	8,249	-0,06	10,524	8,608	0,05	9,972	8,413	**0,184***	9,224	7,590

Keterangan: Tanda (*) menunjukkan model terbaik berdasarkan nilai koefisien determinasi (R^2) tertinggi dengan mempertimbangkan RMSE dan MAE

Tabel 4.5. Kinerja Model RF, QRF, Catboost, dan Stacking dengan Resampling SMOGN

Fraksi	Lapisan	RF			QRF			Catboost			Stacking		
		R^2	RMSE	MAE	R^2	RMSE	MAE	R^2	RMSE	MAE	R^2	RMSE	MAE
Pasir	1	-0,03	6,829	5,046	-0,06	6,944	5,186	0,11	6,365	4,461	**0,249***	5,840	4,660
	2	0,01	7,232	5,928	-0,01	7,278	5,911	-0,11	7,633	6,255	**0,124***	6,780	5,330
Debu	1	-0,04	6,630	5,245	-0,32	7,473	5,865	-0,04	6,618	5,017	**0,196***	5,820	4,630
	2	0,08	5,834	4,478	-0,14	6,496	4,941	0,03	5,974	4,408	**0,137***	5,810	4,590
Lempung	1	0,01	9,672	7,627	-0,02	9,809	7,337	0,04	9,546	7,344	**0,099***	9,230	7,130
	2	-0,03	10,356	8,434	-0,09	10,649	8,942	0,02	10,106	8,348	**0,093***	9,730	7,920

Keterangan: Tanda (*) menunjukkan model terbaik berdasarkan nilai koefisien determinasi (R^2) tertinggi dengan mempertimbangkan RMSE dan MAE

Model Stacking menunjukkan kinerja terbaik dalam memprediksi fraksi tekstur tanah, baik pada pemodelan tanpa SMOGN maupun dengan SMOGN. Hasil tersebut sejalan dengan penelitian Liu et al. (2026) yang menjelaskan bahwa algoritma ensemble learning dapat meningkatkan kerja model, terutama pada Stacking menunjukkan peningkatan yang paling signifikan dalam prediksi tekstur tanah. Stacking memiliki nilai R^2 tertinggi pada seluruh fraksi tekstur dibandingkan Random Forest, Quantile Random Forest, dan CatBoost. Nilai R^2 berkisar antara 0,081–0,184, nilai RMSE berkisar antara 5,690–9,238, sedangkan MAE berkisar antara 4,548–7,590. Kinerja tertinggi berdasarkan nilai R^2 terdapat pada prediksi fraksi lempung Lapisan 2 sebesar 0,184, diikuti fraksi debu Lapisan 1 sebesar 0,159, sedangkan nilai R^2 terendah terdapat pada fraksi pasir Lapisan 1 sebesar 0,081. Nilai tersebut menunjukkan bahwa akurasi prediksi lebih tinggi pada lapisan permukaan dibandingkan pada lapisan bawah dikarenakan kovariat yang digunakan cenderung lebih representatif terhadap kondisi permukaan tanah. Prediksi lapisan bawah tanah dipengaruhi oleh kedalaman sampel yang terbatas dan sensitivitas kovariat yang lebih rendah, seperti faktor relief yang menjadi kovariat utama pengontrol prediksi (Turgut & Koca, 2026)

Setelah penerapan SMOGN, nilai R^2 model Stacking berkisar antara 0,093–0,249, dengan RMSE sebesar 5,810–9,730 dan MAE sebesar 4,590–7,920. Nilai R^2 tertinggi terdapat pada fraksi pasir Lapisan 1 sebesar 0,249, diikuti fraksi debu Lapisan 1 sebesar 0,196, sedangkan nilai terendah terdapat pada fraksi lempung Lapisan 2 sebesar 0,093. Model Stacking mengalami peningkatan kinerja, terutama pada fraksi pasir dan debu. Fraksi pasir mengalami peningkatan R^2 sebesar 0.168 pada Lapisan 1 dan 0.042 pada Lapisan 2, fraksi debu mengalami peningkatan sebesar 0.037 pada Lapisan 1 dan 0.012 pada Lapisan 2. Sedangkan, peningkatan kinerja fraksi lempung relatif kecil pada Lapisan 1, yaitu hanya sebesar 0,001. Sebaliknya, Lapisan 2 pada fraksi lempung mengalami penurunan performa sebesar -0.091. Perbedaan tersebut menunjukkan bahwa efektivitas penerapan SMOGN tergantung pada karakteristik distribusi setiap data.

Peningkatan kinerja setelah penerapan SMOGN menunjukkan bahwa teknik resampling mampu mengurangi pengaruh ketidakseimbangan data regresi (*imbalanced regression*). Dengan menghasilkan nilai-nilai perantara untuk mengisi bagian data yang kurang terwakili, SMOGN mampu meningkatkan akurasi prediksi dalam dataset yang tidak seimbang.(Cesmeli, 2025). Pemodelan dengan resampling menggunakan SMOGN menunjukkan adanya peningkatan nilai R^2 terutama pada fraksi pasir dan debu yang merupakan data minoritas (Chattaraj et al., 2025a).

Algoritma Stacking dengan SMOGN dipilih sebagai model terbaik karena memiliki kinerja model yang tertinggi pada sebagian besar fraksi tekstur. Oleh karena itu, model tersebut digunakan untuk analisis tingkat kepentingan variabel serta pemetaan distribusi spasial fraksi tekstur tanah pada subbab berikutnya. Meskipun penerapan Stacking dengan SMOGN mampu meningkatkan kinerja prediksi, kemampuan model secara keseluruhan masih relatif rendah, dengan nilai R^2 tertinggi sebesar 0,249.

Rendahnya kinerja prediksi berkaitan dengan karakteristik bahan induk teralterasi yang didominasi oleh kandungan lempung tinggi dan variasi relatif rendah. Kondisi tersebut menyebabkan perbedaan komposisi fraksi tekstur tanah antar lokasi kurang kontras, sehingga hubungan antara variasi fraksi tekstur tanah dan kovariat lingkungan sulit diidentifikasi secara optimal oleh model. Selain itu, jumlah sampel yang terbatas dapat mengurangi kemampuan model dalam menangkap keragaman hubungan tanah dan lingkungan. Pada dataset berukuran kecil, jumlah sampel yang sedikit untuk membangun model dapat menurunkan kinerja prediksi, sehingga penerapan model pada kondisi sampel terbatas perlu dilakukan secara hati-hati. (Moura-Bueno et al., 2019)

4.5. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Tekstur Tanah

Penelitian ini menerapkan *Recursive Feature Elimination* (RFE) sebagai metode seleksi fitur untuk mengevaluasi tingkat kepentingan setiap kovariat lingkungan dalam memprediksi fraksi tekstur tanah. RFE memberikan peringkat pada setiap kovariat berdasarkan tingkat kepentingannya, kemudian menghapus kovariat dengan peringkat terendah hingga diperoleh subset fitur yang optimal (Chattaraj et al., 2025a). Pendekatan RFE mampu mengurangi kompleksitas model, meminimalkan risiko *overfitting*, serta mempertahankan kovariat yang memiliki kontribusi terbesar terhadap prediksi.

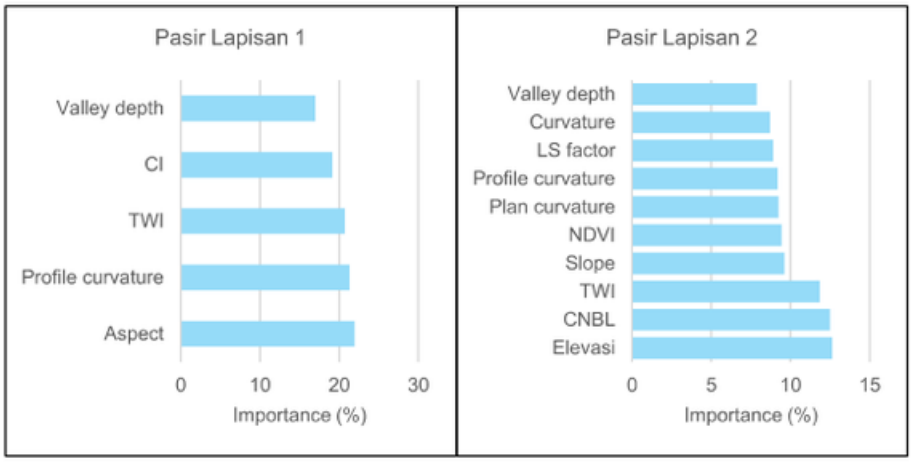

Gambar 4.4. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Pasir Lapisan 1 dan 2

Pada fraksi pasir Lapisan 1 terdapat 5 variabel yang digunakan dengan tingkat kepentingan terbesar berturut-turut adalah aspect (21,92%), *profile curvature* (21,29%), TWI (20,70%), CI (19,13%), dan valley depth (16,96%). Distribusi fraksi pasir pada lapisan permukaan terutama dikendalikan oleh aspect atau arah hadap lereng. Arah hadap lereng (*aspect*) umumnya memberikan pengaruh yang lebih besar terhadap intensitas peyinaran matahari pada wilayah lintang tinggi (Sartohadi et al., 2022). Namun, pada wilayah tropis seperti Sub-DAS Bompon, *aspect* tetap memengaruhi variasi mikroklimat, kelembapan tanah, evapotranspirasi, dan perkembangan vegetasi. TWI dapat digunakan untuk memetakan daerah pengendapan dan untuk mengidentifikasi daerah akumulasi air yang berperan dalam redistribusi partikel tanah (Ågren et al., 2014; Kaya et al., 2022).

Terdapat 10 variabel yang digunakan pada prediksi fraksi pasir Lapisan 2 dengan tingkat kepentingan terbesar berturut-turut adalah elevasi (12,65%), CNBL (12,50%), TWI (11,84%), slope (9,62%), NDVI (9,44%), *plan curvature* (9,26%), *profile curvature* (9,20%), LS factor (8,91%), curvature (8,71%), dan valley depth (7,88%). Sejumlah penelitian menunjukkan bahwa elevasi merupakan salah satu kovariat penting dalam memprediksi distribusi fraksi tekstur tanah (Cremon et al., 2021; Sulaiman et al., 2024). NDVI berkorelasi dengan biomassa, kandungan klorofil, dan kelembapan vegetasi, sehingga secara tidak langsung berkaitan dengan tekstur tanah (Dindaroğlu et al., 2022; Loiseau et al., 2019)

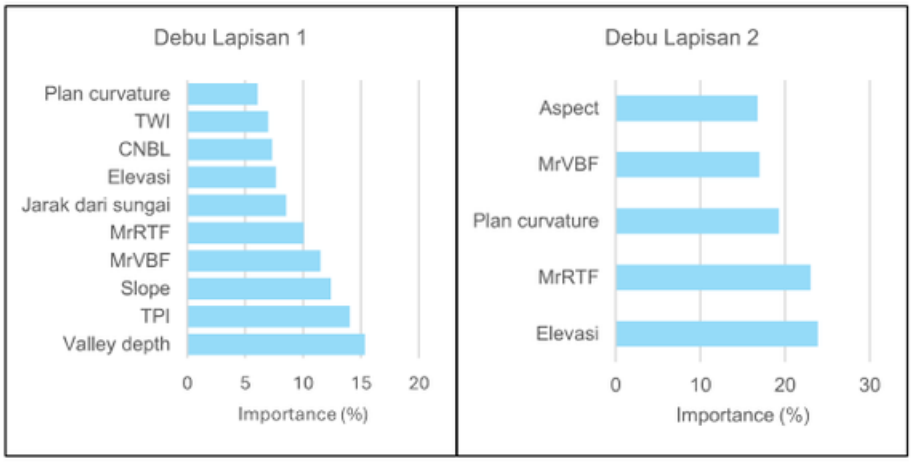

Gambar 4.5. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Debu Lapisan 1 dan 2

Hasil analisis variable importance menunjukkan bahwa distribusi fraksi debu pada Lapisan 1 dipengaruhi oleh sepuluh kovariat, yaitu valley depth (15,34%), TPI (14,03%), slope (12,11%), MrVBF (11,51%), MrRTF (10,07%), jarak dari sungai (8,55%), elevasi (7,68%), CNBL (7,35%), TWI (6,98%), dan *plan curvature* (6,09%). Valley depth merupakan indeks topografi yang menggambarkan jarak vertikal suatu lokasi terhadap tingkat dasar jaringan saluran lembah acuan (Skentos & Ourania, 2017). Pada Lapisan 2, prediksi fraksi debu dipengaruhi oleh lima kovariat utama, yaitu elevasi (23,90%), MrRTF (23,06%), *plan curvature* (19,28%), MrVBF (16,98%), dan aspect (15,78%). Elevasi merupakan data utama untuk menghasilkan turunan atribut topografi yang digunakan sebagai kovariat, sehingga elevasi merupakan kovariat yang penting (Cremon et al., 2021)

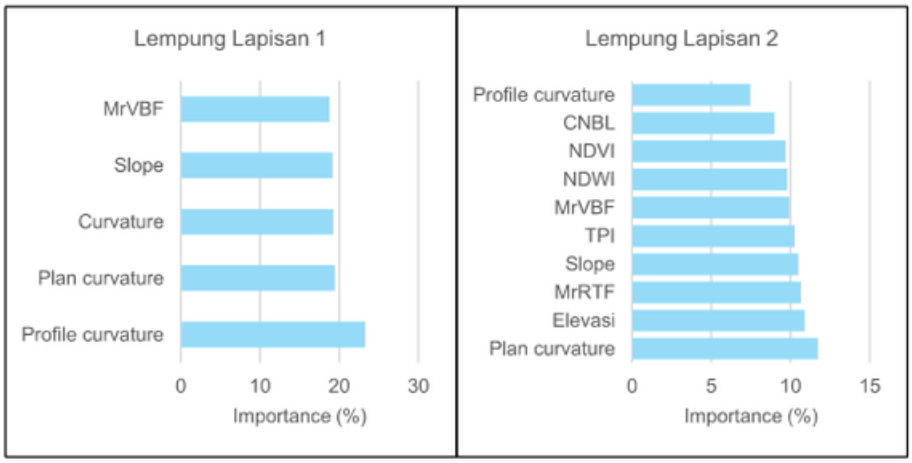

Gambar 4. 6. Tingkat Kepentingan Variabel dalam Prediksi Fraksi Lempung Lapisan 1 dan 2

Hasil analisis *variable importance* menunjukkan bahwa prediksi fraksi lempung pada lapisan 0–20 cm dipengaruhi oleh lima kovariat utama *profile curvature* (23,32%), diikuti oleh *plan curvature* (19,45%), curvature (19,25%), slope (19,19%), dan MrVBF (18,80%). Pada Lapisan 20–40 cm, prediksi fraksi lempung dipengaruhi oleh *plan curvature* (11,74%), elevasi (10,90%), MrRTF (10,68%), slope (10,51%), TPI (10,26%), MrVBF (9,97%), NDWI (9,80%), NDVI (9,69%), CNBL (8,99%), dan *profile curvature* (7,48%). Curvature mengontrol pergerakan air serta material halus pada bentanglahan. Slope, curvature, dan aspect berpengaruh terhadap sifat tanah, proses erosi, dan distribus material serta serasah daun (Rhoton & Duiker, 2008; Mashalaba et al., 2020). Curvature menggambarkan konvergensi dan divergensi topografi serta aliran air di dekat permukaan (Goetz et al., 2011). *Plan curvature* dan *profile curvature* berpengaruh terhadap redistribusi fraksi tekstur pada bentanglahan.

Secara keseluruhan, analisis *variable importance* menunjukkan bahwa kovariat dengan tingkat kepentingan tertinggi berasal dari faktor relief (R), sehingga mengindikasikan bahwa kondisi topografi merupakan pengontrol utama distribusi fraksi tekstur tanah di Sub-DAS Bompon. Relief merupakan faktor pengendali utama distribusi sifat tanah karena memengaruhi distribusi dan akumulasi air dan energi serta transportasi sedimen (Kaya et al., 2022). Pada tahun 1964-2003 terdapat setidaknya 70 penelitian terkait DSM, sebanyak 80% penelitian menggunakan faktor prediktor utama berupa relief (McBratney et al., 2003).

4.6. Analisis Distribusi Spasial Prediski Fraksi Tekstur Tanah

Analisis distribusi spasial dilakukan untuk mengidentifikasi pola sebaran hasil prediksi fraksi pasir, debu, dan lempung pada Lapisan 1 dan 2 di Sub-DAS Bompon. Analisis dilakukan untuk menjelaskan keterkaitan antara pola sebaran hasil prediksi dengan faktor lingkungan yang berkontribusi terhadap variasi spasial fraksi tekstur tanah berdasarkan hasil analisis *variable importance*. Selain itu, analisis lebih lanjut dilakukan berdasarkan landform, material tutupan, dan penggunaan lahan.

Peta distribusi spasial prediksi fraksi pasir Lapisan 1 disajikan pada Gambar 4.7. Berdasarkan peta prediksi, fraksi pasir Lapisan 1 menunjukkan pola spasial yang heterogen dengan dominasi kandungan pasir sebesar 10-20%. Kandungan pasir yang rendah (<10%) tersebar secara lokal, sedangkan kandungan pasir yang lebih tinggi (>20%) tersebar pada bagian tengah sub-DAS yang merupakan bagian dataran koluvial dengan material tutupan breksi vulkanik dan penggunaan lahan berupa sawah.

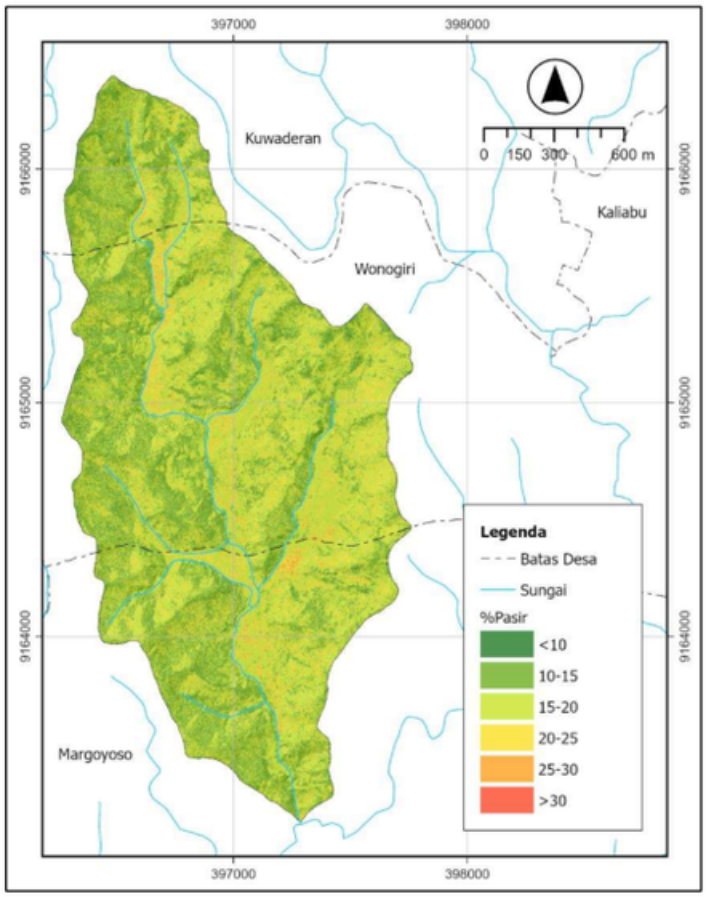

Gambar 4.7. Peta Distribusi Spasial Prediksi Fraksi Pasir Lapisan 1

Pola distribusi pasir mengikuti sebaran aspect yang merupakan kovariat dengan tingkat kepentingan tertinggi (21,92%). Hasil analisis menunjukkan adanya perbedaan kandungan pasir berdasarkan arah hadap lereng, yaitu lereng yang menghadap timur didominasi kandungan pasir 10–15%, lereng yang menghadap utara didominasi kandungan pasir 15–20%, lereng yang menghadap didominasi kandungan pasir selatan 20–25%, sedangkan kandungan pasir >25% terdapat di lereng yang menghadap barat. Lereng yang menghadap ke utara mengalami peningkatan variabilitas iklim mikro tanah secara temporal dibandingkan dengan lereng yang menghadap ke selatan (Fan et al., 2020). Sementara itu, lereng bagian selatan dan barat lebih hangat dengan tingkat penguapan yang lebih tinggi dan kapasitas penyimpanan kelembaban yang lebih rendah sehingga lebih rentan terhadap limpasan dan pergerakan sedimen (Greve et al., 2012).

Kondisi arah hadap lereng menunjukkan kesesuaian spasial dengan hasil prediksi model, yaitu kandungan pasir prediksi cenderung lebih tinggi pada lereng

selatan dan barat. Peningkatan limpasan dan pergerakan sedimen pada lereng tersebut dapat mendorong redistribusi partikel tanah, terutama hilangnya fraksi yang lebih halus, sehingga dapat meningkatkan proporsi fraksi pasir yang tertinggal. Sebaliknya, kandungan pasir yang lebih rendah pada lereng timur dan utara dapat berkaitan dengan kondisi kelembaban yang lebih mendukung keberadaan dan retensi fraksi halus.

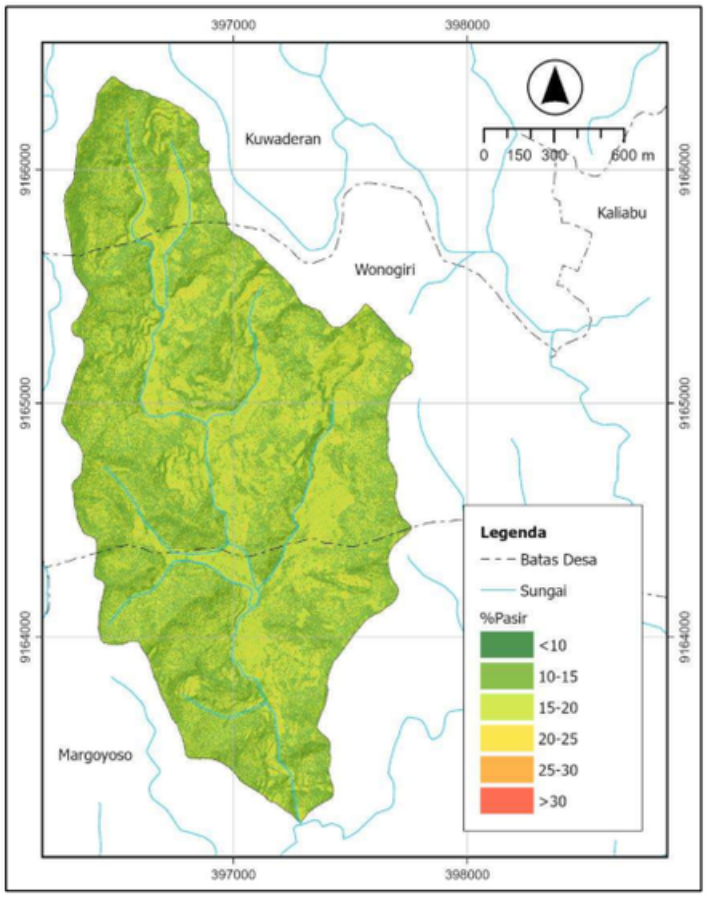

Gambar 4.8. Peta Distribusi Spasial Prediksi Fraksi Pasir Lapisan 2

Peta distribusi spasial prediksi fraksi pasir Lapisan 2 disajikan pada Gambar 4.8. Pada Lapisan 2, elevasi merupakan kovariat dengan tingkat kepentingan tertinggi dalam model prediksi fraksi pasir.. Sub-DAS Bompon memiliki elevasi berkisar antara 400,98 hingga 499,39 meter di atas permukaan laut. Wilayah dengan elevasi tinggi, yang terutama berada pada bagian tepi atau punggungan di barat, barat laut, sebagian timur, dan selatan, cenderung menunjukkan kandungan pasir yang lebih rendah, sekitar 10-15% pada beberapa lokasi. Sebaliknya, wilayah berelevasi lebih rendah, terutama pada zona lembah yang memanjang di bagian dalam dan tengah Sub-DAS, cenderung didominasi kandungan pasir yang lebih tinggi sekitar 15-20%.

Hal tersebut sejalan dengan penelitian (Greve et al., 2012) yang menjelaskan bahwa kandungan pasir di punggung lebih rendah dibandingkan lokasi di sekitarnya.

Berdasarkan peta prediksi, fraksi pasir Lapisan 2 didominasi oleh kandungan pasir sebesar 10-15% yang tersebar di daerah lereng perbukitan, material tutupan breksi andesit dan endapan material Sumbing, serta, penggunaan lahan dominan agroforestri. Bagian tengah sub-DAS yang merupakan bagian dataran koluvial dengan material tutupan breksi vulkanik dan penggunaan lahan berupa sawah didominasi oleh kandungan pasir sebesar 15-20%. Nilai tersebut menunjukkan bahwa kandungan pasir pada Lapisan 2 lebih rendah dibandingkan Lapisan 1.

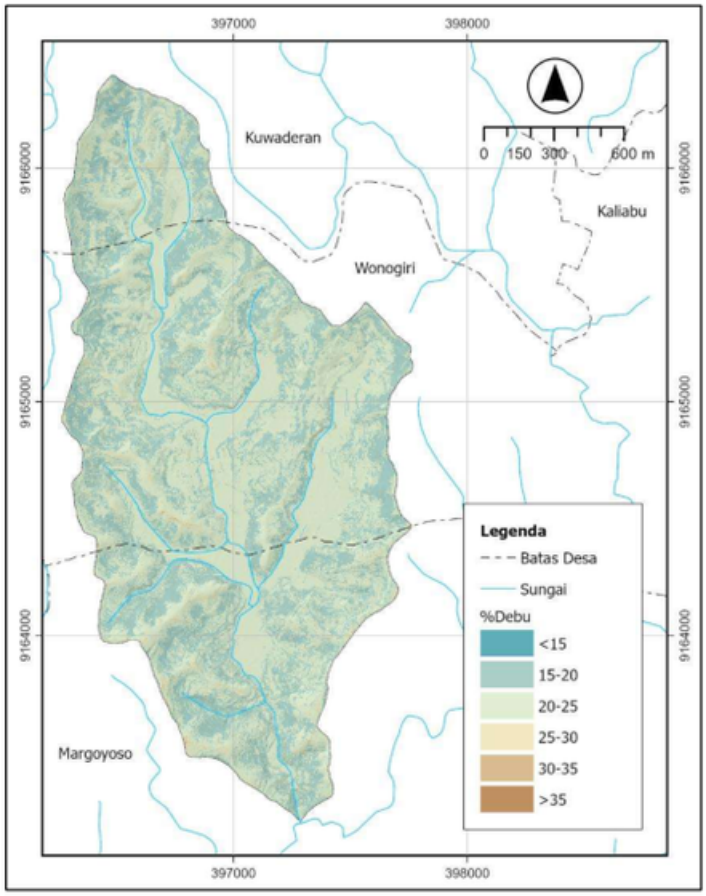

Gambar 4.9. Peta Distribusi Spasial Prediksi Fraksi Debu Lapisan 1

Peta distribusi spasial prediksi fraksi debu Lapisan 1 disajikan pada Gambar 4.9. Pada Lapisan 1, *valley depth* merupakan kovariat dengan tingkat kepentingan tertinggi dalam model prediksi fraksi debu. *Valley depth* menjadi faktor penting yang memengaruhi transportasi sedimen massal seperti tanah longsor (Pennell et al., 2026). Proses tersebut dapat menyebabkan perpindahan dan redistribusi material

tanah, termasuk fraksi debu, dari bagian lereng menuju posisi yang lebih rendah. Hasil prediksi menunjukkan bahwa kandungan debu yang lebih tinggi cenderung dijumpai pada area datar, baik pada puncak maupun lembah. Pada area puncak yang relatif datar, fraksi debu cenderung bertahan pada permukaan yang lebih stabil. Sementara itu, pada area lembah kandungan debu yang lebih tinggi berkaitan dengan akumulasi material halus hasil transportasi dari lereng.

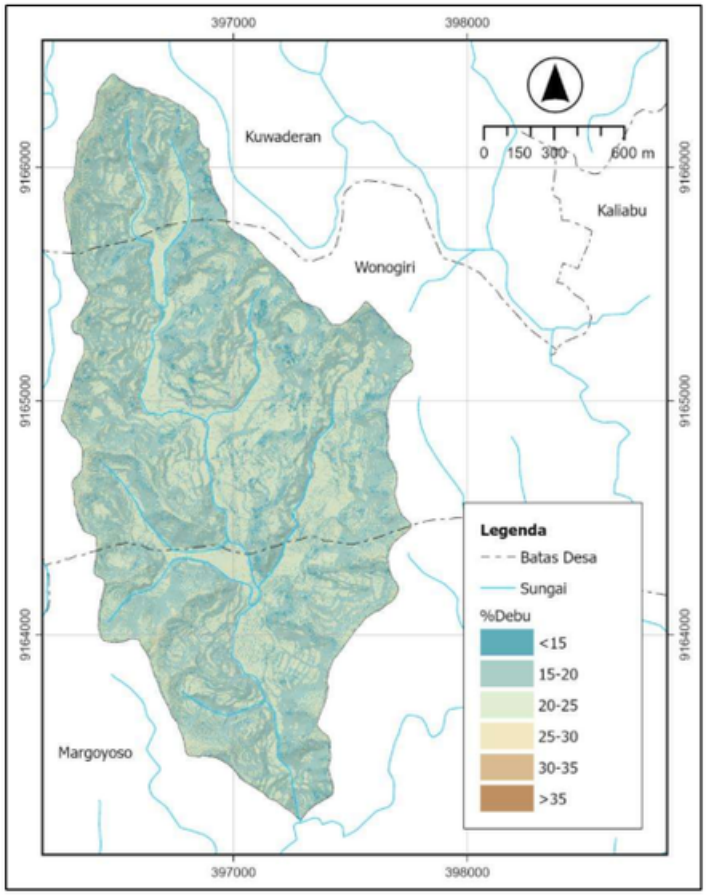

Gambar 4.10. Peta Distribusi Spasial Prediksi Fraksi Debu Lapisan 2

Peta distribusi spasial prediksi fraksi debu Lapisan 2 disajikan pada Gambar 4.10. Pada Lapisan 2, elevasi merupakan kovariat dengan tingkat kepentingan tertinggi dalam model prediksi fraksi debu. Berdasarkan perbandingan pola spasial, wilayah dengan elevasi lebih tinggi yang berada pada bagian punggungan cenderung memiliki kandungan debu relatif lebih rendah, sekitar 15–20%, sedangkan wilayah dengan elevasi lebih rendah pada bagian dalam Sub-DAS dan sepanjang zona lembah cenderung didominasi kandungan debu yang lebih tinggi, yaitu 20-25%. Pola

tersebut berkaitan dengan akumulasi material pada posisi bentanglahan berelevasi rendah.

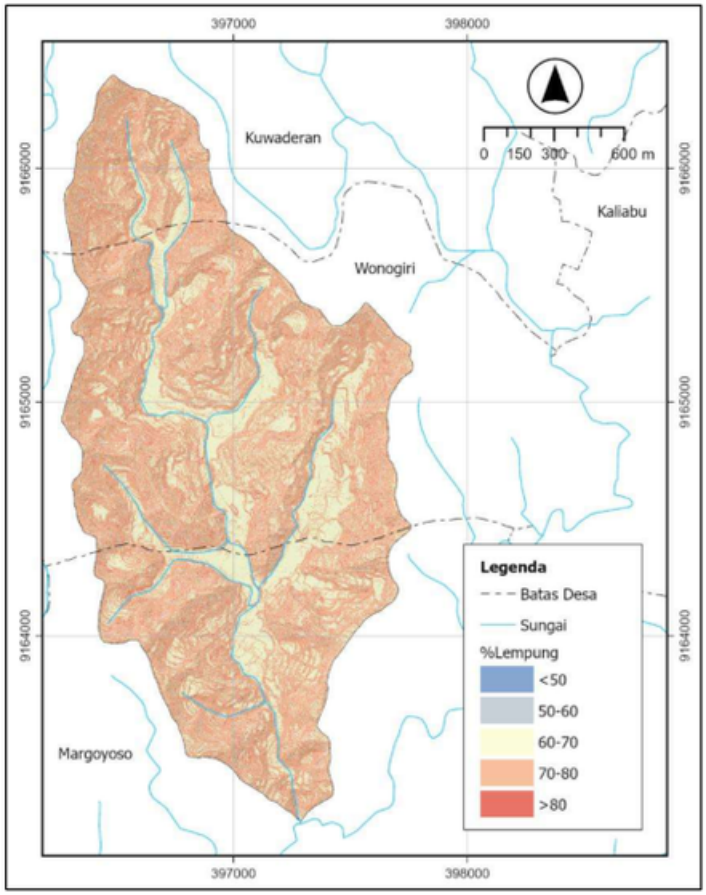

Gambar 4.11. Peta Distribusi Spasial Prediksi Fraksi Lempung Lapisan 1

Peta distribusi spasial prediksi fraksi lempung Lapisan 1 disajikan pada Gambar 4.11. Pada Lapisan 1, *profile curvature* merupakan kovariat dengan tingkat kepentingan tertinggi dalam model prediksi fraksi lempung. Nilai negatif, positif, dan nol dari profil curvature secara berturut-turut menunjukkan permukaan yang *convex* atau cembung ke atas, *concave* atau cekung ke atas, divergen atau cembung ke atas, dan planar atau datar (Dehnavi et al., 2015). Hasil analisis menunjukkan bahwa area dengan nilai *profile curvature* mendekati nol memiliki kandungan lempung lebih rendah, yaitu 60–70%, sedangkan area dengan nilai *profile curvature* negatif dan positif memiliki kandungan lempung lebih tinggi, yaitu 70–80%. *Profile curvature* mengatur perubahan kecepatan aliran dan proses transportasi sedimen (Dehnavi et al., 2015). Hal tersebut berpengaruh terhadap pelepasan, perpindahan, dan pengendapan partikel halus di sepanjang lereng. Kondisi ini dapat menjelaskan kandungan lempung yang lebih tinggi pada area dengan kelengkungan profil yang

lebih nyata, yaitu konvergen dan divergen, dibandingkan area dengan nilai mendekati nol yang relatif datar.

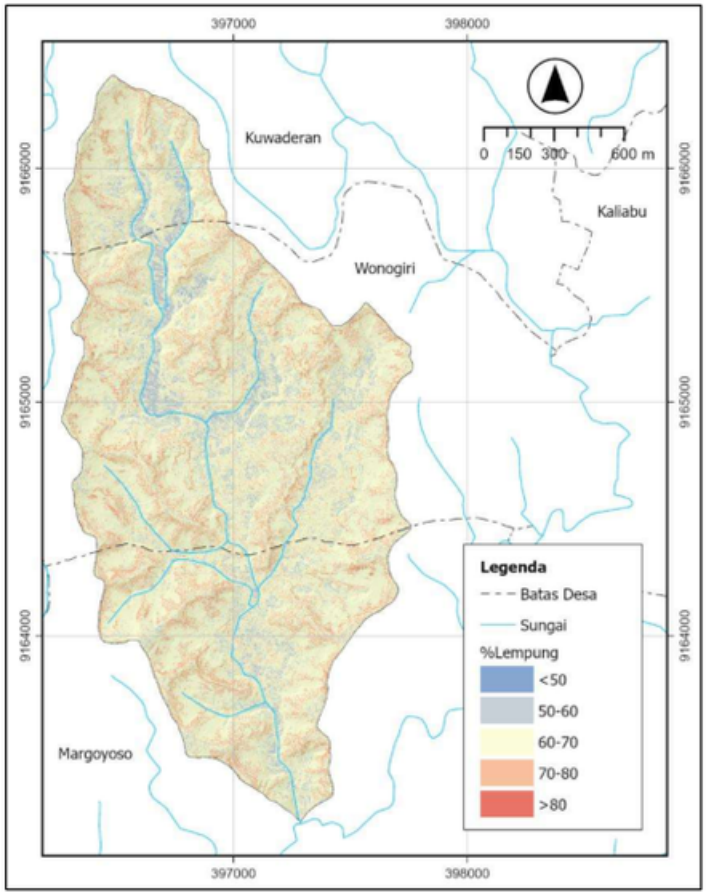

Gambar 4.12. Peta Distribusi Spasial Prediksi Fraksi Lempung Lapisan 2

Peta distribusi spasial prediksi fraksi lempung Lapisan 2 disajikan pada Gambar 4.12. Pada Lapisan 2, *plan curvature* merupakan kovariat dengan tingkat kepentingan tertinggi dalam model prediksi fraksi lempung. Nilai negatif *plan curvature* menunjukkan lereng yang konvergen atau cekung ke samping, nilai positif menunjukkan lereng yang divergen atau cembung ke samping, dan nilai di sekitar nol menunjukkan lereng planar atau datar (Dehnavi et al., 2015). Hasil analisis menunjukkan bahwa area dengan nilai *plan curvature* mendekati nol memiliki kandungan lempung yang lebih rendah, yaitu 60–70%, sedangkan area dengan nilai *plan curvature* negatif dan positif memiliki kandungan lempung lebih tinggi, yaitu 60–80%.

Pada zona konvergen aliran cenderung terkonsentrasi, sedangkan pada zona divergen aliran menyebar ke area yang lebih luas. Oleh karena itu, tingginya kandungan lempung pada nilai *plan curvature* positif maupun negatif menunjukkan

bahwa distribusi fraksi lempung tidak dikendalikan oleh satu arah kelengkungan saja, tetapi berkaitan dengan perbedaan jalur pemusatan dan penyebaran aliran yang memengaruhi redistribusi material halus. Sedangkan, area dengan nilai mendekati nol memiliki pengaruh konvergensi atau divergensi yang lebih lemah dan menunjukkan kandungan lempung yang lebih rendah.

Analisis lebih lanjut terhadap distribusi spasial fraksi tekstur tanah dilakukan dengan menganalisis hasil prediksi terhadap material tutupan, penggunaan lahan, dan bentuklahan. Ketiga faktor tersebut dipilih karena merepresentasikan variasi kondisi pembentukan dan perkembangan tanah di Sub-DAS Bompon serta menjadi dasar dalam penentuan titik sampel. Perbandingan distribusi spasial setiap fraksi dan kedalaman dapat dilihat pada Gambar 4.13. dan Gambar 4.14.

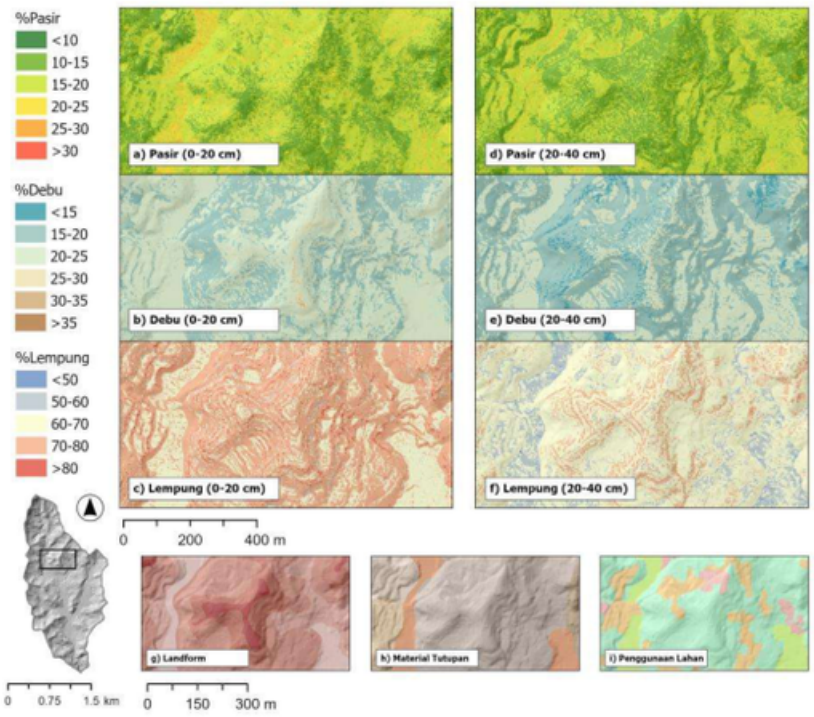

Gambar 4.13. Peta distribusi spasial prediksi kandungan fraksi pasir, debu, dan lempung pada Lapisan 1 dan Lapisan 2 di Bagian Hulu Sub-DAS Bompon

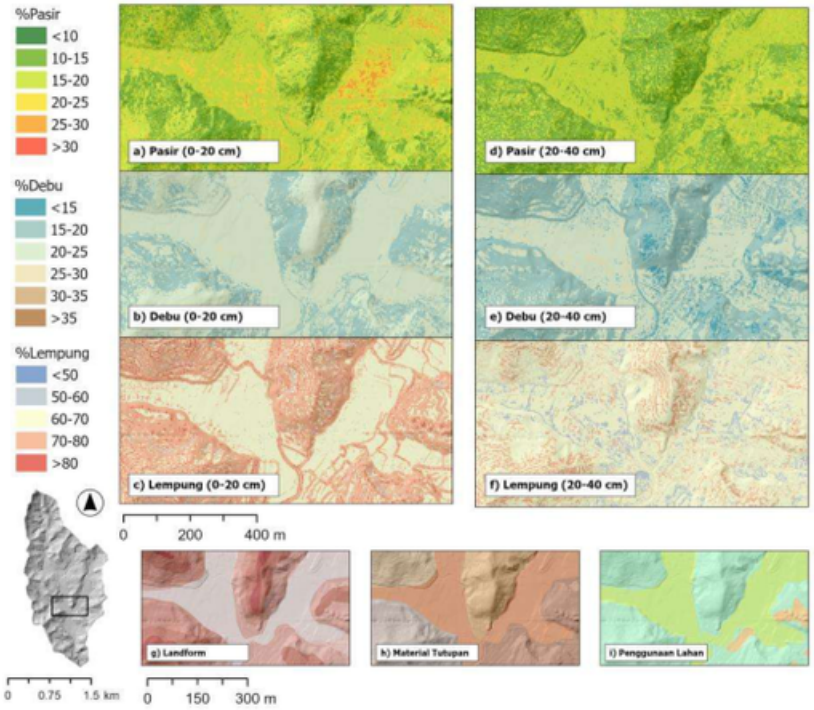

Gambar 4.14. Peta distribusi spasial prediksi kandungan fraksi pasir, debu, dan lempung pada Lapisan 1 dan Lapisan 2 di Bagian Hilir Sub-DAS Bompon

Berdasarkan material tutupan, bentuklahan, dan penggunaan lahan, kandungan pasir Lapisan 1 rata-rata tertinggi masing-masing terdapat pada endapan Sumbing Muda dan endapan material longsor (18,64%), dataran koluvial (18,61%), dan sawah (17,19%). Pola serupa terdapat pada Lapisan 2, dengan nilai tertinggi masing-masing sebesar 17,20%, 17,14%, dan 16,71%. Kandungan pasir yang lebih tinggi pada bagian dataran koluvial tidak sejalan dengan penlitian Qin et al. (2009) yang menyatakan bahwa sampel tanah pada horizon A yang terletak di punggung bukit dan lembah memiliki persentase pasir yang rendah, sedangkan sampel tanah horizon A dengan persentase pasir tertinggi terletak di bagian lereng. Perbedaan tersebut menunjukkan bahwa pola tekstur tidak hanya dikontrol oleh topografi, tetapi juga oleh interkasi antara material penyusun dan proses redistribusi material. Dataran koluvial di Sub-DAS Bompon merupakan zona penerima material hasil erosi, transportasi, dan gerakan massa dari lereng di sekitarnya. Material tutupan berupa endapan material Sumbing Muda dan endapan material longsor menyebabkan kandungan pasir yang lebih tinggi pada dataran koluvial.

Berdasarkan material tutupan, bentuklahan, dan penggunaan lahan, kandungan debu Lapisan 1 rata-rata tertinggi masing-masing terdapat pada endapan Sumbing

Muda dan endapan material longsor (22,79%), dataran koluvial (23,00%), dan sawah (22,63%). Pada Lapisan 2, nilai tertinggi masing-masing terdapat pada endapan Sumbing Muda dan endapan material longsor (21,42%), lereng kaki koluvial (21,30%), dan sawah (21,37%). Kandungan debu yang lebih tinggi pada endapan Sumbing Muda dan endapan material longsor dapat terakumulasi pada posisi yang lebih rendah dan landai, seperti dataran koluvial pada Lapisan 1 dan lereng kaki koluvial pada Lapisan 2. Kandungan debu yang lebih tinggi pada sawah juga berkaitan dengan kondisi lahan yang relatif datar dan pengelolaan air yang mendukung retensi material halus.

Berdasarkan material tutupan, bentuklahan, dan penggunaan lahan, kandungan lempung Lapisan 1 rata-rata tertinggi masing-masing terdapat pada tuff pasiran (63,43%), dataran koluvial (67,91%), dan tegalan (63,13%). Pada Lapisan 2, nilai rata-rata tertinggi masing-masing terdapat pada breksi vulkanik (66,05%), lereng atas perbukitan (67,41%), dan agroforestri (66,14%). Kandungan lempung yang tinggi pada lereng atas perbukitan menunjukkan bahwa akumulasi lempung tidak selalu terbatas pada posisi deposisional di bagian bawah lereng. Pada kondisi tertentu, kandungan lempung dapat menggambarkan pelapukan material dan perkembangan tanah *in situ*, sehingga pengaruh bahan induk dapat lebih dominan daripada redistribusi sedimen terutama pada tanah lapisan bawah.

Peta distribusi prediksi lempung menunjukkan bahwa kandungan lempung pada lapisan permukaan lebih tinggi dibandingkan lapisan bawah. Kondisi tersebut sejalan dengan penelitian Chattaraj et al. (2025a), yang menemukan kandungan lempung lebih tinggi terdapat di lapisan permukaan dan menurun secara bertahap seiring bertambahnya kedalaman. Pola distribusi vertikal tersebut menunjukkan adanya pengaruh proses pembentukan tanah yang melibatkan pelindian lempung dari atas profil tanah, terutama pada wilayah dengan curah hujan tinggi (Chattaraj et al., 2025b; Chen et al., 2022; Jarvis, 2020)

4.7. Manajemen Pengelolaan Lahan Berdasarkan Distribusi Fraksi Tekstur Tanah

Pemetaan distribusi spasial fraksi tekstur dapat digunakan sebagai salah satu dasar dalam mendukung pengelolaan lahan. Dalam perencanaan pertanian, peta tekstur tanah digital dapat diintegrasikan ke dalam proses pengambilan keputusan dalam pemilihan tanaman yang sesuai dengan tekstur tanah di lahan pertanian (Kaya et al., 2022). Perbedaan persentase pasir, debu, dan lempung memengaruhi karakteristik hidrologi tanah. Tanah berpasir memiliki infiltrasi dan drainase cepat

tetapi kemampuan menahan air rendah, sedangkan tanah berlempung memiliki retensi air tinggi tetapi pergerakan air dan drainase lebih lambat. Sementara itu, tanah debuan memiliki kemampuan menahan air yang relatif lebih baik dibandingkan tanah berpasir (Clark, 2020). Seperti yang ditunjukkan Gambar 4.5., tanah berpasir memiliki proporsi air gravitasi yang lebih besar, geluh debuan menyediakan air tersedia bagi tanaman relatif lebih tinggi, sedangkan tanah berlempung menahan lebih banyak air tetapi sebagian tidak tersedia bagi tanaman.

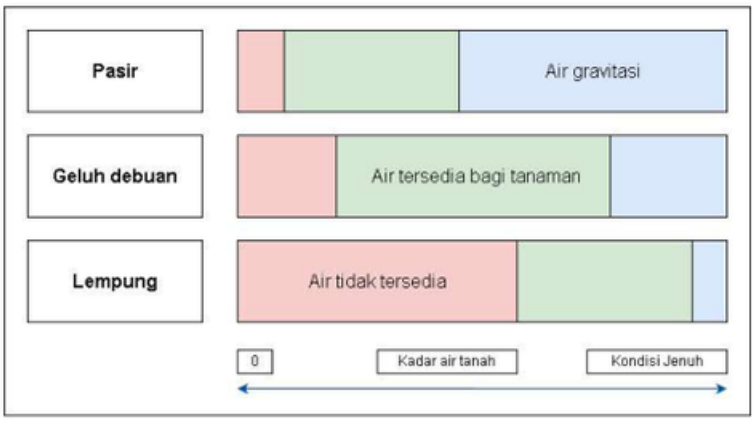

Gambar 4.15. Pengaruh Tekstur Tanah Terhadap Ketersediaan Air Bagi Tanaman
Sumber: Clark, 2020

Sub-DAS Bompon didominasi oleh kandungan lempung tinggi sekitar 60–80%, sehingga dalam pengelolaan lahan perlu memperhatikan upaya konservasi tanah dan air, terutama pada lahan berlereng. Hal ini penting karena beberapa lokasi erosi dan longsor hasil observasi lapangan berada pada area dengan kandungan lempung 70–80% pada Lapisan 1 dan 60–70% pada Lapisan 2 yang disajikan pada Gambar 4.16. Tanah dengan kandungan lempung yang tinggi memiliki risiko longsor yang tinggi (Wida *et al.*, 2019).

Informasi kandungan lempung diintegrasikan dengan zona proses geomorfologi, yaitu zona residual, erosional, dan deposisional, dan residual, sehingga diperoleh enam zona pengelolaan. Zona residual memiliki tingkat kestabilan lereng yang paling rendah, sedangkan zona pengikisan menunjukkan kestabilan sedang dan zona deposisional memiliki tingkat kestabilan paling tinggi (Christanto, 2008; Purwaningsih, 2020). Kestabilan pada setiap zona bersifat dinamis perubahan tersebut dapat dipengaruhi oleh kondisi vegetasi yang berperan dalam stabilitas lereng. Sehingga pengelolaan lahan diarahkan pada konservasi tanah vegetatif melalui pemilihan kelompok tanaman sebagai tutupan lahan. Konservasi tanah vegetatif merupakan

upaya konservasi dengan menggunakan tumbuh-tumbuhan (vegetasi) untuk mengendalikan erosi dan aliran air permukaan pada lahan (Indradewa, 2021).

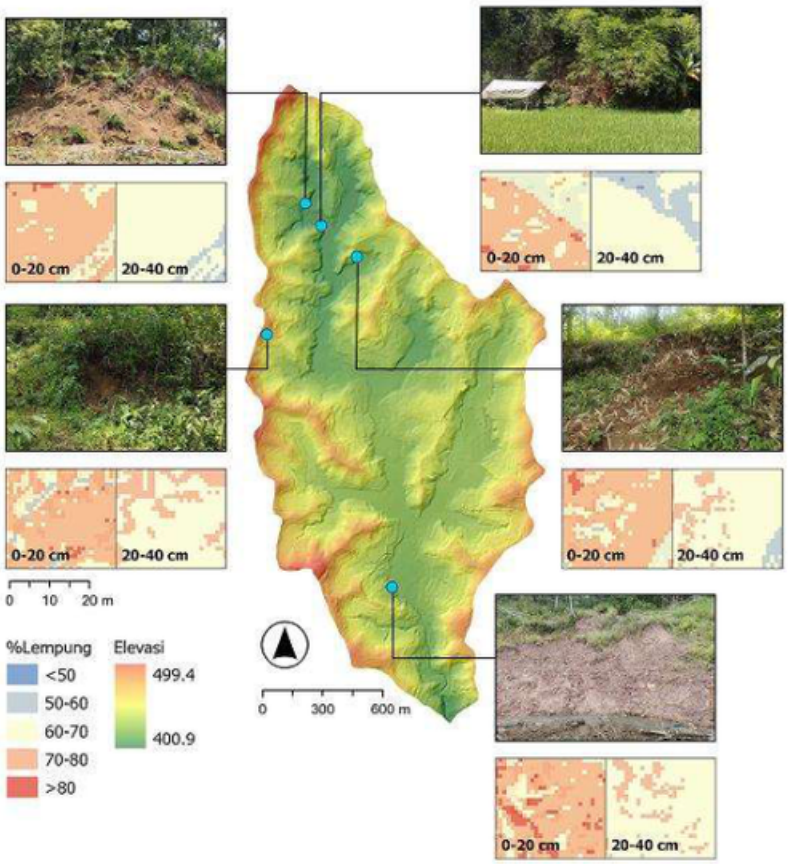

Gambar 4.16. Lokasi Erosi dan Longsor di Sub-DAS Bompon dengan Kandungan Lempung Tinggi

Tabel 4.6. dan Gambar 4.17. menunjukkan bahwa pembagian zona pengelolaan terdiri dari zona residual lempung sedang, residual lempung tinggi, erosional lempung sedang, erosional lempung tinggi, deposisional lempung sedang, dan deposisional lempung tinggi. Selain itu, terdapat zona erosional pada lereng curam yang memerlukan pengelolaan dan tindakan konservasi yang lebih hati-hati untuk meminimalkan risiko erosi. Zona erosional mendominasi sebagian besar wilayah Sub-DAS Bompon, terutama pada bagian lereng di antara zona residual dan jalur deposisional. Zona residual cenderung tersebar pada bagian tepi dan punggungan lereng, sedangkan zona deposisional membentuk pola memanjang yang mengikuti lemba.

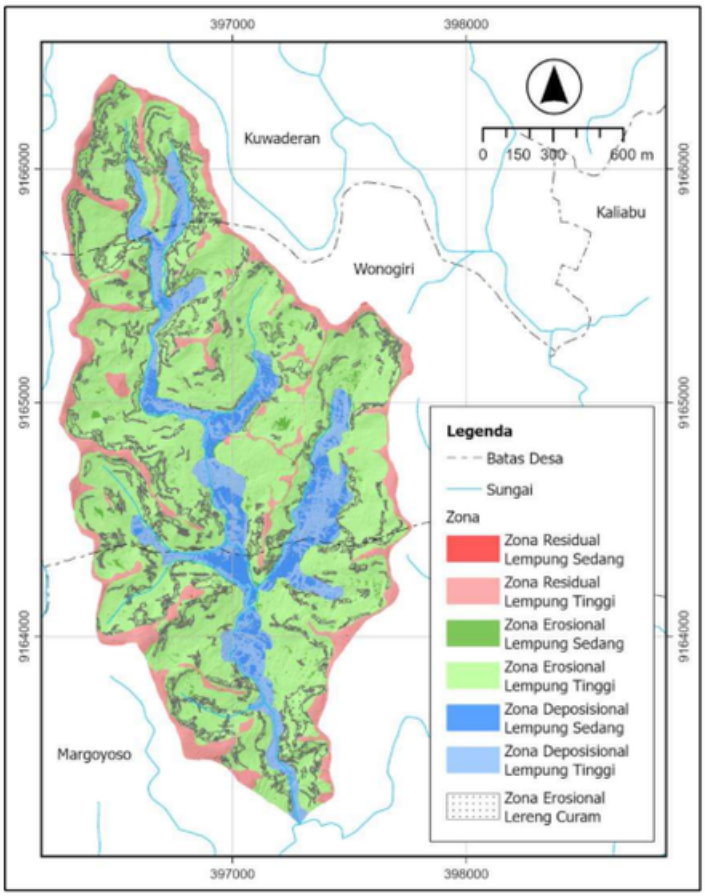

Gambar 4.17. Peta Zona Manajemen Pengelolaan Lahan di Sub-DAS Bompon

Zona residual merupakan zona dengan tingkat kestabilan paling rendah sehingga pemilihan jenis tanaman perlu mempertimbangkan pembatasan beban massa vegetasi pada lereng. Zona erosional memiliki kemiringan lereng yang besar dan kemampuan menyimpan air yang lebih rendah sehingga diperlukan kelompok tanaman penutup. Zona deposisional memiliki kemampuan menyimpan air tanah yang lebih tinggi serta kondisi lahan yang relatif datar membuatnya cocok untuk tanaman dengan sistem akar serabut dan dangkal (Purwaningsih, 2020). Oleh karena itu, pemilihan tanaman pada zona residual difokuskan pada tanaman berukuran kecil hingga sedang dan menghindari dominasi pohon dengan biomassa besar. Pengelolaan vegetasi pada zona erosional diarahkan untuk mendukung produksi sekaligus konservasi, melalui penguatan tanah oleh sistem perakaran tanaman berkayu dan perlindungan permukaan tanah oleh tanaman penutup untuk mengurangi erosi.

Tabel 4.6. Rekomendasi Zona Pengelolaan, Kelompok Tanaman, dan Jenis Tanaman

Zona Pengelolaan	Kelompok Tanaman	Jenis Tanaman
Zona Residual Lempung Sedang	Tanaman Buah ukuran medium	Melinjo, Pisang
	Tanaman Perdu	Cabai
	Tanaman Pagar	Bambu
	Tanaman Rimpang	Jahe, Kunyit, Lengkuas Kencur
Zona Residual Lempung Tinggi	Tanaman Buah ukuran medium	Melinjo, Pisang
	Tanaman Perdu	Cabai
	Tanaman Pagar	Bambu
	Tanaman Rimpang	Jahe, Kunyit, Lengkuas
Zona Erosional Lempung Sedang	Tanaman Kayu	Sengon, Mahoni, Jati, Sonokeling
	Tanaman Buah	Kelapa, Durian
	Tanaman Perdu	Kopi
	Tanaman Rimpang	Jahe, Kunyit
Zona Erosional Lempung Tinggi	Tanaman Kayu	Sengon, Mahoni, Jati
	Tanaman Buah	Kelapa, Durian
	Tanaman Perdu	Kopi
	Tanaman Rimpang	Jahe, Kunyit
	Tanaman Penutup	Vetiver, Rumput Gajah, Kacang Hias
Zona Deposisional Lempung Sedang	Tanaman Kayu	Sengon
	Tanaman Pangan Semusim	Padi, Singkong, Ubi
	Tanaman Buah	Pisang, Kelapa, Durian, Nangka
Zona Deposisional Lempung Tinggi	Tanaman Kayu	Sengon, Waru
	Tanaman Pangan Semusim	Padi, Singkong
	Tanaman Buah	Kelapa, Mangga, Manggis

Tabel 4.6. menunjukkan arahan pengelolaan berdasarkan kelompok tanaman dan jenis tanaman pada enam zona pengelolaan. Pemilihan jenis tanaman dilakukan dengan mempertimbangkan tanaman aktual yang telah berkembang di wilayah penelitian serta rekomendasi tanaman yang dinilai sesuai dengan karakteristik masing-masing zona pengelolaan (Indradewa, 2021). Kelompok tanaman zona residual diarahkan pada vegetasi dengan ukuran relatif kecil hingga sedang, meliputi tanaman buah berukuran medium, perdu, tanaman pagar, dan tanaman rimpang, untuk membatasi penambahan beban massa vegetasi. Pada zona erosional, kelompok tanaman terdiri dari tanaman kayu, tanaman buah, perdu, dan rimpang, serta penambahan tanaman penutup pada zona erosional lempung tinggi untuk mendukung perlindungan permukaan tanah dan mengurangi proses erosi. Sedangkan, zona deposisional diarahkan pada pemanfaatan yang lebih produktif

melalui tanaman kayu, tanaman pangan semusim, dan tanaman buah karena memiliki kestabilan relatif lebih tinggi dibandingkan zona lain.

BAB V KESIMPULAN & SARAN

5.1. Kesimpulan

1. Distribusi fraksi tanah pada bahan induk teralterasi di Sub-DAS Bompon menunjukkan dominasi fraksi lempung dibandingkan fraksi pasir dan debu. Distribusi spasial setiap fraksi tekstur tanah cenderung mengikuti pola distribusi kovariat lingkungan yang memiliki tingkat kepentingan tertinggi dalam model prediksi.
2. Pendekatan SCORPAN mampu memprediksi distribusi fraksi tekstur tanah, namun menunjukkan kinerja prediksi yang relatif rendah dengan nilai R^2 tertinggi sebesar 0,249. Hubungan antara kovariat lingkungan dan variasi fraksi tanah lebih kuat pada lapisan permukaan dibandingkan lapisan bawah.
3. Peta distribusi fraksi lempung diintegrasikan dengan zona proses geomorfologi dapat menghasilkan 6 zona manajemen pengelolaan lahan dengan arah pengelolaan pada konservasi tanah vegetatif melalui pemilihan kelompok tanaman pada setiap zona.

5.2. Saran

1. Model prediksi perlu diuji pada wilayah dengan karakteristik lingkungan dan bahan induk yang berbeda untuk mengevaluasi konsistensi dan kemampuan model dalam menangkap hubungan sifat tanah dengan kovariat lingkungan.
2. Desain sampling dalam penelitian selanjutnya perlu memperhatikan penentuan jumlah dan kepadatan sampel berdasarkan luas setiap unit pemetaan, sehingga unit dengan cakupan wilayah yang luas memiliki keterwakilan spasian yang memadai.
3. Variabel material tutupan, penutup lahan, dan bentuklahan masih berupa data kategorikal yang memiliki keterbatasan dalam merepresentasikan variasi kondisi lingkungan, sehingga perlu dikembangkan menjadi kovariat numerik kontinu agar perngaruhnya terhadap distribusi fraksi tekstur tanah dapat ditangkap secara lebih baik oleh model machine learning.
4. Zona manajemen pengelolaan lahan perlu divalidasi melalui pengamatan lapangan dan analisis sifat tanah pendukung, serta mempertimbangkan kejadian erosi dan longsor untuk memastikan kesesuaian arahan pengelolaan pada setiap zona.

DAFTAR PUSTAKA

Adzima, A. F., Setiawan, M. A., & Mardiatno, D. (2019). Karakteristik Tanah HAHT (Human Altered-Human Transported) di Area Perdesaan Terhadap Kelestarian Lingkungan (Characteristics of HAHT (Human Altered-Human Transported) Soil in Rural Areas for Environmental Sustainability). *Jurnal Sains Informasi Geografi*, *2*(2), 32. https://doi.org/10.31314/jsig.v2i2.373

Aghhavani Shajari, M., Rezvani Moghaddam, P., Ghorbani, R., & Koocheki, A. (2020). The possibility of improving saffron (Crocus sativus L.) flower and corm yield through the irrigation and soil texture managements. *Scientia Horticulturae*, *271*, 109485. https://doi.org/10.1016/j.scienta.2020.109485

Ågren, A. M., Larson, J., Paul, S. S., Laudon, H., & Lidberg, W. (2021). Use of multiple LIDAR-derived digital terrain indices and machine learning for high-resolution national-scale soil moisture mapping of the Swedish forest landscape. *Geoderma*, *404*, 115280. https://doi.org/10.1016/j.geoderma.2021.115280

Ågren, A. M., Lidberg, W., Strömgren, M., Ogilvie, J., & Arp, P. A. (2014). Evaluating digital terrain indices for soil wetness mapping – a Swedish case study. *Hydrology and Earth System Sciences*, *18*(9), 3623–3634. https://doi.org/10.5194/hess-18-3623-2014

Akhtman, Y. (2023, October 2). *Sentinel-2 Deep Resolution 3.0*. Medium.

Breiman, L. (2001). Random Forests. Machine Learning. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cahyana, D., Sulaeman, Y., Barus, B., Darmawan, & Mulyanto, B. (2023). Improving digital soil mapping in Bogor, Indonesia using parent material information. *Geoderma Regional*, *33*, e00627. https://doi.org/10.1016/j.geodrs.2023.e00627

Capra, G. F., Vacca, S., Cabula, E., Grilli, E., & Buondonno, A. (2012). Human-Altered and Human-Transported Soils in an Italian Industrial District. *Soil Science Society of America Journal*, *76*(5), 1828–1841. https://doi.org/10.2136/sssaj2011.0384

Carlson, D. H., C.C. Plummer, & L. Hammersley. (2009). *Physical geology: Earth revealed. 9th Ed* (9th ed.). McGraw Hill.

CDSE. (2016). *A European wide-swath, high-resolution, multi-spectral imaging mission*. Copernicus Data Space Ecosysem .

Cesmeli, M. S. (2025). Increasing the prediction efficacy of the thermodynamic properties of R515B refrigerant with machine learning algorithms using SMOGN

data augmentation method. *International Journal of Refrigeration*, *179*, 44–59. https://doi.org/10.1016/j.ijrefrig.2025.07.026

Chandra, A. (2016). *Penentuan Tekstur Tanah dengan Metode Hidrometer dan Pipet pada Tipe Lahan Kering dan Basah*.

Chanev, M., Kamenova, I., Dimitrov, P., & Filchev, L. (2025). Evaluation of Sentinel-2 Deep Resolution 3.0 Data for Winter Crop Identification and Organic Barley Yield Prediction. *Remote Sensing*, *17*(6), 957. https://doi.org/10.3390/rs17060957

Chattaraj, S., Daripa, A., Reza, S. K., Ghosh, B. N., Majhi, S., Mallick, D., Paul, S., Dey, S., & Rahman, F. H. (2025a). Soil texture and lithological discontinuity mapping for sustainable land use planning: An application of digital soil mapping in a part of Eastern Himalayan Foothills, India. *CATENA*, *258*, 109253. https://doi.org/10.1016/j.catena.2025.109253

Chattaraj, S., Daripa, A., Reza, S. K., Ghosh, B. N., Majhi, S., Mallick, D., Paul, S., Dey, S., & Rahman, F. H. (2025b). Soil texture and lithological discontinuity mapping for sustainable land use planning: An application of digital soil mapping in a part of Eastern Himalayan Foothills, India. *CATENA*, *258*, 109253. https://doi.org/10.1016/j.catena.2025.109253

Chen, L., Wang, J., Wang, H., Xu, F., Song, P., Yang, C., & Li, J. (2022). Variation in soil detachment capacity of structural and sedimentary crusts induced by simulated rainfall formed on ridge and furrow. *CATENA*, *211*, 105971. https://doi.org/10.1016/j.catena.2021.105971

Christanto, N. (2008). *Hydrological-Slope Stability Modelling for Landslide Hazard Assesment by Means of GIS and Remote Sensing Data a Case Study of Probolo Sub-Catchments, Gesing Sub-District Purworejo Regency, Indonesia*. Universitas Gadjah Mada.

Clark, C. A. (2020). *The important role of soil texture on water*. Crops and Soils Division of Extension.

Cremon, É. H., Pereira, A. C., Paula, L. D. L. de, & Nunes, E. D. (2021). Geological and terrain attributes for predicting soil classes using pixel- and geographic object-based image analysis in the Brazilian Cerrado. *Geoderma*, *401*, 115315. https://doi.org/10.1016/j.geoderma.2021.115315

da Silva, A. F., Pereira, M. J., Carneiro, J. D., Zimback, C. R. L., Landim, P. M. B., & Soares, A. (2014). A new approach to soil classification mapping based on the

spatial distribution of soil properties. *Geoderma*, *219–220*, 106–116. https://doi.org/10.1016/j.geoderma.2013.12.011

Dehnavi, A., Aghdam, I. N., Pradhan, B., & Morshed Varzandeh, M. H. (2015). A new hybrid model using step-wise weight assessment ratio analysis (SWARA) technique and adaptive neuro-fuzzy inference system (ANFIS) for regional landslide hazard assessment in Iran. *CATENA*, *135*, 122–148. https://doi.org/10.1016/j.catena.2015.07.020

Dindaroğlu, T., Kılıç, M., Günal, E., Gündoğan, R., Akay, A. E., & Seleiman, M. (2022). Multispectral UAV and satellite images for digital soil modeling with gradient descent boosting and artificial neural network. *Earth Science Informatics*, *15*(4), 2239–2263. https://doi.org/10.1007/s12145-022-00876-7

ESA. (2024). *Introducing Sentinel-2*. European Space Agency.

Fan, B., Tao, W., Qin, G., Hopkins, I., Zhang, Y., Wang, Q., Lin, H., & Guo, L. (2020). Soil micro-climate variation in relation to slope aspect, position, and curvature in a forested catchment. *Agricultural and Forest Meteorology*, *290*, 107999. https://doi.org/10.1016/j.agrformet.2020.107999

Farhadur Rahman, Md., Onoda, Y., & Kitajima, K. (2022). Forest canopy height variation in relation to topography and forest types in central Japan with LiDAR. *Forest Ecology and Management*, *503*, 119792. https://doi.org/10.1016/j.foreco.2021.119792

Febriyana, R. D., Aribowo, Y., & Widiarso, D. A. (n.d.). *Geologi dan Alterasi Hidrotermal Daerah Bantar Karet dan Sekitarnya, Kecamatan Nanggung, Kabupaten Bogor, Provinsi Jawa Barat*.

Goetz, J. N., Guthrie, R. H., & Brenning, A. (2011). Integrating physical and empirical landslide susceptibility models using generalized additive models. *Geomorphology*, *129*(3–4), 376–386. https://doi.org/10.1016/j.geomorph.2011.03.001

Greve, M. H., Kheir, R. B., Greve, M. B., & Bøcher, P. K. (2012). Quantifying the ability of environmental parameters to predict soil texture fractions using regression-tree model with GIS and LIDAR data: The case study of Denmark. *Ecological Indicators*, *18*, 1–10. https://doi.org/10.1016/j.ecolind.2011.10.006

Heung, B., Saurette, D., & Bulmer, C. E. (2021). Digital Soil Mapping. In *Digging Into Canadian Soils: An Introduction to Soil Science* (17). Canadian Society of Soil Science.

Hong, Y., Yu, L., Chen, Y., Liu, Y., Liu, Y., Liu, Y., & Cheng, H. (2017). Prediction of Soil Organic Matter by VIS–NIR Spectroscopy Using Normalized Soil Moisture Index as a Proxy of Soil Moisture. *Remote Sensing*, *10*(1), 28. https://doi.org/10.3390/rs10010028

Hosseinpour-Zarnaq, M., Omid, M., Sarmadian, F., Ghasemi-Mobtaker, H., Alimardani, R., & Bohlol, P. (2025). Exploring the capabilities of hyperspectral remote sensing for soil texture evaluation. *Ecological Informatics*, *90*, 103336. https://doi.org/10.1016/j.ecoinf.2025.103336

Indradewa, D. (2021). *Etnoagronomi Indonesia* (I). Lily Publisher.

Jarvis, N. (2020). Reflection on Jarvis (2007), "Review of non-equilibrium water flow and solute transport in soil macropores: Principles, controlling factors and consequences for water quality". European Journal of Soil Science, 58, 523–546. *European Journal of Soil Science*, *71*(3), 303–307. https://doi.org/10.1111/ejss.12914

Jenny, H. (1941). *Factors of Soil Formation: A System of Quantitative Pedology*. McGraw-Hill.

Karchegani, P. M., Ayoubi, S., Lu, S. G., & Honarju, N. (2011). Use of magnetic measures to assess soil redistribution following deforestation in hilly region. *Journal of Applied Geophysics*, *75*(2), 227–236. https://doi.org/10.1016/j.jappgeo.2011.07.017

Kaya, F., Başayiğit, L., Keshavarzi, A., & Francaviglia, R. (2022). Digital mapping for soil texture class prediction in northwestern Türkiye by different machine learning algorithms. *Geoderma Regional*, *31*, e00584. https://doi.org/10.1016/j.geodrs.2022.e00584

Khalighi, A., Hojjati, Y., Babalar, M., & Naderi, R. (2006). Effects of cytocinin nutrient treatment and soil texture on quality and quantity Characteristic of onion and scallion in Darwin Hybrid Tulip, Apeldoorn figure. *Agronomy Journal in Agriculture and Gardening*, *73*, 58–64.

Kironoto, B. Agus., Yulistiyanto, Bambang., & Olii, M. Ramdhan. (2020). *Erosi dan Konservasi Lahan*. Gadjah Mada University Press.

Kroll, R. (2025). *LIDAR for surveying drones: Functionality, advantages and disadvantages*. Airclip.

Lam, N., Huynh, H., Niculescu, S., Nguyen, Q., & Nguyen Vo Chau, N. (2023). *A Random Forest Approach for Evaluating Forest Cover Changes Outside Dikes with Sentinel Images*.

Liu, J., Munnaf, M. A., Pätzold, S., & Mouazen, A. M. (2026). A dataset-based statistical comparison of gamma-ray and visible-near-infrared sensors for soil texture prediction with ensemble learning. *Computers and Electronics in Agriculture*, *241*, 111326. https://doi.org/10.1016/j.compag.2025.111326

Loiseau, T., Chen, S., Mulder, V. L., Román Dobarco, M., Richer-de-Forges, A. C., Lehmann, S., Bourennane, H., Saby, N. P. A., Martin, M. P., Vaudour, E., Gomez, C., Lagacherie, P., & Arrouays, D. (2019). Satellite data integration for soil clay content modelling at a national scale. *International Journal of Applied Earth Observation and Geoinformation*, *82*, 101905. https://doi.org/10.1016/j.jag.2019.101905

Loiseau, T., Richer-de-Forges, A. C., Martelet, G., Bialkowski, A., Nehlig, P., & Arrouays, D. (2020). Could airborne gamma-spectrometric data replace lithological maps as co-variates for digital soil mapping of topsoil particle-size distribution? A case study in Western France. *Geoderma Regional*, *22*, e00295. https://doi.org/10.1016/j.geodrs.2020.e00295

Lu, Q., Tian, S., & Wei, L. (2023). Digital mapping of soil pH and carbonates at the European scale using environmental variables and machine learning. *Science of The Total Environment*, *856*, 159171. https://doi.org/10.1016/j.scitotenv.2022.159171

Malik, R. F. (2017). *Pemetaan Geomorfologi Detail Menggunakan Teknik Step-Wise-Grid Di Daerah Aliran Sungai (DAS) Bompon Kabupaten Magelang, Jawa Tengah*. Universitas Gadjah Mada.

Mashalaba, L., Galleguillos, M., Seguel, O., & Poblete-Olivares, J. (2020). Predicting spatial variability of selected soil properties using digital soil mapping in a rainfed vineyard of central Chile. *Geoderma Regional*, *22*, e00289. https://doi.org/10.1016/j.geodrs.2020.e00289

McBratney, A. B., Mendonça Santos, M. L., & Minasny, B. (2003). On digital soil mapping. *Geoderma*, *117*(1–2), 3–52. https://doi.org/10.1016/S0016-7061(03)00223-4

Meinshausen, N. (2006). Quantile Regression Forests. In *Journal of Machine Learning Research* (Vol. 7).

Mgohele, R. N., Massawe, B. H. J., Shitindi, M. J., Sanga, H. G., & Omar, M. M. (2024a). Prediction of soil texture using remote sensing data. A systematic review. *Frontiers in Remote Sensing*, *5*. https://doi.org/10.3389/frsen.2024.1461537

Mgohele, R. N., Massawe, B. H. J., Shitindi, M. J., Sanga, H. G., & Omar, M. M. (2024b). Prediction of soil texture using remote sensing data. A systematic review. In *Frontiers in Remote Sensing* (Vol. 5). Frontiers Media SA. https://doi.org/10.3389/frsen.2024.1461537

Moharana, P. C., Dharumarajan, S., Yadav, B., Jena, R. K., Pradhan, U. K., Sahoo, S., Meena, R. S., Nogiya, M., Meena, R. L., Singh, R. S., Singh, S. K., & Dwivedi, B. S. (2023). Prediction of Soil Inorganic Carbon at Multiple Depths Using Quantile Regression Forest and Digital Soil Mapping Technique in the Thar Desert Regions of India. *Communications in Soil Science and Plant Analysis*, *54*(21), 2977–2994. https://doi.org/10.1080/00103624.2023.2253840

Moura-Bueno, J. M., Dalmolin, R. S. D., ten Caten, A., Dotto, A. C., & Demattê, J. A. M. (2019). Stratification of a local VIS-NIR-SWIR spectral library by homogeneity criteria yields more accurate soil organic carbon predictions. *Geoderma*, *337*, 565–581. https://doi.org/10.1016/j.geoderma.2018.10.015

Naimi, A. I., & Balzer, L. B. (2018). Stacked generalization: an introduction to super learning. *European Journal of Epidemiology*, *33*(5), 459–464. https://doi.org/10.1007/s10654-018-0390-z

Navia, R., Hafner, G., Raber, G., Lorber, K. E., Schöffmann, E., & Vortisch, W. (2005). The use of volcanic soil as mineral landfill liner - I. Physicochemical characterization and comparison with zeolites. *Waste Management & Research: The Journal for a Sustainable Circular Economy*, *23*(3), 249–259. https://doi.org/10.1177/0734242X05055476

Noviyanto, A., Sartohadi, J., & Purwanto, B. H. (2020). The distribution of soil morphological characteristics for landslide-impacted Sumbing Volcano, Central Java - Indonesia. *Geoenvironmental Disasters*, *7*(1), 25. https://doi.org/10.1186/s40677-020-00158-8

Nussbaum, M., Spiess, K., Baltensweiler, A., Grob, U., Keller, A., Greiner, L., Schaepman, M. E., & Papritz, A. (2018). Evaluation of digital soil mapping approaches with large sets of environmental covariates. *SOIL*, *4*(1), 1–22. https://doi.org/10.5194/soil-4-1-2018

Nussbaum, M., Vogel, S., Oechslin, S., Tanner, S., & Burgos, S. (2023). Smoothed predicted distributions in digital soil mapping – a comprehensive comparative study to predict soil texture for irrigation. In *EGU General Assembly 2023*. https://doi.org/10.5194/egusphere-egu23-5543

Pahlavan-Rad, M. R., & Akbarimoghaddam, A. (2018). Spatial variability of soil texture fractions and pH in a flood plain (case study from eastern Iran). *CATENA*, *160*, 275–281. https://doi.org/10.1016/j.catena.2017.10.002

Pennell, T., Comeau, L.-P., Zhang, J., Feng, C., & Heung, B. (2026). The importance of zeros in digital soil mapping II: A case study of depth-to-bedrock mapping in New Brunswick, Canada. *Geoderma*, *465*, 117651. https://doi.org/10.1016/j.geoderma.2025.117651

Prayitno, A., Sartohadi, J., & Nurudin, M. (2019). Utilization of Soil Function Information for Assessing Soil Quality of Rice Field in the Quaternary-Tertiary Volcanic Transitional Zones in Central Java. *SAINS TANAH - Journal of Soil Science and Agroclimatology*, *16*(2), 169. https://doi.org/10.20961/stjssa.v16i2.35492

Priyono, K. D. (2012). A Study of Clay Mineral in The Occurences of Landslide Disaster Area at Kulonprogo Mountains Yogyakarta Special Province. *InForum Geografi*, *26*, 53.

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *32nd Conference on Neural Information Processing Systems*. https://github.com/catboost/catboost

Pulungan, N. A., & Sartohadi, J. (2018). New Approach to Soil Formation in the Transitional Landscape Zone: Weathering and Alteration of Parent Rocks. *Journal of Environments*, *5*(1), 1–7. https://doi.org/10.20448/journal.505.2018.51.1.7

Purwaningsih, R. (2020). *Model Tanaman Kebun Agroforestri pada Lahan Bekas Longsor di Sub DAS Kaliwungu Kabupaten Magelang*. Universitas Gadjah Mada.

Purwaningsih, R., Hartanti, H., Dewi, I. K., Salsabila, G., Handayani, S., Hatta, D. A. H., Ariyanti, S. D., Putri, H. A., Stakhis, E. P., Sartohadi, J., Priyawati, E. G. A., Pulungan, N. A. H. J., Paradisa, D. A., Mashum, H., & Gomez, C. (2025). Subsoil Mineralogy as Environmental Factors in Controlling Topsoil Material in the Menoreh–Sumbing Volcanic Structural Transitional Landscape, Central Java. *Journal of Water and Land Development*, 73–73. https://doi.org/10.24425/jwld.2025.156041

Qin, C.-Z., Zhu, A.-X., Shi, X., Li, B.-L., Pei, T., & Zhou, C.-H. (2009). Quantification of spatial gradation of slope positions. *Geomorphology*, *110*(3–4), 152–161. https://doi.org/10.1016/j.geomorph.2009.04.003

Rahmi, M., Setiawan, M. A., & Mardiatno, D. (2019). Analisis Kekeringan Berdasarkan Bentuklahan Di Das Bompon. *Media Komunikasi Geografi*, *20*(2), 90. https://doi.org/10.23887/mkg.v20i2.18399

Rhoton, F. E., & Duiker, S. W. (2008). Erodibility of a soil drainage sequence in the loess uplands of Mississippi. *CATENA*, *75*(2), 164–171. https://doi.org/10.1016/j.catena.2008.05.005

Rinaldi, M., & He, Z. (2014). *Decision Support Systems to Manage Irrigation in Agriculture* (pp. 229–279). https://doi.org/10.1016/B978-0-12-420225-2.00006-6

Salgueiro, L., Marcello, J., & Vilaplana, V. (2021). Single-Image Super-Resolution of Sentinel-2 Low Resolution Bands with Residual Dense Convolutional Neural Networks. *Remote Sensing*, *13*(24), 5007. https://doi.org/10.3390/rs13245007

Sambodo, A. P., & Arpornthip, T. (2021). Increasing the Efficiency of Detailed Soil Resource Mapping on Transitional Volcanic Landforms Using a Geomorphometric Approach. *Applied and Environmental Soil Science*, *2021*, 1–12. https://doi.org/10.1155/2021/8867647

Sartohadi, J., Rahma, A. D., & Nugraha, S. S. (2024a). Productive conservation at the landslide prone area under the threat of rapid land cover changes. *Open Geosciences*, *16*(1). https://doi.org/10.1515/geo-2022-0700

Sartohadi, J., Rahma, A. D., & Nugraha, S. S. (2024b). Productive conservation at the landslide prone area under the threat of rapid land cover changes. *Open Geosciences*, *16*(1). https://doi.org/10.1515/geo-2022-0700

Sartohadi, J., Suratman, Jamulya, & Dewi, N. I. S. (2022). *Pengantar Geografi Tanah* (Cetakan IV). Pustaka Pelajar.

Schulz, G. A., Rodríguez, D. M., Angelini, M., Moretti, L. M., Olmedo, G. F., Tenti Vuegen, L. M., Colazo, J. C., & Guevara, M. (2023). Digital Soil Texture Maps of Argentina and Their Relationship to Soil-Forming Factors and Processes. In *Geopedology* (pp. 263–281). Springer International Publishing. https://doi.org/10.1007/978-3-031-20667-2_14

Sheykhmousa, M., Mahdianpari, M., Ghanbari, H., Mohammadimanesh, F., Ghamisi, P., & Homayouni, S. (2020). Support Vector Machine Versus Random Forest for Remote Sensing Image Classification: A Meta-Analysis and Systematic Review. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, *13*, 6308–6325. https://doi.org/10.1109/JSTARS.2020.3026724

Skentos, A., & Ourania, A. (2017). Landform Analysis Using Terrain Attributes. A Gis Application on the Island of Ikaria (Aegean Sea, Greece). *Annals of Valahia*

University of Targoviste, Geographical Series, *17*(1), 90–97. https://doi.org/10.1515/avutgs-2017-0009

Soil Science Staff. (2017a). Chapter 1: Soil and Soil Survey. In *Soil Survey Manual*.

Soil Science Staff. (2017b). Chapter 3: Examination and Description of Soil Profiles. In *Soil Survey Manual* (Chapter 3:).

Sulaeman, Y., & Husnain. (2021). Membuat Peta Tanah dengan Teknik Disagregasi Spasial. *Jurnal Sumberdaya Lahan*, *15*(2).

Sulaiman, S. M., Mezaal, M. R., & Al-Attar, A. A. A. (2024). Evaluation of Machine Learning Models for Predicting Soil Texture Using Sentinel-1A SAR and Topographic Information. *Ecological Engineering & Environmental Technology*, *25*(11), 200–217. https://doi.org/10.12912/27197050/192397

Theres, B. L., & Sakthivel, R. (2022). Prediction of Soil Properties Using Quantile Regression Forest Machine Learning Algorithm – A Case Study of Salem and Rasipuram Block, Tamil Nadu, India. *International Journal of Environment and Climate Change*, 2530–2553. https://doi.org/10.9734/ijecc/2022/v12i1131246

Trotta, F. (2024, April 7). *How to Handle Imbalanced Data for Machine Learning in Python*. Semaphore.

Turgut, Y. S., & Koca, Y. K. (2026). Predictive mapping of soil texture using vis–NIR spectroscopy and machine learning in semi-arid Eastern Mediterranean. *Advances in Space Research*, *78*(2), 660–683. https://doi.org/10.1016/j.asr.2026.04.065

Unamunzaga, O., Besga, G., Castellón, A., Usón, M. A., Chéry, P., Gallejones, P., & Aizpurua, A. (2014). Spatial and vertical analysis of soil properties in a Mediterranean vineyard soil. *Soil Use and Management*, *30*(2), 285–296. https://doi.org/10.1111/sum.12110

Vaysse, K., & Lagacherie, P. (2017). Using quantile regression forest to estimate uncertainty of digital soil mapping products. *Geoderma*, *291*, 55–64. https://doi.org/10.1016/j.geoderma.2016.12.017

Viloria, J. A., Viloria-Botello, A., Pineda, M. C., & Valera, A. (2016). Digital modelling of landscape and soil in a mountainous region: A neuro-fuzzy approach. *Geomorphology*, *253*, 199–207. https://doi.org/10.1016/j.geomorph.2015.10.007

Viscarra Rossel, R. A., Behrens, T., Ben-Dor, E., Brown, D. J., Demattê, J. A. M., Shepherd, K. D., Shi, Z., Stenberg, B., Stevens, A., Adamchuk, V., Aïchi, H., Barthès, B. G., Bartholomeus, H. M., Bayer, A. D., Bernoux, M., Böttcher, K.,

Brodský, L., Du, C. W., Chappell, A., … Ji, W. (2016). A global spectral library to characterize the world's soil. *Earth-Science Reviews*, *155*, 198–230. https://doi.org/10.1016/j.earscirev.2016.01.012

Vories, E., O'Shaughnessy, S., Sudduth, K., Evett, S., Andrade, M., & Drummond, S. (2021). Comparison of precision and conventional irrigation management of cotton and impact of soil texture. *Precision Agriculture*, *22*(2), 414–431. https://doi.org/10.1007/s11119-020-09741-3

Wadoux, A. M. J.-C. (2019). Using deep learning for multivariate mapping of soil with quantified uncertainty. *Geoderma*, *351*, 59–70. https://doi.org/10.1016/j.geoderma.2019.05.012

Wida, W. A., Maas, A., & Sartohadi, J. (2019). Pedogenesis of Mt. Sumbing Volcanic Ash above The Alteration Clay Layer in The Formation of Landslide Susceptible Soils in Bompon Sub-Watershed. *Ilmu Pertanian (Agricultural Science)*, *4*(1), 15. https://doi.org/10.22146/ipas.41893

Wijayanti, N. F. (2020). *Aplikas Model SWAT (Soil and Water Assesment Tool) untuk Mengetahui Besar Nitrogen dan Fosfor pada Aliran Permukaan di DAS Bompon*. Universitas Gadjah Mada.

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, *5*(2), 241–259. https://doi.org/10.1016/S0893-6080(05)80023-1

Yan, W. Y., Shaker, A., & El-Ashmawy, N. (2015). Urban land cover classification using airborne LiDAR data: A review. *Remote Sensing of Environment*, *158*, 295–310. https://doi.org/10.1016/j.rse.2014.11.001

Zeraatpisheh, M., Jafari, A., Bagheri Bodaghabadi, M., Ayoubi, S., Taghizadeh-Mehrjardi, R., Toomanian, N., Kerry, R., & Xu, M. (2020). Conventional and digital soil mapping in Iran: Past, present, and future. *CATENA*, *188*, 104424. https://doi.org/10.1016/j.catena.2019.104424

LAMPIRAN

Lampiran 1. Perbandingan Peta Prediksi Fraksi Pasir, Debu, dan Lempung Metode RF, QRF, CatBoost, dan Stacking Tanpa Resampling

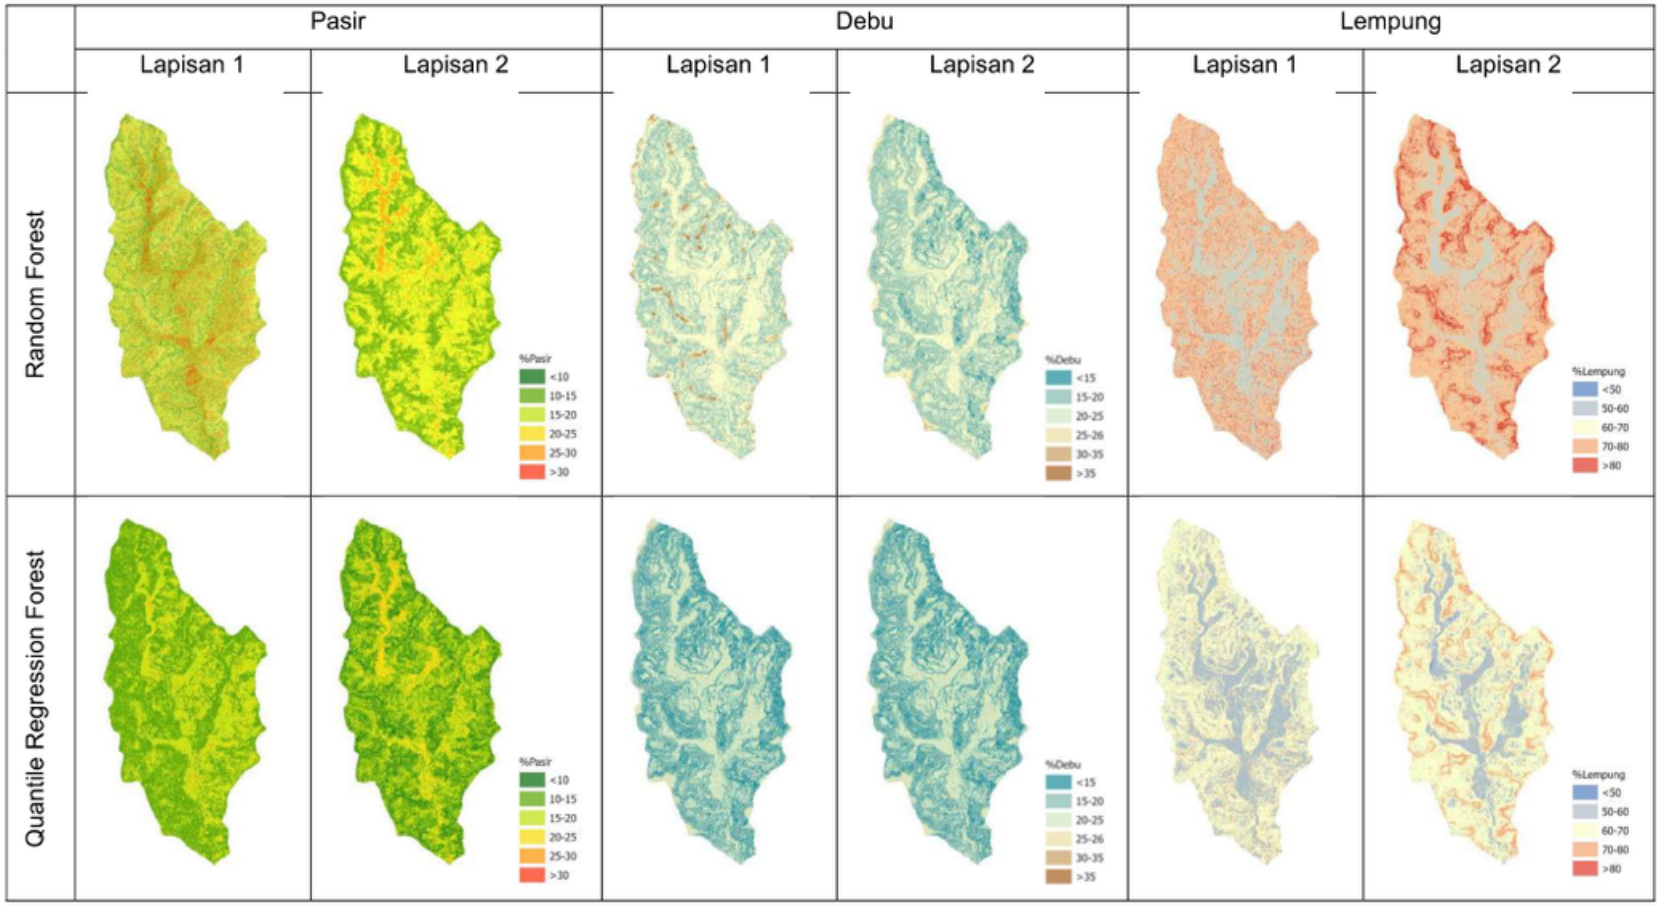

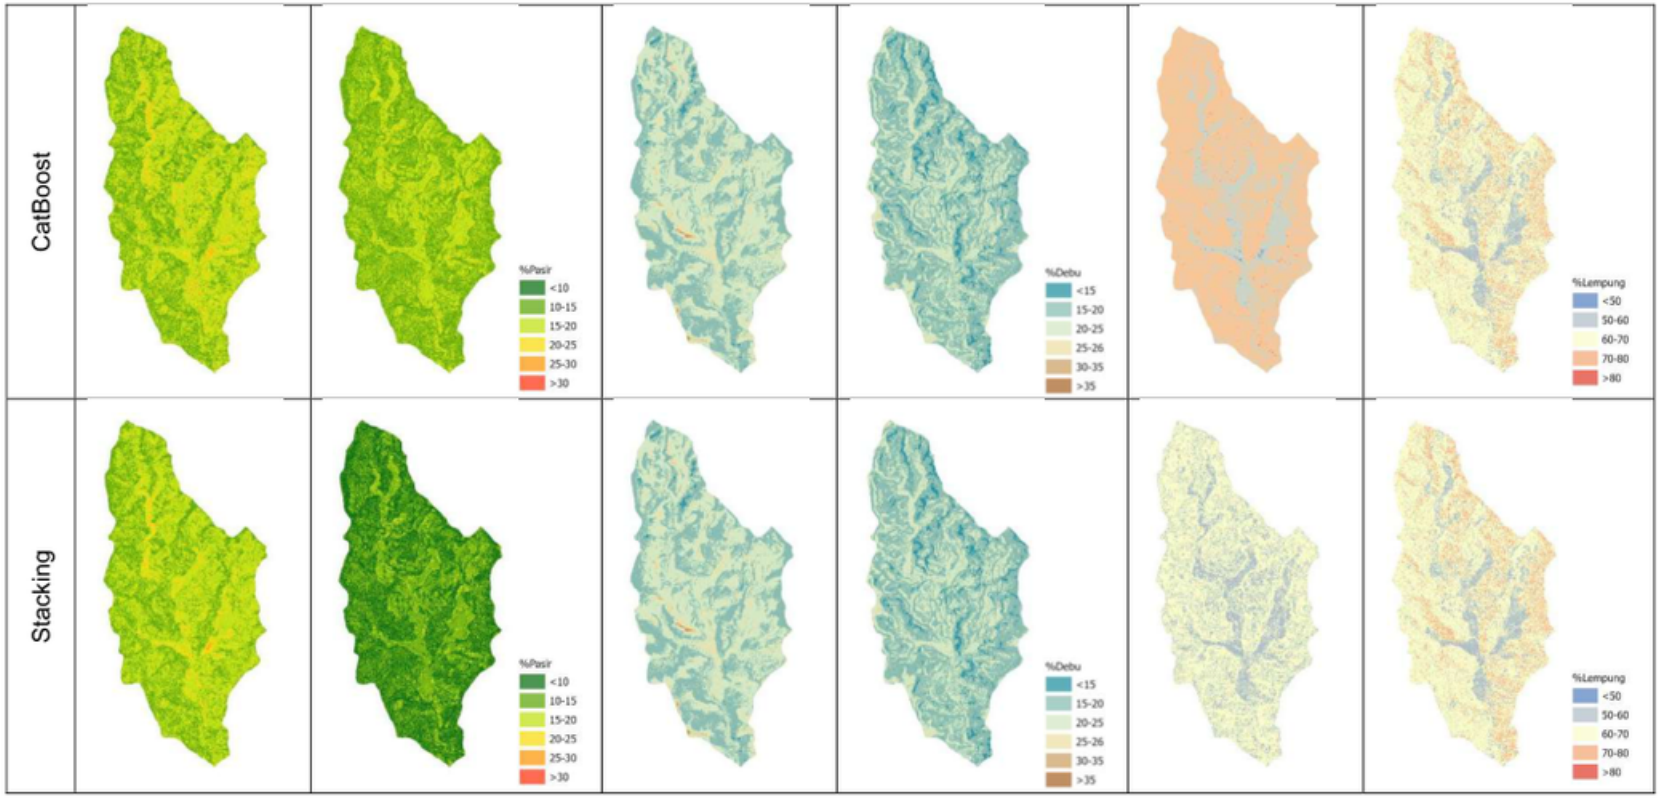
CatBoost
Stacking
%Pasir
<10
10-15
15-20
20-25
25-30
>30
%Debu
<15
15-20
20-25
25-26
30-35
>35
%Lempung
<50
50-60
60-70
70-80
>80

Lampiran 2. Perbandingan Peta Prediksi Fraksi Pasir, Debu, dan Lempung dengan Metode RF, QRF, CatBoost, dan Stackin dengan Resampling SMOGN

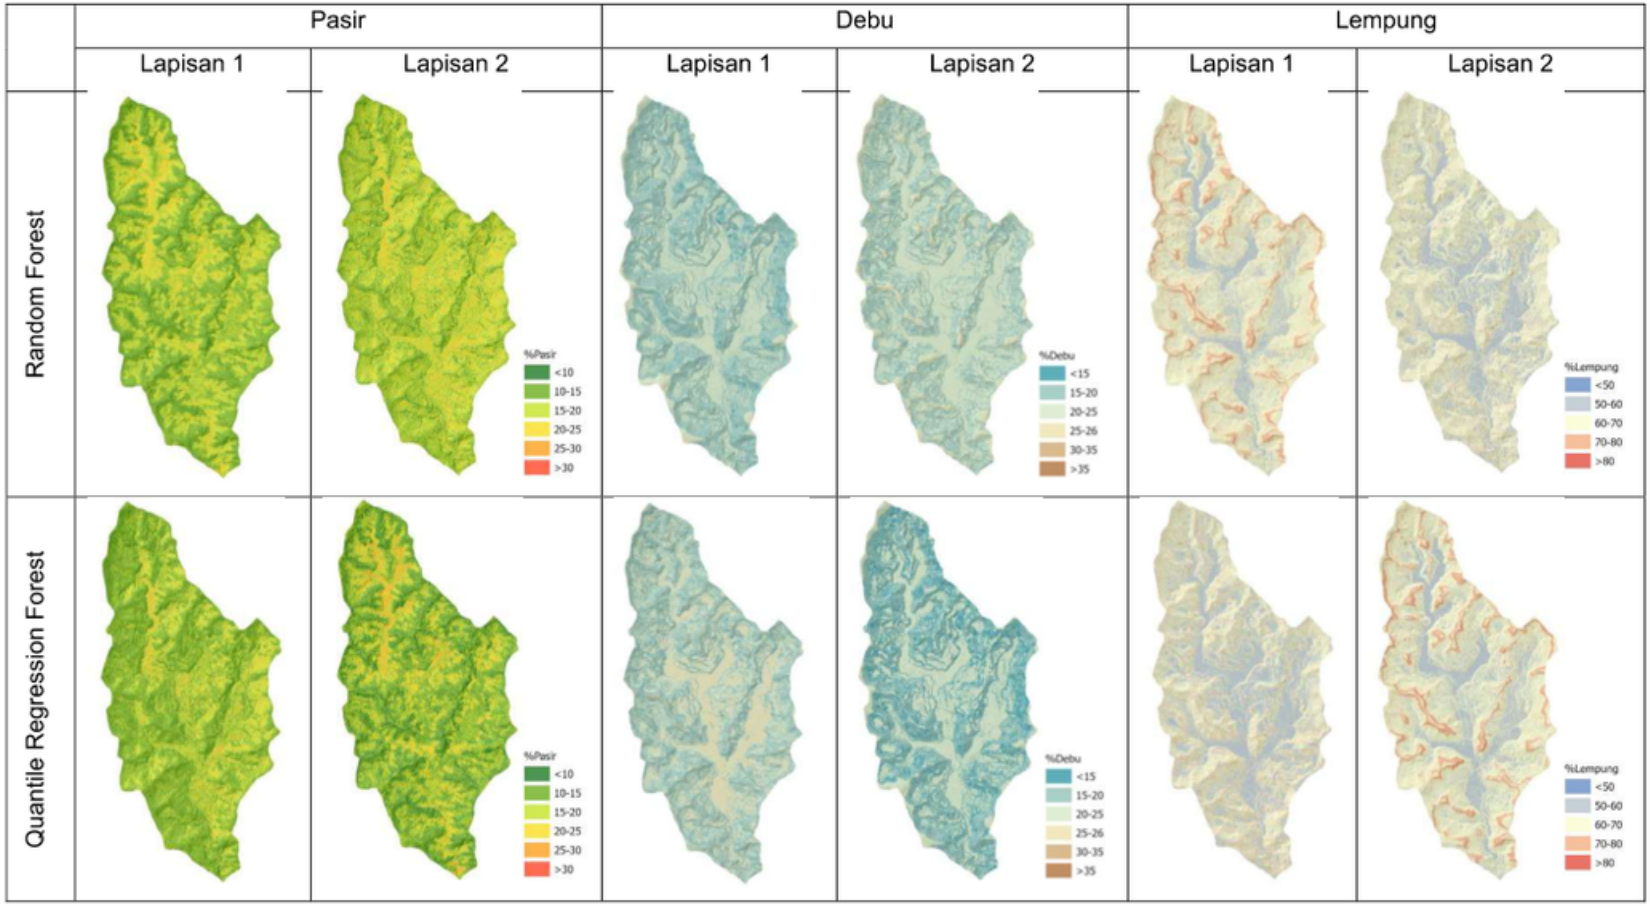

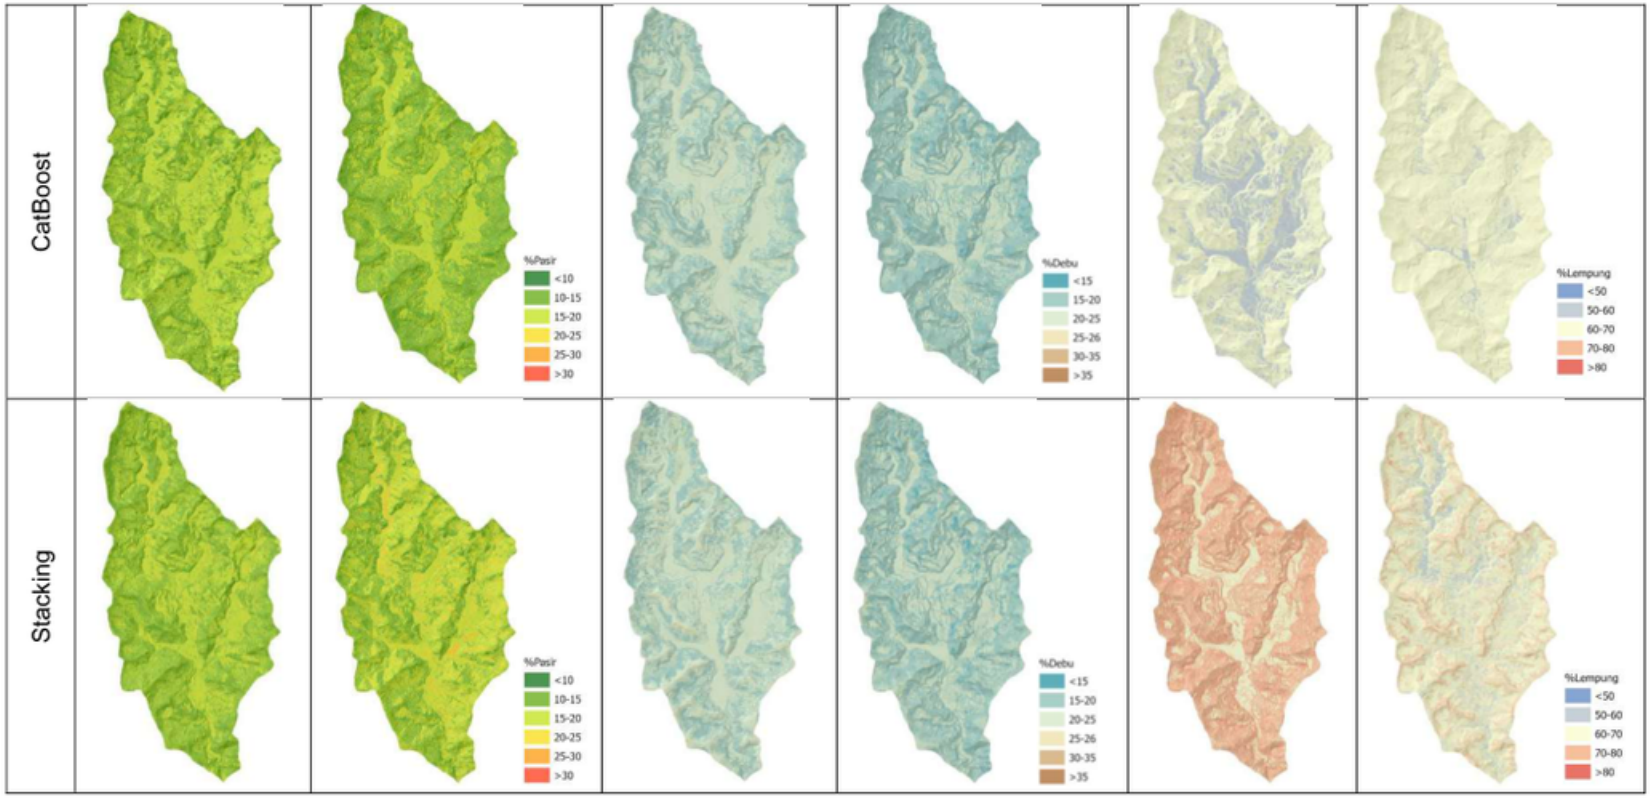
CatBoost
Stacking
%Pasir
<10
10-15
15-20
20-25
25-30
>30
%Debu
<15
15-20
20-25
25-26
30-35
>35
%Lempung
<50
50-60
60-70
70-80
>80

Lampiran 3. Statistik Fraksi Tanah Berdasarkan Material Tutupan

Material Tutupan	Pasir Lapisan 1					Pasir Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Breksi andesit sisipan diorit	7,08	31,44	16,09	2,70	16,76	8,13	29,12	14,74	2,33	15,77
Breksi andesit teralterasi	7,17	31,18	15,92	2,58	16,21	7,37	30,01	14,90	2,34	15,67
Breksi andesit teralterasi, ditumpangi lapukan batupasir Menoreh	7,38	32,21	17,01	2,79	16,38	7,40	29,47	15,00	2,51	16,75
Breksi vulkanik	7,08	29,69	15,52	2,48	15,98	8,13	28,69	14,91	2,36	15,86
Endapan material Sumbing Muda, pasir tufan, tuff pasiran, dan breksi andesit	7,15	32,23	16,86	2,78	16,49	7,16	29,16	15,17	2,39	15,75
Endapan Sumbing Muda dan endapan material longsor	7,05	33,67	**18.64**	2,91	15,63	8,26	30,02	**17.20**	2,24	13,04
Tuff pasiran	7,23	30,57	15,40	2,41	15,67	8,50	29,20	14,60	2,14	14,67

Material Tutupan	Debu Lapisan 1					Debu Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Breksi andesit sisipan diorit	14,68	30,09	20,33	1,38	6,81	12,05	29,07	18,59	2,50	13,47
Breksi andesit teralterasi	15,61	40,14	20,55	1,71	8,30	10,72	36,52	19,13	2,44	12,73
Breksi andesit teralterasi, ditumpangi lapukan batupasir Menoreh	12,45	37,17	20,57	1,60	7,77	11,80	32,58	18,68	2,61	13,98
Breksi vulkanik	14,82	40,39	20,88	1,72	8,22	10,75	35,32	19,28	2,35	12,20
Endapan material Sumbing Muda, pasir tufan, tuff pasiran, dan breksi andesit	12,23	33,25	20,60	1,58	7,68	11,52	31,98	18,60	2,71	14,54
Endapan Sumbing Muda dan endapan material longsor	16,94	27,02	**22.79**	1,33	5,86	11,83	27,15	**21.42**	2,51	11,71
Tuff pasiran	12,52	28,17	20,43	1,55	7,57	10,09	32,22	19,18	2,18	11,37

Material Tutupan	Lempung Lapisan 1					Lempung Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Breksi andesit sisipan diorit	40,18	79,81	62,76	4,71	7,50	52,34	78,46	66,53	3,85	5,79
Breksi andesit teralterasi	39,38	80,92	62,89	4,87	7,75	45,48	81,74	66,14	3,94	5,95
Breksi andesit teralterasi, ditumpangi lapukan batupasir Menoreh	39,93	80,54	62,47	4,94	7,91	46,08	80,89	65,88	4,02	6,11
Breksi vulkanik	39,38	80,74	62,97	4,71	7,48	46,88	79,22	**66.05**	3,90	5,90
Endapan material Sumbing Muda, pasir tufan, tuff pasiran, dan breksi andesit	39,50	80,42	62,75	4,60	7,32	45,55	79,14	65,69	3,96	6,03
Endapan Sumbing Muda dan endapan material longsor	40,46	79,50	58,10	3,69	6,36	44,85	78,78	62,45	4,42	7,08
Tuff pasiran	39,50	80,63	**63.43**	4,55	7,18	45,41	79,88	65,89	3,74	5,67

Lampiran 4, Statistik Fraksi Tanah Berdasarkan Bentuklahan

Bentuklahan	Pasir Lapisan 1					Pasir Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Interfluve	7,37	31,47	15,72	2,55	16,23	8,13	28,56	14,27	2,05	14,35
Lereng Atas Perbukitan	7,47	32,21	16,12	2,65	16,44	7,97	28,02	14,36	2,21	15,40
Lereng Tengah Perbukitan	7,08	32,23	16,37	2,76	16,85	7,16	29,47	15,13	2,39	15,79
Lereng Bawah Perbukitan	7,08	32,21	16,34	2,75	16,82	7,40	30,02	15,51	2,43	15,69
Lereng Kaki Koluvial	7,05	33,23	18,00	3,13	17,42	8,63	29,49	16,92	2,49	14,70
Dataran Koluvial	8,35	33,67	**18.61**	2,78	14,93	8,26	30,03	**17.14**	2,09	12,19

Bentuklahan	Debu Lapisan 1					Debu Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Interfluve	14,53	40,14	21,27	2,19	10,28	11,67	33,56	19,22	2,62	13,66
Lereng Atas Perbukitan	13,78	40,39	20,64	1,72	8,31	10,72	36,52	18,55	2,31	12,43
Lereng Tengah Perbukitan	12,23	34,25	20,39	1,42	6,99	10,24	34,71	18,82	2,46	13,09
Lereng Bawah Perbukitan	12,45	28,09	20,50	1,41	6,86	10,09	28,93	19,18	2,60	13,57
Lereng Kaki Koluvial	15,12	27,02	21,96	1,53	6,98	11,94	27,15	**21.30**	2,54	11,90
Dataran Koluvial	16,70	26,69	**23.00**	1,31	5,72	11,83	26,70	21,27	2,59	12,16

Bentuklahan	Lempung Lapisan 1					Lempung Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Interfluve	40,18	79,47	62,86	4,84	7,70	50,12	79,35	66,86	4,12	6,16
Lereng Atas Perbukitan	39,38	80,75	**63.09**	5,12	8,12	46,49	80,53	**67.41**	3,70	5,49
Lereng Tengah Perbukitan	39,38	80,92	62,92	4,68	7,44	45,48	79,88	65,75	3,73	5,68
Lereng Bawah Perbukitan	39,38	80,75	62,63	4,53	7,23	45,09	81,74	64,68	3,77	5,83
Lereng Kaki Koluvial	40,44	80,75	59,20	4,11	6,94	44,85	80,60	61,02	4,36	7,14
Dataran Koluvial	42,42	80,08	57,91	3,62	6,25	49,56	78,78	64,04	3,81	5,94

Lampiran 5, Statistik Fraksi Tanah Berdasarkan Penggunaan Lahan

Penggunaan Lahan	Pasir Lapisan 1					Pasir Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Agroforestri	7,16	29,16	14,72	2,28	15,46	7,05	32,21	16,11	2,70	16,74
Permukiman	8,25	29,47	16,26	2,43	14,93	7,27	32,23	16,71	2,69	16,12
Sawah	8,26	30,03	**17.19**	2,27	13,19	7,42	33,67	**18.66**	2,88	15,44
Tegalan	8,25	29,04	14,77	2,26	15,29	7,56	30,54	16,03	2,57	16,06

Penggunaan Lahan	Debu Lapisan 1					Debu Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Agroforestri	12,45	40,39	20,56	1,66	8,08	10,09	36,52	18,77	2,43	12,96
Permukiman	14,89	34,25	20,96	1,46	6,96	11,80	34,71	19,84	2,66	13,39
Sawah	14,67	26,86	**22.63**	1,45	6,43	11,82	27,29	**21.37**	2,57	12,04
Tegalan	12,23	32,05	20,29	1,69	8,33	10,64	33,71	18,86	2,62	13,90

Penggunaan Lahan	Lempung Lapisan 1					Lempung Lapisan 2				
	Min	Max	Mean	STD	CV	Min	Max	Mean	STD	CV
Agroforestri	39,38	80,92	63,06	4,73	7,51	45,40	81,74	**66.14**	3,87	5,86
Permukiman	39,50	80,63	61,77	4,57	7,40	46,54	79,14	65,06	3,93	6,04
Sawah	42,57	80,75	58,13	3,72	6,40	45,02	80,60	62,45	4,43	7,10
Tegalan	40,05	80,29	**63.13**	4,96	7,86	44,85	78,64	65,95	4,15	6,30